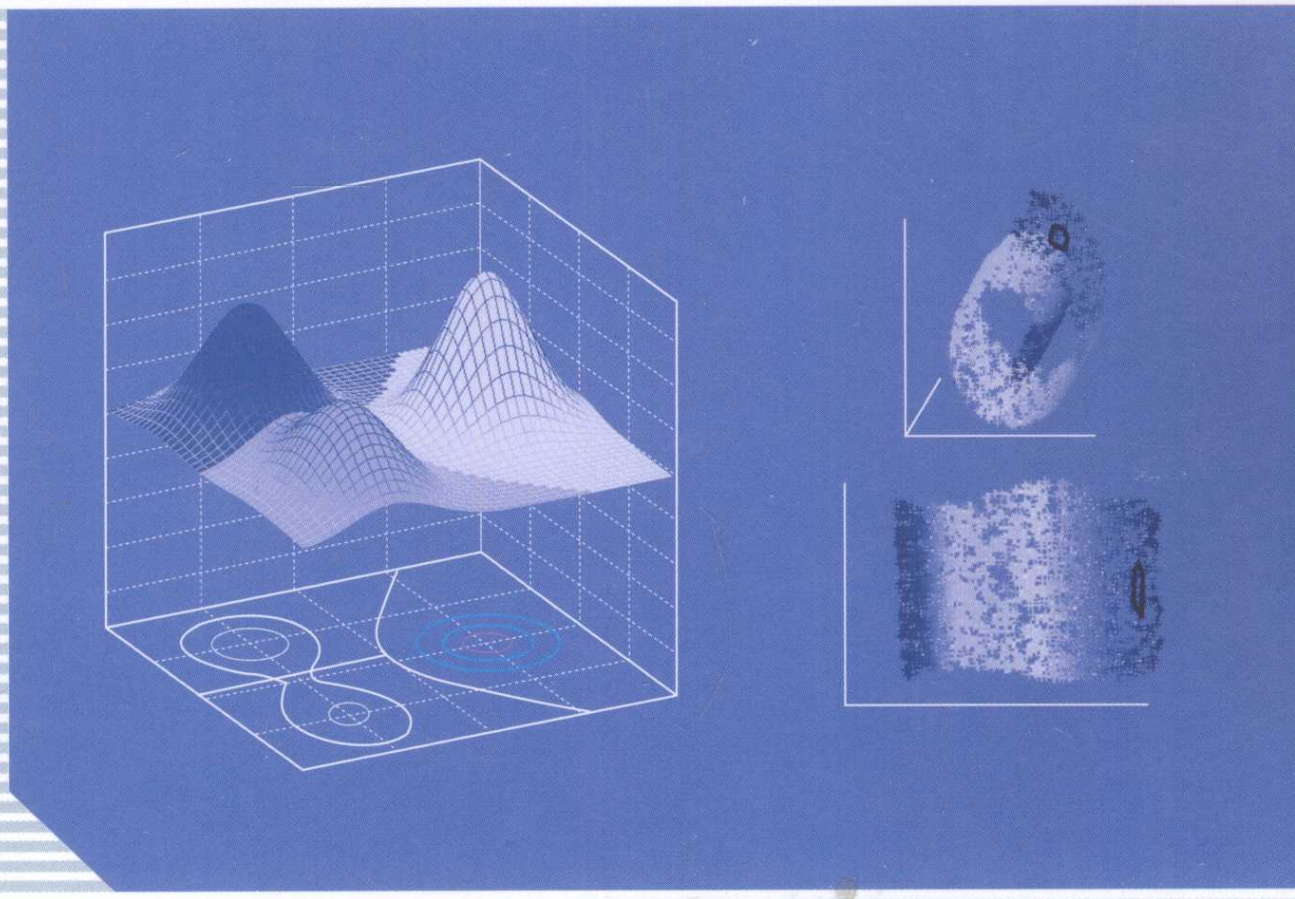
模式识别

Pattern Recognition

孙即祥 姚伟 滕书华 编著



国防工业出版社
National Defense Industry Press

责任编辑：郑　廷　tzheng@ndip.cn
　　王　鑫　xwang@ndip.cn
责任校对：钱辉玲
封面设计：慧　籽

模式识别

▶ 上架建议：通信、电子 ◀
http://www.ndip.cn
ISBN 978-7-118-06433-9
9 787118 064339 >
定价：22.00 元

模式识别

孙即祥　姚 伟　滕书华　编著

国防工业出版社

·北京·

图书在版编目(CIP)数据

模式识别/孙即祥,姚伟,滕书华编著. —北京:国防工业出版社,2009.11

ISBN 978-7-118-06433-9

Ⅰ. 模… Ⅱ. ①孙…②姚…③滕… Ⅲ. 模式识别 Ⅳ. 0235

中国版本图书馆 CIP 数据核字(2009)第 115821 号

※

国防工业出版社出版发行

(北京市海淀区紫竹院南路 23 号 邮政编码 100048)

北京四季青印刷厂印刷

新华书店经售

*

开本 880×1230 1/32 印张 9⅛ 字数 260 千字

2009 年11月第 1 版第 1 次印刷 印数 1—5000 册 定价 22.00 元

(本书如有印装错误,我社负责调换)

国防书店:(010)68428422 发行邮购:(010)68414474

发行传真:(010)68411535 发行业务:(010)68472764

前　言

分类识别是人们最重要的基本活动之一，在人们的日常生活、社会活动、科研生产以及学习、工作中无时无处不在进行着分类识别。模式识别是研究分类识别理论和方法的科学，是一门综合性、交叉性学科。在理论上它涉及代数学、矩阵论、函数论、随机数学、模糊数学、图论、最优化理论、信号处理、计算机科学、神经物理学等众多学科的知识，在应用上又与其他许多领域知识及工程技术密切相关。自20世纪80年代以来，它受到了学术界和各应用领域的极大重视，计算机软、硬件技术的日臻成熟及其他相关学科的迅速发展更使它成为理论研究和技术开发的热门学科。

本书是一本关于模式识别理论和方法的教材，在撰写过程中遵循以下原则：在结构安排上尽量使知识表达体系与学科本身的体系相一致；在内容阐述方式上遵循人的认知规律；在选材上尽量满足读者掌握基础的学科知识。我们的目标就是使本书可读性好、学术性强、实用价值大。本书具有下述的特点。

(1)内容广泛。模式识别是一门相当活跃的重要学科，其发展非常迅速，所涉及的理论十分广泛、方法十分丰富，新理论、新方法、新技术、新应用不断涌现。本书系统地阐述了模式识别领域的基础知识及经典方法，对经实践证明有重要现实意义的新理论、新方法和新技术也进行了介绍。本书包括统计模式识别、模糊模式识别、神经网络技术、人工智能等方法。

(2)结构清晰合理。学科知识的组织结构是否得当将会直接影响读者的学习效果，合理清晰的学科知识表述体系有益于读者对各种理论、方法的理解和记忆。本书处理好模式识别知识点的布局，全书及各章节都尽量按由浅入深、先易后难、先具体后抽象来安排。

(3)选材考究精细。如前所述,这门学科的各种理论、方法、技术纷繁众多,而且还在不断地出现和发展。本书在众多的知识中选取了那些具有基础理论性、思维训练性及有效实用性的重要内容,并且注意处理好本书内容与其他学科知识的关系。

(4)注重基础。打好基础是教育经验的总结,也是科技高速发展的需要,本书自始至终都非常注重强化基本概念、基本思想、基础理论、基本方法和基本技能。

(5)详略得当。由于本书涉及的知识面广,所以必须在论述上有详有略,详略得当。对于统计模式识别等基础的经典内容,详细叙述其基本的、重要的理论和方法;而对于模糊模式识别、神经网络等技术,则重点介绍其思想概念,让读者对其有所了解。这样既实现了知识在面上的宽广,又达到了知识点处的理论深度。

与模式识别直接密切相关的课程是矩阵论、概率论与数理统计、最优化理论与方法等。读者只要具备一些必要的理论基础和相关基本知识便可以顺利地学完每一章的主要内容。对于希望深入学习的读者,则应先行修完上述课程,并根据本书提供的参考文献参阅其他相关的资料。

由于模式识别是一门不断发展的学科,新的理论、方法和技术、新的应用成果不断涌现,再加上我们的学识水平及时间有限,本书可能没有完全达到我们所希望的目标,也不可避免地存在各种错误和疏漏,敬请读者给予批评指正。

作　者

2009 年 7 月于国防科技大学

目　录

第1章　引论 …… 1

1.1　概述 …… 1

1.1.1　模式识别的概念 …… 1

1.1.2　模式识别系统 …… 2

1.1.3　模式识别的基本方法 …… 4

1.2　特征矢量和特征空间 …… 6

1.3　随机矢量的描述 …… 7

1.4　正态分布 …… 12

1.4.1　正态分布的定义 …… 12

1.4.2　多元正态分布的性质 …… 14

第2章　聚类分析及最近邻方法 …… 19

2.1　聚类分析的概念 …… 19

2.1.1　聚类分析的基本思想 …… 19

2.1.2　特征量 …… 20

2.1.3　方法的有效性 …… 20

2.2　模式相似性测度 …… 22

2.2.1　距离测度(差值测度) …… 23

2.2.2　相似测度 …… 26

2.2.3　匹配测度 …… 28

2.3　类间距离 …… 30

2.3.1 类间距离测度方法 …… 30
2.4 准则函数 …… 32
2.4.1 点与集合间的距离 …… 32
2.4.2 聚类的准则函数 …… 35
2.5 聚类的算法 …… 39
2.5.1 聚类的技术方案 …… 39
2.5.2 基于相似性阈值的简单聚类方法 …… 39
2.5.3 谱系聚类法 …… 42
2.5.4 动态聚类法(Dynamic clustering algorithm) …… 46
2.5.5 近邻函数法 …… 55
2.6 最近邻方法 …… 58
2.6.1 最近邻法 …… 59
2.6.2 剪辑最近邻法 …… 59
2.6.3 引入拒绝类别决策的最近邻法 …… 62
习题 …… 63
算法编程 …… 66

第3章 判别域代数界面方程法 …… 69

3.1 判别域界面方程分类的概念 …… 69
3.2 线性判别函数 …… 70
3.2.1 两类问题 …… 71
3.2.2 多类问题 …… 71
3.3 判别函数值的鉴别意义、权空间及解空间 …… 77
3.3.1 判别函数值的大小、正负的数学意义 …… 77
3.3.2 权空间、解矢量与解空间 …… 79
3.4 Fisher 线性判别 …… 81
3.5 线性可分条件下判别函数权矢量算法 …… 86
3.5.1 感知器算法 …… 86

3.5.2 一次准则函数及梯度下降法 …… 89
3.5.3 感知器训练算法在多类问题中的应用 …… 92
3.6 一般情况下的判别函数权矢量算法 …… 94
3.6.1 分段二次准则函数及共轭梯度法 …… 95
3.6.2 最小平方误差准则及 W－H 算法 …… 97
3.6.3 H－K(Ho－Kashyap)算法 …… 99
3.7 广义线性判别函数 …… 102
3.8 二次判别函数 …… 105
3.9 位势函数分类法 …… 106
3.9.1 位势函数的概念 …… 106
3.9.2 由位势函数产生判别函数的训练算法及分类规则 … 108
3.10 支持矢量机简介 …… 111
习题 …… 115
算法编程 …… 116

第4章 统计判决 …… 118

4.1 最小误判概率准则判决 …… 119
4.1.1 最小误判概率准则判决的一般形式 …… 119
4.1.2 正态模式最小误判概率判决规则的具体形式 …… 125
4.1.3 正态模式分类的误判概率 …… 130
4.2 最小损失准则判决 …… 134
4.2.1 损失概念、损失函数与平均损失 …… 134
4.2.2 最小损失准则判决 …… 136
4.3 最小最大损失准则 …… 140
4.4 N－P(Neyman－Pearson)判决 …… 144
4.5 序贯判决(SPRD) …… 149
4.5.1 控制误判概率的序贯判决 …… 150
4.5.2 计入提取特征代价的最小损失准则下的序贯

判决 …… 154
习题 …… 155
算法编程 …… 161

第5章 统计决策中的经典学习方法 …… 164

5.1 统计推断概述 …… 164
5.2 参数估计 …… 166
5.2.1 均值矢量和协方差阵的矩法估计 …… 166
5.2.2 最大似然估计(MLE) …… 169
5.2.3 贝叶斯估计(BE) …… 171
5.2.4 最大似然估计和贝叶斯估计的性能比较 …… 173
5.3 贝叶斯学习 …… 174
5.4 概密的窗函数估计法 …… 178
5.4.1 概密的基本估计式 …… 178
5.4.2 Parzen 窗法 …… 180
5.4.3 k_N—近邻估计法 …… 181
5.4.4 后验概率的估计 …… 182
5.5 有限项正交函数级数逼近法 …… 183
5.5.1 最小积分平方差逼近方法 …… 183
5.5.2 最小均方差逼近方法 …… 186
5.6 用位势函数法逼近贝叶斯判决函数 …… 187
5.7 错误率估计 …… 189
5.7.1 分类器错误率的实验估算基本原理 …… 189
5.7.2 样本抽取方式对误判概率估计的影响 …… 190
5.7.3 训练与测试样本集的大小对错误率的影响 …… 191
5.7.4 训练样本使用技术及错误率的测试方法 …… 192
习题 …… 193
算法编程 …… 197

第 6 章　特征提取与选择 …… 201

6.1　概述 …… 201
6.2　类别可分性判据 …… 202
6.2.1　基于几何距离的可分性判据 …… 203
6.2.2　基于类的概率密度函数的可分性判据 …… 207
6.2.3　基于后验概率的可分性判据 …… 209
6.3　基于可分性判据进行变换的特征提取 …… 211
6.3.1　基于离差阵的特征提取 …… 211
6.3.2　多类情况 …… 213
6.3.3　基于熵概念的某些特征提取与选择方法 …… 214
6.4　最佳鉴别矢量的提取 …… 214
6.4.1　Fisher 鉴别矢量及鉴别平面 …… 215
6.4.2　最佳鉴别矢量集 …… 217
6.5　离散 K－L 变换及其在特征提取与选择中的应用 …… 218
6.5.1　离散 K－L 变换(DKLT) …… 219
6.5.2　离散 K－L 变换在特征提取与选择中的应用 …… 223
6.6　特征选择中的直接挑选法 …… 230
6.6.1　次优搜索法 …… 230
6.6.2　最优搜索法 …… 233
习题 …… 235

第 7 章　其他模式识别方法 …… 238

7.1　模糊模式识别 …… 238
7.1.1　模糊数学基础知识 …… 238
7.1.2　模糊模式识别的基本方法 …… 244
7.2　神经网络在模式识别中的应用 …… 246
7.2.1　人工神经网络的基本知识 …… 246

7.2.2 常见的神经网络模型 …… 250
7.3 句法模式识别 …… 253
7.3.1 句法模式识别概述 …… 253
7.3.2 形式语言介绍 …… 254
7.3.3 句法模式识别的基本内容 …… 259
7.4 信息融合 …… 260
7.4.1 信息融合概述 …… 260
7.4.2 融合技术层次性及融合系统功能模块和结构 …… 261
7.5 树分类器 …… 268
7.5.1 树分类器原理及设计原则 …… 269
7.5.2 树分类器关键技术 …… 270
7.5.3 决策树生成算法 …… 271
习题 …… 276

参考文献 …… 278

第1章 引 论

1.1 概 述

1.1.1 模式识别的概念

人们在日常生活、社会活动、科研生产以及学习、工作中无时无处不在进行着分类识别，分类识别是人类的基本活动之一。例如，儿童在认读识字卡片上的数字时，将它们区分为0～9中的一个，这是对数字符号的识别；在读书看报时，人们进行的是文字识别活动；做某种实验时对示波器显示波形的观察是一个波形识别过程；医生给患者诊断疾病需要对病情进行识别；在人群中寻找某一个人是对人的形体及其他特征的识别行为。随着人类社会活动及生产科研广泛而深入的发展，需要识别的对象种类越来越多，内容越来越深入和复杂，要求也越来越高，为了改善工作条件、减轻工作强度，人们希望机器能代替人类完成某些繁重的识别工作；有些场合环境恶劣、存在危险或人们根本就不能接近，这就需要借助机器、运用分析算法进行识别。人们利用机器可以提高识别的速度、正确率及扩大应用的广度。我们这里所说的模式识别是指运用机器进行分类识别。模式识别的重要应用之一是计算机自动诊断疾病。与医生的诊断过程相仿，首先要获得就诊人的有关情况，如要测量体温、血压、心率，还可能对血液等进行化验，作X光透视、B超、心电图，甚至CT等。医生根据这些量测结果以及病人的病史等资料，运用自己的临床经验对患者进行诊断。而机器识别是将上述各种有用的资料信息输入计算机中，在这之前计算机已装入有关的分析算法，这些算法是专家知识、经验的总结和集成，其形式可以是规则、函数、数表等，通过计算机程序对信息进行分析并作出判断。

下面首先较详细地介绍模式和模式识别这两个基本概念。为了能

让机器执行和完成分类识别任务，必须首先将分类识别对象的有用的信息输入计算机中，为此，应对分类识别对象进行科学的抽象，建立它的数学模型，用以描述和代替识别对象，称这种对象的描述为模式(Pattern)。Pattern 的原义是模范、模型、典型、样品、图案等，其内涵深刻、外延广泛。无论是自然界中物理、化学或生物等领域的对象，还是社会中的语言、文字等，都可以进行科学的抽象，具体地讲，我们对它们进行量测，得到表征它们特征的一组数据，为使用方便，将它们表示成矢量形式，称其为特征矢量；也可以将对象的特征属性作为基元、用符号表示，从而将它们的结构特征描述成一个符号串、图或某个数学式子。通俗地讲，模式就是事物的代表，是事物的数学模型之一，它的表示形式是矢量、符号串、图或数学关系。对一类对象的抽象也称为该类的模式。

所谓模式识别(Pattern Recognition)，是根据研究对象的特征或属性，利用以计算机为中心的机器系统，运用一定的分析算法认定它的类别，系统应使分类识别的结果尽可能地符合真实。

目前，模式识别理论和技术已成功地应用于工业、农业、金融、军事、公安、科研、生物医学、气象、天文学等许多领域，如我们熟知的信件分拣、遥感图片的机器判读、系统的故障诊断、生物特征识别(指纹、虹膜、脸等识别)、生物医学的细胞或组织分析、具有视觉的机器人、武器制导寻的系统、汽车自动驾驶系统以及文字与语言的识别等，并且现在正扩展到许多其他领域。当今时代科技发展的重要趋势之一是智能化，模式识别是人工智能的一个分支。尽管现在机器识别的水平还远不如人脑，但随着模式识别理论以及其他相关学科的发展，可以预言，它的功能将会越来越强大，应用也会越来越广泛。

1.1.2 模式识别系统

一个功能较完善的识别系统在进行模式识别之前，首先需要进行学习。模式识别系统及识别过程的原理框图可以用图 1.1.1 表示。虚线的上部是分类、识别过程，虚线的下部是学习、训练过程。需要指出的是，应用的目的不同、采用的分类识别方法不同，具体的分类识别系统和过程将会有所不同。一般而言，特征提取与选择、训练学习、分类

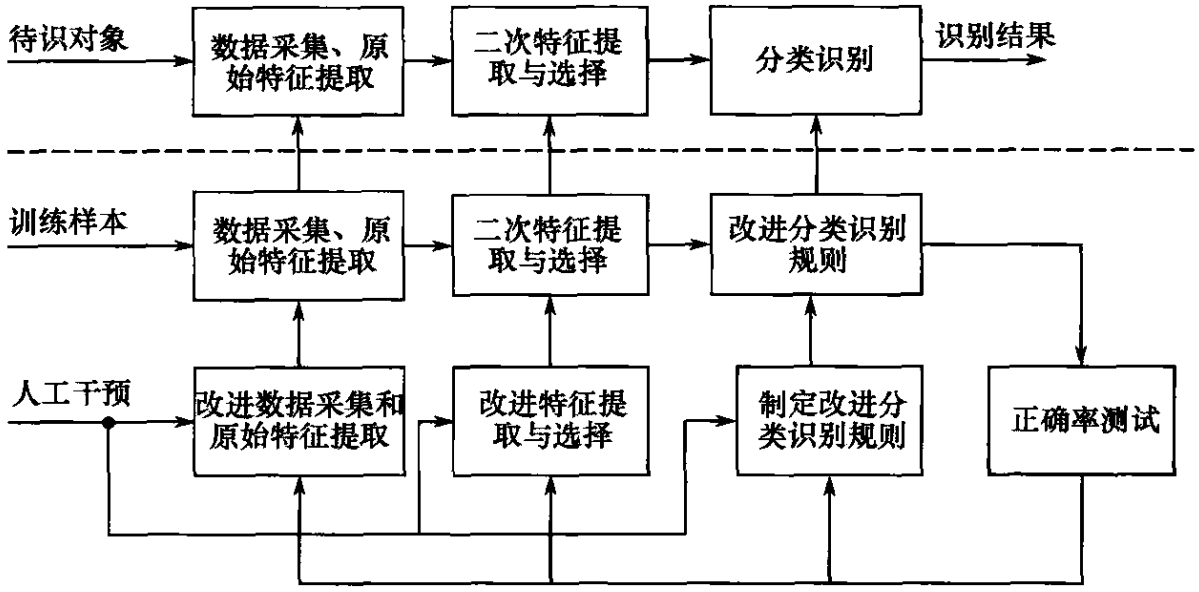


图 1.1.1　模式识别系统及识别过程的原理框图

识别是任何模式识别方法或系统的三大核心问题。

下面对识别系统的主要环节作简要的说明。

1. 特征提取

无论是识别过程还是学习过程，都要对研究对象固有的、本质的及重要的特征或属性进行量测并将结果数值（字）化，或将对象分解并符号化，形成特征矢量或符号串、关系图，从而产生代表对象的模式，模式类中的个体在有些场合中也称为样本。用于学习与训练的样本的类别通常是已知的。另外，在进行特征提取之前一般还需要对目标的有关信息进行预处理。

2. 特征选择

通常能描述对象的特征或属性的种类很多，为了节约资源，节省计算机存储空间、运算时间、特征提取的费用，有时更是为了算法的可行性，在满足分类识别正确率要求的条件下，按某种准则尽量选用对正确分类识别作用较大的特征，使得用较少的特征就能完成分类识别任务。这项工作表现为减少特征矢量的维数、符号串字符数或简化图的结构。

3. 学习和训练

为让机器具有分类识别功能，如同人类自身一样，人们应首先对它进行训练，将人类的识别知识和方法以及关于分类识别对象的知识输入机器中，产生分类识别的规则和分析程序，这也相当于机器进行学

习。这个过程一般要反复进行多次，不断地修正错误、改进不足，这包括修正特征提取方法、特征选择方案、判决规则方法及参数，最后使系统正确识别率达到设计要求。目前，机器学习常需要人工干预，这个过程通常是人机交互的。

4. 分类识别

在学习、训练之后，所产生的分析规则及程序用于未知类别的对象的分类识别。需要指出的是，输入机器的人类分类识别的知识和方法以及有关对象知识越充分，这个系统的识别功能就越强、正确率就越高，有些分类过程（如聚类分析）似乎没有将有关对象的知识输入，实际上我们在选择距离测度、在采用某种聚类方法时，已经隐含地用到了对象的一些知识，也在一定程度上加入了人们的知识。

1.1.3 模式识别的基本方法

由于分类识别活动是人们的基本活动，人们希望机器能代替人们进行分类识别工作，因此模式识别的理论和方法引起人们极大的兴趣并进行了长期的深入研究，现已发展成一门多学科的交叉学科。这门学科涉及的理论与技术相当广泛，包括多种数学理论、神经心理学、计算机科学、信号处理等。从本质上讲，这门学科实际上是数据处理与信息分析；从功能上讲，可以认为它是人工智能的一个分支。

针对不同的对象和不同的目的，可以运用不同的模式识别理论、方法，目前主流的技术是统计模式识别、句法模式识别、模糊模式识别、人工神经网络方法、人工智能方法、子空间方法，它们之间往往存在一定的联系和借鉴。

1. 统计模式识别

这类识别技术理论较完善，方法也很多，通常较为有效，现已形成了一个完整的体系。尽管方法很多，但从根本上讲，都是直接利用各类的分布特征，即利用各类的概率密度函数、后验概率等，或隐含地利用上述概念进行分类识别。其中基本的技术为聚类分析法、判别类域代数界面法、统计决策法、最近邻法等。在聚类分析中，利用待分类模式之间的“相似性”进行分类，较相似的作为一类，较不相似的不作为一类。在分类过程中不断地计算所分划的各类的中心，待分类模式与各

类中心的距离作为对其分类的依据。这实际上是在某些设定下隐含地利用了概率分布概念，因常见的概率密度函数中，距期望值较近的点概密值较大。该类方法的另一种技术是根据待分类模式和已指判出类别的模式的距离来确定其类别，这实际上也是在一定程度上利用了有关的概念。最近邻法是根据待分类模式的一个或 k 个近邻训练样本的类别而确定其类别。判别类域界面法中，用已知类别的训练样本产生判别函数，这相当于学习或训练，根据待分类模式代入判别函数后所得值的正负确定其类别，判别函数提供了相邻两类判别域的界面，其也相应于在一些设定下两类概密函数之差。在统计判决中，在一些分类识别准则下严格地按照概率统计理论导出各种判决规则，这些判决规则可以产生某种意义上的最优分类识别结果，这些判决规则要用到各类的概率密度函数、先验概率或后验概率。这可以通过训练样本对未知概密函数中的参数进行估计，或对未知的概密函数进行逼近而估计它们。

2. 句法模式识别

句法模式识别也称为结构模式识别。在许多情况下，对于较复杂的对象仅用一些数值特征已不能较充分地对其描述与正确识别，这时可采用句法识别技术。句法识别技术是将对象分解成若干个基本单元，这些基本单元称为基元，用这些基元以及它们的结构关系来表征对象，基元以及这些基元的结构关系可以用字符串或图来表示，这些字符串或图进一步抽象为语言的句子，然后根据代表类的文法运用形式语言理论对该句子进行句法分析，根据其是否符合某一类的文法而决定其类别。

3. 模糊模式识别

这类识别技术运用模糊数学的理论和方法解决模式识别问题，因此适用于分类识别对象本身或要求的识别结果具有模糊性的场合。模糊模式识别方法的基本思想是，将模式或模式类作为模糊集，将模式的属性值或属性转化为隶属度，运用隶属度、模糊关系或模糊推理进行分类识别。目前，模糊识别方法较多。这类方法的有效性主要在于对象类的隶属函数建立得是否良好，对象间的模糊关系的度量是否良好。

4. 人工神经网络方法

人工神经网络是由大量简单的基本单元——神经元（Neuron）相

互联结而构成的非线性动态系统，每个神经元结构和功能比较简单，而由其构成的系统却可以非常复杂，具有生物神经网络的某些特性，在自学习、自组织、联想及容错方面具有较强的能力，可用于联想、识别和决策。在模式识别方面，与前述方法显著不同的特点之一是在学习过程中具有自动提取特征的能力。

5. 人工智能方法

众所周知，人类具有极完善的分类识别功能，人工智能是研究如何使机器具有人类智能的理论和方法，模式识别从本质上讲就是如何根据对象的特征进行类别的判断，因此可将人工智能中有关知识表示、推理、学习等技术用于模式识别。

6. 子空间方法

子空间方法是将代数学的基本理论与统计基本理论进行综合，这类方法的基本思想是，根据各类训练样本的相关阵通过线性变换由原始模式特征空间产生各类对应的子空间，这些子空间由原始模式类的样本相关阵的主要特征矢量所张成，这些主要特征矢量反映了模式分布结构信息，每个子空间与每个类别一一对应。在子空间方法中，主要的分类决策规则有基于投影长度的比较方法、基于表达熵的比较方法和基于统计假设检验的方法三个类型。基于投影的识别方法是根据待识模式在各个子空间的投影大小判定该模式类别。

上述的6类方法各有特点及其应用范围，现在来看，它们不能相互取代，只能共存，相互促进、借鉴、渗透及融合。除了上述的6类方法外，还有其他的一些类型方法，如协同模式识别方法等。一个较完善的识别系统很可能是综合利用上述各类识别方法的观点、概念和技术而构成的。

1.2 特征矢量和特征空间

设一个研究对象的 n 个特征量测值分别为 $x_1, x_2, \cdots, x_n$，由于它们来自同一个对象，所以应将它们作为一个整体一起考虑，为此，让它们构成一个 n 维特征矢量 $\boldsymbol{x}$，即 $\boldsymbol{x} = (x_1, x_2, \cdots, x_n)^{\mathrm{T}}$，$\boldsymbol{x}$ 是原对象的一种数学抽象，用其来代表原对象，即为原对象的模式。对某对象的分类识别

实际上是对它的模式即它的特征矢量进行分类识别。各种不同取值的 $\boldsymbol{x}$ 的全体构成了 n 维空间，这个 n 维空间称为特征空间，不同的场合特征空间可记为 X^n、R^n 或 Ω。特征矢量 $\boldsymbol{x}$ 便是特征空间中的一个点，所以特征矢量有时也称为特征点。

经验表明，对于同一个对象的某种特征进行多次量测所得的结果往往是不同的，对同一类不同对象的某一特征的量测结果一般也是按某种规律分布的，因此，同一个对象或同一类对象的某特征量测值是随机变量，这是由于量测系统随机因素的影响及同类不同对象的特征本身就是在特征空间散布的。由随机分量构成的矢量称为随机矢量，从而可知，同一类对象的特征矢量在特征空间中是按某种统计规律随机散布的。应该指出的是，不同类对象的某一特征的量测值或量测值统计特性有时可能是相同的，但如果特征选择适当，则特征矢量应有尽可能多的分量具有不同的统计特性。

1.3 随机矢量的描述

1. 随机矢量的分布函数

设 $\boldsymbol{X}=(X_1,X_2,\cdots,X_n)^{\mathrm{T}}$ 为随机矢量，$\boldsymbol{x}=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}$ 为确定性矢量。随机矢量 $\boldsymbol{X}$ 的联合概率分布函数定义为

$$F(x_1,x_2,\cdots,x_n)=P(X_1\leqslant x_1,X_2\leqslant x_2,\cdots,X_n\leqslant x_n) \tag{1-3-1}$$

式中：$P(\cdot)$ 表示括号中事件同时发生的概率。写成矢量形式，有

$$F(\boldsymbol{x})=P(\boldsymbol{X}\leqslant\boldsymbol{x}) \tag{1-3-2}$$

这里约定，一个矢量小于（或大于）另一个矢量是指它的每个分量均小于（或大于）另一个矢量的对应分量。随机矢量 $\boldsymbol{X}$ 的联合概率密度函数定义为

$$p(x_1,x_2,\cdots,x_n)\triangleq p(x)=\partial^n F(x_1,x_2,\cdots,x_n)/\partial x_1\partial x_2\cdots\partial x_n \tag{1-3-3}$$

设集合由 c 类模式组成，第 i 类记为 ω_i，ω_i 类模式特征矢量有其自

已的分布函数和密度函数。ω_i 类的模式特征矢量的分布函数及密度函数分别定义为

$$F(\boldsymbol{x}|\omega_i) = P(\boldsymbol{X} \leqslant \boldsymbol{x}|\omega_i) \tag{1-3-4}$$

$$p(\boldsymbol{x}|\omega_i) = \partial^n F(x_1, x_2, \cdots, x_n|\omega_i)/\partial x_1 \partial x_2 \cdots \partial x_n \tag{1-3-5}$$

2. 随机矢量的数字特征

1)均值矢量(期望矢量)

n 维随机矢量 $\boldsymbol{X}$ 的数学期望 $\boldsymbol{\mu}$ 定义为

$$\mu = \mathrm{E}[\boldsymbol{X}] \triangleq \overline{\boldsymbol{X}} = \begin{pmatrix} \mathrm{E}[X_1] \\ \mathrm{E}[X_2] \\ \vdots \\ \mathrm{E}[X_n] \end{pmatrix} \triangleq \int_{X^n} \boldsymbol{x} p(\boldsymbol{x}) \mathrm{d}\boldsymbol{x} \tag{1-3-6}$$

其中:$\boldsymbol{\mu}$ 的分量

$$\begin{aligned} \mu_i &= \mathrm{E}[X_i] = \int_{-\infty}^{\infty} x_i p(x_i) \mathrm{d}x_i \\ &= \int_{-\infty}^{\infty} \cdots \int x_i p(x_1, x_2, \cdots, x_n) \mathrm{d}x_1 \mathrm{d}x_2 \cdots \mathrm{d}x_n \triangleq \overline{X}_i \end{aligned} \tag{1-3-7}$$

式中:$p(x_i)$ 是 $\boldsymbol{X}$ 的第 i 个分量的边缘密度。随机矢量 $\boldsymbol{X}$ 的均值矢量 $\boldsymbol{\mu}$ 的各分量是相应的各随机分量的均值。

2)条件期望

在模式识别中,经常以类别 ω_i 作为条件,在这种情况下随机矢量 $\boldsymbol{X}$ 的条件期望矢量定义为

$$\mu_i = \mathrm{E}[\boldsymbol{X}|\ \omega_i] = \int_{X^n} \boldsymbol{x} p(\boldsymbol{x}|\ \omega_i) \mathrm{d}\boldsymbol{x} \tag{1-3-8}$$

3)协方差矩阵

随机矢量 $\boldsymbol{X}$ 的自协方差矩阵表征各分量围绕其均值的散布情况及各分量间的相关关系,其定义为

$$\begin{aligned} \boldsymbol{\Sigma} &= \mathrm{E}[(\boldsymbol{X} - \overline{\boldsymbol{X}})(\boldsymbol{X} - \overline{\boldsymbol{X}})^{\mathrm{T}}] \\ &= \int_{X^n} (\boldsymbol{x} - \boldsymbol{\mu})(\boldsymbol{x} - \boldsymbol{\mu})^{\mathrm{T}} p(\boldsymbol{x}) \mathrm{d}\boldsymbol{x} \triangleq (\sigma_{ij}^2)_{n \times n} \end{aligned} \tag{1-3-9}$$

式中：σ_{ij}^2 是 $\boldsymbol{X}$ 的第 i 个分量与第 j 个分量的协方差，当 $i=j$ 时，σ_{ii}^2 便是 X_i 的方差。

$$\sigma_{ij}^2 = \mathrm{E}[(X_i - \overline{X}_i)(X_j - \overline{X}_j)]$$

$$= \int_{-\infty}^{\infty}\int (x_i - \mu_i)(x_j - \mu_j)p(x_i, x_j)\mathrm{d}x_i\mathrm{d}x_j \qquad (1-3-10)$$

4）自相关矩阵

随机矢量 $\boldsymbol{X}$ 的自相关矩阵定义为

$$\boldsymbol{R} = \mathrm{E}[\boldsymbol{X}\boldsymbol{X}^{\mathrm{T}}] \qquad (1-3-11)$$

由定义可知，$\boldsymbol{X}$ 的协方差矩阵和自相关矩阵间的关系是

$$\boldsymbol{\Sigma} = \boldsymbol{R} - \overline{\boldsymbol{X}}\,\overline{\boldsymbol{X}}^{\mathrm{T}} = \boldsymbol{R} - \boldsymbol{\mu}\boldsymbol{\mu}^{\mathrm{T}} \qquad (1-3-12)$$

5）相关系数

$$r_{ij} = \sigma_{ij}^2/(\sigma_{ii}\sigma_{jj}) \qquad (1-3-13)$$

由布尼亚科夫斯基不等式知

$$|\sigma_{ij}^2| \leqslant \sigma_{ii}\sigma_{jj}$$

所以

$$-1 \leqslant r_{ij} \leqslant 1 \qquad (1-3-14)$$

相关系数矩阵定义为

$$\boldsymbol{R}_c = (r_{ij})_{n\times n}$$

6）协方差矩阵的非负定性

显然，协方差矩阵和自相关矩阵都是对称矩阵。设 $\boldsymbol{A}$ 为对称矩阵，对任意的矢量 $\boldsymbol{x}$，$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}$ 是 $\boldsymbol{A}$ 的二次型。若对任意的 $\boldsymbol{x}$ 恒有

$$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x} \geqslant 0$$

则称 $\boldsymbol{A}$ 为非负定矩阵；若对任意的 $\boldsymbol{x} \neq \boldsymbol{0}$，恒有

$$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x} > 0$$

则称 $\boldsymbol{A}$ 为正定矩阵。对于正定矩阵，各阶主子式非零（包括 $|\boldsymbol{A}| \neq 0$）。协方差矩阵是非负定的。

3. 随机变量、随机矢量间的统计关系

1)不相关

随机矢量 $\boldsymbol{X}$ 的第 i 个分量 X_i 和第 j 个分量 X_j 若有

$$\sigma_{ij}^2 = 0 \quad (i \neq j)$$

则称它们不相关。X_i 和 X_j 不相关等价于

$$\mathrm{E}[X_i X_j] = \mathrm{E}[X_i]\mathrm{E}[X_j] \tag{1-3-15}$$

随机矢量 $\boldsymbol{X}$ 和 $\boldsymbol{Y}$ 不相关的充要条件是互协方差矩阵 $\mathrm{Cov}(\boldsymbol{X},\boldsymbol{Y}) = \boldsymbol{0}$,亦即

$$\mathrm{E}[\boldsymbol{X}\boldsymbol{Y}^{\mathrm{T}}] = \mathrm{E}[\boldsymbol{X}]\mathrm{E}[\boldsymbol{Y}^{\mathrm{T}}] \tag{1-3-16}$$

2)正交

随机矢量 $\boldsymbol{X}$ 和 $\boldsymbol{Y}$ 若满足

$$\mathrm{E}[\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}] = 0 \tag{1-3-17}$$

则称 $\boldsymbol{X}$ 和 $\boldsymbol{Y}$ 正交。

3)独立

随机矢量 $\boldsymbol{X}$ 和 $\boldsymbol{Y}$ 的联合概率密度函数 $p(\boldsymbol{x},\boldsymbol{y})$ 若满足

$$p(\boldsymbol{x},\boldsymbol{y}) = p(\boldsymbol{x})p(\boldsymbol{y}) \tag{1-3-18}$$

则称 $\boldsymbol{X}$ 和 $\boldsymbol{Y}$ 独立。

4)两者关系

独立必不相关,反之不然。独立性是比不相关性更强的条件。

4. 随机矢量的变换

设随机矢量 $\boldsymbol{Y}$ 是另一随机矢量 $\boldsymbol{X}$ 的函数,即

$$\boldsymbol{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} g_1(X_1, X_2, \cdots, X_n) \\ g_2(X_1, X_2, \cdots, X_n) \\ \vdots \\ g_n(X_1, X_2, \cdots, X_n) \end{pmatrix} \triangleq \begin{pmatrix} g_1(X) \\ g_2(X) \\ \vdots \\ g_n(X) \end{pmatrix} \triangleq g(X)$$

若它们的函数关系是一一对应的,则这两个随机矢量的概率密度函数之间有

$$p(\boldsymbol{y}) = \frac{p(\boldsymbol{x})}{|J|}$$

式中:雅可比行列式

$$J = \begin{vmatrix} \dfrac{\partial g_1}{\partial x_1} & \dfrac{\partial g_1}{\partial x_2} & \cdots & \dfrac{\partial g_1}{\partial x_n} \\ \dfrac{\partial g_2}{\partial x_1} & \dfrac{\partial g_2}{\partial x_2} & \cdots & \dfrac{\partial g_2}{\partial x_n} \\ \vdots & \vdots & \vdots & \vdots \\ \dfrac{\partial g_n}{\partial x_1} & \dfrac{\partial g_n}{\partial x_2} & \cdots & \dfrac{\partial g_n}{\partial x_n} \end{vmatrix} \tag{1-3-19}$$

J 表示变换后体积微元的变化,$\boldsymbol{Y}^n$ 坐标系中体积微元 $\mathrm{d}y_1\mathrm{d}y_2\cdots\mathrm{d}y_n = |J|\mathrm{d}x_1\mathrm{d}x_2\cdots\mathrm{d}x_n$,$|J|$ 表示 J 的绝对值。当 $\boldsymbol{X}$ 和 $\boldsymbol{Y}$ 之间只是线性变换时,

$$\boldsymbol{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} a_{11}X_1 + a_{12}X_2 + \cdots + a_{1n}X_n \\ a_{21}X_1 + a_{22}X_2 + \cdots + a_{2n}X_n \\ \vdots \\ a_{n1}X_1 + a_{n2}X_2 + \cdots + a_{nn}X_n \end{pmatrix}$$

$$= \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix} \triangleq \boldsymbol{AX}$$

此时,$J = |\boldsymbol{A}|$,$|\boldsymbol{A}|$ 表示矩阵 $\boldsymbol{A}$ 取行列式,从而随机矢量 $\boldsymbol{Y}$ 的概率密度函数

$$p(\boldsymbol{y}) = p(\boldsymbol{x}) / \| \boldsymbol{A} \|$$

式中:$\| \boldsymbol{A} \|$ 表示行列式 $|\boldsymbol{A}|$ 取绝对值。

设 $\boldsymbol{X}$ 的均值矢量为 $\boldsymbol{\mu}_x$,协方差矩阵为 $\boldsymbol{\Sigma}_x$,则 $\boldsymbol{Y}$ 的均值矢量

$$\boldsymbol{\mu}_y = \mathrm{E}[\boldsymbol{Y}] = \boldsymbol{A}\mathrm{E}[\boldsymbol{X}] = \boldsymbol{A}\boldsymbol{\mu}_x$$

$\boldsymbol{Y}$ 的协方差阵

$$\boldsymbol{\Sigma}_y = \mathrm{E}[(\boldsymbol{Y}-\boldsymbol{\mu}_y)(\boldsymbol{Y}-\boldsymbol{\mu}_y)^{\mathrm{T}}] = \boldsymbol{A}\mathrm{E}[(\boldsymbol{X}-\boldsymbol{\mu}_x)(\boldsymbol{X}-\boldsymbol{\mu}_x)^{\mathrm{T}}]\boldsymbol{A}^{\mathrm{T}} \triangleq \boldsymbol{A}\boldsymbol{\Sigma}_x\boldsymbol{A}^{\mathrm{T}}$$

1.4 正态分布

在概率论、数理统计及决策理论的研究和应用中，正态分布是一种最重要的分布，这是因为它可以模拟大量的实际对象，并且便于计算。在实际中，许多随机变量都服从或近似服从正态分布，例如许多实际的数据集较对称地分布在它们均值的周围，距均值较近的数据较多，距均值较远的数据较少，这近似于正态分布的情况；正态分布又是许多重要概率分布的极限分布；许多非正态随机变量是正态随机变量的函数。同时由于正态分布具有一系列“优良”的性质和简洁的数学形式，因此易于理论上的推导和具体处理。下面介绍正态分布的数学形式和重要性质。

1.4.1 正态分布的定义

1. 一维随机变量的正态分布

一维正态分布的随机变量 X 的概率密度函数定义为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma}\exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] \qquad (1-4-1)$$

式中：μ 为随机变量 X 的数学期望，σ^2 是 X 的方差，它们分别由下式定义和计算。

$$\mu = \mathrm{E}[X] = \int_{-\infty}^{\infty} xp(x)\mathrm{d}x \qquad (1-4-2)$$

$$\sigma^2 = \mathrm{E}[(X-\mu)^2] = \int_{-\infty}^{\infty}(x-\mu)^2 p(x)\mathrm{d}x \qquad (1-4-3)$$

正态随机变量 X 的概率密度函数由 μ 和 σ^2 两个参数就可以完全确定。为简便起见，正态随机变量 X 可记为 $X \sim N(\mu,\sigma^2)$ 或 $p(x) \sim N(\mu,\sigma^2)$。

任何随机变量的概率密度函数都满足下式，正态分布的随机变量

也不例外。

$$p(x) \geqslant 0 \quad (-\infty < x < \infty) \tag{1-4-4}$$

$$\int_{-\infty}^{\infty} p(x)\mathrm{d}x = 1 \tag{1-4-5}$$

随机变量 X 在其均值 μ 周围散布，σ 越大，随机变量 X 取值的分散程度也越大。在以 μ 为中心的区间中正态随机变量 X 出现的概率为

$$P(\mu - \sigma \leqslant x \leqslant \mu + \sigma) = 0.683$$

$$P(\mu - 2\sigma \leqslant x \leqslant \mu + 2\sigma) = 0.954$$

$$P(\mu - 3\sigma \leqslant x \leqslant \mu + 3\sigma) = 0.997$$

2. 多变量正态分布

n 元(维)正态分布的随机矢量 $\boldsymbol{X} = (X_1, X_2, \cdots, X_n)^{\mathrm{T}}$ 的概率密度函数定义为

$$p(x_1, x_2, \cdots, x_n) \triangleq p(\boldsymbol{x}) = \frac{1}{(2\pi)^{n/2}|\boldsymbol{\Sigma}|^{1/2}}\exp\left[-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right] \tag{1-4-6}$$

式中：$\boldsymbol{\mu} = (\mu_1, \mu_2, \cdots, \mu_n)^{\mathrm{T}}$ 为 $\boldsymbol{X}$ 的数学期望矢量，$\boldsymbol{\Sigma}$ 为 $\boldsymbol{X}$ 的协方差矩阵。

$$\boldsymbol{\mu} = \mathrm{E}[\boldsymbol{X}] = \begin{pmatrix} \mathrm{E}[X_1] \\ \mathrm{E}[X_2] \\ \vdots \\ \mathrm{E}[X_n] \end{pmatrix} \tag{1-4-7}$$

$$\boldsymbol{\Sigma} = \mathrm{E}[(\boldsymbol{X}-\boldsymbol{\mu})(\boldsymbol{X}-\boldsymbol{\mu})^{\mathrm{T}}] = \begin{pmatrix} \sigma_{11}^2 & \sigma_{12}^2 & \cdots & \sigma_{1n}^2 \\ \sigma_{21}^2 & \sigma_{22}^2 & \cdots & \sigma_{2n}^2 \\ \vdots & \vdots & \vdots & \vdots \\ \sigma_{n1}^2 & \sigma_{n2}^2 & \cdots & \sigma_{nn}^2 \end{pmatrix} \tag{1-4-8}$$

它们的元素

$$\mu_i = \mathrm{E}[X_i] = \int_{X^n} x_i p(\boldsymbol{x})\mathrm{d}\boldsymbol{x} = \int_{-\infty}^{\infty} x_i p(x_i)\mathrm{d}x_i \quad (1-4-9)$$

$$\begin{aligned}\sigma_{ij}^2 &= \mathrm{E}[(X_i-\mu_i)(X_j-\mu_j)] \\ &= \int_{X^n}(x_i-\mu_i)(x_j-\mu_j)p(\boldsymbol{x})\mathrm{d}\boldsymbol{x} \\ &= \int_{-\infty}^{\infty}\int(x_i-\mu_i)(x_j-\mu_j)p(x_i,x_j)\mathrm{d}x_i\mathrm{d}x_j \quad (1-4-10)\end{aligned}$$

式中：$p(x_i)$和$p(x_i,x_j)$为$p(x_1,x_2,\cdots,x_n)$边缘概率密度分布，X^n为随机矢量各分量定义域的直积空间。易知$\boldsymbol{\Sigma}$为对称半正定矩阵。二维正态分布概密函数如图1.4.1所示。

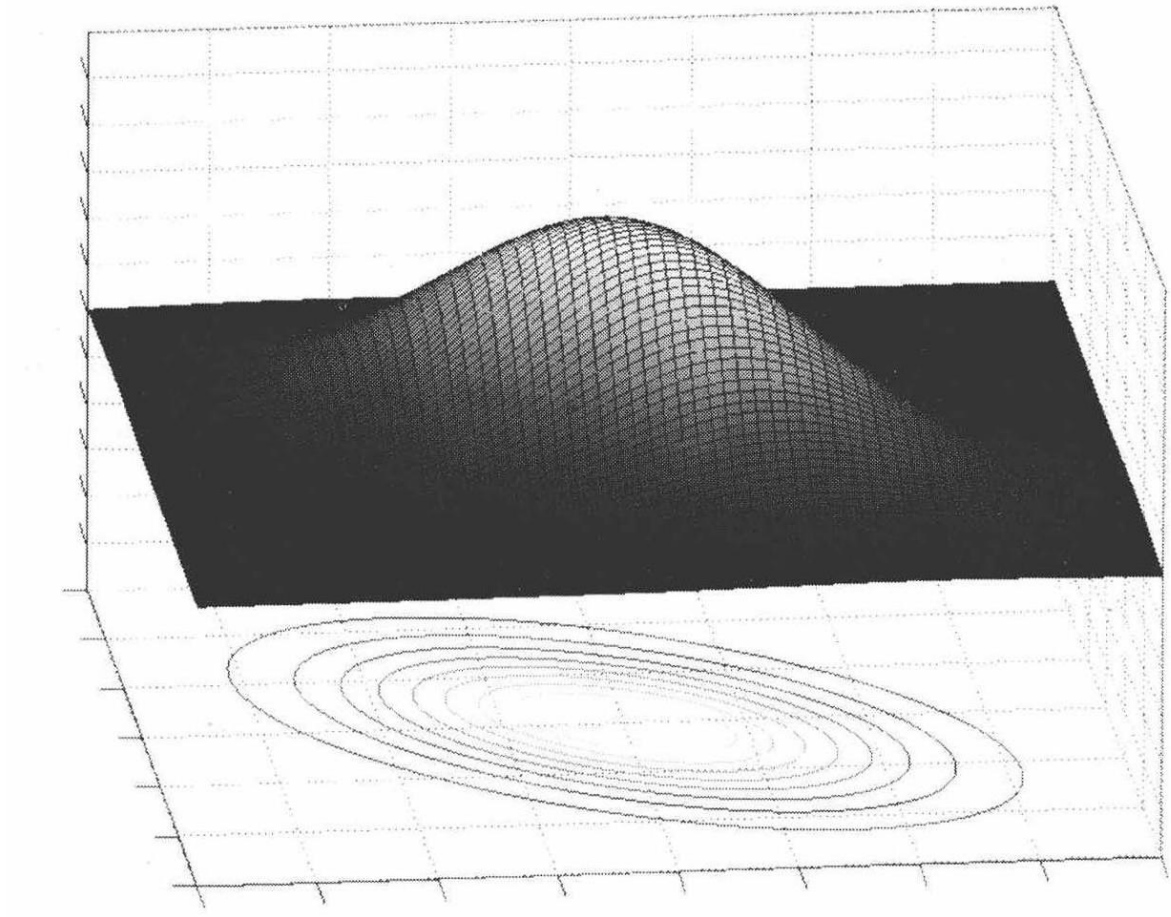


图1.4.1　二维正态分布概密函数示意图

1.4.2　多元正态分布的性质

多元正态分布有许多易于分析和十分有用的性质，下面给出一些重要的内容。

1. 正态分布完全由 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 确定

n 元正态分布随机矢量的概率密度函数由均值矢量 $\boldsymbol{\mu}$ 的 n 个分量和协方差阵 $\boldsymbol{\Sigma}$ 的 $n(n+1)/2$ 个独立阵元所完全确定。多元正态分布的随机矢量 $\boldsymbol{X}$ 常简记为 $\boldsymbol{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 或 $p(\boldsymbol{x}) \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$。

2. 等概率密度点的轨迹为一超椭球面

由式(1-4-6)可知,当指数为常数时,$p(\boldsymbol{x})$ 的值不变,因此等概率密度点 $\boldsymbol{x}$ 应满足

$$(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}) = \text{常数}\ \gamma^2 \qquad (1-4-11)$$

易证式(1-4-11)的解是一个超椭球面,其中心为 $\boldsymbol{\mu}$,椭球面的形状由 $\boldsymbol{\Sigma}$ 确定,取不同的 γ 就对应不同大小的超椭球面,每个等概率密度椭球面围成的椭球体的主轴平行于协方差矩阵 $\boldsymbol{\Sigma}$ 的特征矢量方向,其长度与相应的特征值的方根成正比。

由 $(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}) \leqslant \chi_n^2(\alpha)$ 所定义的椭球体包含 $1-\alpha$ 的概率值,其中 $\chi_n^2(\alpha)$ 是自由度为 n 的 χ^2 分布的上 100α 百分位数。

3. 正态分布的不相关与独立是等价的

如果多元正态分布随机矢量的两个分量 X_i 和 X_j 之间是不相关的,则它们之间一定是独立的。这是因为若 X_i 和 X_j 不相关,由定义,它们的协方差 $\sigma_{ij}^2 = 0 (i \neq j)$,从而协方差阵成为对角阵

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_{11}^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sigma_{nn}^2 \end{pmatrix}$$

易知

$$\boldsymbol{\Sigma}^{-1} = \begin{pmatrix} 1/\sigma_{11}^2 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1/\sigma_{nn}^2 \end{pmatrix}$$

$$|\boldsymbol{\Sigma}| = \prod_{i=1}^{n} \sigma_{ii}^2$$

$$(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}) = \sum_{i=1}^{n} \frac{(x_i-\mu_i)^2}{\sigma_{ii}^2}$$

因此

$$p(\boldsymbol{x}) = \frac{1}{(2\pi)^{n/2}|\boldsymbol{\Sigma}|^{1/2}}\exp\left[-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right]$$

$$= \prod_{i=1}^{n}\frac{1}{\sqrt{2\pi}\sigma_{ii}}\exp\left[-\frac{1}{2}\left(\frac{x_i-\mu_i}{\sigma_{ii}}\right)^2\right] = \prod_{i=1}^{n}p(x_i) \tag{1-4-12}$$

上式正是独立性的充要条件,从而证明了上面等价性的结论。

4. 多元正态随机矢量的边缘概率密度和条件概率密度仍是正态分布

下面只给出二元情况的证明,更多元的情况是类似的。由

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_{11}^2 & \sigma_{12}^2 \\ \sigma_{12}^2 & \sigma_{22}^2 \end{pmatrix}$$

可得

$$\boldsymbol{\Sigma}^{-1} = \frac{1}{|\boldsymbol{\Sigma}|}\begin{pmatrix} \sigma_{22}^2 & -\sigma_{12}^2 \\ -\sigma_{12}^2 & \sigma_{11}^2 \end{pmatrix}$$

由定义可算得

$$p(x_1) = \int_{-\infty}^{\infty}p(x_1,x_2)\,\mathrm{d}x_2$$

$$= \frac{1}{2\pi|\boldsymbol{\Sigma}|^{1/2}}\int_{-\infty}^{\infty}\exp\left[-\frac{1}{2|\boldsymbol{\Sigma}|}(\sigma_{22}^2(x_1-\mu_1)^2\right.$$

$$\left.+\sigma_{11}^2(x_2-\mu_2)^2-2\sigma_{12}^2(x_1-\mu_1)(x_2-\mu_2))\right]\mathrm{d}x_2$$

$$= \frac{1}{(2\pi)^{1/2}\sigma_{11}}\exp\left[-\frac{1}{2}\left(\frac{x_1-\mu_1}{\sigma_{11}}\right)^2\right]\frac{\sigma_{11}}{(2\pi)^{1/2}|\boldsymbol{\Sigma}|^{1/2}}$$

$$\int_{-\infty}^{\infty}\exp\left[\frac{-\sigma_{11}^2}{2|\boldsymbol{\Sigma}|}\left((x_2-\mu_2)-\frac{\sigma_{12}^2}{\sigma_{11}^2}(x_1-\mu_1)\right)^2\right]\mathrm{d}x_2$$

$$= \frac{1}{(2\pi)^{1/2}\sigma_{11}}\exp\left[-\frac{1}{2}\left(\frac{x_1-\mu_1}{\sigma_{11}}\right)^2\right] \tag{1-4-13}$$

同理，可以推出 $p(x_2) \sim N(\mu_2, \sigma_{22}^2)$。

由贝叶斯定理

$$p(x_2 \mid x_1) = p(x_1, x_2)/p(x_1) \tag{1-4-14}$$

并由上面推导可知，$p(x_2 \mid x_1)$ 可表为

$$p(x_2 \mid x_1) = \frac{\sigma_{11}}{(2\pi)^{1/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left[\frac{-\sigma_{11}^2}{2|\boldsymbol{\Sigma}|} \left((x_2 - \mu_2) - \frac{\sigma_{12}^2}{\sigma_{11}^2}(x_1 - \mu_1) \right)^2 \right]$$

$$\sim N\left(\mu_2 + \frac{\sigma_{12}^2}{\sigma_{11}^2}(x_1 - \mu_1), \sigma_{22}^2 - \frac{\sigma_{12}^4}{\sigma_{11}^2} \right) \tag{1-4-15}$$

同理，也可以导出 $p(x_1 \mid x_2)$ 的函数形式。

一般性的结论是，$\boldsymbol{X}_1$、$\boldsymbol{X}_2$ 是两个随机矢量，设 $\boldsymbol{X} = \begin{pmatrix} \boldsymbol{X}_1 \\ \boldsymbol{X}_2 \end{pmatrix} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}$，$\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}$，$|\boldsymbol{\Sigma}_{22}| > 0$，在 $\boldsymbol{X}_2 = \boldsymbol{x}_2$ 条件下，$\boldsymbol{X}_1$ 的条件概率密度函数为

$$p(\boldsymbol{x}_1 \mid \boldsymbol{x}_2) \sim N(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\boldsymbol{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}) \tag{1-4-16}$$

这里 $\boldsymbol{X}_1$、$\boldsymbol{\mu}_1$ 的维数与 $\boldsymbol{\Sigma}_{11}$ 的行、列数相同，$\boldsymbol{X}_2$、$\boldsymbol{\mu}_2$ 的维数与 $\boldsymbol{\Sigma}_{22}$ 的行、列数相同。

5. 多元正态随机矢量的线性变换仍为多元正态随机矢量

设 $\boldsymbol{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，$\boldsymbol{A}$ 为非奇异阵，令 $\boldsymbol{Y} = \boldsymbol{AX}$，有 $\boldsymbol{\nu} = \mathrm{E}[\boldsymbol{Y}] = \boldsymbol{A}E[\boldsymbol{X}] = \boldsymbol{A\mu}$，雅可比行列式 $J = |\boldsymbol{A}|$，于是 $\boldsymbol{Y}$ 的概率密度函数与 $\boldsymbol{X}$ 的概率密度函数之间的关系为

$$p(\boldsymbol{y}) = p(\boldsymbol{x})/|J| = p(\boldsymbol{A}^{-1}\boldsymbol{y})/\|\boldsymbol{A}\|$$

上式中的 $\|\boldsymbol{A}\|$ 表示行列式 $|\boldsymbol{A}|$ 取绝对值，由于

$$\|\boldsymbol{A}\| = \|\boldsymbol{A}^{\mathrm{T}}\| = |\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}|^{1/2}$$

由上面诸式可得

$$p(\boldsymbol{y}) = \frac{1}{(2\pi)^{n/2} |\boldsymbol{\Sigma}|^{1/2} \|\boldsymbol{A}\|}$$

$$\exp\left[-\frac{1}{2}(\boldsymbol{A}^{-1}\boldsymbol{y}-\boldsymbol{A}^{-1}\boldsymbol{\nu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{A}^{-1}\boldsymbol{y}-\boldsymbol{A}^{-1}\boldsymbol{\nu})\right]$$

$$=\frac{1}{(2\pi)^{n/2}|\boldsymbol{A}\boldsymbol{\Sigma}\boldsymbol{A}^{\mathrm{T}}|^{1/2}}\exp\left[-\frac{1}{2}(\boldsymbol{y}-\boldsymbol{\nu})^{\mathrm{T}}(\boldsymbol{A}\boldsymbol{\Sigma}\boldsymbol{A}^{\mathrm{T}})^{-1}(\boldsymbol{y}-\boldsymbol{\nu})\right]$$

即得

$$p(\boldsymbol{y})\sim N(\boldsymbol{A}\boldsymbol{\mu},\boldsymbol{A}\boldsymbol{\Sigma}\boldsymbol{A}^{\mathrm{T}})$$

由于 $\boldsymbol{\Sigma}$ 是对称阵，必存在正交矩阵 $\boldsymbol{A}$，使 $\boldsymbol{Y}=\boldsymbol{A}\boldsymbol{X}$ 的协方差阵 $\boldsymbol{A}\boldsymbol{\Sigma}\boldsymbol{A}^{\mathrm{T}}$ 为对角阵，此时 $\boldsymbol{Y}$ 的各分量彼此独立。这表明可以通过某种变换使变换后的各分量相互独立。

更一般的有，如果 $\boldsymbol{X}=(X_1,X_2,\cdots,X_n)^{\mathrm{T}}\sim N(\boldsymbol{\mu},\boldsymbol{\Sigma})$，$\boldsymbol{A}$ 是秩为 m 的 $m\times n$ 矩阵，$\boldsymbol{b}=(b_1,b_2,\cdots,b_m)^{\mathrm{T}}$，则 $\boldsymbol{Y}=\boldsymbol{A}\boldsymbol{X}+\boldsymbol{b}$ 服从正态分布 $N(\boldsymbol{A}\boldsymbol{\mu}+\boldsymbol{b},\boldsymbol{A}\boldsymbol{\Sigma}\boldsymbol{A}^{\mathrm{T}})$。

6. 多元正态随机矢量 $\boldsymbol{X}$ 的分量的线性组合是一正态随机变量

这实际上是性质 5 简单的引论。若 $\boldsymbol{X}\sim N(\boldsymbol{\mu},\boldsymbol{\Sigma})$，设 $\boldsymbol{\alpha}$ 是与 $\boldsymbol{X}$ 同维的矢量，则 $\boldsymbol{Y}=\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{X}$ 是一个正态随机变量，$p(\boldsymbol{y})\sim N(\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\mu},\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\Sigma}\boldsymbol{\alpha})$。令 $\boldsymbol{A}^{\mathrm{T}}=(\boldsymbol{\alpha},\boldsymbol{A}_1)$ 为非奇异阵，

$$\boldsymbol{Y}=\begin{pmatrix}\boldsymbol{Y}\\ \boldsymbol{Y}_2\end{pmatrix}=\boldsymbol{A}\boldsymbol{X}=\begin{pmatrix}\boldsymbol{\alpha}^{\mathrm{T}}\\ \boldsymbol{A}_1^{\mathrm{T}}\end{pmatrix}\boldsymbol{X}=\begin{pmatrix}\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{X}\\ \boldsymbol{A}_1^{\mathrm{T}}\boldsymbol{X}\end{pmatrix}$$

由性质 5 知，$\boldsymbol{Y}\sim N(\boldsymbol{A}\boldsymbol{\mu},\boldsymbol{A}\boldsymbol{\Sigma}\boldsymbol{A}^{\mathrm{T}})$，又由性质 4 知，$\boldsymbol{Y}=\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{X}\sim N(\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\mu},\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\Sigma}\boldsymbol{\alpha})$。

第2章　聚类分析及最近邻方法

2.1　聚类分析的概念

2.1.1　聚类分析的基本思想

聚类分析(Clustering Analysis)是基于数据集客观存在着若干个自然类、每个自然类中的数据某些属性都具有较强的相似性而建立的一种数据描述方法。因而可以讲,聚类分析是将给定的一些模式分成若干组,对于所选定的属性或特征,每组内的各模式是相似的,而与其他组的模式差别较大。从方法上讲,聚类分析算法的基本思想非常朴素、直观和简单,它是根据各个待分类的模式属性或特征相似程度进行分类的,相似的模式归为一类,不相似的模式作为另外一类,将待分类的模式集分成若干个互不重叠的几部分。聚类分析包括的基本内容是:特征提取,模式相似性度量,点与类间的距离,类间距离,聚类准则,聚类算法和有效性分析。

由于在分类中不需要用训练样本进行学习和训练,故此类方法称为无监督分类。应指出的是,当人为选定某些特征,采用某种模式相似性度量,运用某种聚类算法等时,实际上已引入了某些知识和信息,从而隐含地规定了模式集的分类结构。使用不同的特征,或采用不同的模式相似性度量,或运用不同的聚类方法等都将会产生不同的分类结果,因每个环节都隐含地规定了模式集的分类结构。所以在处理实际问题时,必须要深入了解问题,使所选定的特征、运用的聚类算法等能对问题很好地"匹配"。

聚类算法虽然总的讲较简单,但应用却是十分广泛的,其主要原因和应用领域如下:

(1)在一些情况下,无法获得训练样本。

(2)虽然可以获得训练样本,但是需要耗费较多的人力、财力和时间。

(3)聚类算法可作为后续较复杂分类算法的预处理,或由其获取一些有用的知识和信息。

(4)用于数据压缩。

(5)用于数据挖掘。

2.1.2 特征量

为使特征能代替对象,要求所选用的特征应满足:①尽可能多地包含既定任务的对象物理信息;②尽量使对象易于分类识别。这就要求信息充分且数据冗余量少。为使算法通用性强,这里不涉及具体任务背景,不讨论①,满足要求②的一些理论和技术将在第6章中详细论述,本章讨论聚类分析基本内容后面各部分,重点是模式相似性度量,点与类间的距离,类间距离,聚类准则,聚类算法。

由于分类对象或分类目的不同,对象的特征数值化的结果有下述3种类型。

(1)物理量:直接反映特征的实际物理或几何意义,如重量、长度、速度等。计算机进行处理分析前需要对这些连续量离散化。

(2)次序量:特征在数值化时,按某种规则确定特征的等级,其只反映次序关系。此时特征已为离散量,如产品的等级、人的学识、技能的等级、病症的级或期。

(3)名义量:有些特征本身是非数值的,如男性与女性、事物的状态、种类等,但为便于分析而将它们符号化,用数字代表各种状态,这些特征的数值指标既无数量含义,也无次序关系,实际上它们是代码。

2.1.3 方法的有效性

基于模式相似性而建立的分类方法的有效性,从根本上讲,首先取决于模式特征点在特征空间中的分布情况。如果同类的模式特征点密聚,不同类的模式特征点相距较远,即特征点按类聚集,一般的分类方法通常是有效的;反之,如果不同类的模式特征点混杂散布,许多分类方法往往无效或效果不佳。既然某些对象属于不同的类别,它们之间

必然有一些重要特征显著不同，之所以出现上述特征点混杂的情况，原因是特征选得不适当，对于所选取的特征，不同类的模式的特征值差别不大，换句话说，有显著差别的特征没有选取。这时应重新提取特征，选取不同类别之间显著不同的特征而产生新的特征点。从技术上讲，方法有效性取决于分类算法和特征点分布情况的匹配。

1. 特征选取不当使分类无效

两类模式特征点在二维特征空间中的分布如图 2.1.1(a)所示，分属 ω_1 类和 ω_2 类的模式特征点分别在类域 Ω_1 和 Ω_2 中散布。类域 Ω_1 和 Ω_2 在 x_2 轴上的投影有较大的重叠，如果只根据 x_2 的量测值判别对象类别，当特征量测值 x_2 落入重叠区 b 中时将无法判定。如果以 x_1 作为特征，两个类域投影区域距离较远，特征点则容易分类。

2. 特征选取不足使不同类别的模式判为一类

3 个类别模式特征点分布如图 2.1.1(b)所示，分属 ω_1、ω_2 和 ω_3 的模式特征点分别在类域 Ω_1、Ω_2 和 Ω_3 中散布。若只以 x_1 作为特征进行分类，则 ω_1 和 ω_2 将被判为一类；若只以 x_2 作为特征进行分类，则 ω_2 和 ω_3 就被判为一类；但若同时以 x_1、x_2 作为特征进行分类，3 类就可以完全被分开。

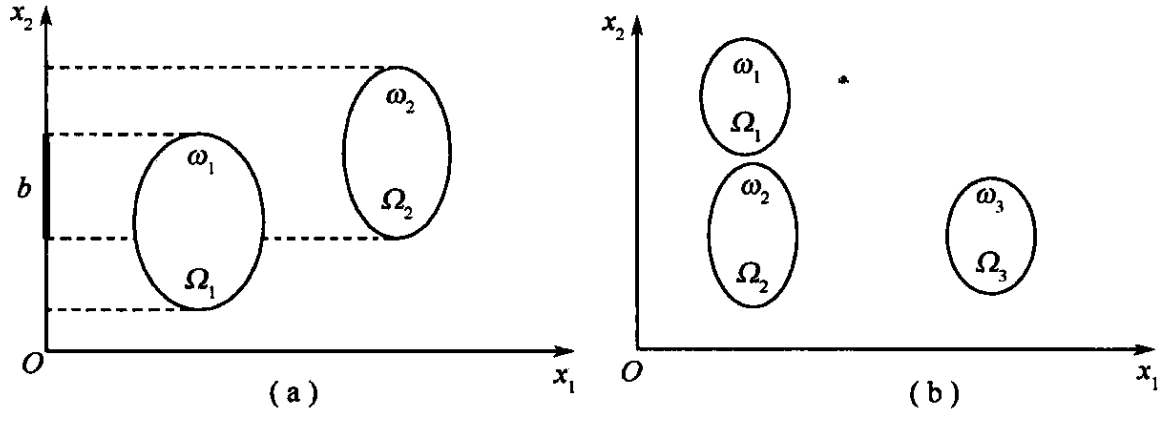


图 2.1.1　特征个数对聚类结果的影响示意图

3. 特征选取过多可能无益反而有害，增加分析负担并使分析效果变差

假设根据已选取的较少的特征可以进行正确分类，如果增加一些新的特征参与分类，这些新增加的特征和原有的特征间可能有如下的统计关系，即独立、不相关或相关。若新增加的特征和原有特征

间是独立或不相关且是有用的，则正确分类结果并不改变，但由于增加特征矢量的维数必然增加资源的耗费，因此既然使用较少的特征便能实现正确分类，就没有必要选用更多的特征。对于第3章、第4章所述的一些统计分类方法，这样作可能会使分类识别的正确率或多或少有所提高，但很有可能是正确率的提高不足以补偿资源的耗费。若新增加的特征和原有特征是相关的，这样并没有引入更多的有用信息但增加了数据的冗余。除了计算量增加外，更为严重的是，由于多了一些相关的特征，可能使对于不同类具有显著差别的重要特征在各种特征“总合”中占的比重变小。当运用门限的方法进行分类时可能造成误分。引入对各类均无显著差别的特征也会产生这个问题。引入更多的特征也可能使各类域复杂化，增加了后续分类识别工作的难度。

4. 量纲选取不当，可使分类无效。

特征量纲的改变会使特征的数值发生较大的变化，当使用某种相似性准则进行判定时，由于特征量纲选取不当，某一特征值的变化可能严重地影响相似性测度值从而产生误判。所以在分类识别中应尽量选用不受量纲影响的相似性测度，或是特征值中心化后再用方差归一化。

通过对特征进行“规格化”可实现某种不变性。要使特征具有平移和尺度缩放的不变性，可以通过平移和缩放坐标轴使得新的特征具有零均值和单位方差；要得到旋转不变性，可以旋转坐标轴使它们与样本协方差矩阵的特征矢量平行。

需要指出的是，分类方法的有效性并不等于分类的正确性。要使分类正确，必须深入了解问题，尽可能多地引入对象信息。选择什么特征、选择多少个特征不仅对聚类分析是极重要的，对其他各种利用数值特征的分类识别方法也是极为重要的，它关系到后续的模式分类识别的正确率。

2.2 模式相似性测度

为了能分划模式的类别，必须首先定义模式相似性测度，以此来描述各模式之间的相似程度。在这里，特征点是矢量的矢端。

2.2.1 距离测度(差值测度)

这类测度是以两个矢量矢端的距离作为度量的基础,因此距离测度值是两矢量各相应分量之差的函数。两矢量间的距离测度的具体算法有许多种,一般地讲,两点距离定义应满足下面的公理。设矢量 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 的距离记为 $d(\boldsymbol{x},\boldsymbol{y})$,$d(\boldsymbol{x},\boldsymbol{y})$ 应满足以下几点。

(1)$d(\boldsymbol{x},\boldsymbol{y}) \geqslant 0$,当且仅当 $\boldsymbol{y}=\boldsymbol{x}$ 时,等号成立,即 $d(\boldsymbol{x},\boldsymbol{y})=0 \Leftrightarrow \boldsymbol{x}=\boldsymbol{y}$。

(2)$d(\boldsymbol{x},\boldsymbol{y})=d(\boldsymbol{y},\boldsymbol{x})$ 。

(3)$d(\boldsymbol{x},\boldsymbol{y}) \leqslant d(\boldsymbol{x},\boldsymbol{z})+d(\boldsymbol{z},\boldsymbol{y})$ 。

需要指出,模式识别中定义的某些距离测度不满足(3),只是在广义上称之为距离。下面给出距离测度的几种具体算式。

设 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}$,$\boldsymbol{y}=(y_1,y_2,\cdots,y_n)^{\mathrm{T}}$。

(1)欧氏(Euclidean)距离

$$d(\boldsymbol{x},\boldsymbol{y}) = \|\boldsymbol{x}-\boldsymbol{y}\| = \left[\sum_{i=1}^{n}(x_i-y_i)^2\right]^{1/2} \qquad (2-2-1)$$

(2)绝对值距离(市区距离或 Manhattan 距离)

$$d(\boldsymbol{x},\boldsymbol{y}) = \sum_{i=1}^{n}|x_i-y_i| \qquad (2-2-2)$$

(3)切氏(Chebyshev)距离

$$d(\boldsymbol{x},\boldsymbol{y}) = \max_i|x_i-y_i| \qquad (2-2-3)$$

(4)明氏(Minkowski)距离

$$d(\boldsymbol{x},\boldsymbol{y}) = \left[\sum_{i=1}^{n}|x_i-y_i|^m\right]^{1/m} \qquad (2-2-4)$$

可以看出,(1)、(2)、(3)式实际上是(4)式当 $m=2$、1、∞ 的特殊情况。可以证明:

$$\text{切氏距离} \leqslant \text{欧氏距离} \leqslant \text{绝对值距离}$$

在实际中较多地使用欧氏距离。只有欧氏距离具有平移和旋转不变性。

显然，在量纲取定的条件下，两个矢量越相似，距离 $d(\cdot)$ 就越小，反之亦然。值得注意的是，在使用上述距离测度描述具体对象时，量纲选取不同会改变某特征的判断依据性，即改变该特征对判断贡献的大小，严重的可造成错误分类。这是因为改变特征矢量某分量的量纲，进行比较的两个矢量的相应的两个分量的数值也将改变。若分量数值变小，则其相应的特征在距离测度中“影响作用比重”将变小，即根据其判断分类的作用变小，反之将增大，这样便不能很好地反映事实。例如：x_1 和 x_2 分别表示长度和质量，如将长度单位由毫米改成米，在距离 $d(\cdot)$ 的算式中其数值大大减小，从而其反映相似性的作用也大为减小；若将质量单位由千克改为克，距离算式中相应数值大大增加，则质量的差别将起主要作用。图 2.2.1 反映了选取量纲不同时，聚类结果将不同。当 x_1 量纲改变使 x_1 值变小时，按欧氏距离聚类结果是 a、b 为一类，c、d 为另一类；而当改变 x_2 量纲使 x_2 值变小时，则 a、c 判为一类，b、d 判为另一类。

(5) 马氏(Mahalanobis)距离

设 n 维矢量 $\boldsymbol{x}_i$ 和 $\boldsymbol{x}_j$ 是矢量集 $\{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_m\}$ 中的两个矢量，它们的马氏距离 d 定义为

$$d^2(\boldsymbol{x}_i, \boldsymbol{x}_j) = (\boldsymbol{x}_i - \boldsymbol{x}_j)^{\mathrm{T}} \boldsymbol{V}^{-1} (\boldsymbol{x}_i - \boldsymbol{x}_j) \tag{2-2-5}$$

式中：

$$\boldsymbol{V} = \frac{1}{m-1} \sum_{i=1}^{m} (\boldsymbol{x}_i - \bar{\boldsymbol{x}})(\boldsymbol{x}_i - \bar{\boldsymbol{x}})^{\mathrm{T}} \tag{2-2-6}$$

$$\bar{\boldsymbol{x}} = \frac{1}{m} \sum_{i=1}^{m} \boldsymbol{x}_i \tag{2-2-7}$$

容易证明，马氏距离对一切非奇异线性变换都是不变的，这说明它不受特征量纲选择的影响，并且是平移不变的；另外，由于 $\boldsymbol{V}$ 的含义是这个矢量集的样本协方差阵，所以马氏距离对特征的相关性也作了处理。

一般地讲，若 $\boldsymbol{x}$、$\boldsymbol{y}$ 是从期望矢量为 $\boldsymbol{\mu}$、协方差矩阵为 $\boldsymbol{\Sigma}$ 的母体 G 中抽取的两个样本，它们间的马氏距离 d 定义为

$$d^2(\boldsymbol{x}, \boldsymbol{y}) = (\boldsymbol{x} - \boldsymbol{y})^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{y}) \tag{2-2-8}$$

当将 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 视作两个数据集中的样本时，设 $\boldsymbol{C}$ 是它们的互协方差

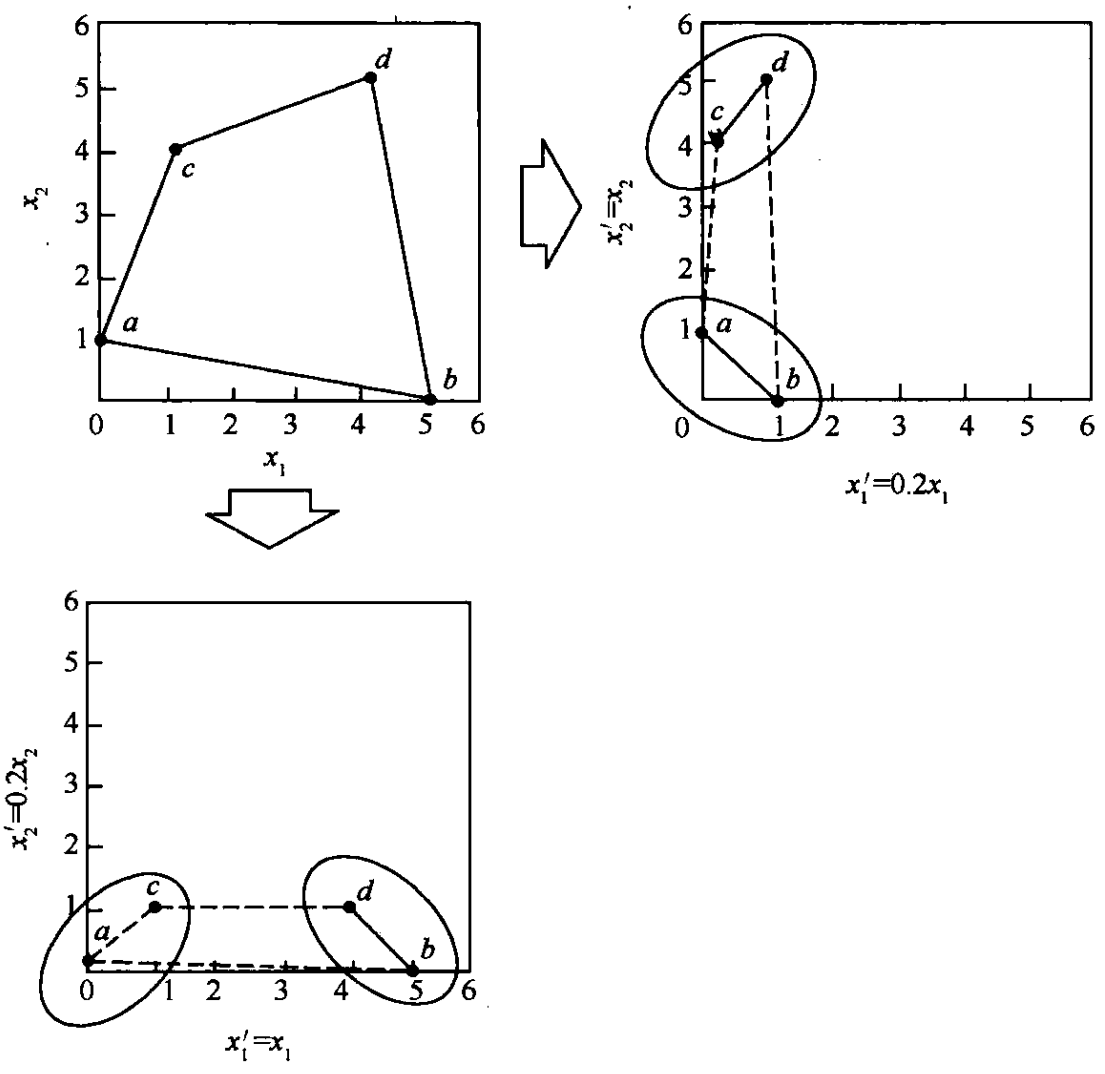


图 2.2.1　特征量纲对聚类结果的影响

阵,这种情况的马氏距离 d 的定义是

$$d^2(\boldsymbol{x},\boldsymbol{y})=(\boldsymbol{x}-\boldsymbol{y})^{\mathrm{T}}\boldsymbol{C}^{-1}(\boldsymbol{x}-\boldsymbol{y}) \qquad (2-2-9)$$

当 $\boldsymbol{\Sigma}$、$\boldsymbol{V}$、$\boldsymbol{C}$ 为单位矩阵时,马氏距离和欧氏距离是等价的。

[例 2.2.1] 已知一二维正态母体 G 的分布为

$$N\left(\begin{pmatrix}0\\0\end{pmatrix},\begin{pmatrix}1 & 0.9\\0.9 & 1\end{pmatrix}\right)$$

求点 $A:\begin{pmatrix}1\\1\end{pmatrix}$ 和点 $B:\begin{pmatrix}1\\-1\end{pmatrix}$ 至均值点 $M:\mu=\begin{pmatrix}0\\0\end{pmatrix}$ 的距离。

解:由题设,可得

$$\boldsymbol{\Sigma}^{-1}=\frac{1}{0.19}\begin{pmatrix}1 & -0.9\\ -0.9 & 1\end{pmatrix}$$

从而可算得马氏距离

$$d_{\mathrm{M}}^2(A,M)=(1\quad 1)\boldsymbol{\Sigma}^{-1}\begin{pmatrix}1\\1\end{pmatrix}=\frac{0.2}{0.19}$$

$$d_{\mathrm{M}}^2(B,M)=(1\quad -1)\boldsymbol{\Sigma}^{-1}\begin{pmatrix}1\\-1\end{pmatrix}=\frac{3.8}{0.19}$$

它们之比达$\sqrt{19}$倍,若用欧氏距离,算得的距离值相同。

$$d_{\mathrm{E}}^2(A,M)=2$$

$$d_{\mathrm{E}}^2(B,M)=2$$

由分布函数可知,A、B 两点的密度分别为

$$p(1,1)=0.2157$$

$$p(1,-1)=0.00001658$$

(6)Camberra 距离(Lance 距离、Willims 距离)

$$d(\boldsymbol{x},\boldsymbol{y})=\sum_{i=1}^{n}\frac{|x_i-y_i|}{|x_i+y_i|}\quad(x_i,y_i\geqslant 0,x_i+y_i\neq 0)\tag{2-2-10}$$

该距离能克服量纲引起的问题,但不能克服分量间的相关性。

(7)归一化距离

$$d(\boldsymbol{x},\boldsymbol{y})=\frac{\|\boldsymbol{x}-\boldsymbol{y}\|}{\|\boldsymbol{x}\|+\|\boldsymbol{y}\|}\tag{2-2-11}$$

显然,$0\leqslant d\leqslant 1$,且当 $\boldsymbol{x}=\boldsymbol{y}$ 时,$d=0$,$\boldsymbol{x}=-\boldsymbol{y}$ 时,$d=1$。

以上定义的各种相似性测度算式属距离测度,两模式越相似,其测度值越小。

2.2.2 相似测度

这类测度是以两矢量的方向是否相近作为度量的基础,矢量长度

并不重要，但其中有的度量依然考虑两矢量端点距离，只是再将其转化具有相似测度的数值属性。

1. 角度相似系数(夹角余弦)

矢量之间的相似性可用它们的夹角余弦来度量。两个矢量 x 和 y 的夹角余弦

$$\cos(x,y)=\frac{x^{\mathrm{T}}y}{\|x\|\ \|y\|}=\frac{x^{\mathrm{T}}y}{[(x^{\mathrm{T}}x)(y^{\mathrm{T}}y)]^{1/2}} \tag{2-2-12}$$

它对于坐标系的旋转和尺度的缩放是不变的(因矢量的长度已规格化)，但对一般的线性变换和坐标系的平移不具有不变性。

2. 相关系数

它实际上是数据中心化后的矢量夹角余弦。

$$r(x,y)=\frac{(x-\bar{x})^{\mathrm{T}}(y-\bar{y})}{[(x-\bar{x})^{\mathrm{T}}(x-\bar{x})(y-\bar{y})^{\mathrm{T}}(y-\bar{y})]^{1/2}} \tag{2-2-13}$$

此处将 x、y 分别视作两个数据集的样本，$\bar{x}$ 和 $\bar{y}$ 分别是这两个数据集的平均矢量。相关系数对于坐标系的平移、旋转和尺度缩放是不变的。

3. 指数相似系数

$$e(x,y)=\frac{1}{n}\sum_{i=1}^{n}\exp\left[-\frac{3}{4}\frac{(x_i-y_i)^2}{\sigma_i^2}\right] \tag{2-2-14}$$

式中：σ_i^2 为相应分量的方差；n 为矢量维数，它不受量纲变化的影响。从函数构造上看，函数指数为距离度量，但从测度值与相似性关系看，其应属相似测度。

4. 当各特征值非负时，还可定义下列几种最值相似系数

$$s(x,y)=\frac{\sum_i \min(x_i,y_i)}{\sum_i \max(x_i,y_i)} \tag{2-2-15}$$

$$s(x,y)=\frac{\sum_i \min(x_i,y_i)}{\frac{1}{2}\sum_i (x_i+y_i)} \tag{2-2-16}$$

$$s(\boldsymbol{x},\boldsymbol{y}) = \frac{\sum_i \min(x_i, y_i)}{\sum_i \sqrt{x_i y_i}} \qquad (2-2-17)$$

以上各种定义式均属相似测度，两个模式特征矢量越相似其值越大，上限为1。

2.2.3 匹配测度

这种测度常用于生物和医学的分类中。在有些情况下，对于一个指定的特征，对象或具有此特征或不具有此特征，此时，若对象有此特征，则相应分量定义为1，而相应分量为0表示对象无此特征，即特征只有两个状态，这就是所谓的二值特征。对于给定的二值特征矢量 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 中的某两个相应分量 x_i 与 y_i，若 $x_i=1$ 和 $y_i=1$，则称 x_i 与 y_i 是(1-1)匹配；若 $x_i=1$ 和 $y_i=0$，则称 x_i 与 y_i 是(1-0)匹配；若 $x_i=0$ 和 $y_i=1$，则称 x_i 与 y_i 是(0-1)匹配；若 $x_i=0$ 和 $y_i=0$，则称 x_i 与 y_i 是(0-0)匹配。令

$$a = \sum_i x_i y_i \qquad b = \sum_i (1-x_i) y_i$$

$$c = \sum_i x_i (1-y_i) \qquad e = \sum_i (1-x_i)(1-y_i)$$

则 a 等于两矢量 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 的(1-1)匹配的特征数目，b 等于 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 的(0-1)匹配的特征数目，c 等于 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 的(1-0)匹配特征数目，e 等于 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 的(0-0)匹配特征数目。对于二值 n 维特征矢量可定义如下相似性测度。

1. Tanimoto 测度

$$s(\boldsymbol{x},\boldsymbol{y}) = \frac{a}{a+b+c} = \frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x} + \boldsymbol{y}^{\mathrm{T}}\boldsymbol{y} - \boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}} \qquad (2-2-18)$$

可以看出，$s(\boldsymbol{x},\boldsymbol{y})$ 等于 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 同时具有的特征数目与 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 分别具有的特征种类总数之比。这里只考虑(1-1)匹配而不考虑(0-0)匹配。

[例 2.2.2] 设两个矢量

$$\boldsymbol{x} = (0,1,0,1,1,0)^{\mathrm{T}}, \boldsymbol{y} = (0,0,1,1,0,1)^{\mathrm{T}}$$

可得

$$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}=3,\quad \boldsymbol{y}^{\mathrm{T}}\boldsymbol{y}=3,\quad \boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}=1$$

则

$$s(\boldsymbol{x},\boldsymbol{y})=\frac{1}{3+3-1}=\frac{1}{5}$$

2. Rao 测度

$$s(\boldsymbol{x},\boldsymbol{y})=\frac{a}{a+b+c+e}=\frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}}{n} \tag{2-2-19}$$

上式等于(1-1)匹配特征数目和所考查的特征数目之比。

3. 简单匹配系数

$$m(\boldsymbol{x},\boldsymbol{y})=\frac{a+e}{n} \tag{2-2-20}$$

上式表明,这时匹配系数分子为(1-1)匹配特征数目与(0-0)匹配特征数目之和,分母为所考查的特征数目。

4. Dice 系数

$$m(\boldsymbol{x},\boldsymbol{y})=\frac{2a}{2a+b+c}=\frac{2\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}+\boldsymbol{y}^{\mathrm{T}}\boldsymbol{y}} \tag{2-2-21}$$

分子、分母无(0-0)匹配,对(1-1)匹配加权。

5. Kulzinsky 系数

$$m(\boldsymbol{x},\boldsymbol{y})=\frac{a}{b+c}=\frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}+\boldsymbol{y}^{\mathrm{T}}\boldsymbol{y}-2\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}} \tag{2-2-22}$$

上式分子为(1-1)匹配特征数目,分母为(1-0)和(0-1)匹配特征数目之和。

距离测度是相异测度,其与相似测度可以通过一定的函数关系相互转换。

上面给出了许多相似性测度的具体定义式,它们各具特点,在实际使用时应根据具体问题进行选择。建立了模式相似性测度之后,两个模式的相似程度就可用数值来表征,据此便可以进行分类和识别。

2.3 类间距离

2.3.1 类间距离测度方法

在有些聚类算法中要用到类间距离，为论述简洁清楚，下面给出一些类间距离定义式。

1. 最近距离法

两个聚类 ω_k 和 ω_l 之间最近距离定义为

$$D_{kl} = \min_{i,j}[d_{ij}] \tag{2-3-1}$$

式中：d_{ij} 为 $x_i \in \omega_k$ 和 $x_j \in \omega_l$ 之间的距离。

如果 ω_l 是由 ω_p 和 ω_q 两类合并而成的，则有递推公式：

$$D_{kl} = \min[D_{kp}, D_{kq}] \tag{2-3-2}$$

2. 最远距离法

两个聚类 ω_k 和 ω_l 之间的最远距离定义为

$$D_{kl} = \max_{i,j}[d_{ij}] \tag{2-3-3}$$

式中：d_{ij} 表示 $\boldsymbol{x}_i \in \boldsymbol{\omega}_k$ 和 $\boldsymbol{x}_j \in \boldsymbol{\omega}_l$ 之间的距离。

如果 ω_l 是由 ω_p 和 ω_q 两类合并而成的，则有递推公式：

$$D_{kl} = \max[D_{kp}, D_{kq}] \tag{2-3-4}$$

3. 中间距离法

设类 ω_k 到类 ω_p 和类 ω_q 的距离分别为 D_{kp} 和 D_{kq}，ω_p 到 ω_q 的距离为 D_{pq}。以这 3 个距离值为边长作三角形 $\triangle kpq$，如图 2.3.1 所示，在 $\triangle kpq$ 中，边 pq 的中线长的平方等于 $\frac{1}{2}D_{kp}^2 + \frac{1}{2}D_{kq}^2 - \frac{1}{4}D_{pq}^2$，以其作为新类 $\omega_l = \omega_p \cup \omega_q$ 与 ω_k 间的距离，即有递推公式：

$$D_{kl}^2 = \frac{1}{2}D_{kp}^2 + \frac{1}{2}D_{kq}^2 - \frac{1}{4}D_{pq}^2 \tag{2-3-5}$$

其值介于最近距离和最远距离之间。

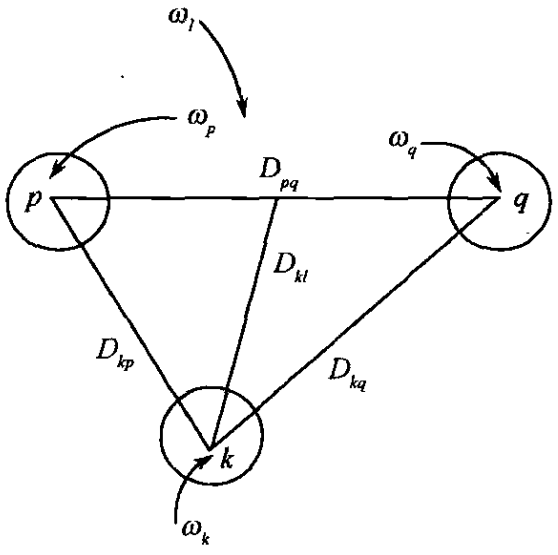


图 2.3.1　中间距离法示意图

4. 重心距离法

从物理的观点看，若一个类的空间位置要用一个点表示，则用它的重心代表较合理。于是类与类之间的距离定义为它们重心之间的距离。设类 ω_p、ω_q 的重心分别为 $\boldsymbol{x}_p$、$\boldsymbol{x}_q$，它们分别有样本 n_p、n_q 个。将 ω_p 和 ω_q 合并为 ω_l，则 ω_l 有 $n_l = n_p + n_q$ 个样本，易知 ω_l 的重心

$$\boldsymbol{x}_l = \frac{1}{n_p + n_q}(n_p \boldsymbol{x}_p + n_q \boldsymbol{x}_q) \tag{2-3-6}$$

设另一类 ω_k 的重心为 $\boldsymbol{x}_k$，则它与 ω_l 的距离平方是

$$\begin{aligned} D_{kl}^2 &= (\boldsymbol{x}_k - \boldsymbol{x}_l)^{\mathrm{T}}(\boldsymbol{x}_k - \boldsymbol{x}_l) \\ &= \left[\boldsymbol{x}_k - \frac{1}{n_p + n_q}(n_p \boldsymbol{x}_p + n_q \boldsymbol{x}_q)\right]^{\mathrm{T}} \left[\boldsymbol{x}_k - \frac{1}{n_p + n_q}(n_p \boldsymbol{x}_p + n_q \boldsymbol{x}_q)\right] \end{aligned}$$

利用

$$\boldsymbol{x}_k^{\mathrm{T}} \boldsymbol{x}_k = \frac{1}{n_p + n_q}(n_p \boldsymbol{x}_k^{\mathrm{T}} \boldsymbol{x}_k + n_q \boldsymbol{x}_k^{\mathrm{T}} \boldsymbol{x}_k)$$

最后有

$$D_{kl}^2 = \frac{n_p}{n_p + n_q} D_{kp}^2 + \frac{n_q}{n_p + n_q} D_{kq}^2 - \frac{n_p n_q}{(n_p + n_q)^2} D_{pq}^2 \tag{2-3-7}$$

5. 平均距离法

两类 ω_p 和 ω_q 之间距离平方也可定义为这两类元素两两之间的平

均平方距离，即

$$D_{pq}^2 = \frac{1}{n_p n_q} \sum_{\substack{x_i \in \omega_p \\ x_j \in \omega_q}} d_{ij}^2 \tag{2-3-8}$$

设 $\omega_l = \omega_p \cup \omega_q$，类平均距离的递推公式为

$$D_{kl}^2 = \frac{n_p}{n_p + n_q} D_{kp}^2 + \frac{n_q}{n_p + n_q} D_{kq}^2 \tag{2-3-9}$$

谱系聚类法中运用该距离定义效果较好。

6. 离差平方和法

设类 ω_t 的重心是 $\boldsymbol{x}_t$，类内离差平方和为

$$s_t = \sum_{x_i \in \omega_t} (\boldsymbol{x}_i - \boldsymbol{x}_t)^{\mathrm{T}} (\boldsymbol{x}_i - \boldsymbol{x}_t) \tag{2-3-10}$$

两类合并后，s_t 要变大，把两类合并后所增加的离差平方和定义为两类平方距离，即当 $\omega_l = \omega_p \cup \omega_q$ 时，定义 $D_{pq}^2 = s_l - s_p - s_q$。可以证明，此时的 D_{pq}^2 有

$$D_{pq}^2 = \frac{n_p n_q}{n_p + n_q} (\boldsymbol{x}_p - \boldsymbol{x}_q)^{\mathrm{T}} (\boldsymbol{x}_p - \boldsymbol{x}_q) \tag{2-3-11}$$

式中：$\boldsymbol{x}_p$、$\boldsymbol{x}_q$ 分别为 ω_p、ω_q 的重心；n_p、n_q 分别为 ω_p、ω_q 的样本个数。

离差平方和法的递推公式为

$$D_{kl}^2 = \frac{n_k + n_p}{n_k + n_l} D_{kp}^2 + \frac{n_k + n_q}{n_k + n_l} D_{kq}^2 - \frac{n_k}{n_k + n_l} D_{pq}^2 \tag{2-3-12}$$

这里，$\omega_l = \omega_p \cup \omega_q$，$n_k$、$n_l$、$n_p$ 和 n_q 分别表示 ω_k、ω_l、ω_p 和 ω_q 所含样本数。

在聚类中，采用不同的类间距离定义，可导致不同的类分布，产生不同的聚类结果，具体的影响在谱系聚类法中介绍。

2.4 准则函数

2.4.1 点与集合间的距离

在许多聚类算法中，要计算待分类模式 $\boldsymbol{x}$ 和各聚类 ω_i 间的距离 $d(\boldsymbol{x}, \omega_i)$，并将 $\boldsymbol{x}$ 归类到具有最小距离的那一类。度量点与集合的距

离分为两类，一类是各集合中的所有点都分别直接参加计算，另一类是集合用一个“模型”来代表，点与模型的距离作为点与集合的距离。

1. 第一类

在对集合的分布没有先验知识时，可采用第一类点与集合距离计算方式，这类的距离有

(1)最小距离 $d(\boldsymbol{x},\omega_i)=\min\limits_{\boldsymbol{y}\in\omega_i}[\boldsymbol{x},\boldsymbol{y}]$

(2)最大距离 $d(\boldsymbol{x},\omega_i)=\max\limits_{\boldsymbol{y}\in\omega_i}[\boldsymbol{x},\boldsymbol{y}]$

(3)平均距离 $d(\boldsymbol{x},\omega_i)=\dfrac{1}{N_i}\sum\limits_{\boldsymbol{y}\in\omega_i}d(\boldsymbol{x},\boldsymbol{y})$

式中：N_i 为 ω_i 类中模式个数。

2. 第二类

当知道集合中点分布的先验知识时，如知道集合中的点是密集分布的，在超平面或某种简单的超二次曲面附近分布的，可用相应的模型，即点、超平面、超二次曲面代替集合(图 2.4.1)，然后求点到相应模型的距离。集合模型分为如下几种型式。

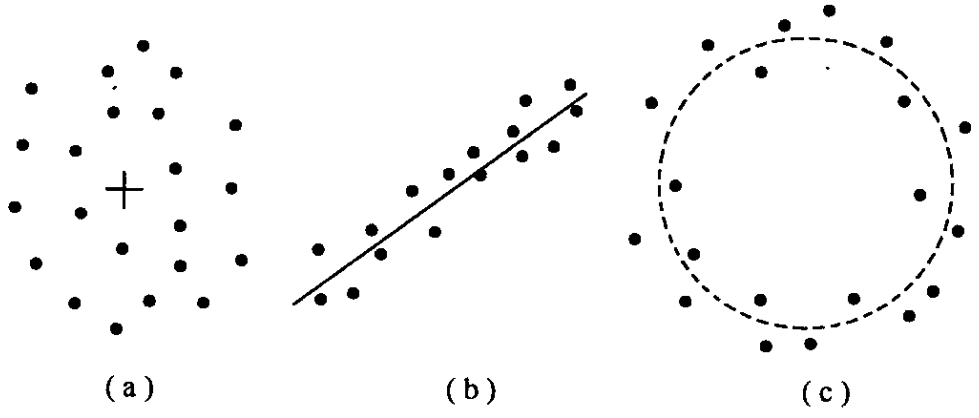


图 2.4.1　点集分布的特点

(a)致密聚类；(b)超平面(线性)聚类；(c)超球面聚类。

1)点模型

若集合是密集分布的，可以用一个点代表该集合，一个集合 ω_i 用一个点代表可以有如下方法。

(1)均矢。

$$\boldsymbol{m}_a=\frac{1}{N_i}\sum_{\boldsymbol{y}\in\omega_i}\boldsymbol{y}$$

式中：N_i 为 ω_i 类中点的个数。

(2)最值中心。集合 ω_i 中的某个点 $\boldsymbol{m}_c$ 若满足

$$\sum_{y\in\omega_i} d(\boldsymbol{m}_c,\boldsymbol{y}) = \min_{x_j\in\omega_i}\left[\sum_{y\in\omega_i} d(\boldsymbol{x}_j,\boldsymbol{y})\right]$$

则称 $\boldsymbol{m}_c$ 为集合 ω_i 的最值中心。

(3)中值中心。集合 ω_i 中的某个点 $\boldsymbol{m}_m$ 若满足

$$\operatorname*{med}_{y\in\omega_i}[d(\boldsymbol{m}_m,\boldsymbol{y})] = \operatorname*{med}_{\substack{y\in\omega_i\\ z\in\omega_i}}[d(\boldsymbol{z},\boldsymbol{y})]$$

则称 $\boldsymbol{m}_m$ 为集合 ω_i 的中值中心。

一个模式 $\boldsymbol{x}$ 与集合 ω_i 的距离定义为这个模式与集合的某个类型的中心 $\boldsymbol{m}_i(i=a,c,m)$ 的距离，常用的有欧氏距离，明氏距离，马氏距离 $d(\boldsymbol{x},\boldsymbol{m}_i)=(\boldsymbol{x}-\boldsymbol{m}_i)^T\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{m}_i)$，其中，$\boldsymbol{A}$ 为对称矩阵。

2)超平面模型

在一个超平面附近分布的模式集用一个点代表它显然是不合理的，此时可用一个超平面代表这个集合。一个超平面可以表示为

$$H: \quad \boldsymbol{w}^T\boldsymbol{z}+w_0=0$$

式中：$\boldsymbol{z}=(z_1,z_2,\cdots,z_n)^T$，$\boldsymbol{w}=(w_1,w_2,\cdots,w_n)^T$。点 $\boldsymbol{x}$ 与 H 平面的距离定义为

$$d(\boldsymbol{x},H)=\min_{z\in H} d(\boldsymbol{x},\boldsymbol{z}) \qquad (2-4-1)$$

采用欧氏距离时有

$$d(\boldsymbol{x},H)=\frac{|\boldsymbol{w}^T\boldsymbol{x}+w_0|}{\|\boldsymbol{w}\|} \qquad (2-4-2)$$

3)超球面模型

如果一个集合的模式分布是一个球面形，则可以用一个球面代表这个集合(图 2.4.1(c))。超球面 S 的方程为

$$(\boldsymbol{z}-\boldsymbol{c})^T(\boldsymbol{z}-\boldsymbol{c})=r^2 \qquad (2-4-3)$$

式中：$\boldsymbol{c}$ 为超球面的中心；r 为超球面的半径。

一点 $\boldsymbol{x}$ 到 S 的距离定义为

$$d(\boldsymbol{x},S)=\min_{\boldsymbol{z}\in S}d(\boldsymbol{x},\boldsymbol{z}) \qquad (2-4-4)$$

图 2.4.2 所示为点到超平面和超球面的距离示意图。

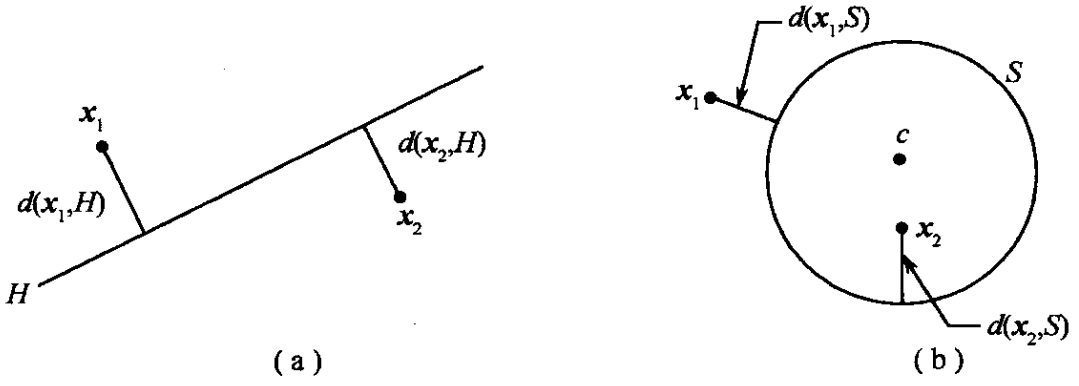


图 2.4.2　点到超平面和超球面的距离示意图

(a)点和超平面之间的距离；(b)点和超球面之间的距离。

2.4.2　聚类的准则函数

在定义了模式与模式的相似性测度、点与集合的距离、类与类之间的距离之后，为了能对模式集进行有效的分类，某些算法需要一个准则函数，依其对分类过程或分类结果的优劣进行指导与评估，如果聚类准则函数选择得好，聚类质量就会高。聚类准则函数往往是和类的定义有关的，是类的定义的某种体现。

1. 类内距离准则

设有待分类的模式集$\{\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N\}$在某种相似性测度基础上被分划为 c 类$\{\boldsymbol{x}_i^{(j)};j=1,2,\cdots,c;i=1,2,\cdots,n_j\}$，其中上角标 j 表示类别，下角标 i 表示类内模式的序号，$\sum_{j=1}^{c}n_j=N$，类内距离准则函数 J_{W} 定义为

$$J_{\mathrm{W}}=\sum_{j=1}^{c}\sum_{i=1}^{n_j}\|\boldsymbol{x}_i^{(j)}-\boldsymbol{m}_j\|^2 \qquad (2-4-5)$$

式中：$\boldsymbol{m}_j$ 表示 ω_j 类的模式均值矢量：

$$\boldsymbol{m}_j=\frac{1}{n_j}\sum_{i=1}^{n_j}\boldsymbol{x}_i^{(j)} \quad (j=1,2,\cdots,c) \qquad (2-4-6)$$

式(2-4-5)表征了各模式到其被指判的类的类心距离平方和。我们

的目标是使 J_W 取最小。J_W 值越大，说明某些模式没有就近分类，在此意义上聚类效果不好，应重新调整分划。这种准则也称为误差平方和准则。

显然，J_W 是模式 $\boldsymbol{x}_i$ 和类心 $\boldsymbol{m}_j$ 的函数，在样本集 $\{\boldsymbol{x}_i\}$ 和类数给定条件下，J_W 的值取决于模式类别的分划与类心的选取，在确定的类心计算方式下，其等价于模式类别的分划。这个准则适用于同类模式比较密聚，且各类模式分布区域体积差别不大的情况，否则采用该准则可能是不适宜的。例如：当某一类模式数目较多而另一类模式较少，两类模式所占空间大小明显不同，两类间的距离又不足够大时，模式较多的那类中一些边缘处的模式可能距离另一类的类心更近一些。

类内距离除了采用欧氏距离外，也可以根据问题采用其他的相似性测度。

2. 类间距离准则

也可以用总的类间距离最大作为聚类的准则。类间距离准则定义为

$$J_B = \sum_{j=1}^{c} (\boldsymbol{m}_j - \boldsymbol{m})^T (\boldsymbol{m}_j - \boldsymbol{m}) \Rightarrow \max \qquad (2-4-7)$$

式中：$\boldsymbol{m}_j$ 为 ω_j 类的模式平均矢量，$\boldsymbol{m}$ 为总的模式平均矢量。

设 n_j 为 ω_j 类所含模式个数，则

$$\boldsymbol{m}_j = \frac{1}{n_j} \sum_{\boldsymbol{x}_i \in \omega_j} \boldsymbol{x}_i$$

$$\boldsymbol{m} = \frac{1}{N} \sum_{i=1}^{N} \boldsymbol{x}_i$$

对于两类问题，类间距离有时取

$$J_{B2} = (\boldsymbol{m}_1 - \boldsymbol{m}_2)^T (\boldsymbol{m}_1 - \boldsymbol{m}_2) \qquad (2-4-8)$$

3. 基于类内距离类间距离的准则函数

我们希望聚类结果使类内距离越小越好，类间距离越大越好，为此构造能同时反映出类内距离和类间距离的准则函数。

设待分类模式集 $\{\boldsymbol{x}_i, i=1,2,\cdots,N\}$，将它们分成 c 类，其中：ω_j 类含 n_j 个模式，分类后各模式记为 $\{\boldsymbol{x}_i^{(j)}, j=1,2,\cdots,c; i=1,2,\cdots,n_j\}$。

ω_j 的类内离差阵定义为

$$\boldsymbol{S}_{\mathrm{W}}^{(j)} = \frac{1}{n_j}\sum_{i=1}^{n_j}(\boldsymbol{x}_i^{(j)} - \boldsymbol{m}_j)(\boldsymbol{x}_i^{(j)} - \boldsymbol{m}_j)^{\mathrm{T}} \quad (j = 1,2,\cdots,c) \tag{2-4-9}$$

式中：$\boldsymbol{m}_j$ 为 ω_j 类的模式均值矢量

$$\boldsymbol{m}_j = \frac{1}{n_j}\sum_{i=1}^{n_j}\boldsymbol{x}_i^{(j)} \quad (j = 1,2,\cdots,c) \tag{2-4-10}$$

总的类内离差阵定义为

$$\boldsymbol{S}_{\mathrm{W}} = \sum_{j=1}^{c}\frac{n_j}{N}\boldsymbol{S}_{\mathrm{W}}^{(j)} \tag{2-4-11}$$

类间离差阵定义为

$$\boldsymbol{S}_{\mathrm{B}} = \sum_{j=1}^{c}\frac{n_j}{N}(\boldsymbol{m}_j - \boldsymbol{m})(\boldsymbol{m}_j - \boldsymbol{m})^{\mathrm{T}} \tag{2-4-12}$$

式中：$\boldsymbol{m}$ 为所有待分类模式的均值矢量

$$\boldsymbol{m} = \frac{1}{N}\sum_{i=1}^{N}\boldsymbol{x}_i \tag{2-4-13}$$

总的离差阵 $\boldsymbol{S}_{\mathrm{T}}$ 定义为

$$\boldsymbol{S}_{\mathrm{T}} = \frac{1}{N}\sum_{i=1}^{N}(\boldsymbol{x}_i - \boldsymbol{m})(\boldsymbol{x}_i - \boldsymbol{m})^{\mathrm{T}} \tag{2-4-14}$$

$\boldsymbol{S}_{\mathrm{W}}$、$\boldsymbol{S}_{\mathrm{B}}$ 和 $\boldsymbol{S}_{\mathrm{T}}$ 有下面的关系：

$$\boldsymbol{S}_{\mathrm{T}} = \boldsymbol{S}_{\mathrm{W}} + \boldsymbol{S}_{\mathrm{B}} \tag{2-4-15}$$

证：

$$\begin{aligned}\boldsymbol{S}_{\mathrm{T}} &= \sum_{j=1}^{c}\frac{n_j}{N}\frac{1}{n_j}\sum_{i=1}^{n_j}(\boldsymbol{x}_i^{(j)} - \boldsymbol{m})(\boldsymbol{x}_i^{(j)} - \boldsymbol{m})^{\mathrm{T}} \\ &= \sum_{j=1}^{c}\frac{n_j}{N}\left[\frac{1}{n_j}\sum_{i=1}^{n_j}(\boldsymbol{x}_i^{(j)} - \boldsymbol{m}_j)(\boldsymbol{x}_i^{(j)} - \boldsymbol{m}_j)^{\mathrm{T}}\right. \\ &\quad \left. + (\boldsymbol{m}_j - \boldsymbol{m})(\boldsymbol{m}_j - \boldsymbol{m})^{\mathrm{T}}\right] \\ &= \boldsymbol{S}_{\mathrm{W}} + \boldsymbol{S}_{\mathrm{B}}\end{aligned}$$

由定义可知，总的离差阵 $\boldsymbol{S}_T$ 与模式集如何具体分类无关，只取决于各模式的分布，即一旦模式集给定后，总的离差阵 $\boldsymbol{S}_T$ 也就随之确定，而类内离差阵 $\boldsymbol{S}_W$ 与类间离差阵 $\boldsymbol{S}_B$ 不仅与各模式的分布有关，还与类的分划有关，一旦模式集给定后，它们是由模式集分类结果所决定的。

$\boldsymbol{S}_W$、$\boldsymbol{S}_B$ 与 $\boldsymbol{S}_T$ 都分别从不同的方面反映模式散布的结构信息。为了能利用 $\boldsymbol{S}_W$、$\boldsymbol{S}_B$ 或 $\boldsymbol{S}_T$ 所提供的信息构造准则函数，可以利用它们的数值特征（如迹、行列式、特征值等）构造准则函数。

可以证明，$\boldsymbol{S}_W^{-1}\boldsymbol{S}_B$ 的特征值 $\lambda_1, \lambda_2, \cdots, \lambda_n$ 是非奇异线性变换下的不变量，它们反映了模式类间离差与类内离差在特征矢量方向上的比值。我们希望聚类结果使这些特征值尽量大。由于存在关系 $\boldsymbol{S}_T = \boldsymbol{S}_W + \boldsymbol{S}_B$，因此利用线性代数有关矩阵正交变换的迹和行列式的性质，可以构造一类基于不变量 $\lambda_1, \lambda_2, \cdots, \lambda_n$ 的形式上不同、性能也略有差别但几乎是等价的准则函数：

$$J_1 = \mathrm{Tr}[\boldsymbol{S}_W^{-1}\boldsymbol{S}_B] \Rightarrow \max \tag{2-4-16}$$

$$J_2 = \mathrm{Tr}[\boldsymbol{S}_W^{-1}\boldsymbol{S}_T] \Rightarrow \max \tag{2-4-17}$$

$$J_3 = |\boldsymbol{S}_W^{-1}\boldsymbol{S}_T| \Rightarrow \max \tag{2-4-18}$$

$$J_4 = \frac{|\boldsymbol{S}_W|}{|\boldsymbol{S}_T|} \Rightarrow \min \tag{2-4-19}$$

当 $\boldsymbol{S}_W^{-1}$ 不存在时，也可采用

$$J_5 = \mathrm{Tr}[\boldsymbol{S}_T^{-1}\boldsymbol{S}_W] \Rightarrow \min \tag{2-4-20}$$

$$J_6 = |\boldsymbol{S}_T^{-1}\boldsymbol{S}_W| \Rightarrow \min \tag{2-4-21}$$

上述的准则函数都具有非奇异线性变换不变性，所以对应的最优分类也具有不变性。当类数较多时，这些准则函数对应的最优分类尽管不同但是相似的，因各准则函数在本质上是相似的。对于两类情况，由于只有一个特征值非零，所以上面的各准则函数产生的分类结果是相同的。

这些准则在特征提取和选择中也有较多的应用。

除了上述的几种准则函数之外，还有近邻函数准则等，该准则函数的构造连同分类算法将在 2.5 节中介绍。

2.5 聚类的算法

2.5.1 聚类的技术方案

聚类分析有许多具体的算法，有的比较简单，有的相对复杂完善，从算法的基本策略上看，可以分为如下几种主要典型方法，其他方法基本上是由它们派生出来的或相近的。

(1)根据相似性阈值和最小距离原则的简单聚类方法。针对具体问题确定相似性阈值，将模式到各聚类中心间的距离与阈值比较，都大于阈值时该模式就作为另一类的类心，小于阈值时按最小距离原则将其分划到某一类中。这类算法运行中模式的类别及类的中心一旦确定将不会改变。

(2)按最小距离原则不断进行两类合并的方法。首先视各模式自成一类，然后将距离最小的两类合并成一类，不断地重复这个过程，直到成为两类为止。这类算法运行中，类心不断地修正，但某些模式一旦归为一类后就不再被分划开。这类方法称为谱系聚类法。

(3)依据准则函数动态聚类法。设定一些分类的控制参数，定义一个能表征聚类过程或结果优劣的准则函数，聚类过程就是使准则函数取极值的优化过程。算法运行中，类心不断地修正，各模式的类别的指定也不断地更改。这类方法有 C－均值法、ISODATA 法等。

(4)近邻函数法。近邻函数法利用近邻函数的概念和有关的规则进行分类，它可以处理类的分布结构较复杂的情况。

此外还有基于神经网络的方法等。

2.5.2 基于相似性阈值的简单聚类方法

1. 根据相似性阈值和最小距离原则的简单聚类方法

1)条件及约定

设待分类的模式特征矢量为 $\{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N\}$，选定类内距离门限 T。

2)算法思想

计算特征矢量到各聚类中心的距离并和门限 T 比较,决定归属哪一类或作为新的一类中心。这种算法通常选择欧氏距离。

3)算法原理步骤

(1)取任意的一个特征矢量作为第一个聚类中心。例如,令 ω_1 类的中心 $z_1 = x_1$。

(2)计算下一个特征矢量 x_2 到 z_1 的距离 d_{21}。若 $d_{21} > T$,则建立新的一类 ω_2,其中心 $z_2 = x_2$;若 $d_{21} \leqslant T$,则 $x_2 \in \omega_1$。

(3)假设已有聚类中心 $z_1, z_2, \cdots, z_k$,计算尚未确定类别的特征矢量 x_i 到各聚类中心 $z_j (j = 1, 2, \cdots, k)$ 的距离 d_{ij}。如果 $d_{ij} > T (j = 1, 2, \cdots, k)$,则 x_i 作为新的一类 ω_{k+1} 的中心,$z_{k+1} = x_i$;否则,如果

$$d_{il} = \min_j [d_{ij}] \tag{2-5-1}$$

则指判 $x_i \in \omega_l$。检查是否所有的模式都分划完类别,如都分划完了则结束;否则返到(3)。

4)性能

这种方法的突出特点是计算简单。容易看出,使用这种方法聚类过程中类的中心一经选定,在聚类过程中就不再改变;同样,在聚类过程中,模式一旦指判类别后也不再改变。因此,在待分类模式集给定的条件下,使用这种方法的聚类结果很大程度上依赖于距离门限 T 的选取、待分类特征矢量参与分类的次序即聚类中心的选取。当有特征矢量分布的先验知识来指导门限 T 及初始中心 z_1 的选取时,可以获得较合理结果。

图 2.5.1 所示为距离阈值及初始类心对聚类的影响。

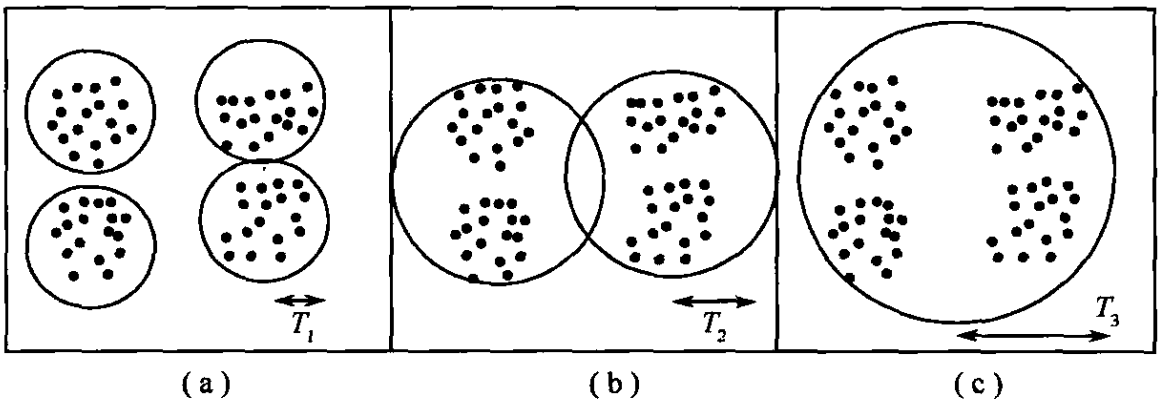


图 2.5.1 距离阈值及初始类心对聚类的影响

2. 最大最小距离算法

1)条件及约定

设待分类的模式特征矢量集为$\{\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N\}$,选定比例系数$\theta$。

2)基本思想

在特征矢量集中以最大距离原则选取新的聚类中心,以最小距离原则进行模式归类。这种方法通常也使用欧氏距离。

3)算法原理步骤

(1)选任一特征矢量作为第一个聚类中心z_1。例如,$z_1=\boldsymbol{x}_1$。

(2)从待分类特征矢量集中选距离z_1最远的特征矢量作为第二个聚类中心z_2。例如图2.5.2中$\|\boldsymbol{x}_6-\boldsymbol{x}_1\|$最大,取$z_2=\boldsymbol{x}_6$。

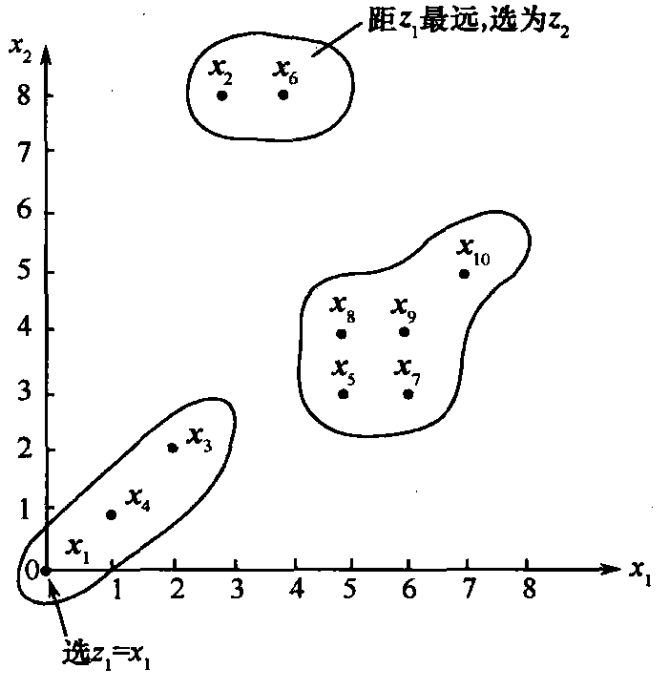


图2.5.2 最大最小距离算法举例

(3)计算未被作为聚类中心的各特征矢量$\{\boldsymbol{x}_i\}$与z_1、z_2之间的距离,并求出它们之中的最小值,即

$$d_{ij}=\|\boldsymbol{x}_i-\boldsymbol{z}_j\|,\quad (j=1,2)$$

$$d_i=\min[d_{i1},d_{i2}],\quad (i=1,2,\cdots,N) \qquad (2-5-2)$$

为表述简洁,虽然某些模式已选作聚类中心,但上面仍将所有模式下角标全部列写出来,因这并不影响算法的正确性。

(4)若

$$d_l = \max_i [\min(d_{i1}, d_{i2})] > \theta \| z_1 - z_2 \| \qquad (2-5-3)$$

则相应的特征矢量 x_l 作为第三个聚类中心，$z_3 = x_l$。此例中 $z_3 = x_7$。然后转至(5)；否则，转至最后一步(6)。

(5)设存在 k 个聚类中心，计算未被作为聚类中心的各特征矢量到各聚类中心的距离 d_{ij}，并算出

$$d_l = \max_i [\min[d_{i1}, d_{i2}, \cdots, d_{ik}]] \qquad (2-5-4)$$

如果 $d_l > \theta \| z_1 - z_2 \|$，则 $z_{k+1} = x_l$ 并转至(5)；否则，转至最后一步(6)。

(6)当判断出不再有新的聚类中心之后，将特征矢量 $\{x_1, x_2, \cdots, x_N\}$ 按最小距离原则分到各类中去，即计算

$$d_{ij} = \| x_i - z_j \| \quad (j = 1, 2, \cdots; i = 1, 2, \cdots, N) \qquad (2-5-5)$$

当 $d_{il} = \min_j [d_{ij}]$，则判 $x_i \in \omega_l$。在此例中，$\{x_1, x_3, x_4\} \in \omega_1, z_1 = x_1$；$\{x_2, x_6\} \in \omega_2, z_2 = x_6$；$\{x_5, x_7, x_8, x_9, x_{10}\} \in \omega_3, z_3 = x_7$。

这种算法的聚类结果与参数 θ 以及第一个聚类中心的选取有关。如果没有先验知识指导 θ 和 z_1 的选取，可适当调整 θ 和 z_1，比较多次试探分类结果，选取最合理的一种聚类。

2.5.3 谱系聚类法

谱系聚类法(Hierarchical Clustering Method)，又称系统聚类法或层次聚类法，是效果较好、经常使用的方法之一，国内外研究得较为深入，有不少成果。

1. 条件及约定

设待分类的模式特征矢量为 $\{x_1, x_2, \cdots, x_N\}$，$G_i^{(k)}$ 表示第 k 次合并时的第 i 类。

2. 基本思想

首先将 N 个模式视作各自成为一类，然后计算类与类之间的距离，选择距离最小的一个类对合并成一个新类，计算在新的类别分划下各类之间的距离，再将距离最近的两类合并，直至所有模式聚成两类

为止。

3. 算法步骤

(1)初始分类。令 $k=0$,每个模式自成一类,即 $G_i^{(0)}=\{\boldsymbol{x}_i\}(i=1,2,\cdots,N)$。

(2)计算各类间的距离 D_{ij},由此生成一个对称的距离矩阵 $\boldsymbol{D}^{(k)}=(D_{ij})_{m\times m}$,$m$ 为类的个数(初始时 $m=N$)。

(3)找出前一步求得的矩阵 $\boldsymbol{D}^{(k)}$ 中的最小元素,设它是 $G_i^{(k)}$ 和 $G_j^{(k)}$ 间的距离,将 $G_i^{(k)}$ 和 $G_j^{(k)}$ 两类合并成一类,令 $k=k+1$,于是产生新的聚类 $G_1^{(k+1)},G_2^{(k+1)},\cdots$,令 $m=m-1$。

(4)检查类的个数。如果类数 m 大于 2,转至(2);否则,停止。

谱系聚类过程可以表示成一个层次树,层次树是由树图表示的嵌套分类图,图 2.5.3 给出了一个示例。

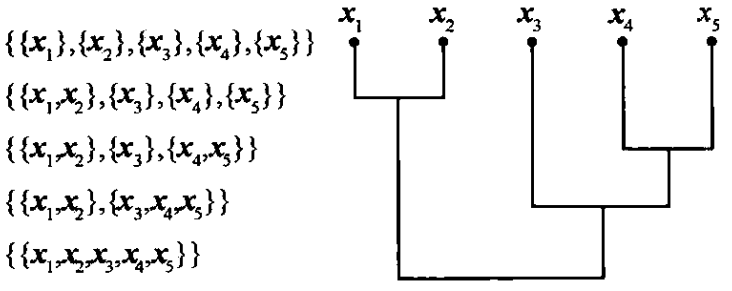


图 2.5.3　聚类层次及其相应的树图

在谱系聚类法中,使用者的关键性技术工作主要是类间距离的选择和类数的确定,它们决定着给定模式集的最后聚类结果。在谱系聚类法中可以采用上节已详细介绍过的不同的类间距离定义,并使用类间距离递推公式。不同的类间距离度量方式将导致不同的分层结构,也就是说,所采用的类间距离定义不同,聚类过程和结果是不一样的。基于最远距离的聚类算法在聚类过程中,类域的半径增长得最慢,这种算法不会促成一个细长分布的类出现,倾向于“成团”聚类,因合并后类内任两个模式间的距离都不大于这两个类的类间距离;基于最近距离的聚类算法则有可能产生细长分布的类;这两种算法都对孤立点和噪声很敏感,最近距离和最远距离是类间距离定义的两个极端;显然,用这两个距离的“折中”如平均距离和重心距离可以避免上述问题;采用中间距离可以克服采用重心距离时当一个较小的聚类与一个较大的

聚类合并时，合并后的重心将靠近较大聚类的重心的问题，这对于某些应用是有利的；基于离差平方和的聚类算法倾向于将孤立点或较小的类与较大的类合并。

上述算法给出了从 N 类至 2 类的聚类过程，在实际应用中没有必要产生所有的层次，可根据某些信息停止聚类过程。该算法可将类间距离门限 T 作为停止条件，当 $\boldsymbol{D}^{(k)}$ 中最小阵元大于 T 时，聚类过程停止；该算法也可将预定的类别数目作为停止条件，在类别合并过程中，类数等于预定值时，聚类过程停止。

[**例 2.5.1**]给出 6 个样本特征矢量如下，按最小距离原则进行聚类。

$$\boldsymbol{x}_1=(0,3,1,2,0)^{\mathrm{T}} \quad \boldsymbol{x}_2=(1,3,0,1,0)^{\mathrm{T}} \quad \boldsymbol{x}_3=(3,3,0,0,1)^{\mathrm{T}}$$

$$\boldsymbol{x}_4=(1,1,0,2,0)^{\mathrm{T}} \quad \boldsymbol{x}_5=(3,2,1,2,1)^{\mathrm{T}} \quad \boldsymbol{x}_6=(4,1,1,1,0)^{\mathrm{T}}$$

解：

(1)将每一样本看成自成一类

$$G_1^{(0)}=\{\boldsymbol{x}_1\} \qquad G_2^{(0)}=\{\boldsymbol{x}_2\} \qquad G_3^{(0)}=\{\boldsymbol{x}_3\}$$

$$G_4^{(0)}=\{\boldsymbol{x}_4\} \qquad G_5^{(0)}=\{\boldsymbol{x}_5\} \qquad G_6^{(0)}=\{\boldsymbol{x}_6\}$$

按欧氏距离计算距离矩阵 $\boldsymbol{D}^{(0)}$（表 2.5.1）。

(2)$\boldsymbol{D}^{(0)}$ 中最小阵元为$\sqrt{3}$，它是 $G_1^{(0)}$ 与 $G_2^{(0)}$ 之间的距离，将它们合并为一类，得一新的分类为

$$G_1^{(1)}=\{G_1^{(0)},G_2^{(0)}\}=\{\boldsymbol{x}_1,\boldsymbol{x}_2\} \qquad G_2^{(1)}=G_3^{(0)}$$

$$G_3^{(1)}=G_4^{(0)} \qquad G_4^{(1)}=G_5^{(0)} \qquad G_5^{(1)}=G_6^{(0)}$$

计算合并后的距离矩阵 $\boldsymbol{D}^{(1)}$（表 2.5.2）。在这里使用了距离递推公式，如

$$D_{12}^{(1)}=\min\{G_1^{(0)} \text{ 与 } G_2^{(1)} \text{ 距离},G_2^{(0)} \text{ 与 } G_2^{(1)} \text{ 距离}\}$$

$$=\min(\sqrt{15},\sqrt{6})=\sqrt{6}$$

(3)$\boldsymbol{D}^{(1)}$ 中距离最小者为$\sqrt{4}$，它是 $G_4^{(1)}$ 与 $G_5^{(1)}$ 间的距离，合并 $G_4^{(1)}$ 和 $G_5^{(1)}$，得新的分类

$$G_1^{(2)}=G_1^{(1)} \qquad G_2^{(2)}=G_2^{(1)}$$

$$G_3^{(2)}=G_3^{(1)} \qquad G_4^{(2)}=\{G_4^{(1)},G_5^{(1)}\}$$

同样计算 $\boldsymbol{D}^{(2)}$（表 2.5.3），进一步聚类得

$$G_1^{(3)}=\{G_1^{(2)},G_3^{(2)}\}\qquad G_2^{(3)}=G_2^{(2)}\qquad G_3^{(3)}=G_4^{(2)}$$

即 $$G_1^{(3)}=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\boldsymbol{x}_4\}\qquad G_2^{(3)}=\{\boldsymbol{x}_3\}\qquad G_3^{(3)}=\{\boldsymbol{x}_5,\boldsymbol{x}_6\}$$

计算 $\boldsymbol{D}^{(3)}$（表 2.5.4）。

（4）由表可知，$G_1^{(3)}$、$G_3^{(3)}$ 和 $G_2^{(3)}$ 距离相同，可以依据其他因素将其中两类合并成一类。

聚类过程表示成层次树如图 2.5.4 所示。

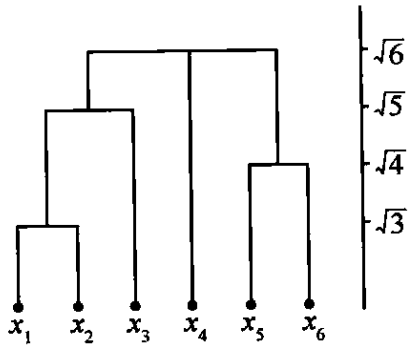


图 2.5.4　例题的聚类树图

表 2.5.1　$D^{(0)}$

	$G_1^{(0)}$	$G_2^{(0)}$	$G_3^{(0)}$	$G_4^{(0)}$	$G_5^{(0)}$	$G_6^{(0)}$
$G_1^{(0)}$	0					
$G_2^{(0)}$	$\sqrt{3}^*$	0				
$G_3^{(0)}$	$\sqrt{15}$	$\sqrt{6}$	0			
$G_4^{(0)}$	$\sqrt{6}$	$\sqrt{5}$	$\sqrt{13}$	0		
$G_5^{(0)}$	$\sqrt{11}$	$\sqrt{8}$	$\sqrt{6}$	$\sqrt{7}$	0	
$G_6^{(0)}$	$\sqrt{21}$	$\sqrt{14}$	$\sqrt{8}$	$\sqrt{11}$	$\sqrt{4}$	0

表 2.5.2　$D^{(1)}$

	$G_1^{(1)}$	$G_2^{(1)}$	$G_3^{(1)}$	$G_4^{(1)}$	$G_5^{(1)}$
$G_1^{(1)}$	0				
$G_2^{(1)}$	$\sqrt{6}$	0			
$G_3^{(1)}$	$\sqrt{5}$	$\sqrt{13}$	0		
$G_4^{(1)}$	$\sqrt{8}$	$\sqrt{6}$	$\sqrt{7}$	0	
$G_5^{(1)}$	$\sqrt{14}$	$\sqrt{8}$	$\sqrt{11}$	$\sqrt{4}^*$	0

表 2.5.3　$D^{(2)}$

	$G_1^{(2)}$	$G_2^{(2)}$	$G_3^{(2)}$	$G_4^{(2)}$
$G_1^{(2)}$	0			
$G_2^{(2)}$	$\sqrt{6}$	0		
$G_3^{(2)}$	$\sqrt{5}^*$	$\sqrt{13}$	0	
$G_4^{(2)}$	$\sqrt{8}$	$\sqrt{6}$	$\sqrt{7}$	0

表 2.5.4　$D^{(3)}$

	$G_1^{(3)}$	$G_2^{(3)}$	$G_3^{(3)}$
$G_1^{(3)}$	0		
$G_2^{(3)}$	$\sqrt{6}$	0	
$G_3^{(3)}$	$\sqrt{7}$	$\sqrt{6}$	0

2.5.4 动态聚类法(Dynamic clustering algorithm)

2.5.2 节和 2.5.3 节中的算法一个共同特点是某个模式一旦分划到某一类之后,在后续的算法过程中就不改变了,而 2.5.1 节算法中类心一旦选定后在后续算法过程中也不再改变了,这类方法效果一般不会太理想。和上述各算法相对有一种动态聚类法。动态聚类技术要点为以下几点。

(1)确定模式和聚类的距离测度。当采用欧氏距离时,是计算此模式和该类中心的欧氏距离;为能反映出类的模式分布结构,应采用马氏距离,设该类的均矢为 $\boldsymbol{\mu}$,协方差阵为 $\boldsymbol{\Sigma}$,则模式 $\boldsymbol{x}$ 和该类的距离平方为 $\boldsymbol{x}$ 与该类均矢 $\boldsymbol{\mu}$ 的马氏距离(平方),即

$$d^2 = (\boldsymbol{x} - \boldsymbol{\mu})^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu})$$

(2)建立评估聚类质量的准则函数。

(3)确定模式分划及聚类合并或分裂的规则。

动态聚类算法的基本步骤有以下几步。

(1)选取初始聚类中心,进行初始聚类。

(2)计算模式和类的距离,调整模式的类别。

(3)计算各聚类的参数,删除、合并或分裂一些聚类。

(4)从初始聚类开始,运用迭代算法动态地改变模式的类别和聚类的中心使准则函数取得极值或设定的参数达到设计要求时停止。

动态聚类原理框图如图 2.5.5 所示。

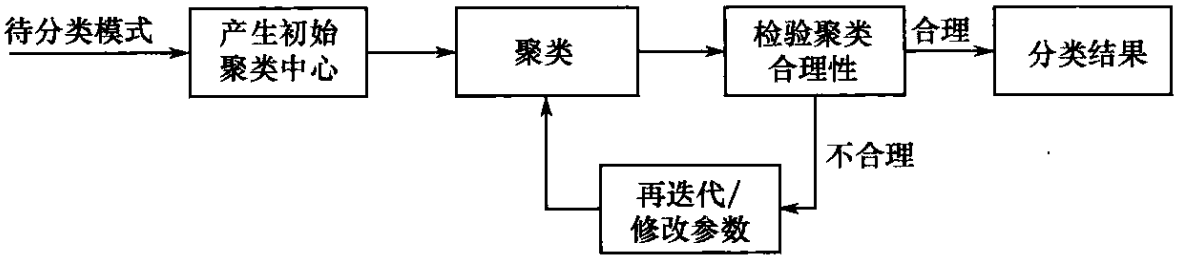


图 2.5.5 动态聚类方法示意图

1. C – 均值法(C – Means)

1)条件及约定

设待分类的模式特征矢量集为 $\{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N\}$,类的数目 c 是事先

取定的。

2)基本思想

该方法取定 c 个类别和选取 c 个初始聚类中心,按最小距离原则将各模式分配到 c 类中的某一类,之后不断地计算类心和调整各模式的类别,最终使各模式到其判属类别中心的距离平方之和最小。

3)算法步骤

(1)任选 c 个模式特征矢量作为初始聚类中心:$z_1^{(0)}, z_2^{(0)}, \cdots, z_c^{(0)}$,令 $k=0$。

(2)将待分类的模式特征矢量集 $\{x_i\}$ 中的模式逐个按最小距离原则分划给 c 类中的某一类,即

$$\begin{aligned} &\text{如果} \quad d_{il}^{(k)} = \min_j [d_{ij}^{(k)}] \quad (i=1,2,\cdots,N) \\ &\text{则判} \quad x_i \in \omega_l^{(k+1)} \end{aligned} \tag{2-5-6}$$

式中:$d_{ij}^{(k)}$ 表示 x_i 和 $\omega_j^{(k)}$ 的中心 $z_j^{(k)}$ 的距离,上角标表示迭代次数。于是产生新的聚类 $\omega_j^{(k+1)}(j=1,2\cdots,c)$。

(3)计算重新分类后的各类心

$$z_j^{(k+1)} = \frac{1}{n_j^{(k+1)}} \sum_{x_i \in \omega_j^{(k+1)}} x_i, \quad (j=1,2,\cdots,c) \tag{2-5-7}$$

式中:$n_j^{(k+1)}$ 为 $\omega_j^{(k+1)}$ 类中所含模式的个数。

因为这一步采取平均的方法计算调整后各类的中心,且定为 c 类,故称 C-均值法。

(4)如果 $z_j^{(k+1)} = z_j^{(k)}(j=1,2,\cdots,c)$,则结束;否则,转至(2)。

4)性能

C-均值法是以确定的类数及选定的初始聚类中心为前提,使各模式到其所判属类别中心距离(平方)之和最小的最佳聚类。显然,该算法的分类结果受到取定的类别数目及聚类中心初始位置的影响,所以结果只是局部最优的;但其方法简单,结果尚令人满意,故应用较多。如模式分布呈现类内团聚状,该算法是能达到很好聚类结果的。在实际应用中需试探不同的 c 值和选择不同的聚类中心初始值,以进一步达到更大范围的最优结果。上述算法的特点是所有待分类模式按最小

距离原则分划类别之后再计算各类的中心，这称为按批修改法；另一种方法是每向算法输入一个模式后就将它进行分类，并计算该模式所进入类的类心，这称为逐个修改法，因而其还受模式读入次序的影响。逐个修改和按批修改方式的动态聚类法的收敛性已于 1967 年和 1974 年分别给出了严格证明。

[**例 2.5.2**]模式分布如图 2.5.6 所示，试用 C－均值法进行聚类，取 $c=2$。

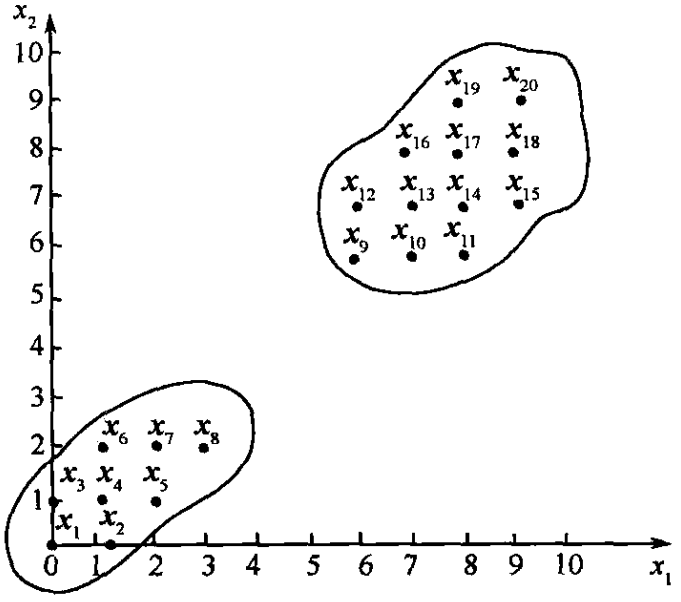


图 2.5.6　C－均值法例题的模式集

解：

(1)选 $z_1^{(0)}=x_1=(0,0)^{\mathrm{T}}, z_2^{(0)}=x_2=(1,0)^{\mathrm{T}}$

(2)因　$\|x_1-z_1^{(0)}\|<\|x_1-z_2^{(0)}\|$，　故 $x_1\in\omega_1^{(1)}$

$\|x_2-z_1^{(0)}\|>\|x_2-z_2^{(0)}\|$，　故 $x_2\in\omega_2^{(1)}$

$\|x_3-z_1^{(0)}\|<\|x_3-z_2^{(0)}\|$，　故 $x_3\in\omega_1^{(1)}$

……

得　$\omega_1^{(1)}=\{x_1,x_3\}, N_1=2; \omega_2^{(1)}=\{x_2,x_4,\cdots,x_{20}\}, N_2=18$

(3)计算新的聚类中心

$$z_1^{(1)}=\frac{1}{N_1}\sum_{x_i\in\omega_1^{(1)}}x_i=\frac{1}{2}(x_1+x_3)=\begin{pmatrix}0.0\\0.5\end{pmatrix}$$

$$z_2^{(1)}=\frac{1}{N_2}\sum_{x_i\in\omega_2^{(1)}}x_i=\frac{1}{18}(x_2+x_4+\cdots+x_{20})=\begin{pmatrix}5.67\\5.33\end{pmatrix}$$

(4)因 $z_j^{(1)} \neq z_j^{(0)}\ (j=1,2)$,故转至(2)。

(2)′由新的聚类中心,得

$$\| x_l - z_1^{(1)} \| < \| x_l - z_2^{(1)} \| \quad (l=1,2,\cdots,8)$$

$$\| x_l - z_1^{(1)} \| > \| x_l - z_2^{(1)} \| \quad (l=9,10,\cdots,20)$$

故得

$$\omega_1^{(2)} = \{x_1, x_2, \cdots, x_8\} \quad (N_1 = 8)$$

$$\omega_2^{(2)} = \{x_9, x_{10}, \cdots, x_{20}\} \quad (N_2 = 12)$$

(3)′计算聚类中心

$$z_1^{(2)} = \frac{1}{N_1} \sum_{x_i \in \omega_1^{(2)}} x_i = \frac{1}{8}(x_1 + x_2 + \cdots + x_8) = \begin{pmatrix} 1.25 \\ 1.13 \end{pmatrix}$$

$$z_2^{(2)} = \frac{1}{N_2} \sum_{x_i \in \omega_2^{(2)}} x_i = \frac{1}{12}(x_9 + x_{10} + \cdots + x_{20}) = \begin{pmatrix} 7.67 \\ 7.33 \end{pmatrix}$$

(4)′因 $z_j^{(2)} \neq z_j^{(1)}\ (j=1,2)$,故转至(2)。

(2)″求得的分类结果与前一次的结果相同,$\omega_j^{(3)} = \omega_j^{(2)}\ (j=1,2)$。

(3)″各聚类中心必然也与前一次的相同,$z_j^{(3)} = z_j^{(2)}\ (j=1,2)$。

因 $z_j^{(3)} = z_j^{(2)}\ (j=1,2)$,不再出现新的类别划分,故分类过程结束。

2. ISODATA 算法(Iterative Self-Organizing Data Analysis Techniques Algorithm)

迭代自组织数据分析算法具有启发性推理、分析监督、控制聚类结构及人机交互等特点,是较好的聚类方法之一。

1)条件及约定

设待分类的模式特征矢量为 $\{x_1, x_2, \cdots, x_N\}$,算法运行前需设定 7 个初始参数。

2)算法思想

在每轮迭代过程中,样本重新调整类别之后计算类内及类间有关参数,并和设定的门限比较,确定是两类合并为一类还是一类分裂为两类,不断地“自组织”,以达到在各参数满足设计要求条件下,使各模式

到其类心的距离平方和最小。

3)算法原理步骤

(1)预置。

①设定聚类分析控制参数:

c = 预期的类数;

N_c = 初始聚类中心个数(可以不等于 c);

θ_n = 每一类中允许的最少模式数目(若少于此数就不能单独成为一类);

θ_s = 类内各分量分布距离标准差上限(大于此数就分裂);

θ_D = 两类中心间最小距离下限(若小于此数,这两类应合并);

L = 在每次迭代中可以合并的类的最多对数;

I = 允许的最多迭代次数。

②将待分类的模式特征矢量$\{\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N\}$读入。

③选定初始聚类中心,可从待分类的模式特征矢量集$\{\boldsymbol{x}_i\}$中任选 N_c 个模式特征矢量作为初始聚类中心 $\boldsymbol{z}_j(j=1,2,\cdots,N_c)$。

(2)按最小距离原则将模式集$\{\boldsymbol{x}_i\}$中每个模式分到某一类中,即

$$\text{如果 } d_{il}=\min_j \|\boldsymbol{x}_i-\boldsymbol{z}_j\| \quad (i=1,2,\cdots,N)$$
$$\text{则判 } \boldsymbol{x}_i\in\omega_l \tag{2-5-8}$$

式中:d_{il}表示 $\boldsymbol{x}_i$ 和类 ω_l 的中心 $\boldsymbol{z}_l$ 之间的距离。

(3)依据 θ_n 判断合并。如果类 ω_j 中样本数 $n_j<\theta_n$,则取消该类的中心 $\boldsymbol{z}_j$,$N_c=N_c-1$,转至(2)。

(4)计算分类后的参数:各类中心、类内平均距离及总体平均距离。

①计算各类的中心

$$\boldsymbol{z}_j=\frac{1}{n_j}\sum_{\boldsymbol{x}_i\in\omega_j}\boldsymbol{x}_i \quad (j=1,2,\cdots,N_c) \tag{2-5-9}$$

②计算各类中模式到类心的平均距离

$$\bar{d}_j=\frac{1}{n_j}\sum_{\boldsymbol{x}_i\in\omega_j}\|\boldsymbol{x}_i-\boldsymbol{z}_j\| \quad (j=1,2,\cdots,N_c) \tag{2-5-10}$$

③计算各个模式到其类内中心的总体平均距离

$$d = \frac{1}{N}\sum_{j=1}^{N_c} n_j \bar{d}_j \qquad (2-5-11)$$

(5)依据 I_p、N_c 判断停止、分裂或合并。

①若迭代次数 $I_p = I$,则置 $\theta_D = 0$,转到(9);否则转下。

②若 $N_c \leqslant \frac{c}{2}$,则转到(6)(将一些类分裂);否则转下。

③若 $N_c \geqslant 2c$,则跳过分裂处理,转至(9),否则转下。

④若 $\frac{c}{2} < N_c < 2c$,当迭代次数 I_p 是奇数时转至(6)(分裂处理);迭代次数 I_p 是偶数时转至(9)(合并处理)。

(6)计算各类类内距离的标准差矢量

$$\boldsymbol{\sigma}_j = (\sigma_{1j}, \sigma_{2j}, \cdots, \sigma_{nj})^{\mathrm{T}} \quad (j = 1,2,\cdots,N_c) \qquad (2-5-12)$$

其各分量

$$\sigma_{kj} = \left[\frac{1}{n_j}\sum_{\boldsymbol{x}_i \in \omega_j} (\boldsymbol{x}_{ki} - \boldsymbol{z}_{kj})^2\right]^{\frac{1}{2}} \quad (k = 1,2,\cdots,n; j = 1,2,\cdots,N_c) \qquad (2-5-13)$$

式中:k 为分量编号;j 为类的编号;n 为矢量维数;$\boldsymbol{x}_{ki}$ 是 $\boldsymbol{x}_i$ 的第 k 个分量,z_{kj} 是 $\boldsymbol{z}_j$ 的第 k 个分量。

(7)求出每一聚类类内距离标准差矢量 $\boldsymbol{\sigma}_j$ 中的最大分量 $\sigma_{j\max}$

$$\sigma_{j\max} = \max_k [\sigma_{kj}] \quad (j = 1,2,\cdots,N_c) \qquad (2-5-14)$$

(8)在 $\{\sigma_{j\max}\}$ 中,若有某 $\sigma_{j\max} > \theta_s$,同时又满足下面两个条件之一:

① $\bar{d}_j > \bar{d}$ 和 $n_j > 2(\theta_n + 1)$

② $N_c \leqslant \frac{c}{2}$

则将该类 ω_j 分裂为两个聚类,原 $\boldsymbol{z}_j$ 取消且令 $N_c = N_c + 1$。这两个新类的中心 $\boldsymbol{z}_j^+$ 和 $\boldsymbol{z}_j^-$ 分别是在原 $\boldsymbol{z}_j$ 中相应于 $\sigma_{j\max}$ 的分量加上和减去 $k\sigma_{j\max}$,而其他分量不变,其中 $0 < k \leqslant 1$,k 的选取应使 $\boldsymbol{z}_j^+$ 和 $\boldsymbol{z}_j^-$ 仍在 ω_j 的类域中且其他类 $\omega_i (i \neq j)$ 的模式到 $\boldsymbol{z}_j^+$ 和 $\boldsymbol{z}_j^-$ 距离较远,而原 ω_j 类中

的模式和它们距离较小。分裂后，$I_p = I_p + 1$，转至(2)，否则转下。

(9)计算各类对中心间的距离

$$D_{ij} = \| z_i - z_j \| \quad (i = 1,2,\cdots,N_c - 1; j = i+1,\cdots,N_c) \tag{2-5-15}$$

(10)依据 θ_D 判断合并。将 D_{ij} 与 θ_D 比较，并将小于 θ_D 的那些 D_{ij} 按递增次序排列，取前 L 个，$D_{i_1j_1} < D_{i_2j_2} < \cdots < D_{i_Lj_L}$。从最小的 D_{ij} 开始，将相应的两类合并。若原来的两个类心为 z_i 和 z_j，则合并后的聚类中心为

$$z_l = \frac{1}{n_i + n_j}[n_i z_i + n_j z_j] \quad (l = 1,2,\cdots,L) \tag{2-5-16}$$

$N_c = N_c$ - 已合并掉的类数。在一次迭代中，某一类最多只能被合并一次。

(11)如果迭代次数 $I_p = I$ 或过程收敛，则结束。否则，$I_p = I_p + 1$，若需要调整参数，则转至(1)；若不改变参数，则转至(2)。

由上述合并与分裂的判断条件可以看出，如果类的数目 N_c 有 $\frac{c}{2} < N_c < 2c$，当 I_p 是奇数时分裂，当 I_p 是偶数时合并，以使机会均等。算法初设的 7 个参数存在一定的相互制约，选取不当，会存在冲突，此时需要修改参数。

[**例 2.5.3**]用 ISODATA 方法聚类图 2.5.7 中的数据。

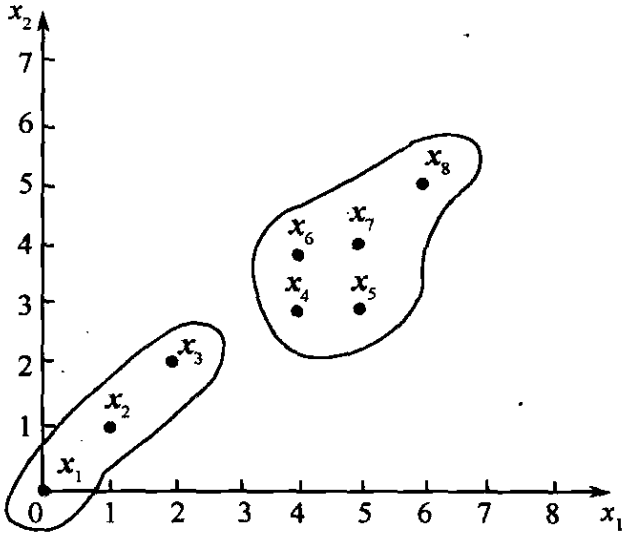


图 2.5.7　ISODATA 算法例题中的模式集

解：在本例中，$N=8$，$n=2$。

(1)设定参数和初始值

$$c=2 \quad \theta_n=2 \quad \theta_s=1 \quad \theta_D=4$$

$$L=1 \quad I=4 \quad N_c=1 \quad z_1=(0,0)' \quad I_p=1$$

在无先验知识的情况下，可任意选取这些参数和初始值，然后在逐次迭代中加以调整。

(2)因只有一个聚类中心，故

$$\omega_1=\{x_1,x_2,\cdots,x_8\} \quad , \quad n_1=8$$

(3)因 $n_1>\theta_n$，无合并。

(4)计算聚类中心、类内平均距离和总的平均距离。

①计算聚类中心

$$z_1=\frac{1}{n_1}\sum_{x_i\in\omega_1}x_i=\begin{pmatrix}3.38\\2.75\end{pmatrix}$$

②计算类内平均距离

$$\bar{d}_1=\frac{1}{n_1}\sum_{x_i\in\omega_1}\|x_i-z_1\|=2.26$$

③计算总的平均距离

$$\bar{d}=\bar{d}_1=2.26$$

(5)因不是最后一次迭代，且 $N_c=\frac{c}{2}$，转至(6)

(6)求 ω_1 的标准差矢量

$$\sigma_1=\begin{pmatrix}1.99\\1.56\end{pmatrix}$$

(7)算得 $\sigma_{1\max}=1.99$

(8)因 $\sigma_{1\max}=1.99>\theta_s$ 且 $N_c=\frac{c}{2}$，将 ω_1 分裂成两类，取 $k=0.5$，$0.5\sigma_{1\max}\approx1.0$，则

$$z_1^+ = \begin{pmatrix} 3.38+1 \\ 2.75 \end{pmatrix} = \begin{pmatrix} 4.38 \\ 2.75 \end{pmatrix} \triangleq z_1$$

$$z_1^- = \begin{pmatrix} 3.38-1 \\ 2.75 \end{pmatrix} = \begin{pmatrix} 2.38 \\ 2.75 \end{pmatrix} \triangleq z_2$$

$N_c = N_c + 1 = 2$，转至(2)。

(2)'按最小距离原则，新划分的类是

$$\omega_1 = \{x_4, x_5, x_6, x_7, x_8\}, n_1 = 5$$

$$\omega_2 = \{x_1, x_2, x_3\}, \quad n_2 = 3$$

(3)'因 $n_j > \theta_n$，无合并。

(4)'计算类的中心、类内平均距离和总的平均距离

① $z_1 = \begin{pmatrix} 4.80 \\ 3.80 \end{pmatrix}$ $z_2 = \begin{pmatrix} 1.06 \\ 1.00 \end{pmatrix}$

② $\bar{d}_1 = 0.80$ $\bar{d}_2 = 0.94$

③ $\bar{d} = 0.85$

(5)'因这是偶次迭代，满足算法原理步骤(5)中④的条件，故转(9)

(9)'计算类间距离得 $D_{12} = 4.72$，由 $D_{12} > \theta_D$，类不能合并。

(11)'因不是最后一次迭代($I_p = 2$，题设 $I = 4$)，$I_p = I_p + 1 = 3$，判断是否修改参数。由上面结果可知，已获得所要求类别数目，类间距离大于类内距离，每类样本数都有样本总数的足够大的百分比，因此不改变参数。

(2)"~(4)"计算结果与前一次迭代结果相同。

(5)"没有任一种情况被满足，转到(6)。

(6)"计算 $\omega_1 = \{x_4, x_5, x_6, x_7, x_8\}$ 和 $\omega_2 = \{x_1, x_2, x_3\}$ 的标准差矢量

$$\sigma_1 = \begin{pmatrix} 0.75 \\ 0.75 \end{pmatrix} \quad \sigma_2 = \begin{pmatrix} 0.82 \\ 0.82 \end{pmatrix}$$

(7)"$\sigma_{1max} = 0.75$，$\sigma_{2max} = 0.82$。

(8)"$\sigma_{jmax} < \theta_s$，分裂条件不满足，转至(9)。

(9)″与前一次迭代结果相同，$D_{12}=4.72$

(10)″无合并发生。

(11)″$I_p<I$，无新的变化，$I_p=4$，转至(2)。

(2)‴～(4)‴与前一次迭代结果相同。

(5)‴因是最后一次迭代，令 $\theta_D=0$，转至(9)。

(9)‴$D_{12}=4.72$，同前。

(10)‴因 $\theta_D=0$，无合并发生。

(11)‴因是最后一次迭代，结束。

实际上，根据第三次迭代发现计算结果不变时，就可以结束算法。

2.5.5 近邻函数法

在 C－均值法中，当类内模式非球状散布时，用样本的均值矢量作为类的代表，聚类结果是不佳的。如果有类的模式分布的某些先验知识，则可以构造能反映类的模式分布情况的核函数，以核函数代表类。当在实际中不能确定核函数或不能用简单的函数表示核函数时，可以采用近邻函数法。这种算法特别适用于类的模式分布是条状或线状的情况，如图 2.5.8 所示。

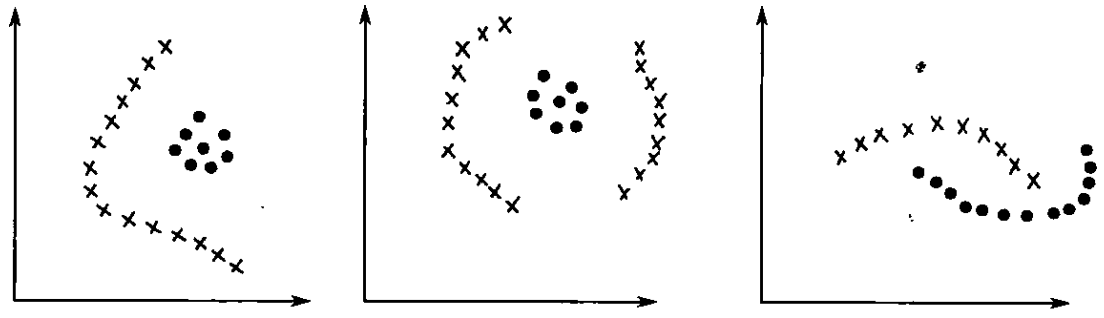


图 2.5.8 类的各种线状分布

对于样本集中的任意两个样本 $\boldsymbol{x}_i$ 和 $\boldsymbol{x}_j$，如果 $\boldsymbol{x}_i$ 是 $\boldsymbol{x}_j$ 的第 I 个近邻点，则定义 $\boldsymbol{x}_i$ 对 $\boldsymbol{x}_j$ 的近邻系数为 I，记为 $d(i,j)=I$；同理，如果 $\boldsymbol{x}_j$ 是 $\boldsymbol{x}_i$ 的第 J 个近邻点，则定义 $\boldsymbol{x}_j$ 对 $\boldsymbol{x}_i$ 的近邻系数为 J，记为 $d(j,i)=J$。于是，$\boldsymbol{x}_i$ 和 $\boldsymbol{x}_j$ 之间的近邻函数值定义为

$$\alpha_{ij}=d(i,j)+d(j,i)-2=I+J-2 \qquad (2-5-17)$$

易知，当 $\boldsymbol{x}_i$ 和 $\boldsymbol{x}_j$ 互为最近邻时，有 $\alpha_{ij}=0$，此也表明了上式中减去2的原因。显然，样本间的近邻函数值越小，说明它们彼此越近，意味着它们越相似。

如果样本集包含 N 个样本，那么近邻系数总是小于或等于 $N-1$，因此，$\boldsymbol{x}_i$ 和 $\boldsymbol{x}_j$ 之间的近邻函数值满足

$$\alpha_{ij} \leqslant 2N-4 \tag{2-5-18}$$

在聚类过程中，如果 $\boldsymbol{x}_i$ 和 $\boldsymbol{x}_j$ 被聚为一类，就称 $\boldsymbol{x}_i$ 与 $\boldsymbol{x}_j$ 是相互连接的。对于每两个样本，都定义一个指标，用以表征这两个样本是否适于连接，称其为连接损失，因此对于每一个连接都存在着一个连接损失。由两样本的近邻函数值 α_{ij} 的定义可知，α_{ij} 越小表明它们越相似，若把它们连接起来，损失也就越小。因此可以将近邻函数值 α_{ij} 作为 $\boldsymbol{x}_i$ 和 $\boldsymbol{x}_j$ 之间的连接损失。为了避免出现只含一个样本的聚类，规定 $\alpha_{ii} \geqslant 2N$。

在聚类过程中，当考虑样本 $\boldsymbol{x}_i$ 时，计算它与其他各样本间的近邻函数值，设

$$\alpha_{ik} = \min_{j}[\alpha_{ij}] \tag{2-5-19}$$

若把 $\boldsymbol{x}_i$ 和 $\boldsymbol{x}_k$ 连接起来，则有连接损失 α_{ik}。若 $\boldsymbol{x}_i$ 与 $\boldsymbol{x}_j$ 不连接，则不存在实际连接损失。

为导出聚类准则函数，在定义了两样本间的连接损失之后，首先定义类内损失和类间损失。设共有 c 类：$\omega_p, p=1,2,\cdots,c$。总的类内连接损失定义为

$$L_{\mathrm{W}} = \sum_{p=1}^{c} \sum_{\substack{\boldsymbol{x}_i \in \omega_p \\ \boldsymbol{x}_j \in \omega_p}} \alpha_{ij} \tag{2-5-20}$$

记 ω_p 类的类内最大近邻函数值

$$\alpha_{p\max} = \max_{\substack{\boldsymbol{x}_i \in \omega_p \\ \boldsymbol{x}_j \in \omega_p}}[\alpha_{ij}] \quad (p=1,2,\cdots,c) \tag{2-5-21}$$

设聚类 ω_p 和 $\omega_q(p,q=1,2,\cdots,c;p\neq q)$ 的样本之间最小近邻函数值为 γ_{pq}，即

$$\gamma_{pq} = \min_{\substack{\boldsymbol{x}_i \in \omega_p \\ \boldsymbol{x}_j \in \omega_q}}[\alpha_{ij}] \tag{2-5-22}$$

设γ_{pk}为聚类ω_p与其他各聚类$\omega_q(q=1,2,\cdots,c;q\neq p)$的最小近邻函数值的最小值,即

$$\gamma_{pk}=\min_{\substack{q\\q\neq p}}[\gamma_{pq}] \quad (p=1,2,\cdots,c) \tag{2-5-23}$$

式(2-5-23)表明,除ω_p类内样本外,只有ω_k中的某一个样本与ω_p中某一个样本最近邻,近邻函数值为γ_{pk}。因此首先考虑ω_p和ω_k是否合并。

ω_p类与ω_k类的类间连接损失有如下4种情况和相应的赋值:

$$\beta_p=\begin{cases}(\alpha_{p\max}-\gamma_{pk})+(\alpha_{k\max}-\gamma_{pk}) & \left(若\begin{cases}\gamma_{pk}>\alpha_{p\max}\\ \gamma_{pk}>\alpha_{k\max}\end{cases}\right)\\ \alpha_{p\max}+\gamma_{pk} & \left(若\begin{cases}\gamma_{pk}\leqslant\alpha_{p\max}\\ \gamma_{pk}>\alpha_{k\max}\end{cases}\right)\\ \alpha_{k\max}+\gamma_{pk} & \left(若\begin{cases}\gamma_{pk}>\alpha_{p\max}\\ \gamma_{pk}\leqslant\alpha_{k\max}\end{cases}\right)\\ \alpha_{p\max}+\alpha_{k\max}+\gamma_{pk} & \left(若\begin{cases}\gamma_{pk}\leqslant\alpha_{p\max}\\ \gamma_{pk}\leqslant\alpha_{k\max}\end{cases}\right)\end{cases} \tag{2-5-24}$$

第一种情况是,类内最大近邻函数值小于类间最小近邻函数值,说明聚类是合理的,这种情况不应付出代价,β_p可赋予负值,即损失值为负数。第二、三、四种情况说明类间最小近邻函数值小于或等于相应类中某一类或两类的类内最大近邻函数值,反映聚类不合理,赋于正值给β_p表示有实际损失,需要调整。

在此基础上,定义总的类间损失

$$L_B=\sum_{p=1}^{c}\beta_p \tag{2-5-25}$$

聚类的目标是使各γ_{pk}尽可能地大,使各$\alpha_{p\max}$尽可能地小,因而构造聚类的准则函数为

$$J_L = L_W + L_B \Rightarrow \min \qquad (2-5-26)$$

在定义了准则函数后可以用迭代方法求解，在上述判断第几近邻时，可以使用欧氏距离。

算法步骤如下：

(1)对于给定的待分类样本集$\{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N\}$计算距离矩阵$\boldsymbol{D}$，$\boldsymbol{D}$的阵元

$$D_{ij} = d(\boldsymbol{x}_i, \boldsymbol{x}_j) \quad (i,j = 1,2,\cdots,N) \qquad (2-5-27)$$

$d(\boldsymbol{x}_i, \boldsymbol{x}_j)$表示样本$\boldsymbol{x}_i$和$\boldsymbol{x}_j$间的距离。

(2)利用矩阵$\boldsymbol{D}$，计算近邻系数矩阵$\boldsymbol{M}$，其元素M_{ij}为样本$\boldsymbol{x}_i$对$\boldsymbol{x}_j$的近邻系数。

(3)生成近邻函数矩阵$\boldsymbol{L}$，其阵元为

$$L_{ij} = M_{ij} + M_{ji} - 2 \qquad (2-5-28)$$

置矩阵$\boldsymbol{L}$的主对角线上阵元$L_{ii} = 2N(i = 1,2,\cdots,N)$，如果$\boldsymbol{x}_i$和$\boldsymbol{x}_j$有连接，则$L_{ij}$给出它们的近邻函数值也是连接损失。

(4)对矩阵$\boldsymbol{L}$进行搜索，将每个点与和它有最小近邻函数值的点连接起来，从而形成初始聚类。

(5)对于(4)所形成的聚类，计算$\gamma_{pk}(p = 1,2,\cdots,c)$、$\alpha_{p\max}(p = 1,2,\cdots,c)$。若$\gamma_{pk}$小于或等于$\alpha_{p\max}$或$\alpha_{k\max}(k = 1,2,\cdots,c; k \neq p)$，则合并$\omega_k$和$\omega_p$，它们的样本间建立连接关系，转至(5)；否则结束。

在进行上述的迭代过程中，最终将使准则函数J_L达极小。

2.6 最近邻方法

在聚类分析中，由于没有样本类别的先验知识，因而按最近距离原则的基本思想进行分类。最近邻法是在具有训练样本条件下，但不进行训练，而是按最近距离原则对待识模式进行分类，这种分类技术思想直观、方法简单、效果较好，其中k-NN法可以看做是一种从样本中获取最大后验概率的方法，最近邻法的某些技术在理论上可以达到后面章节的先验知识完备的贝叶斯决策的分类效果，能适应类域分布较复杂的情况，这类技术是最重要的模式识别技术之一。实际上，这种分类

技术是贝叶斯决策思想的一种体现，因某类样本距待识模式最近，或某一小区域某类样本较多，意味着此处这类概密较大。本节除介绍基本的最近邻法之外，还介绍几种改进的最近邻法。

2.6.1 最近邻法

对于 c 类问题，设类 $\omega_i(i=1,2,\cdots,c)$ 有 N_i 个训练样本 $\boldsymbol{x}_j^{(i)}(j=1,2,\cdots,N_i)$，$N=\sum_{i=1}^{c}N_i$。分类的思想是，对于一个待识模式 $\boldsymbol{x}$，分别计算它与各已知类别的训练样本 $\boldsymbol{x}_j^{(i)}$ 的距离，将它判为距离最近的那个样本所属的类。在这样的分类思想下，ω_i 类的判决函数为

$$d_i(\boldsymbol{x})=\min_{j=1,2,\cdots,N_i}\|\boldsymbol{x}-\boldsymbol{x}_j^{(i)}\| \quad (i=1,2,\cdots,c) \tag{2-6-1}$$

判决规则为

$$\begin{gathered}\text{如果 } d_{\mathrm{m}}(\boldsymbol{x})=\min_{i=1,2,\cdots,c}d_i(\boldsymbol{x})\\ \text{则判 } \boldsymbol{x}\in\omega_{\mathrm{m}}\end{gathered} \tag{2-6-2}$$

由于上述方法只根据离待识模式最近的一个样本的类别而决定其类别，通常称其为 1－NN 方法。为了克服单个样本类别的偶然性以增加分类的可靠性，可以考查待识模式的 k 个最近邻样本，这 k 个最近邻样本中哪一类的样本最多，就将 $\boldsymbol{x}$ 判属哪一类。设 $k_1,k_2,\cdots,k_c$ 分别为待识模式 $\boldsymbol{x}$ 的 k 个最近邻样本属于 $\omega_1,\omega_2,\cdots,\omega_c$ 类的样本数，定义 ω_i 类的判别函数为

$$d_i(\boldsymbol{x})=k_i \quad (i=1,2,\cdots,c) \tag{2-6-3}$$

判决规则为

$$\begin{gathered}\text{如果 } d_{\mathrm{m}}(\boldsymbol{x})=\max_{i=1,2,\cdots,c}[d_i(\boldsymbol{x})]\\ \text{则判 } \boldsymbol{x}\in\omega_{\mathrm{m}}\end{gathered} \tag{2-6-4}$$

这种方法通常称为 k－NN 法。

2.6.2 剪辑最近邻法

清理两类间的边界，去掉类别混杂的样本，使两类边界更清晰，此即剪辑最近邻法。这种方法的性能在理论上明显好于一般的最近邻法。

1. 剪辑 1 – NN 最近邻法

对于两类问题，设将含 N 个已知类别的样本的样本集 $X^{(N)}$ 分成参照集 $X^{(NR)}$ 和测试集 $X^{(NT)}$ 两部分，这两部分没有公共元素，它们的样本数各为 NR 和 NT，$NR+NT=N$。利用参照集 $X^{(NR)}$ 中的样本 $y_1, y_2, \cdots, y_{NR}$，采用最近邻规则对已知类别的测试集 $X^{(NT)}$ 中的每个样本 $x_1, x_2, \cdots, x_{NT}$ 进行分类，在此基础上，剪辑掉 $X^{(NT)}$ 中被错误分类的样本，具体地讲，若记 $y^*(x) \in X^{(NR)}$ 是 $x \in X^{(NT)}$ 的最近邻元，剪辑掉不与 $y^*(x)$ 同类的 x，余下的判决正确的样本组成剪辑样本集 $X^{(NTE)}$，这一操作过程称为剪辑。然后利用剪辑样本集 $X^{(NTE)}$ 采用最近邻规则对待识模式 x 进行分类。

2. 剪辑 k – NN 最近邻法

上述的剪辑最近邻法可以推广至 k – 近邻法中，具体的作法是：第一步用 k – NN 法进行剪辑，第二步用 1 – NN 法进行分类。剪辑 k – NN 法当 $k \to \infty$ 时其性能接近贝叶斯判决，即它的渐近误判概率收敛于贝叶斯误判概率，这显然好于没剪辑的最近邻法。但是在实际应用中，由于样本数 N，k 是有限的，在大子样情况下，样本出现的情况并不像理想的那样，所以该方法的实际效果将会比理论性能差。

这个方法也可以应用到多类问题。当类数增加时，该方法的效果将会变得更好。

3. 重复剪辑最近邻法

只要样本足够多，就可以重复地执行剪辑程序，以进一步提高分类性能。

下面给出一种称之为 MULTIEDIT 的实用算法。

(1)将样本集 $X^{(N)}$ 随机地划分为 s 个子集

$$X^{(N)} = \{X_1, X_2, \cdots, X_s\} \quad (s \geqslant 3)$$

(2)用最近邻法，以 $X_{(i+1) \bmod s}$ 为参照集，对 X_i 中的样本进行分类，其中 $i = 1, 2, \cdots, s$。

(3)去掉在(2)中被错分类的样本。

(4)用所留下的样本构成新的样本集 $X^{(NE)}$。

(5)如果经过 k 次迭代再没有样本被剪辑掉则停止；否则转至(1)。

图 2.6.1 所示为具有不同均矢和协方差阵的两类正态分布的随机样本集；图 2.6.2 所示为用上述算法第一次剪辑后留下的样本；图 2.6.3 所示为第三次剪辑留下的样本；图 2.6.4 所示为已经没有错判后留下的样本。可以看出剪辑掉的只是两类边界上的一些样本，经最后剪辑之后两类的分界面已十分接近贝叶斯决策面。图 2.6.5 至图 2.6.7 所示为利用该算法的另一个例子，图 2.6.5 所示为非正态分布的两类样本集；图 2.6.6 所示为用上述算法对其第一次剪辑后的样本集；图 2.6.7 所示为最后分类的结果，图中虚线表示贝叶斯决策面，实线为运用最近邻法得出的边界，可以看出两者是十分接近的。

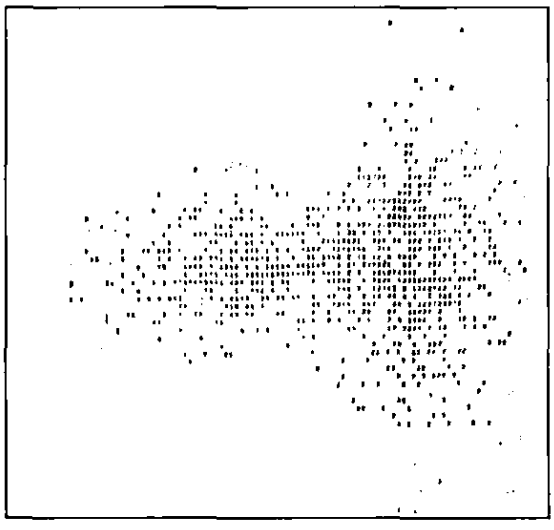


图 2.6.1 不同均矢和协方差阵的两类正态分布的随机样本

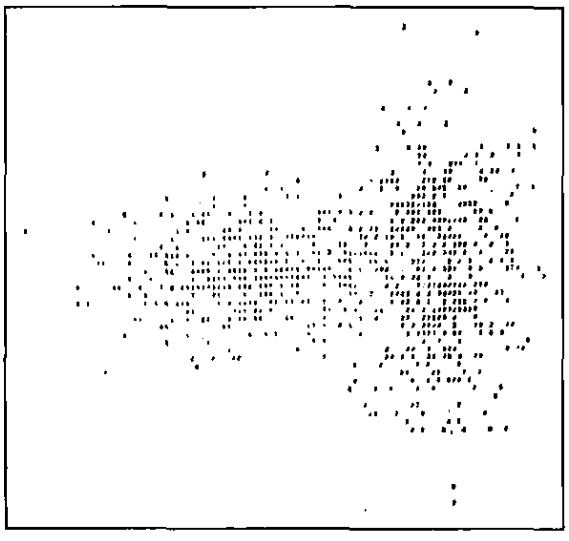


图 2.6.2 图 2.6.1 第一次剪辑后留下的样本

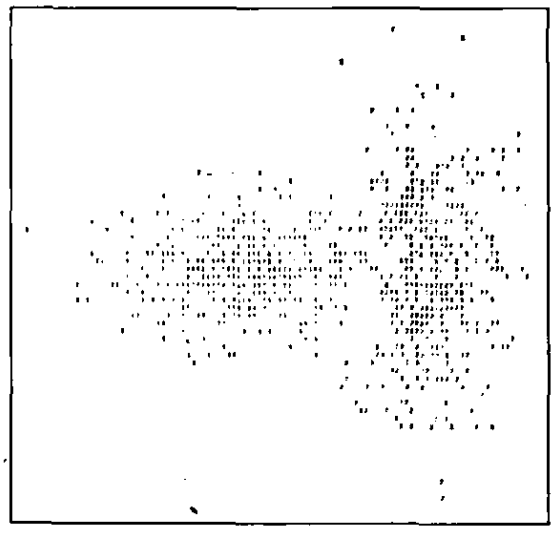


图 2.6.3 图 2.6.1 第三次剪辑后留下的样本

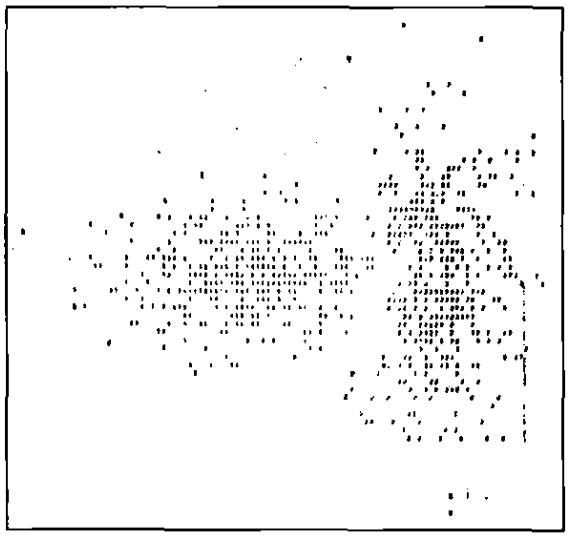


图 2.6.4 算法终止时留下的样本

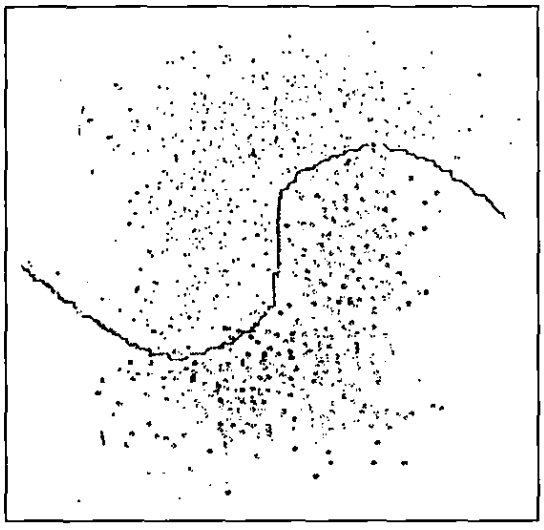


图 2.6.5　非正态分布的两类样本



图 2.6.6　对图 2.6.5 第一次剪辑后留下的样本

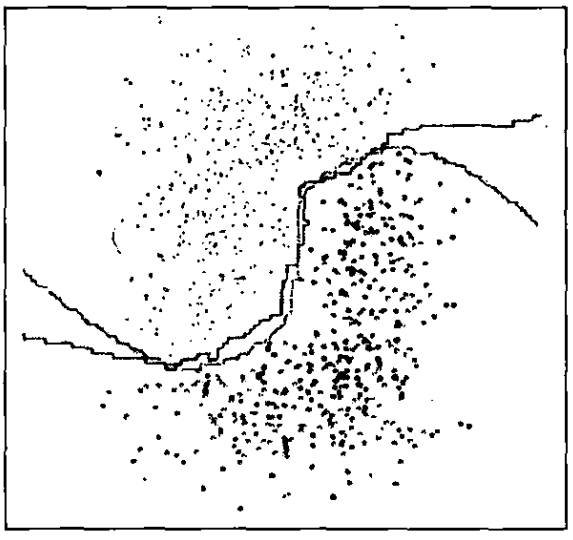


图 2.6.7　最后分类结果

2.6.3　引入拒绝类别决策的最近邻法

在运用 k - NN 方法时，为了克服 k 个近邻元属于不同类别的样本数的偶然性，采用的方法之一是增大 k，然而这仍不能完全消除 k 个近邻元类别的偶然性。如 k 个近邻元中某一类的样本数占很大的优势，则误判的可能性就较小；如果出现“微弱”多数的情况，那么误判概率可能会较大，此时要作出类别决策，若判决错误，由于在某些实际问题中误判的风险很大，则会付出很大代价。所以对于误判风险较大的情况，决策空间中除了包含类别决策外，还应引入拒绝决策，这可以视作

增加了新的一类 ω_0。

1. 含有拒绝决策的 k – NN 法

对于两类问题，引入了拒绝决策的 k – NN 方法是：根据可信性要求选定一个 k' 值，应使 $k' > \frac{k+1}{2}$，如果待识模式 $\boldsymbol{x}$ 的 k 个近邻中有大于或等于 k' 个样本属于某一类 $\omega_i (i=1,2)$，则判 $\boldsymbol{x} \in \omega_i$，否则拒绝作出类别决策。

2. 含有拒绝决策的剪辑 k – NN 法

剪辑技术也可以应用于含有拒绝决策的最近邻方法中，下面给出方法的原理步骤。

(1) 首先选定 k 和 $k' > \frac{k+1}{2}$。

(2) 对于训练模式集 $X^{(N)}$ 中的每个样本 $\boldsymbol{x}_j$，从 $X^{(N)}$ 中找出它的 k 个最近邻元。

(3) 如果 $\boldsymbol{x}_j$ 的 k 个最近邻中至少有 k' 个样本属于 ω_i 类，则给 $\boldsymbol{x}_j$ 一个类别标记 $B(\boldsymbol{x}_j) = i$，否则 $B(\boldsymbol{x}_j) = 0$。

(4) 在 $X^{(N)}$ 中只保留 $B(\boldsymbol{x}_j \in \omega_i) = i (i=1,2)$ 和 $B(\boldsymbol{x}_j) = 0$ 的样本 $\boldsymbol{x}_j$，即去掉被错分类的样本。

(5) 将 $B(\boldsymbol{x}_j) = 0$ 的那些样本 $\boldsymbol{x}_j$ 归为拒绝类 ω_0，从而组成含有 3 类的新的剪辑样本集 $X^{(\mathrm{ER})}$。

(6) 利用 $X^{(\mathrm{ER})}$ 和最近邻规则对待识模式 $\boldsymbol{x}$ 进行分类决策。

习　题

2.1　证明欧氏距离是平移不变的、旋转不变的。

2.2　证明马氏距离是平移不变的、非奇异线性变换不变的。

2.3　证明 Minkowski 距离度量具有成为一种度量所需要的全部 4 种性质。

2.4　证明：

$$\text{切氏距离} \leqslant \text{欧氏距离} \leqslant \text{绝对值距离}$$

2.5 考虑 Tanimoto 距离度量。

(1)请问 Tanimoto 距离是否满足作为距离度量的 4 个基本性质;

(2)把下面的 5 个单词看做一些字母的组合:pattern, pat, pots, stop, elementary,按 Tanimoto 距离大小来对可能的两两组合进行排序;

(3)这 5 个模式是否符合三点距离不等式。

2.6 证明中间距离法与离差平方和法的递推公式。

2.7 令 $\boldsymbol{x}_1,\cdots,\boldsymbol{x}_N$ 是 n 维样本,$\boldsymbol{\Sigma}$ 是任一非奇异 $n\times n$ 矩阵。证明使

$$\sum_{k=1}^{N}(\boldsymbol{x}_k-\boldsymbol{x})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}_k-\boldsymbol{x})$$

最小的矢量 $\boldsymbol{x}$ 是样本均值。

2.8 考虑不变量问题,矩阵 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 的特征值 $\lambda_1,\cdots,\lambda_d$ 是最基本的不变量。

(1)证明如果对数据作非奇异线性变换,则矩阵 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 的特征值 $\lambda_1,\cdots,\lambda_d$ 是不变的;

(2)证明 $\boldsymbol{S}_{\mathrm{T}}^{-1}\boldsymbol{S}_{\mathrm{W}}$ 的特征值 $v_1,\cdots,v_d$ 和 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 的特征值满足关系 $v_i=1/(1+\lambda_i)$;

(3)用上面的结果证明如果数据作非奇异线性变换,$J=|\boldsymbol{S}_{\mathrm{W}}|/|\boldsymbol{S}_{\mathrm{T}}|$ 也是不变的。

2.9 考虑将 N 个样本分到 c 个类别的所有可能的组合。

(1)证明一共有

$$\frac{1}{c!}\sum_{i=1}^{c}\binom{c}{i}(-1)^{c-i}i^n$$

种不同的分类方法;

(2)当 $n=100,c=5$ 时,一共有多少种可能的方法;

(3)当 $N\gg c$ 时,请找到一种近似的简便计算(1)的方法,并用这种方法去估算将 1000 个点分到 10 个类别的可能方法数目。

2.10 证明类内、类间、总的离差矩阵对于数据的线性变换具有下面的不变性。

(1) $\mathrm{Tr}[\boldsymbol{S}_{\mathrm{T}}^{-1}\boldsymbol{S}_{\mathrm{W}}] = \sum_{i=1}^{d}\frac{1}{1+\lambda_i}$;

(2) $|\boldsymbol{S}_{\mathrm{W}}| / |\boldsymbol{S}_{\mathrm{T}}| = \prod_{i=1}^{d}\frac{1}{1+\lambda_i}$;

(3) $|\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}| = \prod_{i=1}^{d}\lambda_i$;

(4)度量(3)中准则的值通常是多少？请解释为什么这个值使得该准则没有什么用处。

2.11 考虑一个 $N=2k+1$ 个样本的集合,其中有 k 个在 $x=-2$ 上重合,有 k 个在 $x=0$ 上重合,有 1 个在 $x=\alpha>0$ 上。证明若 $\alpha^2<2(k+1)$,则使类内距离准则 J_{W} 最小的两类划分是将 $x=0$ 的 k 个样本和 $x=\alpha$ 的那个样本聚为一类。若 $\alpha^2>2(k+1)$,则应如何聚类使 J_{W} 最小?

2.12 若定义下列准则函数

$$J_{\mathrm{T}} = \sum_{i=1}^{c}\sum_{x\in X_i}(\boldsymbol{x}-\boldsymbol{m}_i)^{\mathrm{T}}\boldsymbol{S}_{\mathrm{T}}^{-1}(\boldsymbol{x}-\boldsymbol{m}_i)$$

其中:$\boldsymbol{m}_i$ 是 $\boldsymbol{X}_i$ 中 N_i 个样本的均值矢量,$\boldsymbol{S}_{\mathrm{T}}$ 是总的离差矩阵。

(1)证明 J_{T} 对数据的非奇异线性变换具有不变性;

(2)证明把 $\boldsymbol{X}_i$ 中的样本 $\hat{\boldsymbol{x}}$ 转移到 $\boldsymbol{X}_j$ 中去,则使 J_{T} 改变为

$$J_{\mathrm{T}}^{*} = J_{\mathrm{T}} - \left[\frac{N_j}{N_j+1}(\hat{\boldsymbol{x}}-\boldsymbol{m}_j)^{\mathrm{T}}\boldsymbol{S}_{\mathrm{T}}^{-1}(\hat{\boldsymbol{x}}-\boldsymbol{m}_j) - \frac{N_i}{N_i-1}(\hat{\boldsymbol{x}}-\boldsymbol{m}_i)^{\mathrm{T}}\boldsymbol{S}_{\mathrm{T}}^{-1}(\hat{\boldsymbol{x}}-\boldsymbol{m}_i)\right]$$

(3)写出使 J_{T} 最小化的迭代程序。

2.13 在某种谱系聚类中,每次迭代都将某两类合并为一类,而且这两类的合并是所有可能合并中使误差平方和增加最小的一个,如果第 i 个类有 n_i 个样本,均值为 $\boldsymbol{m}_i$,证明合并后使误差平方和增加最小的两个类同时也是使

$$\frac{n_i n_j}{n_i+n_j}\|\boldsymbol{m}_i-\boldsymbol{m}_j\|^2$$

最小的两个类。

2.14 假设从 n 维的正态模型 $p(\boldsymbol{x}) \sim N(\boldsymbol{\mu},\boldsymbol{\Sigma})$ 中获得了 N 个样本，记为 X，$\boldsymbol{\Sigma}$ 是一个正定的协方差矩阵。

(1) 令 $J_e = \sum_{\boldsymbol{x}\in X} \| \boldsymbol{x} - \boldsymbol{m} \|^2$，$\boldsymbol{m}$ 是所有样本的均值，请证明 J_e 是以 $nN\sigma^2$ 为均值的正态分布，并用 $\boldsymbol{\Sigma}$ 表示 σ；

(2) 证明这个分布的方差是 $2nN\sigma^4$；

(3) 如果将正态分布的数据点用一个经过中心的超平面一分为二，证明当 N 足够大时，这种聚类划分的误差平方和可以近似为正态分布，且均值为 $N(n-2/\pi)\sigma^2$，方差为 $2N(n-8/\pi)\sigma^4$，其中 σ 在(1)中给出。

2.15 说明在什么情况下，最近邻法错误率 P 达到其上界。

2.16 有 7 个二维矢量：$\boldsymbol{x}_1 = (1,0)^{\mathrm{T}}$，$\boldsymbol{x}_2 = (0,1)^{\mathrm{T}}$，$\boldsymbol{x}_3 = (0,-1)^{\mathrm{T}}$，$\boldsymbol{x}_4 = (0,0)^{\mathrm{T}}$，$\boldsymbol{x}_5 = (0,2)^{\mathrm{T}}$，$\boldsymbol{x}_6 = (0,-2)^{\mathrm{T}}$，$\boldsymbol{x}_7 = (-2,0)^{\mathrm{T}}$，假定前 3 个为 ω_1 类，后 4 个为 ω_2 类。

(1) 画出最近邻法决策面；

(2) 求样本均值 $\boldsymbol{m}_1$，$\boldsymbol{m}_2$。若按离样本均值距离的大小进行分类，试画出决策面。

算法编程

2.1 现有样本集 $X = \{(0,0)^{\mathrm{T}},(0,1)^{\mathrm{T}},(4,4)^{\mathrm{T}},(4,5)^{\mathrm{T}},(5,4)^{\mathrm{T}},(5,5)^{\mathrm{T}},(1,0)^{\mathrm{T}}\}$，试用最大最小距离聚类算法进行聚类分析。

2.2 对 2.1 题中的样本集 X，试用 C－均值算法进行聚类分析 $(c=2)$。

2.3 对 2.1 题中的样本集 X，试用 ISODATA 算法进行聚类分析。

2.4 现有六维样本：

$$\boldsymbol{x}_1 = (0,1,3,1,3,4)^{\mathrm{T}},\boldsymbol{x}_2 = (3,3,3,1,2,1)^{\mathrm{T}},$$

$$\boldsymbol{x}_3 = (1,0,0,0,1,1)^{\mathrm{T}},\boldsymbol{x}_4 = (2,1,0,2,2,1)^{\mathrm{T}}$$

$$x_5 = (0,0,1,0,1,0)^T,$$

试按最小距离法进行谱系聚类分析。

以下部分练习使用下表的数据：

表 2.1

样本	x_1	x_2	x_3
1	-7.82	-4.58	-3.97
2	-6.68	3.16	2.71
3	4.36	-2.19	2.09
4	6.72	0.88	2.80
5	-8.64	3.06	3.50
6	-6.87	0.57	-5.45
7	4.47	-2.62	5.76
8	6.73	-2.01	4.18
9	-7.71	2.34	-6.33
10	-6.91	-0.49	-5.68
11	6.18	2.81	5.82
12	6.72	-0.93	-4.04
13	-6.25	-0.26	0.56
14	-6.94	-1.22	1.13
15	8.09	0.20	2.25
16	6.81	0.17	-4.15
17	-5.19	4.24	4.04
18	-6.38	-1.74	1.43
19	4.08	1.30	5.33
20	6.27	0.93	-2.78

2.5 写程序实现 C－均值算法，并用表中的三维数据进行测试。下面给出了每种测试的类别数目和初始值。

(1) $c=2, \boldsymbol{m}_1(0)=(1,1,1)^T, \boldsymbol{m}_2(0)=(-1,1,-1)^T$；

(2) $c=2, \boldsymbol{m}_1(0)=(0,0,0)^T, \boldsymbol{m}_2(0)=(1,1,-1)^T$，将得到结果与(1)中的结果进行比较，并解释差别，包括迭代次数的差别；

(3) $c=3, \boldsymbol{m}_1(0)=(0,0,0)^{\mathrm{T}}, \boldsymbol{m}_2(0)=(1,1,1)^{\mathrm{T}}, \boldsymbol{m}_3(0)=(-1, 0,2)^{\mathrm{T}}$;

(4) $c=3, \boldsymbol{m}_1(0)=(-0.1,0,0.1)^{\mathrm{T}}, \boldsymbol{m}_2(0)=(0,-0.1,0.1)^{\mathrm{T}}, \boldsymbol{m}_3(0)=(-0.1,-0.1,0.1)^{\mathrm{T}}$。

将得到结果与(1)中的结果进行比较,并解释差别,包括迭代次数的差别。

第 3 章　判别域代数界面方程法

3.1　判别域界面方程分类的概念

如前所述，一个模式的 n 维特征矢量 $\boldsymbol{x}$ 对应于 n 维特征空间 X^n 中一个特征点，当特征选取适当时，可使同一类模式的特征点在特征空间中某一子区域内散布，另一类模式的特征点在另一子区域内散布。据此，可运用已知类别的训练样本进行学习产生若干个代数界面 $d(\boldsymbol{x})=0$，将特征空间分划成一些互不重叠的子区域，使不同的模式类或其主体在不同的子区域中。基于不同类的特征点在不同子区域中的观点，可以根据待识模式特征点所在子区域而确定其类别。特征点所在子区域可根据它的特征值代入界面方程中的函数 $d(\boldsymbol{x})$ 后的取值正负而确定。因此这些子区域称为判别域，表示界面的函数 $d(\boldsymbol{x})$ 称为判别函数（Discriminant Function）。对于三维空间，界面一般是曲面，特殊情况下是平面；对于更多维数的情况，则是非直观的所谓超曲面、超平面等。对于来自两类的一组模式 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$，如果能用一个线性判别函数对它们正确分类，则称它们是线性可分的，否则称为非线性可分。对于 c 类模式集，若能用 c 个线性判别函数将特征空间分划成 c 个判别域对它们实现正确分类，则称它们是线性可分的。本章处理分类问题的技术思路是：分类→特征空间的分划→寻求判别域的界面 = 判别函数→判别函数的结构与参数的确定→待识模式特征矢量代入判别函数后取值正负。一个例子如图 3.1.1 所示。一个模式特征矢量 $\boldsymbol{x}=(x_1,x_2)^{\mathrm{T}}$ 在特征空间 $O-x_1x_2$ 平面中对应一个点，不同类别 ω_1 和 ω_2 的模式特征点在不同的类域（子区域）中散布。首先根据已知类别的训练模式确定分划各类子区域的界面方程，在此例中，这个界面可以是一条直线：

$$d(\boldsymbol{x}) = w_1 x_1 + w_2 x_2 + w_3 = 0$$

通过适当的算法所产生的判别函数 $d(\boldsymbol{x})$，应能使当 $\boldsymbol{x}$ 属于 ω_1 时，有 $d(\boldsymbol{x}) > 0$；当 $\boldsymbol{x}$ 属于 ω_2 时，则有 $d(\boldsymbol{x}) < 0$。这个过程称为训练，所得的各个子区域称为判别域。有了判别界面之后，就可以进行判别，将待识模式 $\boldsymbol{x}$ 代入 $d(\boldsymbol{x})$ 中，若 $d(\boldsymbol{x}) > 0$，则判 $\boldsymbol{x} \in \omega_1$；若 $d(\boldsymbol{x}) < 0$，则判 $\boldsymbol{x} \in \omega_2$；若 $d(\boldsymbol{x}) = 0$，则 $\boldsymbol{x}$ 的归属不能判定或任判。本章分别介绍线性与非线性判别函数的一般形式、判别规则及判别函数的产生等几个方面的内容，首先介绍线性判别函数的结构、性质、判别规则以及线性判别函数产生的算法，然后介绍非线性判别函数的知识。

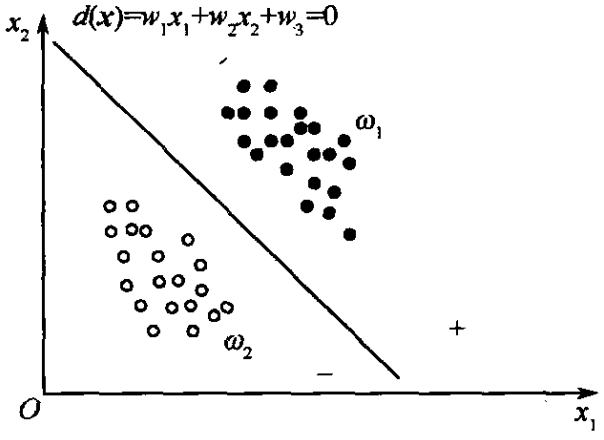


图 3.1.1　两类模式判别类域的界面

3.2　线性判别函数

在 n 维特征空间中，特征矢量 $\boldsymbol{x} = (x_1, x_2, \cdots, x_n)^{\mathrm{T}}$，线性判别函数的一般形式是

$$d(\boldsymbol{x}) = w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + w_{n+1} \triangleq \boldsymbol{w}_0^{\mathrm{T}} \boldsymbol{x} + w_{n+1} \tag{3-2-1}$$

式中：$\boldsymbol{w}_0 = (w_1, w_2, \cdots, w_n)^{\mathrm{T}}$ 称为权矢量或系数矢量。为简洁起见，上式还可以写成

$$d(\boldsymbol{x}) \triangleq \boldsymbol{w}^{\mathrm{T}} \boldsymbol{x} \tag{3-2-2}$$

式中：$\boldsymbol{x} = (x_1, x_2, \cdots, x_n, 1)^{\mathrm{T}}$，$\boldsymbol{w} = (w_1, w_2, \cdots, w_n, w_{n+1})^{\mathrm{T}}$，其中 $\boldsymbol{x}$ 称为增

广特征矢量，w 称为增广权矢量。此时的增广特征矢量的全体称为增广特征空间。

需要特别指出的是，以后我们经常采用这种写法，一般不再特别言明。在给出了线性判别函数以后，下面给出判别规则。

3.2.1 两类问题

对于两类问题，设 $d(\boldsymbol{x})$ 为判别函数，待识模式增广特征矢量 $\boldsymbol{x}$ 可通过下面的判别规则进行分类：

$$d(\boldsymbol{x})=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}\begin{cases}>0\Rightarrow\boldsymbol{x}\in\omega_1\\<0\Rightarrow\boldsymbol{x}\in\omega_2\\=0\Rightarrow\text{任判，或拒判}\end{cases}\qquad(3-2-3)$$

上述规则中，$A\Rightarrow B$ 表示若 A 成立则 B 成立。

3.2.2 多类问题

两类判别方法可以推广应用到类数大于 2 的多类情况，一般有 5 个技术途径，这 5 个途径分别是：$\omega_i/\overline{\omega_i}$ 两分法，ω_i/ω_j 两分法，没有不确定区的 ω_i/ω_j 两分法，决策树法，以及神经网络技术。本章介绍前 3 个途径方法，对后两种方法读者可以参考有关资料。

1. $\omega_i/\overline{\omega_i}$ 两分法

所确定的判别函数将属于 ω_i 类和不属于 ω_i 类的模式分划开是此方法的基本思想。于是，c 类问题转变为 $c-1$ 个两类问题。如果模式是线性可分的，一般地需要建立 $c-1$ 个独立的判别函数。为了方便，可建立 c 个判别函数：

$$d_i(\boldsymbol{x})=\boldsymbol{w}_i^{\mathrm{T}}\boldsymbol{x}\quad(i=1,2,\cdots,c)\qquad(3-2-4)$$

通过训练，其中每个判别函数都具有下面的性质

$$d_i(\boldsymbol{x})\begin{cases}>0\quad(\text{若}\boldsymbol{x}\in\omega_i)\\<0\quad(\text{若}\boldsymbol{x}\notin\omega_i)\end{cases}\quad(i=1,2,\cdots,c)\qquad(3-2-5)$$

$\boldsymbol{x}\notin\omega_i$ 也可记为 $\boldsymbol{x}\in\overline{\omega_i}$。由于 $d_i(\boldsymbol{x})$ 具有上述性质，可考虑将它们作为判别函数。判别界面 $d_i(\boldsymbol{x})=0$ 将特征空间分划成两个子区域，其中一

个子区域包含 ω_i 的类域 Ω_i，另一个子区域包含 $\overline{\omega}_i$ 的类域；同样，另一个判别界面 $d_j(\boldsymbol{x})=0$ 也将特征空间分划成两个子区域，其中一个子区域包含 ω_j 的类域 Ω_j，另一个子区域包含 $\overline{\omega}_j$ 的类域。由两个界面 $d_i(\boldsymbol{x})=0$ 和 $d_j(\boldsymbol{x})=0$ 所分划的包含类域 Ω_i 和 Ω_j 的子区域可能会有部分重叠，落在这个重叠子区域中的点不能由这两个判别函数确定类别，因 $d_i(\boldsymbol{x})>0, d_j(\boldsymbol{x})>0$。由以上分析可知，使用这类判别函数，可能会同时出现两个或两个以上的判别式都大于零或所有的判别式都小于零的情况。对于出现在这样区域中的点将不能判别出它们的类别，称这样的区域为不确定区，用 IR 表示，类别越多，不确定区也就越多。仅用一个判别函数 $d_i(\boldsymbol{x})>0$ 不能可靠地判别出 $\boldsymbol{x}\in\omega_i$，因此不仅要 $d_i(\boldsymbol{x})>0$，还必须有 $d_j(\boldsymbol{x})<0(\forall j\neq i)$，通过多个不等式的联立，使判别域变小从而判别结果更准确。所以对于 c 类问题，判决规则为

$$\text{如果}\quad \begin{cases} d_i(\boldsymbol{x})>0 \\ d_j(\boldsymbol{x})\leqslant 0 \quad (\forall j\neq i) \end{cases}$$

$$\text{则判}\quad \boldsymbol{x}\in\omega_i$$

模式集如果能用 $\omega_i/\overline{\omega}_i$ 两分法正确分类，则称它们是完全线性可分的，其也一定是线性可分的。

[**例 3.2.1**]设有一个二维三类问题，判别函数已求得：

$$d_1(\boldsymbol{x})=-x_1+x_2,\ d_2(\boldsymbol{x})=x_1+x_2-5,\ d_3(\boldsymbol{x})=-x_2+1$$

有一模式 $\boldsymbol{x}=(6,5)^{\mathrm{T}}$，欲判别其类别。可将该模式特征矢量代入上面三式，有

$$d_1(\boldsymbol{x})=-1<0\Rightarrow \boldsymbol{x}\notin\omega_1\ (\boldsymbol{x}\in\omega_2 \text{ 或 } \omega_3)$$

$$d_2(\boldsymbol{x})=6>0\Rightarrow \boldsymbol{x}\in\omega_2$$

$$d_3(\boldsymbol{x})=-4<0\Rightarrow \boldsymbol{x}\notin\omega_3\ (\boldsymbol{x}\in\omega_1 \text{ 或 } \omega_2)$$

最后判 $\boldsymbol{x}\in\omega_2$。

解题结果如图 3.2.1 所示。

2. ω_i/ω_j 两分法

对 c 类中的任意两类 ω_i 和 ω_j 都建立一个判别函数，这个判别函数只将属于 ω_i 类的模式与属于 ω_j 类的模式区分开，对其他类模式分

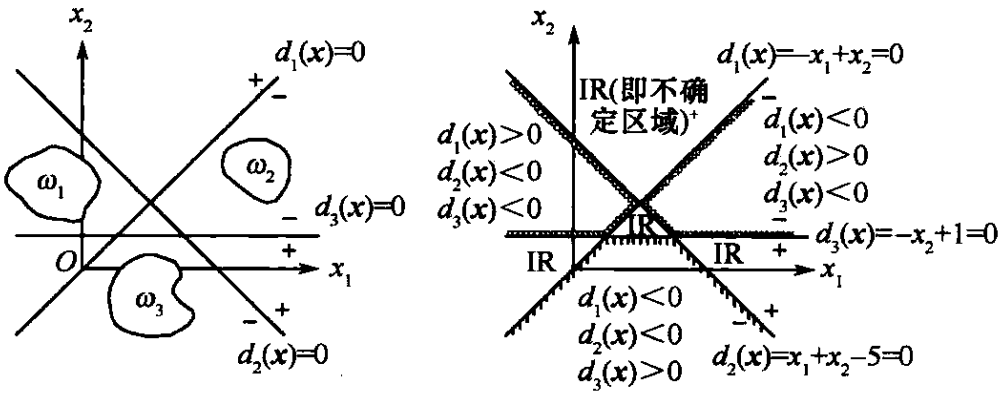


图 3.2.1　$\omega_i/\overline{\omega_i}$ 两分法例题图示

类是否正确不提供信息。由于从 c 元中取 2 元的组合数为 $c(c-1)/2$，所以要分开 c 类需要有 $c(c-1)/2$ 个判别函数。通过训练得到区分两类 ω_i 和 ω_j 的判别函数为

$$d_{ij}(\boldsymbol{x})=\boldsymbol{w}_{ij}^{\mathrm{T}}\boldsymbol{x},\quad (i,j=1,2,\cdots,c;i\neq j) \tag{3-2-6}$$

它具有性质

$$d_{ij}(\boldsymbol{x})=\boldsymbol{w}_{ij}^{\mathrm{T}}\boldsymbol{x}\begin{cases}>0(\text{若}\ \boldsymbol{x}\in\omega_i)\\<0(\text{若}\ \boldsymbol{x}\in\omega_j)\end{cases}$$

$$d_{ij}(\boldsymbol{x})=-d_{ji}(\boldsymbol{x}) \tag{3-2-7}$$

根据 $d_{ij}(\boldsymbol{x})$ 的正负不能作出 $\boldsymbol{x}$ 是属于 ω_i 类还是属于 ω_j 类的判别，只能作出 $\boldsymbol{x}$ 是位于含有 ω_i 类的子区域中还是位于含有 ω_j 类的子区域中，因在其中某一个子区域中还可能含有其他的类域(或一部分)。所以除 $d_{ij}(\boldsymbol{x})$ 之外，还要根据其他的判别函数才能作出正确的判决。这种方法的判别规则是

$$\text{如果}\quad d_{ij}(\boldsymbol{x})>0\quad(\forall j\neq i)$$

$$\text{则判}\quad \boldsymbol{x}\in\omega_i$$

这类方法仍然有不确定区。

模式集如果能用 ω_i/ω_j 两分法正确分类，则称它们是成对线性可分的，成对全线性可分不一定是线性可分。

[例 3.2.2] 设有一个二维三类问题，3 个判别函数为

$$d_{12}(\boldsymbol{x})=-x_1-x_2+5,d_{13}(\boldsymbol{x})=-x_1+3,d_{23}(\boldsymbol{x})=-x_1+x_2$$

有待分类模式 $\boldsymbol{x}=(4,3)^{\mathrm{T}}$，将其代入 $d_{ij}(\boldsymbol{x})$ 有

$$d_{12}(\boldsymbol{x})=-2\Rightarrow \boldsymbol{x}\notin\omega_1$$

$$d_{23}(\boldsymbol{x})=-1\Rightarrow \boldsymbol{x}\notin\omega_2$$

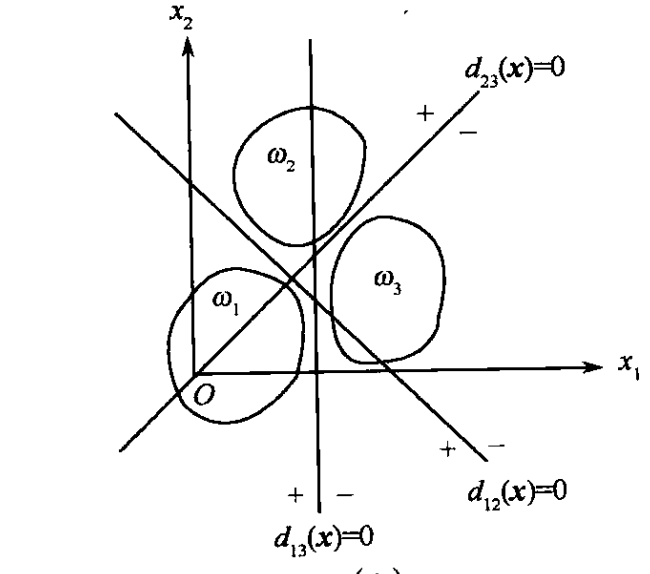
$$d_{13}(\boldsymbol{x})=-1\Rightarrow \boldsymbol{x}\notin\omega_1$$

上面 3 式等效为

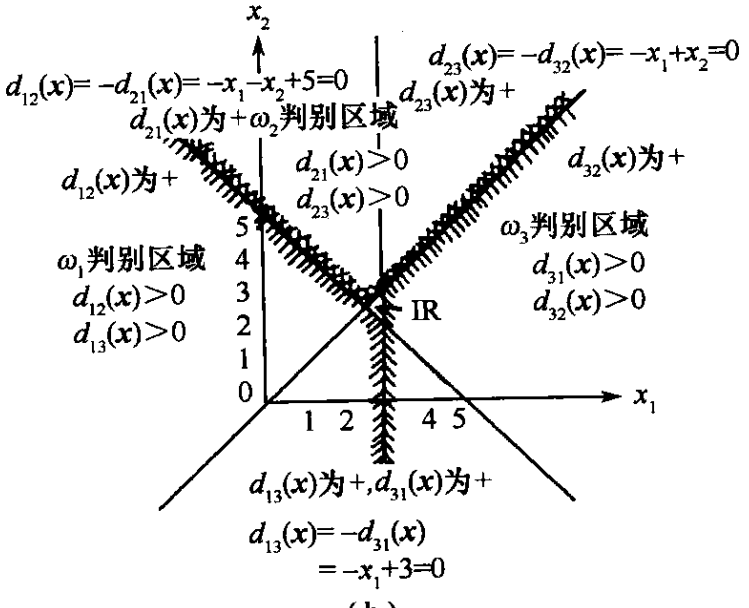
$$d_{21}=2,d_{31}=1,d_{32}=1$$

由于 $d_{3j}(\boldsymbol{x})>0(j=1,2)$，所以判 $\boldsymbol{x}\in\omega_3$。

解题结果如图 3.2.2 所示。



(a)



(b)

图 3.2.2　ω_i/ω_j 两分法例题图示

3. 没有不确定区的 ω_i/ω_j 两分法

对方法 2 中的判别函数作如下形式处理，令

$$d_{ij}(\boldsymbol{x}) = d_i(\boldsymbol{x}) - d_j(\boldsymbol{x}) = (\boldsymbol{w}_i - \boldsymbol{w}_j)^{\mathrm{T}}\boldsymbol{x} \qquad (3-2-8)$$

则 $d_{ij}(\boldsymbol{x}) > 0$ 等价于 $d_i(\boldsymbol{x}) > d_j(\boldsymbol{x})$，于是，对每一类 ω_i 均建立一个判别函数 $d_i(\boldsymbol{x})$，c 类问题有 c 个判别函数

$$d_i(\boldsymbol{x}) = \boldsymbol{w}_i^{\mathrm{T}}\boldsymbol{x} \quad (i = 1,2,\cdots,c) \qquad (3-2-9)$$

此种情况下，判别规则为

如果 $\quad d_i(\boldsymbol{x}) > d_j(\boldsymbol{x}) \quad (\forall j \neq i)$

则判 $\quad \boldsymbol{x} \in \omega_i$

这个判别规则的另一种表述形式为

如果 $\quad d_i(\boldsymbol{x}) = \max_j [d_j(\boldsymbol{x})]$

则判 $\quad \boldsymbol{x} \in \omega_i$

容易知道，不等式组 $d_i(\boldsymbol{x}) > d_j(\boldsymbol{x})$，$\forall j \neq i (i = 1,2,\cdots,c)$ 将特征空间分划成 c 个判别域 $D_1, D_2, \cdots, D_c$，当 $\boldsymbol{x}$ 在 D_i 中时，则有 $d_i(\boldsymbol{x}) > d_j(\boldsymbol{x})$ $(\forall j \neq i)$。实际上有的判别域可能并不相邻。如果 D_i 和 D_j 相邻，则它们的界面方程为 $d_i(\boldsymbol{x}) = d_j(\boldsymbol{x})$。该方法的判别界面是凸的，界面为分片超平面，通常其个数少于 $c(c-1)/2$，判别域单连通。由于这种判别形式，使得该方法没有不确定区。

此种情况下的正确分类是线性可分的。

[例 3.2.3] 一个二维三类模式分类器，其判别函数为

$$d_1(\boldsymbol{x}) = -x_1 + x_2, d_2(\boldsymbol{x}) = x_1 + x_2 - 1, d_3(\boldsymbol{x}) = -x_2$$

属于 ω_1 类的模式 $\boldsymbol{x}$ 应满足 $d_1(\boldsymbol{x}) > d_2(\boldsymbol{x})$ 和 $d_1(\boldsymbol{x}) > d_3(\boldsymbol{x})$；属于 ω_2 类的模式 $\boldsymbol{x}$ 应满足 $d_2(\boldsymbol{x}) > d_1(\boldsymbol{x})$ 和 $d_2(\boldsymbol{x}) > d_3(\boldsymbol{x})$。对待分类模式 $\boldsymbol{x} = (1,1)^{\mathrm{T}}$，$d_1(\boldsymbol{x}) = 0$、$d_2(\boldsymbol{x}) = 1$、$d_3(\boldsymbol{x}) = -1$，从而 $d_2(\boldsymbol{x}) > d_1(\boldsymbol{x})$ 和 $d_2(\boldsymbol{x}) > d_3(\boldsymbol{x})$，故判 $\boldsymbol{x} \in \omega_2$。

解题结果如图 3.2.3 所示。

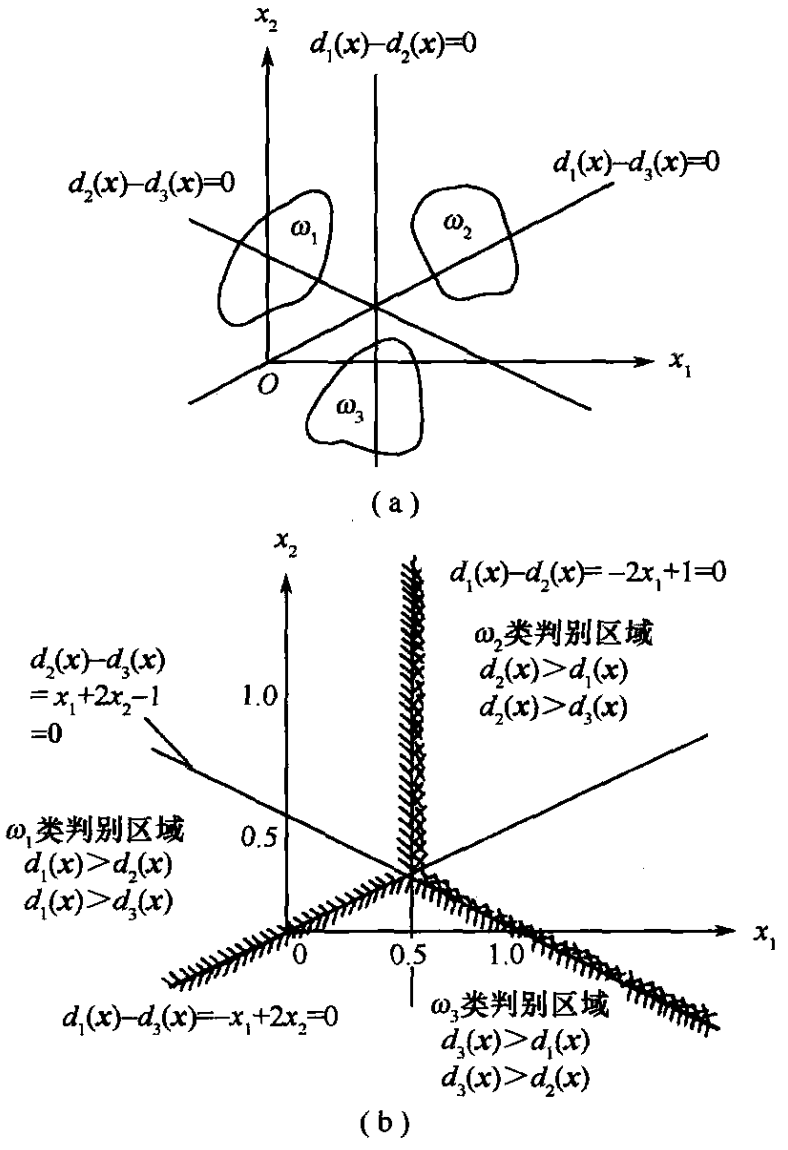


图 3.2.3　无 IR 的 ω_i/ω_j 两分法例题图示

4. 小结

当 $c>3$ 时，ω_i/ω_j 法比 $\omega_i/\overline{\omega_i}$ 法需要更多的判别函数式，这是一个缺点，但是 $\omega_i/\overline{\omega_i}$ 法是将 ω_i 类与其余的 $c-1$ 类区分开，而 ω_i/ω_j 法是将 ω_i 类和 ω_j 类分开，显然 ω_i/ω_j 法使模式更容易线性可分，这是它的优点。方法 3 判别函数的数目和方法 1 相同，但又有方法 2 容易线性可分且没有不确定区的优点，因分析简单，性能良好，故是最常用的一种方法。方法 3 也有一定的局限性，而决策树方法、人工神经网络法通常比方法 1，2，3 更有效。

事实上，线性函数界面方法在本质上与聚类中的最近距离原则是一致的。设定各类的原形点（或中心）$\boldsymbol{p}_1,\boldsymbol{p}_2,\cdots,\boldsymbol{p}_c$，对于一个待识模式

$\boldsymbol{x}$,最小距离分类器是将 $\boldsymbol{x}$ 分到与之最近的原形点所在的类中。$\boldsymbol{x}$ 与原形点 $\boldsymbol{p}_i$ 的距离平方为

$$\| \boldsymbol{x}-\boldsymbol{p}_i \|^2 = \boldsymbol{x}^{\mathrm{T}}\boldsymbol{x} - 2\boldsymbol{p}_i^{\mathrm{T}}\boldsymbol{x} + \boldsymbol{p}_i^{\mathrm{T}}\boldsymbol{p}_i \quad (i=1,2,\cdots,c)$$

因比较上述各式大小进行分类,这等价于比较下式的大小

$$\boldsymbol{p}_i^{\mathrm{T}}\boldsymbol{x} - \frac{1}{2}\boldsymbol{p}_i^{\mathrm{T}}\boldsymbol{p}_i \quad (i=1,2,\cdots,c)$$

上述各式便是线性判别函数。

3.3 判别函数值的鉴别意义、权空间及解空间

3.3.1 判别函数值的大小、正负的数学意义

在 n 维特征空间 X^n 中,两类问题的线性判别界面方程为

$$d(\boldsymbol{x}) = \boldsymbol{w}_0^{\mathrm{T}}\boldsymbol{x} + w_{n+1} = w_1x_1 + w_2x_2 + \cdots + w_nx_n + w_{n+1} = 0 \tag{3-3-1}$$

此方程表示一超平面,记为 π。系数矢量 $\boldsymbol{w}_0 = (w_1, w_2, \cdots, w_n)^{\mathrm{T}}$ 是该平面的法矢量,即 $\boldsymbol{w}_0 \perp$ 平面 π。现证明如下:

设点 $\boldsymbol{x}_1$、$\boldsymbol{x}_2$ 在判别界面中,故它们满足方程,于是有

$$\boldsymbol{w}_0^{\mathrm{T}}\boldsymbol{x}_1 + w_{n+1} = 0$$

$$\boldsymbol{w}_0^{\mathrm{T}}\boldsymbol{x}_2 + w_{n+1} = 0$$

上面二式相减,可得

$$\boldsymbol{w}_0^{\mathrm{T}}(\boldsymbol{x}_1 - \boldsymbol{x}_2) = 0 \tag{3-3-2}$$

上式表明 $\boldsymbol{w}_0 \perp (\boldsymbol{x}_1 - \boldsymbol{x}_2)$,而差矢量$(\boldsymbol{x}_1 - \boldsymbol{x}_2)$在判别界面中,由于 $\boldsymbol{x}_1$、$\boldsymbol{x}_2$ 是 π 中的任意两点,故 $\boldsymbol{w}_0 \perp$ 平面 π。

平面 π 的方程可以写成

$$\frac{\boldsymbol{w}_0^{\mathrm{T}}}{\| \boldsymbol{w}_0 \|}\boldsymbol{x} = \frac{-w_{n+1}}{\| \boldsymbol{w}_0 \|} \tag{3-3-3}$$

式中:$\| \boldsymbol{w}_0 \| = (w_1^2 + w_2^2 + \cdots + w_n^2)^{1/2}$。于是 $\boldsymbol{n} \triangleq \dfrac{\boldsymbol{w}_0}{\| \boldsymbol{w}_0 \|}$是平面 π 的单

位法矢量，上式可写成

$$\boldsymbol{n}^{\mathrm{T}}\boldsymbol{x}=\frac{-w_{n+1}}{\|\boldsymbol{w}_0\|} \tag{3-3-4}$$

设 $\boldsymbol{p}$ 是平面 π 中任一点，$\boldsymbol{x}$ 是特征空间 X^n 中任一点，点 $\boldsymbol{x}$ 到平面 π 的距离为差矢量 $(\boldsymbol{x}-\boldsymbol{p})$ 在 $\boldsymbol{n}$ 上的投影的绝对值，即

$$d_x=|\boldsymbol{n}^{\mathrm{T}}(\boldsymbol{x}-\boldsymbol{p})|=|\boldsymbol{n}^{\mathrm{T}}\boldsymbol{x}-\boldsymbol{n}^{\mathrm{T}}\boldsymbol{p}|=\left|\frac{\boldsymbol{w}_0^{\mathrm{T}}}{\|\boldsymbol{w}_0\|}\boldsymbol{x}-\frac{\boldsymbol{w}_0^{\mathrm{T}}}{\|\boldsymbol{w}_0\|}\boldsymbol{p}\right|$$

$$=\left|\frac{\boldsymbol{w}_0^{\mathrm{T}}}{\|\boldsymbol{w}_0\|}\boldsymbol{x}+\frac{w_{n+1}}{\|\boldsymbol{w}_0\|}\right|=\frac{|\boldsymbol{w}_0^{\mathrm{T}}\boldsymbol{x}+w_{n+1}|}{\|\boldsymbol{w}_0\|} \tag{3-3-5}$$

上式中利用了 $\boldsymbol{p}$ 在平面 π 中，故其满足方程

$$\frac{\boldsymbol{w}_0^{\mathrm{T}}}{\|\boldsymbol{w}_0\|}\boldsymbol{p}=\frac{-w_{n+1}}{\|\boldsymbol{w}_0\|} \tag{3-3-6}$$

式(3-3-5)的分子为判别函数绝对值，此式表明，$d(\boldsymbol{x})$ 的值正比于 $\boldsymbol{x}$ 到超平面 $d(\boldsymbol{x})=0$ 的距离，一个特征矢量代入判别函数后所得值的绝对值越大，表明该特征点距判别界面越远，如图 3.3.1 所示。

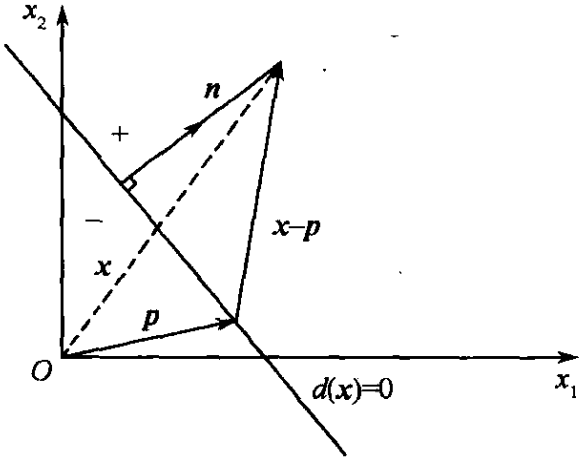


图 3.3.1　点面距离及界面的正负侧示意图

两矢量 $\boldsymbol{n}$ 和 $(\boldsymbol{x}-\boldsymbol{p})$ 的数积为

$$\boldsymbol{n}^{\mathrm{T}}(\boldsymbol{x}-\boldsymbol{p})=\|\boldsymbol{n}\|\ \|\boldsymbol{x}-\boldsymbol{p}\|\cos(\boldsymbol{n},(\boldsymbol{x}-\boldsymbol{p})) \tag{3-3-7}$$

显然，当 $\boldsymbol{n}$ 和 $(\boldsymbol{x}-\boldsymbol{p})$ 夹角小于 90°时，即 $\boldsymbol{x}$ 在 $\boldsymbol{n}$ 指向的那个半空间中，$\cos(\boldsymbol{n},(\boldsymbol{x}-\boldsymbol{p}))>0$；反之，当 $\boldsymbol{n}$ 和 $(\boldsymbol{x}-\boldsymbol{p})$ 夹角大于 90°时，即 $\boldsymbol{x}$ 在 $\boldsymbol{n}$ 背向的那个半空间中，$\cos(\boldsymbol{n},(\boldsymbol{x}-\boldsymbol{p}))<0$。由于 $\|\boldsymbol{w}_0\|>0$，故 $\boldsymbol{n}^{\mathrm{T}}(\boldsymbol{x}-$

p)和 $\boldsymbol{w}_0^{\mathrm{T}}\boldsymbol{x}+w_{n+1}$同号。所以,当 $\boldsymbol{x}$ 在 $\boldsymbol{n}$ 指向的半空间中时,$\boldsymbol{w}_0^{\mathrm{T}}\boldsymbol{x}+\boldsymbol{w}_{n+1}>0$;当 $\boldsymbol{x}$ 在 $\boldsymbol{n}$ 背向的半空间中时,$\boldsymbol{w}_0^{\mathrm{T}}\boldsymbol{x}+\boldsymbol{w}_{n+1}<0$。判别函数值的正负表示出特征点位于哪个半空间中,换句话说,表示特征点位于界面的哪一侧。

在聚类分析中,是以待分类模式与类的距离作为分类的基本依据,在本章,则是以待分类模式在判别界面的哪侧作为分类的基本依据。

3.3.2 权空间、解矢量与解空间

在判别函数中增广特征矢量与增广权矢量在函数结构上是对称的,判别函数可以写成

$$d(\boldsymbol{x})=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{w}=x_1w_1+x_2w_2+\cdots+x_nw_n+w_{n+1} \tag{3-3-8}$$

如果将权系数视为变量,由其组成的增广权矢量的全体为增广权空间 W^{n+1},这里 $x_1,x_2,\cdots,x_n,1$ 则应视为相应的 w_i 的“权”。$d(\boldsymbol{x})=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{w}=0$ 是一个过增广权空间原点的超平面,其将增广权空间分为两个半空间,矢量 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n,1)^{\mathrm{T}}$ 是它的法矢量,$\boldsymbol{x}$ 指向平面 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{w}=0$ 的正侧,即该半空间中的任一点 $(w_1,w_2,\cdots,w_{n+1})^{\mathrm{T}}$ 都使 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{w}>0$,$\boldsymbol{x}$ 背向的半子空间中任一点 $\boldsymbol{w}$ 都有 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{w}<0$。

对于两类问题,在对待分类模式进行分类之前,应根据已知类别的增广训练模式 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 确定线性判别函数

$$d(\boldsymbol{x})=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}$$

具体地讲,就是确定增广权矢量 $\boldsymbol{w}$,使得当训练模式 $\boldsymbol{x}_j\in\omega_1$ 时有 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_j>0$;当训练模式 $\boldsymbol{x}_j\in\omega_2$ 时有 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_j<0$,这时的 $\boldsymbol{w}$ 称为解矢量,记为 $\boldsymbol{w}^*$。有时为表述和处理简洁方便,需要将已知类别的训练模式符号规范化:当 $\boldsymbol{x}$ 属于 ω_1 类时,不改变其符号;当 $\boldsymbol{x}$ 属于 ω_2 类时,改变其符号。在以后,经常针对符号规范化后的训练模式进行讨论。设增广训练模式 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 均已符号规范化,如果所建立的判别函数能正确分类训练模式 $\boldsymbol{x}_j(j=1,2,\cdots,N)$,则有

$$\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_j>0\quad(j=1,2,\cdots,N) \tag{3-3-9}$$

对于一个训练模式 x_j，界面 $d(x_j)=x_j^{\mathrm{T}}w=0$ 过增广权空间原点且将其分成两个半空间，界面 $d(x_j)=0$ 的法矢量 x_j 指向正半空间，所谓正半空间是指该半空间中任一点 w 都使 $w^{\mathrm{T}}x_j>0$。显然，解矢量 w^* 必在正半空间中。N 个训练模式将确定 N 个界面，每个界面都把权空间分为两个半空间，N 个正的半空间的交空间是以权空间原点为顶点的凸多面锥。易知，满足上面各不等式的 w 必在该锥体中，即锥中每一点都是上面不等式组的解，解矢量不是唯一的，上述的凸多面锥包含了解的全体，称其为解区、解空间或解锥。每一个训练模式都对解区提供一个约束，训练模式越多，解区的限制就越多，很多情况下，解区就越小，就越靠近解区的中心，解矢量 w^* 就越可靠，由它构造的判别函数错分模式的可能性就越小。图 3.3.2 所示为由分属 2 类的 4 个训练模式确定解空间的示意图，灰色区域为解空间，图 3.3.2(a) 中训练模式未归一化，而图 3.3.2(b) 中模式则进行了归一化。

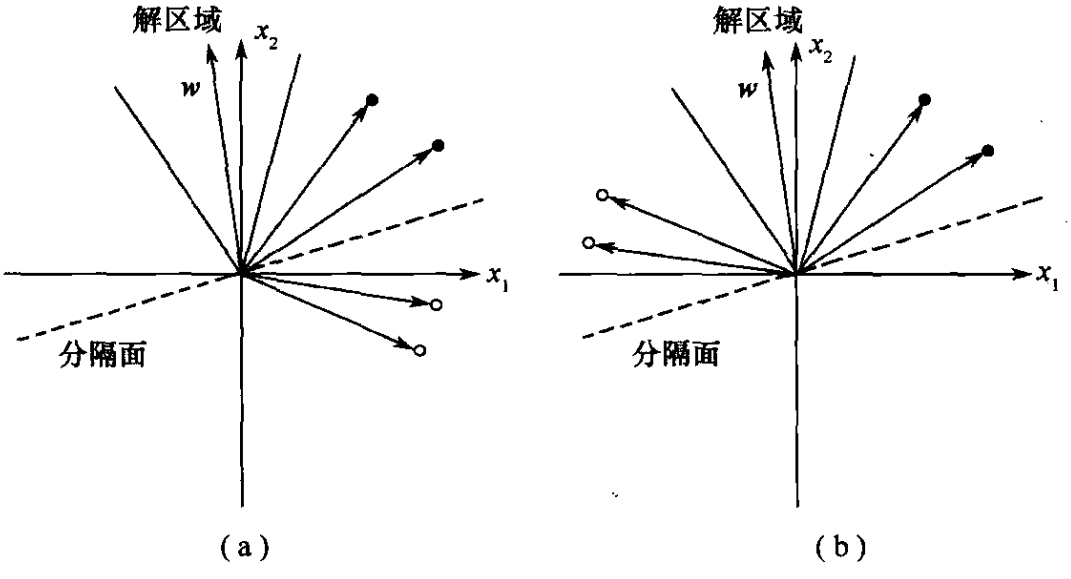


图 3.3.2　解空间的确定示意图

(a)模式未归一化；(b)归一化模式求解。

求解权矢量的最优解 w^*，实质上是求解不等式方程组或等式方程组。原则上讲，可以运用任何有效的方法，通常运用各种最优化理论和技术求解，但常用的计算方法主要有：构造一次或二次准则函数运用最优化技术求解，线性规划法等。下面首先介绍几种常用的线性判别函数的训练算法。

3.4 Fisher 线性判别

对于线性判别函数

$$d(\boldsymbol{x}) = w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + w_{n+1} \triangleq \boldsymbol{w}_0^{\mathrm{T}} \boldsymbol{x} + w_{n+1} \tag{3-4-1}$$

可以将 n 维矢量 $\boldsymbol{w}_0 = (w_1, w_2, \cdots, w_n)^{\mathrm{T}}$ 视作特征空间 X^n 中的以 $w_1, w_2, \cdots, w_n$ 为分量的一个矢量，则 $\boldsymbol{w}_0^{\mathrm{T}} \boldsymbol{x}$ 表示矢量 $\boldsymbol{x}$ 在以 $\boldsymbol{w}_0$ 为方向的轴上投影的 $\| \boldsymbol{w}_0 \|$ 倍。我们希望所求的 $\boldsymbol{w}_0$ 使各模式投影后，同类模式相距较近，同类模式密聚，异类模式相距较远，各类心距离较大。因此寻求权矢量 $\boldsymbol{w}$ 的问题可以归结为寻找满足上述目标的投影轴的方向 $\boldsymbol{w}_0$ 和在一维空间中确定判别规则的问题。降维分析的方法也是其他领域常用的方法。例如，在解决实际问题时，可能遇到的一个困难就是维数问题，许多理论和方法在解析原理上是可行的，但在高维空间中实际运用时将有很大困难或是行不通的，因此，人们经常采用将高维空间问题投影到低维空间中处理的方法。降维的方法也是科学计算可视化一项重要技术。在模式识别中，将 n 维模式投影到低维空间时，首先考虑的是投影到一维空间。从另一观点看，这又是一个特征提取与选择问题。Fisher 分析方法是由 R. A. Fisher 于 1936 年的论文阐述发展的。Fisher 分析方法求判别函数权矢量的算法既适用于线性可分情况，又适用于非线性可分情况，它也是特征提取与选择的有效方法。

图 3.4.1 所示为二维模式向一维空间投影。

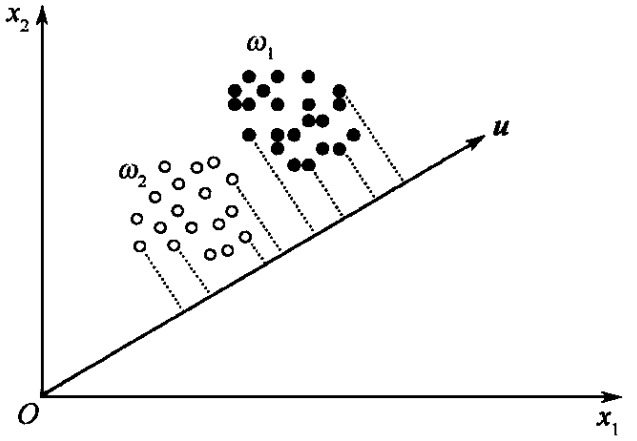


图 3.4.1　二维模式向一维空间投影示意图

下面用 $\boldsymbol{u}$ 表示待求的 $\boldsymbol{w}_0$。设给定 n 维训练模式 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$，其中分别有 N_1 个和 $N_2=N-N_1$ 个模式分属 ω_1 类和 ω_2 类，为方便，各类的模式又可分别记为 $\{\boldsymbol{x}_j^{(1)}\}$ 和 $\{\boldsymbol{x}_j^{(2)}\}$，于是，各类模式均值矢量 $\boldsymbol{m}_i$ 为

$$\boldsymbol{m}_i=\frac{1}{N_i}\sum_j \boldsymbol{x}_j^{(i)} \quad (i=1,2) \tag{3-4-2}$$

各类模式类内离差阵 $\boldsymbol{S}_{\mathrm{W}_i}$ 和总的类内离差阵 $\boldsymbol{S}_{\mathrm{W}}$ 分别为

$$\boldsymbol{S}_{\mathrm{W}_i}=\sum_j (\boldsymbol{x}_j^{(i)}-\boldsymbol{m}_i)(\boldsymbol{x}_j^{(i)}-\boldsymbol{m}_i)^{\mathrm{T}} \quad (i=1,2) \tag{3-4-3}$$

$$\boldsymbol{S}_{\mathrm{W}}=\boldsymbol{S}_{\mathrm{W}_1}+\boldsymbol{S}_{\mathrm{W}_2} \tag{3-4-4}$$

取类间离差阵 $\boldsymbol{S}_{\mathrm{B}}$ 为

$$\boldsymbol{S}_{\mathrm{B}}=(\boldsymbol{m}_1-\boldsymbol{m}_2)(\boldsymbol{m}_1-\boldsymbol{m}_2)^{\mathrm{T}} \tag{3-4-5}$$

注：这里关于类内、类间离差阵的定义与第 6 章的定义在系数上略有不同。

作变换，n 维矢量 $\boldsymbol{x}$ 在以矢量 $\boldsymbol{u}$ 为方向的轴上进行投影

$$y_j^{(i)}=\boldsymbol{u}^{\mathrm{T}}\boldsymbol{x}_j^{(i)} \tag{3-4-6}$$

变换后在一维 y 空间中各类相应的模式的均值为

$$\tilde{m}_i=\frac{1}{N_i}\sum_j y_j^{(i)}=\frac{1}{N_i}\sum_j \boldsymbol{u}^{\mathrm{T}}\boldsymbol{x}_j^{(i)}=\boldsymbol{u}^{\mathrm{T}}\boldsymbol{m}_i \quad (i=1,2) \tag{3-4-7}$$

类内离差度 $\tilde{s}_{\mathrm{W}_i}^2$ 和总的类内离差度 $\tilde{s}_{\mathrm{W}}^2$ 为

$$\begin{aligned}\tilde{s}_{\mathrm{W}_i}^2&=\sum_j (y_j^{(i)}-\tilde{m}_i)^2=\sum_j (\boldsymbol{u}^{\mathrm{T}}\boldsymbol{x}_j^{(i)}-\boldsymbol{u}^{\mathrm{T}}\boldsymbol{m}_i)^2\\&=\sum_j (\boldsymbol{u}^{\mathrm{T}}\boldsymbol{x}_j^{(i)}-\boldsymbol{u}^{\mathrm{T}}\boldsymbol{m}_i)(\boldsymbol{u}^{\mathrm{T}}\boldsymbol{x}_j^{(i)}-\boldsymbol{u}^{\mathrm{T}}\boldsymbol{m}_i)'\\&=\boldsymbol{u}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}_i}\boldsymbol{u} \quad (i=1,2)\end{aligned} \tag{3-4-8}$$

$$\tilde{s}_{\mathrm{W}}^2=\tilde{s}_{\mathrm{W}_1}^2+\tilde{s}_{\mathrm{W}_2}^2=\boldsymbol{u}^{\mathrm{T}}(\boldsymbol{S}_{\mathrm{W}_1}+\boldsymbol{S}_{\mathrm{W}_2})u=\boldsymbol{u}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u} \tag{3-4-9}$$

类间离差度为

$$\tilde{s}_B^2 = (\tilde{m}_1 - \tilde{m}_2)^2 = (\boldsymbol{u}^T\boldsymbol{m}_1 - \boldsymbol{u}^T\boldsymbol{m}_2)(\boldsymbol{u}^T\boldsymbol{m}_1 - \boldsymbol{u}^T\boldsymbol{m}_2)'$$
$$= \boldsymbol{u}^T\boldsymbol{S}_B\boldsymbol{u} \qquad (3-4-10)$$

我们希望找到一个最佳的方向 $\boldsymbol{u}$，以期达到最好的降维分类效果，使各模式在 $\boldsymbol{u}$ 所确定的方向的轴上投影后，在一维 y 空间中，同类的模式尽可能地密聚，不同类的模式尽可能地分开，即希望类内离差度 $\tilde{s}_W^2$ 越小越好，类间离差度 $\tilde{s}_B^2$ 越大越好（显然，对于不同的投影方向，$\tilde{s}_T^2$ 可能是不同的，$\tilde{s}_B^2/\tilde{s}_W^2$ 也可能是不同的，虽然 $\tilde{s}_W^2 + \tilde{s}_B^2 = \tilde{s}_T^2$），根据这个目标，同时也为了消除 $\boldsymbol{u}$ 的矢长对 $\tilde{s}_B^2$ 和 $\tilde{s}_B^2$ 的影响，作准则函数

$$J_F(\boldsymbol{u}) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{s}_{W_1}^2 + \tilde{s}_{W_2}^2} = \frac{\boldsymbol{u}^T\boldsymbol{S}_B\boldsymbol{u}}{\boldsymbol{u}^T\boldsymbol{S}_W\boldsymbol{u}} \qquad (3-4-11)$$

并使其最大。式(3-4-11)称为 Fisher 准则函数。将标量 J_F 对矢量 $\boldsymbol{u}$ 求导并令其为零矢量，注意到 J_F 的分子、分母均为标量，利用二次型关于矢量求导的公式可得

$$\frac{\partial J_F}{\partial \boldsymbol{u}} = \frac{\partial}{\partial \boldsymbol{u}}\left[\frac{\boldsymbol{u}^T\boldsymbol{S}_B\boldsymbol{u}}{\boldsymbol{u}^T\boldsymbol{S}_W\boldsymbol{u}}\right] = \frac{2(\boldsymbol{u}^T\boldsymbol{S}_W\boldsymbol{u})\boldsymbol{S}_B\boldsymbol{u} - 2(\boldsymbol{u}^T\boldsymbol{S}_B\boldsymbol{u})\boldsymbol{S}_W\boldsymbol{u}}{(\boldsymbol{u}^T\boldsymbol{S}_W\boldsymbol{u})^2} = \boldsymbol{0}$$

$$(3-4-12)$$

令

$$\lambda = \frac{\boldsymbol{u}^T\boldsymbol{S}_B\boldsymbol{u}}{\boldsymbol{u}^T\boldsymbol{S}_W\boldsymbol{u}}$$

可得

$$\boldsymbol{S}_B\boldsymbol{u} = \lambda\boldsymbol{S}_W\boldsymbol{u}$$

当 N 较大时，$\boldsymbol{S}_W$ 通常是非奇异的（$N-2<n$ 时，$\boldsymbol{S}_W^{-1}$ 是不存在的），于是有

$$\boldsymbol{S}_W^{-1}\boldsymbol{S}_B\boldsymbol{u} = \lambda\boldsymbol{u} \qquad (3-4-13)$$

式(3-4-13)表明，$\boldsymbol{u}$ 是矩阵 $\boldsymbol{S}_W^{-1}\boldsymbol{S}_B$ 相应于特征值 λ 的特征矢量。对于两类问题，$\boldsymbol{S}_B$ 的秩为 1，因此，$\boldsymbol{S}_W^{-1}\boldsymbol{S}_B$ 只有一个非零特征值，其所对应

的特征矢量 $\boldsymbol{u}$ 称为 Fisher 最佳鉴别矢量，由式(3-4-13)，有

$$\lambda \boldsymbol{u} = \boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u} = \boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{m}_1 - \boldsymbol{m}_2)(\boldsymbol{m}_1 - \boldsymbol{m}_2)^{\mathrm{T}}\boldsymbol{u} \quad (3-4-14)$$

上式右边后两项因子的乘积为一标量，令其为 α，于是可得

$$\boldsymbol{u} = \frac{\alpha}{\lambda}\boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{m}_1 - \boldsymbol{m}_2)$$

式中：$\frac{\alpha}{\lambda}$为一标量因子，其不改变轴的方向，可以取为 1，于是有

$$\boldsymbol{u} = \boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{m}_1 - \boldsymbol{m}_2) \quad (3-4-15)$$

此时的 $\boldsymbol{u}$ 可使 Fisher 准则函数取最大值，即 $\boldsymbol{u}$ 是 n 维空间到一维空间投影轴的最佳方向，J_F 最大值为$(\boldsymbol{m}_1 - \boldsymbol{m}_2)^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{m}_1 - \boldsymbol{m}_2)$。变换

$$y = (\boldsymbol{m}_1 - \boldsymbol{m}_2)^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{x} \quad (3-4-16)$$

称为 Fisher 变换函数。

实际上，不论 $\boldsymbol{S}_{\mathrm{W}}$ 是否奇异，都可以求解特征方程

$$|\boldsymbol{S}_{\mathrm{B}} - \lambda \boldsymbol{S}_{\mathrm{W}}| = 0 \quad (3-4-17)$$

它的所有的根 λ_i 便是特征值，然后求解

$$(\boldsymbol{S}_{\mathrm{B}} - \lambda_i \boldsymbol{S}_{\mathrm{W}})\boldsymbol{u}_i = 0 \quad (3-4-18)$$

中的 $\boldsymbol{u}_i$。

至此可以说解决了将 n 维模式的分类转变为一维模式分类的问题，也相应解决了确定 $\boldsymbol{w}_0$ 的问题。

由于变换后的模式是一维的，因此判别界面实际上是各类模式所在轴上的一个点，可以根据训练模式确定一个阈值 y_t。于是 Fisher 判别规则为

$$\boldsymbol{u}^{\mathrm{T}}\boldsymbol{x} = y \gtrless y_t \Rightarrow \boldsymbol{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases} \quad (3-4-19)$$

可取两类类心在 $\boldsymbol{u}$ 方向上轴的投影间的中点作为判别阈值，即

$$y_t = \frac{\widetilde{m}_1 + \widetilde{m}_2}{2} \quad (3-4-20)$$

容易得出

$$y_t = \frac{\boldsymbol{u}^{\mathrm{T}}\boldsymbol{m}_1 + \boldsymbol{u}^{\mathrm{T}}\boldsymbol{m}_2}{2} = \boldsymbol{u}^{\mathrm{T}}(\boldsymbol{m}_1 + \boldsymbol{m}_2)/2 = \boldsymbol{u}^{\mathrm{T}}\boldsymbol{m}$$

$$= (\boldsymbol{m}_1 - \boldsymbol{m}_2)^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{m}_1 + \boldsymbol{m}_2)/2 \qquad (3-4-21)$$

显然,这里 $\boldsymbol{m}$ 是 $\boldsymbol{m}_1$ 和 $\boldsymbol{m}_2$ 连线的中点。

当考虑类的先验概率时,$\boldsymbol{S}_{\mathrm{W}}$、$\boldsymbol{S}_{\mathrm{B}}$ 应取下面的定义:

$$\boldsymbol{S}_{\mathrm{W}} = P(\omega_1)\boldsymbol{S}_{\mathrm{W}_1} + \boldsymbol{P}(\omega_2)\boldsymbol{S}_{\mathrm{W}_2} \qquad (3-4-22)$$

$$\boldsymbol{S}_{\mathrm{B}} = P(\omega_1)P(\omega_2)(\boldsymbol{m}_1 - \boldsymbol{m}_2)(\boldsymbol{m}_1 - \boldsymbol{m}_2)^{\mathrm{T}} \qquad (3-4-23)$$

$P(\omega_1)$、$P(\omega_2)$ 可由各类训练模式的频率估计,即

$$P(\omega_1) = \frac{N_1}{N}, \quad P(\omega_2) = \frac{N_2}{N}$$

这种情况下,可取以类的频率为权值的两类中心的加权算术平均作为阈值,即

$$y_t = \frac{N_1\widetilde{m}_1 + N_2\widetilde{m}_2}{N_1 + N_2} = \widetilde{m} \qquad (3-4-24)$$

易得

$$y_t = \frac{N_1\boldsymbol{u}^{\mathrm{T}}\boldsymbol{m}_1 + N_2\boldsymbol{u}^{\mathrm{T}}\boldsymbol{m}_2}{N_1 + N_2} = \boldsymbol{u}^{\mathrm{T}}\frac{N_1\boldsymbol{m}_1 + N_2\boldsymbol{m}_2}{N_1 + N_2} = \boldsymbol{u}^{\mathrm{T}}\boldsymbol{m} \qquad (3-4-25)$$

这里的 $\boldsymbol{m}$ 是 $\boldsymbol{m}_1$ 和 $\boldsymbol{m}_2$ 连线上以频率为比例的内分点。

为了反映类概率的影响和作用,一维轴上的阈值也可以取为

$$y_t = \frac{N_2\widetilde{m}_1 + N_1\widetilde{m}_2}{N_1 + N_2} \qquad (3-4-26)$$

利用贝叶斯判决中关于两类均为正态分布且协方差阵相同条件下的判决函数,阈值也可以取为

$$y_t = (\boldsymbol{m}_1 - \boldsymbol{m}_2)^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{m}_1 + \boldsymbol{m}_2)/2 + \lg(P(\omega_2)/P(\omega_1))$$

$$(3-4-27)$$

由上可知，$y \gtrless y_t$ 和 $\boldsymbol{u}^{\mathrm{T}}\boldsymbol{x} - \boldsymbol{u}^{\mathrm{T}}\boldsymbol{m} \gtrless 0$ 是等价的，从而可得 Fisher 线性判别函数为

$$d(\boldsymbol{x}) = \boldsymbol{u}^{\mathrm{T}}\boldsymbol{x} - \boldsymbol{u}^{\mathrm{T}}\boldsymbol{m} \tag{3-4-28}$$

这时 Fisher 判别规则为

$$\boldsymbol{u}^{\mathrm{T}}(\boldsymbol{x} - \boldsymbol{m}) \gtrless 0 \Rightarrow \boldsymbol{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases} \tag{3-4-29}$$

取第一种门限，可以写出具体的判别规则如下：

$$(\boldsymbol{m}_1 - \boldsymbol{m}_2)^{\mathrm{T}} \boldsymbol{S}_{\mathrm{W}}^{-1} \left(\boldsymbol{x} - \frac{\boldsymbol{m}_1 + \boldsymbol{m}_2}{2} \right) \gtrless 0 \Rightarrow \boldsymbol{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases} \tag{3-4-30}$$

由上可知，在使 J_F 取最大的目标下线性判别函数权矢量 $\boldsymbol{w}_0$ 以及判别门限（相当于 w_{n+1}）的确定只需要一、二阶矩（或它们的估计）。可以证明，当训练模式数 N 足够大时，在使式（3-4-11）取最大的要求下，在两类的先验概率相等及正态等协方差阵情况下，式（3-4-27）Fisher 线性判别与 Bayes 判决是等价的。

3.5 线性可分条件下判别函数权矢量算法

3.5.1 感知器算法

感知器算法（Perceptron Approach）的基本思想是，对初始的或迭代中的增广权矢量 $\boldsymbol{w}$，用训练模式检验它的合理性，当不合理时，对其进行校正，校正方法实际上是最优化技术中的梯度下降法。该算法也是人工神经网络理论中的线性阈值神经元的学习算法。算法原理步骤如下：

设给定一个增广的训练模式集 $\{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N\}$，其中每个模式类别已知，它们分属 ω_1 类和 ω_2 类。

（1）置步数 $k=1$，令增量 ρ 为某正的常数，分别赋给初始增广权矢量 $\boldsymbol{w}(1)$ 的各分量较小的任意值。

(2)输入训练模式 x_k,计算判别函数值 $w^{\mathrm{T}}(k)x_k$。

(3)调整增广权矢量,规则是

①如果 $x_k \in \omega_1$ 和 $w^{\mathrm{T}}(k)x_k \leqslant 0$,则 $w(k+1)=w(k)+\rho x_k$;

②如果 $x_k \in \omega_2$ 和 $w^{\mathrm{T}}(k)x_k \geqslant 0$,则 $w(k+1)=w(k)-\rho x_k$;

③如果 $x_k \in \omega_1$ 和 $w^{\mathrm{T}}(k)x_k > 0$,或 $x_k \in \omega_2$ 和 $w^{\mathrm{T}}(k)x_k < 0$,则 $w(k+1)=w(k)$。

(4)如果 $k<N$,令 $k=k+1$,返至(2)。如果 $k=N$,检验判别函数 $w^{\mathrm{T}}x$ 对 $x_1, x_2, \cdots, x_N$ 是否都能正确分类。若是,结束;若不是,令 $k=1$,返至(2)。

在上述算法中,若错误分类,通过给 w 加一个矢量改变它的方向。如果 $x_k \in \omega_1$,但 $w^{\mathrm{T}}(k)x_k \leqslant 0$,说明用该权矢量构造的判别函数对其作了错误分类,应校正权矢量,令 $w(k+1)=w(k)+\rho x_k$;如果 $x_k \in \omega_2$,但 $w^{\mathrm{T}}(k)x_k \geqslant 0$,也说明用该权矢量构造的判别函数对其作了错误分类,故也应校正权矢量,令 $w(k+1)=w(k)-\rho x_k$;如果不是以上两种情况,表明分类正确,权矢量应该不变,$w(k+1)=w(k)$。如果训练模式已经符号规范化,即 $x_k \in \omega_2$ 已乘以 -1(包括增广分量 1),则校正权矢量的规则可统一为

$$w(k+1)=\begin{cases} w(k) & (\text{若 } w^{\mathrm{T}}(k)x_k > 0(\text{正确分类})) \\ w(k)+\rho x_k & (\text{若 } w^{\mathrm{T}}(k)x_k \leqslant 0(\text{错误分类})) \end{cases}$$

在用全部模式训练完一轮后只要还有模式被判错,则需要进行第二轮迭代,再用全部训练模式训练一次,建立新的权矢量。如果对训练模式还有错分的,则进行第三轮迭代,余类推,直至对所有训练模式均能正确分类为止,此时的 w 即为所求的权矢量。

图 3.5.1 中 $x_k^{(i)}$ 表示属于 ω_i 类的模式,$x_k^{(j)}$ 表示属于 ω_j 类的模式。对 $x_k^{(i)}$ 分类错误,则 $d(x_k^{(i)})<0$,即 $w(k)$ 在所求的界面的负区,应根据调整规则进行修正,图中(a)表明了这种情况,由图可见,$w(k+1)$ 更接近该界面所分划的正区。此图(b)中 $d(x_k^{(j)})>0$,说明对 $x_k^{(j)}$ 分类错误,根据调整规则进行修正,使 $w(k+1)$ 更接近另一个半空间。经不断迭代,最终 $w(k+1)$ 可垂直正确分类的界面且指向正区。

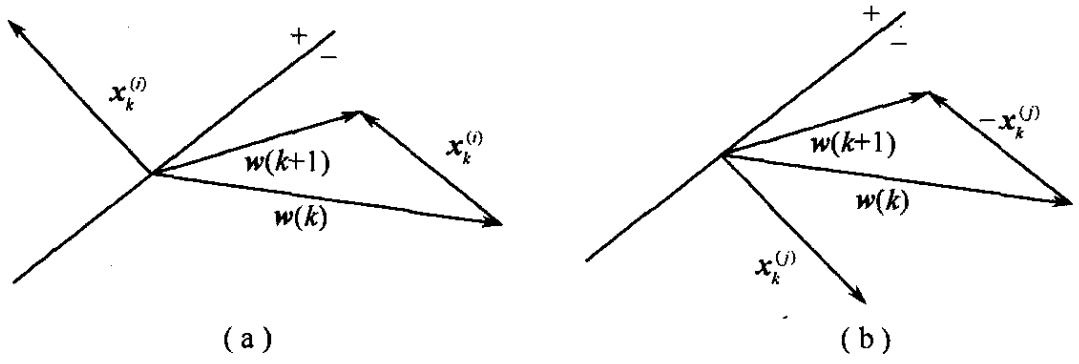


图 3.5.1　权空间中感知器算法权矢量校正过程示意图

[**定理 3.5.1(收敛定理)**] 如果训练模式是线性可分的,感知器训练算法在有限次迭代后便可以收敛到正确的解矢量 $\boldsymbol{w}^*$。

[**例 3.5.1**]已知两类模式训练样本如图 3.5.2 所示,其中$(0,0)^{\mathrm{T}}$、$(0,1)^{\mathrm{T}}$ 属于 ω_1 类,$(1,0)^{\mathrm{T}}$、$(1,1)^{\mathrm{T}}$ 属于 ω_2 类,试用感知器算法求 $\boldsymbol{w}^*$。

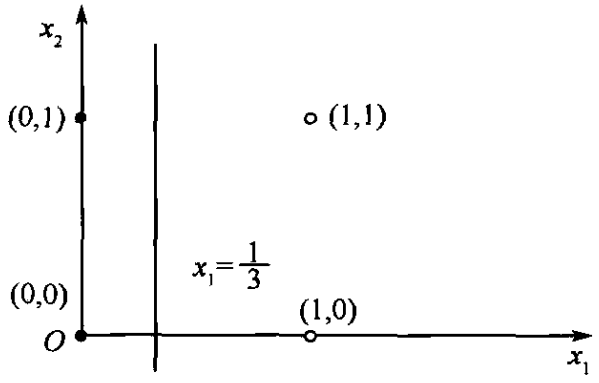


图 3.5.2　两类模式感知器训练算法例题

解:

(1)训练样本增广化及符号规范化。即将训练样本增加一个分量 1,且把来自 ω_2 类的训练样本的各分量乘以 -1,则得到训练模式集:$\boldsymbol{x}_1=(0,0,1)^{\mathrm{T}},\boldsymbol{x}_2=(0,1,1)^{\mathrm{T}},\boldsymbol{x}_3=(-1,0,-1)^{\mathrm{T}},\boldsymbol{x}_4=(-1,-1,-1)^{\mathrm{T}}$。

(2)运用感知器训练算法。给增广权矢量赋初值 $\boldsymbol{w}(1)=(1,1,1)^{\mathrm{T}}$,取增量 $\rho=1$,置迭代步数 $k=1$,则

$k=1,\boldsymbol{x}_k=\boldsymbol{x}_1,d(\boldsymbol{x}_k)=\boldsymbol{w}^{\mathrm{T}}(k)\boldsymbol{x}_k=1>0,\boldsymbol{w}(2)=\boldsymbol{w}(1)$

$k=2,\boldsymbol{x}_k=\boldsymbol{x}_2,d(\boldsymbol{x}_k)=\boldsymbol{w}^{\mathrm{T}}(k)\boldsymbol{x}_k=2>0,\boldsymbol{w}(3)=\boldsymbol{w}(2)$

$k=3,\boldsymbol{x}_k=\boldsymbol{x}_3,d(\boldsymbol{x}_k)=\boldsymbol{w}^{\mathrm{T}}(k)\boldsymbol{x}_k=-2<0,\boldsymbol{w}(4)=\boldsymbol{w}(3)+\boldsymbol{x}_3=$

$(0,1,0)^{\mathrm{T}}$

$k=4, x_k=x_4, d(x_k)=w^{\mathrm{T}}(k)x_k=-1<0, w(5)=w(4)+x_4=(-1,0,-1)^{\mathrm{T}}$

$k=5, x_k=x_1, d(x_k)=w^{\mathrm{T}}(k)x_k=-1<0, w(6)=w(5)+x_1=(-1,0,0)^{\mathrm{T}}$

$k=6, x_k=x_2, d(x_k)=w^{\mathrm{T}}(k)x_k=0, w(7)=w(6)+x_2=(-1,1,1)^{\mathrm{T}}$

$k=7, x_k=x_3, d(x_k)=w^{\mathrm{T}}(k)x_k=0, w(8)=w(7)+x_3=(-2,1,0)^{\mathrm{T}}$

$k=8, x_k=x_4, d(x_k)=w^{\mathrm{T}}(k)x_k=1>0, w(9)=w(8)$

$k=9, x_k=x_1, d(x_k)=w^{\mathrm{T}}(k)x_k=0, w(10)=w(9)+x_1=(-2,1,1)^{\mathrm{T}}$

$k=10, x_k=x_2, d(x_k)=w^{\mathrm{T}}(k)x_k=2>0, w(11)=w(10)$

$k=11, x_k=x_3, d(x_k)=w^{\mathrm{T}}(k)x_k=1>0, w(12)=w(11)$

$k=12, x_k=x_4, d(x_k)=w^{\mathrm{T}}(k)x_k=0, w(13)=w(12)+x_4=(-3,0,0)^{\mathrm{T}}$

$k=13, x_k=x_1, d(x_k)=w^{\mathrm{T}}(k)x_k=0, w(14)=w(13)+x_1=(-3,0,1)^{\mathrm{T}}$

$k=14, x_k=x_2, d(x_k)=w^{\mathrm{T}}(k)x_k=1>0, w(15)=w(14)$

$k=15, x_k=x_3, d(x_k)=w^{\mathrm{T}}(k)x_k=2>0, w(16)=w(15)$

$k=16, x_k=x_4, d(x_k)=w^{\mathrm{T}}(k)x_k=2>0, w(17)=w(16)$

$k=17, x_k=x_1, d(x_k)=w^{\mathrm{T}}(k)x_k=1>0, w(18)=w(17)$

(3)由上面的结果可以看出，经过对 x_1、x_2、x_3、x_4 一轮迭代后表明，使用 $w(14)$ 已能对所有训练样本正确分类，增广权矢量的值不再变化，所以算法收敛于 $w(14)$，$w(14)$ 就是所求的解向量，$w^*=(-3,0,1)^{\mathrm{T}}$。由此还可以得到分类界面为 $-3x_1+1=0$，即 $x_1=\frac{1}{3}$。

3.5.2 一次准则函数及梯度下降法

采用最优化技术求线性判别函数中的增广权矢量时，首先需构造

准则函数。一个可微函数某点处的梯度给出了函数在该点的变化率取最大的方向，梯度模等于这个方向的方向导数，负梯度方向给出了函数下降最快的方向。在解矢量对应于一次准则函数极小值的情况中，采用梯度下降法沿负梯度方向选择适当的步长进行搜索，求解函数的极小值点 $\boldsymbol{w}^*$。

构造准则函数

$$J(\boldsymbol{w}) = k(|\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}| - \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}) \quad (k>0) \qquad (3-5-1)$$

当 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}<0$ 时，$|\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}| - \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} = -2\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}>0$；当 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}\geqslant 0$ 时，$|\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}| - \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} = 0$，$J(\boldsymbol{w})$ 有极小值 $J_{\min}(\boldsymbol{w}) = 0$。所以对于已符号规范化的训练模式，应寻求使 $J(\boldsymbol{w})$ 取极小时的 $\boldsymbol{w}$，因此时的 $\boldsymbol{w}$ 满足 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}\geqslant 0$。令 $k=\frac{1}{2}$，求得准则函数的梯度

$$\nabla J(\boldsymbol{w}) = \frac{\partial J}{\partial \boldsymbol{w}} = \frac{1}{2}[\boldsymbol{x}\mathrm{sgn}(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}) - \boldsymbol{x}] \qquad (3-5-2)$$

为克服 $J(\boldsymbol{w})$ 取极小值出现 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}=0$ 的情况，这里令符号函数

$$\mathrm{sgn}(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}) = \begin{cases} 1 & (\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}>0) \\ -1 & (\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}\leqslant 0) \end{cases}$$

由梯度下降法，增广权矢量的修正迭代公式为

$$\begin{aligned} \boldsymbol{w}(k+1) &= \boldsymbol{w}(k) - \rho_k \nabla J(\boldsymbol{w}(k)) \\ &= \boldsymbol{w}(k) - \frac{\rho_k}{2}[\boldsymbol{x}_k \mathrm{sgn}[\boldsymbol{w}^{\mathrm{T}}(k)\boldsymbol{x}_k] - \boldsymbol{x}_k] \\ &= \begin{cases} \boldsymbol{w}(k) & (\text{若 } \boldsymbol{w}^{\mathrm{T}}(k)\boldsymbol{x}_k>0) \\ \boldsymbol{w}(k) + \rho_k \boldsymbol{x}_k & (\text{若 } \boldsymbol{w}^{\mathrm{T}}(k)\boldsymbol{x}_k\leqslant 0, \rho_k>0) \end{cases} \end{aligned} \qquad (3-5-3)$$

当 ρ_k 为常数时，上述准则下的梯度下降法的迭代公式与感知器训练算法是一致的，此表明感知器算法是梯度下降法的一种情况。ρ_k 取常数时，这种梯度下降法也称为固定增量法。若 ρ 取得较小，收敛速度就较慢；若 ρ 取得较大，收敛加快，但当搜索接近极值点时可能产生过调引起振荡。一般地，ρ_k 应随着搜索步数的增加而逐渐变小，以减小错分

模式的影响。若在迭代过程中 ρ_k 随 k 而变化，则称为可变增量法。在迭代中，我们希望用 $\boldsymbol{x}_k$ 修正 $\boldsymbol{w}(k)$，使 $\boldsymbol{w}(k+1)$ 有

$$\boldsymbol{w}^{\mathrm{T}}(k+1)\boldsymbol{x}_k > 0$$

迭代式 $\boldsymbol{w}(k+1)=\boldsymbol{w}(k)+\rho_k\boldsymbol{x}_k$ 两边和 $\boldsymbol{x}_k$ 数积并利用上式，可得步长应满足

$$\rho_k > \frac{-\boldsymbol{w}^{\mathrm{T}}(k)\boldsymbol{x}_k}{\|\boldsymbol{x}_k\|^2} \qquad (3-5-4)$$

由于上述的准则函数是分段常数函数，对梯度法来讲不是好的准则函数。在上述算法中，每次迭代时，我们只考虑用一个训练模式修正权矢量，实际上，也可以几个训练模式一起考虑。设分属 ω_1 和 ω_2 类的训练模式 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 已符号规范化，如果它们是线性可分的，则存在 $\boldsymbol{w}$ 使

$$\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i > 0 \quad (i=1,2,\cdots,N) \qquad (3-5-5)$$

设在训练中只有一部分训练模式满足上述不等式，而另一些训练模式不满足不等式，被当前 $\boldsymbol{w}$ 错分的这部分模式记为集合 X_m，即

$$\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_j < 0 \quad (\boldsymbol{x}_j \in X_m) \qquad (3-5-6)$$

我们构造准则函数

$$J(\boldsymbol{w}) = \sum_{\boldsymbol{x}_j \in X_m} (-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_j) \qquad (3-5-7)$$

如果 $\boldsymbol{x}_j$ 被错分，必有 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_j<0$，亦即 $-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_j>0$。在求得最佳解 $\boldsymbol{w}^*$ 之前的迭代过程中，总有 $\boldsymbol{x}_j \in \boldsymbol{X}_m$，使 $-\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_j>0$，即 $J(\boldsymbol{w})$ 总是大于零并逐渐变小，集合中的元素也是渐少的，当所求得的 $\boldsymbol{w}^*$ 使所有的不等式 (3-5-5) 成立，X_m 成为空集，$J(\boldsymbol{w})$ 取其最小值 $J_{\min}(\boldsymbol{w}^*)=0$。上述的准则函数是与错分模式到当前界面距离之和成比例的。对一次准则函数采用梯度下降法，梯度

$$\nabla J(\boldsymbol{w},k) = \frac{\partial J(\boldsymbol{w})}{\partial \boldsymbol{w}} = \sum_{\boldsymbol{x}_j \in X_m(k)} (-\boldsymbol{x}_j) \qquad (3-5-8)$$

梯度下降法迭代公式为

$$\boldsymbol{w}(k+1) = \boldsymbol{w}(k) - \rho_k \nabla J(\boldsymbol{w})$$

$$= \boldsymbol{w}(k) + \rho_k \sum_{\boldsymbol{x}_j \in X_m(k)} \boldsymbol{x}_j \qquad (3-5-9)$$

式中：$X_m(k)$是被 $\boldsymbol{w}(k)$错分类的模式集。相对前述的梯度下降法而言，这个迭代式称为批量修正，式(3-5-3)称为单样本修正。

可以证明，如果训练模式是线性可分的，ρ_k 若满足

$$\rho_k \geqslant 0, \quad \lim_{m\to\infty} \sum_{k=1}^{m} \rho_k = \infty, \quad \lim_{m\to\infty} \frac{\sum_{k=1}^{m} \rho_k^2}{\left(\sum_{k=1}^{m} \rho_k\right)^2} = 0 \qquad (3-5-10)$$

式(3-5-3)和式(3-5-9)中的 $\boldsymbol{w}(k)$都收敛于一个解矢量 $\boldsymbol{w}^*$。当 ρ_k 为正的常数或 $\rho_k = 1/k$，ρ_k 都将满足上述条件。

3.5.3 感知器训练算法在多类问题中的应用

一次准则函数及梯度下降法也可以推广应用于多类问题。由于多类问题的第三种分类途径没有不确定区，下面只针对这种途径介绍感知器训练算法，其他算法是类似的。

对于 c 类问题，应建立 c 个判别函数 $d_i(\boldsymbol{x}) = \boldsymbol{w}_i^{\mathrm{T}}\boldsymbol{x}(i = 1,2,\cdots,c)$，如果 $\boldsymbol{x} \in \omega_i$，则有 $\boldsymbol{w}_i^{\mathrm{T}}\boldsymbol{x} > \boldsymbol{w}_j^{\mathrm{T}}\boldsymbol{x}(\forall j \neq i)$，因此判别规则是

若有　$d_i(\boldsymbol{x}) > d_j(\boldsymbol{x}), \forall j \neq i$

则判　$\boldsymbol{x} \in \omega_i$

下面给出算法步骤：

(1)赋初值。分别给 c 个权矢量 $\boldsymbol{w}_i(1)(i = 1,2,\cdots,c)$赋任意的初值，选择正常数 ρ，置步数 $k = 1$。

(2)输入符号未规范化的增广训练模式 $\boldsymbol{x}_k, \boldsymbol{x}_k \in \{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N\}$，计算 c 个判别函数 $d_i(\boldsymbol{x}_k) = \boldsymbol{w}_i^{\mathrm{T}}(k)\boldsymbol{x}_k \quad (i = 1,2,\cdots,c)$。

(3)修正权矢量，修正规则是

若　$\boldsymbol{x}_k \in \omega_i$ 和 $d_i(\boldsymbol{x}_k) > d_j(\boldsymbol{x}_k) \quad (\forall j \neq i)$

则　$\boldsymbol{w}_i(k+1) = \boldsymbol{w}_i(k) \quad (i = 1,2,\cdots,c)$

若 $x_k \in \omega_i$ 和 $d_l(x_k) \geqslant d_i(x_k)$ $(l \neq i)$

则 $w_i(k+1) = w_i(k) + \rho x_k$

$w_l(k+1) = w_l(k) - \rho x_k$

$w_j(k+1) = w_j(k)$ $(\forall j \neq i, l)$

(4)如果 $k < N$,令 $k = k+1$,返至(2)。如果 $k = N$,检验判别函数 $w_i^{\mathrm{T}} x (i = 1,2,\cdots,c)$ 是否对 $x_1, x_2, \cdots, x_N$ 都能正确分类。若是,结束;若不是,则令 $k = 1$,返至(2)。

[**例 3.5.2**]已知训练样本 $(0,0)^{\mathrm{T}}$ 属于 ω_1 类,$(1,1)^{\mathrm{T}}$ 属于 ω_2 类,$(-1,1)^{\mathrm{T}}$ 属于 ω_3 类,试求解矢量 w_1^*、w_2^* 和 w_3^*。

解:

(1)训练样本矢量增广化。将训练样本变成增广训练模式:

$$x_1 = (0,0,1)^{\mathrm{T}}; x_2 = (1,1,1)^{\mathrm{T}}; x_3 = (-1,1,1)^{\mathrm{T}}$$

这里 x 的下标恰是 x 所属类别。各类样本不需符号规范化。

(2)运用感知器训练算法。置迭代步数 $k = 1$,增量 $\rho = 1$,赋初值:$w_1(1) = (0,0,0)^{\mathrm{T}}$,$w_2(1) = (0,0,0)^{\mathrm{T}}$,$w_3(1) = (0,0,0)^{\mathrm{T}}$,进行迭代运算:

$k = 1, x_k = x_1 \in \omega_1, d_1(x_1) = d_2(x_1)$ 和 $d_1(x_1) = d_3(x_1)$,所以

$$w_1(2) = w_1(1) + x_1 = (0,0,1)^{\mathrm{T}}$$

$$w_2(2) = w_2(1) - x_1 = (0,0,-1)^{\mathrm{T}}$$

$$w_3(2) = w_3(1) - x_1 = (0,0,-1)^{\mathrm{T}}$$

$k = 2, x_k = x_2 \in \omega_2, d_2(x_2) < d_1(x_2)$ 和 $d_2(x_2) = d_3(x_2)$,所以

$$w_1(3) = w_1(2) - x_2 = (-1,-1,0)^{\mathrm{T}}$$

$$w_2(3) = w_2(2) + x_2 = (1,1,0)^{\mathrm{T}}$$

$$w_3(3) = w_3(2) - x_2 = (-1,-1,-2)^{\mathrm{T}}$$

$k = 3, x_k = x_3 \in \omega_3, d_3(x_3) < d_1(x_3)$ 和 $d_3(x_3) < d_2(x_3)$,所以

$$w_1(4) = w_1(3) - x_3 = (0,-2,-1)^{\mathrm{T}}$$

$$w_2(4) = w_2(3) - x_3 = (2,0,-1)^{\mathrm{T}}$$

$$w_3(4) = w_3(3) + x_3 = (-2,0,-1)^{\mathrm{T}}$$

$k=4, \boldsymbol{x}_k=\boldsymbol{x}_1 \in \omega_1, d_1(\boldsymbol{x}_1)=d_2(\boldsymbol{x}_1)$ 和 $d_1(\boldsymbol{x}_1)=d_3(\boldsymbol{x}_1)$，所以

$$\boldsymbol{w}_1(5)=\boldsymbol{w}_1(4)+\boldsymbol{x}_1=(0,-2,0)^{\mathrm{T}}$$

$$\boldsymbol{w}_2(5)=\boldsymbol{w}_2(4)-\boldsymbol{x}_1=(2,0,-2)^{\mathrm{T}}$$

$$\boldsymbol{w}_3(5)=\boldsymbol{w}_3(4)-\boldsymbol{x}_1=(-2,0,-2)^{\mathrm{T}}$$

依此类推，令 $k=5,6,7$，依次代入 $\boldsymbol{x}_k=\boldsymbol{x}_2,\boldsymbol{x}_3,\boldsymbol{x}_1$，3 个权矢量不再变化，可以确定所有训练样本均已被正确分类，由此得到 3 个解矢量：$\boldsymbol{w}_1^*=\boldsymbol{w}_1(5)$，$\boldsymbol{w}_2^*=\boldsymbol{w}_2(5)$，$\boldsymbol{w}_3^*=\boldsymbol{w}_3(5)$，同时可得 3 个判别函数：

$$d_1(\boldsymbol{x})=-2\boldsymbol{x}_2$$

$$d_2(\boldsymbol{x})=2\boldsymbol{x}_1-2$$

$$d_3(\boldsymbol{x})=-2\boldsymbol{x}_1-2$$

3.6 一般情况下的判别函数权矢量算法

由 3.5 节中准则函数的结构及其解法容易知道，该节的算法只适用于线性可分的情况，因它们本质上都是误差校正方法，有分类错误就要校正；如果训练模式集是非线性可分的，分类过程将不会收敛，迭代运算永远进行下去，尤其是固定增量法。然而在实际问题中，往往无法事先知道模式集能否线性可分。下面提供的几种算法既适用于线性可分情况，又适用于非线性可分情况。其中一些算法是，如果训练模式集是线性可分的，所求得解矢量对所有模式都能正确分类；如果是非线性可分的，所求的解矢量往往使错分模式数目最少或可以接受，如 H－K 算法，共轭梯度法。而另一些算法则对于两种情况都能达到较好的折中，对训练模式集是线性可分情况虽然不能肯定得到解矢量，但分类效果也较好，如 W－H 算法。实际上，对训练模式集可以达到理想分类效果的解矢量，未必对测试模式也能正确分类。如果已知应用 3.5 节中的算法所求得的解矢量造成的误判率很小也可以用。

对于两类问题，设 $n+1$ 维增广训练模式 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 已符号规范化，如果训练模式是线性可分的，则存在权矢量 $\boldsymbol{w}$ 使不等式组

$$\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i>0 \quad (i=1,2,\cdots,N) \qquad (3-6-1)$$

成立，即不等式组是一致的，有解。若训练模式是非线性可分的，表明不存在 w 对所有的训练模式都能正确分类，也就是说，无论任何的权矢量 w，都有某些模式被错分，不等式不能都成立，即不等式组是不一致的，不等式组没解。因此在这种情况下，我们希望所求得的权矢量使尽可能多的不等式被满足，等价地说，使最少的训练模式被错分。

将上面的不等式组写成矩阵方程形式，为使解可靠，引入 N 维余量矢量 $\boldsymbol{b}>\boldsymbol{0}$，于是不等式方程组变为

$$\boldsymbol{Xw}\geqslant\boldsymbol{b}>\boldsymbol{0} \tag{3-6-2}$$

式中：$\boldsymbol{X}$ 为 $N\times(n+1)$ 矩阵

$$\boldsymbol{X}=\begin{pmatrix}\boldsymbol{x}_1^{\mathrm{T}}\\ \boldsymbol{x}_2^{\mathrm{T}}\\ \vdots\\ \boldsymbol{x}_N^{\mathrm{T}}\end{pmatrix}=(\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N)^{\mathrm{T}}$$

3.6.1 分段二次准则函数及共轭梯度法

由上式可写出分段二次准则函数

$$J(\boldsymbol{w})=\|(\boldsymbol{Xw}-\boldsymbol{b})-|\boldsymbol{Xw}-\boldsymbol{b}|\|^2\Rightarrow\min \tag{3-6-3}$$

显然，如果 $\boldsymbol{Xw}\geqslant\boldsymbol{b}$，则 $\boldsymbol{Xw}-\boldsymbol{b}$ 的各分量与 $|\boldsymbol{Xw}-\boldsymbol{b}|$ 的各分量相等，因此 $J(\boldsymbol{w})=0$；如果有某些 $\boldsymbol{x}_i$ 不满足 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i\geqslant b_i$，则分量 $(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i-b_i)$ 和 $|\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i-b_i|$ 异号，因此 $J(\boldsymbol{w})>0$。使 $J(\boldsymbol{w})$ 取最小值的最优解 $\boldsymbol{w}^*$，在训练模式线性可分情况下，即不等式组一致条件下，使 $J(\boldsymbol{w}^*)=0$，此表明 $\boldsymbol{w}^*$ 构造的判别函数已对所有模式均能正确分类；在训练模式非线性可分的情况下，$J(\boldsymbol{w}^*)>0$，但 $\boldsymbol{w}^*$ 往往使误分模式数最少。由于 $J(\boldsymbol{w})$ 是一个和式，一般讲算法是收敛的。

下面采用共轭梯度法求解二次准则函数的极小化。设 $\boldsymbol{Q}$ 是 $n\times n$ 对称阵，如果有两个 n 维矢量 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 使 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Qy}=0$ 成立，即 $\boldsymbol{x}$ 与 $\boldsymbol{Qy}$ 正交，则称 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 关于 $\boldsymbol{Q}$ 互为共轭。显然，两矢量正交是矢量互为共轭的特例，此时 $\boldsymbol{Q}=\boldsymbol{I}$。对称正定阵相应于不同特征值的两个特征矢量对该矩

阵是互为共轭的。设 x 和 y 是对称正定阵 Q 的不同特征值对应的两个特征矢量，λ 是相对 y 的特征值，由线性代数知，由于 x 与 y 正交，有

$$x^{\mathrm{T}}Qy = x^{\mathrm{T}}(\lambda y) = \lambda x^{\mathrm{T}}y = 0 \qquad (3-6-4)$$

共轭梯度法是在迭代过程中沿梯度的共轭方向搜索，求得一序列 $w_0, w_1, \cdots, w^*$，使 $J(w_0) \geqslant J(w_1) \geqslant \cdots \geqslant J(w^*)$。共轭梯度法对二次函数 $J(w)$ 是非常有效的，最多用 w 维数 $(n+1)$ 步就可以使 $\{w_k\}$ 收敛于 $J(w)$ 的极小值解 w^*。对于其他类型的函数，由于极值点附近都可以用二次函数近似，因此也是有效的，但迭代的步数可能要多于 $n+1$。令 s_k 为寻求 $J(w)$ 极小值点的搜索方向，一般函数的共轭梯度法的基本公式为

$$\begin{aligned}
&g_k = -\nabla J(w_k)\\
&s_0 = g_0\\
&s_{k+1} = g_{k+1} + \beta_k s_k\\
&\beta_k = \frac{g_{k+1}^{\mathrm{T}} g_{k+1}}{g_k^{\mathrm{T}} g_k} = \frac{\| g_{k+1} \|^2}{\| g_k \|^2}\\
&w_{k+1} = w_k + \nu_k s_k\\
&\nu_k : J(w_k + \nu_k s_k) = \min_{\nu} J(w_k + \nu s_k)
\end{aligned} \qquad (3-6-5)$$

在共轭梯度法迭代过程中的任意点 w_k 处，$J(w_k)$ 的负梯度可表示为

$$g_k = -\frac{1}{4}\nabla J(w_k) = X^{\mathrm{T}}[\,|Xw_k - b| - (Xw_k - b)\,] \qquad (3-6-6)$$

为算法实现方便，令

$$\lambda_k = \frac{1}{\| g_k \|^2}$$

用 k 表示迭代次数，用 γ 表示不等式成立的数目，算法步骤如下：

(1) 置 $k=0$，任取一初始权矢量 w_0，计算 Xw_0，由此求得 γ_0。如果 $0 < \gamma_0 < \frac{N}{2}$，则令 $w_0 = -w_0$，$Xw_0 = -Xw_0$，$\gamma_0 = N - \gamma_0$，然后继续。

(2)如果 $\gamma_k = N$,则令 $\boldsymbol{w}^* = \boldsymbol{w}_k$,停止;如果 $\gamma_0 = 0$,则令 $\boldsymbol{w}^* = -\boldsymbol{w}_k$,停止;否则继续。

(3)计算 $\boldsymbol{g}_k$,如果 $\boldsymbol{g}_k = \boldsymbol{0}$,则停止;否则,计算 λ_k,然后继续。

(4)如果 k 为零或为增广模式维数$(n+1)$整数倍,则令 $\theta_k = 0$;否则,令 $\theta_k = 1$。计算 $\boldsymbol{s}_k = \theta_k \boldsymbol{s}_{k-1} + \lambda_k \boldsymbol{g}_k$,这里 $\boldsymbol{s}_k$ 表示第 k 步搜索的方向,$\boldsymbol{s}_0 = \boldsymbol{g}_0, \boldsymbol{s}_1, \boldsymbol{s}_2, \cdots$是互为共轭的。

(5)计算最佳步长 ν_k,即计算使 $J(\boldsymbol{w}_k + \nu \boldsymbol{s}_k) = \min$ 时的 ν。

(6)令 $\boldsymbol{w}_{k+1} = \boldsymbol{w}_k + \nu_k \boldsymbol{s}_k$,$\boldsymbol{X}\boldsymbol{w}_{k+1} = \boldsymbol{X}\boldsymbol{w}_k + \nu_k \boldsymbol{X}\boldsymbol{s}_k$,并求出 γ_{k+1}。

(7)令 $k = k+1$,转至(2)。

运用上述算法时,在线性可分的情况下,即方程组一致时,上述算法可以在有限步内使序列$\{\boldsymbol{w}_k\}$收敛于最优解 $\boldsymbol{w}^*$;而在非线性可分条件下,即方程组不是一致的条件下,只要适当选择 $\boldsymbol{b}$,使在 $J(\boldsymbol{w})$ 的唯一极小点 $\boldsymbol{w}^*$ 上有 $\boldsymbol{w}^{*\mathrm{T}}\boldsymbol{x}_i \neq b_i (i = 1, 2, \cdots, N)$,则算法产生的序列也在有限步内收敛于 $\boldsymbol{w}^*$。

3.6.2 最小平方误差准则及 W-H 算法

前面针对不等式方程组(3-6-2)建立了二次准则函数,适当选择 $\boldsymbol{b}$,也可以针对等式方程组

$$\boldsymbol{X}\boldsymbol{w} = \boldsymbol{b} \tag{3-6-7}$$

建立二次准则函数。若 $\boldsymbol{X}$ 有逆,由上式可得 $\boldsymbol{w} = \boldsymbol{X}^{-1}\boldsymbol{b}$。但通常运用最优化技术求解权矢量 $\boldsymbol{w}$。基于方程组(3-6-7),构造平方误差准则函数

$$\begin{aligned} J(\boldsymbol{w}) &= (\boldsymbol{X}\boldsymbol{w} - \boldsymbol{b})^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{b}) \\ &= \sum_{i=1}^{N} (\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i - b_i)^2 \Rightarrow \min \end{aligned} \tag{3-6-8}$$

显然,若 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i = b_i (i = 1, 2, \cdots, N)$,那么此时的 $J = \min J(\boldsymbol{w}) = 0$;若某些 $\boldsymbol{x}_i$ 有 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i \neq b_i$,则 $J(\boldsymbol{w}) > 0$。当 $\boldsymbol{b}$ 给定后,可以采用最优化技术搜索 $J(\boldsymbol{w})$ 极小值点以求解等式方程组(3-6-7)。如果方程组有唯一解,极小值点即是该解,说明训练模式集是线性可分的;如果方程组无解,极小值点是最小二乘解。由于式(3-6-8)中的各项取平方,反映模式在界面那一侧的正负信息丢失了,上述准则实际上是将各模式到界

面的距离平方和最小化，即使训练模式线性可分，该算法也不能保证所求得的权矢量对所有模式都能正确分类，以及误分模式个数最少。

1. 伪逆法

求 $J(\boldsymbol{w})$ 对 $\boldsymbol{w}$ 的梯度并令其为零，有

$$\nabla J(\boldsymbol{w}) = 2\boldsymbol{X}^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{b}) = \boldsymbol{0}$$

可得

$$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}\boldsymbol{w} = \boldsymbol{X}^{\mathrm{T}}\boldsymbol{b} \tag{3-6-9}$$

当 $(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}$ 存在时

$$\boldsymbol{w} = (\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{b} \triangleq \boldsymbol{X}^{+}\boldsymbol{b}$$

式中：$\boldsymbol{X}^{+} = (\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}$ 称为 $\boldsymbol{X}$ 的伪逆（有的书称为广义逆或 M－P 逆）；$\boldsymbol{w} = \boldsymbol{X}^{+}\boldsymbol{b}$ 称为 $\boldsymbol{w}$ 的伪逆解或 MSE 解。$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}$ 是 $(n+1)\times(n+1)$ 矩阵，一般是非奇异的。当 $(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}$ 不存在时，可用广义逆法解 $\boldsymbol{w} = (\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{+}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{b}$，这里 $(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{+}$ 为 $\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}$ 的广义逆矩阵。求矩阵的广义逆计算量较大，引入的误差也可能很大，在实际中多采用下面的梯度法。

2. 梯度法

由前述知，$J(\boldsymbol{w})$ 的梯度为

$$\nabla J(\boldsymbol{w}) = 2\boldsymbol{X}^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{b})$$

梯度下降算法迭代公式为

(1) $\boldsymbol{w}(1)$ 任取。

(2) $\boldsymbol{w}(k+1) = \boldsymbol{w}(k) - \rho_k\boldsymbol{X}^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w}(k) - \boldsymbol{b})$ (3-6-10)

可以证明，当 $\rho_k = \rho_1/k$（ρ_1 为任意正的常数），则该算法使权矢量序列 $\{\boldsymbol{w}(k)\}$ 收敛于 $\boldsymbol{w}^*$，满足

$$\nabla J(\boldsymbol{w}^*) = 0$$

$\boldsymbol{w}^*$ 也称为 MSE 解。该算法只计算 $(n+1)\times(n+1)$ 方阵 $\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}$，比 $(n+1)\times N$ 阵 $(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}$ 的计算量要小得多。

为了减少计算量和存储量，由于 $\boldsymbol{X}^{\mathrm{T}}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{b}) = \sum_{k=1}^{N}(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_k - \boldsymbol{b}_k)\boldsymbol{x}_k$，仿前采用单样本修正法，则式(3-6-10)可以修改为

(1) $\boldsymbol{w}(1)$ 任取。

(2) $\boldsymbol{w}(k+1)=\boldsymbol{w}(k)+\rho_k(b_k-\boldsymbol{w}(k)^{\mathrm{T}}\boldsymbol{x}_k)\boldsymbol{x}_k$ (3-6-11)

此算法通常称为 W-H(Widrow-Hoff)算法。

3.6.3 H-K(Ho-Kashyap)算法

在前述的有关算法中,余量矢量 $\boldsymbol{b}$ 是取定的常矢量,显然,使用那些算法所求得的解 $\boldsymbol{w}$ 受 $\boldsymbol{b}$ 选取的影响。如果 $\boldsymbol{b}$ 的某些分量取得不当,所求得的 $\boldsymbol{w}$ 可能不稳健,另外,$\boldsymbol{b}$ 的各分量选取不当也会影响收敛速度。H-K 算法是针对前述一些算法不足的改进。

H-K 算法仍然使用最小平方误差准则

$$J(\boldsymbol{X},\boldsymbol{w},\boldsymbol{b})=\|\boldsymbol{Xw}-\boldsymbol{b}\|^2=\sum_{i=1}^{N}(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i-b_i)^2\Rightarrow\min \tag{3-6-12}$$

这种算法是将准则函数 $J(\cdot)$ 视作矢量 $\boldsymbol{w}$ 和 $\boldsymbol{b}$ 的函数,在迭代过程中修正 $\boldsymbol{w}$ 的同时,也对 $\boldsymbol{b}$ 进行调整,运用最优化技术求得使准则函数 J 取极小值的 $\boldsymbol{w}^*$ 和 $\boldsymbol{b}^*$。如果训练模式集是线性可分的,该算法所求得解矢量 $\boldsymbol{w}^*$ 对所有模式都能正确分类,且可使 $J(\cdot)=0$。在迭代调整过程中,应满足 $\boldsymbol{b}$ 的各分量均为正值的约束,同时也为了使 $\{\boldsymbol{w}\}$ 更趋向解区的中心,$\boldsymbol{b}(k)$ 的调整矢量 $\boldsymbol{\beta}(k)$ 的各分量也为非负值,以使 $\boldsymbol{b}(k)$ 的各分量只能向增大的方向调整。仍采用梯度下降法。易知

$$\nabla_b J(\cdot)=-2(\boldsymbol{Xw}-\boldsymbol{b})$$

$\boldsymbol{b}(k)$ 的迭代公式为

$$\boldsymbol{b}(k+1)=\boldsymbol{b}(k)-\rho\nabla_b J(\cdot)\equiv\boldsymbol{b}(k)+\boldsymbol{\beta}(k) \tag{3-6-13}$$

$$(0\leqslant\rho<1)$$

调整规则是

若 $\boldsymbol{Xw}(k)-\boldsymbol{b}(k)\leqslant\boldsymbol{0}$,则 $\boldsymbol{\beta}(k)=\boldsymbol{0}$;

若 $\boldsymbol{Xw}(k)-\boldsymbol{b}(k)>\boldsymbol{0}$,则 $\boldsymbol{\beta}(k)=-\rho\left(\dfrac{\partial J}{\partial b}\right)_{b=b(k)}=2\rho[\boldsymbol{Xw}(k)-\boldsymbol{b}(k)]$;

若 $\boldsymbol{Xw}(k)-\boldsymbol{b}(k)$ 仅某些分量为正值,则只增大与这些正分量对应的 $\boldsymbol{b}$ 的分量。

记误差矢量

$$\boldsymbol{e}(k)=\boldsymbol{X}\boldsymbol{w}(k)-\boldsymbol{b}(k) \tag{3-6-14}$$

于是上面 $\boldsymbol{b}(k)$ 的 3 条调整规则中的 $\boldsymbol{\beta}(k)$ 可统一写成

$$\boldsymbol{\beta}(k)=\rho[\boldsymbol{e}(k)+|\boldsymbol{e}(k)|] \tag{3-6-15}$$

由伪逆法知道

$$\boldsymbol{w}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{b}\equiv\boldsymbol{X}^{+}\boldsymbol{b} \tag{3-6-16}$$

从而有关于 $\boldsymbol{w}$ 的迭代公式

$$\begin{aligned}\boldsymbol{w}(k+1)&=\boldsymbol{X}^{+}\boldsymbol{b}(k+1)=\boldsymbol{X}^{+}\boldsymbol{b}(k)+\boldsymbol{X}^{+}\boldsymbol{\beta}(k)\\&=\boldsymbol{w}(k)+\boldsymbol{X}^{+}\boldsymbol{\beta}(k)\end{aligned} \tag{3-6-17}$$

在介绍了算法的基本原理之后，下面给出算法步骤：

(1)由训练模式集 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 构造矩阵 $\boldsymbol{X}=(\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N)^{\mathrm{T}}$，求伪逆 $\boldsymbol{X}^{+}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}$。

(2)赋 $\boldsymbol{b}(0)$ 初值，应使 $\boldsymbol{b}$ 的各分量为正值，选取正的常数 $\rho(\rho<1)$，置步数 $k=0$。

(3)计算：$\boldsymbol{w}(k)=\boldsymbol{X}^{+}\boldsymbol{b}(k)$，$\boldsymbol{e}(k)=\boldsymbol{X}\boldsymbol{w}(k)-\boldsymbol{b}(k)$。

(4)判断：若 $\boldsymbol{e}(k)\lesssim\boldsymbol{0}$ 继续下步(5)；

若 $\boldsymbol{e}(k)=\boldsymbol{0}$，停止，得 $\boldsymbol{w}^{*}$；

若 $\boldsymbol{e}(k)$ 的负的分量停止变为正值或各分量均为负值，停止。

(5)计算 $\boldsymbol{b}(k+1)=\boldsymbol{b}(k)+\rho[\boldsymbol{e}(k)+|\boldsymbol{e}(k)|]$，$w(k+1)=X^{+}b(k+1)$

(6)令 $k=k+1$，返至(3)。

在上述步骤中，若 $\boldsymbol{e}(k)\lesssim\boldsymbol{0}$，表示 $\boldsymbol{e}$ 至少有一个分量是正的，其他分量非负，说明 $\boldsymbol{X}\boldsymbol{w}(k)-\boldsymbol{b}(k)>\boldsymbol{0}$，方程组有解，继续迭代，$\boldsymbol{b}$ 的相应分量可调整得再大一些，使 $\boldsymbol{e}(k)\to\boldsymbol{0}$。若 $\boldsymbol{e}(k)=\boldsymbol{0}$，说明 $\boldsymbol{X}\boldsymbol{w}(k)-\boldsymbol{b}(k)=\boldsymbol{0}$，方程组有解，过程已收敛。上述两种情况均说明线性可分。若 $\boldsymbol{e}(k)$ 的各分量均非正，则有 $\boldsymbol{\beta}(k)=\boldsymbol{0}$，由(5)知，$\boldsymbol{w}(k+1)=\boldsymbol{w}(k)$，$\boldsymbol{b}(k+1)=\boldsymbol{b}(k)$，$\boldsymbol{w}(k+1)$、$\boldsymbol{b}(k+1)$ 不再发生变化，从而停止，表明非线性可分。在模式集非线性可分的情况下，$\boldsymbol{\beta}(k)$ 不一定为零矢，此时 $\{\|\boldsymbol{e}(k)\|^{2}\}$ 仍然收敛，只是不收敛于 $\boldsymbol{0}$。

$H-K$ 算法在迭代过程中已设置检查误差矢量 $e(k)$ 步骤，监测有关的量，及早采取相应措施，如得解，退出迭代等。

参考文献[1]证明了 H－K 算法的收敛性。

[例 3.6.1] 已知训练模式分布如图 3.6.1 所示，其中 $(0,0)^{T}$、$(0,1)^{T}$ 属于 ω_1 类，$(1,0)^{T}$、$(1,1)^{T}$ 属于 ω_2 类，试用 H－K 算法进行分类器训练。

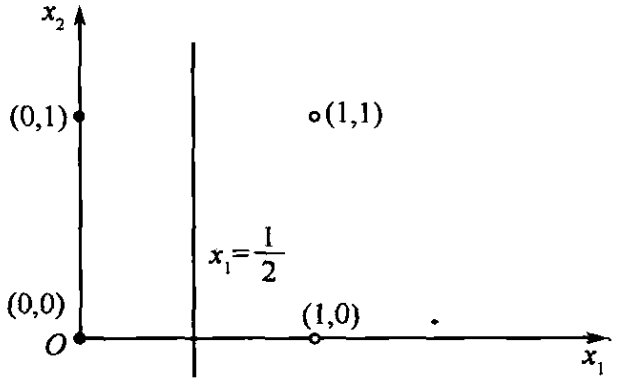


图 3.6.1　例题图示

解：

模式的增广矩阵 $\boldsymbol{X}$ 为

$$\boldsymbol{X}=\begin{pmatrix}0 & 0 & 1\\ 0 & 1 & 1\\ -1 & 0 & -1\\ -1 & -1 & -1\end{pmatrix}$$

则伪逆

$$\boldsymbol{X}^{+}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}=\frac{1}{2}\begin{pmatrix}-1 & -1 & -1 & -1\\ -1 & 1 & 1 & -1\\ 3/2 & 1/2 & -1/2 & 1/2\end{pmatrix}$$

取余量矢量 $\boldsymbol{b}(0)=(1,1,1,1)^{\mathrm{T}}$，常数 $\rho=1$，由算法可知

$$\boldsymbol{w}(0)=\boldsymbol{X}^{+}\boldsymbol{b}(0)=(-2,0,1)^{\mathrm{T}}$$

$$\boldsymbol{e}(0)=\boldsymbol{X}\boldsymbol{w}(0)-\boldsymbol{b}(0)=(1,1,1,1)^{\mathrm{T}}-\boldsymbol{b}(0)=(0,0,0,0)^{\mathrm{T}}$$

所以 $\boldsymbol{w}(0)$ 就是所求的解 $\boldsymbol{w}^{*}$，从而可得 $d(\boldsymbol{x})=-2x_1+1$。

3.7 广义线性判别函数

首先考虑一个简单的两类问题的例子，设一维两类模式 x 在一维空间——坐标轴上分布如图 3.7.1 所示，两类的类域为 $\Omega_1:(-\infty,a)$ 和 (b,∞)，$\Omega_2:(a,b)$。显然，这两类不是线性可分的，因不能用一个分界点将两类分开。但是，对于一条穿过 a、b 两点的二次曲线 $d(x)=(x-a)(x-b)=x^2-(a+b)x+ab$，当 $x\in\omega_1$，即 $x<a$ 或 $x>b$ 时，$d(x)>0$；当 $x\in\omega_2$，即 $a<x<b$ 时，$d(x)<0$。如果作非线性变换：$y_1=x^2$，$y_2=x$，则原来的一维特征空间映射为二维特征空间，二次判别函数 $d(x)$ 变换后在二维特征空间中映射成一次判别函数 $d(y)=y_1-(a+b)y_2+ab$，原来的一维非线性可分的模式在所映射的二维特征空间中是线性可分的，即 $y\in\omega_1$，则 $d(y)>0$，而 $y\in\omega_2$，则 $d(y)<0$。这实际上通过非线性变换：$y_1=x^2$，$y_2=x$，$y_3=1$，原来的一条直线映射成三维空间 $R^3=\{y_1,y_2,y_3\}$ 中的一条抛物线。我们可以将这类方法一般化。设 n 维模式特征矢量集 $\{\boldsymbol{x}_i\}$ 在特征空间 X^n 中是非线性可分的，对各模式 $\boldsymbol{x}$ 作非线性变换 $T:X^n\Rightarrow Y^d$，$d>n$，$\boldsymbol{x}=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}$，$\boldsymbol{y}=(y_1,y_2,\cdots,y_d)^{\mathrm{T}}$，其中 $y_i=f_i(\boldsymbol{x})$ 是 $\boldsymbol{x}$ 单值实函数，选取适当的函数 $f_i(\boldsymbol{x})(i=1,2,\cdots,d)$，使 $\{\boldsymbol{y}_j=(f_1(\boldsymbol{x}_j),f_2(\boldsymbol{x}_j),\cdots,f_d(\boldsymbol{x}_j))^{\mathrm{T}}\}$ 在特征空间 Y^d 中是线性可分的，即分类界面是线性的。这样，在原始特征空间中的非线性判别函数在变换特征空间中就成为线性判别函数，称其为广义线性判别函数。

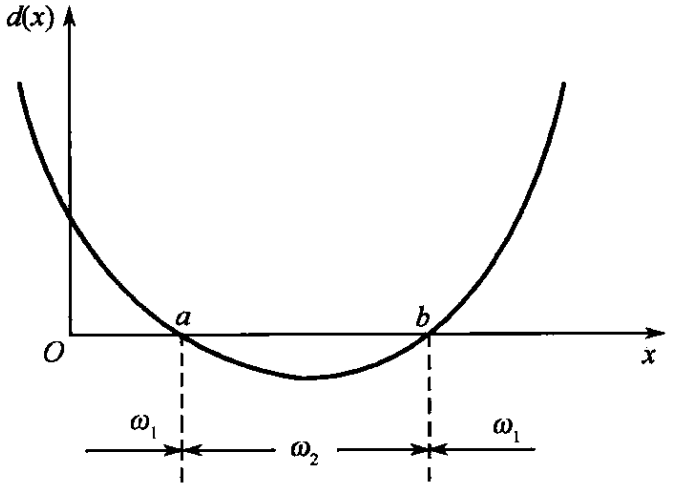


图 3.7.1　一维非线性可分模式高维映射后成线性可分

可以将 X^n 中非线性判别函数 $d(\boldsymbol{x})$ 的一般形式和 Y^d 中相应的线性判别函数 $\tilde{d}(\boldsymbol{y})$ 的关系表示如下：

$$\begin{aligned} d(\boldsymbol{x}) &= w_1 f_1(\boldsymbol{x}) + w_2 f_2(\boldsymbol{x}) + \cdots + w_d f_d(\boldsymbol{x}) + w_{d+1} \\ &= w_1 y_1 + w_2 y_2 + \cdots + w_d y_d + w_{d+1} \triangleq \boldsymbol{w}^{\mathrm{T}} \boldsymbol{y} \triangleq \tilde{d}(\boldsymbol{y}) \end{aligned} \tag{3-7-1}$$

式中：

$$\boldsymbol{w} = (w_1, w_2, \cdots, w_{d+1})^{\mathrm{T}}$$

$$\boldsymbol{y} = (y_1, y_2, \cdots, y_d, 1)^{\mathrm{T}} = (f_1(\boldsymbol{x}), f_2(\boldsymbol{x}), \cdots, f_d(\boldsymbol{x}), 1)^{\mathrm{T}}$$

$y_i = f_i(\boldsymbol{x})\ (i = 1, 2, \cdots, d)$ 是 $\boldsymbol{x}$ 的单值实函数。

显然，在原始特征空间中线性判别函数实际上是广义线性判别函数在 $y_i = f_i(\boldsymbol{x}) = \boldsymbol{x}_i\ (i = 1, 2, \cdots, n)$ 下的特例。由于相当多的实际问题不是线性可分的，任何非线性判别函数总可以变换成广义线性判别函数，而线性判别技术已有了较全面的理论和方法，因此，研究广义线性判别函数具有重要的意义。

下面针对 $f_i(\boldsymbol{x})$ 的几种典型形式进行讨论。

1. d(x)为二次多项式

此时，$d(\boldsymbol{x})$ 的一般形式是

$$d(\boldsymbol{x}) = \sum_{i=1}^{n} w_{ii} x_i^2 + \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} w_{ij} x_i x_j + \sum_{i=1}^{n} w_i x_i + w_{n+1} \tag{3-7-2}$$

取 $y_i = f_i(\boldsymbol{x})$ 为二次或一次式，可使 $d(\boldsymbol{y})$ 为线性函数。上式右边前两项是 $\boldsymbol{x}$ 各分量的二次项求和式，显然它们的项数分别为 n 和 $n(n-1)/2$，第三项是 $\boldsymbol{x}$ 的各分量一次项求和式，项数为 n，所以 $d(\boldsymbol{x})$ 的项数为 $n + n(n-1)/2 + n + 1 = n(n+3)/2 + 1 = (n+1)(n+2)/2$，由于有一个常数项，变换后的特征空间维数为 $[(n+1)(n+2)/2] - 1 = n(n+3)/2$。

2. d(x)为 r 次多项式

此时，非线性判别函数 $d(\boldsymbol{x})$ 的一般形式如下：

$$d(\boldsymbol{x}) = d^r(\boldsymbol{x}) + d^{r-1}(\boldsymbol{x}) + \cdots + d^1(\boldsymbol{x}) + d^0(\boldsymbol{x}) \triangleq d^{(r)}(\boldsymbol{x}) \tag{3-7-3}$$

式中：

$$d^0(\boldsymbol{x}) = w_{n+1}$$

$$d^1(\boldsymbol{x}) = \sum_{i=1}^{n} w_i x_i$$

$$d^2(\boldsymbol{x}) = \sum_{i_1=1}^{n} \sum_{i_2=i_1}^{n} w_{i_1 i_2} x_{i_1} x_{i_2}$$

……

$$d^r(\boldsymbol{x}) = \sum_{i_1=1}^{n} \sum_{i_2=i_1}^{n} \cdots \sum_{i_r=i_{r-1}}^{n} w_{i_1 i_2 \cdots i_r} x_{i_1} x_{i_2} \cdots x_{i_r}$$

显然 $d(\boldsymbol{x})$ 可以表示为递推形式

$$\begin{aligned} d^{(0)}(\boldsymbol{x}) &= w_{n+1} \\ d^{(r)}(\boldsymbol{x}) &= d^r(\boldsymbol{x}) + d^{(r-1)}(\boldsymbol{x}) \end{aligned} \tag{3-7-4}$$

从 n 个不同的元素中每次取出 k 个元素，允许重复合成一组，其组合数为 C_{n+k-1}^k，而 $\sum_{k=1}^{r} C_{n+k-1}^k = \frac{(n+r)!}{n!r!} - 1$。因 $\boldsymbol{x}$ 为 n 维矢量，注意到还有一个常数项，所以 $d^{(r)}(\boldsymbol{x})$ 的项数为 $(n+r)!\ /n!\ r!$。在这种情况下有 $f_i(\boldsymbol{x}) = \boldsymbol{x}_1^{s1}\boldsymbol{x}_2^{s2}\cdots\boldsymbol{x}_n^{sn}, s_1 + s_2 + \cdots + s_n \leqslant r$。容易知道，在进行变换时，线性判别函数 $d(\boldsymbol{y})$ 的项数与非线性判别函数 $d(\boldsymbol{x})$ 的项数相同，所以 $\boldsymbol{y}$ 的维数 $d = (n+r)!\ /n!\ r!\ -1$。例如当 $n=2, r=2$ 时，$d=5$。下面讨论广义线性判别函数的二分能力。在由非线性判别函数 $d(\boldsymbol{x})$ 变换成线性判别函数 $d(\boldsymbol{y})$ 后，特征空间的维数由原来的 n 维增长到 d 维（$d > n$），所以二分能力增大了。例如二次广义线性函数在变换前特征空间维数 $n=2$，变换后特征空间维数 $d=5$，当模式数 $N=10$ 时，变换前二分能力 $D(n,N)=92, N_{0.5}=6$，变换后的二分能力 $D(d,N)=764, N_{0.5}=12$。

对于一般的二次多项式判别函数，它可以表示为

$$d(\boldsymbol{x}) = \boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}^{\mathrm{T}}\boldsymbol{x} + c \tag{3-7-5}$$

式中：$\boldsymbol{A} = (a_{ij})_{n\times n}$ 为实对称矩阵，$\boldsymbol{b} = (b_1, b_2, \cdots b_n)^{\mathrm{T}}$，$c$ 为常数，上式中

的各元素与一般形式广义线性判别函数的各项系数的关系是

$$w_{d+1}=c$$

$$w_i=b_i \quad (i=1,2,\cdots,n)$$

$$w_{ij}=2a_{ij} \quad (i=1,2,\cdots,n-1;j=i,i+1,\cdots,n)$$

$$w_{ii}=a_{ii} \quad (i=1,2,\cdots,n)$$

如果 $\boldsymbol{A}$ 是单位矩阵，由于 $a_{ii}=1, a_{ij}=0(i\neq j)$，此时 $d(\boldsymbol{x})=0$ 表示一超球面，作变换后，特征空间维数由 n 维增大到 $d=2n$ 维，$N_{0.5}=2(d+1)=2(2n+1)$。当 $d(\boldsymbol{x})$ 为一般的二次多项式时，$d(\boldsymbol{x})$ 变换成线性判别函数 $d(\boldsymbol{y})$ 后，$\boldsymbol{y}$ 的维数 $d=\frac{1}{2}n(n+3)$，$N_{0.5}=(n+1)(n+2)$。此时 $N_{0.5}$ 称为超二次曲面的容量。对于一般的 n 维 r 次多项式的非线性判别函数，因转变为 d 维线性判别函数 $d(\boldsymbol{y})$ 后，$\boldsymbol{y}$ 的维数 $d=\frac{(n+r)!}{n!\ r!}-1$，$N_{0.5}=2(d+1)=2\frac{(n+r)!}{n!\ r!}$。类似地，$N_{0.5}=2(n+r)!/n!\ r!$ 称为 n 维 r 次超曲面容量。

3.8 二次判别函数

二次判别函数是一种常用的非线性判别函数，函数构造比较简单，适用面比线性判别函数要广，例如当两类都是正态分布时，若它们的协方差阵 $\boldsymbol{\Sigma}_1\neq\boldsymbol{\Sigma}_2$，则由贝叶斯决策导出的判决函数就是二次超曲面。

在 n 维特征空间中，二次判别函数的一般表示式为

$$d(\boldsymbol{x})=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{W}\boldsymbol{x}+\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+w_{n+1} \qquad (3-8-1)$$

式中：$\boldsymbol{W}$ 为 $n\times n$ 实对称阵；$\boldsymbol{w}$ 为 n 维矢量；w_{n+1} 为一标量。

在实际中，要确定式(3-8-1)就需要确定 $n(n+3)/2+1$ 个系数，因此计算较复杂，但由于参数多，也提供了较大的灵活性。二次判别函数确定的界面是一个超二次曲面，它可能是超球面、超椭球面、超双曲面等。

将坐标平移公式 $\boldsymbol{x}=\boldsymbol{y}-\boldsymbol{b}$ 代入式(3-8-1)中，并令一次项为零，

可得 $\boldsymbol{b}=\frac{1}{2}\boldsymbol{W}^{-1}\boldsymbol{w}$，由此式(3-8-1)可以化为一个形式：

$$\tilde{d}(\boldsymbol{y})=\boldsymbol{y}^{\mathrm{T}}\boldsymbol{W}\boldsymbol{y}-\frac{1}{4}\boldsymbol{w}^{\mathrm{T}}\boldsymbol{W}^{-1}\boldsymbol{w}+w_{n+1} \tag{3-8-2}$$

从而判别界面可表示为如下二次超曲面形式

$$\boldsymbol{y}^{\mathrm{T}}\boldsymbol{W}\boldsymbol{y}=\frac{1}{4}\boldsymbol{w}^{\mathrm{T}}\boldsymbol{W}^{-1}\boldsymbol{w}-w_{n+1} \tag{3-8-3}$$

令

$$\hat{\boldsymbol{W}}=\boldsymbol{W}/(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{W}^{-1}\boldsymbol{w}-4w_{n+1}) \tag{3-8-4}$$

由式(3-8-3)可知，如果$\hat{\boldsymbol{W}}$为单位矩阵的正的倍数，那么 $d(\boldsymbol{x})=0$ 表示一超球面；如果$\hat{\boldsymbol{W}}$是正定阵，那么 $d(\boldsymbol{x})=0$ 为一超椭球面；如果$\hat{\boldsymbol{W}}$是不定阵(特征值有正有负)，则 $d(\boldsymbol{x})=0$ 为超双曲面；如果$\hat{\boldsymbol{W}}$是半正定阵，则 $d(\boldsymbol{x})=0$ 类型相对复杂一些。更细致的分类还要考查式(3-8-1)写成 $n+1$ 维矢量时的二次型的矩阵。

3.9 位势函数分类法

位势函数算法是利用物理概念，通过训练模式对特征空间中的积累位势函数修正，使积累位势函数对训练模式具有正确分类的性质，从而以其作为判别函数。由于位势函数是非线性的，所以由位势函数训练算法产生的判别函数是非线性的。该方法可用于非线性可分情况，也可用于线性可分情况。位势函数选取的灵活性使位势函数法有很强的分类能力。

3.9.1 位势函数的概念

如前所述，一个模式特征矢量对应特征空间中一个特征点，现有分属两类 ω_1 和 ω_2 的模式集$\{\boldsymbol{x}_j\}$，我们设想，每个特征点上都具有某种形式的相同的能量(如电位)，令属于 ω_1 类的模式特征点具有正的位能，于是在该点处能量达到最大值，随着与该点距离的增大，其周围空间中的能量分布逐渐减小，位能逐渐变低；令属于 ω_2 的模式特征点具有负

的位能，在该点处，位能达到负的最大值，随着与该点距离的增加，负位能逐渐升高。特征点及其周围的位能分布可以用一个位势函数 $K(\boldsymbol{x}, \boldsymbol{x}_j)$ 表示。形象地理解，当把位势函数值视作高度时，属于 ω_1 类的模式特征点较密聚的区域的位能形成“高地”，这些点所在的位置就是这些高地的“山头”；属于 ω_2 类的模式特征点较密集的区域的位能形成地平线以下的“洼地”。显然，可以将位能为零的等值面作为两类的阈值界面。

为了将上述分类思想数学化，需定义点 $\boldsymbol{x}_j$ 处的位势函数 $K(\boldsymbol{x}, \boldsymbol{x}_j)$，它应满足：

(1) $K(\boldsymbol{x}, \boldsymbol{x}_j) = K(\boldsymbol{x}_j, \boldsymbol{x})$。

(2) $K(\boldsymbol{x}, \boldsymbol{x}_j)$ 是连续光滑函数。

(3) $K(\boldsymbol{x}, \boldsymbol{x}_j)$ 是 $\boldsymbol{x}$ 与 $\boldsymbol{x}_j$ 间距离的单值单调下降函数。当且仅当 $\boldsymbol{x} = \boldsymbol{x}_j$ 时，$K(\boldsymbol{x}, \boldsymbol{x}_j)$ 达到最大值。当 $\boldsymbol{x}$ 与 $\boldsymbol{x}_j$ 之间的距离趋于无穷大时，$K(\boldsymbol{x}, \boldsymbol{x}_j)$ 趋于零。

所有模式特征点 $\{\boldsymbol{x}_j\}$ 的位势函数 $K(\boldsymbol{x}, \boldsymbol{x}_j)$ 在任一点 $\boldsymbol{x}$ 处之和称为积累位势函数，表示为 $K(\boldsymbol{x})$。由该定义可以知道，特征空间中的积累位势函数反映了模式特征点密集的程度，积累位势函数绝对值取最大的点附近模式最密集，因此积累位势函数可以作为模式分布的一种估计，这个观点在下一章的概率密度估计中也是有意义的。

下面介绍两类位势函数：

第一类位势函数。设 $\{\varphi_i(\boldsymbol{x}); i = 1, 2, \cdots\}$ 是 $\boldsymbol{x}$ 定义域中的完备正交函数集，位势函数取为

$$K(\boldsymbol{x}, \boldsymbol{x}_j) = \sum_{i=1}^{m} \varphi_i(\boldsymbol{x}) \varphi_i(\boldsymbol{x}_j) \qquad (3-9-1)$$

这是对称的有限项多项式。

第二类位势函数。取关于 $\boldsymbol{x}$ 和 $\boldsymbol{x}_j$ 的距离的对称函数作位势函数，这类函数通常称为径向基函数(RBF)，例如

$$K(\boldsymbol{x}, \boldsymbol{x}_j) = \exp[-\alpha \| \boldsymbol{x} - \boldsymbol{x}_j \|^2] \qquad (3-9-2)$$

$$K(\boldsymbol{x}, \boldsymbol{x}_j) = \frac{1}{1 + \alpha \| \boldsymbol{x} - \boldsymbol{x}_j \|^2}$$

上面两式中的 α 为常数，其作用是控制位势函数衰减的速度。当类间的界面越复杂时，α 的选择应使位势函数衰减得越快。此外，我们还可以构造其他形式以距离为自变量的具有衰减性质的函数作为位势函数。

3.9.2 由位势函数产生判别函数的训练算法及分类规则

我们在上面利用位势函数的概念定义了各特征点处的位势函数及特征空间各点处的积累位势函数，下面给出产生具有分类能力的积累位势函数的算法。

设训练模式集为 $\{\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N\}$，它们分属 ω_1 和 ω_2 类。定义一个位势函数 $K(\boldsymbol{x},\boldsymbol{x}_j)$。

(1)初始化。令特征空间中各点处的初始积累位势函数 $K_0(\boldsymbol{x})=0$，判错计数 $m=0$。

(2)令 $j=1$，输入训练模式 $\boldsymbol{x}_1$，使积累位势函数

$$K_1(\boldsymbol{x})=\begin{cases}K_0(\boldsymbol{x})+K(\boldsymbol{x},\boldsymbol{x}_1)>0 & (\text{若 } \boldsymbol{x}_1\in\omega_1)\\ K_0(\boldsymbol{x})-K(\boldsymbol{x},\boldsymbol{x}_1)<0 & (\text{若 } \boldsymbol{x}_1\in\omega_2)\end{cases}$$

(3)令 $j=j+1$，输入 $\boldsymbol{x}_j$，计算积累位势函数

$$K_j(\boldsymbol{x})=K_{j-1}(\boldsymbol{x})+\alpha_j K(\boldsymbol{x},\boldsymbol{x}_j)$$

积累位势函数的调整规则为

$$\alpha_j=\begin{cases}0 & (\text{若 } \boldsymbol{x}_j\in\omega_1 \text{ 和 } K_{j-1}(\boldsymbol{x}_j)>0)\\ 0 & (\text{若 } \boldsymbol{x}_j\in\omega_2 \text{ 和 } K_{j-1}(\boldsymbol{x}_j)<0)\\ 1 & (\text{若 } \boldsymbol{x}_j\in\omega_1 \text{ 和 } K_{j-1}(\boldsymbol{x}_j)\leqslant 0)\\ -1 & (\text{若 } \boldsymbol{x}_j\in\omega_2 \text{ 和 } K_{j-1}(\boldsymbol{x}_j)\geqslant 0)\end{cases}$$

$$m=m+|\alpha_j|$$

(4)如果 $j<N$，返至(3)。如果 $j=N$，检查是否有模式判错；若 $m=0$，则结束，$d(\boldsymbol{x})=K_j(\boldsymbol{x})$；若 $m\neq 0$，令 $j=0$，$m=0$，返至(3)。

上述的算法步骤解释如下：

在(2)中,按位势函数概念,当 $x_1 \in \omega_1$ 时,$K_1(x)$ 应该为正,故令 $K_1(x) = K(x, x_1)$;当 $x_1 \in \omega_2$ 时,加负号于 $K(x, x_1)$ 以使 $K_1(x)$ 为负。在(3)中,若 $x_j \in \omega_1$,$K(x_j)$ 应该为正,但实际上若 $K(x_j)$ 为负,说明 $K(x_j)$ 位势太低,应该提高,加上 $K(x, x_j)$,以使它最终为正;若 $x_j \in \omega_2$,$K(x_j)$ 应该为负,但实际上若 $K(x_j)$ 为正,说明 $K(x_j)$ 位势太高,应该降低,减去 $K(x, x_j)$,以使它最终为负。若 $x_j \in \omega_1$ 且 $K(x_j) > 0$ 或 $x_j \in \omega_2$ 且 $K(x_j) < 0$,说明分类正确,故 $K(x)$ 不变。规定如上修正规则的目的是使积累位势函数可以作为判别函数,零位势作为阈值界面。在迭代过程中,只要有训练模式被判错,就要使用全部训练模式进行下一轮迭代,直到全轮迭代中没有模式判错为止,(4)就是执行这个任务的。

如果从所给的训练模式集 $\{x_1, x_2, \cdots, x_N\}$ 中略去不对积累位势修正的那些模式,可得一简化模式集 $\hat{X} = \{x_{i_1}, x_{i_2}, \cdots, x_{i_M}\}$ $(M < N)$,则位势函数迭代式可以归纳为

$$K_j(x) = \sum_{x_{i_j} \in \hat{X}} \alpha_j K(x, x_{i_j}) \qquad (3-9-3)$$

式中:

$$\alpha_j = \begin{cases} 1 & (\text{若 } x_{i_j} \in \omega_1) \\ -1 & (\text{若 } x_{i_j} \in \omega_2) \end{cases}$$

上式表明,积累位势等于 ω_1 类和 ω_2 类中校正积累位势的模式的总位势之差。

从上述产生积累位势函数的算法可以看出,由于当训练模式 $x \in \omega_1$ 时有 $K(x) > 0$,当训练模式 $x \in \omega_2$ 时有 $K(x) < 0$,所以积累位势函数 $K(x)$ 可以作为判别函数 $d(x)$,阈值界面为 $K(x) = 0$。当根据训练模式集按上述算法产生积累位势函数后,对于给定的待分类的模式 x,判别规则是:若 $K(x) > 0$,则判 $x \in \omega_1$;若 $K(x) < 0$,则判 $x \in \omega_2$。

[例 3.9.1] 已知两类训练样本:$x_1 = (1, 0)^T$,$x_2 = (0, -1)^T$ 属于 ω_1 类,$x_3 = (-1, 0)^T$,$x_4 = (0, 1)^T$ 属于 ω_2 类,如图 3.9.1 所示,试用势

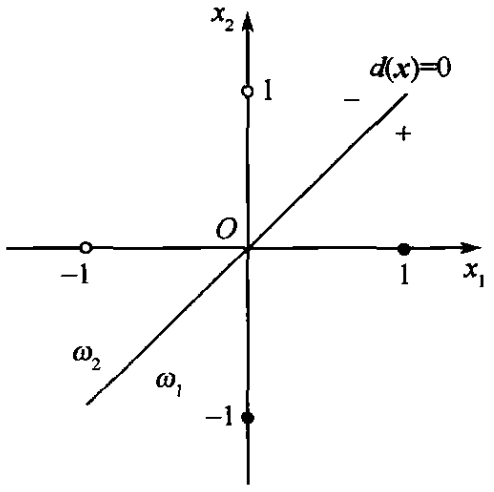


图 3.9.1　势函数法分类器训练例题

函数法进行分类器训练。

解:选用埃尔米特多项式作势函数,取前几项,即

$$H_0(x)=1, H_1(x)=2x, H_2(x)=4x^2-2, H_3(x)=8x^3-12x$$

作为正交函数集$\{\varphi_i(x)\}$组成所采用的函数。由于待分类模式为二维,需组成二维正交函数集,这可由任意两个一维正交函数形成。

$$\varphi_1(x)=\varphi_1(x_1,x_2)=H_0(x_1)H_0(x_2)=1$$

$$\varphi_2(x)=\varphi_2(x_1,x_2)=H_1(x_1)H_0(x_2)=2x_1$$

$$\varphi_3(x)=\varphi_3(x_1,x_2)=H_0(x_1)H_1(x_2)=2x_2$$

$$\varphi_4(x)=\varphi_4(x_1,x_2)=H_1(x_1)H_1(x_2)=2x_1x_2$$

于是,势函数为

$$K(x,x_j)=\sum_{i=1}^{4}\varphi_i(x)\varphi_i(x_j)=1+4x_1x_{j1}+4x_2x_{j2}+16x_1x_2x_{j1}x_{j2}$$

式中:$x=(x_1,x_2)^{\mathrm{T}}$;$x_j=(x_{j1},x_{j2})^{\mathrm{T}}$。

$K(x)$为积累位势函数,根据位势函数法的算法步骤进行迭代,即

$j=0$,令$K_0(x)=0$;

$j=1$,输入训练模式$x_j=x_1\in\omega_1$,积累位势函数为

$$K_1(x)=K(x,x_1)=1+4x_1*1+4x_2*0+16x_1x_2*1*0=1+4x_1$$

$j=2$,输入训练模式$x_j=x_2\in\omega_1$,计算得

$$K_1(x_2) = 1 + 4 * 0 = 1 > 0$$

所以，$K_2(x) = K_1(x) = 1 + 4x_1$

$j = 3$，输入训练模式 $x_j = x_3 \in \omega_2$，计算得

$$K_2(x_3) = 1 + 4 * (-1) = -3 < 0$$

所以，$K_3(x) = K_2(x) = 1 + 4x_1$

$j = 4$，输入训练模式 $x_j = x_4 \in \omega_2$，计算得

$$K_3(x_4) = 1 + 4 * 0 = 1 > 0$$

所以，$K_4(x) = K_3(x) - K(x, x_4) = (1 + 4x_1) - (1 + 4x_2)$

$$= 4x_1 - 4x_2$$

$j = 5$，输入 $x_j = x_1 \in \omega_1$，$K_4(x_1) = 4 * 1 - 4 * 0 = 4 > 0$，所以 $K_5(x) = K_4(x)$；

$j = 6$，输入 $x_j = x_2 \in \omega_1$，$K_5(x_2) = 4 * 0 - 4 * (-1) = 4 > 0$，所以 $K_6(x) = K_5(x)$；

$j = 7$，输入 $x_j = x_3 \in \omega_2$，$K_6(x_3) = 4 * (-1) - 4 * 0 = -4 < 0$，所以 $K_7(x) = K_6(x)$；

$j = 8$，输入 $x_j = x_4 \in \omega_2$，$K_7(x_4) = 4 * 0 - 4 * 1 = -4 < 0$，所以 $K_8(x) = K_7(x)$；

以上说明所有训练模式已均可被正确分类，算法已经收敛，判别函数

$$d(x) = K_4(x) = 4x_1 - 4x_2$$

令 $d(x) = 0$，可得判别界面 $x_1 = x_2$。

3.10 支持矢量机简介

我们已经了解了线性判别函数的形式、判别规则以及产生其权系数的各种算法和技巧，虽然有一些线性判别算法也可以用于非线性可分的模式集，但通常运用非线性界面进行分类效果会更好。非线性界面方法也可以看做是通过非线性变换使在变换空间中原模式集的映射点是线性可分的，并相应地使非线性判别函数成为线性判别函数。另外需要指出的是，对于训练模式集分类性能良好的分类器对工作样本

也未必能达到或接近训练时的分类性能，即所设计的分类器推广能力或普适性较差。支持矢量机是利用人们已经掌握的基本概念和技术，采用有关的数学理论和方法在原特征空间中产生线性判别函数，然后通过核函数隐式地映射到变换特征空间中，使原模式集在变换特征空间中是线性可分的，且由于隐含地利用了结构风险设计的概念，使其推广性大大增强。

为处理方便，定义样本 $\boldsymbol{x}_i$ 的类别标记 y_i，对于两类问题：

若 $\boldsymbol{x}_i \in \omega_1$，则 $y_i = 1$；

若 $\boldsymbol{x}_i \in \omega_2$，则 $y_i = -1$；

于是原来的模式集 $\{\boldsymbol{x}_i\}$ 可以表示为 $\{(\boldsymbol{x}_i, y_i)\}$。

设模式集 $\{\boldsymbol{x}_i\}$ 是线性可分的，令正确分类的界面为

$$d(\boldsymbol{x}) = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b = 0 \tag{3-10-1}$$

对判别函数 $d(\boldsymbol{x})$ 规范化，使对所有的样本都满足 $|d(\boldsymbol{x})| \geqslant 1$，即离界面最近的样本 $\boldsymbol{x}$ 有 $|d(\boldsymbol{x})| = 1$，这就要求：

若 $y_i = 1$，则 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b \geqslant 1$；

若 $y_i = -1$，则 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b \leqslant -1$；

可以将上面两式合写成

$$y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) \geqslant 1 \quad (i = 1, 2, \cdots, N) \tag{3-10-2}$$

由点面距离公式(3-3-5)：

$$d_x = \frac{|\boldsymbol{w}_0^{\mathrm{T}}\boldsymbol{x}_i + w_{n+1}|}{\|\boldsymbol{w}_0\|}$$

可知，距界面最近的两类样本它们离界面的距离为 $1/\|\boldsymbol{w}\|$，如图 3.10.1 所示。

求最优界面。在满足式(3-10-2)的条件下，所求的最优界面使 $1/\|\boldsymbol{w}\|$ 最大，这等价于使 $\|\boldsymbol{w}\|$ 最小化，其体现了 SVM 的最大间隔思想。它应满足下面的规划问题：

$$\begin{aligned} &\min \frac{\boldsymbol{w}^{\mathrm{T}}\boldsymbol{w}}{2} \\ &\text{s.t. } y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) - 1 \geqslant 0 \quad (i = 1, 2, \cdots, N) \end{aligned} \tag{3-10-3}$$

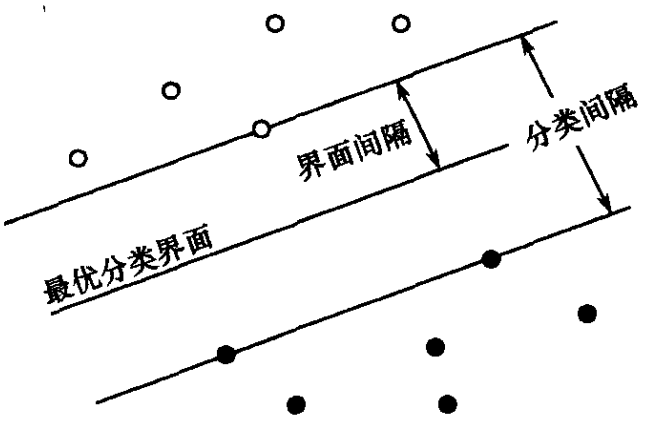


图 3.10.1　支持矢量机界面示意图

可利用拉格朗日方法求解，而拉格朗日函数定义为：

$$L(\boldsymbol{w},b,\alpha) = \boldsymbol{w}^{T}\boldsymbol{w}/2 - \sum_{i=1}^{N}\alpha_i\{y_i[(\boldsymbol{w}^{T}\boldsymbol{x}_i + b) - 1\} \tag{3-10-4}$$

其中 α_i 为与每个样本对应的拉格朗日乘数子。

将上式分别对 $\boldsymbol{w}$、b 求偏导

$$\frac{\partial L(\boldsymbol{w},b,\alpha)}{\partial \boldsymbol{w}} = \boldsymbol{0}, \quad \frac{\partial L(\boldsymbol{w},b,\alpha)}{\partial b} = 0$$

这样就把原问题转化为在

$$\sum_{i=1}^{N} y_i\alpha_i = 0 \quad (\alpha_i \geqslant 0, i = 1,2,\cdots,N) \tag{3-10-5}$$

的约束条件下，对 α_i 求解下列函数的最大值问题

$$Q(\alpha) = \sum_{i=1}^{N}\alpha_i - \frac{1}{2}\sum_{i,j=1}^{N}\alpha_i\alpha_j y_i y_j(\boldsymbol{x}_i \cdot \boldsymbol{x}_j) \tag{3-10-6}$$

若 α_i^* 为最优解，则 $\boldsymbol{w}^* = \sum_{i=1}^{N}\alpha_i^* y_i \boldsymbol{x}_i$

若该解中，只有一部分（通常是少部分）α_i 不为零，则其对应的样本就是支持矢量。可见，支持矢量本身就是支撑了最优分类面的那部分样本。

上述问题得到的最优分类函数是

$$f(\boldsymbol{x}) = \mathrm{sgn}\{(\boldsymbol{w}^* \cdot \boldsymbol{x}) + b^*\}$$

$$= \operatorname{sgn}\left\{\sum_{i=1}^{N} \alpha_i^* y_i (\boldsymbol{x}_i \cdot \boldsymbol{x}) + b^*\right\}$$

式中：b^* 是分类阈值。

在非线性可分的情况下，并不是所有样本都满足式(3－10－2)，另外，为了克服噪声影响和容忍离群点，并能顾及更多的训练样本而不是只对靠近边界的样本，可以采用软间隔方法。

可以构造简化的广义最优分类界面，求解简化广义最优分类界面是如下最小化问题。在约束

$$y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) \geqslant 1 - \xi_i \quad (i = 1,2,\cdots,N)$$

下，最小化引入了不可分类的泛函

$$f(\boldsymbol{w},\boldsymbol{\xi}) = \frac{1}{2}\boldsymbol{w}^{\mathrm{T}}\boldsymbol{w} + \gamma\sum_{i=1}^{N}\xi_i \qquad (3-10-7)$$

式中：N 为模式个数；γ 为某指定的正常数，以实现算法复杂性与错分样本数的折中，γ 的值越小，对离群点惩罚就越小，界面间隔越宽。于是上述问题成为如下规划问题。

$$\begin{cases} \min \quad \dfrac{1}{2}\boldsymbol{w}^{\mathrm{T}}\boldsymbol{w} + \gamma\sum\limits_{i=1}^{N}\xi_i \\ \text{s.t} \quad y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) - 1 + \xi_i \geqslant 0 \\ \qquad\quad \xi_i \geqslant 0 \end{cases} \quad (i = 1,2,\cdots,N)$$

$$(3-10-8)$$

利用拉格朗日乘数法，目标函数为

$$\mathrm{L}(\boldsymbol{w},b,\boldsymbol{\xi},\boldsymbol{\lambda},\boldsymbol{\beta}) = \frac{1}{2}\boldsymbol{w}^{\mathrm{T}}\boldsymbol{w} + \gamma\sum_{i=1}^{N}\xi_i - \sum_{i=1}^{N}\lambda_i[y_i(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^{N}\beta_i\xi_i$$

$$(3-10-9)$$

由极小值原则，有

$$\boldsymbol{w} = \sum_{i=1}^{N}\lambda_i y_i x_i \qquad (3-10-10)$$

$$\sum_{i=1}^{N} y_i \lambda_i = 0 \qquad (3-10-11)$$

$$\gamma - \lambda_i - \beta_i = 0 \qquad (3-10-12)$$

得到的结果与可分情况下的结果几乎是相同的，仅有的区别是式(3-10-12)。由非负性，$\beta_i \geqslant 0$，可知式(3-10-12)蕴含着

$$0 \leqslant \lambda_i \leqslant \gamma \quad (i = 1, 2, \cdots, N)$$

上式表明，γ 控制了 λ_i 的大小，因而控制了噪声和离群点的影响。

习 题

3.1 在多类情况中，如果任何标记为 ω_i 类的样本都可被一个简单的超平面分类的话，就被称为“完全线性可分”(Totally Linearly Separable)。试证明完全线性可分样本集一定是线性可分的，反之则不成立。

3.2 对于一个样本集，如果存在$\frac{c(c-1)}{2}$个超平面，每个超平面都将 ω_i 和 ω_j 的样本进行分类，这样的一个样本集被称为“成对线性可分”(Pairwise Linearly Separable)。证明成对线性可分不一定是线性可分。

3.3 矢量集 $\boldsymbol{x}_i (i = 1, 2, \cdots, N)$ 的凸包(Convex Hull)是所有形如

$$\boldsymbol{x} = \sum_{i=1}^{n} \alpha_i \boldsymbol{x}_i$$

的矢量的集合，其中系数 α_i 为非负数且和为 1。当有两个这样的集合，证明或者它们是线性可分的，或者它们的凸包是相交的(为了证明这一点，假设这两个结论都成立并考虑处于凸包的交集中的点)。

3.4 考虑一个线性判别函数 $d_i(\boldsymbol{x}) = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + w_{i0}$，证明判别区是凸的，即如果 $\boldsymbol{x}_1 \in D_i, \boldsymbol{x}_2 \in R_i$，那么 $\lambda \boldsymbol{x}_1 + (1-\lambda)\boldsymbol{x}_2 \in R_i (0 \leqslant \lambda \leqslant 1)$。

3.5 证明：当将属于 ω_1 类和 ω_2 类的样本分别放在系数矩阵的上

N_1 行和下 N_2 行，且余量矢量 $b=\left(\underbrace{\frac{N}{N_1},\cdots,\frac{N}{N_1}}_{N_1},\underbrace{\frac{N}{N_2},\cdots,\frac{N}{N_2}}_{N_2}\right)$ 时，MSE 解等价于 Fisher 解。

3.6 令 $p(\boldsymbol{x}|\omega_i)(i=1,2)$，为任意的类概率密度函数，各类均值为 $\boldsymbol{\mu}_i$，协方差矩阵为 $\boldsymbol{\Sigma}_i$，令 $y=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}$ 表示投影，并且设投影后的结果的概率密度函数为 $p(y|\omega_i)$，其均值为 μ_i，方差为 σ_i^2。

(1)证明准则函数

$$J_1(\boldsymbol{w})=\frac{(\mu_1-\mu_2)^2}{\sigma_1^2+\sigma_2^2}$$

当 $\boldsymbol{w}=(\boldsymbol{\Sigma}_1+\boldsymbol{\Sigma}_2)^{-1}(\boldsymbol{\mu}_1-\boldsymbol{\mu}_2)$ 时取得最大值。

(2)如果 $P(\omega_i)$ 为 ω_i 的先验概率，证明

$$J_2(\boldsymbol{w})=\frac{(\mu_1-\mu_2)^2}{P(\omega_1)\sigma_1^2+P(\omega_2)\sigma_2^2}$$

当 $\boldsymbol{w}=[P(\omega_1)\boldsymbol{\Sigma}_1+P(\omega_2)\boldsymbol{\Sigma}_2]^{-1}(\boldsymbol{\mu}_1-\boldsymbol{\mu}_2)$ 时取得最大值。

3.7 试证在几何上，感知准则函数正比于被错分类的样本到判别界面的距离之和。

3.8 在感知器算法的收敛证明中取尺度因子 c 为 a/b。

(1)证明如果 $c>a/(2b)$，那么需要校正的次数的最大值为

$$k_0=\frac{\|\boldsymbol{w}_1-c\boldsymbol{w}_i\|}{2cb-a}$$

(2)当 $\boldsymbol{w}_1=0$ 时，c 为何值时使得 k_0 最小？

算法编程

以下部分练习使用下表的数据：

表 3.1

样本	ω_1		ω_2		ω_3		ω_4	
	x_1	x_2	x_1	x_2	x_1	x_2	x_1	x_2
1	0.1	1.1	7.1	4.2	-3.0	-2.9	-2.0	-8.4
2	6.8	7.1	-1.4	-4.3	0.5	8.7	-8.9	0.2
3	-3.5	-4.1	4.5	0.0	2.9	2.1	-4.2	-7.7
4	2.0	2.7	6.3	1.6	-0.1	5.2	-8.5	-3.2
5	4.1	2.8	4.2	1.9	-4.0	2.2	-6.7	-4.0
6	3.1	5.0	1.4	-3.2	-1.3	3.7	-0.5	-9.2
7	-0.8	-1.3	2.4	-4.0	-3.4	6.2	-5.3	-6.7
8	0.9	1.2	2.5	-6.1	-4.1	3.4	-8.7	-6.4
9	5.0	6.4	8.4	3.7	-5.1	1.6	-7.1	-9.7
10	3.9	4.0	4.1	-2.2	1.9	5.1	-8.0	-6.3

3.1 编写梯度下降算法，并应用到 ω_1 和 ω_3 的数据上，再应用到 ω_4 和 ω_2 的数据上。(a)学习率 $\rho(k)=0.1$；(b) $\rho(k)=0.5$。

3.2 编写 H－K 算法，并自行产生数据运用 H－K 算法进行分类。

3.3 应用 H－K 算法到 ω_1 和 ω_3 的数据上。再应用到 ω_4 和 ω_2 的数据上。

3.4 编写势函数算法，并运用算法对例题数据进行分类。

第4章　统计判决

客观现象或事物的发生和发展，依据是否具有可预见性可以分为两类：一类是确定性的，此类事物在一定条件下必然要发生或不发生；另一类是随机性的，此类事物有很多可能的结果，在实验或实现前不能预知会出现哪种结果，但是其有统计规律，这种统计规律可用概率分布（密度）函数或数字特征来刻画。实际上对于许多必然性事物，当我们对其发生、发展的一些条件不确知时，或影响它们的条件是随机的，其也表现具有随机性。在对它们提取特征产生特征矢量时，前者是确定性矢量，后者是随机矢量，它的分量是随机变量。确定性矢量是随机矢量的一种特别的情况，也可以纳入随机问题来讨论。这里的随机性除了量值的随机性之外主要涉及判决模式类别的随机性。

前一章方法中，我们没有直接利用各类的概率、概率分布密度、后验概率等统计特性，在那里将模式作为确定性的。当我们更为精细地研究时可以知道，特征分量的量测值总含有某种误差，其具有一定的随机性，而且同一类的不同个体的某个特征分量的值也是按某种规律散布的。特征分量数值的随机性反映至个体上就涉及模式类别判决结果的随机性。因此，我们用概率论的理论和方法解决分类识别问题，从理论和总体上讲都是更为合理和可靠的。本章方法用于随机模式分类识别，通常称为贝叶斯统计判决。在本章中，主要依据类的先验概率、概密、后验概率、损失函数，按照某种准则使我们的分类识别结果从统计上讲是最佳的。准则函数不同，所导出的判决规则就不同，分类结果也不同。在实际中使用哪种准则或方法应根据具体问题来确定。

为以后表述简洁，首先明确一些概念和符号的意义。$P(\omega_i)$ 表示 ω_i 类出现的先验概率，简称为 ω_i 类的概率。条件概率 $P(\omega_i \mid \boldsymbol{x})$ 表示 $\boldsymbol{x}$ 出现条件下 ω_i 类出现的概率，称其为类别 ω_i 的后验概率，对于模式识别

来讲，可理解为 $\boldsymbol{x}$ 来自 ω_i 类的概率。$p(\boldsymbol{x} \mid \omega_i)$ 表示在 ω_i 类条件下 $\boldsymbol{x}$ 的概率分布密度，即 ω_i 类模式 $\boldsymbol{x}$ 的概率密度，简称为类概密。同样，为了表述简洁，将随机矢量 $\boldsymbol{X}$ 及它的某个取值 $\boldsymbol{x}$ 都用同一个符号 $\boldsymbol{x}$ 表示，在以后各节中出现的 $\boldsymbol{x}$ 是表示随机矢量还是它的一个实现，根据内容是可以清楚知道的。并且 ω_i 类条件期望

$$\mathrm{E}_i[g(\boldsymbol{x})]\int_{\Omega} g(\boldsymbol{x})p(\boldsymbol{x} \mid \omega_i)\mathrm{d}\boldsymbol{x}$$

式中的 Ω 为特征空间，因不涉及 $\boldsymbol{x}$ 的维数，为简便，将 X^n 改写为 Ω。

这一章主要论述分类识别的一般性原理、几种重要的准则和相应的判决规则，正态分布模式类的判决函数以及它们的性能、误判概率上界。

4.1 最小误判概率准则判决

4.1.1 最小误判概率准则判决的一般形式

本章所研讨的类别判决是在统计意义下进行的。当按某种准则把待识模式判属某类时，应意识到存在判错的可能，就是说在用统计规则判决某一具体的模式 $\boldsymbol{x}$ 的类别时，由于用以判决的模式特征矢量的散布性和随机性，判决结果可能是错误的，把实属 ω_j 类的模式 $\boldsymbol{x}$ 判为属于 ω_i 类，这是本章中考虑问题的基础。

对于两类问题，统计判决的基本方式是根据类的概率和概密将模式的特征空间 Ω 分划成两个判决域 D_1 和 D_2，即

$$D_1 \cup D_2 = \Omega, \quad D_1 \cap D_2 = \varnothing$$

这里∅是空集。当 $\boldsymbol{x} \in D_1$ 时，判 $\boldsymbol{x} \in \omega_1$ 类；当 $\boldsymbol{x} \in D_2$ 时，判 $\boldsymbol{x} \in \omega_2$ 类。这时可能会发生两种错误，一种是把实属 ω_1 类的模式判属 ω_2 类，发生这种错误的原因是属于 ω_1 类的模式在特征空间中散布到 D_2 中去，从而将其判为属于 ω_2 类，这时的误判概率为

$$\varepsilon_{12} = \int_{D_2} p(\boldsymbol{x} \mid \omega_1)\mathrm{d}\boldsymbol{x} \qquad (4-1-1)$$

类似地，另一种错误是把实属 ω_2 类的模式判属 ω_1 类，此时的误判概率为

$$\varepsilon_{21} = \int_{D_1} p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} \qquad (4-1-2)$$

设 ω_1 类和 ω_2 类出现的概率分别为 $P(\omega_1)$ 和 $P(\omega_2)$，则总的误判概率 $P(e)$ 是

$$\begin{aligned} P(e) &= P(\omega_1)\varepsilon_{12} + P(\omega_2)\varepsilon_{21} \\ &= P(\omega_1)\int_{D_2} p(\boldsymbol{x} \mid \omega_1)\mathrm{d}\boldsymbol{x} + P(\omega_2)\int_{D_1} p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} \end{aligned} \qquad (4-1-3)$$

我们希望在总体上、统计上误判最少，因此所取的判决准则是使误判概率最小，这等价于使正确分类识别概率 $P(c)$ 最大（多类情况下，出现错误判决的方式要比正确判决的方式多，因而分析计算正确分类的概率相对比较简单）。即要求正确概率

$$P(c) = \int_{D_1} P(\omega_1)p(\boldsymbol{x} \mid \omega_1)\mathrm{d}\boldsymbol{x} + \int_{D_2} P(\omega_2)p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} \Rightarrow \max \qquad (4-1-4)$$

注意到

$$\int_{D_2} P(\omega_2)p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} = P(\omega_2) - \int_{D_1} P(\omega_2)(p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} \qquad (4-1-5)$$

将上式代入式(4-1-4)，得

$$P(c) = P(\omega_2) + \int_{D_1} [P(\omega_1)p(\boldsymbol{x} \mid \omega_1) - P(\omega_2)p(\boldsymbol{x} \mid \omega_2)]\mathrm{d}\boldsymbol{x} \qquad (4-1-6)$$

上式中，D_1 是待求的，显然直接求解 D_1 很困难，但是，为使 $P(c)$ 最大，ω_1 的判决域 D_1^* 应是 Ω 中所有满足条件

$$P(\omega_1)p(\boldsymbol{x} \mid \omega_1) > P(\omega_2)p(\boldsymbol{x} \mid \omega_2) \qquad (4-1-7)$$

那些点 $\boldsymbol{x}$ 组成的集合。类似地有，D_2^* 应是 Ω 中所有满足条件

$$P(\omega_1)p(\boldsymbol{x}\mid\omega_1) < P(\omega_2)p(\boldsymbol{x}\mid\omega_2) \qquad (4-1-8)$$

那些点 $\boldsymbol{x}$ 组成的集合。任何别的分划所对应的 $P(c)$ 都将小于上述分划时的 $P^*(c)$。这是因为，任何别的分划都可以使新的 ω_1 判决域表示为 $D'_1 = (D_1^* - D_{11}) \cup D_{21}$，其中，$D_{11}$ 是 D_1^* 的子域，D_{21} 是 D_2^* 的子域，于是此时的正确分类概率为

$$\begin{aligned} P'(c) &= P(\omega_2) + \int_{(D_1^* - D_{11})\cup D_{21}} [P(\omega_1)p(\boldsymbol{x}\mid\omega_1) - P(\omega_2)p(\boldsymbol{x}\mid\omega_2)]\mathrm{d}\boldsymbol{x} \\ &= P(\omega_2) + \int_{D_1^*}[P(\omega_1)p(\boldsymbol{x}\mid\omega_1) - P(\omega_2)p(\boldsymbol{x}\mid\omega_2)]\mathrm{d}\boldsymbol{x} \\ &\quad - \int_{D_{11}}[P(\omega_1)p(\boldsymbol{x}\mid\omega_1) - P(\omega_2)p(\boldsymbol{x}\mid\omega_2)]\mathrm{d}\boldsymbol{x} \\ &\quad + \int_{D_{21}}[P(\omega_1)p(\boldsymbol{x}\mid\omega_1) - P(\omega_2)p(\boldsymbol{x}\mid\omega_2)]\mathrm{d}\boldsymbol{x} \qquad (4-1-9) \end{aligned}$$

上式中，前两项之和为原来的 $P^*(c)$，由 D_{11} 和 D_{21} 的设定可知，第二项积分值为正，第三项积分值为负，所以有

$$P^*(c) > P'(c)$$

图 4.1.1 给出了一维两类问题的误判概率计算示意图，t^* 是最佳门限，显然它比另一个门限 t 的误判概率要小。

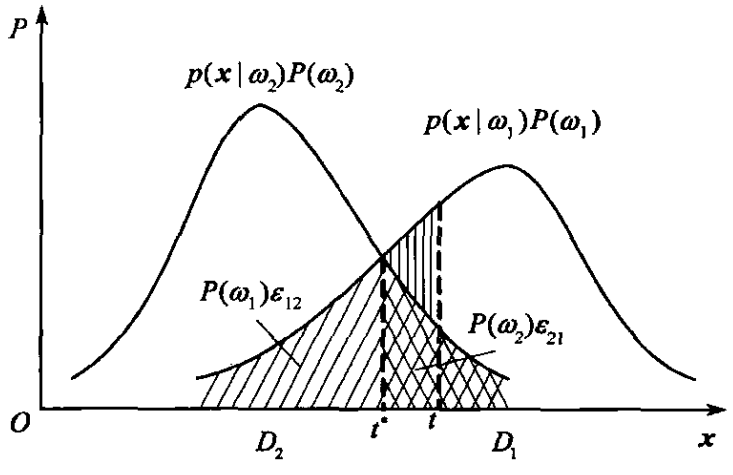


图 4.1.1　一维两类问题的误判概率计算示意图

综上所述，可以得到最小误判概率准则下的判决规则：

$$\text{如果 } P(\omega_1)p(\boldsymbol{x}\mid\omega_1) \gtrless P(\omega_2)p(\boldsymbol{x}\mid\omega_2)$$

$$\text{则判 } \boldsymbol{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases} \tag{4-1-10}$$

或等价地表示成

$$\text{如果 } l_{12}(\boldsymbol{x}) = \frac{p(\boldsymbol{x} \mid \omega_1)}{p(\boldsymbol{x} \mid \omega_2)} \gtrless \frac{P(\omega_2)}{P(\omega_1)}$$

$$\text{则判 } \boldsymbol{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases} \tag{4-1-11}$$

这里 $l_{12}(\boldsymbol{x})$ 称为似然比(Likelihood Ratio),$P(\omega_2)/P(\omega_1)$ 称为似然比阈值,通常记为 θ_{12}。

由贝叶斯定理

$$p(\boldsymbol{x})P(\omega_i \mid \boldsymbol{x}) = P(\omega_i)p(\boldsymbol{x} \mid \omega_i) \tag{4-1-12}$$

可得判决规则的另一个等价形式是

$$\text{如果 } P(\omega_1 \mid \boldsymbol{x}) \gtrless P(\omega_2 \mid \boldsymbol{x})$$

$$\text{则判 } \boldsymbol{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases} \tag{4-1-13}$$

这个结果是很容易理解的,通常称之为最大后验概率准则,可见,最大后验概率准则实际上是最小误判概率准则的一种规则形式。

将同样的分析方法运用到多类问题。设 $D_i(i = 1,2,\cdots,c)$ 为关于 ω_i 类的判决域,对 ω_i 正确分类概率 $P(c \mid \omega_i)$ 为

$$P(c \mid \omega_i) = \int_{D_i} p(\boldsymbol{x} \mid \omega_i)\mathrm{d}\boldsymbol{x}$$

总的正确分类概率 $P(c)$ 为

$$P(c) = \sum_{i=1}^{c} P(\omega_i)P(c \mid \omega_i)$$

因 $P(e) = 1 - P(c)$,故

$$\min P(e) \Rightarrow \max P(c) = \max \sum_{i=1}^{c} P(\omega_i)P(c \mid \omega_i)$$

$$\Rightarrow \int_{\Omega} \max[P(\omega_i)p(\boldsymbol{x} \mid \omega_i)]\mathrm{d}\boldsymbol{x} = \sum_{i=1}^{c} \int_{D^*} P(\omega_i)p(\boldsymbol{x} \mid \omega_i)\mathrm{d}\boldsymbol{x}$$

利用上式可得最佳的判决域

$$D_i^* = \{\boldsymbol{x} \mid P(\omega_i)p(\boldsymbol{x} \mid \omega_i) > P(\omega_j)p(\boldsymbol{x} \mid \omega_j), \forall j \neq i\}$$

对于多类问题,最小误判概率准则有如下几种等价的判决规则:

(1) 如果 $P(\omega_i \mid \boldsymbol{x}) > P(\omega_j \mid \boldsymbol{x})(\forall j \neq i)$

则判 $\boldsymbol{x} \in \omega_i$ (4-1-14)

(2) 如果 $P(\omega_i \mid \boldsymbol{x}) = \max_j[P(\omega_j \mid \boldsymbol{x})]$

则判 $\boldsymbol{x} \in \omega_i$ (4-1-15)

(3) 如果 $p(\boldsymbol{x} \mid \omega_i)P(\omega_i) > p(\boldsymbol{x} \mid \omega_j)P(\omega_j)(\forall j \neq i)$

则判 $\boldsymbol{x} \in \omega_i$ (4-1-16)

(4) 如果 $p(\boldsymbol{x} \mid \omega_i)P(\omega_i) = \max_j[p(\boldsymbol{x} \mid \omega_j)P(\omega_j)]$

则判 $\boldsymbol{x} \in \omega_i$ (4-1-17)

(5) 如果 $l_{ij}(\boldsymbol{x}) = \dfrac{p(\boldsymbol{x} \mid \omega_i)}{p(\boldsymbol{x} \mid \omega_j)} > \dfrac{P(\omega_j)}{P(\omega_i)} = \theta_{ij}(\forall j \neq i)$

则判 $\boldsymbol{x} \in \omega_i$ (4-1-18)

(6) 如果 $\ln p(\boldsymbol{x} \mid \omega_i) + \ln P(\omega_i) > \ln p(\boldsymbol{x} \mid \omega_j) + \ln P(\omega_j)(\forall j \neq i)$

则判 $\boldsymbol{x} \in \omega_i$ (4-1-19)

图 4.1.2 及图 4.1.3 为其示意图。

[**例 4.1.1**] 对一批人进行癌症普查,患癌症者定为属 ω_1 类,正常者定为属 ω_2 类。统计资料表明人们患癌的概率 $P(\omega_1) = 0.005$,从而 $P(\omega_2) = 0.995$。设有一种诊断此病的化验,其结果有阳性反应和阴性反应之分,依其作诊断。化验结果是一维离散模式特征。资料表明:癌症者有阳性反应的概率为 0.95,即 $P(x = 阳 \mid \omega_1) = 0.95$,从而可知 $P(x = 阳 \mid \omega_1) = 0.05$,正常人阳性反应的概率为 0.01 即 $P(x = 阳 \mid \omega_2) = 0.01$,可知 $P(x = 阴 \mid \omega_2) = 0.99$,问有阳性反应的人患癌症的概率有多大?

解:

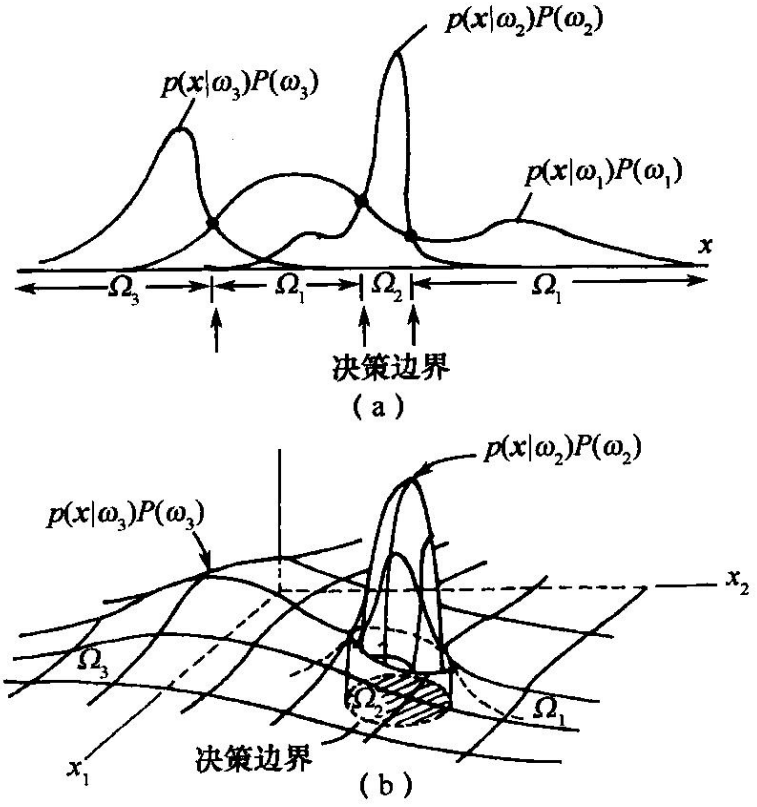


图 4.1.2　二维三类问题各类 $P(\omega_i)p(\boldsymbol{x} \mid \omega_i)$ 示意图

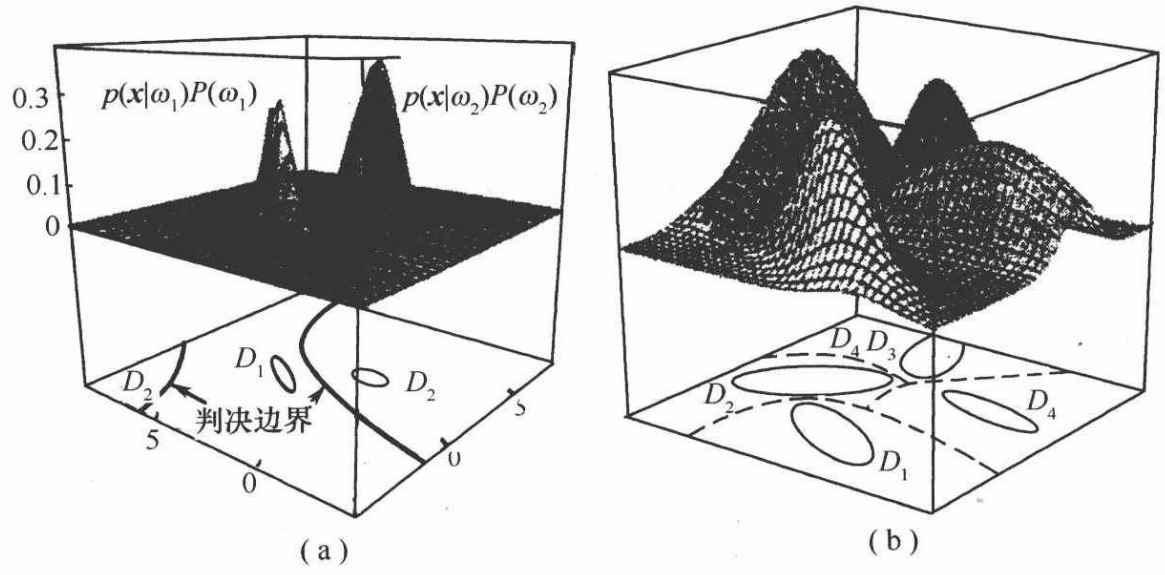


图 4.1.3　二维两类和四类正态分布问题判决边界示意图

$$P(\omega_1 \mid x = \text{阳}) = \frac{P(x = \text{阳} \mid \omega_1)P(\omega_1)}{P(x = \text{阳})}$$

$$= \frac{P(x = \text{阳} \mid \omega_1)P(\omega_1)}{P(x = \text{阳} \mid \omega_1)P(\omega_1) + P(x = \text{阳} \mid \omega_2)P(\omega_2)}$$

$$= \frac{0.95 \times 0.005}{0.95 \times 0.005 + 0.01 \times 0.995} \approx 0.323$$

说明有阳性反应的人其患癌的概率有 32.3% 。当要求医生必须判决其属于哪类时,因为

$$P(\omega_2 \mid x = \text{阳}) = 1 - 0.323 = 0.677 > P(\omega_1 \mid x = \text{阳})$$

故“x = 阳” $\in \omega_2$,即有阳性反应的人判属正常人。写成似然比形式:

$$l_{12}(x) = \frac{P(x = \text{阳} \mid \omega_1)}{P(x = \text{阳} \mid \omega_2)} = \frac{0.95}{0.01} = 95$$

判决阈值:

$$\theta_{12} = \frac{P(\omega_2)}{P(\omega_1)} = \frac{0.995}{0.005} = 199$$

$$\because l_{12}(x) < \theta_{12}$$

$$\therefore x \in \omega_2$$

4.1.2 正态模式最小误判概率判决规则的具体形式

由于正态分布易于分析,而且对许多实际问题是较合理的模型,所以受到了人们的极大重视,并进行了深入的研究。如果各类概率密度函数是多变量正态分布,则可以由上节的一般性判决规则导出更具体的判决函数。在 c 类问题中,属于 ω_i 类的 n 维模式 $\boldsymbol{x}$ 的多变量正态分布密度函数为

$$p(\boldsymbol{x} \mid \omega_i) = \frac{1}{(2\pi)^{n/2} \mid \boldsymbol{\Sigma}_i \mid^{1/2}} \exp\left[-\frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu}_i)^{\mathrm{T}} \boldsymbol{\Sigma}_i^{-1} (\boldsymbol{x} - \boldsymbol{\mu}_i) \right]$$

$$(i = 1, 2, \cdots, c) \qquad (4-1-20)$$

式中:$\boldsymbol{\mu}_i = \mathrm{E}_i[\boldsymbol{x}]$ 为 ω_i 类模式的均值矢量;$\boldsymbol{\Sigma}_i = \mathrm{E}_i[(\boldsymbol{x} - \boldsymbol{\mu}_i)(\boldsymbol{x} - \boldsymbol{\mu}_i)^{\mathrm{T}}]$ 为 ω_i 类模式的协方差矩阵;$\mid \boldsymbol{\Sigma}_i \mid$ 为 $\boldsymbol{\Sigma}_i$ 的行列式。

由上式可以看出,多变量正态分布密度函数完全由均值矢量的 n 个元素和协方差阵的 $n(n+1)/2$ 个元素所确定(因 $\boldsymbol{\Sigma}_i$ 是对称的)。取自一正态母体的模式的分布在理论上其中心取决于均值矢量,而其分布形状取决于协方差阵,等密度点的轨迹为超椭球面,超椭球的主轴与协方差阵的特征矢量方向一致,主轴的长度与相应的特征值方根成比例。

由 4.1.1 节知，ω_i 类的判决函数为

$$d_i(\boldsymbol{x}) = p(\boldsymbol{x} \mid \omega_i)P(\omega_i)(i = 1,2,\cdots,c) \quad (4-1-21)$$

由于对数函数是单值单调递增函数，并根据密度函数的结构特点，显然对于正态分布取对数更便于分析，于是 ω_i 类的判决函数可以表示为

$$d_i(\boldsymbol{x}) = \ln P(\omega_i) - \frac{n}{2}\ln(2\pi) - \frac{1}{2}\ln|\boldsymbol{\Sigma}_i| - \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^{\mathrm{T}}\boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i)(i = 1,2,\cdots,c) \quad (4-1-22)$$

由于判决规则是比较 $d_i(\boldsymbol{x})$ 和 $d_j(\boldsymbol{x})$ 的大小，去掉与类别无关的项并不影响分类判决结果，故 $d_i(\boldsymbol{x})$ 可简化为

$$d_i(\boldsymbol{x}) = \ln P(\omega_i) - \frac{1}{2}\ln|\boldsymbol{\Sigma}_i| - \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^{\mathrm{T}}\boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i) \quad (4-1-23)$$

这就是正态分布模式的贝叶斯判决函数。上式表明，$d_i(\boldsymbol{x})$ 是一超二次曲面。

如果 ω_i 类和 ω_j 类相邻，则它们的决策界面方程为 $d_i(\boldsymbol{x}) = d_j(\boldsymbol{x})$。

一般地讲，正态分布的两个模式类别之间用一个二次判决界面就可以得到最优效果。由于对数函数是单调增函数，所以判决规则不变：

$$d_i(\boldsymbol{x}) > d_j(\boldsymbol{x})(\forall j \neq j) \Rightarrow \boldsymbol{x} \in \omega_i$$

下面就一些特殊情况进一步具体讨论。

1. $\boldsymbol{\Sigma}_i = \boldsymbol{\Sigma}$

这种情况下，各类模式分布的协方差阵相同。略去与类别无关的项并注意到 $\boldsymbol{\Sigma}$ 是对称阵，ω_i 类的判决函数可以写为

$$\begin{aligned} d_i(\boldsymbol{x}) &= \ln P(\omega_i) - \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i) \\ &= \ln P(\omega_i) - \frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{x} + \boldsymbol{\mu}_i^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{x} - \frac{1}{2}\boldsymbol{\mu}_i^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i \\ &\quad (i = 1,2,\cdots,c) \end{aligned} \quad (4-1-24)$$

因是比较两个判决函数的大小进行分类识别，$d_i(\boldsymbol{x})$ 进一步可简化为

$$d_i(\boldsymbol{x}) = \ln P(\omega_i) + \boldsymbol{\mu}_i^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{x} - \frac{1}{2}\boldsymbol{\mu}_i^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i$$

如果 ω_i 和 ω_j 相邻，那么判决界面方程为

$$\begin{aligned} d_i(\boldsymbol{x}) - d_j(\boldsymbol{x}) &= \ln P(\omega_i) - \ln P(\omega_j) + (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{x} \\ &\quad - \frac{1}{2}\boldsymbol{\mu}_i^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_i + \frac{1}{2}\boldsymbol{\mu}_j^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_j \qquad (4-1-25) \\ &\triangleq \boldsymbol{w}_{ij}^{\mathrm{T}}(\boldsymbol{x} - \boldsymbol{x}_0) = 0 \end{aligned}$$

式中：

$$\boldsymbol{w}_{ij} = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \qquad (4-1-26)$$

$$\boldsymbol{x}_0 = \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\ln[P(\omega_i)/P(\omega_j)]}{(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_i)}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \qquad (4-1-27)$$

显然，这时界面为一超平面。此决策超平面过 $\boldsymbol{x}_0$ 点，矢量 $\boldsymbol{w}_{ij}$ 是该超平面的法矢量。$\boldsymbol{w}_{ij} = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$ 通常不与 $(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$ 方向相同，所以决策界面不与 $(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$ 正交。若各类的概率相等，则有

$$\boldsymbol{x}_0 = \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) \qquad (4-1-28)$$

即 $\boldsymbol{x}_0$ 是 $\boldsymbol{\mu}_i$ 和 $\boldsymbol{\mu}_j$ 连线的中点。此时由式(4-1-24)可知，各类判决函数可化简为马氏距离平方的相反数，因此 $\boldsymbol{x}$ 的类别由 $\boldsymbol{x}$ 到各类的均矢的马氏距离决定，应判 $\boldsymbol{x}$ 属于马氏距离最小的那一类。若 $P(\omega_i) \neq P(\omega_j)$，由式(4-1-27)可以看出，点 $\boldsymbol{x}_0$ 在 $\boldsymbol{\mu}_i$ 和 $\boldsymbol{\mu}_j$ 的连线上，距类概率较小的那一类的类心较近，如图 4.1.4 所示。如果 $\boldsymbol{\Sigma} = \sigma^2\boldsymbol{I}$（$\boldsymbol{I}$ 为单位阵，σ^2 为分量的方差），显然有矢量 $\boldsymbol{w}_{ij}$ 和矢量 $(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$ 方向相同，此时决策平面垂直于两类中心的连线；若 $P(\omega_i) = P(\omega_j)$，此时决策界面还过 $\boldsymbol{\mu}_i$ 和 $\boldsymbol{\mu}_j$ 连线的中点，在这种情况下，对于待识模式 $\boldsymbol{x}$，只要计算它与各类均矢 $\boldsymbol{\mu}_i$ 的欧氏距离，把 $\boldsymbol{x}$ 判属距均矢较近的那一类，这就是最小距离分类器。

2. $\boldsymbol{\Sigma}_i \neq \boldsymbol{\Sigma}_j$

这是一般的情况。ω_i 类模式的判决函数为

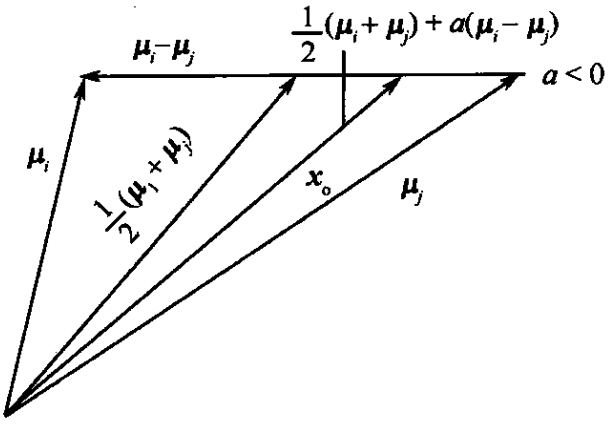


图 4.1.4　类概率对决策界影响的示意图

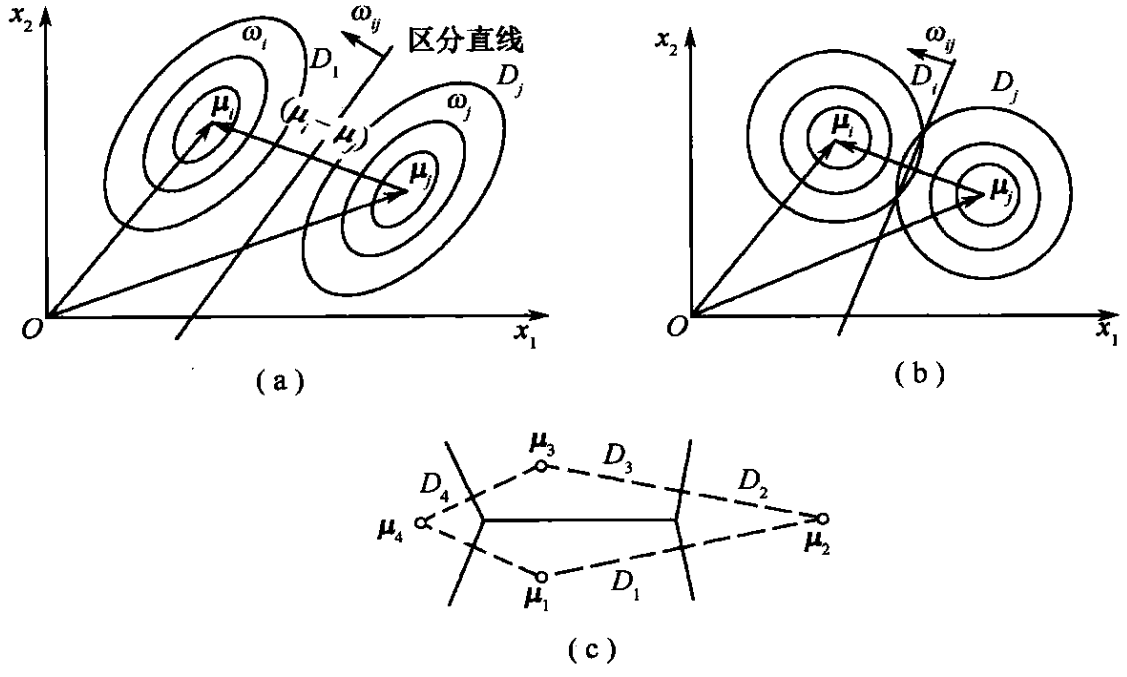


图 4.1.5　二维模式 $\Sigma_i = \Sigma$ 的几种典型情况示意图

(a) 二维模式，$\Sigma_i = \Sigma_j$；(b) 二维模式，$\Sigma_i = \Sigma_j = \sigma^2 I$；

(c) 二维多类问题，$\Sigma_i = \Sigma = \sigma^2 I$。

$$d_i(\boldsymbol{x}) = \ln P(\omega_i) - \frac{1}{2}\ln|\boldsymbol{\Sigma}_i| - \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu}_i)^{\mathrm{T}}\boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i)$$

$$\triangleq \boldsymbol{x}^{\mathrm{T}}\boldsymbol{W}_i\boldsymbol{x} + \boldsymbol{w}_i^{\mathrm{T}}\boldsymbol{x} + w_{i0} \quad (i = 1,2,\cdots,c) \qquad (4-1-29)$$

其中：

$$\boldsymbol{W}_i = -\frac{1}{2}\boldsymbol{\Sigma}_i^{-1} \qquad (4-1-30)$$

$$\boldsymbol{w}_i = \boldsymbol{\Sigma}_i^{-1}\boldsymbol{\mu}_i \qquad (4-1-31)$$

$$w_{i0} = \ln P(\omega_i) - \frac{1}{2}\ln|\boldsymbol{\Sigma}_i| - \frac{1}{2}\boldsymbol{\mu}_i^{\mathrm{T}}\boldsymbol{\Sigma}_i^{-1}\boldsymbol{\mu}_i \quad (4-1-32)$$

相邻两类 ω_i 和 ω_j 的决策界面为

$$d_i(\boldsymbol{x}) - d_j(\boldsymbol{x}) = \boldsymbol{x}^{\mathrm{T}}(\boldsymbol{W}_i - \boldsymbol{W}_j)\boldsymbol{x} + (\boldsymbol{w}_i - \boldsymbol{w}_j)^{\mathrm{T}}\boldsymbol{x} + (w_{i0} - w_{j0}) = 0 \quad (4-1-33)$$

显然，上式表示的决策界面是二次曲面，随着 $\boldsymbol{\Sigma}_i$、$\boldsymbol{\mu}_i$ 及 $P(\omega_i)$ 的不同而呈现为不同的二次曲面，它可能是超球面、超椭球面、超双曲面、超抛物面等。当 $\boldsymbol{x}$ 是二维模式时，判决界面即为二次曲线。图4.1.6所示为二维特征空间中两类的概率密度函数立体图以及决策界线，图中的一些椭圆为等概密点轨迹。

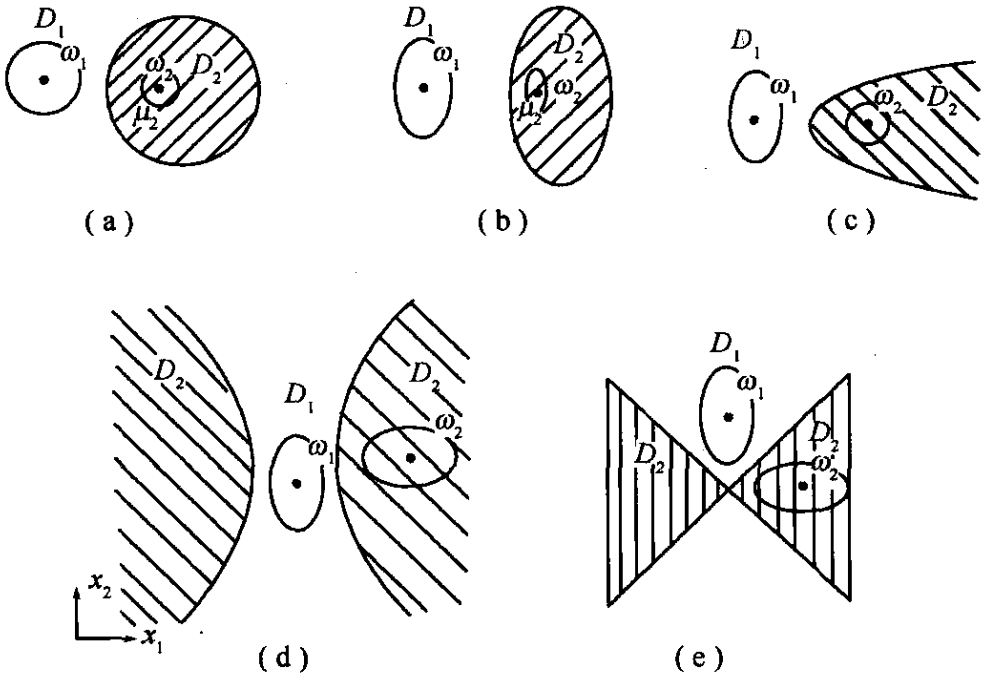


图 4.1.6　二维模式 $\boldsymbol{\Sigma}_1 \neq \boldsymbol{\Sigma}_2$ 几种情况的决策界面

(a) 圆；(b) 椭圆；(c) 抛物线；(d) 双曲线；(e) 直线。

[例 4.1.2] 模式分布如图 4.1.7 所示，两类的均矢和协方差阵可用下式估计。

$$\boldsymbol{\mu}_i \approx \boldsymbol{m}_i = \frac{1}{N_i}\sum_{j=1}^{N_i}\boldsymbol{x}_j^{(i)}$$

$$\boldsymbol{\Sigma}_i \approx \boldsymbol{C}_i = \frac{1}{N_i}\sum_{j=1}^{N_i}\boldsymbol{x}_j^{(i)}(\boldsymbol{x}_j^{(i)})^{\mathrm{T}} - \boldsymbol{m}_i\boldsymbol{m}_i^{\mathrm{T}}$$

式中：N_i 为 ω_i 类中模式的数目；$x_j^{(i)}$ 表示 ω_i 类中第 j 个模式。利用上式可求出：

$$\boldsymbol{m}_1 = \frac{1}{4}(3,1,1)^{\mathrm{T}}$$

$$\boldsymbol{m}_2 = \frac{1}{4}(1,3,3)^{\mathrm{T}}$$

$$\boldsymbol{C}_1 = \boldsymbol{C}_2 = \boldsymbol{C} = \frac{1}{16}\begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{bmatrix}$$

$$\boldsymbol{C}^{-1} = \begin{bmatrix} 8 & -4 & -4 \\ -4 & 8 & 4 \\ -4 & 4 & 8 \end{bmatrix}$$

两类均作为正态分布，并假设 $P(\omega_1) = P(\omega_2)$，故判决式为

$$d_i(\boldsymbol{x}) = \boldsymbol{x}^{\mathrm{T}}\boldsymbol{C}^{-1}\boldsymbol{m}_i - \frac{1}{2}\boldsymbol{m}_i^{\mathrm{T}}\boldsymbol{C}^{-1}\boldsymbol{m}_i$$

将 $\boldsymbol{m}_i$ 和 $\boldsymbol{C}^{-1}$ 代入并展开，得

$$d_1(\boldsymbol{x}) = 4x_1 - \frac{3}{2}$$

$$d_2(\boldsymbol{x}) = -4x_1 + 8x_2 + 8x_3 - \frac{11}{2}$$

判决界面为

$$d_1(\boldsymbol{x}) - d_2(\boldsymbol{x}) = 8x_1 - 8x_2 - 8x_3 + 4 = 0$$

上式可以化简为

$$2x_1 - 2x_2 - 2x_3 + 1 = 0$$

图 4.1.7 所示为判决界面的一部分，它是一个三维平面，其将所给模式分为两部分。

4.1.3 正态模式分类的误判概率

对于两类问题，设两类模式为协方差阵相等的多变量正态分布，它

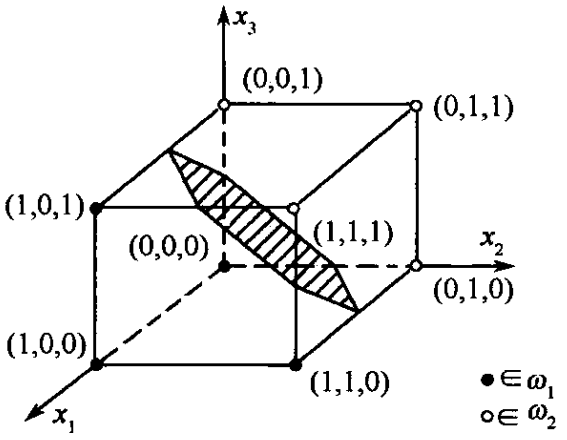


图 4.1.7　例题的训练模式及判决界面

们的密度函数分别为

$$p(\boldsymbol{x} \mid \omega_i) \sim N(\boldsymbol{\mu}_i, \boldsymbol{\Sigma})$$

$$p(\boldsymbol{x} \mid \omega_j) \sim N(\boldsymbol{\mu}_j, \boldsymbol{\Sigma})$$

决策规则的具体形式之一是似然比门限形式，对数似然比

$$\begin{aligned} L_{ij}(\boldsymbol{x}) &\triangleq \ln l_{ij}(\boldsymbol{x}) = \ln p(\boldsymbol{x} \mid \omega_i) - \ln p(\boldsymbol{x} \mid \omega_j) \\ &= -\frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu}_i)^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{x} - \boldsymbol{\mu}_i) + \frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu}_j)^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (x - \mu_j) \\ &= \boldsymbol{x}^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j)^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \end{aligned} \tag{4-1-34}$$

由上式可知，$L_{ij}(\boldsymbol{x})$ 是 $\boldsymbol{x}$ 的线性函数，因 $\boldsymbol{x}$ 的各分量是正态分布的，故 $L_{ij}(\boldsymbol{x})$ 是正态分布的随机变量。由式(4-1-34)易得 $L_{ij}(\boldsymbol{x})$ 在 $\boldsymbol{x} \in \omega_i$ 条件下的数学期望

$$\begin{aligned} \mathrm{E}_i[L_{ij}] &= \boldsymbol{\mu}_i^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) - \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j)^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \\ &= \frac{1}{2}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \end{aligned} \tag{4-1-35}$$

令

$$r_{ij}^2 = (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \tag{4-1-36}$$

显然，r_{ij} 为这两类中心的马氏距离。于是有

$$\mathrm{E}_i[L_{ij}] \triangleq \bar{L}_{ij} = \frac{1}{2} r_{ij}^2 \tag{4-1-37}$$

L_{ij} 在 $\boldsymbol{x} \in \omega_i$ 条件下的方差

$$\begin{aligned}\mathrm{Var}_i[L_{ij}] &= \mathrm{E}_i[(L_{ij} - \bar{L}_{ij})^2] \\ &= \mathrm{E}_i[((\boldsymbol{x} - \boldsymbol{\mu}_i)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j))^2] \\ &= \mathrm{E}_i[(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x} - \boldsymbol{\mu}_i)(\boldsymbol{x} - \boldsymbol{\mu}_i)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)] \\ &= (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) = r_{ij}^2 \qquad (4-1-38)\end{aligned}$$

因此，对于 $\boldsymbol{x} \in \omega_i$，对数似然比 $L_{ij}(\boldsymbol{x} \mid \omega_i)$ 的分布为 $N(r_{ij}^2/2, r_{ij}^2)$。类似地易得，对于 $\boldsymbol{x} \in \omega_j$，对数似然比 $L_{ij}(\boldsymbol{x} \mid \omega_j)$ 的分布为 $N(-r_{ij}^2/2, r_{ij}^2)$。图 4.1.8 是关于两类的对数似然比 $L_{ij}(\boldsymbol{x})$ 的概密分布示意图。

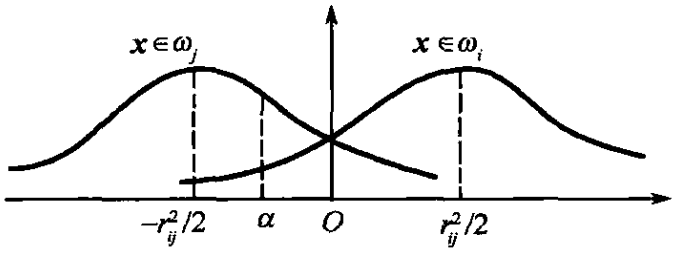


图 4.1.8　正态变量的对数似然比密度函数

设 $\alpha = \ln\theta_{ij} = \ln(p(\omega_i)/p(\omega_j))$，由决策规则可知，将属于 ω_j 类的模式误判为属于 ω_j 类的错误概率为 $P(L_{ij} < \alpha \mid \omega_i)$，而将属于 ω_j 类的模式误判为属于 ω_i 类的错误概率为 $P(L_{ij} > \alpha \mid \omega_j)$，它们可具体计算如下：

$$P(L_{ij} < \alpha \mid \omega_i) = \int_{-\infty}^{\alpha} \frac{1}{\sqrt{2\pi}r_{ij}} \exp\left[-\frac{\left(L_{ij} - \frac{1}{2}r_{ij}^2\right)^2}{2r_{ij}^2}\right] \mathrm{d}L_{ij} \qquad (4-1-39)$$

$$= \Phi\left[\frac{\alpha - \frac{1}{2}r_{ij}^2}{r_{ij}}\right] \qquad (4-1-40)$$

$$P(L_{ij} > \alpha \mid \omega_j) = \int_{\alpha}^{\infty} \frac{1}{\sqrt{2\pi}r_{ij}} \exp\left[-\frac{\left(L_{ij} + \frac{1}{2}r_{ij}^2\right)^2}{2r_{ij}^2}\right] \mathrm{d}L_{ij}$$

$$= 1 - \Phi\left[\frac{\alpha + \frac{1}{2}r_{ij}^2}{r_{ij}}\right] \qquad (4-1-41)$$

式中：

$$\Phi(u) = \int_{-\infty}^{u} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{y^2}{2}\right] \mathrm{d}y \qquad (4-1-42)$$

于是，总的误判概率为

$$P(e) = P(\omega_i)P(L_{ij} < \alpha \mid \omega_i) + P(\omega_j)P(L_{ij} > \alpha \mid \omega_j)$$

$$= P(\omega_i)\Phi\left[\frac{\alpha - \frac{1}{2}r_{ij}^2}{r_{ij}}\right] + P(\omega_j)\left\{1 - \Phi\left[\frac{\alpha + \frac{1}{2}r_{ij}^2}{r_{ij}}\right]\right\} \qquad (4-1-43)$$

为能看出 $P(e)$ 和 r_{ij}^2 关系趋势，特取 $P(\omega_i) = P(\omega_j) = \frac{1}{2}$，此时 $\alpha = 0$，则

$$P(e) = \frac{1}{2}\Phi\left[-\frac{1}{2}r_{ij}\right] + \frac{1}{2}\left\{1 - \Phi\left[\frac{1}{2}r_{ij}\right]\right\}$$

$$= \int_{-\infty}^{-r_{ij}/2} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{y^2}{2}\right] \mathrm{d}y$$

$$= \Phi\left[-\frac{r_{ij}}{2}\right] = \int_{r_{ij}/2}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{y^2}{2}\right] \mathrm{d}y \qquad (4-1-44)$$

上式表明了误判概率与两类的马氏距离的关系，即 $P(e)$ 随 r_{ij}^2 的增大而单调递减（图 4.1.9），只要两类马氏距离足够大，其误判概率可足够小，例如当 $r_{ij}^2 = 11$ 时，$P(e) \approx 5\%$。

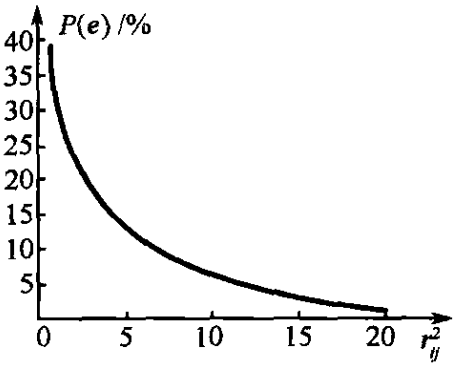


图 4.1.9　正态模式的误判概率与马氏距离关系

4.2 最小损失准则判决

4.2.1 损失概念、损失函数与平均损失

在上一节中已经知道，对于随机模式，由于是根据类的概率和概密进行分类判决，所以总会存在误判的可能。不同的待识对象误判后付出的代价一般来讲是不同的。例如，在诊断中把正常细胞误判为癌细胞会给病人及其亲人带来精神上的负担和痛苦，并且要耗费大量的精力和财力进行无病医病，而将癌细胞误判为正常细胞将使病人失去进一步检查和医治的机会，造成致命的后果，显然这两种不同的误判所造成损失的严重程度是不同的。再如，战争中对一架飞机进行敌我识别时，有些情况下将一架敌机判为友机所带来的人员损失要比友机判为敌机大得多。不同的对象误判后蒙受的损失是不一样的，如战争中，对飞机的误判要比对汽车的误判经济损失大得多。另外，相同的对象在不同的领域误判后蒙受的损失也不一样。如果说在判决时只考虑误判概率相对纯数学一些，那么我们还要考虑判决后带来的社会或经济上的影响，使分类识别规则更适于实际问题，因此有必要引入能够反映由于误判而要付出代价的“损失函数”。下面对 c 类问题构造损失函数。

设模式空间中存在 c 个类别：$\omega_1,\omega_2,\cdots,\omega_c$，决策空间由 a 个决策组成：$\alpha_1,\alpha_2,\cdots,\alpha_a$。这里，决策 α_j 是将一具有某些属性的模式指判为某一类或者是拒判，a 可以大于、等于或小于 c。对一个实属 ω_i 类的模式采用了决策 α_j 所造成的损失记为 $\lambda(\alpha_j/\omega_i) \triangleq \lambda_{ij}$，它是定义于 $\{\omega_1,\omega_2,\cdots,\omega_c\} \times \{\alpha_1,\alpha_2,\cdots,\alpha_a\}$ 空间中的二元函数，称其为损失函数。可以根据具体的实际背景对其赋值。一般认为正确判决没有损失，如果将决策 α_i 定义为指判模式 $\boldsymbol{x}$ 属于 ω_i 类，可取 $\lambda_{ii}=0$；显然错误判决的损失总是大于正确判决的损失，为简单起见，常取 $\lambda_{ij}=1(i\neq j)$，这时称为 0－1 损失函数。损失函数与模式实属类别和决策三者之间的关系可用表 4.2.1 决策－损失表表示。

对于确定的各类统计特性，当在分类识别中需要考虑误判损失（代

表 4.2.1　决策 - 损失表

类别 / 损失 / 决策	ω_1	ω_2	…	ω_c
α_1	$\lambda(\alpha_1/\omega_1)$	$\lambda(\alpha_1/\omega_2)$	…	$\lambda(\alpha_1/\omega_c)$
α_2	$\lambda(\alpha_2/\omega_1)$	$\lambda(\alpha_2/\omega_2)$	…	$\lambda(\alpha_2/\omega_c)$
⋮	⋮	⋮	⋮	⋮
α_a	$\lambda(\alpha_a/\omega_1)$	$\lambda(\alpha_a/\omega_2)$	…	$\lambda(\alpha_a/\omega_c)$

价）时，采取哪种决策取决于待识模式 $\boldsymbol{x}$ 以及损失函数 λ_{ij} 的设定。在损失函数取定的情况下，决策和模式的关系记为 $\alpha(\boldsymbol{x})$，由于 $\boldsymbol{x}$ 是随机矢量，因此决策 α 也是随机的，从而对于实属 ω_i 类的随机模式 $\boldsymbol{x}$ 作出决策 α 所付出的损失代价 $\lambda(\alpha(\boldsymbol{x})/\omega_i)$ 是随机变量。为简单而又不失一般性，令决策的数目 a 等于类数 c，如果决策 α_j 定义为判 $\boldsymbol{x}$ 属于 ω_j 类，那么对于给定的模式 $\boldsymbol{x}$ 在采取决策 α_j 的条件下损失的期望为

$$R_j(\boldsymbol{x}) = R(\alpha_j \mid \boldsymbol{x}) = \sum_{i=1}^{c} \lambda_{ij} P(\omega_i \mid \boldsymbol{x}) \triangleq \mathrm{E}[\lambda_{ij} \mid \boldsymbol{x}] \quad (j = 1,2,\cdots,c) \tag{4-2-1}$$

注意这里“E”是相对各类求全期望。容易看出，上式是相应于决策 α_j，即判 $\boldsymbol{x}$ 属于 ω_j 类时的各损失函数 λ_{ij} 以各类后验概率为权重的加权和。上式中 $\boldsymbol{x}$ 来自任何一类的情况都考虑到了，$\boldsymbol{x}$ 属于某一类 ω_i 的可能性越大，$P(\omega_i \mid \boldsymbol{x})$ 就越大，于是给的权重就越大。条件期望损失 $R_j(\boldsymbol{x})$ 度量了在模式为 $\boldsymbol{x}$、决策为 α_j 条件下的平均损失，一个预期的损失称为风险，故 $R_j(\boldsymbol{x})$ 也称为条件平均损失或条件平均风险（Risk）。

由贝叶斯公式，上式可以写为

$$\begin{aligned} R_j(\boldsymbol{x}) &= \sum_{i=1}^{c} \lambda_{ij} p(\boldsymbol{x} \mid \omega_i) P(\omega_i)/p(\boldsymbol{x}) \\ &= \sum_{i=1}^{c} \lambda_{ij} p(\boldsymbol{x} \mid \omega_i) P(\omega_i) \Big/ \sum_{i=1}^{c} p(\boldsymbol{x} \mid \omega_i) P(\omega_i) \end{aligned} \tag{4-2-2}$$

下面求各个决策 α_j 条件下的平均损失 $R_j(\boldsymbol{x})$ 关于 $\boldsymbol{x}$ 的数学期望，

设特征空间 Ω 中判决域为 $D_j(j=1,2,\cdots,c)$，于是有

$$
\begin{aligned}
R &= \sum_{j=1}^{c}\int_{D_j} R_j(\boldsymbol{x})p(\boldsymbol{x})\mathrm{d}\boldsymbol{x} \\
&= \sum_{j=1}^{c}\int_{D_j}\sum_{i=1}^{c}\lambda_{ij}p(\boldsymbol{x}\mid\omega_i)P(\omega_i)\mathrm{d}\boldsymbol{x} \\
&= \sum_{i=1}^{c}\sum_{j=1}^{c}\int_{D_j}\lambda(\alpha_j(\boldsymbol{x})/\omega_i)p(\boldsymbol{x}\mid\omega_i)P(\omega_i)\mathrm{d}\boldsymbol{x} \\
&= \sum_{i=1}^{c}P(\omega_i)\int_{\Omega}\lambda(\alpha(\boldsymbol{x})/\omega_i)p(\boldsymbol{x}\mid\omega_i)\mathrm{d}\boldsymbol{x} \\
&= \mathop{\mathrm{E}}_{i,\boldsymbol{x}}[\lambda(\alpha(\boldsymbol{x})/\omega_i)] \qquad (4-2-3)
\end{aligned}
$$

上式表明，R 是损失函数 $\lambda_{ij}=\lambda(\alpha_j(\boldsymbol{x})/\omega_i)$ 关于各类及各类的 $\boldsymbol{x}$ 的数学期望，称其为平均损失或平均风险。

4.2.2 最小损失准则判决

引入了损失概念、损失函数与平均损失后，在作分类识别决策时，为使结果更为有利，不能只根据类的概率和概密作出分类识别，还必须考虑误判的损失代价。按照两害相权取其轻原则，所采取的决策应是在统计意义上使由于误判而蒙受的损失最小，这就是所谓的最小条件平均损失准则。具体地讲，当对一待识模式 $\boldsymbol{x}$ 进行分类识别决策时，算出判属它为各类的条件期望损失 $R_1(\boldsymbol{x}),R_2(\boldsymbol{x}),\cdots,R_a(\boldsymbol{x})$ 之后，判决 $\boldsymbol{x}$ 属于条件期望损失最小的那一类。可以将最小条件平均损失判决规则写为

$$
\begin{aligned}
&\text{如果 } R_j(\boldsymbol{x}) = \min_i[R_i(\boldsymbol{x})] \\
&\text{则判 } \boldsymbol{x}\in\omega_j \qquad (4-2-4)
\end{aligned}
$$

[**定理 4.2.1**] 使条件平均损失最小的判决也必然使总的平均损失最小。

最小条件平均损失准则也称为最小平均损失准则或最小平均风险准则，简称为最小损失准则。这个定理是不难理解的，只有对每一特征点 $\boldsymbol{x}$，所采取的判决 $\alpha(\boldsymbol{x})$ 使条件平均损失 $R(\alpha(\boldsymbol{x})\mid\boldsymbol{x})$ 都最小，才能使

总的平均损失$\int_{\Omega} R(\alpha(x) \mid x) p(x) \mathrm{d}x$最小。

对于两类问题，由式(4-2-2)可知，当将x判属ω_1类时，条件平均损失为

$$R_1(x) = [\lambda_{11} p(x \mid \omega_1) P(\omega_1) + \lambda_{21} p(x \mid \omega_2) P(\omega_2)] / p(x) \tag{4-2-5}$$

当判x属于ω_2类时，条件平均损失为

$$R_2(x) = [\lambda_{12} p(x \mid \omega_1) P(\omega_1) + \lambda_{22} p(x \mid \omega_2) P(\omega_2)] / p(x) \tag{4-2-6}$$

这时最小损失判决规则中的$R_1(x) \gtrless R_2(x)$具体表示为

$$\lambda_{11} p(x \mid \omega_1) P(\omega_1) + \lambda_{21} p(x \mid \omega_2) P(\omega_2)$$
$$\gtrless \lambda_{12} p(x \mid \omega_1) P(\omega_1) + \lambda_{22} p(x \mid \omega_2) P(\omega_2)$$

经整理可得

$$(\lambda_{21} - \lambda_{22}) p(x \mid \omega_2) P(\omega_2) \gtrless (\lambda_{12} - \lambda_{11}) p(x \mid \omega_1) P(\omega_1)$$

于是，两类问题的最小损失准则的似然比形式的判决规则为

$$\text{如果} \frac{p(x \mid \omega_1)}{p(x \mid \omega_2)} \gtrless \frac{P(\omega_2)(\lambda_{21} - \lambda_{22})}{P(\omega_1)(\lambda_{12} - \lambda_{11})} \tag{4-2-7}$$

$$\text{则判 } x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

若记似然比阈值

$$\theta_{12} = \frac{P(\omega_2)}{P(\omega_1)} \frac{(\lambda_{21} - \lambda_{22})}{(\lambda_{12} - \lambda_{11})}$$

则两类问题的判决规则为

$$\text{如果 } l_{12}(x) \gtrless \theta_{12}$$

$$\text{则判 } x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

注意，若

$$l_{12}(x) = \theta_{12}$$

我们规定任判或拒判。

用类似的方法，由式(4 - 2 - 1) 容易得出上述判决规则的一种等价形式，即

$$\text{如果}\frac{P(\omega_1 \mid x)}{P(\omega_2 \mid x)} \gtrless \frac{\lambda_{21} - \lambda_{22}}{\lambda_{12} - \lambda_{11}} \qquad (4-2-8)$$

$$\text{则判 } x \in \begin{cases}\omega_1 \\ \omega_2\end{cases}$$

显然，这两个判决规则也可以直接用贝叶斯公式相互导出。

损失函数如何确定依赖于实际问题和经验，有时为了方便，对于 c 类问题，取 0 - 1 损失函数。令

$$\lambda_{ij} = \begin{cases}0(i = j) \\ 1(i \neq j)\end{cases}$$

于是

$$\begin{aligned} R_j(x) &= \left[\sum_{i=1}^{c} p(x \mid \omega_i)P(\omega_i) - p(x \mid \omega_j)P(\omega_j)\right] \Big/ p(x) \\ &= [p(x) - p(x \mid \omega_j)P(\omega_j)] \Big/ p(x) \\ &= 1 - P(\omega_j) \mid x) \end{aligned} \qquad (4-2-9)$$

此时，最小损失准则下的决策规则为

$$\text{如果 } p(x \mid \omega_i)P(\omega_i) > p(x \mid \omega_j)P(\omega_j) \quad (\forall j \neq i) \qquad (4-2-10)$$

$$\text{则判 } x \in \omega_i$$

或即

$$\text{如果 } P(\omega_i \mid x) > P(\omega_j \mid x) \quad (\forall j \neq i) \qquad (4-2-11)$$

$$\text{则判 } x \in \omega_i$$

此即为最小误判概率准则的判决规则，即取 0 - 1 损失函数时，最小损失准则等价于最小误判概率准则，此时的平均损失就是误判概率，使平均损失最小即使误判概率最小。这也表明，最小误判概率准则是最小损

失准则的特例。

[例 4.2.1] 设信源信号为{0,1},其通过一受加性噪声干扰的信道,噪声为正态分布,均值为零,方差为 σ^2,信道输出为 x,试求出最优判决规则,以区分输入是 0 还是 1。

解:设信号 0 为 ω_0 类,信号 1 为 ω_1 类。因输入信号受正态分布 $N(0,\sigma^2)$ 的加性噪声干扰,所以输出信号为信源信号与噪声的叠加,输出信号的概型由噪声确定,方差仍为 σ^2,均值分别为 0 和 1。故输入信号值为 0 和 1 而输出幅值为 x 的概密函数为

$$p(x \mid \omega_0) = \frac{1}{\sqrt{2\pi}\sigma}\exp\left[-\frac{x^2}{2\sigma^2}\right]$$

$$p(x \mid \omega_1) = \frac{1}{\sqrt{2\pi}\sigma}\exp\left[-\frac{(x-1)^2}{2\sigma^2}\right]$$

似然比为

$$l_{01}(x) = \frac{p(x \mid \omega_0)}{p(x \mid \omega_1)}\exp\left[\frac{1-2x}{2\sigma^2}\right]$$

运用最小损失准则,判决规则为

当 $x < \frac{1}{2} - \sigma^2\ln\left[\frac{(\lambda_{10}-\lambda_{11})}{(\lambda_{01}-\lambda_{00})}\frac{P(\omega_1)}{P(\omega_0)}\right]$ 时,判 $x \in \omega_0$,即信号为“0”;否则信号为“1”。

若取 $\lambda_{01} = \lambda_{10} = 1, \lambda_{00} = \lambda_{11} = 0, P(\omega_0) = P(\omega_1) = \frac{1}{2}$,则 $x < \frac{1}{2}$ 时,应判信号为“0”;$x > \frac{1}{2}$ 时应判信号为“1”。这和我们通常的习惯处理方法是一致的。

[例 4.2.2] 设正常细胞属于 ω_1 类,异常细胞属于 ω_2 类,它们的先验概率分别为 $P(\omega_1) = 0.9, P(\omega_2) = 0.1$。现有一个待识细胞,其观测特征矢量为 $\boldsymbol{x}$,从类概密曲线上查得 $p(\boldsymbol{x} \mid \omega_1) = 0.2, p(\boldsymbol{x} \mid \omega_2) = 0.4$,如果损失系数取为 $\lambda_{11} = 0, \lambda_{12} = 1, \lambda_{21} = 6, \lambda_{22} = 0$。试用最小误判概率准则和最小损失准则判断该细胞是正常的还是异常的。

解:由贝叶斯定理可以分别算出 ω_1 和 ω_2 的后验概率,即

$$P(\omega_1 \mid \boldsymbol{x}) = \frac{p(\boldsymbol{x} \mid \omega_1)P(\omega_1)}{\sum_{i=1}^{2} p(\boldsymbol{x} \mid \omega_i)P(\omega_i)} = \frac{0.2 \times 0.9}{0.2 \times 0.9 + 0.4 \times 0.1} = 0.818$$

$$P(\omega_2 \mid \boldsymbol{x}) = 1 - P(\omega_1 \mid \boldsymbol{x}) = 0.182$$

因 $P(\omega_1 \mid \boldsymbol{x}) = 0.818 > P(\omega_2 \mid \boldsymbol{x}) = 0.182$，所以把 $\boldsymbol{x}$ 归于正常细胞。

当依据损失进行判决时，需计算条件平均损失，即

$$R(\alpha_1 \mid \boldsymbol{x}) = \sum_{i=1}^{2} \lambda_{i1} P(\omega_i \mid \boldsymbol{x}) = \lambda_{21} P(\omega_2 \mid \boldsymbol{x}) = 1.092$$

$$R(\alpha_2 \mid \boldsymbol{x}) = \sum_{i=1}^{2} \lambda_{i2} P(\omega_i \mid \boldsymbol{x}) = \lambda_{12} P(\omega_1 \mid \boldsymbol{x}) = 0.818$$

取损失最小的判决，由于 $R(\alpha_1 \mid \boldsymbol{x}) > R(\alpha_2 \mid \boldsymbol{x})$，因此判 $\boldsymbol{x} \in \omega_2$。之所以这两个判决结果相反，是因为 λ_{21} 取得较大的缘故。

4.3 最小最大损失准则

前面讨论的最小损失判决，是在类先验概率已知、损失函数取定条件下的最佳判决。我们在具体运用判决规则时，是根据给定的 $\boldsymbol{x}$ 的似然函数相对确定的似然比阈值进行判决的，这相当于最佳判决域一旦分划后，在分类识别过程中就固定不变了。然而在实际中，各类先验概率 $P(\omega_i)$ 往往不能精确知道或在分类识别过程中是变动的，从而先前确定的判决域将不是最佳的，因此实际的平均损失要变大，甚至变得很大，所以应考虑如何解决在 $P(\omega_i)$ 不确知或变动的情况下平均损失变大的问题。按对策论的思想，应该立足在最差的情况下争取最好的结果，即最小化最大损失。

对于两类问题，设一种分类识别决策将特征空间 Ω 分划为两个判决域 D_1 和 D_2，记 λ_{ij} 为将实属 ω_i 类的模式判为 ω_j 的损失函数，各种判决的平均损失为

$$R = \int_{\Omega} R(\alpha(\boldsymbol{x}) \mid \boldsymbol{x}) p(\boldsymbol{x}) \mathrm{d}\boldsymbol{x}$$

$$= \int_{D_1} R(\alpha_1(\boldsymbol{x}) \mid \boldsymbol{x}) p(\boldsymbol{x}) \mathrm{d}\boldsymbol{x} + \int_{D_2} R(\alpha_2(\boldsymbol{x}) \mid \boldsymbol{x}) p(\boldsymbol{x}) \mathrm{d}\boldsymbol{x}$$

$$= \int_{D_1} \sum_{i=1}^{2} \lambda_{i1} p(\boldsymbol{x} \mid \omega_i) P(\omega_i) \mathrm{d}\boldsymbol{x} + \int_{D_2} \sum_{i=1}^{2} \lambda_{i2} p(\boldsymbol{x} \mid \omega_i) P(\omega_i) \mathrm{d}\boldsymbol{x}$$

$$= \lambda_{11} P(\omega_1) \int_{D_1} p(\boldsymbol{x} \mid \omega_1) \mathrm{d}\boldsymbol{x} + \lambda_{21} P(\omega_2) \int_{D_1} p(\boldsymbol{x} \mid \omega_2) \mathrm{d}\boldsymbol{x}$$

$$+ \lambda_{12} P(\omega_1) \int_{D_2} p(\boldsymbol{x} \mid \omega_1) \mathrm{d}\boldsymbol{x} + \lambda_{22} P(\omega_2) \int_{D_2} p(\boldsymbol{x} \mid \omega_2) \mathrm{d}\boldsymbol{x} \tag{4-3-1}$$

利用

$$P(\omega_2) = 1 - P(\omega_1)$$

$$\int_{D_1} p(\boldsymbol{x} \mid \omega_i) \mathrm{d}\boldsymbol{x} = 1 - \int_{D_2} p(\boldsymbol{x} \mid \omega_i) \mathrm{d}\boldsymbol{x}$$

则平均损失可写成

$$R = \lambda_{22} + (\lambda_{21} - \lambda_{22}) \int_{D_1} p(\boldsymbol{x} \mid \omega_2) \mathrm{d}\boldsymbol{x}$$

$$+ P(\omega_1) \left[(\lambda_{11} - \lambda_{22}) + (\lambda_{12} - \lambda_{11}) \int_{D_2} p(\boldsymbol{x} \mid \omega_1) \mathrm{d}\boldsymbol{x} \right.$$

$$\left. + (\lambda_{22} - \lambda_{21}) \int_{D_1} p(\boldsymbol{x} \mid \omega_2) \mathrm{d}\boldsymbol{x} \right]$$

$$\triangleq a + bP(\omega_1) \quad (a, b \text{ 为常数}) \tag{4-3-2}$$

由式(4-3-2)可看出，当类的概密$p(\boldsymbol{x} \mid \omega_i)$、概率$P(\omega_1)$已知、损失函数$\lambda_{ij}$选定时，相对这些条件确定最佳判决域$D_1$、$D_2$，当$P(\omega_1)$变化时，在判决域$D_i$不作相应调整情况下，平均损失$R$是$P(\omega_1)$的线性函数。另一方面，考虑$P(\omega_1)$的各种可能取值情况下的最佳判决，为此$P(\omega_1)$在区间(0,1)中取一系列不同的值，并分别按最小损失准则确定相应的最佳决策域D_1、D_2，计算出其相应的最小平均损失R^*，从而可得最小平均损失R^*与先验概率$P(\omega_1)$的关系曲线，如图4.3.1所示，可以看出，曲线是上凸的。在图4.3.1(a)中，曲线上A点的纵坐标值R_A^*是对应于先验概率$P_A(\omega_1)$的最小平均损失值，而过A点的R^*切线CD则对应上述的直线方程式(4-3-2)，直线上各点的纵坐标值对应于新的$P(\omega_1)$在原先(即针对$P_A(\omega_1)$最佳)判决域分划下计算的平均损失值，由于没有针对新的$P(\omega_1)$求最佳判决域D_1、D_2，故平均损

失值要比取最佳的 D_i 时的大，直线 CD 在曲线的上方说明了这一点，对于已取定的 D_1、D_2，由于 $P(\omega_1)$ 在 0 和 1 之间取值，所以平均损失值有 $a \leqslant R \leqslant a+b$。注意这里的 a，b 是相对 $P_A(\omega_1)$ 的最佳分划判决域算得的。由式(4-3-2)可以想到，如果能求出某个 $P(\omega_1) \triangleq P_B(\omega_1)$，相对于 $P_B(\omega_1)$ 的最佳判决域 D_1 和 D_2 能使该式中的 $b=0$，即

$$b = (\lambda_{11}-\lambda_{22}) + (\lambda_{12}-\lambda_{11})\int_{D_2} p(\boldsymbol{x} \mid \omega_1)\mathrm{d}\boldsymbol{x}$$

$$+ (\lambda_{22}-\lambda_{21})\int_{D_1} p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} = 0 \qquad (4-3-3)$$

在此决策域下，无论 $P(\omega_1)$ 如何变化，因 $b=0$ 而使 R 与 $P(\omega_1)$ 无关，从而使得平均损失 R 恒等于常数 a，即

$$R = \lambda_{22} + (\lambda_{21}-\lambda_{22})\int_{D_1} p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} = a \quad (4-3-4)$$

求使 $b=0$ 的 $P(\omega_1)$ 等价于在最小平均损失 $R^* \sim P(\omega_1)$ 关系中求使

$$\mathrm{d}R^*/\mathrm{d}P(\omega_1) = 0 \qquad (4-3-5)$$

的 $P(\omega_1)$，即找出使 R^* 取最大值的 $P(\omega_1)$，显然，此时的 $P(\omega_1)$ 使 R^* 取所有最小损失的最大值 R_{m}^*，R_{m}^* 是最大的最小损失。在图 4.3.1(b)中，过 B 点的切线对应 $b=0$ 时的直线，其纵坐标为 $R^*(P_B(\omega_1))$，与横轴平行，表示相对 $P_B(\omega_1)$ 求得的最佳决策域 D_i，不论 $P(\omega_1)$ 如何变化，都使平均损失值不变，$R \equiv R_{\mathrm{m}}^*$。由图 4.3.1(a) 可以看出，根据 $P_A(\omega_1)$ 设计最佳分类器，当实际概率为 $P_B(\omega_1)$ 时，其平均损失 $R(P_B(\omega_1))$ 要大于 $R^*(P_B(\omega_1))$，而其最大的可能损失是 D 点的幅值。从图也可以看出，R_{m}^* 是所有可能的最大损失最小值。

当以 $P(\omega_2)$ 作为考虑问题的变量，由问题表述的对称性或由式(4-3-3)，我们都可以得出式(4-3-4)的最小损失还等于

$$R = \lambda_{11} + (\lambda_{12}-\lambda_{11})\int_{D_2} p(\boldsymbol{x} \mid \omega_1)\mathrm{d}\boldsymbol{x}$$

式(4-3-3)可以写成

$$\lambda_{11} + (\lambda_{12}-\lambda_{11})\int_{D_2} p(\boldsymbol{x} \mid \omega_1)\mathrm{d}\boldsymbol{x} = \lambda_{22} + (\lambda_{21}-\lambda_{22})\int_{D_1} p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x}$$

$$(4-3-6)$$

特例，当 $\lambda_{11} = \lambda_{22} = 0$ 时，上式成为

$$\lambda_{12}\int_{D_2} p(\boldsymbol{x} \mid \omega_1)\mathrm{d}\boldsymbol{x} = \lambda_{21}\int_{D_1} p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} \qquad (4-3-7)$$

式(4-3-6)和式(4-3-7)通常称为最小最大损失准则的定义式。

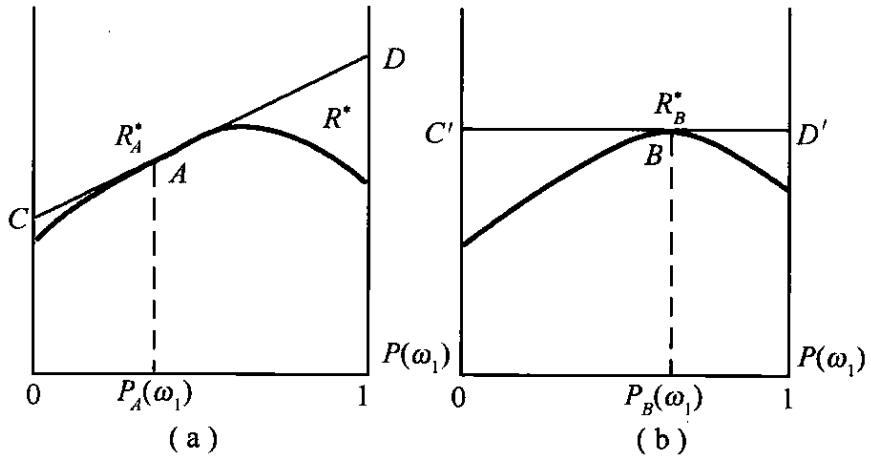


图 4.3.1　最小平均损失 R^* 与先验概率 $P(\omega_1)$ 的关系曲线及相对确定的 $P(\omega_1)$ 的最佳的分类器损失曲线

由上述分析可知，运用最小损失准则时，在不精确知道 $P(\omega_1)$ 或 $P(\omega_1)$ 变动的情况下，处理这类问题的原则是使最大的可能损失最小，为此应该选择最小损失 R^* 取最大值 R_m^* 时的 $P^*(\omega_1)$ 来设计分类器，其损失 R_m^* 相对于其他的 $P(\omega_1)$ 在最优设计下的 R^* 为最大，但却能保证当 $P(\omega_1)$ 在(0,1)中发生变化时，使相应的损失界定为 R_m^*，使最大损失最小，就是说在训练过程中取最小平均损失最大，而在运用时，可使最大的可能损失最小，所以称为最小最大损失判决。这是一种稳健(Robustness)的设计方法，也是偏于保守的设计方法，是对策论思想在分类器设计中的应用。

具体的设计过程是按最小损失准则找出对应于(0,1)中的各个不同值的 $P(\omega_1)$ 的最佳决策域 D_1、D_2，计算相应各个 $P(\omega_1)$ 及最佳决策域的最小平均损失，得 $R^* - P(\omega_1)$ 曲线，找出使 R^* 取最大值的 $P^*(\omega_1)$，最后运用 $P^*(\omega_1)$、$1 - P^*(\omega_1)$ 及 λ_{ij} 构造似然比阈值并运用最小损失准则下的决策规则对具体的模式分类识别。具体地讲，最小最大损失判决规则为

$$\text{如果}\frac{p(\boldsymbol{x}\mid\omega_1)}{p(\boldsymbol{x}\mid\omega_2)}\gtrless\frac{(\lambda_{21}-\lambda_{22})(1-P^*(\omega_1))}{(\lambda_{12}-\lambda_{11})P^*(\omega_1)}$$

$$\text{则判}\ \boldsymbol{x}\in\begin{cases}\omega_1\\ \omega_2\end{cases}$$

当在式(4-3-3)中采用0-1损失函数时,由 $b=0$ 可得

$$\int_{D_1}p(\boldsymbol{x}\mid\omega_2)\mathrm{d}\boldsymbol{x}=\int_{D_2}p(\boldsymbol{x}\mid\omega_1)\mathrm{d}\boldsymbol{x}\qquad(4-3-8)$$

式(4-3-8)表明,最小最大损失判决所导出的最佳分界面应使两类错误概率相等,由式(4-3-4)可知此时的平均损失

$$R=\int_{D_1}p(\boldsymbol{x}\mid\omega_2)\mathrm{d}\boldsymbol{x}\qquad(4-3-9)$$

显然,R 已与 $P(\omega_1)$ 无关,而是一个常数。

除了有几个定理为最小最大损失判决提供了可能方法外,在许多实际应用中也可以运用式(4-3-6)~式(4-3-8)求出判决阈值。

4.4 N-P(Neyman-Pearson)判决

在最小误判概率准则或最小损失准则判决中,我们的目标是使总的误判概率最小或总的平均损失最小,因此需要知道各类 $\omega_i(i=1,2,\cdots,c)$ 的后验概率 $P(\omega_i\mid\boldsymbol{x})$ 或各类的概密 $p(\boldsymbol{x}\mid\omega_i)$ 与各类的概率 $P(\omega_i)$ 及损失函数 λ_{ij},但在某些实际问题中,可能存在以下几种情况:① 不知道各类的先验概率 $P(\omega_i)$;② 难于确定误判的代价 λ_{ij};③ 某一种错误较另一种错误更为重要,即危害更为严重。针对①,可以采用最小最大损失准则或令各类概率相等的办法处理;针对②,如果允许的话,可以避开使用损失函数而采用最小误判概率准则。对上面的3个问题,更主要的是针对③,我们采用N-P准则。N-P准则是严格限制较重要的一类错误概率,在令其等于某常数的约束下使另一类误判概率最小。

对于两类问题,设 $p(\boldsymbol{x}\mid\omega_1)$ 和 $p(\boldsymbol{x}\mid\omega_2)$ 已知,又设有一判决界面将特征空间 Ω 分成两个判决类域 D_1 和 D_2,其中 $D_1\cup D_2=\Omega$,$D_1\cap D_2=\varnothing$。当一模式特征点 $\boldsymbol{x}\in D_1$ 时,指判 $\boldsymbol{x}\in\omega_1$;当 $\boldsymbol{x}\in D_2$ 时,指判 $\boldsymbol{x}\in\omega_2$。

于是,将实属 ω_1 类的模式 $\boldsymbol{x}$ 判属 ω_2 类的误判概率为

$$\varepsilon_{12} = \int_{D_2} p(\boldsymbol{x} \mid \omega_1)\mathrm{d}\boldsymbol{x} \tag{4-4-1}$$

将实属 ω_2 类的模式判属 ω_1 类的误判概率为

$$\varepsilon_{21} = \int_{D_1} p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} \tag{4-4-2}$$

采用 N - P 准则,不妨设 ε_{21} 为控制量,令 $\varepsilon_{21} = \varepsilon_0 =$ 常数,求使 ε_{12} 最小。运用拉格朗日乘数法求条件极值。作辅助函数

$$\begin{aligned} y &= \varepsilon_{12} + \lambda(\varepsilon_{21} - \varepsilon_0) \\ &= \int_{D_2} p(\boldsymbol{x} \mid \omega_1)\mathrm{d}\boldsymbol{x} + \lambda\left[\int_{D_1} p(\boldsymbol{x} \mid \omega_2)\mathrm{d}\boldsymbol{x} - \varepsilon_0\right] \\ &= (1 - \lambda\varepsilon_0) - \int_{D_1}(p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2))\mathrm{d}\boldsymbol{x} \end{aligned} \tag{4-4-3}$$

我们求 D_1 使 y 取极小值。一般地讲,D_1 无法直接用解析的办法求得。注意到 λ 在式子中是确定的,$p(\boldsymbol{x} \mid \omega_1)$、$p(\boldsymbol{x} \mid \omega_2)$ 在 Ω 空间中也是确定的,如果选择满足条件 $p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2) > 0$ 的 $\boldsymbol{x}$ 的全体作为 D_1^*,就能保证这时所求得的 y 值 y^* 比 D_1 的其他任何取法时的 y 值都要小。因为这种取法下,D_1^* 无论怎样分成一些子区域,在各子区域上的积分都是正值,而且 D_1^* 是使被积函数取正值的最大的域,而对于任何其他取法,ω_1 的新的判决类域 $D'_1 = (D_1^* - D_{11}) \cup D_{21}$,$D_1^*$ 如前定义,在 $D_{11} \subset D_1^*$ 上有 $p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2) > 0$,在 $D_{21} \subset D_2$ 上有 $p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2) < 0$,这时的 y 值为

$$\begin{aligned} y &= (1 - \lambda\varepsilon_0) - \int_{D_1^* - D_{11}}(p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2))\mathrm{d}\boldsymbol{x} \\ &\quad - \int_{D_{21}}(p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2))\mathrm{d}\boldsymbol{x} \\ &= y^* + \int_{D_{11}}(p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2))\mathrm{d}\boldsymbol{x} \\ &\quad - \int_{D_{21}}(p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2))\mathrm{d}\boldsymbol{x} \end{aligned} \tag{4-4-4}$$

γ 式中第二项的积分为正值，第三项的积分为负值，显然 $\gamma > \gamma^*$。类似地，

$$\gamma = (\lambda - \lambda\varepsilon_0) + \int_{D_2} (p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2)) \mathrm{d}\boldsymbol{x} \tag{4-4-5}$$

同理，要求选择满足条件 $p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2) < 0$ 的 $\boldsymbol{x}$ 的全体作为 D_2^*。将上面的两个结果综合起来可以得出，所求得的最佳判决域 D_1^* 和 D_2^* 应满足

$$\begin{aligned} &\text{在 } D_1^* \text{ 中} \quad p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2) > 0 \\ &\text{在 } D_2^* \text{ 中} \quad p(\boldsymbol{x} \mid \omega_1) - \lambda p(\boldsymbol{x} \mid \omega_2) < 0 \end{aligned} \tag{4-4-6}$$

于是，将其中一类错误概率作为控制量而使另一类错误概率最小的 N - P 判决规则为

$$\text{如果} \frac{p(\boldsymbol{x} \mid \omega_1)}{p(\boldsymbol{x} \mid \omega_2)} \gtrless \lambda, \text{则判 } \boldsymbol{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

上式中，λ 是判决阈值。可以看出，N - P 判决规则的形式和最小误判概率准则及最小损失准则的形式相同，只是似然比阈值不同。λ 的值决定着判决类域 D_1、D_2，这里的 λ 又是由 ε_0 所确定的，这就要求适当地选取 λ 使 $\varepsilon_{21} = \varepsilon_0$。为求 λ，令 $p(l \mid \omega_2)$ 为似然比 $l(\boldsymbol{x})$ 在 $\boldsymbol{x} \in \omega_2$ 的条件下的概密，因当 $l > \lambda$ 时就判 $\boldsymbol{x} \in \omega_1$，所以当 ε_0 给定后，拉格朗日乘子 λ 可由式

$$\varepsilon_{21} = \int_{\lambda}^{+\infty} p(l \mid \omega_2) dl = \varepsilon_0 \tag{4-4-7}$$

确定。实际上，难以由上式求得 λ 的解析显式，通常采用近似的办法。上式的积分是 λ 的单调减函数，给出一系列 λ 值，由上式可以相应地算得一系列 ε_{21} 值，总存在一个 λ 使 ε_{21} 最接近 ε_0，那个 λ 值便是我们所求的 λ 的近似值。当作得足够精细时，λ 近似值的精度就很高。在一些特殊情况下，$p(l \mid \omega_i)$ 容易确定，如正态分布。综上所述可知，在具体运用 N - P 准则时，首先根据给定的控制量 ε_0 由式(4-4-7) 计算门限 λ，然后运用判决规则进行判决分类。

图 4.4.1 所示为 N - P 准则判决原理示意图。

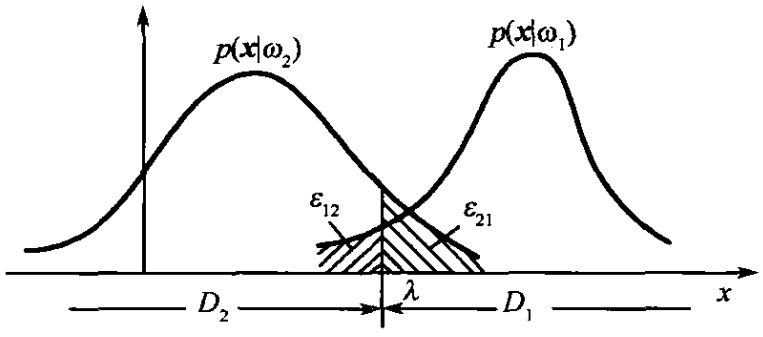


图 4.4.1　N - P 准则判决原理示意图

在信号检测中,正确识别出目标信号的概率称为检测概率 P_D,将背景或噪声信号当做目标信号的概率称为虚警概率 P_F,将目标信号当做背景或噪声信号的概率称为漏检概率。

对于给定的两类概率分布和取定的虚警概率,在单观测模式情况下,这相当于固定了漏检概率,但在多观测条件下,可以在虚警概率为常数的约束下,求使漏检概率最小。在雷达某些应用中,通常在固定虚警概率下使用 N - P 准则检测,这就是所谓的恒虚警检测。

通常决策规划的特性可以用受试工作特性曲线(ROC) 表示,二维坐标系的横轴为虚警概率 $P_F = \varepsilon_{21}$,纵轴为检测概率 $P_D = 1 - \varepsilon_{12}$。对于给定的两类概率分布及取定的阈值 μ,通过大量的实验可以得出 P_D 和 P_F,改变阈值 μ,P_D 和 P_F 也随之改变,从而可得当阈值 μ 变化时检测概率 P_D 与虚警概率 P_F 的关系曲线 - ROC,当改变两类分布如改变 $d' = |\mu_1 - \mu_2| / \sigma$ 时,便得到一族曲线,如图 4.4.2 所示,这些曲线过(0,0)点和(1,1) 点,d' 越大,曲线越靠近左上角,决策规划越好。

[**例 4.4.1**] 设两类问题中,二维模式均为正态分布,其均值矢量和协方差阵分别为:$\boldsymbol{\mu}_1 = (-1,0)^T$,$\boldsymbol{\mu}_2 = (1,0)^T$,$\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \boldsymbol{I}$,取定 $\varepsilon_{21} = 0.04$,试求 N - P 判决阈值。

解:由公式和给定的条件可算得两类的概密分别为

$$p(\boldsymbol{x} \mid \omega_1) = \frac{1}{2\pi}\exp[-((x_1+1)^2 + x_2^2)/2]$$

$$p(\boldsymbol{x} \mid \omega_2) = \frac{1}{2\pi}\exp[-((x_1+1)^2 + x_2^2)/2]$$

由上面二式可以算得

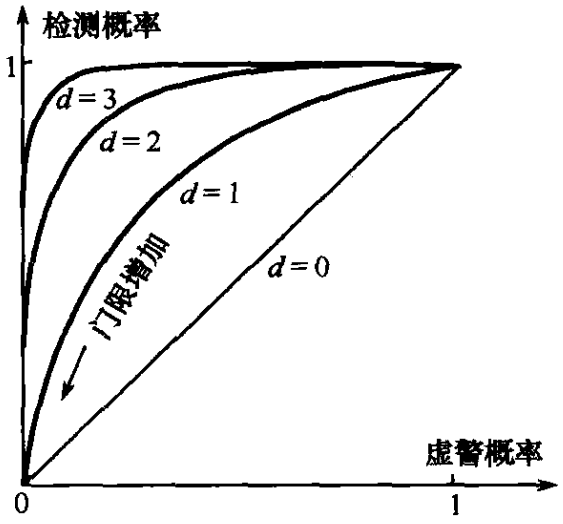


图 4.4.2　受试工作特性曲线(ROC)

$$\frac{p(\boldsymbol{x} \mid \omega_1)}{p(\boldsymbol{x} \mid \omega_2)} = \exp[-2x_1] = \lambda$$

其为判决界面,上式两边取对数,于是可得判决规则

$$x_1 \gtrless -\frac{1}{2}\ln\lambda \Rightarrow \boldsymbol{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

由于界面只是 x_1 的函数,需求 $p(\boldsymbol{x} \mid \omega_2)$ 的边缘密度 $p(x_1 \mid \omega_2)$,

$$\begin{aligned} p(x_1 \mid \omega_2) &= \int_{-\infty}^{\infty} p(\boldsymbol{x} \mid \omega_2)\,\mathrm{d}x_2 \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi}\exp[(-(x_1-1)^2 + x_2^2)/2]\,\mathrm{d}x_2 \\ &= \frac{1}{\sqrt{2\pi}}\exp[-(x_1-1)^2/2] \end{aligned}$$

由上面的判决规则,有

$$\begin{aligned} \varepsilon_{21} &= \int_{-\infty}^{-\frac{1}{2}\ln\lambda} \frac{1}{\sqrt{2}}\exp\left[\frac{-(x_1-1)^2}{2}\right]\mathrm{d}x_1 \\ &= \int_{-\infty}^{-\frac{1}{2}\ln\lambda - 1} \frac{1}{\sqrt{2}}\exp\left[\frac{-y^2}{2}\right]\mathrm{d}y \end{aligned}$$

上面的函数关系有数学用表可查。经查表,可算得 ε_{21} 与 λ 的关系如表 4.4.1 所列。

表 4.4.1　ε_{21} 与 λ 的关系

λ	4	2	1	1/2	1/4
ε_{21}	0.046	0.089	0.159	0.258	0.378

由设定的 $\varepsilon_{21}=0.04$，查表可得 $\lambda=4$，对应的 $-(\ln\lambda)/2=-0.693$，从而得此问题的判决规则为

$$若\ x_1 \gtrless -0.693，则判\ \boldsymbol{x}\in\begin{cases}\omega_1\\ \omega_2\end{cases}$$

类的分布及判决界面如图 4.4.3 所示。

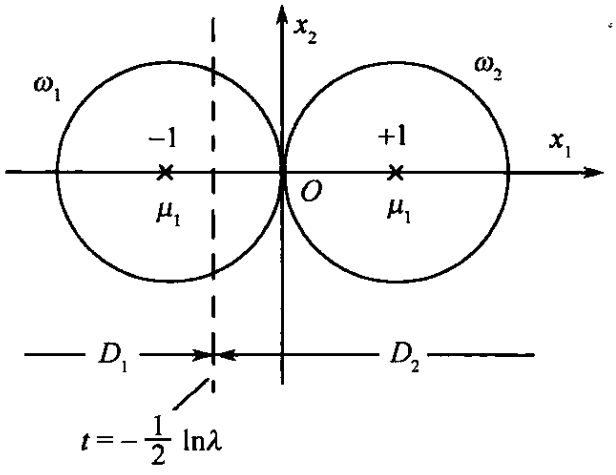


图 4.4.3　N－P 准则判决例题图示

4.5　序贯判决(SPRD)

前面所述的一些方法是在取得并使用 n 个特征后再考虑进行分类识别时的误判概率或误判损失，实际上，在特征获取上也要花费一定的代价。如果在判决时，可能有 k 个特征($k<n$)就能作出合理的判决，再加入其余 $n-k$ 个特征虽然可以使误判概率或损失降低，但其所减少的代价不足以补偿获得这 $n-k$ 个特征所花费的代价。

序贯判决是解决上述问题的一种很有用的统计决策方法。它可分为两种：一种是先用一部分特征参与判决，以后逐步地每次加入一个新的特征进行判决，在某一步中如能判决出模式的类别则对该模式判决结束；如不能判定，就增加新的特征继续判决，这样不断地重复下去，直到能作出判决为止，显然这种方法能节省人力、物力和机时。这种方法

在每一步都要衡量加入新特征所花费的代价与所降低分类损失的大小，以加入新特征所花费的代价大于所降低的分类损失作为停止的条件。在模式识别中，当增加一个特征分量要付出较大代价时，多采用这种方法。

4.5.1 控制误判概率的序贯判决

1. 判决规则

对于两类问题。在有些情况下，当似然比在似然比门限附近时，对 $\boldsymbol{x}$ 作出的类别判决将不那么可靠。为了提高判决的可靠性，可设置两个似然比门限 A、B，且 $0 < B < 1 < A < \infty$，这相当于将特征空间分划成 3 个子区域，在两个决策类域之外增加了一个“可疑区域”。当特征个数不足时，待识模式 $\boldsymbol{x}$ 类别属性不显著，则使 $\boldsymbol{x}$ 落入可疑区域 D_3，然后通过增加特征使该模式进入决策类域 D_1 或 D_2，从而可判决模式类别。

取 n 个特征中的 k 个特征 $x_1, x_2, \cdots, x_k$ 作特征矢量，令 $\boldsymbol{x}^{(k)} = (x_1, x_2, \cdots, x_k)^{\mathrm{T}}$，可以考虑关于这 k 个特征的似然比

$$l_{12}(\boldsymbol{x}^{(k)}) = \frac{p(x_1, x_2, \cdots, x_k \mid \omega_1)}{p(x_1, x_2, \cdots, x_k \mid \omega_2)} \triangleq \frac{p(\boldsymbol{x}^{(k)} \mid \omega_1)}{p(\boldsymbol{x}^{(k)} \mid \omega_2)} \tag{4-5-1}$$

称其为序贯似然比。

在序贯判决中，当序贯地加入新特征进行判决过程中，似然比门限是变动的，从而平均损失难于确定，因此不能运用最小损失准则进行分类，而采用 Wald 提出的方法。序贯判决规则为

(1) $l_{12}(\boldsymbol{x}^{(k)}) \geqslant A \Rightarrow \boldsymbol{x} \in \omega_1$；

(2) $l_{12}(\boldsymbol{x}^{(k)}) \leqslant B \Rightarrow \boldsymbol{x} \in \omega_2$；

(3) $B < l_{12}(\boldsymbol{x}^{(k)}) < A \Rightarrow \boldsymbol{x} \in D_3$，不能判决，对此模式增加一个特征，继续识别。

2. 门限的确定

令 ε_{12} 表示模式 $\boldsymbol{x}$ 实属 ω_1 但判定 $\boldsymbol{x} \in \omega_2$（即否定 $\boldsymbol{x} \in \omega_1$）的概率，$\varepsilon_{21}$ 表示 $\boldsymbol{x}$ 实属 ω_2 但判定 $\boldsymbol{x} \in \omega_1$（即否定 $\boldsymbol{x} \in \omega_2$）的概率。

因特征个数一旦达到能判决的数目 m 时，就可实施判决，令 D_1 为 ω_1 的判决域，D_2 为 ω_2 的判决域，于是有

$$\varepsilon_{21} = \int_{D_1} p(\boldsymbol{x}^{(m)} \mid \omega_2)\,\mathrm{d}\boldsymbol{x}^{(m)} \leqslant \int_{D_1} \frac{1}{A} p(\boldsymbol{x}^{(m)} \mid \omega_1)\,\mathrm{d}\boldsymbol{x}^{(m)}$$

由上有

$$A \leqslant \int_{D_1} p(\boldsymbol{x}^{(m)} \mid \omega_1)\,\mathrm{d}\boldsymbol{x}^{(m)} \Big/ \int_{D_1} p(\boldsymbol{x}^{(m)} \mid \omega_2)\,\mathrm{d}\boldsymbol{x}^{(m)}$$

从而可得

$$A \leqslant (1 - \varepsilon_{12})/\varepsilon_{21} \qquad (4-5-2\mathrm{a})$$

仿此也可以得出

$$B \geqslant \varepsilon_{12}/(1 - \varepsilon_{21}) \qquad (4-5-2\mathrm{b})$$

由上式可见，门限 A，B 与 ε_{12} 和 ε_{21} 有关，受两类的误判概率选取的控制。

为使分类判决具有所选定的两类误判概率 ε_{12}，ε_{21}，界限 A 和 B 必须满足上式。在设计分类器时，为减小虚警概率和漏板概率上面两式取等号

$$A = (1 - \varepsilon_{12})/\varepsilon_{21}$$

$$B = \varepsilon_{12}/(1 - \varepsilon_{21}) \qquad (4-5-3)$$

称其为停止边界。式中的 ε_{12} 和 ε_{21} 取预定的适当小的设计值 e_{12} 和 e_{21}，一些有代表性的值是 0.01，0.05，0.1，取满足上式的门限进行序贯判决时所产生的真实错误概率 ε_{12} 和 ε_{21} 由式(4-5-2) 和(4-5-3) 显然有关系

$$(1 - \varepsilon_{12})/\varepsilon_{21} \geqslant (1 - e_{12})/e_{21}$$

$$\varepsilon_{12}/(1 - \varepsilon_{21}) \leqslant e_{12}/(1 - e_{21}) \qquad (4-5-4)$$

上面两个不等式蕴含着

$$\varepsilon_{12} \leqslant e_{12}/(1 - e_{21})$$

$$\varepsilon_{21} \leqslant e_{21}/(1 - e_{12}) \qquad (4-5-5)$$

由于 e_{12}、e_{21} 很小，当 ε_{12} 或 ε_{21} 大于 e_{12} 或 e_{21} 时，不会大许多。将式(4-5-6) 两个不等式整理后相加，可以得到

$$\varepsilon_{12} + \varepsilon_{21} \leqslant e_{12} + e_{21} \tag{4-5-6}$$

上式表明，两类错误概率之和 $\varepsilon_{12} + \varepsilon_{21}$ 的上界是设计指标 e_{12} 与 e_{21} 之和 $e_{12} + e_{21}$。上式还表明，不等式 $\varepsilon_{12} \leqslant e_{12}$ 与 $\varepsilon_{21} \leqslant e_{21}$ 至少有一个成立，通常这两个不等式很可能都成立。

3. 特征个数的期望

因为在达到能够判决时我们使用的特征的数目是随机的，所以应该研究所用的特征数目的期望值。在可以作出判决时有如下 4 种情况其正确或错误概率为

$$\begin{aligned}
&① \ l_{12}(\boldsymbol{x}^{(k)}) \geqslant A \Rightarrow \boldsymbol{x} \in \omega_1, P(l_{12}(\boldsymbol{x}^{(k)}) \geqslant A \mid \boldsymbol{x} \in \omega_1) = 1 - \varepsilon_{12} \\
&② \ l_{12}(\boldsymbol{x}^{(k)}) \geqslant A \Rightarrow \boldsymbol{x} \in \omega_1, P(l_{12}(\boldsymbol{x}^{(k)}) \geqslant A \mid \boldsymbol{x} \in \omega_2) = \varepsilon_{21} \\
&③ \ l_{12}(\boldsymbol{x}^{(k)}) \leqslant B \Rightarrow \boldsymbol{x} \in \omega_2, P(l_{12}(\boldsymbol{x}^{(k)}) \leqslant B \mid \boldsymbol{x} \in \omega_1) = \varepsilon_{12} \\
&④ \ l_{12}(\boldsymbol{x}^{(k)}) \leqslant B \Rightarrow \boldsymbol{x} \in \omega_2, P(l_{12}(\boldsymbol{x}^{(k)}) \leqslant B \mid \boldsymbol{x} \in \omega_2) = 1 - \varepsilon_{21}
\end{aligned} \tag{4-5-7}$$

由上可得停止似然比的期望值为

$$\mathrm{E}[l_{12}(\boldsymbol{x}^{(k)})] = \begin{cases} A(1-\varepsilon_{12}) + B\varepsilon_{12} & (\text{若 } \boldsymbol{x} \in \omega_1) \\ A\varepsilon_{21} + B(1-\varepsilon_{21}) & (\text{若 } \boldsymbol{x} \in \omega_2) \end{cases} \tag{4-5-8a}$$

对似然比取对数，由式(4-5-7)，停止似然比期望值还可以表示为

$$\mathrm{E}[\ln(l_{12}(\boldsymbol{x}^{(k)}))] = \begin{cases} (1-\varepsilon_{12})\ln A + \varepsilon_{12}\ln B & (\text{若 } \boldsymbol{x} \in \omega_1) \\ \varepsilon_{21}\ln A + (1-\varepsilon_{21})\ln B & (\text{若 } \boldsymbol{x} \in \omega_2) \end{cases} \tag{4-5-8b}$$

为简单计，设对每一类各特征都是独立同分布的，则有

$$\ln[l_{12}(\boldsymbol{x}^{(k)})] = \ln\left[\prod_{j=1}^{k} l_{12}(\boldsymbol{x}_j)\right] = k\ln[l_{12}(x)] \tag{4-5-9}$$

对上式两边取条件期望，有

$$\mathrm{E}[\ln[l_{12}(\boldsymbol{x}^{(k)})] \mid \omega_i] = \mathrm{E}[k\ln[l_{12}(\boldsymbol{x})] \mid \omega_i]$$

$$= \mathrm{E}[k \mid \omega_i]\mathrm{E}[\ln[l_{12}(\boldsymbol{x})] \mid \omega_i] \tag{4-5-10}$$

从而有

$$\mathrm{E}[k \mid \omega_i] = \mathrm{E}[\ln[l_{12}(\boldsymbol{x}^{(k)})] \mid \omega_i] / \mathrm{E}[\ln[l_{12}(\boldsymbol{x})] \mid \omega_i] \tag{4-5-11}$$

利用停止对数似然比期望式(4-5-11b),可得特征个数的期望值

$$\mathrm{E}[k \mid \omega_1] = \frac{(1-\varepsilon_{12})\ln A + \varepsilon_{12}\ln B}{\mathrm{E}[\ln l_{12}(\boldsymbol{x}) \mid \omega_1]} \tag{4-5-12a}$$

$$\mathrm{E}[k \mid \omega_2] = \frac{\varepsilon_{21}\ln A + (1-\varepsilon_{21})\ln B}{\mathrm{E}[\ln l_{12}(\boldsymbol{x}) \mid \omega_2]} \tag{4-5-12b}$$

关于序贯判决所采用的特征数目的期望有如下定理:若限制两类错误概率,使满足

$$e_{12} \leqslant \alpha, e_{21} \leqslant \beta \quad (0 < \alpha, \beta < 1)$$

则序贯判决 SPRD(A,B) 使特征数目的期望 $\mathrm{E}[k \mid \omega_1]$ 和 $\mathrm{E}[k \mid \omega_2]$ 与任何其他序贯或固定特征个数的判决相比是最小的,其中 A,B 满足实际的错误概率 $\varepsilon_{12} = \alpha, \varepsilon_{21} = \beta$。尽管如此,为加快判决速度,还应首先选取主要特征。

在模式识别中,不能保证 $\mathrm{E}[\ln l_{12}(\boldsymbol{x}_j) \mid \omega_i]$ 与 j 无关,此时可用 $\min\limits_{j}[\mathrm{E}[\ln l_{12}(\boldsymbol{x}_j) \mid \omega_i]]$ 代替 $\mathrm{E}[\ln l_{12}(x) \mid \omega_i]$ 后运用式(4-5-15)来求 $\mathrm{E}[k \mid \omega_i]$ 的近似值。

一般情况下,$l_{12}(x)$ 落在 B 和 A 之间的概率总是小于 1,即

$$P(B < l_{12}(\boldsymbol{x}) < A) = p < 1$$

k 个特征的似然比全部落在 B 和 A 之间的概率

$$P(B < l_{12}(\boldsymbol{x}^{(k)}) < A) = p^k$$

因此,当 k 趋于无穷时,有

$$\lim_{k \to \infty} P(B < l_{12}(\boldsymbol{x}^{(k)}) < A) = 0$$

这表明,序贯判决是以概率 1 可停止的。在对具体的实际问题进行分类判决时,往往最多只能用有限个特征 $x_1, x_2, \cdots, x_n$,而序贯判决技术设

有两个门限，当 n 个特征全部用完后还有可能不能作出判决。为了克服这个缺点，可以将原来是常数的停止边界 A 和 B 取为所用特征个数 k 的函数，使当所有的特征都用上后有 $A = B$，这样就一定可以作出判决。例如我们可以取 A 和 B 有下面的关系

$$\ln A = \left(1 - \frac{k}{n}\right)^{r_1} \ln \frac{1 - e_{12}}{e_{21}}$$

$$\ln B = \left(1 - \frac{k}{n}\right)^{r_2} \ln \frac{e_{12}}{1 - e_{21}} \qquad (4-5-13)$$

其中 r_1 与 r_2 为两个任意的正数，$0 < r_1 < 1$，$0 < r_2 < 1$。显然当 $k = n$ 时，$A = B = 1$。

4.5.2 计入提取特征代价的最小损失准则下的序贯判决

在序贯判决中，设已取得并使用 k 个特征 $x_1, x_2, \cdots, x_k$，此时有两种选择：① 根据这些特征作出最后的分类判决；② 再选择第 $k+1$ 个特征 x_{k+1} 供下步决策用。这两种选择都要付出代价，显然我们应该根据哪个代价较小而进行选择。第 k 步的最小代价 $\rho_{\min}$ 定义为

$$\rho_{\min}(x_1, x_2, \cdots, x_k) = \min[\rho_s(x_1, x_2, \cdots, x_k), \rho_c(x_1, x_2, \cdots, x_k)] \qquad (4-5-14)$$

其中，$\rho_s(x_1, x_2, \cdots, x_k)$ 是根据已获得的 k 个特征 $x_1, x_2, \cdots, x_k$ 作出判决而产生的所谓停止损失，根据最小损失准则有

$$\rho_s(x_1, x_2, \cdots, x_k) = \min_j \left[\sum_{i=1}^{c} \lambda_{ij} P(\omega_i \mid x_1, x_2, \cdots, x_k) \right] \qquad (4-5-15)$$

式中：c 为类数；λ_{ij} 为实属 ω_i 类而判属 ω_j 类的损失函数；$\rho_c(x_1, x_2, \cdots, x_k)$ 表示再取第 $k+1$ 个特征而判决或继续取特征所产生的继续损失。

由于 x_{k+1} 在获得前是随机量，若取得 x_{k+1} 继续作序贯判决，第 $k+1$ 步的最小代价的期望值是

$$\int \rho_{\min}(x_1, x_2, \cdots, x_k, x_{k+1}) p(x_{k+1} \mid x_1, x_2, \cdots, x_k) \mathrm{d}x_{k+1} \qquad (4-5-16)$$

设获得第 $k+1$ 个特征所需的代价是 g_{k+1}，则第 k 步继续损失

$$\rho_c(x_1,x_2,\cdots,x_k)$$

$$= g_{k+1} + \int \rho_{\min}(x_1,x_2,\cdots,x_k,x_{k+1})p(x_{k+1} \mid x_1,x_2,\cdots,x_k)\,\mathrm{d}x_{k+1} \tag{4-5-17}$$

由上式可知，为了计算 $\rho_{\min}(x_1,x_2,\cdots,x_k)$，必须计算第 $k+1$ 步的最小损失，依此类推，所以应先求

$$\rho_{\min}(x_1,x_2,\cdots,x_k,x_{k+1},\cdots,x_n)$$

$$= \min_j \left[\sum_{i=1}^{c} \lambda_{ij} P(\omega_i \mid x_1,x_2,\cdots,x_k,x_{k+1},\cdots,x_n) \right] \tag{4-5-18}$$

才能得到第 k 步最小损失。在逐步增加特征过程中，当停止损失等于最小损失时就停止增加新的特征而作出判决。

显然，此方法计算量和存储量都很大，一个“次优”的办法是只考虑第 k 步之后有限的 r 步，即有限的 r 个特征（$k+r<n$），就是说决策一定停止在第 k 步和第 $k+r$ 步之间，这样计算工作量大大减少。为了减少序贯判决的步数，应按对分类识别贡献的大小对每个特征进行排序，首先选择贡献大的特征用于分类。

习　题

4.1　对于一个一维两类问题，考虑采用下列判决规则：如果 $x > \theta$，则判其属于 ω_1，否则判其属于 ω_2。

（1）证明此规则下的误判概率为

$$P(e) = P(\omega_1)\int_{-\infty}^{\theta} p(x \mid \omega_1)\,\mathrm{d}x + P(\omega_2)\int_{\theta}^{+\infty} p(x \mid \omega_2)\,\mathrm{d}x$$

（2）通过微分运算，证明最小化 $P(e)$ 的一个必要条件是 θ 满足

$$p(\theta \mid \omega_1)P(\omega_1) = p(\theta \mid \omega_2)P(\omega_2)$$

(3) 此式可以唯一确定 θ 吗?

(4) 给出一个例子说明满足此式的 θ 事实上有可能使误判概率最大化。

4.2 设 $\omega_{\max}(\boldsymbol{x})$ 为 $\boldsymbol{x}$ 的类别状态,此时对所有的 $i(i=1,\cdots,c)$,有 $P(\omega_{\max}\mid\boldsymbol{x})\geqslant P(\omega_i\mid\boldsymbol{x})$。

(1) 证明 $P(\omega_{\max}\mid\boldsymbol{x})\geqslant 1/c$。

(2) 证明对于最小误判概率准则判决,平均误判概率为

$$P(e)=1-\int P(\omega_{\max}\mid\boldsymbol{x})p(\boldsymbol{x})\mathrm{d}\boldsymbol{x}$$

(3) 利用这两个结论证明 $P(e)\leqslant(c-1)/c$。

(4) 描述一种情况,在此情况下有 $P(e)\leqslant(c-1)/c$。

4.3 考虑 n 维两类问题。设 $p(\boldsymbol{x}\mid\omega_i)\sim N(\boldsymbol{\mu}_i,\sigma^2\boldsymbol{I})$,且 $P(\omega_1)=P(\omega_2)=\dfrac{1}{2}$。

(1) 证明最小误判概率为

$$P(e)=\frac{1}{\sqrt{2\pi}}\int_a^{+\infty}\mathrm{e}^{-u^2/2}\mathrm{d}u$$

其中 $a=\|\boldsymbol{\mu}_2-\boldsymbol{\mu}_1\|/2\sigma$。

(2) 利用下面不等式证明,当 a 趋于无穷大时,$P(e)$ 趋于零。

$$P(e)=\frac{1}{\sqrt{2\pi}}\int_a^{+\infty}\mathrm{e}^{-u^2/2}\mathrm{d}u\leqslant\frac{1}{\sqrt{2\pi}a}\mathrm{e}^{-a^2/2}$$

(3) 令 $\boldsymbol{\mu}_1=\boldsymbol{0}$,且 $\boldsymbol{\mu}_2=(\mu_1,\cdots,\mu_n)\neq\boldsymbol{0}$。利用上面不等式证明,当维数 n 趋于无穷大时,$P(e)$ 趋于零。解释此结论的意义。

4.4 考虑 n 维两类问题。设两类分布为 $p(\boldsymbol{x}\mid\omega_1)\sim N(\boldsymbol{\mu}_i,\boldsymbol{\Sigma})$,两类具有相同的协方差,而有任意的均值和先验概率。对于平方 Mahalanobis 距离

$$r_i^2=(\boldsymbol{x}-\boldsymbol{\mu}_i)^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i)$$

(1) 证明 r_i^2 的梯度为

$$\nabla r_i^2=2\boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}_i)$$

(2) 证明某一给定通过 $\boldsymbol{\mu}_i$ 的直线上的任意一点处的梯度 ∇r_i^2 指向

相同的方向。此方向一定与该直线平行吗?

(3) 证明 ∇r_1^2 和 ∇r_2^2 指向与从 $\boldsymbol{\mu}_1$ 到 $\boldsymbol{\mu}_2$ 的直线相反的方向。

(4) 证明最优分类超平面与等密度超椭球面相切,切于该超平面分割从 $\boldsymbol{\mu}_1$ 到 $\boldsymbol{\mu}_2$ 的直线的点处。

4.5 设一维两类模式满足正态分布,它们的均值和方差分别为 $\mu_1 = 0$, $\sigma_1 = 2$, $\mu_2 = 2$, $\sigma_2 = 2$,令 $P(\omega_1) = P(\omega_2)$。绘出它们的概率密度曲线;取0-1损失函数,试算出判决边界点,试确定样本 -3, -2, 1,3,5 各属哪一类。

4.6 考虑一维 c 类问题。设各类均服从 Rayleigh 分布

$$p(x \mid \omega_i) = \begin{cases} \dfrac{x}{\sigma_i^2}\exp\left(\dfrac{-x^2}{2\sigma_i^2}\right) & (x > 0) \\ 0 & (x < 0) \end{cases}$$

取0-1损失函数,令 $P(\omega_i) = 1/c$,试导出贝叶斯最小损失判决函数。

4.7 考虑一维两类问题。设两类先验概率相等,且它们的类概率密度服从 Cauchy 分布

$$p(x \mid \omega_i) = \frac{1}{\pi b}\frac{1}{1 + \left(\dfrac{x - a_i}{b}\right)^2} \quad (i = 1,2)$$

试证分界点在 $\left|\dfrac{a_1 - a_2}{b}\right|$ 处,可使最小误判概率为

$$P(e) = \frac{1}{2} - \frac{1}{\pi}\arctan\left|\frac{a_1 - a_2}{2b}\right|$$

4.8 对 $\boldsymbol{\Sigma}_i = \sigma^2 \boldsymbol{I}$ 的特殊情况,证明

(1) 若 $P(\omega_i) \neq P(\omega_j)$,则超平面靠近先验概率较小的类;

(2) 在什么情况下,先验概率对超平面的位置影响不大。

4.9 对 $\boldsymbol{\Sigma}_i = \boldsymbol{\Sigma}$ 的特殊情况,指出在先验概率不等时,决策面沿 $\boldsymbol{\mu}_i$ 点和 $\boldsymbol{\mu}_j$ 点连线向先验概率小的方向移动。

4.10 证明在两类先验概率相等、损失函数相等及正态等协方差阵的情况下,Fisher 线性判别与贝叶斯判决是等价的。

4.11 在图像识别中，假定有灌木丛和坦克两种类型，它们的先验概率分别是0.7和0.3，损失函数如表4.1所列，其中，类型ω_1和ω_2分别表示灌木丛和坦克，判决$\alpha_1 = \omega_1, \alpha_2 = \omega_2, \alpha_3$表示拒绝判决。现在做了4次试验，获得4个样本的类概率密度如下：

$p(x \mid \omega_1)$	0.1	0.15	0.3	0.6
$p(x \mid \omega_2)$	0.8	0.7	0.55	0.3

(1) 试用贝叶斯最小误判概率准则判决4个样本各属于哪一个类型；

(2) 假定只考虑前两种判决，试用贝叶斯最小风险准则判决4个样本各属于哪一个类型；

(3) 把拒绝判决考虑在内，重新考核4次试验的结果。

表4.1

损失 / 类型 / 判决	ω_1	ω_2
α_1	0.5	2
α_2	4	1.0
α_3	1.5	1.5

4.12 假设二维两类正态分布参数为$\boldsymbol{\mu}_1 = (-1,0)^{\mathrm{T}}$，$\boldsymbol{\mu}_2 = (1,0)^{\mathrm{T}}$，先验概率相等，

(1) 令$\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 \equiv \boldsymbol{I}$，试给出负对数似然比判决规则；

(2) 令

$$\boldsymbol{\Sigma}_1 = \begin{bmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{bmatrix} \quad \boldsymbol{\Sigma}_2 = \begin{bmatrix} 1 & -\frac{1}{2} \\ -\frac{1}{2} & 1 \end{bmatrix}$$

试给出负对数似然比判决规则。

4.13 考虑二维两类问题，其中

$$p(\boldsymbol{x} \mid \omega_1) \sim N(\boldsymbol{0}, \boldsymbol{I}), \quad p(\boldsymbol{x} \mid \omega_2) \sim N\left(\begin{pmatrix} 1 \\ 1 \end{pmatrix}, \boldsymbol{I}\right)$$

且$P(\omega_1) = P(\omega_2) = \frac{1}{2}$。

(1) 计算贝叶斯判决边界。

(2) 计算误判概率界。

(3) 对同样的先验概率,但

$$p(\boldsymbol{x} \mid \omega_1) \sim N\left(\mathbf{0}, \begin{pmatrix} 20.5 \\ 0.52 \end{pmatrix}\right), \text{且} p(\boldsymbol{x} \mid \omega_2) \sim N\left(\begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}\right)$$

试计算贝叶斯判决边界和误判概率界。

4.14 考虑最小最大误判概率准则决策,令$\lambda_{11} = \lambda_{22} = 0$且$\lambda_{12} = \lambda_{21} = 1$。

(1) 证明在这种情况下判决区域将满足

$$\int_{D_2} p(\boldsymbol{x} \mid \omega_1) \mathrm{d}\boldsymbol{x} = \int_{D_1} p(\boldsymbol{x} \mid \omega_2) \mathrm{d}\boldsymbol{x};$$

(2) 此解是否是唯一的?如果不是,请构造一个简单的反例。

4.15 考虑两类问题最小最大误判概率准则决策。

(1) 解释为什么作为先验概率$P(\omega_1)$的函数的总贝叶斯风险一定要上凸;

(2) 假设有一维正态分布$p(x \mid \omega_i) \sim N(\mu_i, \sigma_i^2)(i = 1,2)$,但先验概率未知,在0 - 1风险下找到最优决策点x^*,以μ_i, σ_i的形式表示;

(3) 对于(2)中所得的决策点,总极小化极大风险是多少?用误差函数erf(·)的形式表示此风险;

(4) 假设$p(\boldsymbol{x} \mid \omega_1) \sim N(0,1)$且$p(\boldsymbol{x} \mid \omega_2) \sim N(1/2, 1/4)$,在0 - 1风险下找到$x^*$和总的极小化极大损失;

(5) 假设$p(\boldsymbol{x} \mid \omega_1) \sim N(5,1)$且$p(\boldsymbol{x} \mid \omega_2) \sim N(6,1)$,不作任何显式的计算,确定最小最大误判概率准则决策下的x^*,并说明原因。

4.16 考虑一维两类问题。设各类正态分布$p(x \mid \omega_i) \sim N(\mu_i \sigma_i^2)$,且$P(\omega_i) = 1/2(i = 1,2)$,为了方便,设$\mu_2 > \mu_1$,运用Neyman - Pearson准则。

(1) 假设当一样本实属ω_1,却被认为是ω_2时的最大可接受的误判概率为ε_{12},试确定判决边界点;

(2) 对于此边界点,将ω_2错分为ω_1的误判概率是多少?

(3) 总误判概率是多少?

(4) 将你的结论应用于特殊情况:$p(x \mid \omega_1) \sim N(-1,1)$ 及 $p(x \mid \omega_2) \sim N(1,1)$,且 $\varepsilon_{12} = 0.05$;

(5) 将上述结论与最小误判概率准则判决的误判概率作比较。

4.17 考虑两个一维两类问题。设各类柯西分布为

$$p(x \mid \omega_i) = \frac{1}{\pi b_i} \cdot \frac{1}{1 + \left(\frac{x - a_i}{b_i}\right)^2} \quad (i = 1,2)$$

为了简化,设 $a_2 > a_1$,宽度 b_i 相同,且先验概率相等,运用 Neyman - Pearson 准则。

(1) 假设当一样本实属 ω_1,却被认为是 ω_2 时的最大可接受的误判概率为 ε_{12},试确定判决边界点;

(2) 对于此边界点,将 ω_2 错分为 ω_1 的误判概率是多少?

(3) 总误判概率是多少?

(4) 将你的结论应用于特殊情况:$b = 1$ 且 $a_1 = -1, a_2 = 1$ 且 $\varepsilon_{12} = 0.1$;

(5) 将上述结论与最小误判概率准则判决的误判概率作比较。

4.18 设矢量 $\boldsymbol{x} = (x_1, \cdots, x_n)'$ 的分量为 0 或 1 二值的,且设 $P(\omega_j)$ 为类别状态 ω_j 的先验概率,$j = 1, \cdots, c$。现定义

$$p_{ij} = P(x_i = 1 \mid \omega_j) \quad \begin{matrix}(i = 1, \cdots, n) \\ (j = 1, \cdots, c)\end{matrix}$$

且对于 ω_j 中所有 $\boldsymbol{x}$,其分量 x_i 是统计独立的。证明最小误判概率通过下面的判定规则获得:如果 $d_k(\boldsymbol{x}) \geqslant d_j(\boldsymbol{x})$, $\forall j$,则判 $\boldsymbol{x}$ 属于 ω_k,其中

$$d_j(\boldsymbol{x}) = \sum_{i=1}^{n} x_i \ln \frac{p_{ij}}{1 - p_{ij}} + \sum_{i=1}^{n} x_i \ln(1 - p_{ij}) + \ln P(\omega_j)$$

4.19 设 $\boldsymbol{x}$ 的分布同第 4.18 题且 $c = 2$,n 为奇数,

$$p_{i1} = p > 1/2 (i = 1, \cdots, n)$$

$$p_{i2} = 1 - p (i = 1, \cdots, n)$$

且 $P(\omega_1) = P(\omega_2) = \frac{1}{2}$。

(1) 证明最小误判概率判决规则变为

如果 $\sum_{i=1}^{n} x_i > \frac{n}{2}$，则判为 ω_1；否则判为 ω_2；

(2) 证明最小误判概率为

$$P_e(n,p) = \sum_{k=0}^{(n-1)/2} \binom{n}{k} p^k (1-p)^{n-k}$$

其中：$\binom{n}{k} = n!/(k!(n-k)!)$ 为二项式系数。

4.20 在关于损失 $\lambda_{12} > \lambda_{11}$ 且 $\lambda_{21} > \lambda_{22}$ 的假设下，证明在独立二元情况下的一般最小风险判别函数为 $d(\boldsymbol{x}) = \boldsymbol{w}'\boldsymbol{x} + w_{n+1}$，其中

$$\boldsymbol{w} = (w_1, \cdots, w_n)', w_i = \ln \frac{p_i(1-q_i)}{q_i(1-p_i)}$$

$$w_{n+1} = \sum_{i=1}^{n} \ln \frac{1-p_i}{1-c} + \ln \frac{P(\omega_1)}{P(\omega_2)} + \ln \frac{\lambda_{12} - \lambda_{11}}{\lambda_{21} - \lambda_{22}}$$

算法编程

以下部分练习使用表 4.2 的数据。

表 4.2

样本	ω_1			ω_2			ω_3		
	x_1	x_2	x_3	x_1	x_2	x_3	x_1	x_2	x_3
1	-5.01	-8.12	-3.68	-0.91	-0.18	-0.05	5.35	2.26	8.13
2	-5.43	-3.48	-3.54	1.30	-2.06	-3.53	5.12	3.22	-2.66
3	1.08	-5.52	1.66	-7.75	-4.54	-0.95	-1.34	-5.31	-9.87
4	0.86	-3.78	-4.11	-5.47	0.50	3.92	4.48	3.42	5.19
5	-2.67	0.63	7.39	6.14	5.72	-4.85	7.11	2.39	9.21

4.1 下面的几道题可能会用到如下的程序：

(1) 编写一个程序使能产生服从 n 维正态分布 $N(\boldsymbol{\mu},\boldsymbol{\Sigma})$ 的随机样本；

(2) 编写一个程序计算一给定正态分布及先验概率 $P(\omega_i)$ 的判别函数；

(3) 编写一个程序计算任意两个点间的欧氏距离；

(4) 在给定协方差矩阵 $\boldsymbol{\Sigma}$ 的情况条件下，编写一个程序计算任意一点 $\boldsymbol{x}$ 到均值 $\boldsymbol{\mu}$ 间的马氏距离。

4.2 考虑将上面表格中的 10 个样本进行分类，假设分布是正态的。

(1) 假设前面两个类别的先验概率相等：$p(\omega_1) = p(\omega_2) = \frac{1}{2}$，且 $p(\omega_3) = 0$，仅利用 x_1 特征值为这两类判别设计一个分类器；

(2) 确定样本的经验误判率；

(3) 利用 Bhattacharyya 界来界定对该分布所产生的新模式进行分类会产生的误差；

(4) 现在利用两个特征值 x_1 和 x_2，重复以上各步；

(5) 利用所有 3 个特征值重复以上各步；

(6) 讨论所得的结论。特别是，对于一有限的数据集，是否有可能在更高的数据维数下经验误差会增加？

4.3 根据以下步骤测试经验误差是如何接近或不接近 Bhattacharyya 界的：

(1) 考虑正态分布

$$p(\boldsymbol{x}\mid\omega_1) \sim N\left(\begin{pmatrix}1\\0\end{pmatrix},\boldsymbol{I}\right)\text{和}\ p(\boldsymbol{x}\mid\omega_2) \sim N\left(\begin{pmatrix}-1\\0\end{pmatrix},\boldsymbol{I}\right)$$

且 $p(\omega_1) = p(\omega_2) = \frac{1}{2}$。说明贝叶斯判决边界；

(2) 利用程序产生服从均值为 $\boldsymbol{\mu}$ 和协方差矩阵 $\boldsymbol{\Sigma}$ 的正态分布的 n 维样本；

(3) 产生 $N = 100$ 个点(50 个 ω_1 类的点，50 个 ω_2 类的点)，并计算经验误判率；

(4) 不断增加的 N 值重复以上步骤，$100 \leqslant N \leqslant 1000$，步长量为100，并绘出所得的经验误判率；

(5) 讨论所得的结论。特别是，经验误判率是否可能比Bhattacharyya或Chernoff界还大？

第 5 章　统计决策中的经典学习方法

5.1　统计推断概述

在贝叶斯决策中，需要知道类的概率密度 $p(\boldsymbol{x} \mid \omega_i)$、类的先验概率 $P(\omega_i)$ 或后验概率 $P(\omega_i \mid \boldsymbol{x})$，但在实际应用中，这些知识往往是不知道或不完全知道的，这就需要根据来自这一类的模式或称样本确定它们，这项工作称为训练或学习。用同一类的样本直接确定分类界面也是一种学习。

设模式空间 Ω 是 n 维的。一个模式类称为一个总体或母体，$p(\boldsymbol{x} \mid \omega_i)$、$P(\omega_i)$、$P(\omega_i \mid \boldsymbol{x})$、数学期望、方差等称为总体的理论分布或理论量；一个模式类中某些模式（即母体中的一些元素）的集合称为这个母体的子样，母体的子样含有母体的某些信息，可以通过构造样本的函数来获得，由样本构造的函数称为统计量，由样本推断的分布称为经验分布。如果已知 ω_i 类的概密 $p(\boldsymbol{x} \mid \omega_i)$ 的函数类型，即知道 ω_i 类的概型，但不知道其中的某些或全部参数 $\{\theta_i\} \triangleq \boldsymbol{\theta} = (\theta_1, \theta_1, \cdots, \theta_m)^{\mathrm{T}}$，可采用参数估计的方法确定未知参数 $\boldsymbol{\theta}$，当解得这些参数后 $p(\boldsymbol{x} \mid \omega_i)$ 也就完全确定了。参数估计有两类方法，一类方法是将参数作为非随机量处理，如矩法估计、最大似然估计就属这类方法，另一类方法是将参数作为随机变量，贝叶斯估计就属此类。当不知道类的概型时，就要采用非参数估计的方法，这种方法也称为总体推断，这类方法有 P - 窗法、有限项正交函数级数逼近法、随机逼近法等。为了准确地对某一类的分布进行参数估计或总体推断，应只使用该类的样本，即在各类内对该类独立进行参数估计或总体推断。因此在以后的论述中，如无必要，不特别言明类别。

所谓估计就是由样本 $\boldsymbol{x}_j (j = 1, 2, \cdots, N)$ 按某种规则构造一个统计

量 $\hat{\boldsymbol{\theta}}_N = \boldsymbol{\theta}(\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N)$，用 $\hat{\boldsymbol{\theta}}_N$ 的值作为被估参数集 $\boldsymbol{\theta}$ 的近似值。估计量 $\hat{\boldsymbol{\theta}}_N$ 作为随机样本的函数，显然也是随机量。下面给出应用统计的观点来衡量估计量性质优劣的一些标准。

我们希望估计量 $\hat{\boldsymbol{\theta}}_N$ 无系统误差，其所取的值围绕真值摆动。用术语讲就是希望估计量是无偏估计，估计量 $\hat{\boldsymbol{\theta}}_N$ 的数学期望等于被估量 $\boldsymbol{\theta}$ 的数学期望，即 $\mathrm{E}[\hat{\boldsymbol{\theta}}_N] = \mathrm{E}[\boldsymbol{\theta}]$。估计无偏性的意义在于可以用多个估计值的平均近似真值。当不能有 $\mathrm{E}[\hat{\boldsymbol{\theta}}_N] = \mathrm{E}[\boldsymbol{\theta}]$ 时，希望估计量 $\hat{\boldsymbol{\theta}}_N$ 是渐近无偏估计，即 $\lim\limits_{N\to\infty} \mathrm{E}[\hat{\boldsymbol{\theta}}_N] = \mathrm{E}[\boldsymbol{\theta}]$。同时，也希望在无偏的基础上，估计量随机摆幅（偏差）越小越好，即估计量的方差越小越好。设 $\hat{\boldsymbol{\theta}}_N^*$ 和 $\hat{\boldsymbol{\theta}}_N$ 是 $\boldsymbol{\theta}$ 的两个估计，如果 $\mathrm{E}[(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_N^*)(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_N^*)^{\mathrm{T}}] < \mathrm{E}[(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_N)(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_N)^{\mathrm{T}}]$，则称 $\hat{\boldsymbol{\theta}}_N^*$ 比 $\hat{\boldsymbol{\theta}}_N$ 有效。一般的提法是，在无偏估计条件下，$\hat{\boldsymbol{\theta}}_N^*$ 都比其他的估计 $\hat{\boldsymbol{\theta}}_N$ 的方差要小（或相等），也就是说 $\mathrm{Var}[\hat{\boldsymbol{\theta}}_N^*] \leqslant \mathrm{Var}[\hat{\boldsymbol{\theta}}_N]$，则称 $\hat{\boldsymbol{\theta}}_N^*$ 是最小方差无偏估计量。在无偏条件下，估计量的方差越小，一个估计值的信用度就越大。如果不能有这样的良好性能，那么我们希望随着训练样本的增多，估计的效果越来越好，即估值具有良好的逼近特性。这方面有下面几个主要概念：若 $\lim\limits_{N\to\infty} \mathrm{Var}[\hat{\boldsymbol{\theta}}_N] = \boldsymbol{0}$，则称 $\hat{\boldsymbol{\theta}}_N$ 是均方收敛的；若 $\lim\limits_{N\to\infty} \mathrm{E}[(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_N)(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_N)^{\mathrm{T}}] = \boldsymbol{0}$，则称 $\hat{\boldsymbol{\theta}}_N$ 是均方逼近 $\boldsymbol{\theta}$ 或均方收敛于 $\boldsymbol{\theta}$；当样本无限增多时，估计量 $\hat{\boldsymbol{\theta}}_N$ 依概率收敛于 $\boldsymbol{\theta}$，即 $\lim\limits_{N\to\infty} P(\|\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta}\| > \varepsilon) = 0$，则称 $\hat{\boldsymbol{\theta}}_N$ 是一致估计或相合估计。若 $\hat{\boldsymbol{\theta}}_N$ 均方收敛于 $\boldsymbol{\theta}$，这时 $\hat{\boldsymbol{\theta}}_N$ 也是相合估计。可以证明，当估计是无偏时，上述关于方差的估计的各渐近概念实际上是等价的。无偏估计不一定存在，若存在也不一定唯一，无偏估计不一定是好的估计。相合性是对估计的一个最基本的要求。一个好的估计应是无偏的、最小方差的、相合的。

由样本构造出总体的概密估计式、概率估计式称为总体推断。在整个特征空间中，当我们将任一点处的概密估计也视作“数”的估计，类似上述参数估计的评价标准，也可以定义总体推断的评价标准。例如，

设$\boldsymbol{X}_1,\boldsymbol{X}_2,\cdots,\boldsymbol{X}_N$是从概密为$p(\boldsymbol{x})$的总体中独立抽取的$N$个随机矢量，根据这些随机矢量的测量值$\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$估计$p(\boldsymbol{x})$，如果

$$\mathrm{E}[\hat{p}(\boldsymbol{x})] = p(\boldsymbol{x})$$

则称$\hat{p}(\boldsymbol{x})$是无偏的，其中

$$\mathrm{E}[\hat{p}(\boldsymbol{x})] = \int \hat{p}(\boldsymbol{x} \mid \boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N)p(\boldsymbol{x}_1)\cdots p(\boldsymbol{x}_N)\,\mathrm{d}\boldsymbol{x}_1\cdots\mathrm{d}\boldsymbol{x}_N$$

5.2 参数估计

若由样本集可以求出$p(\boldsymbol{x}\mid\boldsymbol{\theta})$中的$\boldsymbol{\theta}$的唯一解，则称$p(\boldsymbol{x}\mid\boldsymbol{\theta})$中的$\boldsymbol{\theta}$是可辨识的，有唯一解的含义是，若$\boldsymbol{\theta}\neq\boldsymbol{\theta}'$，就存在$\boldsymbol{x}$使$p(\boldsymbol{x}\mid\boldsymbol{\theta})\neq p(\boldsymbol{x}\mid\boldsymbol{\theta})'$；若$p(\boldsymbol{x}\mid\boldsymbol{\theta})$的$\boldsymbol{\theta}$有两个或更多的解，则称$\boldsymbol{\theta}$是不可辨识的，$\boldsymbol{\theta}$有多解的含义是，对于不同的$\boldsymbol{\theta}$有完全相同的$p(\boldsymbol{x}\mid\cdot)$；若$\boldsymbol{\theta}$无法求出，则称$\boldsymbol{\theta}$是完全不可辨识的。从本质上讲，$\boldsymbol{\theta}$是可辨识的是对象内在的性质，与方法无关。不可辨识问题常与离散分布有关，或未知参数多于独立方程的个数，我们接触的大多数问题都是可辨识的。下面给出的方法总是假定问题是可辨识的。

5.2.1 均值矢量和协方差阵的矩法估计

所谓矩法估计就是用样本（的统计）矩作为总体（理论）矩的估值。若类的概型为正态分布，用矩法估计出类的均值矢量和协方差阵后，类的概密也就完全确定了。下面利用属于ω_i类的样本$\boldsymbol{x}_j(j=1,2,\cdots,N)$对该类的均矢和协方差阵进行估计。

设模式$\boldsymbol{x}=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}$，$\boldsymbol{x}\in\omega_i$类，$\omega_i$类总体$\boldsymbol{x}$概密为$p(\boldsymbol{x}\mid\omega_i)\triangleq p(\boldsymbol{x})$，则其均矢定义为

$$\boldsymbol{\mu}=\mathrm{E}[\boldsymbol{x}]=\int_{\Omega}\boldsymbol{x}p(\boldsymbol{x})\mathrm{d}\boldsymbol{x}\triangleq(\boldsymbol{\mu}_1,\boldsymbol{\mu}_2,\cdots,\boldsymbol{\mu}_n)^{\mathrm{T}} \qquad (5-2-1)$$

式中：Ω为特征空间。

设$\boldsymbol{x}_j(j=1,2,\cdots,N)$是这个类的$N$个样本，则总体$\boldsymbol{x}$的均矢$\boldsymbol{\mu}$的无偏估计为

$$\hat{\boldsymbol{\mu}} = \frac{1}{N}\sum_{j=1}^{N}\boldsymbol{x}_j \tag{5-2-2}$$

k 阶原点矩估计为

$$\hat{\mu}^k = \frac{1}{N}\sum_{j=1}^{N}(\boldsymbol{x}_j)^k$$

k 阶中心矩估计为

$$\hat{\boldsymbol{v}}^k = \frac{1}{N}\sum_{j=1}^{N}(\boldsymbol{x}_j - \hat{\boldsymbol{\mu}})^k$$

总体 $\boldsymbol{x}$ 的协方差阵定义为

$$\boldsymbol{\Sigma} = \mathrm{E}[(\boldsymbol{x}-\boldsymbol{\mu})(\boldsymbol{x}-\boldsymbol{\mu})^{\mathrm{T}} = \mathrm{E}[\boldsymbol{x}\boldsymbol{x}^{\mathrm{T}}] - \boldsymbol{\mu}\boldsymbol{\mu}^{\mathrm{T}}$$

$\boldsymbol{\Sigma}$ 是一个对称的矩阵，记

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_{11}^2 & \sigma_{12}^2 & \cdots & \sigma_{1n}^2 \\ \sigma_{21}^2 & \sigma_{22}^2 & \cdots & \sigma_{2n}^2 \\ \vdots & \vdots & \vdots & \vdots \\ \sigma_{n1}^2 & \sigma_{n2}^2 & \cdots & \sigma_{nn}^2 \end{pmatrix} \tag{5-2-3}$$

其中

$$\begin{aligned} \sigma_{kl}^2 &= \mathrm{E}[(\boldsymbol{x}_k - \boldsymbol{\mu}_k)(\boldsymbol{x}_l - \boldsymbol{\mu}_l)] \\ &= \iint_{-\infty}^{\infty}(\boldsymbol{x}_k - \boldsymbol{\mu}_k)(\boldsymbol{x}_l - \boldsymbol{\mu}_l)p(\boldsymbol{x}_k, \boldsymbol{x}_l)\mathrm{d}\boldsymbol{x}_k\mathrm{d}\boldsymbol{x}_l \end{aligned} \tag{5-2-4}$$

由 ω_i 类的 N 个样本 $\boldsymbol{x}_j(j = 1,2,\cdots,N)$ 所求得的 $\boldsymbol{\Sigma}$ 的矩法估计为

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{N}\sum_{j=1}^{N}(\boldsymbol{x}_j - \hat{\boldsymbol{\mu}})(\boldsymbol{x}_j - \hat{\boldsymbol{\mu}})^{\mathrm{T}} \tag{5-2-5a}$$

$\boldsymbol{\Sigma}$ 的修正无偏估计为

$$\hat{\boldsymbol{\Sigma}} = \boldsymbol{C}\frac{1}{N-1}\sum_{j=1}^{N}(\boldsymbol{x}_j - \hat{\boldsymbol{\mu}})(\boldsymbol{x}_j - \hat{\boldsymbol{\mu}})^{\mathrm{T}} \tag{5-2-5b}$$

为节省计算时间和存储空间，可采用递推方法计算。下面给出均矢和协方差阵估计的递推式。设 $\boldsymbol{m}(N)$ 和 $\boldsymbol{C}(N)$ 是由 N 个样本估得的均矢和协方差阵，若再加入一个新的样本 $\boldsymbol{x}_{N+1}$ 进行估算，则有

$$\boldsymbol{m}(N+1) = \frac{1}{N+1}\sum_{j=1}^{N+1}\boldsymbol{x}_j = \frac{1}{N+1}\left(\sum_{j=1}^{N}\boldsymbol{x}_j + \boldsymbol{x}_{N+1}\right)$$

$$= \frac{1}{N+1}(N\boldsymbol{m}(N) + \boldsymbol{x}_{N+1})$$

$$= \boldsymbol{m}(N) + \frac{1}{N+1}(\boldsymbol{x}_{N+1} - \boldsymbol{m}(N)) \qquad (5-2-6)$$

它的初始值

$$\boldsymbol{m}(1) = \boldsymbol{x}_1$$

记 $\boldsymbol{m}(N) = \boldsymbol{m}_N$,依定义

$$\boldsymbol{C}(N+1) = \frac{1}{N}\sum_{j=1}^{N+1}(\boldsymbol{x}_j - \boldsymbol{m}_{N+1})(\boldsymbol{x}_j - \boldsymbol{m}_{N+1})^{\mathrm{T}}$$

$$= \frac{1}{N}\sum_{j=1}^{N}(\boldsymbol{x}_j - \boldsymbol{m}_{N+1})(\boldsymbol{x}_j - \boldsymbol{m}_{N+1})^{\mathrm{T}}$$

$$+ \frac{1}{N}(\boldsymbol{x}_{N+1} - \boldsymbol{m}_{N+1})(\boldsymbol{x}_{N+1} - \boldsymbol{m}_{N+1})^{\mathrm{T}}$$

$$= \frac{1}{N}\left[\sum_{j=1}^{N}(\boldsymbol{x}_j - \boldsymbol{m}_N)(\boldsymbol{x}_j - \boldsymbol{m}_N)^{\mathrm{T}}\right.$$

$$+ \frac{1}{(N+1)^2}(\boldsymbol{x}_{N+1} - \boldsymbol{m}_N)(\boldsymbol{x}_{N+1} - \boldsymbol{m}_N)^{\mathrm{T}}$$

$$\left. + \frac{N^2}{(N+1)^2}(\boldsymbol{x}_{N+1} - \boldsymbol{m}_N)(\boldsymbol{x}_{N+1} - \boldsymbol{m}_N)^{\mathrm{T}}\right]$$

$$= \frac{N-1}{N}\boldsymbol{C}(N) + \frac{1}{N+1}(\boldsymbol{x}_{N+1} - \boldsymbol{m}_N)(\boldsymbol{x}_{N+1} - \boldsymbol{m}_N)^{\mathrm{T}}$$

$$(5-2-7)$$

上面推导中,利用了式(5-2-6)。易知取

$$\boldsymbol{C}(1) = \boldsymbol{0}$$

矩法估计只能用于各阶矩的估计,样本统计矩是相应的总体理论矩的相合估计量,对于原点矩的估计是无偏,但对中心矩的估计一般不是无偏估计量。矩法估计算法简单但优良性较差,宜用于样本容量 N 较大的情况,以保证它的优良性。矩法估计对二项分布,Poisson 分布,正态分布等均矢估计都有好的效果。

5.2.2 最大似然估计(MLE)

最大似然估计也是将被估计量作为确定性的。矩法估计在计算时不需要总体的概型,而最大似然估计须要总体概型即概密的具体函数形式。最大似然估计适用范围比矩法估计更宽一些。

设总体 $\boldsymbol{x}$ 的概密函数为 $p(\boldsymbol{x};\boldsymbol{\theta})$,因 $\boldsymbol{\theta}$ 是确定的参数集,故 $p(\boldsymbol{x};\boldsymbol{\theta})$ 是以 $\boldsymbol{\theta}$ 为参数关于 $\boldsymbol{x}$ 的函数。来自这个总体的 N 个随机样本的联合概密为 $p(\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N;\boldsymbol{\theta})$。现设 $\boldsymbol{\theta}$ 是一个未知参数集,当 N 个随机样本取定值 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 后,$p(\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N;\boldsymbol{\theta})$ 称为相对于 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 的 $\boldsymbol{\theta}$ 的似然函数,显然,此时的 $p(\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N;\boldsymbol{\theta})$ 是 $\boldsymbol{\theta}$ 的函数,对于不同的 $\boldsymbol{\theta}$,$p(\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N;\boldsymbol{\theta})$ 将不同。令 $\boldsymbol{X}^{(N)}=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N\}$,似然函数 $p(\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N;\boldsymbol{\theta})\triangleq p(\boldsymbol{X}^{(N)};\boldsymbol{\theta})$ 有时记为 $L(\boldsymbol{\theta})$。由于 $\boldsymbol{\theta}$ 是 $\boldsymbol{x}$ 的概密的确定的参数集,因此 $p(\boldsymbol{X}^{(N)};\boldsymbol{\theta})$ 实际上就是条件概密 $p(\boldsymbol{X}^{(N)}\mid\boldsymbol{\theta})$;另外,在没有关于 $\boldsymbol{\theta}$ 的任何先验知识的情况下,$\boldsymbol{\theta}$ 可以视作均匀分布的随机矢量,$p(\boldsymbol{X}^{(N)};\boldsymbol{\theta})\propto p(\boldsymbol{X}^{(N)}\mid\boldsymbol{\theta})$。所以为明确起见,我们取 $p(\boldsymbol{X}^{(N)}\mid\boldsymbol{\theta})$ 这种表示。如果各个 $\boldsymbol{x}_j(j=1,2,\cdots,N)$ 是独立抽取的,则进一步有

$$p(\boldsymbol{X}^{(N)}\mid\boldsymbol{\theta})=p(\boldsymbol{x}_1\mid\boldsymbol{\theta})\,p(\boldsymbol{x}_2\mid\boldsymbol{\theta})\cdots p(\boldsymbol{x}_N\mid\boldsymbol{\theta})=\prod_{j=1}^{N}p(\boldsymbol{x}_j\mid\boldsymbol{\theta}) \tag{5-2-8}$$

在给定 $\boldsymbol{\theta}$ 时,$p(\boldsymbol{X}^{(N)}\mid\boldsymbol{\theta})$ 表示样本在 $\boldsymbol{X}^{(N)}$ 点处出现的可能性。最大似然估计的思想是:如果对总体的独立观测中获得样本集 $\boldsymbol{X}^{(N)}=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N\}$,则认为 $p(\boldsymbol{X}^{(N)}\mid\boldsymbol{\theta})$ 在点 $\boldsymbol{X}^{(N)}$ 处最可能取得最大值。对于不同的 $\boldsymbol{\theta}$,$p(\boldsymbol{X}^{(N)}\mid\boldsymbol{\theta})$ 虽是同一概型但不是同一概密,从而它们的最大值点 $\boldsymbol{X}^{(N)}$ 也不同,于是有理由选取满足 $p(\boldsymbol{X}^{(N)}\mid\hat{\boldsymbol{\theta}})=\max_{\boldsymbol{\theta}}[p(\boldsymbol{X}^{(N)}\mid\boldsymbol{\theta})]$ 的 $\hat{\boldsymbol{\theta}}$ 作为未知参数集的估计值。这种估计方法称为最大似然估计。此方法所得到的 $\boldsymbol{\theta}$ 的估值 $\hat{\boldsymbol{\theta}}$ 称为最大似然估计(值),显然 $\boldsymbol{\theta}$ 的最大似然估计 $\hat{\boldsymbol{\theta}}$ 是 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 的函数。由于在实际中多是独立取样和经常处理正态变量,而且对数函数是单值单调函数,对数似然函数与似然函数在相同的 $\boldsymbol{\theta}$ 处取得最大值,因此在似然函数可微的条件下,求下面微分方

程组的解

$$\frac{\partial p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{0} \qquad (5-2-9)$$

或等价地求下面微分方程组

$$\frac{\partial[\ln p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})]}{\partial \boldsymbol{\theta}} = \sum_{j=1}^{N} \frac{\partial}{\partial \boldsymbol{\theta}} \ln p(\boldsymbol{x}_j \mid \boldsymbol{\theta}) = \mathbf{0} \qquad (5-2-10)$$

的解作为极值的必要条件，然后在上面方程组的一切解中和边界上求出使$p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})$最大的$\boldsymbol{\theta}^*$作为$\boldsymbol{\theta}$的最大似然估计。上面的方程组分别称为似然方程组和对数似然方程组。可以用牛顿 - 拉弗森算法求解似然方程。

当将$\boldsymbol{\theta}$视作随机矢量时，参数矢量$\boldsymbol{\theta}$的全部知识可以由概密$p(\boldsymbol{\theta})$来体现。在没有关于$\boldsymbol{\theta}$的任何先验知识的情况下，可以视作均匀分布或具有无穷方差的正态分布的极限情况，此时容易求得，$\frac{\partial \ln p(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{0}$，从而有一个等价的最大后验估计$\frac{\partial \ln p(\boldsymbol{X}^{(N)}, \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{0} = \frac{\partial \ln p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})}{\partial \boldsymbol{\theta}}$。可知，求$\ln p(\boldsymbol{\theta})$的极大值的必要条件在最大后验估计意义上也可以由式(5 - 2 - 10)等价确定。

由于$\boldsymbol{X}^{(N)}$是随机量，$\boldsymbol{\theta}$是$\boldsymbol{X}^{(N)}$的函数，所以$\boldsymbol{\theta}$的最大似然估计$\hat{\boldsymbol{\theta}}$也是随机量。在相当一般条件下，最大似然估计量具有相合性，依概率1收敛于真值$\boldsymbol{\theta}$；在$p(\boldsymbol{x};\boldsymbol{\theta})$满足一定的正则条件下，具有相合性质的最大似然估计$\hat{\boldsymbol{\theta}}$是渐近正态分布的，其均矢为$\boldsymbol{\theta}$；在满足一定的正则件下，最大似然估计$\hat{\boldsymbol{\theta}}$方差最小。

正态分布的总体$\boldsymbol{x}$的均矢$\boldsymbol{\mu}$和协方差阵$\boldsymbol{\Sigma}$的的最大似然估计

$$\hat{\boldsymbol{\mu}} = \frac{1}{N} \sum_{j=1}^{N} \boldsymbol{x}_j$$

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{N} \sum_{j=1}^{N} (\boldsymbol{x}_j - \hat{\boldsymbol{\mu}})(\boldsymbol{x}_j - \hat{\boldsymbol{\mu}})'$$

图5.2.1所示为一维最大似然估计，当随机的训练样本非常多时，图中的函数波形将变得很窄，且峰点也将很准确。

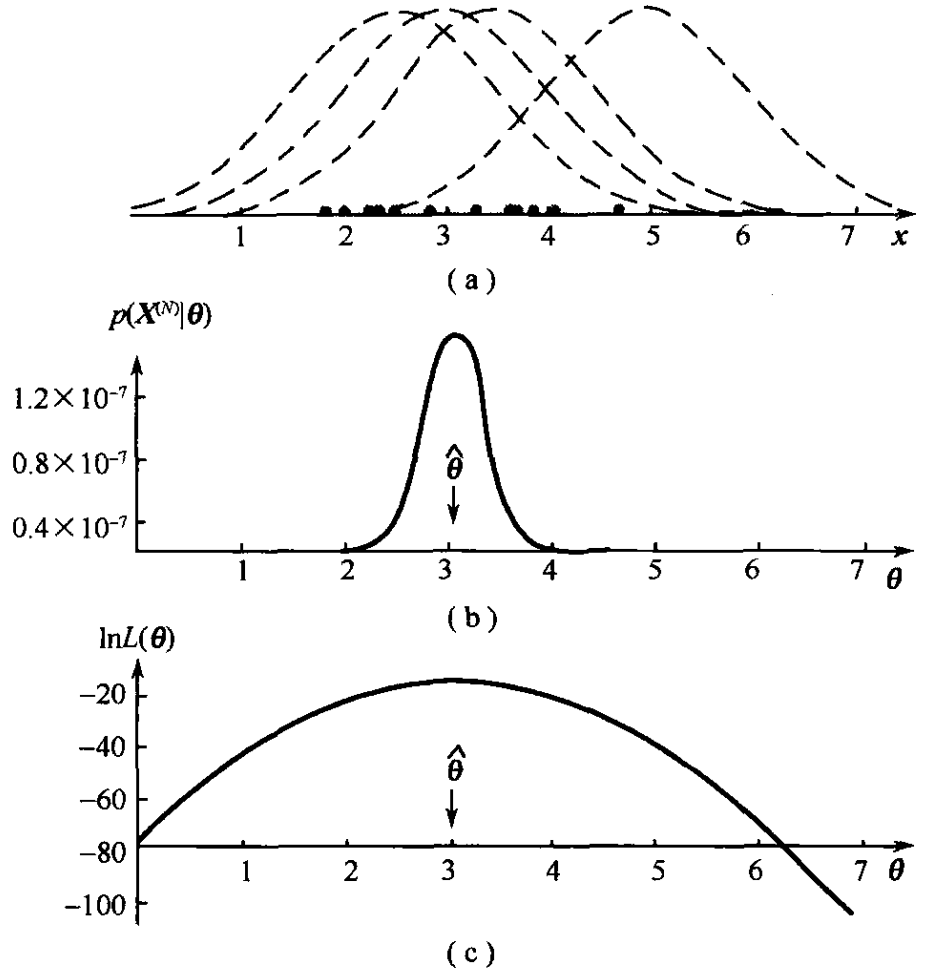


图 5.2.1　一维最大似然估计示意图

(a) 随机样本及可能源分布；(b)$P(\boldsymbol{x}^N \mid \boldsymbol{\theta})$ 的波形；(c) 对数似然函数的波形。

5.2.3　贝叶斯估计(BE)

在类别判决讨论中定义了损失函数与平均损失，并依据最小平均损失准则建立了判决规则。类似地，在参数估计中，也可以考虑平均损失问题，这里，损失函数是用估计值$\hat{\boldsymbol{\theta}}$作为真实值$\boldsymbol{\theta}$的代价。令$\lambda(\boldsymbol{\theta}, \hat{\boldsymbol{\theta}})$为$\hat{\boldsymbol{\theta}}$代替$\boldsymbol{\theta}$所造成的损失，对于一个观测矢量集合$\boldsymbol{X}^{(N)} = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N\}$，当用$\hat{\boldsymbol{\theta}}$作为$\boldsymbol{\theta}$的估计时，在观测$\boldsymbol{X}^{(N)}$条件下的期望损失为

$$R(\hat{\boldsymbol{\theta}} \mid \boldsymbol{X}^{(N)}) = \int_{\Theta} \lambda(\boldsymbol{\theta}, \hat{\boldsymbol{\theta}}) p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta} \quad (5-2-11)$$

其中：Θ为参数空间。

考虑到$\boldsymbol{X}^{(N)}$的各种取值，我们应求$R(\hat{\boldsymbol{\theta}} \mid \boldsymbol{X}^{(N)})$在$\Omega^N = \Omega \times \Omega \times \cdots \times \Omega$空间中的期望

$$R = \int_{\Omega^N} R(\hat{\boldsymbol{\theta}} \mid \boldsymbol{X}^{(N)}) p(\boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{x}^{(N)}$$

$$= \int_{\Omega^N}\int_{\Theta} \lambda(\boldsymbol{\theta},\hat{\boldsymbol{\theta}}) p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) p(\boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta}\mathrm{d}\boldsymbol{X}^{(N)} \tag{5-2-12}$$

贝叶斯估计的思想是:所求得的 $\boldsymbol{\theta}$ 的估计值 $\hat{\boldsymbol{\theta}}$ 应使估计损失的期望最小,这种使 R 或等价地使 $R(\hat{\boldsymbol{\theta}} \mid \boldsymbol{X}^{(N)})$ 取最小值的 $\boldsymbol{\theta}$ 的估值 $\hat{\boldsymbol{\theta}}$ 称为 $\boldsymbol{\theta}$ 的贝叶斯估计。对于 $\lambda(\boldsymbol{\theta},\hat{\boldsymbol{\theta}})$ 不同的具体定义,可得到不同的最佳贝叶斯估计。平方误差作为代价,此时

$$\lambda(\boldsymbol{\theta},\hat{\boldsymbol{\theta}}) = (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}})^{\mathrm{T}}(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}) \tag{5-2-13}$$

于是,估计的平均损失

$$R = \int_{\Omega^N}\int_{\Theta} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}})^{\mathrm{T}}(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}) p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) p(\boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta}\mathrm{d}\boldsymbol{X}^{(N)}$$

$$= \int_{\Omega^N} \left[\int_{\Theta} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}})^{\mathrm{T}}(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}) p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta} \right] p(\boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{X}^{(N)} \tag{5-2-14}$$

由于 $p(\boldsymbol{X}^{(N)})$ 是非负的,$\hat{\boldsymbol{\theta}}$ 只出现在内积分中,关于 $\hat{\boldsymbol{\theta}}$ 使 R 最小等价于使

$$R(\hat{\boldsymbol{\theta}} \mid \boldsymbol{X}^{(N)}) = \int_{\Theta} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}})^{\mathrm{T}}(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}) p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta} \Rightarrow \min \tag{5-2-15}$$

为求 $R(\hat{\boldsymbol{\theta}} \mid \boldsymbol{X}^{(N)})$ 极小,令

$$\frac{\partial R(\hat{\boldsymbol{\theta}} \mid \boldsymbol{X}^{(N)})}{\partial \hat{\boldsymbol{\theta}}} = -2\int_{\Theta} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}) p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta} = \boldsymbol{0}$$

从而可得

$$\hat{\boldsymbol{\theta}}(\boldsymbol{X}^{(N)}) = \int_{\Theta} \boldsymbol{\theta} p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta} = \mathrm{E}[\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}] \tag{5-2-16}$$

由于 R 是关于 $\hat{\boldsymbol{\theta}}$ 的二次函数,易知上式的 $\hat{\boldsymbol{\theta}}$ 确使 $R(\hat{\boldsymbol{\theta}} \mid \boldsymbol{X}^{(N)})$ 或即 R 最小。上式表明,$\boldsymbol{\theta}$ 的最小方差贝叶斯估计是在观测 $\boldsymbol{X}^{(N)}$ 条件下的 $\boldsymbol{\theta}$ 的条件期望。在许多情况下,最小方差贝叶斯估计是最理想的贝叶斯最优

估计。

下面给出估计 $\boldsymbol{\theta}$ 所涉及的其他公式或近似算式。

由于各样本是独立抽取的，故它们条件独立，即有

$$p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta}) = p(\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N \mid \boldsymbol{\theta}) = \prod_{j=1}^{N} p(\boldsymbol{x}_j \mid \boldsymbol{\theta}) \tag{5-2-17}$$

由贝叶斯定理知

$$\begin{aligned} p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) &= p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) / p(\boldsymbol{X}^{(N)}) \\ &= \frac{p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})}{\int_{\Theta} p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) \mathrm{d}\boldsymbol{\theta}} \end{aligned} \tag{5-2-18}$$

$\boldsymbol{\theta}$ 的后验概密 $p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)})$ 也可以作如下近似计算：设 $p(\boldsymbol{\theta})$ 为正态分布 $N(\boldsymbol{\theta}_0, \boldsymbol{C}_0)$，可取 $\boldsymbol{\theta}_0 = \hat{\boldsymbol{\theta}}$，$\boldsymbol{C}_0$ 为估计的不确定性度量。由于认为 $p(\boldsymbol{X}^{(N)})$ 只与 $\boldsymbol{X}^{(N)}$ 有关而与 $\boldsymbol{\theta}$ 无关，可取其为一个关于 $\boldsymbol{X}^{(N)}$ 的简单函数 $\alpha(\boldsymbol{X}^{(N)})$，由于观测是独立的，则上式可近似为

$$p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) = p(\boldsymbol{\theta} \mid \boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N) = \alpha^{-1}(\boldsymbol{X}^{(N)}) \prod_{j=1}^{N} p(\boldsymbol{x}_j \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) \tag{5-2-19}$$

式中：$\alpha^{-1}(\boldsymbol{X}^{(N)})$ 可理解为一个归一化系数。

归纳起来，贝叶斯估计的步骤为以下几步。

(1) 确定未知参数集 $\boldsymbol{\theta}$ 的先验概密 $p(\boldsymbol{\theta})$。

(2) 由样本集 $\boldsymbol{X}^{(N)}$ 根据式(5-2-18)求 $p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})$，在这里类的概型是已知的。

(3) 根据式(5-2-19)或式(5-2-20)计算 $p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)})$。

(4) 根据式(5-2-16)计算 $\hat{\theta}$。

5.2.4 最大似然估计和贝叶斯估计的性能比较

最大似然估计与贝叶斯估计有如下不同。

(1) 最大似然估计计算复杂度要比贝叶斯估计小。因最大似然估

计只涉及一些微分运算和梯度搜索技术，而贝叶斯估计则要计算多重积分。

(2) 最大似然估计比贝叶斯估计更易理解和掌握。最大似然估计的结果形式和初设形式相同，最大似然估计结果是所提供的训练样本的一个最佳解答，而贝叶斯估计的结果是许多可能解的加权平均。

(3) 贝叶斯估计比最大似然估计能利用更多的信息，如果这些信息是可靠的，那么贝叶斯估计比最大似然估计更准确。然而，

① 当训练样本趋于无穷多时，两者估计效果是相同的；

② 如果没有特殊的先验信息(如都是均匀分布的)，两者估计是相似的。

(4) 当 $p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)})$ 的波形较宽或在 $\hat{\boldsymbol{\theta}}$ 附近不对称时贝叶斯估计比最大似然估计要好。

最大似然估计的另一个优点是在实际中计算 $p(\boldsymbol{x} \mid \boldsymbol{\theta})$ 比计算 $p(\boldsymbol{\theta} \mid \boldsymbol{x})$ 要容易得多，这里不涉及 $\boldsymbol{\theta}$ 的概密。虽然最大似然估计次于贝叶斯估计，但由于在某些条件下，最大似然估计能获得方差最小的估计或渐近性很好的估计，因此有着广泛应用意义。

5.3 贝叶斯学习

贝叶斯学习与贝叶斯估计前提条件是相同的，但贝叶斯学习不是进行概密的参数估计，而是进行总体概密的估计以获得 $p(\boldsymbol{x} \mid \boldsymbol{X}^{(N)})$，因此，它们虽具有某些相同的计算内容，但有不同的计算目标，具体地讲，在贝叶斯估计的 4 个步骤中，贝叶斯学习在执行完了前三个步骤得到未知参数 $\boldsymbol{\theta}$ 的后验概密 $p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)})$ 之后不是去求 $\hat{\boldsymbol{\theta}}$，而是直接求总体 $\boldsymbol{x}$ 的后验概密 $p(\boldsymbol{x} \mid \boldsymbol{X}^{(N)})$。为了容易看出计算的条件和过程，下面写出主干公式。

$$p(\boldsymbol{x} \mid \boldsymbol{X}^{(N)}) = \int_{\Theta} p(\boldsymbol{x}, \boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta} = \int_{\Theta} p(\boldsymbol{x} \mid \boldsymbol{\theta}, \boldsymbol{X}^{(N)}) p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta}$$

$$= \int_{\Theta} p(\boldsymbol{x} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) \mathrm{d}\boldsymbol{\theta} \qquad (5-3-1)$$

上面最后一个等式成立是因为样本 $\boldsymbol{x}$ 和 $\boldsymbol{X}^{(N)}$ 间是独立抽取的。由贝叶

斯公式,有

$$p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) = p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})p(\boldsymbol{\theta}) \Big/ \int_{\Theta} p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})\mathrm{d}\boldsymbol{\theta} \tag{5-3-2}$$

由于抽样是独立进行的,$\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N$ 是条件独立的,故有

$$p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta}) = p(\boldsymbol{x}_N \mid \boldsymbol{\theta})p(\boldsymbol{X}^{(N-1)} \mid \boldsymbol{\theta}) = \prod_{j=1}^{N} p(\boldsymbol{x}_j \mid \boldsymbol{\theta}) \tag{5-3-3}$$

在贝叶斯学习中,$p(\boldsymbol{x} \mid \boldsymbol{\theta})$ 概型是已知的。一般来讲,首先运用式(5-3-3)计算$p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})$,然后运用式(5-3-2)计算$p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)})$,最后运用式(5-3-1)计算$p(\boldsymbol{x} \mid \boldsymbol{X}^{(N)})$,便完成由观测$\boldsymbol{X}^{(N)}$对总体的概密$p(\boldsymbol{x} \mid \boldsymbol{X}^{(N)})$的推断。

通常,$p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)})$具有递推收敛的性质。由贝叶斯公式,有

$$\begin{aligned} p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) &= p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})p(\boldsymbol{\theta}) \Big/ \int_{\Theta} p(\boldsymbol{X}^{(N)} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})\mathrm{d}\boldsymbol{\theta} \\ &= p(\boldsymbol{x}_N \mid \boldsymbol{\theta})p(\boldsymbol{X}^{(N-1)} \mid \boldsymbol{\theta})p(\boldsymbol{\theta}) \Big/ \\ &\quad \int_{\Theta} p(\boldsymbol{x}_N \mid \boldsymbol{\theta})p(\boldsymbol{X}^{(N-1)} \mid \boldsymbol{\theta})p(\boldsymbol{\theta})\mathrm{d}\boldsymbol{\theta} \\ &= p(\boldsymbol{x}_N \mid \boldsymbol{\theta})p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N-1)})p(\boldsymbol{X}^{(N-1)}) \Big/ \int_{\Theta} p(\boldsymbol{x}_N \mid \boldsymbol{\theta}) \\ &\quad p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N-1)})p(\boldsymbol{X}^{(N-1)})\mathrm{d}\boldsymbol{\theta} \\ &= P(\boldsymbol{x}_N \mid \boldsymbol{\theta})p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N-1)} \Big/ \int_{\theta} p(\boldsymbol{x}_N \mid \boldsymbol{\theta})p(\boldsymbol{\theta} \mid \boldsymbol{x}^{(N-1)})\mathrm{d}\boldsymbol{\theta} \end{aligned} \tag{5-3-4}$$

$$= p(\boldsymbol{x}_N \mid \boldsymbol{\theta})p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N-1)})/p(\boldsymbol{x}_N \mid \boldsymbol{X}^{(N-1)}) \tag{5-3-5}$$

上式为一个递推公式。显然$p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(0)}) = p(\boldsymbol{\theta})$,其为$\boldsymbol{\theta}$的先验概密,当不断地逐一增加样本重复使用上述公式时,可以产生一个序列$p(\boldsymbol{\theta})$,$p(\boldsymbol{\theta} \mid \boldsymbol{x}_1)$,$p(\boldsymbol{\theta} \mid \boldsymbol{x}_1, \boldsymbol{x}_2, \cdots)$,这一过程称为递推贝叶斯方法。如果这个序列收敛于一个以真实参数$\boldsymbol{\theta}$为中心的δ-函数,那么这个过程称为递推贝叶斯参数学习。正态分布以及我们接触到的大多数典型概密都具有此性质。图5.3.1所示为对正态分布均值的递推贝叶斯参数学习过

程，概密曲线或曲面旁的数字表示用于估计的样本数。

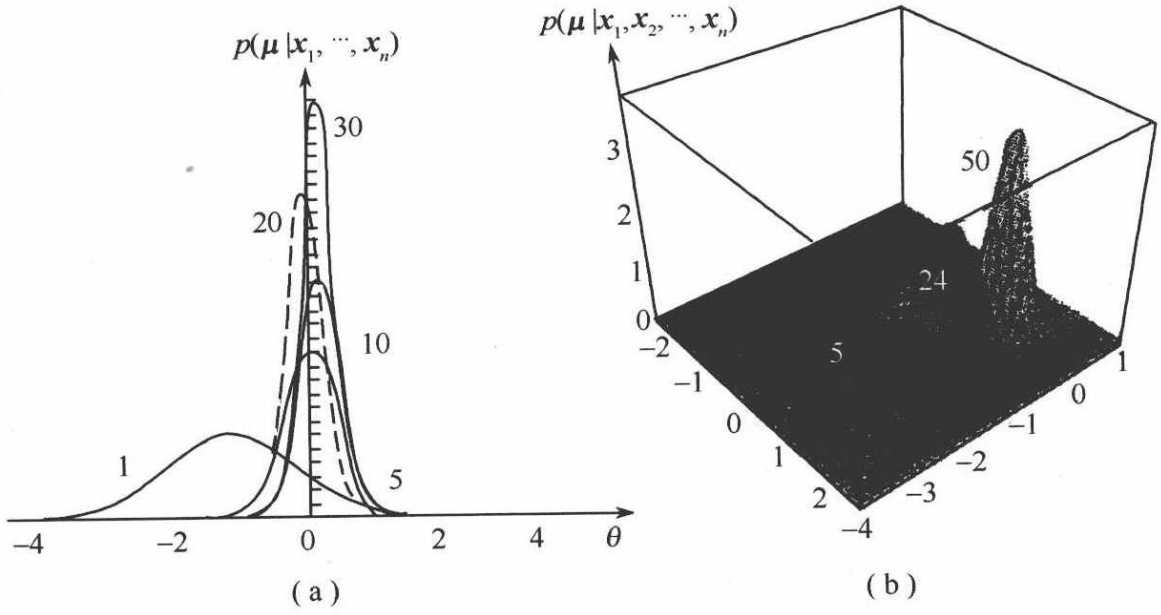


图 5.3.1　正态分布均值的递推贝叶斯参数学习过程

(a) 一维情况；(b) 二维情况。

式(5－3－1)反映了总体 $\boldsymbol{x}$ 后验概密 $p(\boldsymbol{x}\mid \boldsymbol{X}^{(N)})$ 与参数 $\boldsymbol{\theta}$ 后验概密 $p(\boldsymbol{\theta}\mid \boldsymbol{X}^{(N)})$ 的关系。如果 $p(\boldsymbol{\theta}\mid \boldsymbol{X}^{(N)})$ 在真实参数 $\boldsymbol{\theta}$ 处逼近一个 δ－函数，将其代入式(5－3－1)，对于光滑函数 $p(\boldsymbol{x}\mid \boldsymbol{\theta})$，当样本数目 N 无穷大或很大时，可得或近似有 $p(\boldsymbol{x}\mid \boldsymbol{X}^{(N)}) = p(\boldsymbol{x}\mid \hat{\boldsymbol{\theta}} = \boldsymbol{\theta}) = p(\boldsymbol{x})$；如果 $p(\boldsymbol{\theta}\mid \boldsymbol{X}^{(N)})$ 不能在真实参数 $\boldsymbol{\theta}$ 处逼近一个 δ－函数，而是一个较宽的函数，式(5－3－1)表示对所有可能的 $\boldsymbol{\theta}$ 求平均，通过求 $p(\boldsymbol{x}\mid \boldsymbol{\theta})$ 关于 $\boldsymbol{\theta}$ 的条件期望来实现。式(5－3－2)反映了贝叶斯估计与最大似然估计的关系。如果先验概密 $p(\boldsymbol{\theta})$ 在 $\hat{\boldsymbol{\theta}}$ 处不为零且比较平坦，由式(5－3－2)可知，$p(\boldsymbol{\theta}\mid \boldsymbol{X}^{(N)}) \propto p(\boldsymbol{X}^{(N)}\mid \boldsymbol{\theta})$，可知若 $p(\boldsymbol{X}^{(N)}\mid \boldsymbol{\theta})$ 在 $\hat{\boldsymbol{\theta}}$ 处出现尖峰，$p(\boldsymbol{\theta}\mid \boldsymbol{X}^{(N)})$ 也会在 $\hat{\boldsymbol{\theta}}$ 处出现尖峰，$\boldsymbol{\theta}$ 的后验概密收敛于一个 δ－函数。此时，也有 $p(\boldsymbol{x}\mid \boldsymbol{X}^{(N)})$ 近似等于 $p(\boldsymbol{\theta})$。当有大量样本时，若仅有一个 $\boldsymbol{\theta}$ 值，这个 $\boldsymbol{\theta}$ 值产生的 $p(\boldsymbol{x}\mid \boldsymbol{\theta})$ 在最大似然估计 $\hat{\boldsymbol{\theta}}$ 处近似 δ－函数，这时的 $p(\boldsymbol{x}\mid \boldsymbol{\theta})$ 被称为一致的。有时不同的 $\boldsymbol{\theta}$ 值也可以产生相同的 $p(\boldsymbol{x}\mid \boldsymbol{\theta})$，换句话说，$\boldsymbol{\theta}$ 不能由 $p(\boldsymbol{x}\mid \boldsymbol{\theta})$ 唯一确定，若 $p(\boldsymbol{\theta}\mid \boldsymbol{X}^{(N)})$ 将在这些 $\boldsymbol{\theta}$ 值处突起尖峰，因 $p(\boldsymbol{x}\mid \boldsymbol{\theta})$ 对于所有这些 $\boldsymbol{\theta}$ 是相同的，所以积分

$$p(\boldsymbol{x}\mid \boldsymbol{X}^{(N)}) = \int_{\boldsymbol{\Theta}} p(\boldsymbol{x}\mid \boldsymbol{\theta})p(\boldsymbol{\theta}\mid \boldsymbol{X}^{(N)})\mathrm{d}\boldsymbol{\theta} \quad (5-3-6)$$

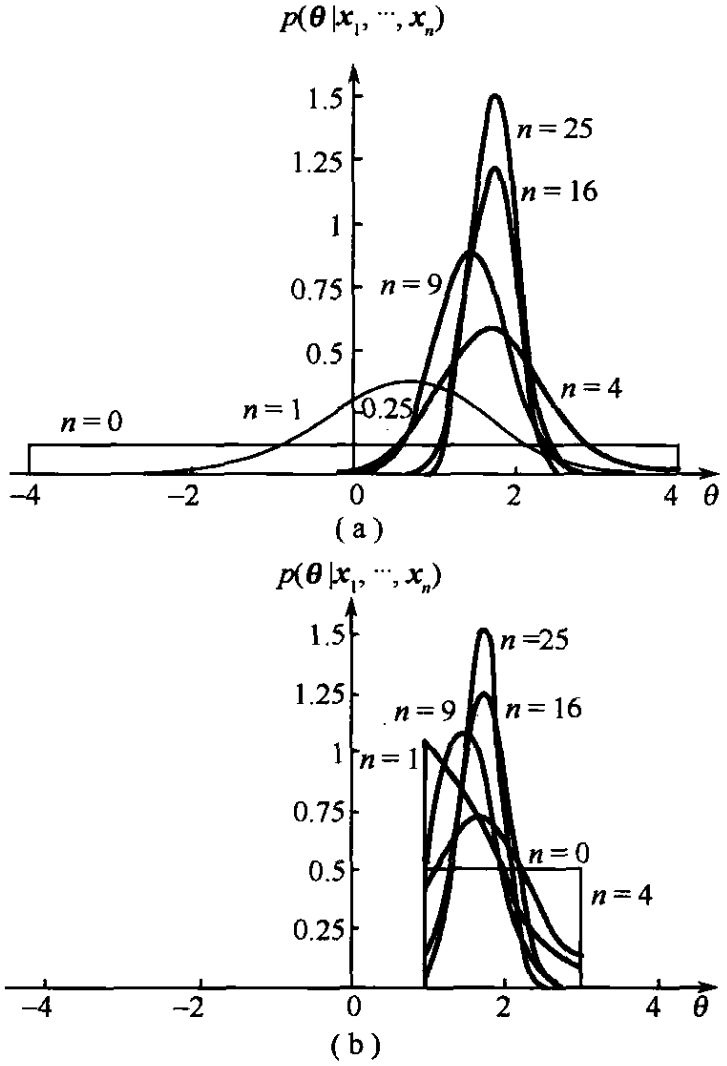
也是唯一的，也使 $p(\boldsymbol{x} \mid \boldsymbol{X}^{(N)})$ 仍收敛于 $p(\boldsymbol{x} \mid \boldsymbol{\theta})$。对多数典型概密 $p(\boldsymbol{x} \mid \boldsymbol{\theta})$，其后验概密序列也有收敛于一个 δ - 函数的性质。

在运用主干公式推断 $p(\boldsymbol{x} \mid \boldsymbol{X}^{(N)})$ 时，可以运用递推算法。除了可以用式

$$p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)}) = p(\boldsymbol{\theta} \mid \boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N) = \alpha^{-1}(\boldsymbol{X}^{(N)}) \prod_{j=1}^{N} p(\boldsymbol{x}_j \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) \tag{5-3-7}$$

之外，也可运用上面导出的递推式(5 - 3 - 4) 求 $p(\boldsymbol{x} \mid \boldsymbol{X}^{(N)})$。

图 5.3.2 所示为对两个正态分布变量混合分布中的一个正态分布均值的递推贝叶斯参数学习过程，可以看出，当训练样本非常多时(此例为 25 个)，先验概密 $p(\boldsymbol{\theta})$ 虽然设定差别很大，但后验概密 $p(\boldsymbol{\theta} \mid \boldsymbol{X}^{(N)})$ 几乎完全相同，因训练样本的信息抑制并修正了设定的信



(图中 n 为样本数)

图 5.3.2　贝叶斯学习过程结果不受先验概密 $p(\boldsymbol{\theta})$ 设定的影响例图

息偏差。

5.4 概密的窗函数估计法

5.4.1 概密的基本估计式

这里是针对 ω_i 类的概密和样本进行讨论，为简洁以下不再标记类别，记 ω_i 类的概密 $p(\boldsymbol{x} \mid \omega_i) = p(\boldsymbol{x})$，易知一个随机样本 $\boldsymbol{x}$ 落入特征空间中某一区域 R 中的概率为

$$p = \int_R p(\boldsymbol{x})\mathrm{d}\boldsymbol{x} \tag{5-4-1}$$

设 N 个样本 $\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N$ 是从一个总体中独立抽取的，N 个样本中有 k 个样本落入区域 R 中的概率 P_k 服从离散随机变量的二项分布

$$P_k = C_N^k P^k (1-P)^{N-k} \tag{5-4-2}$$

P_k 取最大时的 k 值称为众数，这里记为 m。如果 $(N+1)P$ 不是整数，则 m 等于 $(N+1)P$ 的整数部分，即 $m = [(N+1)P]$；如果 $(N+1)P$ 是整数，则 $m = (N+1)P - 1$ 和 $m = (N+1)P$。众数定义表明有 m 个样本落入区域 R 的概率最大。若实际落入 R 域的样本有 k 个，则认为这时的 $k \approx m$。由于 $(N+1)p - 1 \leqslant m \leqslant (N+1)p$，所以

$$k \approx NP \approx N\widehat{P} \tag{5-4-3}$$

这里 $\widehat{P}$ 是 P 的估计，当 N 较大 P 较小时上式的近似程度是足够的。若固定 k，对 P 的最大似然估计 $\widehat{P}_{\mathrm{ML}} = k/N$。由概率论知，$k$ 的数学期望 $\mathrm{E}[k] = NP$。综上所述并根据极限情况下的贝努利定理，可以认为 P 的估值

$$\widehat{P} = k/N \tag{5-4-4}$$

设区域 R 的体积为 V，取 R 足够小，使

$$p = \int_R p(\boldsymbol{x})\mathrm{d}\boldsymbol{x} \approx p(\boldsymbol{x})V \tag{5-4-5}$$

设 $\widehat{p}(\boldsymbol{x})$ 是 $p(\boldsymbol{x})$ 的估计，由上面二式有

$$\frac{k}{N} = \widehat{P} = \int_R \widehat{p}(\boldsymbol{x})\mathrm{d}\boldsymbol{x} = \widehat{p}(\boldsymbol{x})V \tag{5-4-6}$$

于是可得

$$\hat{p}(\boldsymbol{x}) = \frac{k/N}{V} \tag{5-4-7}$$

上式就是 $p(\boldsymbol{x})$ 的基本估计式，它与 N, V, k 有关，显然 $\hat{p}(\boldsymbol{x})$ 与 $p(\boldsymbol{x})$ 有一定的误差。

从理论上讲，要使 $\hat{p}(\boldsymbol{x})$ 趋于 $p(\boldsymbol{x})$，就必须让积分域 R 无限小，即让其体积 V 近于零，同时让 N、k 无穷大。在实际估计时体积 V 不可能是任意的小，而且样本总数也是有限的，所以 $\hat{p}(\boldsymbol{x})$ 总是存在误差。即使 R 的体积 V 能达到所希望的那样小，由于样本数目总是有限的，所以当 V 趋于零时，会使区域 R 不断缩小以致于可能不包含任何样本，这样会得出 $\hat{p}(\boldsymbol{x}) = 0$；如果恰巧有一个或几个样本出现于 $\boldsymbol{x}$ 处，则会使估计发散，甚至无穷大，这表明 k/N 或 $\hat{p}(\boldsymbol{x})$ 是随机量，并且估计存在很大的方差。

为了提高 $\boldsymbol{x}$ 处的概密 $p(\boldsymbol{x})$ 的估计精度，根据极限理论，可以采取如下步骤以尽量满足理论要求：

(1) 构造一包含 $\boldsymbol{x}$ 的区域序列 $R_1, R_2, \cdots$，各区域 $R_N (N = 1, 2, \cdots)$ 的体积 V_N 满足

① $\lim\limits_{N\to\infty} V_N = 0$

(2) 相对区域 $R_N (N = 1, 2, \cdots)$ 取 N 个样本进行估计实验，设有 k_N 个样本落入 R_N 中，样本数目应满足

② $\lim\limits_{N\to\infty} k_N = \infty$

③ $\lim\limits_{N\to\infty} \dfrac{k_N}{N} = 0$

则估计序列

$$\hat{p}_N(\boldsymbol{x}) = \frac{k_N/N}{V_N} (N = 1, 2, \cdots) \tag{5-4-8}$$

处处收敛于 $p(\boldsymbol{x})$。

只要区域平稳地缩小，$p(\boldsymbol{x})$ 在 $\boldsymbol{x}$ 处连续，条件 ① 可使空间平均密度 $\dfrac{P}{V}$ 收敛于真实的密度 $p(\boldsymbol{x})$；条件 ② 仅对 $p(\boldsymbol{x}) \neq 0$ 的点才有意义，即

当$p(\boldsymbol{x}) \neq 0$时，使$\hat{p}(\boldsymbol{x}) \neq 0$，可使频率依概率收敛于概率$P$；条件③是式（5－4－8）收敛的必要条件，它描述了N的增长速率要大于k_N的增长速率，使k_N/N为无穷小，而k_N/N和V_N为同阶的无穷小，使$\dfrac{k_N/N}{V_N}$为非无穷大的有界数，避免了$\hat{p}(\boldsymbol{x}) \to \infty$。原理上满足上述3个条件的区域序列和样本选取可以有两种方法，从而形成了两种总体概密估计。

（1）Parzen窗法。使区域序列的体积V_N按N的某个函数随N的增大不断地缩小，例如$V_N = V_1/\sqrt{N}$，在这时应对k_N和k_N/N都要加以适当的限制以使$\hat{p}_N(\boldsymbol{x})$收敛于$p(\boldsymbol{x})$。

（2）k_N－近邻估计。让k_N为N的某个函数，随N的增大而变大，例如$k_N = \sqrt{N}$，V_N的选取是使相应的R_N正好只包含$\boldsymbol{x}$的k_N个近邻点的最小区域，该区域的体积可以用做$\boldsymbol{x}$点的密度估计时的V_N。

图5.4.1所示为二维Parzen窗估计和k_N－近邻估计产生区域序列与样本序列序列示意图，估计点位于正方形的中心。

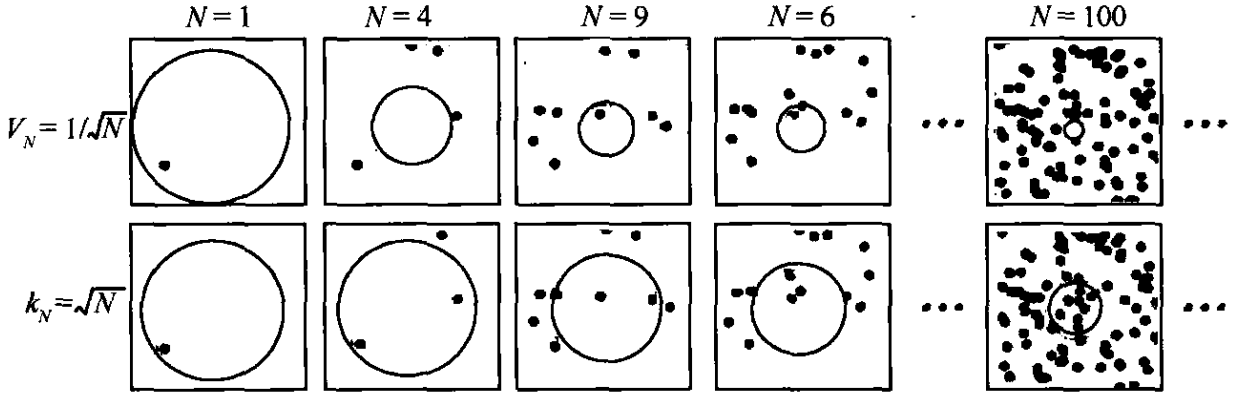


图5.4.1　Parzen窗估计和k_N－近邻估计产生区域序列与样本序列示意图

5.4.2　Parzen窗法

在n维特征空间中，取区域R_N是一n维超立方体，h_N为其棱长，则其体积$V_N = h_N^n$。为能用函数描述区域R_N和对落入R_N的样本计数，定义基本窗函数$\varphi(\boldsymbol{x})$

$$\varphi(\boldsymbol{x}) = \begin{cases} 1 & (\text{当} \mid x_i \mid \leqslant 1/2, i = 1,2,\cdots,n) \\ 0 & (\text{其他}) \end{cases} \tag{5-4-9}$$

这样，$\varphi(\boldsymbol{x})$ 以函数值1界定了一个以原点为中心、棱长为1的 n 维超立方体。通过坐标的平移和尺度的缩放可以改变超立方体的位置和大小。如果一个样本 $\boldsymbol{x}_j$ 落入以 $\boldsymbol{x}$ 为中心以 h_N 为棱长的超立方体 R_N 内时则计数为1，否则计数为0，可以利用窗函数 $\varphi(\boldsymbol{x})$ 实现这个约定，即

$$\varphi(\boldsymbol{x}) = \varphi\left[\frac{\boldsymbol{x}-\boldsymbol{x}_j}{h_N}\right] \tag{5-4-10}$$

因此落入该立方体 R_N 的样本数

$$k_N = \sum_{j=1}^{N} \varphi\left[\frac{\boldsymbol{x}-\boldsymbol{x}_j}{h_N}\right] \tag{5-4-11}$$

将式(5-4-11)代入式(5-4-8)，可得到 $\boldsymbol{x}$ 点处概密估计

$$\hat{p}_N(\boldsymbol{x}) = \frac{1}{N}\sum_{j=1}^{N} \frac{1}{V_N}\varphi\left[\frac{\boldsymbol{x}-\boldsymbol{x}_j}{h_N}\right] \tag{5-4-12}$$

式(5-4-12)实际上是一个迭加函数，窗函数作叠加基函数，每个样本点处作为叠加节点，使用 k_N 个以样本 $\boldsymbol{x}_j$ 为中心的窗函数叠加对 $\boldsymbol{x}$ 处的概密进行估计。易知，样本较密集的区域上必然概密估计(叠加函数)的值较大。这种方法称为 Parzen 窗估计法。式(5-4-12)称为 P-估计式。

在 P-窗法中，通过样本处窗函数叠加的方法产生估计式，使样本处的函数值和样本的密度统一起来。P-窗法的特点是：可适用于各类复杂概密的估计，无论概密是规则的或是不规则的、单峰的或多峰的，用这个方法都可能得到很好的估计结果。从这个意义上讲，它的适用范围很普遍。但它要求样本分布较好且数量要大，显然这也是一个良好估计所必需的，但它的估计过程的操作相对来说复杂些。应该指出的是，一个好的窗函数有利于提高估计的精度和减少样本的数量。

5.4.3 k_N-近邻估计法

在 P-窗法中，把体积 V_N 作为 N 的函数导致 V_N 对估计结果影响很大。例如 $V_N = V_1/\sqrt{N}$，当 V_1 选得太小将导致大部分区域是空的，会使 $\hat{p}_N(\boldsymbol{x})$ 不稳定；当 V_1 选得太大，则 $\hat{p}_N(\boldsymbol{x})$ 较平坦，将丢失 $p(\boldsymbol{x})$ 的一些重要空间变化。k_N-近邻估计法是克服这个问题的一个可能的方法。

这种估计方法的基本思想是，预先确定k_N是N的某个函数，把含$\boldsymbol{x}$点的序列区域的体积$V_1, V_2, \cdots, V_N, \cdots$作为落入$R_N$中样本数$k_N$的函数，而不是直接作为实验样本数$N$的函数，方法是在$\boldsymbol{x}$点附近选择一最小的“紧凑”区域，让它只含$k_N$个邻近样本。如果$\boldsymbol{x}$点附近概密较大，则包含$k_N$个样本的区域体积自然就相对较小；如果$\boldsymbol{x}$点附近概密较小，则区域体积就较大。显然，当区域为含有k_N个邻近样本而扩展到高密度区时，扩展过程必然会停止。

如果满足条件

① $\lim\limits_{N\to\infty} V_N = 0$

② $\lim\limits_{N\to\infty} k_N = \infty$

③ $\lim\limits_{N\to\infty} k_N/N = 0$

则$\hat{p}_N(\boldsymbol{x}) = \dfrac{k_N/N}{V_N}$收敛于真实的概密$p(\boldsymbol{x})$。这3个条件的必要性前已陈述。

在选k_N为N的某个函数时，应保证$k_N \geqslant 1$。如取$k_N = k_1\sqrt{N}$，可以选择k_1是满足$k_N \geqslant 1$的某个整数。在样本数目有限的条件下，k_1的选择也会影响估计的结果，但此方法避免了出现空的区域R_N，消除了估计不稳定性；同时，R_N的体积V_N适应于k_N的变化，而不是取决于N，这也避免了出现V_N过大的情况，不会使估计过于平坦而严重失真。和P－窗法相比，k_N－近邻估计法是一个较好的估计方法。由k_N－近邻法的估计式可知，该方法也需要较多的样本。

5.4.4 后验概率的估计

利用前面的方法，也可以估计后验概率$P(\omega_i \mid \boldsymbol{x})$。假设在点$\boldsymbol{x}$处有一个窗函数，其包含$k$个样本，其中$k_i$个样本属于$\omega_i$，由于是多类混合样本，由前述的知识，$\boldsymbol{x}$和$\omega_i$的联合分布

$$\hat{p}_N(\boldsymbol{x}, \omega_i) = \frac{k_i/N}{V_N} \tag{5-4-13}$$

及公式

$$P(\omega_i \mid \boldsymbol{x}) = \frac{p(\boldsymbol{x},\omega_i)}{\sum_{j=1}^{c} p(\boldsymbol{x},\omega_j)}$$

可知

$$\hat{P}_N(\omega_i \mid \boldsymbol{x}) = \frac{\frac{k_i/N}{V_N}}{\sum_i \frac{k_i/N}{V_N}} = \frac{k_i}{k} \qquad (5-4-14)$$

上式表明，点 $\boldsymbol{x}$ 属于 ω_i 类的后验概率等于窗中属于 ω_i 类的样本数与窗中全部样本数的比值。如果窗体积足够小，并且有足够多的样本，这个方法是比较准确的。窗的选择可以采用 P－窗的方法或者 k_N－近邻的方法。

5.5 有限项正交函数级数逼近法

前面方法的特点是所有的样本一起考虑，通过各样本处的窗函数叠加构造类的概密。本节介绍的方法是设定类概密的逼近函数为有限项正交函数级数，按某种准则求级数中的待定系数，这种方法可以通过样本的逐个加入而提高逼近精度。

5.5.1 最小积分平方差逼近方法

设有 N 个抽自同一母体 $\boldsymbol{x}$ 的样本 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 用于估计总体概密 $p(\boldsymbol{x})$，将概密 $p(\boldsymbol{x})$ 的估计 $\hat{p}(\boldsymbol{x})$ 表示成有限项正交级数

$$\hat{p}(\boldsymbol{x}) = \sum_{i=1}^{R} C_i \varphi_i(\boldsymbol{x}) \qquad (5-5-1)$$

式中：$\varphi_i(\boldsymbol{x})$ 是某一正交函数集 $\{\varphi_i(\boldsymbol{x})\}$ 的基函数。

应根据 $p(\boldsymbol{x})$ 的特点适当选择 $\{\varphi_i(\boldsymbol{x})\}$ 以期在固定的项数下减小误差，$C_i(i=1,2,\cdots,R)$ 为待定系数，项数 R 取得越大近似得就越好。我们构造的估计 $\hat{p}(\boldsymbol{x})$ 与真值 $p(\boldsymbol{x})$ 之间的误差可用下式测度

$$J(C_1,C_2,\cdots,C_R) = \int_{\Omega}\rho(\boldsymbol{x})(p(\boldsymbol{x}) - \hat{p}(\boldsymbol{x}))^2\mathrm{d}\boldsymbol{x} \tag{5-5-2}$$

式中：Ω 为特征空间；$\rho(\boldsymbol{x})$ 为权函数。

显然 $J(\cdot)$ 越小，则得到的估计从总体上讲就越精确。将式(5-5-1)代入式(5-5-2)，有

$$J(C_1,C_2,\cdots,C_R) = \int_{\Omega}\rho(\boldsymbol{x})(p(\boldsymbol{x}) - \sum_{i=1}^{R}C_i\varphi_i(\boldsymbol{x}))^2\mathrm{d}\boldsymbol{x} \tag{5-5-3}$$

可以看出，上式的 J 是 $C_i(i=1,2,\cdots,R)$ 的二次函数，因此使 J 达到最小值的 C_i^* 必要且只要满足

$$\left.\frac{\partial J(C_1,C_2,\cdots,C_R)}{\partial C_k}\right|_{\substack{C_i=C_i^*\\ i=1,2,\cdots,R}} = 0 \quad (k=1,2,\cdots,R) \tag{5-5-4}$$

由此可得

$$2\int_{\Omega}\rho(\boldsymbol{x})(p(\boldsymbol{x}) - \sum_{i=1}^{R}C_i^*\varphi_i(\boldsymbol{x}))(-\varphi_k(\boldsymbol{x}))\mathrm{d}\boldsymbol{x} = 0$$
$$(k=1,2,\cdots,R) \tag{5-5-5}$$

从而有

$$\sum_{i=1}^{R}C_i^*\int_{\Omega}\rho(\boldsymbol{x})\varphi_i(\boldsymbol{x})\varphi_k(\boldsymbol{x})\mathrm{d}\boldsymbol{x} = \int_{\Omega}\rho(\boldsymbol{x})\varphi_k(\boldsymbol{x})p(\boldsymbol{x})\mathrm{d}\boldsymbol{x}$$
$$(k=1,2,\cdots,R) \tag{5-5-6}$$

上式是使 J 达最小的充要条件。可以看出，式(5-5-6)的右边是 $\rho(\boldsymbol{x})\varphi_k(\boldsymbol{x})$ 的数学期望，用 $\boldsymbol{x}$ 的 N 个独立抽取的样本函数平均近似，即

$$\sum_{i=1}^{R}C_i^*\int_{\Omega}\rho(\boldsymbol{x})\varphi_i(\boldsymbol{x})\varphi_k(\boldsymbol{x})\mathrm{d}\boldsymbol{x} \approx \frac{1}{N}\sum_{j=1}^{N}\rho(\boldsymbol{x}_j)\varphi_k(\boldsymbol{x}_j)(k=1,2,\cdots,R) \tag{5-5-7}$$

令 $\{\varphi_i(\boldsymbol{x})\}$ 是带权函数 $\rho(\boldsymbol{x})$ 的正交函数集，即

$$\int_{\Omega}\rho(\boldsymbol{x})\varphi_i(\boldsymbol{x})\varphi_k(\boldsymbol{x})\mathrm{d}\boldsymbol{x}=\begin{cases}A_i & (i=k)\\ 0 & (i\neq k)\end{cases} \qquad (5-5-8)$$

则有

$$C_i^*\approx\frac{1}{NA_i}\sum_{j=1}^{N}\rho(\boldsymbol{x}_j)\varphi_i(\boldsymbol{x}_j)\quad(k=1,2,\cdots,R) \qquad (5-5-9)$$

若$\{\varphi_i(\boldsymbol{x})\}$是在$\rho(\boldsymbol{x})$下的规范化的正交函数集,即$A_i=1$,则有

$$C_i^*\approx\frac{1}{N}\sum_{j=1}^{N}\rho(\boldsymbol{x}_j)\varphi_i(\boldsymbol{x}_j)\quad(k=1,2,\cdots,R) \qquad (5-5-10)$$

将所求得的最佳系数$C_i^*(i=1,2,\cdots,R)$代入式(5-5-1),便可以得到$\hat{p}(\boldsymbol{x})$。

为了节省时间和空间,可以将C_i^*的计算式化为迭代的形式。令$\rho(\boldsymbol{x})=1$,若$C_i^*(N)$表示用前N个样本所求得的系数,当加入第$N+1$个样本后,则有

$$C_i^*(N+1)=\frac{1}{N+1}[NC_i^*(N)+\varphi_i(\boldsymbol{x}_{N+1})]\quad(k=1,2,\cdots,R) \qquad (5-5-11)$$

这里初始系数$C_i^*(0)=0$,显然$C_i^*(1)=\varphi_i(\boldsymbol{x}_1)$。

若令第N次迭代所得的逼近函数为

$$\hat{p}_N(\boldsymbol{x})=\sum_{i=1}^{R}C_i^*(N)\varphi_i(\boldsymbol{x}) \qquad (5-5-12)$$

由式(5-5-11),有

$$\begin{aligned}\hat{p}_{N+1}(\boldsymbol{x})&=\frac{N}{N+1}\hat{p}_N(\boldsymbol{x})+\frac{1}{N+1}\sum_{i=1}^{R}\varphi_i(\boldsymbol{x}_{N+1})\varphi_i(\boldsymbol{x})\\&=\hat{p}_N(\boldsymbol{x})+\frac{1}{N+1}[\sum_{i=1}^{R}\varphi_i(\boldsymbol{x}_{N+1})\varphi_i(\boldsymbol{x})-\hat{p}_N(\boldsymbol{x})]\end{aligned} \qquad (5-5-13)$$

这里令$\hat{p}_0(\boldsymbol{x})=0$。可以证明,若$p(\boldsymbol{x})$确可以表示为式(5-5-1)的形式,则当样本个数$N$无限增加时,$\hat{p}_N(\boldsymbol{x})$在各种收敛准则意义下均收敛

于 $p(\boldsymbol{x})$。

5.5.2 最小均方差逼近方法

上面介绍的方法中被逼近的函数是概密(对 $d(\boldsymbol{x})$ 的逼近,从本质上讲也是如此),很多情况下,概密在某些区域中取值很小,而在另一些区域中取值较大,在取样时,前者区域中样本出现的可能性就较小,而后者区域中样本出现的可能性就较大。对于这种幅值大小变化较剧烈的函数,必须用较多的项才能在整个空间中有较好的逼近,如用多项式正交函数作逼近就要非常高的次数才行,这就大大地增加了计算量。另外,由于实现逼近的最终目的是为了判决,因此在样本出现较密集的区域即概密取值较大的区域中,应要求逼近精度高些,而在那些样本出现稀疏的区域即概密取值较小的区域中,可以让逼近精度低一些,即不应在整个空间 Ω 中对所有的样本同等对待,这样分别对待会使在相同数目的训练样本下总的误判概率较小,因此应考虑加权的最小均方差逼近。

对于 c 类问题,设类概密和类概率分别为 $p(\boldsymbol{x}|\omega_i)$ 和 $P(\omega_i)(i=1,2,\cdots,c)$,则混合概密为

$$p(\boldsymbol{x}) = \sum_{i=1}^{c} P(\omega_i)p(\boldsymbol{x}|\omega_i) \qquad (5-5-14)$$

设对每类的概密 $p(\boldsymbol{x}|\omega_i)$ 的估计 $\hat{p}(\boldsymbol{x}|\omega_i)$ 可用正交级数有限项表示为

$$\hat{p}(\boldsymbol{x}|\omega_i) = \sum_{j=1}^{R} C_j^{(i)}\varphi_j(\boldsymbol{x}) \qquad (5-5-15)$$

我们考虑以混合概密作为权值的加权均方差

$$J^{(i)}(C_1^{(i)},C_2^{(i)},\cdots,C_R^{(i)}) = \int_{\Omega}\left[p(\boldsymbol{x}|\omega_i) - \sum_{j=1}^{R} C_j^{(i)}\varphi_j(\boldsymbol{x})\right]^2 p(\boldsymbol{x})\mathrm{d}\boldsymbol{x}$$
$$(i=1,2,\cdots,c) \qquad (5-5-16)$$

求解 $J^{(i)}(i=1,2,\cdots,c)$ 的最小值,有如下的定理。

[**定理 5.5.1**] 设有 N 个样本 $\{\boldsymbol{x}_s\}$,其中有 N_i 个样本属于 ω_i 类,为方便,把它们记为 $\{\boldsymbol{x}_j^{(i)}\}$,其中 $i=1,2,\cdots,c, j=1,2,\cdots,N_i, N=$

$\sum_{i=1}^{c} N_i$，若取各类的概率 $P(\omega_i) = \frac{N_i}{N}$，使式(5-5-16)所确定的 $J^{(i)}$ 达到最小值的 $C_j^{(i)}$ 近似满足线性方程组

$$\sum_{j=1}^{R} C_j^{(i)} a_{jl} = b_l^{(i)} \quad (l = 1,2,\cdots,R) \qquad (5-5-17)$$

式中：

$$a_{jl} = \sum_{s=1}^{N} \varphi_j(\boldsymbol{x}_s)\varphi_l(\boldsymbol{x}_s)$$

$$b_l^{(i)} = \sum_{s=1}^{N} \varphi_l(\boldsymbol{x}_s)u_i(\boldsymbol{x}_s)$$

$$(l,j = 1,2,\cdots,R;i = 1,2,\cdots,c)$$

$$u_i(\boldsymbol{x}_s) = \begin{cases} 1 & (\text{当}\boldsymbol{x}_s \in \omega_i) \\ 0 & (\text{当}\boldsymbol{x}_s \notin \omega_i) \end{cases} \quad (i = 1,2,\cdots,c)$$

$$(5-5-18)$$

求得 $C_j^{(i)}(i = 1,2,\cdots,c;j = 1,2,\cdots,R)$ 后就能构造各类的概密逼近式：

$$\hat{p}(\boldsymbol{x}|\omega_i) = \sum_{j=1}^{R} C_j^{(i)}\varphi_j(\boldsymbol{x}) \quad (i = 1,2,\cdots,c) \qquad (5-5-19)$$

显然，上述用 $u_i(\boldsymbol{x}_s)$ 代替 $p(\boldsymbol{x}_s|\omega_i)$ 会带来一些误差，改进的方法之一是适当地调整 $u_i(\boldsymbol{x}_s)$ 的值，例如根据各类样本的分布情况改变 $u_i(\boldsymbol{x}_s)$ 的大小。

5.6 用位势函数法逼近贝叶斯判决函数

在第3章中引进了位势函数的概念，从物理观点出发说明了积累位势函数可以作为判别函数，并建立了产生判别函数的方法。在那里，实际上是利用训练样本通过迭代的方法产生积累位势函数去逼近在第4章导出的最小误判概率准则下最大后验概率判决函数，亦即两类的后验概率之差

$$d_{ij}(\boldsymbol{x}) = P(\omega_i|\boldsymbol{x}) - P(\omega_j|\boldsymbol{x}) \qquad (5-6-1)$$

由于我们是用积累位势函数逼近两类后验概率之差，根据其大于或小于零而判决，所以位势函数 $K(\boldsymbol{x},\boldsymbol{x}_j)$ 的面积归一已不必要。

如果位势函数还满足窗函数其他条件

$$\int K(\boldsymbol{x},\boldsymbol{x}_j)\mathrm{d}\boldsymbol{x} = 1$$

显然，可以用它构造概密估计式

$$\hat{p}_N(\boldsymbol{x}) = \frac{1}{N}\sum_{j=1}^{N} K(\boldsymbol{x},\boldsymbol{x}_j) \qquad (5-6-2)$$

式中：$\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_N$ 为独立取自同一总体 $\boldsymbol{x}$ 的样本。

下面我们给出一般性的位势函数逼近算法。

设 $\{\varphi_i(\boldsymbol{x})\}$ 是特征空间 Ω 中的完备正交函数集，被逼近的判决函数可以表示为

$$f(\boldsymbol{x}) = \sum_{i=1}^{m} c_i\varphi_i(\boldsymbol{x}) \qquad (5-6-3)$$

由于上式的项数是有限的，这表示 $f(\boldsymbol{x})$ 是光滑的，小范围内不应有许多拐点。设位势函数

$$K(\boldsymbol{x},\boldsymbol{x}_j) = \sum_{i=1}^{\infty}\lambda_i^2\varphi_i(\boldsymbol{x})\varphi_i(\boldsymbol{x}_j) \triangleq \sum_{i=1}^{\infty}\psi_i(\boldsymbol{x})\psi_i(\boldsymbol{x}_j) \qquad (5-6-4)$$

式中：

$$\psi_i(\boldsymbol{x}) = \lambda_i\varphi_i(\boldsymbol{x}),\lambda_i > 0,\sum_{i=1}^{\infty}\lambda_i^2 < \infty \qquad (5-6-5)$$

逼近 $f(\boldsymbol{x})$ 的迭代公式为

$$f_{j+1}(\boldsymbol{x}) = f_j(\boldsymbol{x}) + \gamma_j K(\boldsymbol{x},\boldsymbol{x}_{j+1}) \qquad (5-6-6)$$

设 $f_j(\boldsymbol{x})$ 按 $\{\varphi_i(\boldsymbol{x})\}$ 展成级数，取其 m 项，各项系数为 $c_{j,i}$。令 $\tilde{c}_{j,i} = c_{j,i}/\lambda_i$，于是

$$f_j(\boldsymbol{x}) = \sum_i c_{j,i}\varphi_i(\boldsymbol{x}) = \sum_i \tilde{c}_{j,i}\psi_i(\boldsymbol{x}) \qquad (5-6-7)$$

由迭代式(5 - 6 - 6) 可得 $f_j(\boldsymbol{x})$ 的展开式系数的迭代式

$$c_{j+1,i} = c_{j,i} + \gamma_j \lambda_i^2 \varphi_i(\boldsymbol{x}_{j+1})$$

$$\tilde{c}_{j+1,i} = \tilde{c}_{j,i} + \gamma_j \psi_i(\boldsymbol{x}_{j+1}) \qquad (5-6-8)$$

各种不同的位势函数算法实际上只是修正规则 $\{\gamma_j\}$ 取法不同。

一般地,利用式(5 - 6 - 8) 递归地算出系数 $\tilde{c}_{j,i}(i = 1,2,\cdots,m)$,从而也就递归地得到了逼近式 $f_j(x)$。设在输入训练样本 x_j 后,已算出 $\tilde{c}_{j,i}(i = 1,2,\cdots,m)$。再输入一个训练样本 x_{j+1} 后,首先算出 $\psi_i(x_{j+1})$ $(i = 1,2,\cdots,m)$,然后按式(5 - 6 - 7) 计算 $f_j(x_{j+1})$,之后根据式(5 - 6 - 8) 计算 $\tilde{c}_{j,i}(i = 1,2,\cdots,m)$,该式中的 γ_j 可按下面关系取值:

$$\gamma_j = \begin{cases} 0 & (x_{j+1} \in \omega_1 \text{ 且 } f_j(x_{j+1}) > 0) \\ 0 & (x_{j+1} \in \omega_2 \text{ 且 } f_j(x_{j+1}) < 0) \\ 1 & (x_{j+1} \in \omega_1 \text{ 且 } f_j(x_{j+1}) < 0) \\ -1 & (x_{j+1} \in \omega_2 \text{ 且 } f_j(x_{j+1}) > 0) \end{cases}$$

位势函数算法也适用于多类问题。

5.7 错误率估计

5.7.1 分类器错误率的实验估算基本原理

第 4 章讨论的是分类识别的一般性原理算法,为区别起见,解决某一实际问题的具体的分类识别算法称为分类器。由前面的章节可知,分类识别算法的误判概率的理论分析与计算一般来讲是非常困难的,只有在某些特殊的情况下才能有解析式或是可计算的;另外,绝大多数分类器的误判概率须运用训练样本对其训练产生。鉴于上述的情况,通过实验的方法估计误判概率具有极为重要的意义。误判概率的估值通常称为错误率。

设用含 N 个已知类别测试样本的测试集对分类器进行检验,如果其中有 m 个测试样本判错了,那么错误率等于 $\frac{m}{N}$。这个结论在下面将进

一步讨论。

为了能提高分类器的识别率，对训练样本以及它们的各特征分量都有一些基本的要求。由于可用的特征可能很多，应首选不同类别差别较大而相同类别差别较小的特征，而且希望各特征分量是不相关的。还希望对各个样本的抽取是独立的并且有代表性或称典型性，所谓代表性是指训练样本在类内足够地散开，并且密集和稀疏反映了模式的分布情况，研究表明，对分类识别最重要的训练样本是位于类域边界上的样本。为使运用实验的方法得到的错误率更接近误判概率，要求每个测试样本都是独立抽取的，并且测试样本集应该独立于训练样本集，还要求样本具有代表性。样本抽取的方法有很多种，不同的方法将有不同的估计特性。这里只讨论随机抽取和按类概率选择抽取两种基本的情况。

5.7.2 样本抽取方式对误判概率估计的影响

下面我们用统计估计的基本原理和方法分析用测试样本集估计误判概率的可行性以及相应的估计性能。

1. 随机抽取样本的情况

如果不知道各类的先验概率，也不知道各类的分布情况，这时可以任意随机地抽取样本。一般地讲，一个分类器对各个样本的分类识别的错误率是不同的，而且在概念上也不同于特征空间上的误判概率。为简单计，在一定条件下，我们将两者看做是相等的。

设对每个样本的误判概率为 P_e，又设对于 N 个测试样本，有 m 个判错了，显然 m 是服从二项分布的随机变量，m 出现的概率为

$$P_N(m) = C_N^m P_e^m (1 - P_e)^{N-m} \qquad (5-7-1)$$

设 m 是取定的，上式则是关于 P_e 的似然函数。上式取对数然后对 P_e 求导并令其为零，有

$$\frac{\partial \ln P_N(m)}{\partial P_e} = \frac{m}{P_e} - \frac{N-m}{1-P_e} = 0 \qquad (5-7-2)$$

由式(5 - 7 - 2) 可得

$$\hat{P}_e = m/N \qquad (5-7-3)$$

可知，错误率 $\hat{P}_e = m/N$ 实际上是在一些设定下误判概率的最大似然估

计。

2. 依类的概率比例抽取样本的情况

设已知两类的概率分别为 $P(\omega_1)$ 和 $P(\omega_2)$，令允许抽取测试样本数为 N，从 ω_1 类中抽取 $N_1 = P(\omega_1)N$ 个样本，从 ω_2 类中抽取 $N_2 = P(\omega_2)N$ 个样本。又设测试结果有 m_1 个 ω_1 类的样本和 m_2 个 ω_2 类的样本被错判，两种情况同时发生的概率为

$$\begin{aligned} P_N(m_1, m_2) &= P_{N_1}(m_1)P_{N_2}(m_2) \\ &= C_{N_1}^{m_1} e_{12}^{m_1}(1 - e_{12})^{N_1 - m_1} C_{N_2}^{m_2} e_{21}^{m_2}(1 - e_{21})^{N_2 - m_2} \end{aligned} \tag{5-7-4}$$

上式中，e_{12} 和 e_{21} 分别表示将属于 ω_1 类和 ω_2 类的样本错判的概率，由上述同样可以求出 e_{12} 和 e_{21} 的最大似然估计

$$\hat{e}_{12} = \frac{m_1}{N_1}, \hat{e}_{21} = \frac{m_2}{N_2}$$

于是误判概率的估计为

$$\hat{P}_N(e) = P(\omega_1)\hat{e}_{12} + P(\omega_2)\hat{e}_{21} = \frac{m_1 P(\omega_1)}{N_1} + \frac{m_2 P(\omega_2)}{N_2} \tag{5-7-5}$$

可以证明，随机抽取和比例抽取的样本对误判概率的估计都是无偏的。但比例抽取的样本一般地比随机抽取样本对误判概率估计的方差要少。

5.7.3 训练与测试样本集的大小对错误率的影响

上面讨论的是用测试样本集对分类器的理论错误率（误判概率）进行检测估计，然而一个面向实际问题的分类器往往是由一般性的分类识别原理算法、利用训练样本进行训练产生的，所以一个分类器的设计错误率和具体的训练样本集有关。所谓的设计错误率是指对利用训练样本产生的分类器，运用理论上完善的测试方法所检测的错误率。设计错误率要大于理论错误率。如果训练样本集性能质量较好，设计错误率就接近理论错误率。由测试样本集对分类器检测所得的估计错误率

显然和测试样本集的性能质量有关。因此，对一个分类器进行错误率测试所得结果，既和训练集的性能有关，也与测试集的性能有关。下面分析由训练集和测试集的不同组合产生的错误率和误判概率的关系。

当有无限多个典型的训练样本和测试样本时，由于这都是理想情况，分类器的设计错误率等于理论错误率，估计错误率也等于理论错误率。

当有无限多个典型的训练样本和 N 个测试样本时，由于是无限多个典型的训练样本，这属理想情况，分类器性能可达到理论上的最优，因此分类器的设计错误率等于理论错误率；由于测试样本只有 N 个，估计错误率一般地要依赖于具体的估计方法和样本情况，很多情况下要小于理论错误率但有时结论却相反。对于某些无偏估计（如最大似然估计），两者的期望值是相等的。

当有 N 个训练样本和无限多个典型的测试样本时，由于训练样本是有限的，分类器性能达不到理论上的最优，此时分类器的设计错误率大于理论错误率；又由于用无限多个各种样本去测试，所以估计错误率要大于等于设计错误率。

当用同样的 N 个样本去训练和测试时，虽然这 N 个样本不能使训练达到理论上的最优，但由于还用它们去测试，显然这种情况下错误率是最低的。

5.7.4 训练样本使用技术及错误率的测试方法

人们希望设计错误率等于或接近理论错误率，推广性好，错误率估计值尽量接近真实值，但现在的问题是，我们所得的样本总是有限的，为从这有限的样本中既得到训练样本又得到测试样本，或为利用这有限的样本最大程度地提高分类器性能，可采用下述方法。

（1）分组固定法。我们将已知类别的 N 个样本随机地分成两组，其中 N_1 个样本作为训练集，另外的 N_2 个样本作为测试集，$N_1 + N_2 = N$。

（2）留一法。从 N 个样本中仅留出一个样本用作测试，其余的 $N-1$ 个样本用于训练，当训练和测试完后再从这 N 个样本中留出另一个样本用作测试，而其余的 $N-1$ 个样本用于训练；依此反复进行 N 次，若得到的判错次数为 m 次，则错误率估计 $\hat{P}(e) = m/N$。显然此方法计算

量较大。

(3) 分组轮换法(Fold Cross Validation)。它是将 N 个样本随机分成若干个组,每组 n 个样本,每次只取其中的一组样本作测试,其余各组均作训练用,当这次训练和测试完后改用另一组样本作测试,而其余组样本用于训练。依此反复进行直到每一组都用于测试过。

(4) 自助法(bootstrap)。从给定的 N 个样本中随机地可放回地取出 N 个样本组成一个新的样本集,这个操作重复 B 次,由此可以获得 B 个相互独立的自助样本集。显然每个新的样本集不可避免地存在样本的重复。自助样本集可以用于统计估计,也可以用于分类器的训练和测试。

习 题

5.1 设总体分布密度为 $N(\mu,\sigma^2)$,并设独立地采自这个总体的样本集 $X=\{x_1,x_2,\cdots,x_N\}$,运用矩法,最大似然方法求总体的均值和方差的估计 $\hat{\mu},\hat{\sigma}^2$。

5.2 对于多元正态分布 $N(\mu,\Sigma)$,推导出用最大似然估计方法估计均值和协方差的公式,并且明确地给出可能需要的假设条件。

5.3 证明对正态总体的期望 μ 和方差 σ^2 的最大似然估计 $\hat{\mu}$ 是无偏的,而 $\hat{\sigma}^2$ 是有偏的。

5.4 设总体为一维正态分布 $N(\mu,\sigma^2)$,利用独立地采自这个总体的样本集 $X=\{x_1,x_2,\cdots,x_N\}$ 和先验分布 $p(\mu)\sim N(\mu_0,\sigma_0^2)$,通过对总体 $N(\mu,\sigma^2)$ 进行贝叶斯学习,求得总体后验概率密度 $p(x\mid X)$,此处设 $\sigma^2,\mu_0,\sigma_0^2$ 已知。

(1) 试证 $p(x\mid X)$ 服从正态分布 $N(\mu_N,\sigma^2+\sigma_N^2)$;

(2) 证明 $\mu_N=(\sigma^2\mu_0+N\sigma_0^2\hat{\mu}_N)/(\sigma^2+N\sigma_0^2)$,其中 $\hat{\mu}_N=\dfrac{1}{N}\sum_{i=1}^{N}x_i$;

(3) 证明方差为 $\sigma^2+\sigma_N^2$,其中 $\sigma_N^2=\sigma^2\sigma_0^2/(\sigma^2+N\sigma_0^2)$;

(4) 说明总方差为什么大于 σ^2;

(5) 当 $N \to \infty$ 时,总方差有什么变化;

(6) 利用贝叶斯学习的性质分析(3) 的结果。

5.5 令 $X = \{x_1, x_2, \cdots, x_N\}$ 为独立来自总体 $N(\mu, \Sigma)$ 的样本集,设 μ 的先验分布为 $p(\mu) \sim N(\mu_0, \Sigma_0)$,且 Σ, μ_0, Σ_0 已知,仿 5.4 求得总体后验概率密度 $p(x \mid X)$。

5.6 设 $X = \{x_1, x_2, \cdots, x_N\}$ 为来自二项分布的样本集,即

$$P(x, p) = p^x q^{1-x} \quad (x = 0, 1; 0 < p < 1; q = 1 - p)$$

试求参数 p 的最大似然估计量 $\hat{p}$。

5.7 运用贝叶斯学习的性质,说明当样本数 N 趋于无穷大时,最大似然估计将等价于贝叶斯估计。

5.8 设 $X = \{x_1, x_2, \cdots, x_N\}$ 是独立地采自总体的随机样本集,其概率密度 $p(x \mid \theta)$ 是均匀分布的:

$$p(x \mid \theta) \sim U(0, \theta) = \begin{cases} \dfrac{1}{\theta} & (0 \leqslant x \leqslant \theta) \\ 0 & (\text{其他}) \end{cases}$$

(1) 证明 θ 的最大似然估计是 $\max_k [x_k]$。

(2) 假设 $N = 5$,并且有 $\max_k [x_k] = 0.6$,画出在区间 $0 \leqslant \theta \leqslant 1$ 上的似然函数。$p(X \mid \theta)$ 并且解释为什么此时不需要知道其余 4 个点的值。

5.9 最大似然估计也可以用于估计先验概率。假设样本是独立地从自然状态 ω_i 中抽取的,每一个自然状态的概率为 $P(\omega_i)$。如果第 k 个样本的自然状态为 ω_i,那么就记为 $z_{ik} = 1$,否则 $z_{ik} = 0$。

(1) 证明

$$P(z_{i1}, \cdots, z_{iN} \mid P(\omega_i)) = \prod_{k=1}^{N} P(\omega_i)^{z_{ik}} (1 - P(\omega_i))^{1 - z_{ik}}$$

(2) 证明对 $P(\omega_i)$ 的最大似然估计为

$$\hat{P}(\omega_i) = \frac{1}{n} \sum_{k=1}^{n} z_{ik}$$

并且简单解释这个结果。

5.10 设 $\boldsymbol{x}$ 为 n 维二值矢量(即其分量取值为0或1),服从伯努利分布

$$P(\boldsymbol{x} \mid \boldsymbol{\theta}) = \prod_{i=1}^{n} p_i^{x_i}(1-p_i)^{1-x_i}$$

其中 $\boldsymbol{\theta} = (\theta_1, \cdots, \theta_n)^{\mathrm{T}}$ 是一个未知的参数矢量,而 p_i 为 $x_i = 1$ 的概率。证明,对于 θ 的最大似然估计为

$$\hat{\theta} = \frac{1}{N}\sum_{k=1}^{N} \boldsymbol{x}_k$$

5.11 在一个二类问题中,$P(\omega_1) = P(\omega_2) = 0.5$,而样本 $\boldsymbol{x}$ 的分量为二值变量。假设每一个分量 x_i 取1的概率为

$$p_{i1} = p$$

$$p_{i0} = 1 - p$$

其中规定 $p > \frac{1}{2}$。并且已知当维数 n 趋近于无穷时,误差概率趋近于0。这个问题要求讨论对某一个特定的样本,当增加其特征的个数时的情况。

(1) 假设这个样本 $\boldsymbol{x} = (x_1, \cdots, x_n)^{\mathrm{T}}$ 属于类别 ω_1,证明 p 的最大似然估计为

$$\hat{p} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

(2) 描述当 n 趋于无穷时,$\hat{p}$ 的性质。并且说明,为什么即使在每一类别只有一个样本的情况下,仅仅靠增加特征的个数,就能使分类误差概率无限的小。

5.12 证明最大似然估计不变性:如果 $\hat{\theta}$ 为 θ 的最大似然估计,那么对于任意的可微函数 $g(\cdot)$,对 $g(\theta)$ 的最大似然估计是 $\tau(\hat{\theta})$。

5.13 设 $p(x) \sim N(\mu, \sigma^2)$,窗函数 $\varphi(x) \sim N(0,1)$,证明 Parzen 窗估计

$$\hat{p}_N(x) = \frac{1}{Nh_N}\sum_{i=1}^{N} \varphi\left(\frac{x - x_i}{h_N}\right)$$

对于较小的 h_N,有如下的性质:

(1)$\mathrm{E}[\hat{p}_N(x)] \sim N(\mu, \sigma^2 + h_N^2)$;

(2)$\mathrm{Var}[\hat{p}_N(x)] = \dfrac{1}{Nh_N 2\sqrt{\pi}} p(x)$;

(3)$p(x) - \mathrm{E}[\hat{p}_N(x)] \approx \dfrac{1}{2}\left(\dfrac{h_N}{\sigma}\right)^2 \left[1 - \left(\dfrac{x-\mu}{\sigma}\right)^2\right] p(x)$。

注意,如果 $h_N = h_1/\sqrt{N}$,那么这个结果表示由于偏差而导致的误差率以 $1/N$ 的速度趋向于零,而噪声的标准差以速度 $\sqrt[4]{N}$ 趋于零。

5.14 令 $p(x) \sim U(0,a)$,而窗函数为当 $x > 0$ 时,$\varphi(x) = \mathrm{e}^{-x}$,当 $x \leqslant 0$ 时则为零。

(1) 证明这个 Parzen 窗估计的均值为

$$\mathrm{E}[\hat{p}_N(x)] = \begin{cases} 0 & (x < 0) \\ \dfrac{1}{a}(1 - \mathrm{e}^{-x/h_N}) & (0 \leqslant x \leqslant a) \\ \dfrac{1}{a}(\mathrm{e}^{a/h_N} - 1)\mathrm{e}^{-x/h_N} & (a \leqslant x) \end{cases}$$

(2) 画出当 $a = 1$,而 h_N 分别等于 1,1/4,1/16 时的 $\mathrm{E}[\hat{p}_N(x)]$ 关于 x 的函数图像。

(3) 为了在区间 $0 < x < a$ 的 99% 处都有小于 1% 的误差,那么 h_N 的值应该至少多小?

(4) 在这种情况下,对于 $a = 1$,求 h_N 的值。并且画出区间 $0 \leqslant x \leqslant 0.05$ 的 $\mathrm{E}[\hat{p}_N(x)]$ 的函数图像。

5.15 证明当 $\lim\limits_{N\to\infty} V_N = 0$, $\lim\limits_{N\to\infty} k_N = \infty$ 和 $\lim\limits_{N\to\infty} k_N/N = 0$ 时,式(5-4-8)收敛到 $p(x)$。

5.16 利用正交函数展开逼近法,试求两类模式的类概率密度的估计 $\hat{p}(x \mid \omega_1)$ 和 $\hat{p}(x \mid \omega_2)$,训练样本分别为

ω_1:$(-5,-5)^{\mathrm{T}}$,$(-5,-4)^{\mathrm{T}}$,$(-4,-5)^{\mathrm{T}}$,$(-6,-5)^{\mathrm{T}}$,$(-5,-6)^{\mathrm{T}}$

ω_2:$(5,5)^{\mathrm{T}}$,$(5,6)^{\mathrm{T}}$,$(6,5)^{\mathrm{T}}$,$(5,4)^{\mathrm{T}}$,$(4,5)^{\mathrm{T}}$

(1) 试用正交的埃尔米特多项式的前四项低阶基函数计算各

系数；

(2) 令两类先验概率相等，求贝叶斯判决函数；

(3) 给出决策面方程，并且图示。

算法编程

以下部分练习使用下表的数据：

表 5.1

样本	ω_1			ω_2			ω_3		
	x_1	x_2	x_3	x_1	x_2	x_3	x_1	x_2	x_3
1	0.42	-0.087	0.58	-0.40	0.58	-0.089	0.835	1.60	-0.014
2	-0.20	-3.00	-3.40	-0.31	0.27	-0.04	1.10	1.60	0.48
3	1.30	-0.32	1.70	0.38	0.055	-0.035	-0.44	-0.41	0.32
4	0.39	0.71	0.23	-0.15	0.53	0.011	0.047	-0.45	1.40
5	-1.6	-5.3	-0.15	-0.35	0.47	0.034	0.28	0.35	3.10
6	-0.029	0.89	-4.70	0.17	0.69	0.10	-0.39	-0.48	0.11
7	-0.23	1.90	2.20	-0.011	0.55	-0.18	0.34	-0.079	0.14
8	0.27	-0.30	-0.87	-0.27	0.61	0.12	-0.30	-0.22	2.2
9	-1.90	0.76	-2.10	-0.065	0.49	0.0012	1.10	1.20	-0.46
10	0.87	-1.0	-2.6	-0.12	0.054	-0.063	0.18	-0.11	-0.49

5.1 考虑不同维数下的正态分布模型。

(1) 编写程序，对表中的 ω_1 类中的 3 个特征 x_i，分别求解最大似然估计 $\hat{\mu}$ 和 $\hat{\sigma}^2$；

(2) 修改程序，处理二维数据的情形 $p(x) \sim N(\mu,\Sigma)$。然后处理对表中的 ω_1 类中的任意两个特征的组合(共 3 种可能)；

(3) 修改程序，处理三维数据的情形 $p(x) \sim N(\mu,\Sigma)$。然后处理对表中的 ω_1 类中的 3 个特征的组合；

(4) 假设这个三维正态模型是可分离的，即 $\Sigma = \mathrm{diag}(\sigma_1^2,\sigma_2^2,\sigma_3^2)$，写一个程序估计类别 ω_2 中的均值和协方差矩阵中的 3 个参数；

(5) 比较前4种方式计算出来的每一个特征的均值μ_i的异同，并加以解释；

(6) 比较前4种方式计算出来的每一个特征的方差σ_i的异同，并加以解释。

5.2 考虑一个具有两个参数的一维三角形概率模型

$$p(\boldsymbol{x} \mid \boldsymbol{\theta}) \equiv T(\boldsymbol{\mu},\delta) = \begin{cases} (\delta - \mid \boldsymbol{x} - \boldsymbol{\mu} \mid)/\delta^2 & (\mid \boldsymbol{x} - \boldsymbol{\mu} \mid < \delta) \\ 0 & (\text{其他}) \end{cases}$$

其中$\boldsymbol{\theta} = \begin{pmatrix} \boldsymbol{\mu} \\ \delta \end{pmatrix}$。编写程序，对类别$\omega_2$种的特征$x_2$使用贝叶斯方法估计概率密度$p(\boldsymbol{x} \mid X)$。并且画出后验概率$p(\boldsymbol{x} \mid X)$。

5.3 考虑对一维正态分布$N(\mu,\sigma^2)$均值进行贝叶斯估计。假设已知均值服从分布$p(\mu) \sim N(\mu_0,\sigma_0)$。

(1) 编写程序，画出已知μ_0,σ_0,σ和训练样本集$X = \{x_1,\cdots,x_N\}$时的概率密度$p(x \mid X)$。

(2) 对类别ω_3中的特征x_2，估计它的σ。假设$\mu_0 = -1$，分别对下列值：σ^2/σ_0^2:0.1,1.0,10,100画出估计结果$p(x \mid X)$。

5.4 考虑不同维数下的误差概率。

(1) 对类别ω_1和ω_2中的三维数据，使用最大似然估计算法训练判别函数，并且使用数值积分来估计分类误差概率。

(2) 把这些数据投影到二维子空间中。对下列的三个子空间——分别根据$x_1 = 0,x_2 = 0,x_3 = 0$来定义——训练高斯判别函数。并且使用数值积分来估计分类误差概率。

(3) 把这些数据投影到一维子空间中，也分别根据3个坐标轴来定义。训练高斯判别函数。并且使用数值积分来估计分类误差概率。

(4) 讨论误差概率的排序(Rank Order)。

5.5 考虑Fisher判别方法(使用第5章的数据)。

(1) 编写用Fisher判别方法对三维数据求最优方向$\boldsymbol{w}$的通用程序。

(2) 对表格中的类别ω_2和ω_3，计算最优方向$\boldsymbol{w}$。

(3) 画出表示最优方向$\boldsymbol{w}$的直线，并且标记出投影后的点在直线

上的位置。

(4) 在这个子空间中,对每种分布用一维高斯函数拟合,并且求分类决策面。

(5)(2) 中得到的分类器的训练误差是什么?

(6) 为了比较,使用非最优方向 $\boldsymbol{w} = (1.0, 2.0, -1.5)^{\mathrm{T}}$ 重复(4)(5) 两个步骤。在这个非最优子空间中,训练误差是什么。

以下部分练习使用表 5.2 的数据。

表 5.2

样本	ω_1			ω_2			ω_3		
	x_1	x_2	x_3	x_1	x_2	x_3	x_1	x_2	x_3
1	0.28	1.31	-6.2	0.011	1.03	-0.21	1.36	2.17	0.14
2	0.07	0.58	-0.78	1.27	1.28	0.08	1.41	1.45	-0.38
3	1.54	2.01	-1.63	0.13	3.12	0.16	1.22	0.99	0.69
4	-0.dd	1.18	-4.32	-0.21	1.23	-0.11	2.46	2.19	1.31
5	-0.81	0.21	5.73	-2.18	1.39	-0.19	0.68	0.79	0.87
6	1.52	3.16	2.77	0.34	1.96	-0.16	2.51	3.22	1.35
7	2.20	2.42	-0.19	-1.38	0.94	0.45	0.60	2.44	0.92
8	0.91	1.94	6.21	-0.12	0.82	0.17	0.64	0.13	0.97
9	0.65	1.93	4.38	-1.44	2.31	0.14	0.85	0.58	0.99
10	-0.26	0.82	-0.96	0.26	1.94	0.08	0.66	0.51	0.88

5.6 研究一些概率密度函数的估计的特性:

(1) 编写程序,产生服从在单位立方体内($-\frac{1}{2} \leqslant x_i \leqslant \frac{1}{2}$, $i = 1, 2, 3$) 均匀分布的样本点。共产生 10^4 个。

(2) 编写程序,基于这 10^4 个样本,估计原点附近的概率密度,作为边长为 h 的立方体窗函数。并且对于 $0 < h \leqslant 1$,画出估计的函数图像。

(3) 估计原点附近的概率密度,使用 $N < 10^4$ 个样本,并且选择窗使得恰好包含进 N 个样本点。对于 $N = 1, 2, \cdots, 10^4$,画出估计的函数图像。

(4) 编写程序,产生服从正态分布 $N(0, \boldsymbol{I})$ 样本点。利用你的正态数据重复(2) 和(3)。

(5) 定性地讨论在均匀和正态密度两种情况下，估计结果对函数形式的依赖性的异同。

5.7 考虑使用表中的数据进行 Parzen 窗估计和设计分类器。取窗函数为高斯函数：

$$\varphi((\boldsymbol{x}-\boldsymbol{x}_i)/h) \propto \exp[-(\boldsymbol{x}-\boldsymbol{x}_i)^{\mathrm{T}}(\boldsymbol{x}-\boldsymbol{x}_i)/(2h^2)]$$

(1) 编写程序，使用 Parzen 窗估计方法对一个任意的测试样本点 $\boldsymbol{x}$ 进行分类。对分类器的训练使用表中的三维数据。同时令 $h=1$，分类样本点为 $(0.5,1.0,0.0)^{\mathrm{T}}$，$(0.31,1.51,-0.50)^{\mathrm{T}}$，$(-0.3,0.44,-0.1)^{\mathrm{T}}$。

(2) 令 $h=0.1$，重复(1)。

5.8 考虑不同维数的空间中，使用 k - 近邻概率密度估计方法的效果。

(1) 编写程序，对于一维的情况，当有 N 个数据样本时，进行 k - 近邻概率密度估计。对表中的类别 ω_3 中的特征 x_1，用程序画出当 $k=1$，3，5 时的概率密度估计结果。

(2) 编写程序，对于二维的情况，当有 N 个数据样本时，进行 k - 近邻概率密度估计。对表中的类别 ω_2 中的特征 $(x_1,x_2)^{\mathrm{T}}$，用程序画出当 $k=1,3,5$ 时的概率密度估计结果。

(3) 对表中的 3 个类别的三维特征，使用 k - 近邻概率密度估计方法。并且对下列点处的概率密度进行估计：$(-0.41,0.82,0.88)^{\mathrm{T}}$，$(0.14,0.72,4.1)^{\mathrm{T}}$，$(-0.81,0.61,-0.38)^{\mathrm{T}}$。

第6章　特征提取与选择

在一个较完善的模式识别系统中，或者明显地或者隐含地要有特征提取与选择技术环节，通常其处于对象特征数据采集和分类识别两个环节之间，特征提取与选择方法（或质量）的优劣极大地影响着分类器的设计和性能，它是模式识别三大核心问题之一。

特征提取与选择的基本任务是研究如何从众多特征中求出那些对分类识别最有效的特征，从而实现特征空间维数的压缩。本章讨论从模式样本的诸量测中提取与选择最能有效反映类别属性特征的主要原则和方法，其中包括基于类别可分性判据、Fisher 准则函数、判决边界的方法，基于 DKLT 提取与选择特征（主成分分析方法）及独立分量分析方法，还介绍如何直接从众多的特征中依据可分性判据选择特征。

6.1　概　述

分类识别的正确率取决于对象的表示、训练学习和分类识别算法，后两方面的内容在书中已有较深入讨论，在本章中重点讨论特征提取与选择问题，这是对象表示的一个关键问题。从直观上可知，在特征空间中如果同类模式分布比较密集，不同类模式相距较远，分类识别就比较容易正确，因此，在从实际对象提取特征时要求所提取的特征对不同类的对象差别很大而同类对象差别较小，这将给后续分类识别环节带来很大的便益。但是由于某些原因，我们提取的特征没有使模式显著地如上述那样分布，或者所得的特征过多。为了保证所要求的分类识别的正确率和尽量节省资源，我们希望依据最少的特征达到所要求的分类识别的正确率。另外在实际应用中，通常发现特征个数增加到某一个值时，若再继续增加，反而会导致分类器的性能变差，这主要原因

是所选的模型与实际不匹配，或是可用的训练样本个数不够多。因此，通常在得到实际对象的若干具体特征之后，再由这些原始特征产生出对分类识别最有效、数目最少的特征，这就是特征提取与选择的任务。在实现上述目标时，往往需要首先制定特征提取与选择的准则，可直接以反映类内类间距离的函数作为准则，或直接以误判概率最小作为准则，也可以用类别判决函数作为准则，还可以构造与误判概率有关的判据来刻画特征对分类识别的贡献或者有效性。在具体实施特征提取与选择时有如下两个基本途径。

(1)当实际用于分类识别的特征数目 d 给定后，直接从已获得的 n 个原始特征中选出 d 个特征 $x_1, x_2, \cdots, x_d$，使可分性判据 J 的值满足

$$J(x_1, x_2, \cdots, x_d) = \max[J(x_{i1}, x_{i2}, \cdots, x_{id})]$$

式中：$x_{i1}, x_{i2}, \cdots, x_{id}$ 是 n 个原始特征中的任意 d 个特征，此即直接寻找 n 维特征空间中的 d 维子空间。这类方法称为直接选择法，主要有分支定界法。

(2)在使判据 J 取最大的目标下，对 n 个原始特征进行变换降维，即对原 n 维特征空间进行坐标变换，再取子空间。这类方法称为变换法，其主要有：基于可分性判据的特征选择、基于误判概率的特征选择、离散 K-L 变换法(即主分量分析)、独立分量分析方法及基于决策界的特征选择等方法。

6.2 类别可分性判据

一般要依据某种准则进行特征提取与选择，为此应当首先构造这样的准则——类别可分性判据，这些判据应能反映各类在特征空间中的分布情况，应能刻画各特征分量在分类识别中的重要性或贡献。因此，我们希望所构造的可分性判据满足下列要求：

(1)与误判概率或误判概率的界限有单调关系。判据取最大(或最小)值时，误判概率最小。

(2)当特征相互独立时，判据有可加性，即

$$J_{ij}(x_1, x_2, \cdots, x_d) = \sum_{k=1}^{d} J_{ij}(x_k) \qquad (6-2-1)$$

式中，$x_1, x_2, \cdots, x_d$ 是对象不同种类特征的测量值，$J_{ij}(\cdot)$ 表示使用括号中的特征时 ω_i 类与 ω_j 类可分性判据函数。

(3)判据具有“距离”的某些特性，即

$$J_{ij} > 0, \text{当 } i \neq j \text{ 时；}$$

$$J_{ij} = 0, \text{当 } i = j \text{ 时；}$$

$$J_{ij} = J_{ji}$$

(4)对特征数目是单调不减，即加入新的特征后，判据值不减，

$$J_{ij}(x_1, x_2, \cdots, x_d) \leqslant J_{ij}(x_1, x_2, \cdots, x_d, x_{d+1}) \qquad (6-2-2)$$

应该指出的是，所构造的可分性判据并不一定同时具有上述 4 个性质，但这并不影响它在实际使用中的价值。

6.2.1 基于几何距离的可分性判据

一般地讲，不同类的模式可以被区分是因为它们所属类别在特征空间中的类域是不同的区域。显然这些区域重叠的部分越小或完全没有重叠，类别的可分性越好，因此可以用几何距离或离差测度来构造类别可分性判据。为了应用方便，下面首先给出一些重要的距离定义。

1. 点与点的距离

在 n 维特征空间中，特征点 $\boldsymbol{a} = (a_1, a_2, \cdots, a_n)^{\mathrm{T}}$ 与特征点 $\boldsymbol{b} = (b_1, b_2, \cdots, b_n)^{\mathrm{T}}$ 之间的欧氏距离为

$$d(\boldsymbol{a}, \boldsymbol{b}) = [(\boldsymbol{a} - \boldsymbol{b})^{\mathrm{T}}(\boldsymbol{a} - \boldsymbol{b})]^{\frac{1}{2}} = \left[\sum_{k=1}^{n} (a_k - b_k)^2\right]^{\frac{1}{2}} \qquad (6-2-3)$$

2. 点到点集的距离

特征点 $\boldsymbol{x}$ 到特征点集 $\omega_i = \{\boldsymbol{a}_k^{(i)}, k = 1, 2, \cdots, N_i\}$ 之间的均方欧氏距离为

$$\bar{d}^2(\boldsymbol{x}, \{\boldsymbol{a}_k^{(i)}\}) = \frac{1}{N_i} \sum_{k=1}^{N_i} d^2(\boldsymbol{x}, \boldsymbol{a}_k^{(i)}) \qquad (6-2-4)$$

式中：$d^2(\boldsymbol{x}, \boldsymbol{a}_k^{(i)})$ 表示 $\boldsymbol{x}$ 和 $\boldsymbol{a}_k^{(i)}$ 之间的欧氏距离平方。

3. 类内及总体的均值矢量

设 N 个模式样本$\{x_l\}$分属 c 类,记为 $\omega_i=\{x_k^{(i)},k=1,2,\cdots,N_i\}$,$i=1,2,\cdots,c$,则各 ω_i 类模式的样本均值矢量为

$$\boldsymbol{m}^{(i)}=\frac{1}{N_i}\sum_{k=1}^{N_i}\boldsymbol{x}_k^{(i)}\ (i=1,2,\cdots,c) \tag{6-2-5}$$

所有各类模式的总体样本均值矢量为

$$\boldsymbol{m}=\sum_{i=1}^{c}P_i\boldsymbol{m}^{(i)} \tag{6-2-6}$$

式中:P_i 为相应类的先验概率。当用统计量代替先验概率时,有

$$P_i=\frac{N_i}{N}$$

$$\boldsymbol{m}=\sum_{i=1}^{c}P_i\boldsymbol{m}^{(i)}=\sum_{i=1}^{c}\frac{N_i}{N}\boldsymbol{m}^{(i)}=\frac{1}{N}\sum_{i=1}^{c}\sum_{k=1}^{N_i}\boldsymbol{x}_k^{(i)}=\frac{1}{N}\sum_{l=1}^{N}\boldsymbol{x}_l \tag{6-2-7}$$

4. 类内距离

设类 $\omega_i=\{x_k^{(i)},k=1,2,\cdots,N_i\}$,其样本均值矢量为 $\boldsymbol{m}^{(i)}$,则由样本集定义的类内均方欧氏距离为

$$\bar{d}^2(\omega_i)=\frac{1}{N_i}\sum_{k=1}^{N_i}(\boldsymbol{x}_k^{(i)}-\boldsymbol{m}^{(i)})^{\mathrm{T}}(\boldsymbol{x}_k^{(i)}-\boldsymbol{m}^{(i)}) \tag{6-2-8}$$

类内均方距离也可定义为

$$\bar{d}_c^2(\omega_i)=\frac{1}{N_i(N_i-1)}\sum_{k}\sum_{l}d^2(\boldsymbol{x}_k^{(i)},\boldsymbol{x}_l^{(i)}) \tag{6-2-9}$$

式中:$d^2(\boldsymbol{x}_k^{(i)},\boldsymbol{x}_l^{(i)})$为模式 $\boldsymbol{x}_k^{(i)}$ 和 $\boldsymbol{x}_l^{(i)}$ 的欧氏距离平方。

5. 类内离差矩阵

类内离差矩阵表示各类模式样本在本类的样本均值矢量周围散布情况。设 $\omega_i=\{x_k^{(i)},k=1,2,\cdots,N_i\}$,$\boldsymbol{m}^{(i)}$ 为 ω_i 类的样本均值矢量,则类内离差矩阵为

$$\boldsymbol{S}_{\mathrm{W}_i}=\frac{1}{N_i}\sum_{k=1}^{N_i}(\boldsymbol{x}_k^{(i)}-\boldsymbol{m}^{(i)})(\boldsymbol{x}_k^{(i)}-\boldsymbol{m}^{(i)})^{\mathrm{T}} \tag{6-2-10}$$

显然,类内离差矩阵 $\boldsymbol{S}_{\mathrm{W}_i}$ 的迹等于类内均方欧氏距离,即

$$\bar{d}^2(\omega_i) = \mathrm{Tr}[\boldsymbol{S}_{\mathrm{W}_i}] \tag{6-2-11}$$

6. 两类之间的距离

设类 $\omega_i = \{\boldsymbol{x}_k^{(i)}, k = 1,2,\cdots,N_i\}$,类 $\omega_j = \{\boldsymbol{x}_l^{(j)}, l = 1,2,\cdots,N_j\}$,由两类样本集定义的 ω_i 与 ω_j 之间的平均距离为

$$\bar{d}(\omega_i,\omega_j) = \frac{1}{N_iN_j}\sum_{k=1}^{N_i}\sum_{l=1}^{N_j} d(\boldsymbol{x}_k^{(i)},\boldsymbol{x}_l^{(j)}) \tag{6-2-12}$$

式中:$d(\boldsymbol{x}_k^{(i)},\boldsymbol{x}_l^{(j)})$ 是某种定义下的两个模式间的距离。当取欧氏距离时,两类均方距离为

$$\bar{d}^2(\omega_i,\omega_j) = \frac{1}{N_iN_j}\sum_{k=1}^{N_i}\sum_{l=1}^{N_j} (\boldsymbol{x}_k^{(i)} - \boldsymbol{x}_l^{(j)})^{\mathrm{T}}(\boldsymbol{x}_k^{(i)} - \boldsymbol{x}_l^{(j)}) \tag{6-2-13}$$

7. 各类模式之间的总的均方距离

设 N 个模式分属 c 类,$\omega_i = \{\boldsymbol{x}_k^{(i)}, k = 1,2,\cdots,N_i\}$,$i = 1,2,\cdots,c$,各类模式之间总的样本平均距离为

$$\bar{d}(\boldsymbol{x}) = \frac{1}{2}\sum_{i=1}^{c} P_i \sum_{j=1}^{c} P_j \frac{1}{N_iN_j}\sum_{k=1}^{N_i}\sum_{l=1}^{N_j} d(\boldsymbol{x}_k^{(i)},\boldsymbol{x}_l^{(j)}) \tag{6-2-14}$$

式中:$d(\boldsymbol{x}_k^{(i)},\boldsymbol{x}_l^{(j)})$ 是 $\boldsymbol{x}_k^{(i)}$ 和 $\boldsymbol{x}_l^{(i)}$ 间的距离。当取欧氏距离时,总的均方距离为

$$\bar{d}^2(\boldsymbol{x}) = \frac{1}{2}\sum_{i=1}^{c} P_i \sum_{j=1}^{c} P_j \frac{1}{N_iN_j}\sum_{k=1}^{N_i}\sum_{l=1}^{N_j} (\boldsymbol{x}_k^{(i)} - \boldsymbol{x}_l^{(j)})^{\mathrm{T}}(\boldsymbol{x}_k^{(i)} - \boldsymbol{x}_l^{(j)}) \tag{6-2-15}$$

8. 多类情况下总的类内、类间及总体离差矩阵

设 N 个模式 $\{\boldsymbol{x}_l\}$ 分属 c 类,$\omega_i = \{\boldsymbol{x}_k^{(i)}, k = 1,2,\cdots,N_i\}$,$i = 1,2,\cdots,c$,$\boldsymbol{S}_{\mathrm{W}_i}$ 为 ω_i 类类内离差矩阵。则总的类内离差矩阵定义为

$$\boldsymbol{S}_{\mathrm{W}} = \sum_{i=1}^{c} P_i \boldsymbol{S}_{\mathrm{W}_i} = \sum_{i=1}^{c} P_i \frac{1}{N_i} \sum_{k=1}^{N_i} (\boldsymbol{x}_k^{(i)} - \boldsymbol{m}^{(i)})(\boldsymbol{x}_k^{(i)} - \boldsymbol{m}^{(i)})^{\mathrm{T}} \tag{6-2-16}$$

总的类间离差矩阵定义为

$$\boldsymbol{S}_{\mathrm{B}} = \sum_{i=1}^{c} P_i (\boldsymbol{m}^{(i)} - \boldsymbol{m})(\boldsymbol{m}^{(i)} - \boldsymbol{m})^{\mathrm{T}} \tag{6-2-17}$$

总体离差矩阵为

$$\boldsymbol{S}_{\mathrm{T}} = \frac{1}{N} \sum_{l=1}^{N} (\boldsymbol{x}_l - \boldsymbol{m})(\boldsymbol{x}_l - \boldsymbol{m})^{\mathrm{T}} \tag{6-2-18}$$

上面 3 式中，P_i 为 ω_i 类的样本频率，$\boldsymbol{m}^{(i)}$ 为 ω_i 类的样本均值矢量，$\boldsymbol{m}$ 为总的样本均值矢量，它们分别是如下的统计量：

$$P_i = \frac{N_i}{N} \qquad \boldsymbol{m}^{(i)} = \frac{1}{N_i} \sum_{k=1}^{N_i} \boldsymbol{x}_k^{(i)} \qquad \boldsymbol{m} = \frac{1}{N} \sum_{l=1}^{N} \boldsymbol{x}_l$$

以上各种定义式是建立在各类有限样本集上的，如果知道各类的理论统计知识，则可用各类的期望矢量代替均值矢量，协方差矩阵代替离差矩阵，先验概率代替频率。

易证得

$$\boldsymbol{S}_{\mathrm{T}} = \boldsymbol{S}_{\mathrm{W}} + \boldsymbol{S}_{\mathrm{B}} \tag{6-2-19}$$

$$\bar{d}^2(\boldsymbol{x}) = \mathrm{Tr}[\boldsymbol{S}_{\mathrm{W}} + \boldsymbol{S}_{\mathrm{B}}] = \mathrm{Tr}[\boldsymbol{S}_{\mathrm{T}}]$$

$\boldsymbol{S}_{\mathrm{W}}$、$\boldsymbol{S}_{\mathrm{B}}$、$\boldsymbol{S}_{\mathrm{T}}$ 为对称阵，而任意对称阵均可经正交变换对角化，且对角线上阵元为特征值。由离差阵的定义可知，此时对角线上的阵元具有方差、均方距离等涵义，且各分量不相关。正交变换为相似变换，变换后矩阵迹不变、行列式值亦不变。因此可以在原特征空间中用 $\boldsymbol{S}_{\mathrm{W}}$、$\boldsymbol{S}_{\mathrm{B}}$ 和 $\boldsymbol{S}_{\mathrm{T}}$ 的迹或行列式构造多个可分性判据。常用的有

$$J_1 = \mathrm{Tr}[\boldsymbol{S}_{\mathrm{W}}^{-1} \boldsymbol{S}_{\mathrm{B}}] \tag{6-2-20}$$

$$J_2 = \frac{\mathrm{Tr}[\boldsymbol{S}_{\mathrm{B}}]}{\mathrm{Tr}[\boldsymbol{S}_{\mathrm{W}}]} \tag{6-2-21}$$

容易证明，$\boldsymbol{S}_{\mathrm{W}}^{-1} \boldsymbol{S}_{\mathrm{B}}$ 的特征值或等价地讲 J_1 是非奇异线性变换下的不变

量，$\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 的特征值 $\lambda_1,\lambda_2,\cdots,\lambda_n$ 反映模式类间离差与类内离差的比值，我们希望选择的特征使 J_1 尽量的大，也希望选择的特征使 J_2 尽量的大。由于存在关系 $\boldsymbol{S}_{\mathrm{T}}=\boldsymbol{S}_{\mathrm{W}}+\boldsymbol{S}_{\mathrm{B}}$，因此可以构造一类基于 $\lambda_1,\lambda_2,\cdots,\lambda_n$ 的形式上不同、性能略有差别，但几乎等价的可分性判据：

$$J_3=\mathrm{Tr}[\boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{S}_{\mathrm{W}}+\boldsymbol{S}_{\mathrm{B}})]=\mathrm{Tr}[\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{T}}] \tag{6-2-22}$$

$$J_4=\frac{|\boldsymbol{S}_{\mathrm{W}}+\boldsymbol{S}_{\mathrm{B}}|}{|\boldsymbol{S}_{\mathrm{W}}|}=\frac{|\boldsymbol{S}_{\mathrm{T}}|}{|\boldsymbol{S}_{\mathrm{W}}|}=|\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{T}}| \tag{6-2-23}$$

在特征空间中，当类内模式较密聚，不同类模式相距较远时，分类就较容易，由上述各判据的构造可知，所算得的判据值也较大。也可采用：

$$J_5=\mathrm{Tr}[\boldsymbol{S}_{\mathrm{T}}^{-1}\boldsymbol{S}_{\mathrm{W}}]\Rightarrow\min$$

$$J_6=|\boldsymbol{S}_{\mathrm{T}}^{-1}\boldsymbol{S}_{\mathrm{W}}|\Rightarrow\min$$

$$J_7=\frac{\mathrm{Tr}[\boldsymbol{S}_{\mathrm{T}}]}{\mathrm{Tr}[\boldsymbol{S}_{\mathrm{W}}]}\Rightarrow\max$$

上述的各种可分性判据存在关联，其中一些判据如 J_1,J_4 等具有非奇异线性变换不变性。虽然各种可分性判据在本质上是相似的，但性能在一些情况下是不同的。

另外，由判据的构造也可以初步了解运用这类判据的原则和方法。

6.2.2 基于类的概率密度函数的可分性判据

首先研究两类问题。图 6.2.1 所示为两类一维情形下的概率密度。容易看出，图(a)中两类是完全可分的，因为所有使 $p(\boldsymbol{x}|\omega_1)\neq0$ 的点 $\boldsymbol{x}$ 都有 $p(\boldsymbol{x}|\omega_2)=0$；图(b)中两类是完全不可分的，因为对所有的 $\boldsymbol{x}$ 都有 $p(\boldsymbol{x}|\omega_1)=p(\boldsymbol{x}|\omega_2)$。由此启发我们可用两类概密函数的重叠程度来度量可分性，构造基于类概密的可分性判据。此处所谓的重叠程度是指两个概密函数相似的程度。用类概密构造的可分性判据 J_p 应满足：

(1) $J_p\geqslant0$。

(2) 当两类概密函数完全不重叠时，$J_p\Rightarrow\max$。

(3) 当两类概密函数完全重合时，$J_p=0$。

(4) 相对于两个概密具有“对称性”。

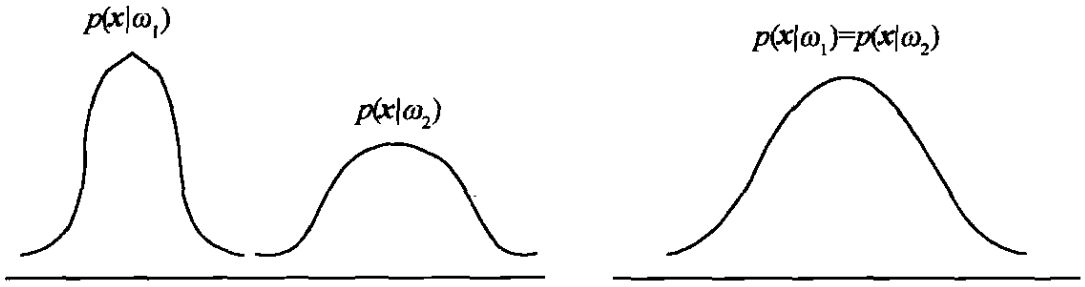


图 6.2.1　一维情形下两类概率密度分布的两种极端情况

可以在特征空间中通过对两类的概率密度函数的乘积(这类似于相关运算)、比或差的积分来刻画两类概密函数重叠的程度。下面介绍的 3 个判据 J_B、J_C 及 J_D 分别是根据某种概念和准则推导出来的,但从函数结构上看它们符合上述基本构造方式。它们均满足前 3 个性质,其中 J_B 和 J_D 判据还满足性质(4)。

设两类 ω_1 和 ω_2 的概率密度分别为 $p(\boldsymbol{x}\mid\omega_1)$ 和 $p(\boldsymbol{x}\mid\omega_2)$,$\boldsymbol{x}=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}$,下面构造 3 个基于概率密度的判据。

1. Bhattacharyya 判据(J_B)

受相关运算概念与应用的启发构造 B - 判据,它的计算式为

$$J_B=-\ln\int_{\Omega}[p(\boldsymbol{x}\mid\omega_1)p(\boldsymbol{x}\mid\omega_2)]^{\frac{1}{2}}\mathrm{d}\boldsymbol{x} \qquad (6-2-24)$$

式中:Ω 为特征空间。

在最小误判概率准则下,误判概率有

$$P_0(e)\leqslant[P(\omega_1)P(\omega_2)]^{\frac{1}{2}}\exp[-J_B] \qquad (6-2-25)$$

2. Chernoff 判据(J_C)

可以构造比 J_B 更一般的判据,称其为 C - 判据,其定义式为

$$J_C=-\ln\int_{\Omega}p(\boldsymbol{x}\mid\omega_1)^s p(\boldsymbol{x}\mid\omega_2)^{1-s}\mathrm{d}\boldsymbol{x}\triangleq J_C(s;x_1,x_2,\cdots,x_n)$$

$$\triangleq J_C(\omega_1,\omega_2;s)\triangleq J_C(s),\quad(0<s<1) \qquad (6-2-26)$$

易知,$J_C\left(\frac{1}{2}\right)=J_B$。

Bayes 误判概率有

$$P_0(e)\leqslant P(\omega_1)^s P(\omega_2)^{1-s}\exp[-J_C(\omega_1,\omega_2,s)]$$

3. 散度(J_D)

在贝叶斯判决中,似然比 $p(\boldsymbol{x}|\omega_1)/p(\boldsymbol{x}|\omega_2)$ 是 $\boldsymbol{x}$ 类别属性的重要度量,对于给定的门限 $P(\omega_2)/P(\omega_1)$,$p(\boldsymbol{x}|\omega_1)/p(\boldsymbol{x}|\omega_2)$ 越大,对 ω_1 类来讲可分性越好。从数学上讲,此比值也反映出 $p(\boldsymbol{x}|\omega_1)$ 和 $p(\boldsymbol{x}|\omega_2)$ 的重叠情况。为使概密完全重叠时判据为零,应对该比值取对数,还应在全域中考虑,并以分布密度作为"和"的权值即求数学期望。于是,可以构造出下面的 D-判据。

ω_1 类相对 ω_2 类的平均可分性信息为

$$I_{12}(\boldsymbol{x}) = \mathrm{E}_1\left[\ln\frac{p(\boldsymbol{x}|\omega_1)}{p(\boldsymbol{x}|\omega_2)}\right] = \int_{\Omega} p(\boldsymbol{x}|\omega_1)\ln\frac{p(\boldsymbol{x}|\omega_1)}{p(\boldsymbol{x}|\omega_2)}\mathrm{d}\boldsymbol{x} \tag{6-2-27}$$

ω_2 类相对 ω_1 类的平均可分性信息为

$$I_{21}(\boldsymbol{x}) = \mathrm{E}_2\left[\ln\frac{p(\boldsymbol{x}|\omega_2)}{p(\boldsymbol{x}|\omega_1)}\right] = \int_{\Omega} p(\boldsymbol{x}|\omega_2)\ln\frac{p(\boldsymbol{x}|\omega_2)}{p(\boldsymbol{x}|\omega_1)}\mathrm{d}\boldsymbol{x}$$

对于 ω_1 和 ω_2 两类总的平均可分性信息称为散度,其定义为

$$\begin{aligned} J_D &= I_{12}(\boldsymbol{x}) + I_{21}(\boldsymbol{x}) \\ &= \int_{\Omega}[p(\boldsymbol{x}|\omega_1) - p(\boldsymbol{x}|\omega_2)]\ln\frac{p(\boldsymbol{x}|\omega_1)}{p(\boldsymbol{x}|\omega_2)}\mathrm{d}\boldsymbol{x} \\ &\triangleq J_D(\omega_1,\omega_2) \triangleq J_D(x_1,x_2,\cdots,x_n) \end{aligned} \tag{6-2-28}$$

从数学构造上看上式是合理的,式中被积函数两概密的差和两概密的比能反映出两概密的重叠程度,同时被积函数中两因式永远同号,故其乘积非负。

6.2.3 基于后验概率的可分性判据

前面用类的概密来刻画类别的可分性,在那里各种可分性判据就其内涵来讲,是度量各类间概密重叠的程度。也可以用类的后验概率来刻画类别的可分性,在这里各种判据就其内涵来讲是度量各类后验概率的差别。在信息论中,从熵的定义可知,熵表示不确定性,熵越小不确定性越小,从熵的构造可知,各个概率的差别越大,熵越小,因此也

可以借用信息论中的熵来描述各类的可分性。

对于 c 类问题，设给定的 x 的各类后验概率为 $P(\omega_i|\boldsymbol{x}) \triangleq p_i (i=1,2,\cdots,c)$，$\sum_{i=1}^{c} p_i = 1$。熵的定义是

$$H_c(\boldsymbol{x}) \triangleq H_c(\boldsymbol{p}) = -\sum_{i=1}^{c} p_i \log p_i \qquad (6-2-29)$$

式中：$\boldsymbol{p} = (p_1, p_2, \cdots, p_c)^{\mathrm{T}}$。

当 $p_i = 0$ 时，定义 $p_i \log p_i = \lim_{p_i \to 0} p_i \log p_i$，由洛必达法则知，此时 $p_i \log p_i = 0$。

从特征提取与选择角度看，应选择使熵最小的那些特征用于分类识别，为一般性，基于统计的观点，要对整个特征空间中每一点的熵都应予以考虑，为此取熵的期望

$$J_{\mathrm{H}} = \mathrm{E}_x\left[-\sum_{i=1}^{c} P(\omega_i \mid \boldsymbol{x}) \log P(\omega_i \mid \boldsymbol{x})\right] \qquad (6-2-30)$$

作为类别可分性判据。可以构造满足上述性质而计算更为简单的广义熵，其定义为

$$H^{(\alpha)}(p_1, p_2, \cdots, p_c) = (2^{1-\alpha} - 1)^{-1}\left[\sum_{i=1}^{c} p_i^{\alpha} - 1\right] \qquad (6-2-31)$$

式中 α 是一实的正参数，$\alpha \neq 1$。不同的 α 值可得到不同的可分性度量。

当 $\alpha \to 1$ 时，据洛必达法则可得 Shannon 熵

$$H^{(1)}(\boldsymbol{p}) = -\sum_{i=1}^{c} p_i \log p_i \qquad (6-2-32)$$

当 $\alpha = 2$ 时，可得平方熵

$$H^{(2)}(\boldsymbol{p}) = 2\left[1 - \sum_{i=1}^{c} p_i^2\right] \qquad (6-2-33)$$

同理，亦应用点熵在整个特征空间的概率平均

$$J_{\mathrm{H}}^{(\alpha)} = \mathrm{E}_x\left[H^{(\alpha)}(p_1, p_2, \cdots, p_c)\right] \qquad (6-2-34)$$

作为可分性判据。使用 J_H 或 $J_H^{(\alpha)}$ 判据进行特征提取与选择时，我们的目标是使 $J_H, J_H^{(\alpha)} \Rightarrow \min$。

6.3 基于可分性判据进行变换的特征提取

设有 n 个原始特征构成的特征矢量 $\boldsymbol{x} = (x_1, x_2, \cdots, x_n)^T$，对 $\boldsymbol{x}$ 作线性变换，产生 d 维矢量 $\boldsymbol{y} = (y_1, y_2, \cdots, y_d)^T$，$d \leqslant n$，即

$$\boldsymbol{y} = \boldsymbol{W}^T \boldsymbol{x} \tag{6-3-1}$$

式中：$\boldsymbol{W} = \boldsymbol{W}_{n \times d}$ 称为特征提取矩阵或简称变换矩阵；$\boldsymbol{y}$ 称为二次特征。

本节将研究在一定的准则函数下，如何求最优的变换矩阵 $\boldsymbol{W}$。

6.3.1 基于离差阵的特征提取

在利用基于离差阵构造可分性判据以进行特征提取与选择时，通常要求矩阵的迹最大或行列式值最大。下面以 J_1 为例说明如何求矩阵迹最大，然后以 J_4 为例说明如何求行列式值最大，其他各判据亦可类似运用。

设 $\boldsymbol{S}_W$ 和 $\boldsymbol{S}_B$ 分别为原始特征空间中类内和类间离差矩阵，$\boldsymbol{S}_W^*$ 和 $\boldsymbol{S}_B^*$ 分别为变换特征空间中类内和类间离差矩阵，可知

$$\boldsymbol{S}_W^* = \boldsymbol{W}^T \boldsymbol{S}_W \boldsymbol{W} \tag{6-3-2}$$

$$\boldsymbol{S}_B^* = \boldsymbol{W}^T \boldsymbol{S}_B \boldsymbol{W} \tag{6-3-3}$$

在变换域中，J_1 为

$$J_1^*(\boldsymbol{W}) = \mathrm{Tr}[(\boldsymbol{S}_W^*)^{-1} \boldsymbol{S}_B^*] = \mathrm{Tr}[(\boldsymbol{W}^T \boldsymbol{S}_W \boldsymbol{W})^{-1} (\boldsymbol{W}^T \boldsymbol{S}_B \boldsymbol{W})] \tag{6-3-4}$$

若 $\boldsymbol{W}$ 为非奇异矩阵，可得 $\mathrm{Tr}[(\boldsymbol{S}_W^*)^{-1} \boldsymbol{S}_B^*] = \mathrm{Tr}[\boldsymbol{S}_W^{-1} \boldsymbol{S}_B]$，这表明作非奇异变换，$J_1$ 是不变的。对矩阵作相似变换其特征值不变，其行列式值不变，其迹不变。一个方阵的迹等于它的所有特征值之和。设 $\boldsymbol{W}_T$ 是标准正交阵，用 $\boldsymbol{W}_T$ 对对称阵 $\boldsymbol{S}_W^{-1} \boldsymbol{S}_B$ 作相似变换使其成为对角阵，

$$\boldsymbol{W}_{\mathrm{T}}^{-1}\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{W}_{\mathrm{T}}=\boldsymbol{W}_{\mathrm{T}}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{W}_{\mathrm{T}}=\begin{pmatrix}\lambda_1 & & 0\\ & \lambda_2 & \\ & & \ddots \\ 0 & & \lambda_n\end{pmatrix}\triangleq\mathrm{diag}(\lambda_1,\lambda_2,\cdots,\lambda_n)$$

(6-3-5)

其中，$\lambda_i(i=1,2,\cdots,n)$ 为 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 的特征值，$\boldsymbol{W}_{\mathrm{T}}$ 的列矢量 $\boldsymbol{w}_i$ 为 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 相应于 λ_i 的特征矢量。由上式可得

$$J_1=\mathrm{Tr}[\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}]=\mathrm{Tr}[\boldsymbol{W}_{\mathrm{T}}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{W}_{\mathrm{T}}]=\sum_{i=1}^{n}\boldsymbol{w}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{w}_i=\sum_{i=1}^{n}\lambda_i$$

(6-3-6)

设此处 $\boldsymbol{W}_{\mathrm{T}}$ 的列矢量的排列已作适当调整，使 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 的特征值 $\lambda_1\geqslant\lambda_2\geqslant\cdots\geqslant\lambda_n$，由此可以得出，在 d 给定后，取前 d 个较大的特征值所对应的特征矢量 $\boldsymbol{w}_i$ 构造特征提取矩阵 $\boldsymbol{W}$，即

$$\boldsymbol{W}=(\boldsymbol{w}_1\quad\boldsymbol{w}_2\quad\cdots\quad\boldsymbol{w}_d)\tag{6-3-7}$$

对 $\boldsymbol{x}$ 作变换 $\boldsymbol{y}=\boldsymbol{W}^{\mathrm{T}}\boldsymbol{x}$，这时对于给定的 d 所得到的

$$J_1^*(\boldsymbol{W})=\sum_{i=1}^{d}\lambda_i\tag{6-3-8}$$

达最大值。

下面介绍如何运用以行列式形式出现的判据求最优变换矩阵 $\boldsymbol{W}$。以 J_4 为例，由于 $\boldsymbol{S}_{\mathrm{W}}$ 是对称正定矩阵，故有非奇异阵 $\boldsymbol{A}$，使

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{A}=\boldsymbol{I}$$

这里 $\boldsymbol{I}$ 为单位矩阵。有标准正交矩阵 $\boldsymbol{V}$，可使 $\boldsymbol{V}^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{T}}\boldsymbol{A}\boldsymbol{V}=\tilde{\boldsymbol{\Lambda}}$，$\tilde{\boldsymbol{\Lambda}}$ 为对角阵，而 $\boldsymbol{V}^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{A}\boldsymbol{V}=\boldsymbol{V}^{-1}\boldsymbol{I}\boldsymbol{V}=\boldsymbol{I}$。令 $\boldsymbol{U}=\boldsymbol{A}\boldsymbol{V}$，因此存在非奇异矩阵 $\boldsymbol{U}$，使

$$\boldsymbol{U}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{T}}\boldsymbol{U}=\tilde{\boldsymbol{\Lambda}}=\mathrm{diag}(\tilde{\lambda}_1,\tilde{\lambda}_2,\cdots,\tilde{\lambda}_n)\tag{6-3-9}$$

和

$$\boldsymbol{U}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{U}=\boldsymbol{I}\tag{6-3-10}$$

式(6－3－10)两边同时取逆,有

$$\boldsymbol{U}^{-1}\boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{U}^{\mathrm{T}})^{-1}=\boldsymbol{I} \tag{6-3-11}$$

式(6－3－11)两边左乘式(6－3－9)两边,然后左乘 $\boldsymbol{U}$,有

$$\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{T}}\boldsymbol{U}=\boldsymbol{U} \tag{6-3-12}$$

由上式可知,$\boldsymbol{U}$ 及 $\tilde{\boldsymbol{\Lambda}}$ 分别是 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{T}}$ 的特征矢量矩阵(特征矢量组成的矩阵)及特征值对角阵。又由于

$$\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{T}}=\boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{S}_{\mathrm{W}}+\boldsymbol{S}_{\mathrm{B}})=\boldsymbol{I}+\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$$

所以有

$$(\boldsymbol{I}+\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}})\boldsymbol{U}=\boldsymbol{U}\tilde{\boldsymbol{\Lambda}} \tag{6-3-13}$$

亦即

$$\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{U}=\boldsymbol{U}(\tilde{\boldsymbol{\Lambda}}-\boldsymbol{I}) \tag{6-3-14}$$

设 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 的特征值矩阵 $\boldsymbol{\Lambda}=\mathrm{diag}(\lambda_1,\lambda_2,\cdots,\lambda_n)$,则

$$\boldsymbol{I}+\boldsymbol{\Lambda}=\tilde{\boldsymbol{\Lambda}} \tag{6-3-15}$$

于是

$$J_4=\frac{|\boldsymbol{S}_{\mathrm{T}}|}{|\boldsymbol{S}_{\mathrm{W}}|}=\frac{|\boldsymbol{U}^{\mathrm{T}}||\boldsymbol{S}_{\mathrm{T}}||\boldsymbol{U}|}{|\boldsymbol{U}^{\mathrm{T}}||\boldsymbol{S}_{\mathrm{W}}||\boldsymbol{U}|}=\frac{|\boldsymbol{U}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{T}}\boldsymbol{U}|}{|\boldsymbol{U}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{U}|}$$

$$=\prod_{i=1}^{n}\tilde{\lambda}_i=\prod_{i=1}^{n}(1+\lambda_i) \tag{6-3-16}$$

由上面的推导可知,此处的 $\boldsymbol{U}$ 就是前述的 $\boldsymbol{W}_{\mathrm{T}}$。设 $\lambda_1\geqslant\lambda_2\geqslant\cdots\geqslant\lambda_n$,对于给定的 d,取前 d 个较大的特征值对应的特征矢量构造变换矩阵 $\boldsymbol{W}$ 可使 J_4 取最大值,此时

$$J_4(\boldsymbol{W})=\prod_{i=1}^{d}(1+\lambda_i) \tag{6-3-17}$$

从 J_4 的构造可知,对于多类问题用 J_4 作判据,不至于选用那些只对两类有很好的可分性而对其他各类分类效果不好的特征,对于 J_1 就有可能发生这种情况。

6.3.2 多类情况

前面研究的是两类问题,对于多类情况可作如下的简要讨论。当

不考虑各类的概率时，多类情况下的可分性判据可以表示为

$$J(\boldsymbol{W}) = \sum_{i=1}^{c-1}\sum_{j=i+1}^{c} J_{ij}(\boldsymbol{W}) \qquad (6-3-18)$$

这里 $J_{ij}(\cdot)$ 表示 ω_i 和 ω_j 两类间的某种可分性判据。求使 $J(\boldsymbol{W})$ 最大的解析解是困难的，可行的办法是先求一个候选矢量集 $\{\boldsymbol{v}_l\}$，可以用搜索算法从这些矢量中选出使 $J(\boldsymbol{W})$ 达最大的 d 个矢量来构成特征提取矩阵。

6.3.3 基于熵概念的某些特征提取与选择方法

利用总体熵可以压缩降维空间中类域的体积。令 $p(\boldsymbol{x}|\omega_i)$ 是 ω_i 类的概率密度函数，该类的总体熵定义为

$$H_p = -\mathrm{E}[\log p(\boldsymbol{x}|\omega_i)] \triangleq -\mathrm{E}[\log p(\boldsymbol{x})] \qquad (6-3-19)$$

设 $\boldsymbol{m}_i$ 是该类的均值矢量，当 $p(\boldsymbol{x}|\omega_i) = \delta(\boldsymbol{x}-\boldsymbol{m}_i)$ 时，$H_p = -\infty$；当随机矢量 $\boldsymbol{x} \in \omega_i$ 的概率密度函数在类域 Ω_i 中均匀分布，即 $p(\boldsymbol{x}|\omega_i) = 1/V_i$ 时，$H_p = \log V_i$，这里 V_i 是类域 Ω_i 的体积。易知，V_i 越大，H_p 也越大，所以总体熵能反映类的分布特性。从分类识别的角度看，H_p 越小，表明类的方差越小，分类特性就越好，类的均值矢量可提供较好的分类信息。

我们的目标是找到一个线性变换 $\boldsymbol{W}_{n\times d}$，使 ω_i 类经变换后，在新的 d 维坐标系中所占的体积变得最小，或等价地说使新的 d 维特征矢量 $\boldsymbol{y}$ 的分量方差和 $\mathrm{E}[(\boldsymbol{y}-\boldsymbol{m}_y)^{\mathrm{T}}(\boldsymbol{y}-\boldsymbol{m}_y)]$ 最小。因此，准则函数及其目标是

$$H_p(\boldsymbol{W}) = -\mathrm{E}[\log p(\boldsymbol{W}^{\mathrm{T}}\boldsymbol{x})] \Rightarrow \min \qquad (6-3-20)$$

求解可以得到 $\boldsymbol{W}$。

此外，还可以利用熵的概念，选取方差差别大的特征或增大两类中心距离，以得到更好的分类结果。

6.4 最佳鉴别矢量的提取

前面依据 $\boldsymbol{S}_{\mathrm{W}}$，$\boldsymbol{S}_{\mathrm{B}}$ 或 $\boldsymbol{S}_{\mathrm{T}}$ 构造可分性判据求最佳变换矩阵，它的特

点是整个最佳坐标系在形式上一起求出，也可以用单个分量的类间类内距离比作为准则，逐个求出最佳坐标系的各轴矢量。

6.4.1 Fisher 鉴别矢量及鉴别平面

在第3章中立足于训练学习讨论了如何建立 Fisher 线性判别函数，类似的思想和处理方法也可以用于特征提取与选择。这里首先回顾一下有关的内容。

在设计分类器时，在适当保证分类识别正确率的条件下，为简便或为可实现性，常要求降低维数，或有时为便于显示，常首先要求模式的维数是1或2，这就要求将目标的原始 n 维特征矢量映射成一维的标量或二维的矢量。

将高维模式变换为一维模式，实际上是将高维模式投影到一个新的坐标系统，只取原模式在其某一个轴 $\boldsymbol{u}_i$ 上的投影表示该模式。希望所选取的新的分量使类内离差较小，类间离差较大，将其写成准则函数，即有

$$J_F(\boldsymbol{u}_i)=\frac{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i}{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_i}\Rightarrow\max \tag{6-4-1}$$

将标量 J_F 对矢量 $\boldsymbol{u}_i$ 求导并令其为零矢量，可得

$$\frac{\partial J_F}{\partial \boldsymbol{u}_i}=\frac{\partial}{\partial \boldsymbol{u}_i}\left(\frac{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i}{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_i}\right)=\frac{2(\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_i)\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i-2(\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i)\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_i}{(\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_i)^2}=\boldsymbol{0} \tag{6-4-2}$$

令

$$\lambda_i=\frac{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i}{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_i} \tag{6-4-3}$$

可得

$$\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i=\lambda_i\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_i \tag{6-4-4}$$

设 $\boldsymbol{S}_{\mathrm{W}}$ 有逆，于是有

$$\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i=\lambda_i\boldsymbol{u}_i \tag{6-4-5}$$

此式表明 $\boldsymbol{u}_i$ 是矩阵 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 的特征值 λ_i 所对应的特征矢量，$\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 最多有 $c-1$ 个非零特征值。由式(6-4-3)可知，$\lambda_i(\boldsymbol{u}_i)=J_F(\boldsymbol{u}_i)$，所以应选 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$ 的最大特征值 λ_1 对应的特征矢量 $\boldsymbol{u}_1$ 作为变换矩阵。此时的 $\boldsymbol{u}_i$ 称为 Fisher 最佳鉴别矢量，式(6-4-1)称为 Fisher 准则函数。

对于两类问题，设 $\boldsymbol{m}_i$ 为 ω_i 类的均矢，这时 $\boldsymbol{S}_{\mathrm{B}}=P(\omega_1)P(\omega_2)(\boldsymbol{m}_1-\boldsymbol{m}_2)(\boldsymbol{m}_1-\boldsymbol{m}_2)^{\mathrm{T}}$，于是

$$\lambda_1\boldsymbol{u}_1=\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_1=P(\omega_1)P(\omega_2)\boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{m}_1-\boldsymbol{m}_2)(\boldsymbol{m}_1-\boldsymbol{m}_2)^{\mathrm{T}}\boldsymbol{u}_1$$

上式右边后两项因子的乘积为一标量，其与 $P(\omega_1)P(\omega_2)$ 的积记为 α，于是可得

$$\boldsymbol{u}_1=\frac{\alpha}{\lambda_1}\boldsymbol{S}_{\mathrm{W}}^{-1}(\boldsymbol{m}_1-\boldsymbol{m}_2) \tag{6-4-6}$$

其中$\frac{\alpha}{\lambda_1}$为一标量因子，它不影响 $\boldsymbol{u}_1$ 的方向。

要将高维模式映射成二维模式，需要两个正交矢量，这时除了 Fisher 鉴别矢量 $\boldsymbol{u}_1$ 外，还要求出第二个矢量 $\boldsymbol{u}_2$，因 $\boldsymbol{u}_1$ 与 $\boldsymbol{u}_2$ 正交，可用 $\boldsymbol{u}_1^{\mathrm{T}}\boldsymbol{u}_2=0$ 作为约束条件使 $J_F(\boldsymbol{u}_2)$ 最大，于是采用条件极值方法作准则函数

$$\frac{\boldsymbol{u}_2^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_2}{\boldsymbol{u}_2^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_2}-\gamma\boldsymbol{u}_1^{\mathrm{T}}\boldsymbol{u}_2\Rightarrow\max \tag{6-4-7}$$

式(6-4-7)对 $\boldsymbol{u}_2$ 求偏导并令其为零矢量，可得

$$\boldsymbol{u}_2=\beta\left[\boldsymbol{S}_{\mathrm{W}}^{-1}-\frac{(\boldsymbol{m}_1-\boldsymbol{m}_2)^{\mathrm{T}}(\boldsymbol{S}_{\mathrm{W}}^{-1})^2(\boldsymbol{m}_1-\boldsymbol{m}_2)}{(\boldsymbol{m}_1-\boldsymbol{m}_2)^{\mathrm{T}}(\boldsymbol{S}_{\mathrm{W}}^{-1})^3(\boldsymbol{m}_1-\boldsymbol{m}_2)}(\boldsymbol{S}_{\mathrm{W}}^{-1})^2\right](\boldsymbol{m}_1-\boldsymbol{m}_2) \tag{6-4-8}$$

式中 β 为一标量。

$\boldsymbol{u}_1$、$\boldsymbol{u}_2$ 及原点可构成最佳鉴别平面，高维模式向其投影所得二维模式比其他任何变换所得二维模式在 Fisher 准则下更易分类。

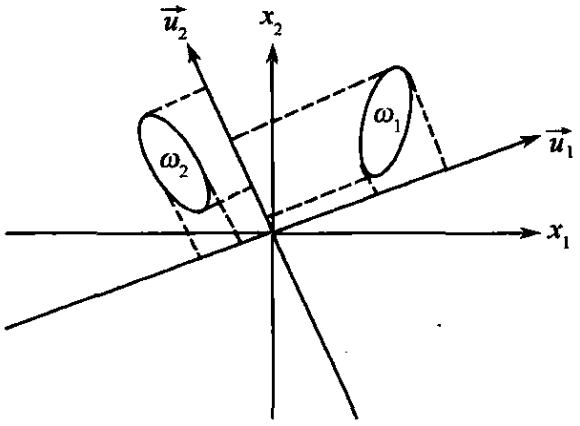


图 6.4.1　二维模式分别向轴 u_1 和 u_2 上的投影

6.4.2　最佳鉴别矢量集

1. Foley – Sammon 变换

设 $\boldsymbol{u}_1$ 是使 $J_F(\boldsymbol{u}_i)$ 取最大的 Fisher 最佳鉴别矢量，且 $\boldsymbol{u}_1$ 已规格化，其模长 $\| \boldsymbol{u}_1 \| = 1$，则单位 Fisher 最佳鉴别矢量 $\boldsymbol{u}_1$ 是 F-S 最佳鉴别矢量集 $\boldsymbol{S} = \{\boldsymbol{u}_i; i = 1,2,\cdots,r\}$ 中的第一个矢量，该矢量集中的第 i 个鉴别矢量 $\boldsymbol{u}_i$ 通过解下面的最优化问题求得

$$\begin{cases} \max[J_F(\boldsymbol{u}_i)] \\ \text{s. t.} \quad \boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{u}_j = 0 \quad (j = 1,2,\cdots,i-1) \\ \quad\quad \| \boldsymbol{u}_i \| = 1 \end{cases} \tag{6-4-9}$$

令 $\boldsymbol{U} = (\boldsymbol{u}_1\boldsymbol{u}_2\cdots\boldsymbol{u}_r)$，则变换

$$\boldsymbol{y} = \boldsymbol{U}^{\mathrm{T}}\boldsymbol{x} \tag{6-4-10}$$

称为 Foley – Sammon 变换(FST)。当 $r = 2$ 时，这两个鉴别矢量等价为 Fisher 最佳鉴别平面中的两个坐标轴矢量。

无论是 Fisher 鉴别矢量、鉴别平面，还是 F-S 最佳鉴别矢量集，以及后面的一些定理都可以从下面的基本数学概念和定理引发出来。

[**定义 6.4.1**]设 $\boldsymbol{A}$ 是 n 阶对称阵，$\boldsymbol{B}$ 是同阶正定阵，称 $|\boldsymbol{A} - \lambda\boldsymbol{B}| = 0$ 的根 λ 为 $\boldsymbol{A}$ 相对于 $\boldsymbol{B}$ 的特征值，而满足 $(\boldsymbol{A} - \lambda\boldsymbol{B})\boldsymbol{x} = \boldsymbol{0}$ 的非零矢量 $\boldsymbol{x}$ 称为相应于 λ 的 $\boldsymbol{A}$ 相对于 $\boldsymbol{B}$ 的特征矢量。

显然，上面定义的与两个矩阵有关的特征值和特征矢量实际上就是关于矩阵 $\boldsymbol{B}^{-1}\boldsymbol{A}$ 的特征值和特征矢量。

[**定理 6.4.1**]设 $\boldsymbol{A}$ 为 n 阶对称阵，$\boldsymbol{B}$ 为同阶正定阵，$\lambda_i(i=1,2,\cdots,n)$是 $\boldsymbol{A}$ 相对于 $\boldsymbol{B}$ 的第 i 大特征值，$\boldsymbol{u}_i$ 是相应于 λ_i 的 $\boldsymbol{A}$ 相对于 $\boldsymbol{B}$ 的特征矢量，各特征矢量两两正交，c 为非零常数，则有

$$\max_{x\neq 0}\left[\frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{B}\boldsymbol{x}}\right]=\lambda_1,\text{当 }\boldsymbol{x}=c\boldsymbol{u}_1\text{ 时达到最大值；}$$

$$\max_{x\neq 0}\left[\frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{B}\boldsymbol{x}}\right]=\lambda_n,\text{当 }\boldsymbol{x}=c\boldsymbol{u}_n\text{ 时达到最小值；}$$

$$\max_{\substack{x\neq 0\\ x\perp u_1,\cdots,u_k}}\left[\frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{B}\boldsymbol{x}}\right]=\lambda_{k+1},\text{当 }\boldsymbol{x}=c\boldsymbol{u}_{k+1}\text{时达到最大值。}$$

(6-4-11)

2. 广义最佳鉴别矢量集及其求解方法

设 $\tilde{\boldsymbol{S}}=\{\tilde{\boldsymbol{u}}_i;i=1,2,\cdots,r\}$ 表示广义最佳鉴别矢量集，$\tilde{\boldsymbol{S}}$ 中的每个矢量可用如下方法逐步求得，即

(1)$\tilde{\boldsymbol{u}}_1$ 是 n 维空间中使 Fisher 准则函数 $J_F(\boldsymbol{u})$ 最大的单位矢量，显然 $\tilde{\boldsymbol{u}}_1=\boldsymbol{u}_1$，$\boldsymbol{u}_1$ 是 F-S 最佳矢量集的第一个鉴别矢量。

(2)第 i 个广义最佳鉴别矢量 $\tilde{\boldsymbol{u}}_i(2\leqslant i\leqslant r)$ 通过解最优化问题求得：

$$\begin{cases}\max[J_i(\tilde{\boldsymbol{u}}_i)]\\ \text{s. t.}\quad \tilde{\boldsymbol{u}}_i^{\mathrm{T}}\tilde{\boldsymbol{u}}_j=0\qquad (j=1,2,\cdots,i-1)\\ \quad\ \|\tilde{\boldsymbol{u}}_i\|=1\end{cases}\tag{6-4-12}$$

$$J_i(\boldsymbol{u})=\frac{\sum_{j=1}^{i-1}\tilde{\boldsymbol{u}}_j^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\tilde{\boldsymbol{u}}_j+\boldsymbol{u}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}/\|\boldsymbol{u}\|^2}{\sum_{j=1}^{i-1}\tilde{\boldsymbol{u}}_j^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\tilde{\boldsymbol{u}}+\boldsymbol{u}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}/\|\boldsymbol{u}\|^2}\tag{6-4-13}$$

6.5 离散 K-L 变换及其在特征提取与选择中的应用

有限离散 K-L 变换，又称霍特林(Hotelling)变换或主分量分解

(PCA),它是一种基于目标统计特性的最佳正交变换。称其为最佳变换是由于它具有一些重要的优良性质,即:使变换后产生的新的分量正交或不相关;以部分新的分量表示原矢量均方误差最小;使变换矢量更趋确定、能量更趋集中等,这使它在特征选取、数据压缩等方面都有着极为重要的应用。

6.5.1 离散 K-L 变换(DKLT)

设 n 维随机矢量 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}$,其均值矢量 $\bar{\boldsymbol{x}}=\mathrm{E}[\boldsymbol{x}]$,相关阵 $\boldsymbol{R}_x=\mathrm{E}[\boldsymbol{x}\boldsymbol{x}^{\mathrm{T}}]$,协方差阵 $\boldsymbol{C}_x=\mathrm{E}[(\boldsymbol{x}-\bar{\boldsymbol{x}})(\boldsymbol{x}-\bar{\boldsymbol{x}})^{\mathrm{T}}]$,$\boldsymbol{x}$ 经标准正交变换矩阵 $\boldsymbol{T}^{\mathrm{T}}$ 正交变换后成为矢量 $\boldsymbol{y}=(y_1,y_2,\cdots,y_n)^{\mathrm{T}}$,即

$$\boldsymbol{y}=\boldsymbol{T}^{\mathrm{T}}\boldsymbol{x}\triangleq(\boldsymbol{t}_1\boldsymbol{t}_2\cdots\boldsymbol{t}_n)^{\mathrm{T}}\boldsymbol{x}=\begin{pmatrix}\boldsymbol{t}_1^{\mathrm{T}}\\ \boldsymbol{t}_2^{\mathrm{T}}\\ \vdots\\ \boldsymbol{t}_n^{\mathrm{T}}\end{pmatrix}\boldsymbol{x} \tag{6-5-1}$$

从而 $\boldsymbol{y}$ 的各分量

$$y_i=\boldsymbol{t}_i^{\mathrm{T}}\boldsymbol{x}\qquad(i=1,2,\cdots,n) \tag{6-5-2}$$

而

$$\boldsymbol{x}=(\boldsymbol{T}^{\mathrm{T}})^{-1}\boldsymbol{y}=\boldsymbol{T}\boldsymbol{y}=(\boldsymbol{t}_1\boldsymbol{t}_2\cdots\boldsymbol{t}_n)\begin{pmatrix}y_1\\ y_2\\ \vdots\\ y_n\end{pmatrix}=\sum_{i=1}^{n}y_i\boldsymbol{t}_i \tag{6-5-3}$$

选择 $\boldsymbol{x}$ 关于 y_i 的展开式(6-5-3)的 m 项在最小均方误差准则下线性估计 $\boldsymbol{x}$,这时估计式可表示为

$$\hat{\boldsymbol{x}}=\sum_{i=1}^{m}y_i\boldsymbol{t}_i\quad(1\leqslant m<n) \tag{6-5-4}$$

引入的均方误差为

$$\varepsilon^2(m) = \mathrm{E}[(\boldsymbol{x}-\hat{\boldsymbol{x}})^{\mathrm{T}}(\boldsymbol{x}-\hat{\boldsymbol{x}})] = \sum_{i=m+1}^{n}\mathrm{E}[y_i^2] = \sum_{i=m+1}^{n}\mathrm{E}[y_i y_i^{\mathrm{T}}]$$

$$= \sum_{i=m+1}^{n}\boldsymbol{t}_i^{\mathrm{T}}\mathrm{E}[\boldsymbol{x}\boldsymbol{x}^{\mathrm{T}}]\boldsymbol{t}_i = \sum_{i=m+1}^{n}\boldsymbol{t}_i^{\mathrm{T}}\boldsymbol{R}_x\boldsymbol{t}_i \qquad (6-5-5)$$

我们希望在 $\boldsymbol{T}$ 为标准正交阵的约束下(即 $\boldsymbol{t}_i^{\mathrm{T}}\boldsymbol{t}_j = \delta_{ij}$),使 $\varepsilon^2(m)$ 取最小,为此作准则函数

$$J = \sum_{i=m+1}^{n}\boldsymbol{t}_i^{\mathrm{T}}\boldsymbol{R}_x\boldsymbol{t}_i - \sum_{i=m+1}^{n}\lambda_i(\boldsymbol{t}_i^{\mathrm{T}}\boldsymbol{t}_i - 1) \qquad (6-5-6)$$

由 $\dfrac{\partial J}{\partial \boldsymbol{t}_i} = \boldsymbol{0}$,得

$$(\boldsymbol{R}_x - \lambda_i \boldsymbol{I})\boldsymbol{t}_i = \boldsymbol{0} \quad (i = m+1, \cdots, n)$$

即

$$\boldsymbol{R}_x\boldsymbol{t}_i = \lambda_i\boldsymbol{t}_i \quad (i = m+1, \cdots, n) \qquad (6-5-7)$$

式(6-5-7)表明,λ_i 为 $\boldsymbol{x}$ 的相关阵 $\boldsymbol{R}_x$ 的特征值,$\boldsymbol{t}_i$ 为 $\boldsymbol{R}_x$ 的对应于 λ_i 的特征矢量。

将上式代入 $\varepsilon^2(m)$式中,得

$$\varepsilon^2(m) = \sum_{i=m+1}^{n}\boldsymbol{t}_i^{\mathrm{T}}\lambda_i\boldsymbol{t}_i = \sum_{i=m+1}^{n}\lambda_i \qquad (6-5-8)$$

在 $\boldsymbol{x}$ 的估计式中,如果保留 m 个 y_i,而余下的$(n-m)$个分量 $y_i(i = m+1, \cdots, n)$分别由预选的$(n-m)$个常数 b_i 代替,此时的估计式为

$$\hat{\boldsymbol{x}} = \sum_{i=1}^{m} y_i\boldsymbol{t}_i + \sum_{i=m+1}^{n} b_i\boldsymbol{t}_i \qquad (6-5-9)$$

估计的均方误差为

$$\varepsilon^2(m) = \mathrm{E}[(\boldsymbol{x}-\hat{\boldsymbol{x}})^{\mathrm{T}}(\boldsymbol{x}-\hat{\boldsymbol{x}})] = \sum_{i=m+1}^{n}\mathrm{E}[(y_i - b_i)^2]$$

$$(6-5-10)$$

(1) 最佳的 b_i 可通过 $\partial\varepsilon^2/\partial b_i = 0$ 求得。由

$$\frac{\partial}{\partial b_i}\{\mathrm{E}[(y_i - b_i)^2]\} = 0$$

得

$$b_i = \mathrm{E}[y_i] = \boldsymbol{t}_i^{\mathrm{T}}\mathrm{E}[\boldsymbol{x}] = \boldsymbol{t}_i^{\mathrm{T}}\bar{\boldsymbol{x}} \qquad (6-5-11)$$

于是

$$\varepsilon^2(m) = \sum_{i=m+1}^{n}\mathrm{E}[(y_i - b_i)^2] = \sum_{i=m+1}^{n}\mathrm{E}[(y_i - b_i)(y_i - b_i)^{\mathrm{T}}]$$

$$= \sum_{i=m+1}^{n}\boldsymbol{t}_i^{\mathrm{T}}\mathrm{E}[(\boldsymbol{x} - \bar{\boldsymbol{x}})(\boldsymbol{x} - \bar{\boldsymbol{x}})^{\mathrm{T}}]\boldsymbol{t}_i = \sum_{i=m+1}^{n}\boldsymbol{t}_i^{\mathrm{T}}\boldsymbol{C}_x\boldsymbol{t}_i \qquad (6-5-12)$$

(2) 求最佳的 $\boldsymbol{t}_i$。在 $\boldsymbol{T}$ 为标准正交阵的约束下，求使 $\varepsilon^2(m)\Rightarrow\min$ 的 $\boldsymbol{t}_i$ 的方法和前述类似，作准则函数

$$J = \sum_{i=m+1}^{n}[\boldsymbol{t}_i^{\mathrm{T}}\boldsymbol{C}_x\boldsymbol{t}_i - \lambda_i(\boldsymbol{t}_i^{\mathrm{T}}\boldsymbol{t}_i - 1)] \qquad (6-5-13)$$

由 $\dfrac{\partial J}{\partial \boldsymbol{t}_i} = \boldsymbol{0}$，得

$$\boldsymbol{C}_x\boldsymbol{t}_i = \lambda_i\boldsymbol{t}_i \qquad (i = m+1, \cdots, n) \qquad (6-5-14)$$

上式表明，这时的 $\boldsymbol{t}_i$ 为 $\boldsymbol{x}$ 的协方差阵 $\boldsymbol{C}_x$ 的对应于特征值 λ_i 的特征矢量。

将上式代入 $\varepsilon^2(m)$ 式中，可得

$$\varepsilon^2(m) = \sum_{i=m+1}^{n}\lambda_i \qquad (6-5-15)$$

上述的讨论可以归纳如下。当用简单的“截断”方式产生估计式时，使均方误差最小的正交变换矩阵是随机矢量 $\boldsymbol{x}$ 的相关阵 $\boldsymbol{R}_x$ 的特征矢量矩阵的转置；而当估计式除了选用 m 个分量 $y_i(i = 1, 2, \cdots, m)$ 之外，还用余下的各 y_i 的均值 b_i 代替相应的分量 y_i 时，使均方误差最小的正交变换矩阵是 $\boldsymbol{x}$ 的协方差阵 $\boldsymbol{C}_x$ 的特征矢量矩阵的转置。无论哪种情况，为使 $\varepsilon^2(m)$ 最小化，都应取前 m 个较大特征值对应的特征矢量构造 $m \times n$ 变换矩阵。由代数学知，因为 $\boldsymbol{R}_x - \boldsymbol{C}_x$ 为非负定阵，故有

$$\lambda_i(\boldsymbol{R}_x) \geqslant \lambda_i(\boldsymbol{C}_x) \quad (i = 1, 2, \cdots, n)$$

式中：$\lambda_i(\boldsymbol{R}_x)$ 和 $\lambda_i(\boldsymbol{C}_x)$ 分别表示 $\boldsymbol{R}_x$ 和 $\boldsymbol{C}_x$ 的第 i 大的特征值，从而可知对于相同的 m，第一种估计式比第二种估计式的均方差大。

这种取 $\boldsymbol{x}$ 的相关阵 $\boldsymbol{R}_x$ 或协方差阵 $\boldsymbol{C}_x$ 的特征矢量矩阵的转置作为变换矩阵的变换称为离散 K－L 变换(DKLT)，在此基础上，式(6－5－3)称为 $\boldsymbol{x}$ 的 K－L 展开。

无论变换矩阵是 $\boldsymbol{x}$ 的相关阵 $\boldsymbol{R}_x$ 或协方差阵 $\boldsymbol{C}_x$ 的特征矢量矩阵的转置，它们都具有如下相同或类似的重要性质或结论，其中性质(1)和性质(2)是 DKLT 最基本的重要性质。

(1)变换后各分量正交或不相关，两个新的坐标轴方向分别由 $\boldsymbol{t}_1$ 和 $\boldsymbol{t}_2$ 确定，如图 6.5.1 所示。

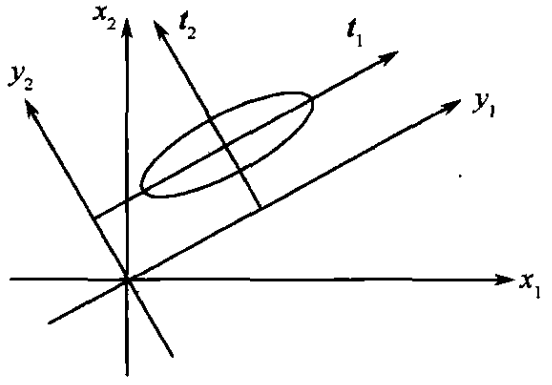


图 6.5.1　DKLT 使新的分量 y_1 和 y_2 不相关(或正交)

(2)变换后各分量的非零平方期望或方差更趋于不均。

(3)最佳逼近性。利用 DKLT 变换，按式(6－5－4)或式(6－5－9)对随机矢量 $\boldsymbol{x}$ 进行逼近，其均方误差比用任何其他标准正交变换按上述方法逼近 $\boldsymbol{x}$ 所引入的误差都更小。

(4)使能量向某些分量相对集中。如果用能量的观点来看，任何标准正交变换下模式总的平均能量保持不变，但 DKLT 使各分量能量分布更趋不均，即能量更为相对集中。

(5)DKLT 可以增强随机矢量总体的确定性。基于前述的 DKLT 的诸多性质以及有关量的含义，如 λ_i 具有能量意义、方差意义等，可将 DKLT 用于特征提取与选择。

需要说明的是：DKLT 现在还没有普遍适用的快速算法，也不像其他一些正交变换那样变换矩阵是确定的，它的变换矩阵依赖于具体信号的二阶统计特性。为要达到较好效果，在实际中需要大量的样本以便对二阶矩精确估计。

6.5.2 离散 K－L 变换在特征提取与选择中的应用

在模式识别中，类别的可分性不仅取决于类间的距离，而且还取决于各类模式围绕其中心的散布情况，而各类内离差阵、类间离差阵、总的类内、类间离差阵就含有这方面的信息，因此，可以依据 $\boldsymbol{S}_{\mathrm{W}}$、$\boldsymbol{S}_{\mathrm{B}}$、$\boldsymbol{S}_{\mathrm{T}}$，或等价地依据相应的协方差矩阵进行 DKLT，凸显变换后所得矢量的各分量对分类识别的贡献。实际上，利用 J_1，J_4 的特征提取和本节的技术内涵是一致的，在那里实际上是依据 $\boldsymbol{S}_{\mathrm{W}}^{-1}\boldsymbol{S}_{\mathrm{B}}$、$\boldsymbol{\Sigma}^{-1}\boldsymbol{M}$、$\boldsymbol{\Sigma}_2^{-1}\boldsymbol{\Sigma}_1$ 进行 DKLT 提取选择特征。

1. 运用 DKLT 消除两类问题的特征相关性方法

两个随机分量间的相关性是指当一个随机分量变化时，另一个随机分量也随之发生具有确定倾向性的变化，它们之间存在着统计上的相依关系，相关性强表示一个随机分量的取值较大程度地依赖于另一个随机分量。两个分量间的归一化协方差—相关系数刻画了这两个分量间的线性相关性程度。线性相关性表示当一个分量增大时另一个分量按线性关系增大或减小的趋势，相关系数绝对值越接近 1，这种趋势越明显。当只考虑一类的各特征分量时，如前所述，理论上 DKLT 能完全消除分量间的（线性）相关性。在几何上 DKLT 实际上是坐标系（或平移后）旋转，即是说这种相依关系可以通过坐标系的旋转予以消除。对于非单类情况，DKLT 消除分量相关性的有效性依赖于各类样本围绕其中心分布的情况。只有各类协方差矩阵的特征矢量矩阵相同时，方可完全消除相关性；否则，依据 $\boldsymbol{S}_{\mathrm{W}}$ 作 DKLT 时，只能减弱而不能完全消除相关性。

这里就两类问题介绍一种完全消除相关性的方法：先依据 ω_1 类的 $\boldsymbol{S}_{\mathrm{W}_1}$ 作 DKLT 消除该类各分量的相关性，设 $\boldsymbol{U}$ 是 $\boldsymbol{S}_{\mathrm{W}_1}$ 的特征矢量矩阵（这里 $\boldsymbol{S}_{\mathrm{W}_1}$ 也可以理解为 ω_1 类的协方差），对属于 ω_1 类的模式 $\boldsymbol{x}^{(1)}$ 作变换：

$$\boldsymbol{y}^{(1)} = \boldsymbol{U}^{\mathrm{T}}\boldsymbol{x}^{(1)} \tag{6-5-16}$$

这时，$\boldsymbol{y}^{(1)}$ 的各分量不相关，其协方差矩阵 $\boldsymbol{\Lambda}_1$ 为一对角阵。

再对 $\boldsymbol{y}^{(1)}$ 作变换

$$\tilde{\boldsymbol{y}}^{(1)} = \boldsymbol{\Lambda}_1^{-1/2}\boldsymbol{y}^{(1)} = \boldsymbol{\Lambda}_1^{-1/2}\boldsymbol{U}^{\mathrm{T}}\boldsymbol{x}^{(1)} \triangleq \boldsymbol{B}^{\mathrm{T}}\boldsymbol{x}^{(1)} \qquad (6-5-17)$$

显然，$\tilde{\boldsymbol{y}}^{(1)}$ 的协方差阵为单位阵，表明它的各分量也不相关。这两种变换合在一起称为白化变换。白化变换之后再作任何标准正交变换，其协方差阵仍为单位阵。这个白化变换 $\boldsymbol{B}$ 使 ω_2 类原始的 $\boldsymbol{S}_{\mathrm{W}_2}$ 变为 $\tilde{\boldsymbol{S}}_{\mathrm{W}_2} = \boldsymbol{B}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}_2}\boldsymbol{B}$，然后依据 $\tilde{\boldsymbol{S}}_{\mathrm{W}_2}$ 作 DKLT，设 $\boldsymbol{V}$ 是 $\tilde{\boldsymbol{S}}_{\mathrm{W}_2}$ 的特征矢量矩阵，因此当以 $\boldsymbol{W}^{\mathrm{T}} = \boldsymbol{V}^{\mathrm{T}}\boldsymbol{\Lambda}_1^{-1/2}\boldsymbol{U}^{\mathrm{T}}$ 对各类模式 $\boldsymbol{x}$ 作变换，

$$\boldsymbol{z} = \boldsymbol{V}^{\mathrm{T}}\boldsymbol{\Lambda}_1^{-1/2}\boldsymbol{U}^{\mathrm{T}}\boldsymbol{x} \qquad (\boldsymbol{x}\in\omega_1 \text{ 或 } \boldsymbol{x}\in\omega_2) \qquad (6-5-18)$$

显然，$\boldsymbol{z}$ 的各分量也不相关，即是说，对两类的特征矢量来说，它们的各分量互不相关，于是就可依据某种准则选择 $\boldsymbol{z}$ 的分量以降低维数。需要指出的是，由于白化变换不具有保范性（使矢量长度不变的性质），再简单地依据 λ_i 的大小选择特征矢量已不可靠。

2. 基于总的类间离差矩阵 $\boldsymbol{S}_{\mathrm{B}}$ 的 DKLT 进行特征提取选择

对于 c 类问题，由于 $\boldsymbol{S}_{\mathrm{B}}$ 的秩不大于 $c-1$，故 $\boldsymbol{S}_{\mathrm{B}}$ 最多有 $c-1$ 个非零特征值，而模式的维数 n 通常要大于 c，因此依据类间离差矩阵 $\boldsymbol{S}_{\mathrm{B}}$ 进行特征选择是一个重要途径。具体的方法是：求出 $\boldsymbol{S}_{\mathrm{B}}$ 的非零特征值 λ_i 及其相应的特征矢量 $\boldsymbol{u}_i(i=1,2,\cdots)$，按次序 $\lambda_1 \geqslant \lambda_2 \geqslant \cdots \geqslant \lambda_{c-1}$，选取前 d 个较大的特征值对应的特征矢量构成变换矩阵，可实现特征的提取。类间离差矩阵 $\boldsymbol{S}_{\mathrm{B}}$ 反映了各类中心到总体中心的平均平方距离，依据 $\boldsymbol{S}_{\mathrm{B}}$ 进行 DKLT 的目的是使各类的中心在新的坐标系某些轴上的投影相距变得较远，相应这些轴上的分量具有更好的可分性。

这种方法实质上是从各类的中心提取分类信息，因此它适用于类间距离比类内距离大得多的情况。

3. 基于总的类内离差矩阵 $\boldsymbol{S}_{\mathrm{W}}$ 的 DKLT 进行特征提取选择

类内离差矩阵 $\boldsymbol{S}_{\mathrm{W}}$ 反映了各分量总的平均方差，为了减少或消除各分量间的相关性，加大新的各分量方差的不均匀性，以便估计各分量对于分类的单独作用，可先依据 $\boldsymbol{S}_{\mathrm{W}}$ 作 DKLT，求出相应的特征值 λ_i 和特征矢量 $\boldsymbol{u}_i(i=1,2,\cdots)$，于是有

$$\lambda_i = \boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_i \qquad (6-5-19)$$

λ_i 表示变换后的分量 $y_i = \boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{x}$ 的平均方差，直接根据 λ_i 的大小来选取

$\boldsymbol{u}_i$ 一般是不可靠的。从图 6.5.2 中所示的简单例子可以看出，对于图(a)中各类分布情况，宜取小的特征值对应的特征矢量构成变换矩阵，因为不同的类域在方差小的分量轴上的投影是不重叠的；在(b)中，宜取大的特征值对应的特征矢量构成变换矩阵，理由是类似的，类域在方差大的分量轴上的投影是不重叠的；对于(c)中的情况，DKLT 后两个特征值差别不大。而 $\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i$ 可以理解为各类中心矢量第 i 个分量与总体中心矢量的相应分量的均方距离，即该分量总的类间均方距离。一个分量对可分性的作用，不仅和类内距离有关，还和类间距离有关，因此，一个较可靠的方法是用类间类内距离比构造准则函数

$$J(y_i)=\frac{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i}{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{u}_i}=\frac{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_i}{\lambda_i} \tag{6-5-20}$$

来刻画变换后的分量 $y_i=\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{x}$ 的可分性能，$J(y_i)$ 越大，可分性越好。设 $J(y_1)\geqslant J(y_2)\geqslant\cdots\geqslant J(y_n)$，为了降低维数，应从中选取那些含有较多分类信息的分量，对于给定的 d，取前面 d 个较大的 $J(\cdot)$ 值对应的特征矢量 $\boldsymbol{u}_i(i=1,2,\cdots,d)$ 作变换矩阵，等价地讲，取前 d 个分量 $y_i(i=1,2,\cdots,d)$ 代表原模式。

这种方法适用于各类模式分布结构相似以及类域在某些分量轴上的投影不重叠或较少重叠的情况。

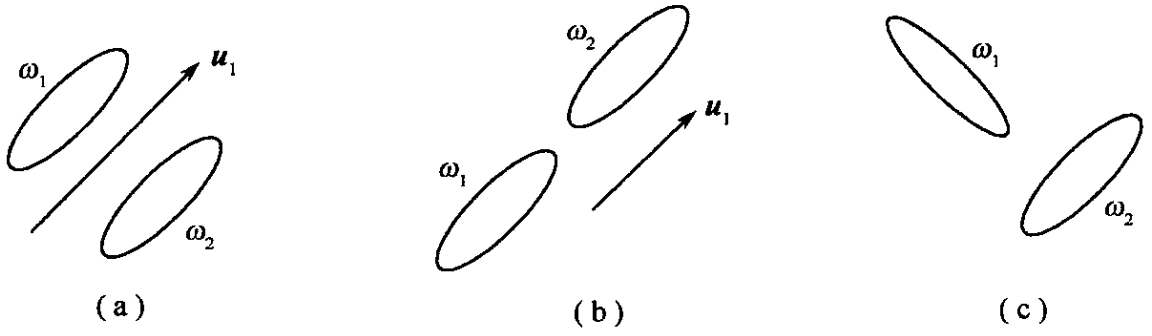


图 6.5.2　两类的中心与协方差主轴不同对依据 $\boldsymbol{S}_{\mathrm{W}}$ 选取特征的影响

4. 依据 $\boldsymbol{S}_{\mathrm{W}}$ 与 $\boldsymbol{S}_{\mathrm{B}}$ 作 DKLT 降低特征维数的最优压缩方法

如上所述，直接依据总的类内离差阵 $\boldsymbol{S}_{\mathrm{W}}$ 作 DKLT 一般来讲并不能满足对各类各分量不相关的要求。可以依据 $\boldsymbol{S}_{\mathrm{W}}$ 和 $\boldsymbol{S}_{\mathrm{B}}$ 作 DKLT，在保证不损失信息的前提下实现将特征维数压缩至最小的目的。这个保持

信息的最优压缩方法如下：

设 $\boldsymbol{\Lambda}$ 和 $\boldsymbol{U}$ 是对称正定阵 $\boldsymbol{S}_{\mathrm{W}}$ 的特征值对角阵和特征矢量矩阵，作如下的白化变换：

$$\boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{W}}\boldsymbol{U}\boldsymbol{\Lambda}^{-1/2}=\boldsymbol{I} \tag{6-5-21}$$

易知，存在正交阵 $\tilde{\boldsymbol{V}}$ 可使

$$\tilde{\boldsymbol{V}}^{\mathrm{T}}\boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{U}\boldsymbol{\Lambda}^{-1/2}\tilde{\boldsymbol{V}}=\tilde{\boldsymbol{\Lambda}} \tag{6-5-22}$$

式中 $\tilde{\boldsymbol{\Lambda}}$ 为白化变换后的总的类间离差阵 $\tilde{\boldsymbol{S}}_B=\boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{U}\boldsymbol{\Lambda}^{-1/2}$ 的特征值对角阵。由于 $\boldsymbol{S}_{\mathrm{B}}$ 的秩不大于 $c-1$，所以 $\tilde{\boldsymbol{S}}_{\mathrm{B}}$ 最多只有 $c-1$ 个非零特征值，设 $\tilde{\boldsymbol{S}}_{\mathrm{B}}$ 非零特征值共有 d 个，用这 d 个非零特征值所对应的特征矢量 $\boldsymbol{v}_j(j=1,2,\cdots,d)$ 作变换矩阵，所得的 d 个分量含有原来 n 维模式的全部信息。设

$$\boldsymbol{V}=(\boldsymbol{v}_1\boldsymbol{v}_2\cdots\boldsymbol{v}_d) \tag{6-5-23}$$

则不损失信息而又达到最小维数的变换矩阵为

$$\boldsymbol{W}^{\mathrm{T}}=\boldsymbol{V}^{\mathrm{T}}\boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^{\mathrm{T}} \tag{6-5-24}$$

从而

$$\boldsymbol{y}=\boldsymbol{W}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{V}^{\mathrm{T}}\boldsymbol{\Lambda}^{-1/2}\boldsymbol{U}^{\mathrm{T}}\boldsymbol{x} \tag{6-5-25}$$

当类数 c 远比特征矢量维数 n 小时，该方法的压缩性能是十分明显的。

[例 6.5.1] 两类样本的均值矢量分别为 $\boldsymbol{m}_1=(4,2)^{\mathrm{T}}$ 和 $\boldsymbol{m}_2=(-4,-2)^{\mathrm{T}}$，协方差矩阵分别为

$$\boldsymbol{C}_1=\begin{pmatrix}3 & 1\\ 1 & 3\end{pmatrix},\qquad \boldsymbol{C}_2=\begin{pmatrix}4 & 2\\ 2 & 4\end{pmatrix}$$

两类的先验概率相等，试求一维特征提取矩阵。

解：总的类内离差阵 $\boldsymbol{S}_{\mathrm{W}}$ 可以算得：

$$\boldsymbol{S}_{\mathrm{W}}=\frac{1}{2}\boldsymbol{C}_1+\frac{1}{2}\boldsymbol{C}_2=\begin{pmatrix}3.5 & 1.5\\ 1..5 & 3.5\end{pmatrix}$$

依据 $\boldsymbol{S}_{\mathrm{W}}$ 进行 DKLT，得到特征值 $\lambda_1=5,\lambda_2=2$。对应的特征矢量分别为

$$\boldsymbol{u}_1 = (0.707, 0.707)^{\mathrm{T}}, \quad \boldsymbol{u}_2 = (0.707, -0.707)^{\mathrm{T}}$$

因为总的均值矢量为

$$\boldsymbol{m} = \frac{1}{2}\boldsymbol{m}_1 + \frac{1}{2}\boldsymbol{m}_2 = (0,0)^{\mathrm{T}}$$

故类间离差阵 $\boldsymbol{S}_{\mathrm{B}}$ 为

$$\boldsymbol{S}_{\mathrm{B}} = \frac{1}{2}\boldsymbol{m}_1\boldsymbol{m}_1^{\mathrm{T}} + \frac{1}{2}\boldsymbol{m}_2\boldsymbol{m}_2^{\mathrm{T}} = \begin{pmatrix} 16 & 8 \\ 8 & 4 \end{pmatrix}$$

计算 $J(y_1)$ 与 $J(y_2)$：

$$J(y_1) = \frac{\boldsymbol{u}_1^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_1}{\lambda_1} \approx 3.7, \quad J(y_2) = \frac{\boldsymbol{u}_2^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{u}_2}{\lambda_2} \approx 1$$

因为 $J(y_1) > J(y_2)$，所以选最佳变换矩阵为 $\boldsymbol{W} = \boldsymbol{u}_1 = (0.707, 0.707)^{\mathrm{T}}$。

上述是依据总的类内离差阵 $\boldsymbol{S}_{\mathrm{W}}$ 作 DKLT 进行特征提取，下面依据 $\boldsymbol{S}_{\mathrm{W}}$ 和 $\boldsymbol{S}_{\mathrm{B}}$ 作 DKLT 进行最优特征提取。注意到 $\lambda_1^{-1/2} = 0.447$ 和 $\lambda_2^{-1/2} = 0.707$，则

$$\boldsymbol{B} = \boldsymbol{U}\boldsymbol{\Lambda}^{-1/2} = \begin{pmatrix} 0.707 & 0.707 \\ 0.707 & -0.707 \end{pmatrix}\begin{pmatrix} 0.447 & 0 \\ 0 & 0.707 \end{pmatrix} = \begin{pmatrix} 0.316 & 0.5 \\ 0.316 & -0.5 \end{pmatrix}$$

对 $\boldsymbol{S}_{\mathrm{B}}$ 进行白化变换：

$$\tilde{\boldsymbol{S}}_{\mathrm{B}} = \boldsymbol{B}^{\mathrm{T}}\boldsymbol{S}_{\mathrm{B}}\boldsymbol{B} = \begin{pmatrix} 3.6 & 1.896 \\ 1.896 & 1 \end{pmatrix}$$

$\tilde{\boldsymbol{S}}_{\mathrm{B}}$ 的非零特征值只有一个，$\tilde{\lambda}_1 = 4.6$，对应的特征矢量为

$$\boldsymbol{v}_1 = (0.884, \quad 0.466)^{\mathrm{T}}$$

所以，总的最优变换为

$$\boldsymbol{W} = \boldsymbol{B}\boldsymbol{v}_1 = (0.512, \quad 0.046)^{\mathrm{T}}$$

图 6.5.3 给出了两种变换以及数据变化的示意图，由于是分别依据 $\boldsymbol{S}_{\mathrm{W}}$ 和 $\boldsymbol{S}_{\mathrm{W}}$ 与 $\boldsymbol{S}_{\mathrm{B}}$ 作 DKLT，所以产生的两个新的坐标系是不同的。

尽管此例两类中心不同，但也可以针对此例数据基于熵概念运用

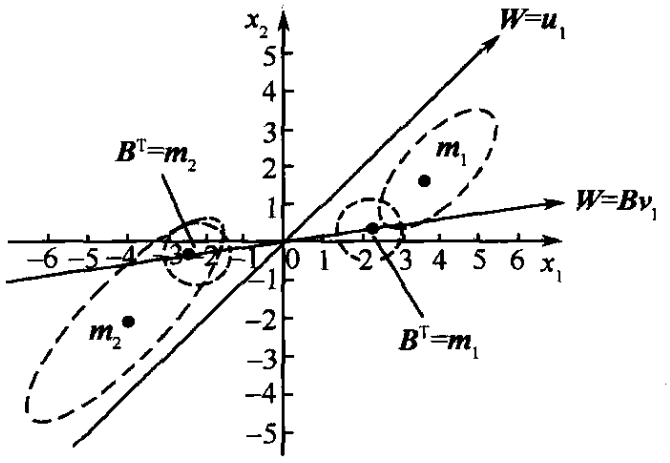


图 6.5.3　DKLT 最优变换示意图

DKLT 方法选择方差差别大的特征。利用前面导出的特征矢量 $\boldsymbol{u}_1$、$\boldsymbol{u}_2$ 令 $\boldsymbol{U}=(\boldsymbol{u}_1\boldsymbol{u}_2)$，对两类协方差阵作变换：

$$\boldsymbol{U}^{\mathrm{T}}\boldsymbol{C}_1\boldsymbol{U}=\begin{pmatrix}4 & 0\\ 0 & 2\end{pmatrix}\qquad \boldsymbol{U}^{\mathrm{T}}\boldsymbol{C}_2\boldsymbol{U}=\begin{pmatrix}6 & 0\\ 0 & 2\end{pmatrix}$$

可得两类各分量的方差：

$$\sigma_{11}^2=4,\sigma_{12}^2=2,\sigma_{21}^2=6,\sigma_{22}^2=2$$

利用前面导出的特征值 $\lambda_1=5,\lambda_2=2$，运用式

$$\tilde{\sigma}_{ij}^2=P_i\sigma_{ij}^2/\lambda_j$$

可得

$$\tilde{\sigma}_{11}^2=0.4,\tilde{\sigma}_{21}^2=0.6,\tilde{\sigma}_{12}^2=0.5,\tilde{\sigma}_{22}^2=0.5$$

将上面各 $\tilde{\sigma}_{ij}^2$ 的值代入下式

$$J(y_j)=-\sum_{i=1}^{2}\tilde{\sigma}_{ij}^2\log\tilde{\sigma}_{ij}^2$$

可得

$$J(y_1)=0.29,J(y_2)=0.30$$

因为 $J(y_1)<J(y_2)$，所以取

$$\boldsymbol{W}=\boldsymbol{u}_1=(0.707,0.707)^{\mathrm{T}}$$

5. 基于总体离差阵 S_T 的 DKLT 选择特征

在有些情况下，所得的样本并不知道它们属于那一类，从而无法得

到 $\boldsymbol{S}_W$ 和 $\boldsymbol{S}_B$，此时，可依据总体离差阵 $\boldsymbol{S}_T$ 作 DKLT，设所得特征值依下面次序排列：

$$\lambda_1 \geqslant \lambda_2 \geqslant \cdots \geqslant \lambda_n$$

由于 $\boldsymbol{S}_T = \boldsymbol{S}_W + \boldsymbol{S}_B$，当类间距离较大时，$\boldsymbol{S}_B$ 在 $\boldsymbol{S}_T$ 中起主导作用。对于给定的 d，选择前面较大的特征值对应的特征矢量作变换矩阵相当于选取变换后类间距离较大的分量，从而可以实现特征选择降低特征空间维数的目的。显然，这种方法适用于类间距离较大的情况。

[**例 6.5.2**] 有两类样本，其分布如图 6－5－4(a)所示，

ω_1:{$(-5,-5)^T$,$(-5,-4)^T$,$(-4,-5)^T$,$(-5,-6)^T$,$(-6,-5)^T$}

ω_2:{$(5,5)^T$,$(5,4)^T$,$(4,5)^T$,$(5,6)^T$,$(6,5)^T$}

用基于 $\boldsymbol{S}_T$ 的 DKLT 作一维特征提取后，结果是原来二维空间中的样本在 t_1 上的投影，如图 6.5.4(b)所示。

$$\omega_1:\left\{-\frac{10}{\sqrt{2}},\quad -\frac{9}{\sqrt{2}},\quad -\frac{9}{\sqrt{2}},\quad -\frac{11}{\sqrt{2}},\quad -\frac{11}{\sqrt{2}}\right\}$$

$$\omega_2:\left\{\frac{10}{\sqrt{2}},\quad \frac{9}{\sqrt{2}},\quad \frac{9}{\sqrt{2}},\quad \frac{11}{\sqrt{2}},\quad \frac{11}{\sqrt{2}}\right\}$$

可见映射后的样本仍然是线性可分的，显然，降维后的模式分类更为便捷。

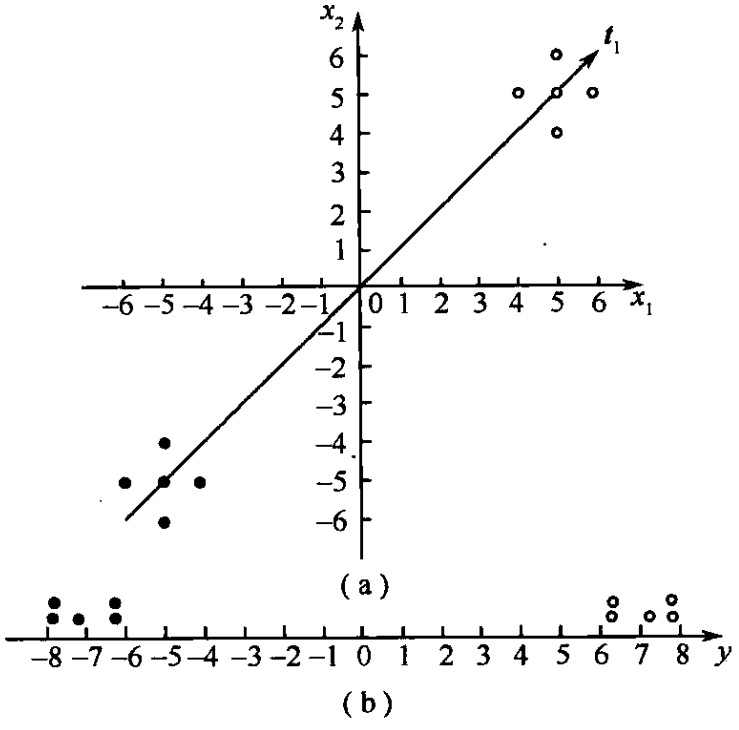


图 6.5.4　两类二维样本及其映射后的一维样本分布图

本节介绍的主要方法是基于 S_W、S_B 作 DKLT，以消除或减弱各特征（分量）之间的相关性，再利用统计的、线性代数的或模式识别的某些概念或性质去选取主分量来达到特征提取与选择、数据压缩等目的。该方法需要较多的已知类别的样本去估计 S_W 和 S_B。如果有一些类别的分布知识，可据此指导选择适当的离差阵进行 DKLT，这样效果会更好，否则可以试用“比选”方法，确定实际依据什么矩阵进行 DKLT。

6.6 特征选择中的直接挑选法

除了前面几节所述的变换法之外，也可以在原坐标系中依据某种原则直接选择特征，由于各种特征组合方案数很大，因此采用搜索树的方法，利用分支定界技术在对某些特征组合并不计算它的可分性判据值的情况下，仍然可以求得全局最优解，从而提高了求解速度。在要求不高的场合，为减少计算量，可求次优解。

6.6.1 次优搜索法

1. 单独最优的特征选择法

要从现存的 n 个特征 $\{x_1, x_2, \cdots, x_n\}$ 中直接选出 d 个特征，所有可能的方案数为 C_n^d，一般情况下这是一个非常大的数，显然要对每一个特征组合计算可分性判据 J 值以寻找使其达到最大的一组特征是不现实的。下面介绍的单独选优法是一种简单而效果尚可的方法。

单独选优法的基本思路是计算各特征单独使用时的判据值并以递减排序，选取前 d 个分类效果最好的特征。一般地讲，即使各特征是统计独立的，这种方法选出的 d 个特征也不一定是最优的特征组合，只有可分性判据 J 是可分的，即

$$J(\boldsymbol{x}) = \sum_{i=1}^{n} J(x_i) \text{ 或 } J(\boldsymbol{x}) = \prod_{i=1}^{n} J(x_i)$$

用这种方法才能选出一组最优特征。例如，在正态分布情况下，当各特征相互独立时，用马氏距离作为判据所选出的特征是一组最优特征。

2. 增添特征法

该方法也称为顺序前进法(SFS)。这是最简单的自下而上搜索方法,每次从未选入的特征中选择一个特征,使它与已选入的特征组合在一起时 J 值最大,直到选入特征数目达到指定的维数 d 为止。

设已选入了 k 个特征,它们记为 X_k,把未选入的 $n-k$ 个特征 $x_j(j=1,2,\cdots,n-k)$ 逐个与已选入的特征 X_k 组合后计算 J 值,若

$$J(X_k+x_1)\geqslant J(X_k+x_2)\geqslant\cdots\geqslant J(X_k+x_{n-k})$$

则选入 x_1,下一步的特征组合为 $X_{k+1}=X_k+x_1$。开始时,$k=0$,$X_0=\varnothing$,该过程一直进行到 $k=d$ 为止。

一般地讲,该方法比单独最优的特征选择法要好,其主要缺点是某特征一旦选入,即使后边的 $n-k$ 个特征中的某个比它好,也无法把它剔除。

该方法的一个推广是每次增加 l 个特征,求 J 值并选取使其最大的特征组合。若已选入 k 个特征,此时每步有 C_{n-k}^{l} 个候选特征组合需要逐个计算,因而计算量变大,但比前面的方法更可靠,因前者是更局部的最优。该方法也无法剔除已选入的特征。这个推广的 SFS 法称为广义 SFS 法(GSFS)。

3. 剔减特征法

该方法也称为顺序后退法(SBS)。这是一种自上而下的搜索方法,从全部特征开始每次剔除一个特征,所剔除的特征应使尚保留的特征组合的 J 值最大。设已剔除了 k 个特征,剩下的特征组合记为 $\bar{X}_k$,将 $\bar{X}_k$ 中的各特征 $x_j(j=1,2,\cdots,n-k)$ 分别有放回地逐个剔除,并同时计算 $J(\bar{X}_k-x_j)$,若

$$J(\bar{X}_k-x_1)\geqslant J(\bar{X}_k-x_2)\geqslant\cdots\geqslant J(\bar{X}_k-x_{n-k})$$

则在这轮中 x_1 应该剔除。

$$\bar{X}_{k+1}=\bar{X}_k-x_1$$

这里初值 $k=0$,$\bar{X}_0=\{x_1,x_2,\cdots,x_n\}$,过程直到 $k=n-d$ 为止。

由于该方法是在高维空间中计算 J 值,因此计算量比增添特征法更大。此方法也可以推广至每次剔除 r 个特征,此推广方法称为广义 SBS 方法(GSBS)。

4. 增 l 减 r 法($l-r$ 法)

为了克服前面 SFS 法、SBS 法中的某特征一旦选入或剔除就不能再剔除或选入的缺点,可在选择过程中加入局部回溯,例如在第 k 步可先用 SFS 方法,对已选入的 k 个特征再一个个地加入新的特征到 $k+l$ 个特征,然后用 SBS 方法一个个地剔除 r 个特征,称这种方法为增 l 减 r 法($l-r$ 法)。

5. Z_l-Z_r 法

类似地,若在每一步用 GSFS 和 GSBS 代替 $l-r$ 法中的 SFS 和 SBS,则形成广义的 $l-r$ 法。

将 l、r 分解成一些正整数:

$$l_i: i=1,2,\cdots,z_l,\quad 0\leqslant l_i\leqslant l,\quad \sum_{i=1}^{z_l} l_i=l$$

$$r_j: j=1,2,\cdots,z_r,\quad 0\leqslant r_j\leqslant r,\quad \sum_{j=1}^{z_r} r_j=r$$

用 GSFS 法逐次分 z_l 步增加特征,每次加入 l_i 个特征,一共加入 l 个特征;用 GSBS 法逐次分 z_r 步剔除特征,每次剔除 r_j 个特征,一共剔除 r 个特征。增加和剔除是交替进行的。之所以要分 z_l 步增加 l 个特征和分 z_r 步减少 r 个特征,是为了既考虑到选入或剔除特征之间的相关性,又不至于因此引起计算量过大。例如假使一步就使特征组由原来的空集增加到 d 个特征,这就成为计算量极大的穷举法,而每次只增加一个特征,则没考虑入选特征间的相关性。合理地设置整数序列 $Z_l=(l_1,l_2,\cdots,l_{z_l})$ 和 $Z_r=(r_1,r_2,\cdots,r_{z_r})$ 可以同时对计算复杂性和特征选择的合理性兼顾考虑,称此方法为 Z_l-Z_r 法。SFS 法、SBS 法、$l-r$ 法都可视作 Z_l-Z_r 法的特例。例如,取 $Z_l=(1,1,\cdots,1)$、$Z_r=(1,1,\cdots,1)$,$l_i=r_j=1$,此时,Z_l-Z_r 法就是的 $l-r$ 法。

6. 可分性判据递推算法

上述的搜索法都有一个共同特点,第 k 步的特征组是在第 $k-1$ 步特征组的基础上加入或剔除某些特征构成的,由离差阵构造的可分性判据 $J_1\sim J_4$ 可以看出,各判据都是协方差阵和均值矢量的函数,加上或剔除某个特征,均值矢量只增加或减少一个分量,协方差阵只增加或

减少一行一列，此表明这些判据递推关系是存在的，即求 $J(X_k)$ 时可在 $J(X_{k-1})$ 的基础上把新加入或剔除的特征的影响加进去即可，不必从头计算，这样就大大简化了计算工作。

6.6.2 最优搜索法

下面讲述分支定界法（BAB 算法）原理。

寻求全局最优的特征组合的搜索过程可用一个树结构来描述，称其为搜索树或解树。总的搜索方案是沿着树自上而下、从右至左进行，由于树的每个节点代表一种特征组合，于是所有可能的组合都可以被考虑，因为同时利用了可分性判据的单调性采用分支定界策略使得在实际上并不计算某些特征组合而又不影响全局寻优，又因为搜索先从结构简单的部分开始，所以这种特征选择算法效率很高。这种快速搜索方法，称为分支定界算法。

下面以图 6.6.1 所示的从 6 个特征中选出 2 个特征的例子来说明从 n 个特征中选出 d 个特征 $S(n,d)$ 的原理和方法。

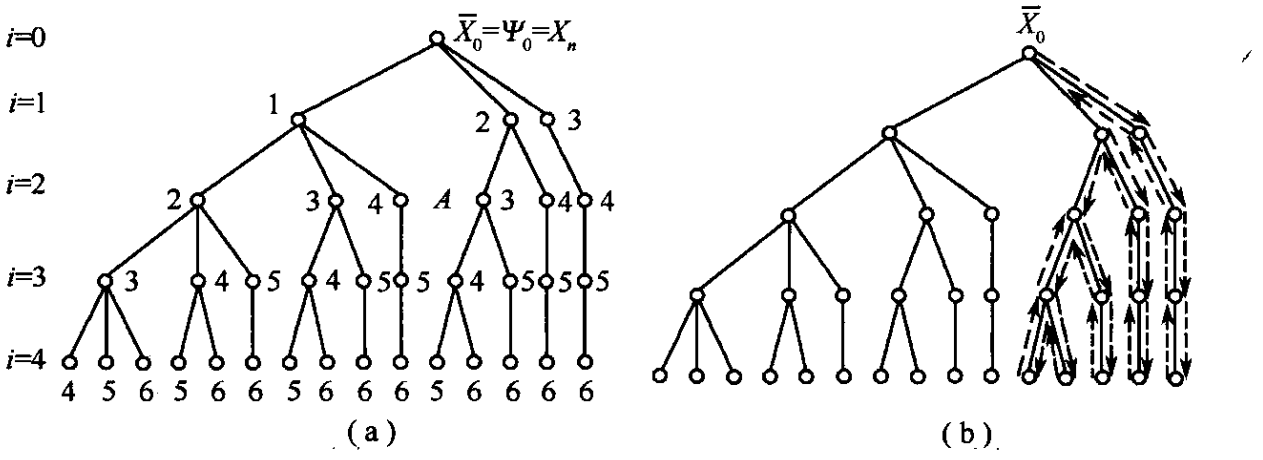


图 6.6.1　6 选 2 的特征选择问题 $S(6,2)$

（a）搜索树；（b）搜索回溯示意图。

树的每个节点表示一种特征组合。根节点代表全部特征的组合，在这里为 $(x_1,x_2,\cdots,x_6)$。子节点代表的特征比其父节点代表的特征少一个，同父的各子节点分别代表从父节点的特征组合中丢弃不同的一个特征后余下的特征，节点上的标记 k 表示被丢弃的特征的序号，这个节点所代表的特征是从其父节点特征组中去掉 x_k 所余下的特征。如节点 A 表示已去掉 x_2、x_3 后的特征组合 (x_1,x_4,x_5,x_6)。各叶节点代

表各种不同的 d 个特征的组合，表示特征选择后的一个可能解，这里表示两个特征。$S(n,d)$ 共有 C_n^d 个叶节点。沿树的纵向看，每去掉一个特征称为树的一级，由于从 n 个特征中要选出 d 个特征，因此全树有 $n-d$ 级，根节点为 0 级，叶节点为 $n-d$ 级。级也称为深度，可用 s 表示，$s=0,1,\cdots,n-d$。具有深度 s 的节点代表 $n-s$ 个特征。用 X_l 表示含 l 个特征的特征集，$\overline{X}_s$ 表示舍弃 s 个特征后余下的特征，Ψ_s 表示可供第 s 级当前节点的下一级选择舍弃的特征的集合，r_s 表示这个集合中元素的数目，q_s 表示当前节点的子节点数。由于在第 s 级某节点后续的每个子节点都要舍弃 Ψ_s 中互不相同的一个特征，从而对于这个节点在确定它的下一级（$s+1$ 级）可以丢弃一个特征的实际方案数（即子节点数）时，必须使这一级任一子节点丢弃一个特征后 $\overline{X}_{s+1}$（至少）还剩下 $(n-d)-(s+1)$ 个特征以供下面每级丢弃一个特征，对某子节点来讲，它及其左边同父节点已丢弃的特征以后不再在要丢弃的特征组之内，所以子节点数 $q_s=r_s-(n-d-s-1)$。例如在 0 级，$\Psi_0=(x_1,x_2,\cdots,x_6)$，$r_0=6$，$q_0=6-(4-0-1)=3$，即对于 0 级，有 3 个子节点，左、中、右子节点舍弃的特征分别为 x_1、x_2、x_3。所谓第 s 级当前节点是指尚未搜索过的最右边的节点。例如对于 $s=1$，左边的节点 $\Psi_1=(x_2,x_3,x_4,x_5,x_6)$，中间节点 $\Psi_1=(x_3,x_4,x_5,x_6)$，右边的节点 $\Psi_1=(x_4,x_5,x_6)$。对于同父的各子节点，从左至右 Ψ_1 逐次少一个特征，最右边的那个节点总有 $q_s=1$，即最右边节点总是只有一个子节点。

搜索过程在总体上是由上至下、从右至左地进行。在这个过程中包含几个可能子过程：向下搜索、更新界值、向上回溯、停止回溯再向下搜索。开始时置界值 $B=0$，首先从树的根节点沿最右边的一支自上而下搜索。对于一个节点，它的子树最右边的一支总是无分支的，即是 1 度节点（只有一个子节点的节点称为 1 度节点）或叶节点（0 度节点）。此时可直接到达叶节点，计算该节点代表的特征组的可分性判据 $J(\overline{X}_{n-d})$，更新界值，令 $B=J(\overline{X}_{n-d})$，然后向上回溯。一旦遇到有分支的那个节点则停止回溯向下转入搜索。例如回溯到 $q_{s-1}>1$ 的那个节点，则转入 s 深度的左边的最近的那个节点，使该节点成为当前节点。按上述，从这一节点向下首先对它最右边的子树

搜索。在搜索过程中，当某节点的 J 值不大于当前界值 B 时，就停止向下搜索（因其所有的子节点的 J 值都不大于当前界值 B），开始回溯；否则，搜索到叶节点，如果该叶节点代表的特征组的可分性判据 J 大于 B，则更新界值，令 $B=J$；否则，不更新界值。显然，无论是哪一种情况，到达叶节点后都要向上回溯。重复上述过程，一直进行到 J 值不大于当前界值 B 为止。

确定搜索树可以采用递推的方法，由子树通过不断地添加一个特征并由子树的叶节点“长”出新的叶节点的方法产生搜索树。此外还可以采用下面的方法，为能确定树结构，即确定在回溯结束后转入搜索时的节点的后续子节点数，要求知道该节点的 Ψ_s，因此在回溯过程中，每次向上一级（$s-1$ 级）回溯时，都要把原来节点的 Ψ_s 加上那个节点所舍弃的特征。此例中沿最右一支回溯中，在根节点才有分支，因而向上搜索时 $s=1$ 的当前节点 $\Psi_1=\Psi'_1+x_3=(x_4,x_5,x_6)+x_3=(x_3,x_4,x_5,x_6)$，$\Psi'_1$ 为当前节点的同父右边近邻的节点的 Ψ_1。

该算法具有高效性的原因在于以下两点。

（1）利用了判据 J 值的单调性，如树上某节点 A 的可分性判据值 $J_A\leqslant B$，可知 A 的子树上各节点的 J 值都不会大于 B，于是节点 A 的子树各节点都不必去搜索，这就是所谓的分支定界，从而有相当多的特征组合不需计算而仍能求得全局最优解。

（2）树的右边比左边结构简单，而搜索过程是从右至左进行的。在此基础上，为了提高效率，对于单支可以直接跳跃到叶节点。

习　题

6.1 考虑散度：

$$J_D=\int(p(\boldsymbol{x}\mid\omega_1)-p(\boldsymbol{x}\mid\omega_2))\log\left(\frac{p(\boldsymbol{x}\mid\omega_1)}{p(\boldsymbol{x}\mid\omega_2)}\right)\mathrm{d}\boldsymbol{x}$$

其中，$\boldsymbol{x}=(x_1,\cdots,x_n)^{\mathrm{T}}$。证明：在各分量独立条件下，$J_D$ 可以表示成：

$$J_D = \sum_{i=1}^{n} J_D(x_i)$$

6.2 试以 J_2、J_4 为准则进行特征提取与选择。

6.3 试证定理 6.4.1。

6.4 试证当 $\boldsymbol{R}_x - \boldsymbol{C}_x$ 为非负定阵时，有

$$\lambda_i(\boldsymbol{R}_x) \geqslant \lambda_i(\boldsymbol{C}_x)$$

其中 $\lambda_i(\boldsymbol{R}_x)$ 和 $\lambda_i(\boldsymbol{C}_x)$ 分别表示 $\boldsymbol{R}_x$ 和 $\boldsymbol{C}_x$ 的第 i 大的特征值。

6.5 (Chatfield 和 Collins，1980) 设 n 维随机向量 $\boldsymbol{x}$ 的协方差矩阵为 $\boldsymbol{\Sigma}$，其特征值为 $\{\lambda_i\}$，正交特征向量为 $\{\boldsymbol{a}_i\}$。证明单位矩阵可由下式给出：

$$\boldsymbol{I} = \boldsymbol{a}_1\boldsymbol{a}_1^{\mathrm{T}} + \cdots + \boldsymbol{a}_n\boldsymbol{a}_n^{\mathrm{T}}$$

且有：

$$\boldsymbol{\Sigma} = \lambda_1\boldsymbol{a}_1\boldsymbol{a}_1^{\mathrm{T}} + \cdots + \lambda_n\boldsymbol{a}_n\boldsymbol{a}_n^{\mathrm{T}}$$

6.6 对于两个具有相同协方差矩阵 $\boldsymbol{\Sigma}$ 的正态分布 $N(\boldsymbol{\mu}_1, \boldsymbol{\Sigma})$ 和 $N(\boldsymbol{\mu}_2, \boldsymbol{\Sigma})$ 的类，证明散度：

$$J_D(\omega_1, \omega_2) = \int [p(\boldsymbol{x} \mid \omega_1) - p(\boldsymbol{x} \mid \omega_2)] \log \frac{p(\boldsymbol{x} \mid \omega_1)}{p(\boldsymbol{x} \mid \omega_2)} \mathrm{d}\boldsymbol{x}$$

由马氏距离

$$(\boldsymbol{\mu}_2 - \boldsymbol{\mu}_1)^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_2 - \boldsymbol{\mu}_1)$$

给出。

6.7 令 $\boldsymbol{\Sigma}_i$ 和 P_i 分别是 ω_i 类 $(i = 1, 2)$ 的协方差矩阵和先验概率。假定对数据进行了白化变换，即使 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{S}_w\boldsymbol{B} = \boldsymbol{I}$，$\boldsymbol{I}$ 是单位阵。证明矩阵 $P_1\boldsymbol{B}^{\mathrm{T}}\boldsymbol{\Sigma}_1\boldsymbol{B}$ 和 $P_2\boldsymbol{B}^{\mathrm{T}}\boldsymbol{\Sigma}_2\boldsymbol{B}$ 所产生的 K-L 坐标轴是相同的。若用 $\boldsymbol{\Lambda}_i$ 表示 $P_i\boldsymbol{B}^{\mathrm{T}}\boldsymbol{\Sigma}_i\boldsymbol{B}$ 的特征值矩阵，求证

$$\boldsymbol{\Lambda}_1 = \boldsymbol{I} - \boldsymbol{\Lambda}_2$$

6.8 若有下列两类样本集：

ω_1	ω_2
$x_1^1=(0,0,0)^T$	$x_1^2=(0,0,1)^T$
$x_2^1=(1,0,0)^T$	$x_2^2=(0,1,0)^T$
$x_3^1=(1,0,1)^T$	$x_3^2=(0,1,1)^T$
$x_4^1=(1,1,0)^T$	$x_4^2=(1,1,1)^T$

用 K－L 变换，分别把特征空间维数降到 $d=2$ 和 $d=1$ 并用图画出样本在该特征空间中的位置。

6.9 试编写分支定界法程序并自行产生实验数据进行特征选择。

第 7 章　其他模式识别方法

7.1　模糊模式识别

7.1.1　模糊数学基础知识

1965 年,Zadeh 提出了著名的模糊集理论,该理论引起了数学界和科技工程界的极大兴趣并进行了深入广泛的研究,理论成果和应用成果不断出现,从而创建了一门新的学科—模糊数学。模糊集理论是对一类客观事物和性质更合理的抽象和描述,是传统集合理论的必然推广。在介绍具体模糊模式识别技术之前,先介绍模糊数学中基本的重要的概念、定义、性质等知识。

1. 普通集合与模糊集合

在普通集合论中,一个元素要么属于一个集合,要么不属于这个集合,二者必居其一且只居其一。记 A 是论域 U 上的一个集合,x 为 U 中的元素,则 $x \in A$ 与 $x \notin A$ 只有且必有一个成立。一个集合可以用特征函数来表征,它由映射

$$C_A(x) = \begin{cases} 1 & (x \in A) \\ 0 & (x \notin A) \end{cases} \qquad (7-1-1)$$

唯一确定。$C_A(x)$ 在 x_0 处的取值 $C_A(x_0)$ 称为 $x_0 \in U$ 对 A 的隶属度。显然,这里元素的归属是明确的,这是所谓的“硬划分”,集合也是“分明集”。将普通集合论中特征函数的取值范围由 $\{0,1\}$ 推广到闭区间 $[0,1]$,于是得到模糊集的定义。

[定义 7.1.1] 相对于论域 U 上的一个集合 $\underset{\sim}{A}$,对任意 $x \in U$,都指定了一个数 $\mu_{\underset{\sim}{A}}(x) \in [0,1]$ 用以表示 x 属于 $\underset{\sim}{A}$ 的程度,即有映射

$$\mu_{\underset{\sim}{A}}(x): U \rightarrow [0,1]$$

$$x \rightarrow \mu_{\underset{\sim}{A}}(x)$$

由$\mu_{\underset{\sim}{A}}(x)$所确定的集合$\underset{\sim}{A}$称为$U$上的一个模糊(子)集,函数$\mu_{\underset{\sim}{A}}(x)$称为模糊集$\underset{\sim}{A}$的隶属函数,对某一$x \in U$,值$\mu_{\underset{\sim}{A}}(x)$称为$x$对$\underset{\sim}{A}$的隶属度。有时为简洁$\mu_{\underset{\sim}{A}}(x)$也写成$\underset{\sim}{A}(x)$。

例如,某人属于"老年人"集合的隶属函数,可以用下式进行计算:

$$\mu_{老年人}(x) = \frac{1}{1 + \left(\frac{5}{x-50}\right)^2}$$

式中的x表示50岁以上的人的年龄,由计算可得

$$\mu_{老年人}(55) = 0.5, \mu_{老年人}(60) = 0.8, \mu_{老年人}(70) = 0.94$$

这表明55岁的人只能算是"半老",因为他属于"老年人"集合的资格只有0.5,而60岁、70岁的人属于"老年人"集合的程度分别为0.8和0.94。

在论域U上模糊集的全体称为U的模糊幂集,记为$F(U)$。

作为确定集的推广,和确定集一样,具有共同论域的模糊集也可以定义相等、包含,以及集合运算,此时逐点对其隶属度作相应运算。模糊集$\underset{\sim}{A}, \underset{\sim}{B}$相等、包含及集合运算定义如下。

(1)相等。设$\underset{\sim}{A}, \underset{\sim}{B} \in F(U)$,当且仅当 $\forall x \in U$,有$\mu_{\underset{\sim}{A}}(x) = \mu_{\underset{\sim}{B}}(x)$,则称$\underset{\sim}{A}$和$\underset{\sim}{B}$相等,记为$\underset{\sim}{A} = \underset{\sim}{B}$。

(2)包含。设$\underset{\sim}{A}, \underset{\sim}{B} \in F(U)$,若对$\forall x \in U$,都有$\mu_{\underset{\sim}{A}}(x) \geqslant \mu_{\underset{\sim}{B}}(x)$成立,则称$\underset{\sim}{A}$包含$\underset{\sim}{B}$,或称$\underset{\sim}{B}$是$\underset{\sim}{A}$的子集,记为$\underset{\sim}{A} \supseteq \underset{\sim}{B}$

(3)并。设$\underset{\sim}{A}, \underset{\sim}{B} \in F(U)$,$\underset{\sim}{A}$与$\underset{\sim}{B}$的并集仍是一模糊集,记为$\underset{\sim}{A} \cup \underset{\sim}{B}$,它的隶属函数为

$$\mu_{\underset{\sim}{A} \cup \underset{\sim}{B}}(x) = \max[\mu_{\underset{\sim}{A}}(x), \mu_{\underset{\sim}{B}}(x)] \triangleq \mu_{\underset{\sim}{A}}(x) \vee \mu_{\underset{\sim}{B}}(x)$$

(4)交。设$\underset{\sim}{A}, \underset{\sim}{B} \in F(U)$,$\underset{\sim}{A}$与$\underset{\sim}{B}$的交集记为$\underset{\sim}{A} \cap \underset{\sim}{B}$,它的隶属函数为

$$\mu_{\underset{\sim}{A}\cap\underset{\sim}{B}}(x)=\min[\mu_{\underset{\sim}{A}}(x),\mu_{\underset{\sim}{B}}(x)]\triangleq\mu_{\underset{\sim}{A}}(x)\wedge\mu_{\underset{\sim}{B}}(x)$$

(5)补。设$\underset{\sim}{A}\in F(U)$,模糊集$\underset{\sim}{A}$的补集$\underset{\sim}{A}^c$的隶属函数为

$$\mu_{\underset{\sim}{A}^c}(x)=1-\mu_{\underset{\sim}{A}}(x)$$

模糊集除了并、交、补运算外,还可定义代数积、代数和、有界和、有界差、有界积、极端和、极端积、对称差、Einstein 和 Einstein 积、集中运算、扩张运算等运算,这里从略。

一些常见的隶属函数有

(1)矩形隶属函数。

(a)偏小型 $$\underset{\sim}{A}(x)=\begin{cases}1(0\leqslant x\leqslant a)\\0(x>a)\end{cases}$$

(b)偏大型 $$\underset{\sim}{A}(x)=\begin{cases}0(x<a)\\1(x\geqslant a)\end{cases}$$

(c)中间型 $$\underset{\sim}{A}(x)=\begin{cases}0(x<a)\\1(a\leqslant x\leqslant b)\\0(x>b)\end{cases}$$

(2)梯形隶属函数。

(a)偏小型 $$\underset{\sim}{A}(x)=\begin{cases}1(0\leqslant x<a)\\\dfrac{b-x}{b-a}(a\leqslant x<b)\\0(x\geqslant b)\end{cases}$$

(b)偏大型 $$\underset{\sim}{A}(x)=\begin{cases}0(x<a)\\\dfrac{x-a}{b-a}(a\leqslant x<b)\\1(x\geqslant b)\end{cases}$$

(c)中间型 $$\underset{\sim}{A}(x)=\begin{cases}0(x<a)\\\dfrac{x-a}{b-a}(a\leqslant x<b)\\1(b\leqslant x<c)\\\dfrac{d-x}{d-c}(c\leqslant x<d)\\0(x\geqslant d)\end{cases}$$

(3)k 次梯形隶属函数。

(a)偏小型 $$\underset{\sim}{A}(x)=\begin{cases}1(x<a)\\ \left(\dfrac{b-x}{b-a}\right)^{k}(a\leqslant x<b)\\ 0(x\geqslant b)\end{cases}$$

(b)偏大型 $$\underset{\sim}{A}(x)=\begin{cases}0(x<a)\\ \left(\dfrac{x-a}{b-a}\right)^{k}(a\leqslant x<b)\\ 1(x\geqslant b)\end{cases}$$

(c)中间型 $$\underset{\sim}{A}(x)=\begin{cases}0(x<a)\\ \left(\dfrac{x-a}{b-a}\right)^{k}(a\leqslant x<b)\\ 1(b\leqslant x<c)\\ \left(\dfrac{d-x}{d-c}\right)^{k}(c\leqslant x<d)\\ 0(x\geqslant d)\end{cases}$$

(4)Γ 型隶属函数。

(a)偏小型 $$\underset{\sim}{A}(x)=\begin{cases}1(0\leqslant x<a)\\ \mathrm{e}^{-k(x-a)}(x\geqslant a,k>0)\end{cases}$$

(b)偏大型 $$\underset{\sim}{A}(x)=\begin{cases}0(x<a)\\ 1-\mathrm{e}^{-k(x-a)}(x\geqslant a,k>0)\end{cases}$$

(c)中间型 $$\underset{\sim}{A}(x)=\begin{cases}\mathrm{e}^{k(x-a)}(x<a)\\ 1(a\leqslant x<b)(k>0)\\ \mathrm{e}^{-k(x-b)}(x\geqslant b)\end{cases}$$

(5)正态型隶属函数。

(a)偏小型 $$\underset{\sim}{A}(x)=\begin{cases}1(0\leqslant x\leqslant a)\\ \mathrm{e}^{-\left(\frac{x-a}{\sigma}\right)^{2}}(x>a)\end{cases}$$

(b)偏大型 $$\underset{\sim}{A}(x)=\begin{cases}0(x<a)\\ 1-\mathrm{e}^{-\left(\frac{x-a}{\sigma}\right)^{2}}(x\geqslant a)\end{cases}$$

(c)中间型 $$\underset{\sim}{A}(x)=\begin{cases}e^{-\left(\frac{x-a}{\sigma}\right)^2} & (x<a)\\ 1 & (a\leqslant x\leqslant b)\\ e^{-\left(\frac{x-b}{\sigma}\right)^2} & (x>b)\end{cases}$$

2. 模糊关系

世界上事物之间普遍存在着各种各样的联系,这种联系也称为关系。人与人之间有各种关系,人与物、物与物之间也有各种关系;在实数中有大于、小于、等于关系,几何上有全等、相似等关系。数学上的关系概念是客观事物之间联系的一种科学抽象,是事物之间联系的基本数学模型,它去掉了关系的具体含义,而只考虑关系是否存在。

关系通常用符号"R"表示,如果只涉及两事物之间的关系,则称为二元关系。若 a 和 b 有关系 R,就记为 $a\mathrm{R}b$;若它们没有关系 R,就记为 $a\mathrm{R}b$。

在集合 A 和 B 中各取出一元素排成一个序对,所有这样的序对组成了 A 和 B 的直积(集)或笛卡儿积

$$A\times B=\{(x,y)\mid x\in A,y\in B\} \qquad (7-1-2)$$

设 R 是集合 A 到集合 B 的一个关系,对任意的 $x\in A,y\in B$,在分明集中,它们只能是下列两种情况之一:

(1)x 与 y 有关系 R,即 $x\mathrm{R}y$;

(2)x 与 y 无关系 R,即 $x\mathrm{R}y$。

所有有关系 R 的序对(x,y)组成一个 R 集

$$R=\{(x,y)\mid x\in A,y\in B,x\mathrm{R}y\} \qquad (7-1-3)$$

即关系定义了一个序对集合,也可以说,序对集合定义了一个关系,关系可由序对集合表示,所以关系和其确定的集合通常用一个符号表示。显然,R 集是 $A\times B$ 的子集。当 $B=A$ 时,称 R 为集合 A 中的关系。

许多情况下,两个事物之间的关系不宜用"有"或"无"作完全肯定或完全否定的回答,这就需要对经典数学上的关系概念加以推广,为此引入模糊关系。

[定义 7.1.2]设 X,Y 是论域,所谓 $X\times Y$ 上的一个模糊关系$\underset{\sim}{R}$是指,$\underset{\sim}{R}$确定了 $X\times Y$ 上的一个模糊集,其亦记为$\underset{\sim}{R}$。$x\in X,y\in Y$ 满足关系

R的程度(相关程度)作为(x,y)对模糊集R的隶属度,并记为$R(x,y)$或$\mu_R(x,y)$。

上述定义表明,模糊关系确定了一个模糊集,模糊集也定义了一个模糊关系。$X\times Y$上的模糊关系R也称为X到Y的模糊关系。

例如,考察集合$X=\{1,5,7,9,20\}$上的"大的多"关系R。直积空间$X\times X$中有20个序对,序对(20,1)中第一个元素比第二个元素确实大很多,可以认为它属于大得多的程度为1。而序对(9,5)中虽然也具有大于的关系,但说大得多却比较勉强,可以认为此序对属于大得多的程度为0.3。应该说明,这样确定R的从属函数带有相当的主观性,但也是对模糊关系的一个客观反应。

对于有限论域$X=\{x_1,x_2,\cdots,x_m\}$,$Y=\{y_1,y_2,\cdots,y_n\}$,X到Y的模糊关系R可用$m\times n$矩阵$\boldsymbol{R}$表示

$$\boldsymbol{R}=(r_{ij})_{m\times n},\qquad r_{ij}=R(x_i,y_j)\in[0,1]$$

称$\boldsymbol{R}$为模糊矩阵。

3. 模糊度

度量一个模糊集的模糊程度是很重要的,它可以从总体上反映论域的各元素属于或不属于一个集合的明确性。

[**定义7.1.3**]$F(U)$上的模糊度是一个映射

$$d:F(U)\to[0,1]$$

$$A\to d(A)$$

其满足:(1) $d(A)=0\Leftrightarrow A$是确定集。

(2) $d(A)=1\Leftrightarrow\forall x\in U,\mu_A(x)=\dfrac{1}{2}$。

(3)如果$\forall x\in U,\mu_A(x)\leqslant\mu_B(x)\leqslant\dfrac{1}{2}$或$\mu_A(x)\geqslant\mu_B(x)\geqslant\dfrac{1}{2}$,则$d(A)\leqslant d(B)$。

(4) $d(A^c)=d(A)$。

称$d(A)$为A的模糊度。

模糊度刻画一个模糊集的整体模糊程度。定义中的4条公理性质是容易理解的。确定集显然是不模糊的;(2)和(3)表明,从总体上讲

各元素隶属度越接近 1 或 0,越不模糊;越接近 0.5 越模糊;(4)表明$\tilde{A}$与它的补集$\tilde{A}^c$模糊度是相同的。

7.1.2 模糊模式识别的基本方法

模糊模式识别方法是利用模糊数学中的概念、原理与方法解决分类识别问题,这里有很多与统计模式识别算法"平行"的方法。它们之间存在某种程度的借鉴和相似,但又有很大的不同,最根本性的差别是将类别、待识对象作为模糊集和其元素。因此,应根据实际问题进行特征提取或特征变换,将原来普通意义上的特征值变为模糊特征,建立模糊集的隶属函数,或建立元素之间的模糊相似关系,并确定这个关系的隶属函数(相关程度),然后运用有关的模糊数学的原理方法进行分类识别。模糊模式识别方法主要有最大隶属度原则、择近原则、传递闭包法、直接聚类法、模糊 C - 均值法、最大树法及模糊综合评判等。

模糊模式识别可能要作如下几项工作。

1. 特征的变换

由于类别(本质)和特征(表象)之间可能存在较复杂的非线性关系,为使它们之间的关系更为直接和简单,可以将原来的特征值域分成若干部分,并且使各部分的特征含义也作更本质的改变,于是原先的每个或几个特征分量转变为多个特征变量,并且使每个特征值是原特征的某一局部更本质特征的隶属度。用这些新的特征表示原来的对象,由于这些新的特征能更好地反映对象的本质,因此对后续的分类器的设计提供了很大的方便,同时也能提高分类器的性能。在实际中要使这种变换有益和有效,往往需要应用领域的专门知识。

2. 建立隶属函数

为能运用模糊数学方法进行分类识别,应根据具体情况确定采用何种方法建立模糊集的隶属函数。在这里首先需要确定什么作为论域,什么作为模糊集。

3. 确定模糊相似关系

设 $\boldsymbol{x}_i = (x_{i1}, x_{i2}, \cdots, x_{in})^{\mathrm{T}}$ 是对象的 n 维特征矢量,$X = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_N\}$ 是被分类的对象的全体。根据实际情况,可以运用集值统计法,也可以按照第二章中普通的聚类技术中相关测度方法,例如取夹角余弦、

相关系数、最大最小法等建立模糊相似矩阵(通常称为标定),矩阵元素表示 x_i 和 x_j 相似关系的隶属度,也可以采用模糊集的贴近度法计算。

4. 模糊模式识别

根据对象的特点和已有的知识,选用适当的模糊模式识别方法进行识别。

5. 模糊结果的处理

使用模糊技术进行分类的结果不再是一个模式明确地属于某一类或不属于某一类,而是以一定的隶属度属于各个类别。这样的结果往往更真实,具有更多的信息。如果分类识别系统是多级的,这样的结果无疑有益于下一级的决策。如果这是最后一级决策,而且要求一个明确的类别判决,可以根据模式相对各类的隶属度或其他一些指标如贴近度等进行硬性分类。例如可用下面的方法使模糊划分明晰化。

(1)设 x_j 是待识模式,$v_i(i=1,2,\cdots,c)$ 为类心,如果 $\|x_j - v_k\| = \min_i \|x_j - v_i\|$,则判 $x_j \in \omega_k$。

(2)设 μ_{ij} 是 x_j 关于 ω_i 类的隶属度,如果 $\mu_{kj} = \max_i [\mu_{ij}]$,则判 $x_j \in \omega_k$。

在模糊模式识别中,有许多识别的原则和方法,其中最常用的原则方法是最大隶属度原则。

设$\underset{\sim}{A}_i,(i=1,2,\cdots,c)$ 是论域 U 上的模糊集,这里每个模糊集$\underset{\sim}{A}_i$ 表示一个模糊模式类 ω_i。设论域中各个元素 x 对每个$\underset{\sim}{A}_i$ 的隶属度为 $\mu_{\underset{\sim}{A}_i}(x)$,如果对于给定的 $x_j \in U$ 有

$$\mu_{\underset{\sim}{A}_k}(x_j) = \max_i [\mu_{\underset{\sim}{A}_i}(x_j)]$$

则判 $x_j \in \underset{\sim}{A}_k$,即判 x_j 属于 ω_k 类,或说 x_j 相对地属于 ω_k 类。上述的方法(二)实际上就是最大隶属度原则。

为能运用最大隶属度原则,对一个分类识别问题可如下处理。一些特征的值域分别作为论域,在其上定义若干有意义的类别属性,将它们视为模糊集,构造有关特征(值)关于这些属性的隶属函数,各类模糊集是各属性模糊集的某些“运算”,即各类别的隶属函数是各属性隶

属函数的某种“综合”。对一个待识模式，将其各特征值代入各类隶属函数，运用最大隶属度原则进行分类。

7.2 神经网络在模式识别中的应用

模式识别不仅要研发运用机器处理分析信息的技术，而且还应进行人类感知与思维规律的探索。现代模式识别算法构成的计算机识别系统已初步显示出了一定的人脑功能——智能，但是与人相比还差得很远，总体上可以说只相当于一个儿童水平。作为一种智能技术，人工神经网络技术以其崭新的思路，优良的特性引起了人们极大的研究开发兴趣，以期使机器智能处理能力有较大的提高。

人工神经网络是最近30多年来发展起来的一支十分活跃的交叉学科，它涉及生物物理学、数学、控制论、电子及计算机技术，并显示出极其广泛的应用前景，目前已在模式识别等领域得到了广泛的应用。模式识别的神经网络方法和传统的方法相比，具有下面几个明显的优点。

(1)具有很强的容错性，能够识别带有噪声或变形的输入模式。

(2)具有较强的自适应学习能力。

(3)并行分布式信息存储与处理，识别速度快。

(4)能把识别和若干预处理融为一体进行。

本节主要讨论几种用于模式识别的较成熟的神经网络模型及其应用。

7.2.1 人工神经网络的基本知识

1. 生物神经元与人工神经元

一个神经细胞即神经元(neuron)是由细胞体、树突、轴突和突触组成的，其结构如图7.2.1所示。细胞体是神经元新陈代谢的中心，是接受和处理信息的单位。高等动物的神经细胞，除了特殊的神经元外，一般每个神经元都在细胞体的轴丘处生长着一根突起，称其为轴突，它的功能是向外传送从细胞体发出的神经信息。树突为细胞体向外伸出的很多树状突起，它们的作用是从周围收集其他神经元发出的信息。轴

突的末端分出许多分枝和别的神经元树突或细胞体相接触，两者接触部分称为突触，它是一个神经元与另一个神经元相联系的部位，它包括突触前、突触后、突触间隙。突触前是一个神经元轴突的末梢，突触后是另一个神经元的树突的始端或细胞体与轴突末梢接触的部分。人脑大约有 10^{11} 个神经细胞，这些神经细胞分布在不同模块内，人脑大约有数百个神经网络，神经细胞轴突和其他神经细胞树突或胞体一一连接，把众多的神经元连成一个个神经元网络。每个神经细胞大约平均有 10^3 个 ~ 10^4 个突触。信息传递在突触处表现为化学或电的变化和传递。一个神经元所受的信息电位可以累加。突触的状态分为兴奋和抑制两种，分别传递兴奋信号和抑制信号。突触传递信息需要一定的时间，神经冲动信号沿神经纤维传导速率为 1m/s ~ 150m/s。

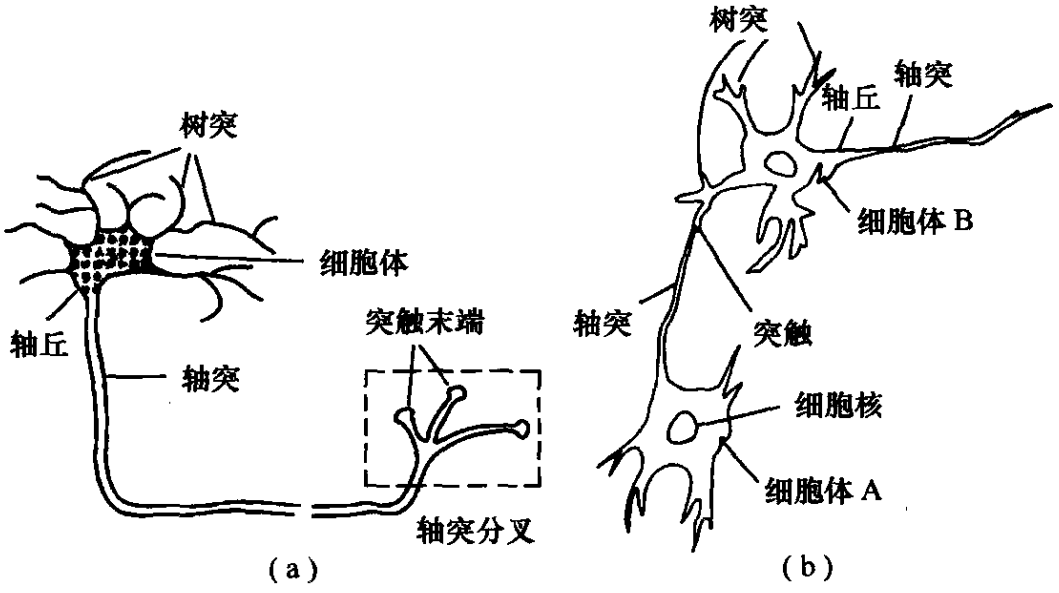


图 7.2.1　神经细胞单元示意图

人工神经网络是采用物理可实现的器件或计算机通过硬件与软件的方式模拟生物体神经系统的某些结构与功能，用以解决机器学习、识别、控制、决策等机器智能问题。目前神经元模型有许多种，一个简单的神经元功能模型如图 7.2.2 所示，其中 $x_1, x_2, \cdots, x_n$ 为输入信号，它们对应于这个神经元的树突输入、其他神经元的轴突输出，u_i 为神经元的内部状态，θ_i 为阈值，w_{ji} 为神经元 j 和神经元 i 的连接权值，其正、负分别表示兴奋和抑制，I_i 表示外部输入信号，$f(\cdot)$ 为激活函数，也称转换函数或变换函数，y_i 为输出(外部状态)。对于稳态，这个模型可

以描述为

$$s_i = \sum_{j=1}^{n} w_{ji}x_j + I_i - \theta_i \qquad (7-2-1a)$$

$$u_i = g(s_i) \qquad (7-2-1b)$$

$$y_i = f(u_i) \qquad (7-2-1c)$$

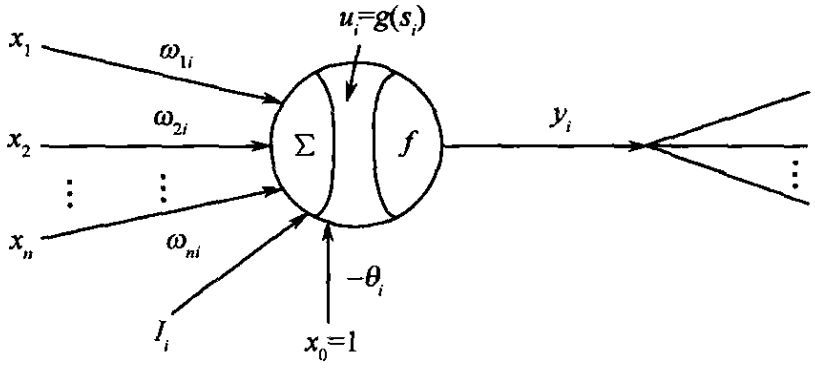


图 7.2.2　神经元功能模型示意图

在多数情况下，$g(\cdot)$是线性函数；当神经元没有内部状态时，可认为 $y_i = u_i$，为表示方便，取 $u_i = s_i$。上式表明，每一神经元的输入为前一级各神经元输出的加权和与外部输入信号 I_i，阈值 $-\theta_i$ 之和，通常将 I_i 与 $-\theta_i$ 合为一个参量，$f(\cdot)$是一个单调上升有界函数。

转换函数主要有如图 7.2.3 所示的几种基本形式。其中：(a)表示输入输出是线性关系；(b)表示输入输出是分段线性关系；(c)表示的阶跃函数；(d)表示的符号函数输出值是二值变量，如果输入也是二值变量，这种神经网络称为离散型网络；(e)和(f)是单调上升的非线性光滑函数，通常取为 Sigmoid 函数。人工神经元的状态 u_i 和输出 y_i 的关系常取非线性转换函数，其中包括径向基函数，径向基函数中广泛使用高斯函数。

2. 人工神经网络典型结构

神经元模型确定之后，神经网络的特性和能力主要取决于网络拓扑结构及学习方法，下面介绍几种神经网络的基本结构。

1)前向网络

前向网络中神经元是分层排列的，每个神经元的输出只馈给前一层的神经元，最下一层为输入层，最上一层为输出层。这两层之间的各

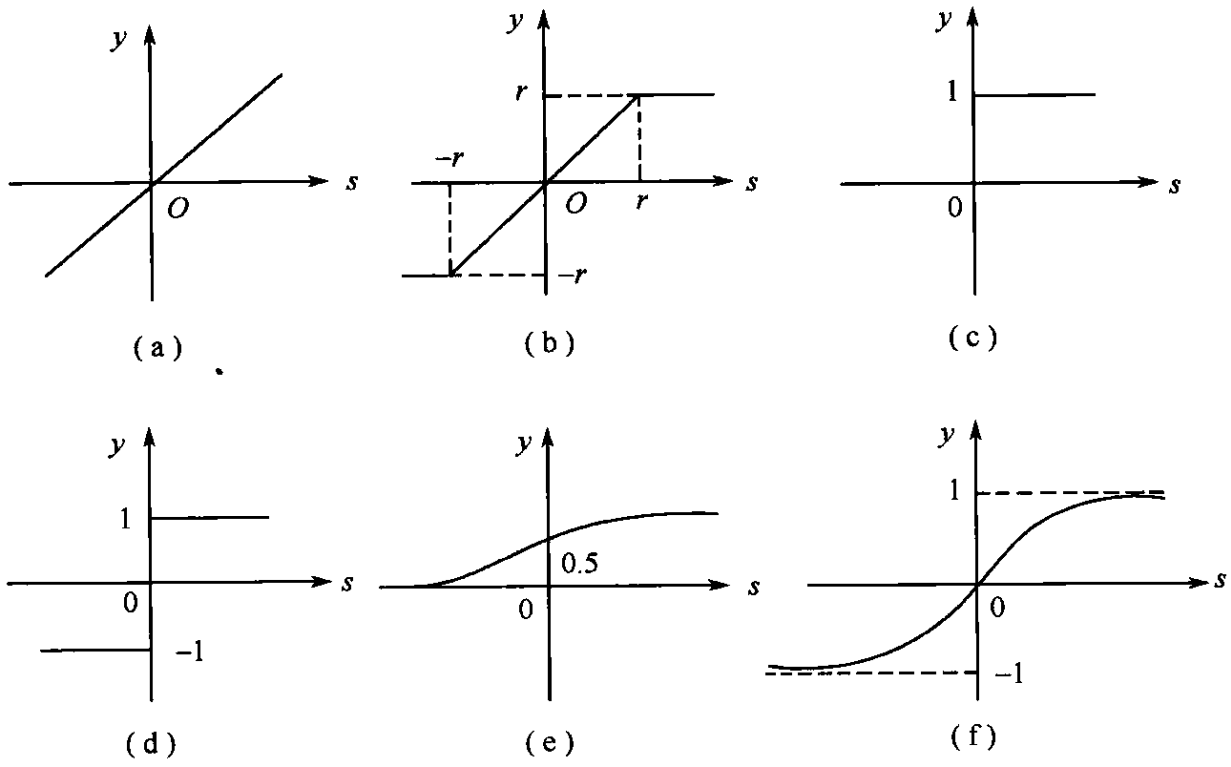


图 7.2.3　几种神经元转换函数

层称为隐含层,它可以只有一层,也可以有多层。此类网络如图 7.2.4(a)所示,感知器就属于这种类型网络。

2)输出向输入反馈的前向网络

这也是前向型网络,只是在输出层上接有反馈回路,将输出信号回馈到输入层,网络结构如图 7.2.4(b)所示。Fukushima(福岛)网络就属于此种类型。

3)层内互连前向网络

在同一层内存在相互连接,实现层内神经元之间的横向兴奋或抑制机理,其网络结构如图 7.2.4(c)所示。很多自组织网络都存在着层内互连结构。

4)全互连反馈网络

这类网络每个神经元的输出都与其他神经元输入相连,图 7.2.4(d)所示为这类网络示意图。Hopfield 网络和一类 Boltzmann 网络属于这类结构。

5)局部互连反馈网络

它的每个神经元的输出只与其周围的神经元相连,Boltzmann 网络也有这类结构。

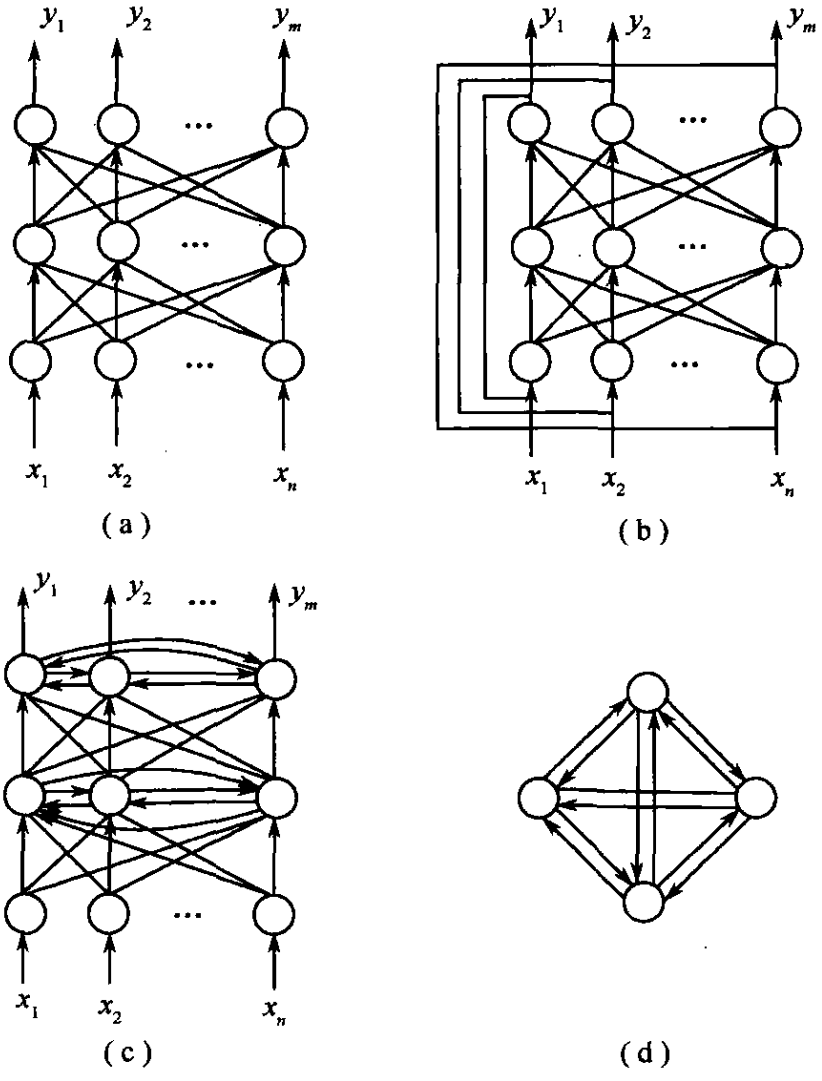


图 7.2.4　几种神经网络的基本结构示意图

(a)前向网络；(b)反馈型前向网络；

(c)层内互连前向网络；(d)全互连反馈网络。

7.2.2　常见的神经网络模型

1. 前向型人工神经网络

这里介绍单层感知器网络，如图 7.2.5 所示，这类网络只含输入层和输出层，由于输入层节点不存在信号变换，通常称为单层感知器网络。设输入模式为 n 维矢量 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)^{\mathrm{T}}$，那么输入层应含 n 个节点。若输入模式集有 m 类模式，一般输出层就有 m 个神经元，神经元的转换取线性阈值函数。若把 m 个模式类分别记为 $\omega_1,\omega_2,\cdots,\omega_m$，则输出层第 j 个神经元对应第 j 个模式类 ω_j。对于两类识别问题，输出层只设一个神经元。输入节点 i 与输出神经元 j 的连接权为 w_{ij}，$i=1$，

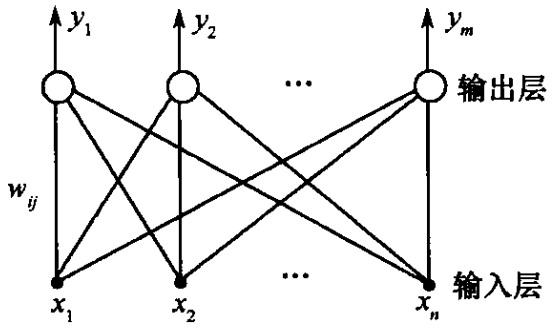


图 7.2.5　单层感知器网络结构示意图

$2,\cdots,n, j=1,2,\cdots,m$，对第 j 个输出神经元，其转换函数为

$$y_j = f\left(\sum_{i=1}^{n} w_{ij}x_i - \theta_j\right) \triangleq f(u_j) \qquad (7-2-2)$$

m 类问题的神经元的输出函数和判决规则定义为

$$y_j = \mathrm{sgn}(u_j) = \begin{cases} +1 \Leftrightarrow \boldsymbol{x} \in \omega_j \\ -1 \Leftrightarrow \boldsymbol{x} \notin \omega_j \end{cases} \quad (1 \leqslant j \leqslant m) \qquad (7-2-3)$$

2. Hopfield 网络

下面讨论反馈型神经网络，在这种网络中每个神经元的输出都反馈到其他神经元的输入，这种网络分为离散型和连续型。其具有联想记忆功能、最优化计算功能，这些功能可以应用于许多领域，如模式识别、人工智能等。反馈神经网络有许多种模型，这里只讨论 Hopfield 网络。

单层全反馈网络如图 7.2.6 所示，网络含有 n 个神经元，每个神经元的输出都与其他神经元的输入相连。若网络第 j 神经元在时刻 t 的状态为 $x_j(t)$，输入为 $s_j(t)$，输出为 $y_j(t)$，那么网络的状态表示为 $\boldsymbol{x}(t) = (x_1(t), x_2(t), \cdots, x_n(t))^{\mathrm{T}}$，网络的输入表示为 $\boldsymbol{s}(t) = (s_1(t), s_2(t), \cdots, s_n(t))^{\mathrm{T}}$，网络的输出表示为 $\boldsymbol{y}(t) = (y_1(t), y_2(t), \cdots, y_n(t))^{\mathrm{T}}$，$i$ 神经元的输出反馈至 j 神经元的输入强度用连结权重 $w_{ij}(i, j = 1, 2, \cdots, n)$ 表示，网络的权值 w_{ij} 可以表示成一个矩阵 $\boldsymbol{W} = (w_{ij})_{n \times n}$，称其为权矩阵，每个神经元 j 通常都有一个阈值 θ_j 或激励 I_j，下式中将神经元的阈值和激励合用 I_j 表示，网络的阈值可以表示成 $\boldsymbol{\theta} = (\theta_1, \theta_2, \cdots, \theta_n)^{\mathrm{T}}$。稳态时，神经元的输入、状态和输出的关系可以分别表示成

$$s_j = \sum_i w_{ij}y_i + I_j \qquad (7-2-4a)$$

$$x_j = g(s_j) \qquad (7-2-4b)$$

$$y_j = f(x_j) \qquad (7-2-4c)$$

如果令 $x_j = s_j, y_j = \mathrm{sgn}(x_j)$，那么网络只有两态，称其为离散型。如果状态方程式(7－2－4b)为微分方程 $x_j = -\mathrm{d}x_j/\mathrm{d}t + s_j$，且式(7－2－4c)中函数 f 为单调上升连续有界函数，那么网络为连续型。

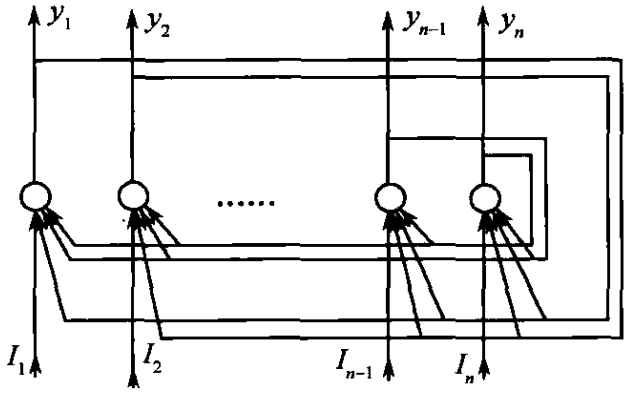


图 7.2.6　单层全反馈网络结构示意图

反馈型网络的输入 $\boldsymbol{x}(t)$ 和输出 $\boldsymbol{y}(t)$ 之间是相互影响和演化的，若经历了有限的时间后，输入和输出的状态都不再改变，则称网络是稳定的，这时的输出状态称为网络的稳定点。系统的稳定点可以视作记忆，系统从一个初态向稳定点的演化过程就是寻找记忆的过程，稳定点的个数称为网络的存储容量，稳定点越多，网络的记忆容量越大。对于某个输出状态，若从其周围一个区域的任意点初始，总会收敛到这个状态，则称其为一个渐进稳定点或吸引子，相应的区域称为稳定域或吸引域。吸引域半径越大，离稳定点较远的点也能演化到稳定点，这相当于联想功能越强，即由少量记忆恢复全部记忆的能力越强。我们希望稳定点在空间分布多而均匀，这可使吸引域较大，从而网络记忆容量大、联想能力强。一个网络对应一个能量函数，能量函数的极小点对应网络的稳定点，因此这种网络也可以用于解决优化问题。这里涉及的 Hopfield 网络有两种运行形式，相应地其有两种不同的应用，即联想记忆和优化计算，这都可以应用到模式识别中。若采用联想记忆方式进行模式识别，通过一定的学习方法，使各训练样本成为网络的稳定状态，一个待识模式输入网络后，网络将按海明距离收敛稳定在与其最近的某一训练样本上。若采用优化计算方式，先将问题表达成能量函数，

由此推出网络结构和参数，然后网络在某种状态下运行，网络的稳定状态对应问题的解。

7.3 句法模式识别

7.3.1 句法模式识别概述

前面的各种模式识别方法中，都是用目标的数值特征对其进行表示的，需要指出的是，对于较复杂的目标，只提取它们的数值特征构成特征矢量往往不能深刻、全面地对其进行描述，这是因为通常这些数值特征不能反映出目标某些重要的结构信息，尤其是细节结构。要反映出目标的这些结构信息，就必须使特征空间的维数十分高，这将给后续的识别工作带来巨大的困难。为能充分刻画出目标的结构信息，可将目标进行层次分解，每个层次分解都产生一些子模式，最后分解成一些基本部分，这些基本部分在某个研究水平上不需要再进行分解，其内部结构信息在这个研究水平上已经不重要，或可以用数值特征来描述它们，这些基本部分实际上也是子模式，在这里称为基元。目标是由这些基元按照目标分解层次关系“装配”而成的。这些基元可以用符号或简单的图案图形来表示，他们在目标中的结构关系可以通过符号串或图以及描述它们的规则反映出来。这种利用目标的结构特征对目标进行描述与识别的方法称为结构模式识别。由于采用了上述的模式描述方式，在形式语言基本理论和方法的基础上形成了结构模式识别的各种技术。

在结构模式识别中，具有某一结构特征的模式类 ω_i 用一个文法 G_i 来表征，这个文法的字母表示子模式和基元，文法规则表示子模式、基元及目标之间的结构关系，该类中的对象可以运用文法 G_i 生成的一个“符号—图”的模式来表征它，这个模式可以是一个符号串、一个树、网或其他的“符号—图”，它是文法 G_i 所生成的语言 $L(G_i)$ 中的一个句子，而这个语言中的任何一个句子都表示了这个模式类中的一个模式，它们之间形成对应关系。

为了进行识别，首先要得到表征各个模式类的文法 $G_i(i=1,2,\cdots,$

c)。与统计模式识别相类似,用已知类别的训练句子进行学习,产生该类或至少是这些句子的文法。这个学习、训练过程称为文法推断。

当得到了表征模式类的文法之后,就可以进行识别了。对于一个待识别的模式 x,对其进行句法分析,当确认它是属于文法 G_i 所生成的语言 $L(G_i)$ 中的一个句子,其由文法 G_i 所生成,或者说是能够被这种文法所接受,那么就判定它属于该文法所表征的 ω_i 类;若它不属于 $L(G_i)$ 中的句子,就判定它不属于 ω_i 类。所以,结构模式识别也称为句法模式识别。一个句法模式识别系统原理框图如图 7.3.1 所示。图 7.3.2 所示为一个目标(图像)分解的示意图。

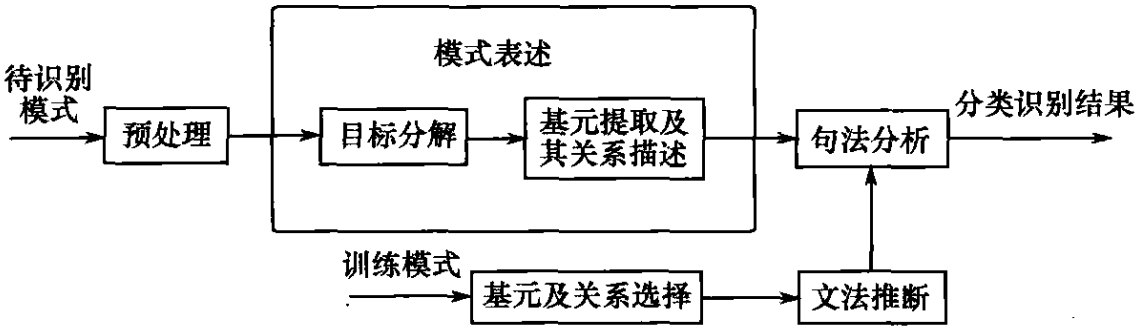


图 7.3.1　句法模式识别系统原理框图

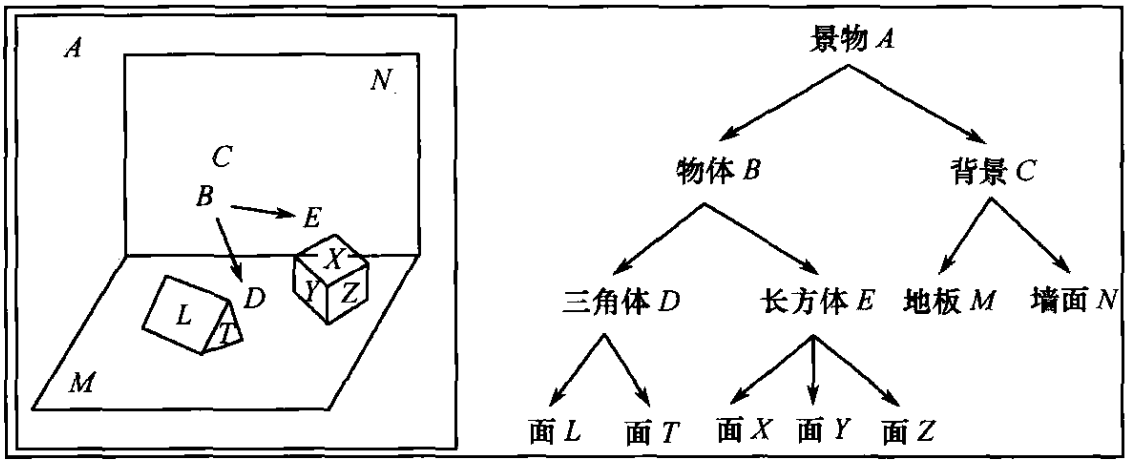


图 7.3.2　目标(图像)分解示意图

7.3.2　形式语言介绍

形式语言的渊源可追溯到 20 世纪 50 年代,在前人工作的基础上,乔姆斯基等人在研究自然语言的过程中提出了文法的数学模型——形式语言。他们原来的目的是开发一种适合于计算机的文法,使它具有描述和理解自然语言的能力。不过,形式语言在其他方面的应用(如

模式识别)要比用在机器自然语言的理解上早得多。众所周知,我们可以用自然语言描述一个对象,还可以用一幅图像表示对象,因此也可以将形式语言应用于模式识别。在模式识别中,如果大量复杂的模式集合能用一组为数不多的简单的模式基元和文法规则来描述,那么就可以用给定的一组文法规则对每一输入模式进行剖析以完成识别,如果模式能为给定的文法规则所接受,就可判它属于该模式类,否则就不属于该模式类。

下面介绍形式语言里的一些基本概念。

1. 字母表和符号串

字母表是以某些符号作为元素的非空有限集。通常以 V 或 Σ 表示。例如字母表

$$V=\{a,b,c\},\qquad V=\{0,1\}$$

符号串是由字母表中符号组成的有限序列。例如:上述字母表的符号串可以是 $a,b,c,aa,ab,ba,\cdots,abca,\cdots;00,01,011,001,111,\cdots$。符号串中,符号的排列顺序是很重要的。不含任何符号的串称为空符或空串,记为 ε。符号串 x 所含符号个数称为该串的长度,记为 $|x|$,显然,$|\varepsilon|=0$。如果 x 和 y 都是符号串,把 y 写在 x 之后就得到联结的符号串 xy,如 $x=ab,y=bc$,则 $xy=abbc,yx=bcab$。显然,$\varepsilon x=x\varepsilon=x$。一个符号串自身的联结可以用幂的形式写出,如:$x^0=\varepsilon,x^1=x,x^2=xx,\cdots,x^n=x^{n-1}x$。

符号串集合 A 和 B 的积定义为:$AB=\{x_iy_j|x_i\in A\wedge y_j\in B\}$;

符号串集合 A 的幂定义为:$A^0=\{\varepsilon\},A^1=A,A^2=AA,\cdots,A^n=A^{n-1}A$;

符号串集合 A 的正闭包为:$A^+=A^1\cup A^2\cup\cdots\cup A^n\cup\cdots$;

符号串集合 A 的闭包为:$A^*=A^0\cup A^1\cup A^2\cup\cdots\cup A^n\cup\cdots=A^0\cup A^+$;

类似的,字母表 V 的幂定义为:$V^0=\{\varepsilon\},V^1=V,V^2=VV,\cdots,V^n=V^{n-1}V$;

字母表 V 的正闭包定义为:$V^+=V^1\cup V^2\cup\cdots\cup V^n\cup\cdots$;

字母表 V 的闭包定义为:$V^*=V^0\cup V^+$。

V^* 表示 V 中字母构成的所有符号串及空串所组成的集合。例如字母表 $V=\{a,b\}$，则有：

$$V^*=\{\varepsilon,a,b,aa,ab,bb,\cdots\}$$

$$V^+=V^*-\varepsilon=\{a,b,aa,ab,bb,\cdots\}$$

2. 短语结构文法

在一种语言中文法是构成句子所必须遵守的规则。由语言的字母表中的字母所组成的串不一定都是该语言的句子，只有当它符合该语言的文法规则时，才能算是该语言的句子。我们把文法 G 定义为四元组，即

$$G=(V_N,V_T,P,S)$$

其中：

V_N 是非终止符有限集。可以由别的符号代替的符号称为非终止符，通常用英语大写字母表示，如：$S,A,B,\cdots$。

V_T 是终止符有限集。不能由别的符号代替的符号称为终止符，通常用英语字母表中起始部分的小写字母表示，如：$a,b,c,\cdots$。

V_N,V_T 之间有关系：

(1) $V_N\cap V_T=\phi$，即 V_N 和 V_T 没有公共字母；

(2) $V_N\cup V_T=V$，即字母表包含非终止符和终止符集合中的所有符号。

终止符组成的符号串通常用英语字母表后部的小写字母表示，如：$v,w,x,\cdots$；终止符和非终止符混合的符号串或任一符号串通常用希腊字母表示，如：$\alpha,\beta,\gamma,\delta,\cdots$。

P 是产生式(重写规则)有限集，它被定义为

$$P=\{\alpha\rightarrow\beta\mid\alpha\in V^+,\beta\in V^*\}$$

这里 α 和 β 都是符号串，α 至少含有一个非终止符。$\alpha\rightarrow\beta$ 表示串 α 可改写成 β，即表示 α 可以用 β 代替。更一般地对于各类文法，“→”也表示“可代替成”。

$S\in V_N$ 称为起始符或根符，具体地说，它可以是一个符号(串)、树或网，符号串、树图、网图等由 S 开始推导产生。它相当于句法分析中树状结构的根。

将形式语言的文法与英语文法作一对比有助于对句法分析思想的理解。考虑句子“The girl walks gracefully”,该句子的树结构分析如图7.3.3所示。

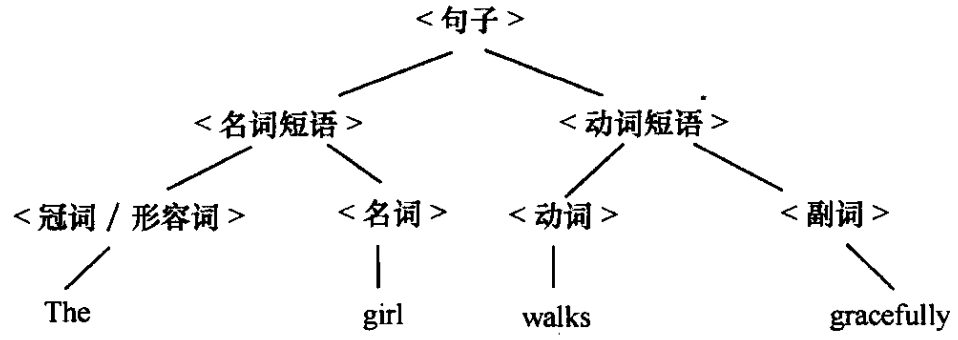


图7.3.3 一个句子的树结构分析

其终止符、非终止符、起始符和产生式规则如下:

V_T = {The, girl, walks, gracefully }

V_N = { <句子>, <名词短语>, <动词短语>, <冠词/形容词>, <名词>, <动词>, <副词> }

S = <句子>

P: <句子> → <名词短语> <动词短语>

<名词短语> → <冠词/形容词> <名词>

<动词短语> → <动词> <副词>

<冠词> → The

<名词> → girl

<动词> → walks

<副词> → gracefully

在重写规则中“< >”叫语法元符号,其中的内容称为语法元。一个简单句子的生成由<句子>开始,反复地把重写规则中箭头左边部分用其右边部分代替,直到不再出现语法元而只是单词为止。图7.3.3称为文法树,文法树的根一定是文法 G 中的起始符,树的叶一定是终止符,树的分支对应产生式。

3. 句型、句子与语言

我们使用 $\eta \underset{G}{\rightarrow} \gamma$ 表示根据文法 G 由一字符串 η 直接导出另一字符

串 γ。例如：$\eta=\omega_1\alpha\omega_2$，$\gamma=\omega_1\beta\omega_2$，$P$ 中有 $\alpha\to\beta$ 的产生式，当使用这个产生式时，便可由 η 直接导出 γ。

若存在一个直接推导序列 $\eta=\gamma_0\underset{G}{\to}\gamma_1\underset{G}{\to}\cdots\underset{G}{\to}\gamma_n=\gamma$，其中 $n>0$，称该推导序列是长度为 n 的推导，可写成 $\eta\overset{+}{\underset{G}{\to}}\gamma$。因为推导也可看成是一种传递关系，于是在形式上，“$\overset{+}{\underset{G}{\to}}$”就类似于关系“$\to$”的传递闭包，“$\overset{+}{\underset{G}{\to}}$”只能是有限推导才有意义。用 $\eta\overset{*}{\underset{G}{\to}}\gamma$ 表示包含 $\eta\overset{+}{\underset{G}{\to}}\gamma$ 和 $\eta=\gamma$，这类似于自反传递闭包。在推导过程中，当所用的文法 G 是明确的，推导下标 G 可以省略。

有一文法 $G=(V_N,V_T,P,S)$，若 $S\overset{*}{\to}\gamma$，γ 是终止符和非终止符组成的符号串，则称 γ 为句型，即句型是由起始符开始推导而得到的由字母表中的符号（包括 V_N,V_T,ε）组成的任意符号串。当 $\gamma\subset V_T^*$ 时，句型就成为句子，即句子一定是由字母表中终止符组成的符号串。一个文法 $G=(V_N,V_T,P,S)$ 所产生的语言 $L(G)$ 是由 S 开始根据 G 推出的所有终止符串（句子）组成的集合，即

$$L(G)=\{x\mid x\in V_T,S\overset{*}{\to}x\}$$

一文法 $G=(V_N,V_T,P,S)$ 有句型 $\omega=xuy$，如果有 $S\overset{*}{\to}xUy$，且 $U\overset{+}{\to}u$，则称 u 为相对于非终止符 U 和句型 ω 的短语。若 $U\to u$，则称 u 为简单短语。

可以看出，从起始符推导一个句子的过程，实际上就是在推导过程中将句型中的一部分不断地用短语来取代的过程，这种文法也称为短语结构文法。

4. 文法的分类

乔姆斯基按照产生式的形式定义了 4 种文法。

1）0 型文法（无约束文法）

这种文法对 P 中产生式没有任何限制。它的产生式形式为 $\alpha\to\beta$，$\alpha\in V^+$，$\beta\in V^*$，这就是说允许 $\beta=\varepsilon$，但不能有 $\alpha=\varepsilon$。

2）1 型文法（上下文有关文法）

它的产生式形式为 $\alpha_1A\alpha_2\to\alpha_1\beta\alpha_2$，其中 $\alpha_1,\alpha_2\in V^*$，$A\in V_N$，$\beta\in$

V^+。这种产生式表明，只有在 α_1 和 α_2 之间时，A 才能被 β 代替，α_1、α_2 称为句型 $\alpha_1 A \alpha_2$ 中对于 A 的上、下文。

3）2 型文法（上下文无关文法）

它的产生式形式为

$$A \rightarrow \beta, \quad A \in V_N, \quad \beta \in V^+$$

这种文法产生式左侧为单变量，而右侧是字符串，这表明用 β 代替 A 与其上下文无关。

4）3 型文法（正则文法）

它的产生式形式为

$$A \rightarrow aB \text{ 或 } A \rightarrow b, A, B \in V_N, a, b \in V_T$$

产生式的特点是规则的右侧要首先含有终止符。

这 4 种文法的包含关系是：（3 形）⊂（2 型）⊂（1 型）⊂（0 型），其中上下文无关文法和正则文法较为常用。

前面介绍的串文法是一维文法，它适用于基元顺序连接的情况，对于较复杂的对象，不同层次的子模式和各个基元之间的关系很复杂，这就需要使用高维文法。高维文法有很多种，包括树文法、网文法、形状文法、随机文法等，这里不进行具体介绍。

7.3.3 句法模式识别的基本内容

1. 模式的描述

为了能够运用句法模式识别技术，具有结构特征的训练模式和待识模式应分解成一些子模式和一些最基本的单元，这些在某个研究水平上不能或不需再分的最小模式元素称为基元。基元应是这个研究水平上最简单的子模式，它本身的结构信息在这个研究水平上已不重要，或者可以用参数对其描述，基元应易于提取与识别，并且能够方便地用子模式与基元、基元与基元的关系表示整个原模式的结构关系。

当使用句法识别时，这些基元对应文法中的终止符或终止图形元素，子模式与基元之间的结构关系及基元之间的结构关系可通过产生式来描述。对于以边界或骨架表征的模式，常以线段（直线段或曲线段）作为基元；对于用区域表征的模式通常以基本图形区域作为基元。

在基元确定之后，下一步应是构造一个文法，以便生成一个语言来描述模式。

模式的描述基本方法包括基于线基元的模式描述和基于区域基元的模式描述。

2. 句法分析

句法分析是句法模式识别的主要手段，主要有两个基本途径：一个途径是检查所给的句子是否由某个文法生成；另一个是看所给的句子是否被句法识别器所接受。前一个途径的基本技术是穷举法，后一个途径的基本技术是自动机分析法。

3. 文法推断

在句法模式识别中，文法 G 用来描述某类模式的结构，并且用文法 G 来对给定的某一模式进行识别。类似于统计模式识别中的学习训练，也可通过对已知类别的句子训练样本集的学习产生描述该类结构的文法 G，这是文法推断问题。对不同类别的文法，如正则文法、上下文无关文法、树文法、随机文法等，有不同的推断方式，具体请参考有关文献。

7.4 信息融合

7.4.1 信息融合概述

随着检测、识别、决策与跟踪等问题越来越复杂，传统的单传感器检测识别系统往往不能满足实际的需求，尤其是在军事领域，于是，科技工作者考虑运用多个同类的传感器，或多种传感器，诸如可见光、红外线、毫米波、超声波及 X 射线等联合起来，同时观测目标、协同工作，这就产生了多传感器系统。多传感器系统，不仅利用多个传感器观测目标，还要对其观测数据进行综合处理得到最终结果。

在模式识别中，多传感器系统也称为组合分类器，其关键技术之一是数据或信息融合（fusion），其目的是将多传感器目标观测信息进行处理、分析与合成，以产生满足特定应用需求的综合信息，最终使系统的性能指标得到较大的提高。目前，军事需求驱动研发的融合技术已

广泛应用于各领域。由于融合的理论与方法十分丰富，这里只能着重以目标检测识别为背景，论述有关决策融合原理与算法。

在多观测器融合系统中，由于采用了多观测器，合理地利用这些数据资源，利用目标在物理上、几何形状、表面纹理以及时空上的信息互补和冗余，按某种准则将数据或信息进行整合，显然可以获得更多的目标信息，可以提高系统的测量精度，增强容错能力，提升稳健性、可靠性，得出更加准确的决策，即提高了系统的性能指标。具体来讲，应用融合技术的意义可概括为以下几点。

(1)提高系统可靠性。当某个观测器失效、否定(由于干扰)或覆盖不到事件或目标时，仍有其他观测器可以提供信息。

(2)扩展了空间和时间的覆盖范围。因为系统利用了多个观测器，在不同地点、从不同视点、在不同时间上观测同一目标，扩大了系统的时空工作空间。

(3)增加对象的信息量。由于采用了在物理、时间、空间上分布的多个(种类)观测器，可以在不同的层面上获得对象更多的互补信息。

(4)提高系统稳定性。由于采用了多观测器，有了系统冗余以及信息冗余，使系统稳定性提高。

(5)增强信息的确定性。由于采用了融合技术，减少了系统输出的随机性、模糊性、不确定性。

(6)提高决策的正确性。这里泛指提高正确决策的概率、空间定位和运动参数估计的准确性。

当然，上述优益的获得不是无偿的，而是以增加系统额外开销、增加冗余性、降低可维护性为代价的，所以在应用中，应从实际出发，权衡融合系统的效益得失，采取适当的设计方案和策略。

融合技术和方法可以应用于模式识别、态势估计、目标定位、航迹估计等。

7.4.2 融合技术层次性及融合系统功能模块和结构

无论是对目标的原始观测，还是对目标观测量的特征提取，以及对目标的分类识别、决策等，所得结果都可以认为是(或含)目标在不同层次上不同表示形态和性质的信息，从信息表征形式的层次上看，可以

分为:数据层次、特征层次和决策层次。在不同层次,信息的特征是不同的。较多情况下,信息融合是在同一个层次上进行的。系统可以只进行一个层次的融合,也可以进行由底层到顶层的多源多层融合。在不同的问题领域、不同的层次上往往采用不同的融合技术和方法。

1. 融合技术的层次性

1)数据层次融合

这一层次的融合通常要对同一目标的多个或多种物理观测器测得的原始数据进行配准、关联合成,以克服单一观测器在物理(如光谱、运动参数)、空间等方面的欠缺或局限性,使有关目标的信息更趋完备。这类融合主要应用于图象数据和目标运动估计。

2)特征层次融合

这个层次的融合是指对表征目标的状态或特征的数据进行配准和关联,增加描述目标状态或特征的维数,获得联合状态或特征矢量,使有关目标的知识更趋准确和完备,主要用于目标的空间位置、运动参数和几何形状特征的数据融合。

3)决策层次融合

用多个观测器观测同一个目标,每个观测器在本地对观测量进行处理,并作出初步的决策,然后将这些本地决策融合产生最终的决策结果,这就是决策层次的融合。决策层次融合主要采用贝叶斯决策、D-S 证据理论、模糊推理以及人工智能等方法。

2. 融合系统的功能模块

一个融合系统包括以下的主要功能模块。

1)观测器管理

这个模块的功能是对各观测器任务的分配、工作模式的确定、观测区域的划分及工作顺序的控制等进行协调管理。

2)数据管理

将多个观测器输出统一到一个公共的时空参考系中,并将同一层次的各类信息数据化为同一种表示形式,在这里进行数据格式配准、时空坐标配准,并对表示同一目标的数据进行关联以及数据库管理。

3)信息优化融合

采用统计的、模糊的、人工智能的及其他的理论和技术,对已有的

数据、信息进行关联，并进而采用适当的算法进行最优化的评判、推理、识别和决策。

3. 融合系统的结构

根据多观测器系统中观测、决策和融合的关系，可以将多观测器融合系统分为集中式和分布式两种基本结构。

1）集中式结构

将各个观测器对目标进行观测的原始数据全部传送到融合中心（Fusion Center，FC），由融合中心完成对数据的各种处理，然后作出最终决策（或估计），这种结构称为集中式结构，如图 7.4.1 所示。

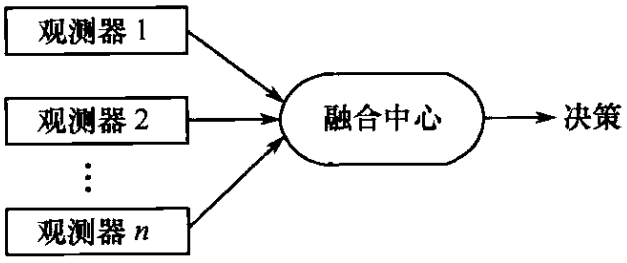


图 7.4.1　集中式多观测器融合系统

由于融合中心获得了尽可能多的信息，所以这种方案的检测决策性能是最佳的。但这种结构对传输信道的带宽、融合中心的存储和运算能力等都有较高的要求，这种结构在比较复杂的应用场合中较少被采用。

2）分布式结构

在保证一定性能的前提下，可以在每个观测器处由子决策器根据观测值作出本地决策，此时的观测器和子决策器合起来称为一个检测器。这种系统作出最终决策不是直接依赖于观测器的原始观测数据，而是基于各检测器的决策和其他有关信息。这种结构称为分布式结构，它又可以分为并行结构、串行结构和网络结构。这里重点对并行结构进行研究。

并行结构如图 7.4.2 所示。每个检测器基于自己的观测作出本地决策，所有检测器的本地决策传送至融合中心进行融合，得到最终决策。这里的融合是决策融合。

显然，并行结构对信道带宽与融合中心处理能力的要求降低了。

很多模式识别方法可以用于图 7.4.2 的决策融合系统中，如最小

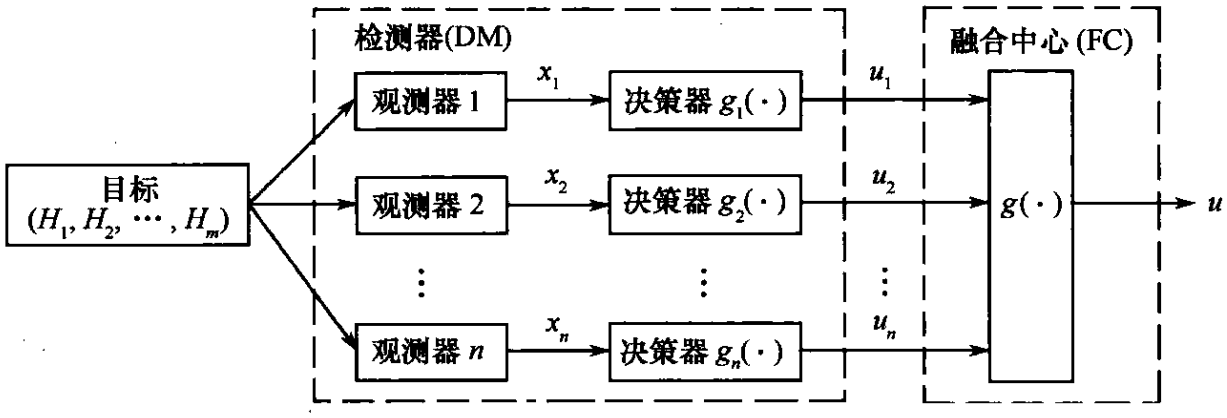


图 7.4.2　并行分布式检测决策融合系统

损失准备判决、N－P 准则，D－S 证据理论。此外，多观测器的相关性也影响决策的进行，观测器相关与不相关将对决策有很大影响。

4. 融合算法

1）抽象层分类器融合方法

抽象层融合方法的实现过程如图 7.4.3 所示。各个基本分类器 $C_m(m=1,2,\cdots,M)$ 的输入选自输入样本的特征属性。它们可能为输入样本的全部特征属性，也可能为输入样本的特征属性的一部分。基

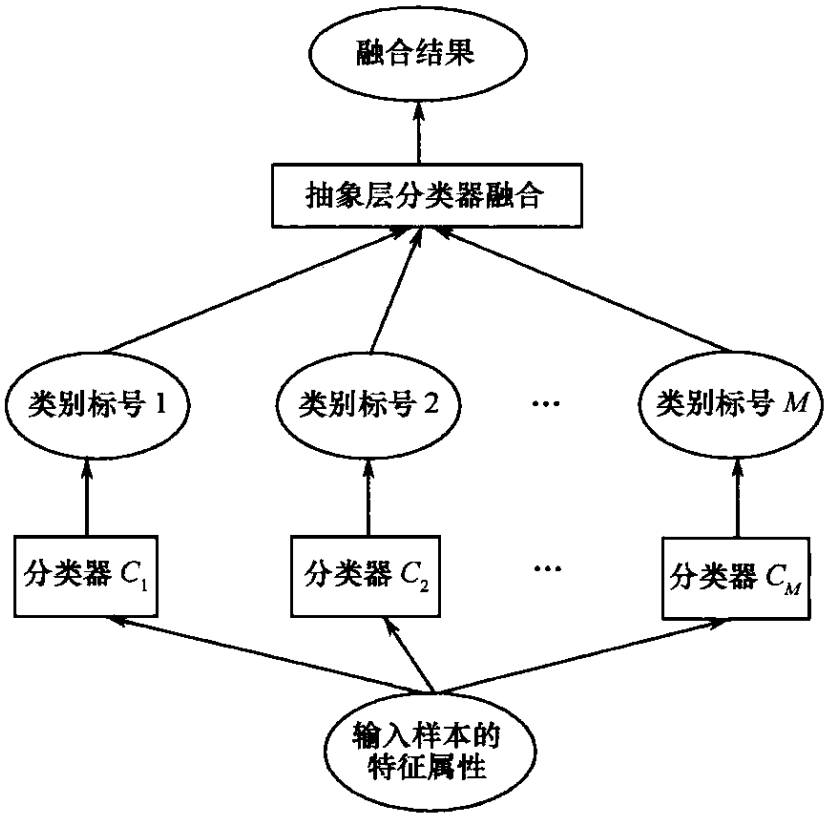


图 7.4.3　抽象层分类器融合框架

本分类器输出的信息为类别标号 $O_m \in \{\omega_1, \omega_2, \cdots, \omega_L\}$。融合算法综合根据各个基本分类器输出的类别标号确定最终的分类结果。典型的抽象层融合算法有投票法、朴素贝叶斯法、行为知识空间法等，下面分别加以介绍。

(1)投票法。投票法是最简单的分类器组合方法。在融合过程中各个基本分类器对其所支持的模式类进行投票，最后以得票最多的模式类作为融合后的输出结果。

投票法分为两类：一类假定各个基本分类器都平等，在投票过程中对它们都一视同仁。另一类假定各个基本分类器的影响不同，对它们的输出给以不同的权系数。

投票法很简单，在许多应用中采用，目前已经被成功的应用在字符识别，身份验证等很多领域中。

(2)朴素贝叶斯法。朴素贝叶斯法采用混淆矩阵来统计各个基本分类器的性能。对于每个基本分类器 $C_m(m=1,2,\cdots,M)$，其混淆矩阵为一 $L \times L$ 矩阵 $\boldsymbol{CM}^m$。

$$\boldsymbol{CM}^m = \begin{bmatrix} cm_{1,1}^m & cm_{1,2}^m & \cdots & cm_{1,L}^m \\ cm_{2,1}^m & cm_{2,2}^m & \cdots & cm_{2,L}^m \\ \vdots & \vdots & \cdots & \vdots \\ cm_{L,1}^m & cm_{L,2}^m & \cdots & cm_{L,L}^m \end{bmatrix}$$

该矩阵的第(l,q)项 $cm_{l,q}^m$ 表示训练集中真实类别为 ω_l，而被基本分类器 C_m 分类为 ω_q 的样本数。根据混淆矩阵可以计算出一个新的 $L \times L$ 矩阵 $\boldsymbol{LM}^m$，其形式为

$$\boldsymbol{LM}^m = \begin{bmatrix} lm_{1,1}^m & lm_{1,2}^m & \cdots & lm_{1,L}^m \\ lm_{2,1}^m & lm_{2,2}^m & \cdots & lm_{2,L}^m \\ \vdots & \vdots & \cdots & \vdots \\ lm_{L,1}^m & lm_{L,2}^m & \cdots & lm_{L,L}^m \end{bmatrix}$$

其中的第(l,q)项 $lm_{l,q}^m$ 表示训练集中属于模式类 ω_l 的样本被分类为 ω_q 的概率，通过下式计算：

$$lm_{l,q}^{m} = P(O_m = \omega_q \mid \omega_l) = \frac{cm_{l,q}^{m}}{\sum_{q=1}^{M} cm_{l,q}^{m}}$$

这里 O_m 表示基本分类器 C_m 输出的类别，$P(O_m = \omega_q \mid \omega_l)$ 表示当样本属于模式类 ω_l 时，$O_m = \omega_q$ 的概率。

假设各个基本分类器之间是独立关系，对于任意输入样本 x，各个基本分类器的输出结果为 $O_1 = \hat{O}_1, O_2 = \hat{O}_2, \cdots, O_M = \hat{O}_M$，则有

$$P(O_1 = \hat{O}_1, O_2 = \hat{O}_2, \cdots, O_M = \hat{O}_M \mid \omega_l) = \prod_{m=1}^{M} P(O_m = \hat{O}_m \mid \omega_l) = \prod_{m=1}^{M} lm_{l,\hat{O}_m}^{m}$$

$$P(\omega_l \mid O_1 = \hat{O}_1, O_2 = \hat{O}_2, \cdots, O_M = \hat{O}_M) = \frac{P(\omega_l) \prod_{m=1}^{M} lm_{l,\hat{O}_m}^{m}}{P(O_1 = \hat{O}_1, O_2 = \hat{O}_2, \cdots, O_M = \hat{O}_M)}$$

这里 $P(\omega_l)$ 表示模式类 ω_l 的先验概率。当 $P(\omega_l)$ 不可知时，可以假定各个模式类的先验概率相等。此外，分母 $P(O_1 = \hat{O}_1, O_2 = \hat{O}_2, \cdots, O_M = \hat{O}_M)$ 也与模式类 ω_l 无关，从而在分类器融合规则中可以用下式计算输入样本 x 属于每个模式类的置信水平 $S_l(x)$ $(l = 1, 2, \cdots, L)$：

$$S_l(x) = \prod_{m=1}^{M} lm_{l,\hat{O}_m}^{m} (l = 1, 2, \cdots, L)$$

在朴素贝叶斯方法的推导过程中假定各个基本分类器之间是独立关系，实际问题往往难以满足这一条件。但是一些研究成果表明，当分类器之间存在相关性时，朴素贝叶斯方法也能取得较好的分类成果。

2）度量层分类器融合方法

度量层分类器融合方法的实现过程如图 7.4.4 所示。在这类方法中，各个基本分类器输出样本属于各个模式类的置信水平，融合算法基于全部分类置信水平得到最终的分类结果。度量层分类器融合方法非常多。融合算子指一类简单的分类器融合方法，其融合规则可以通过

一种代数运算来表示。下面介绍度量层 4 种基本的融合算子:平均规则、乘积规则、最大规则、最小规则。

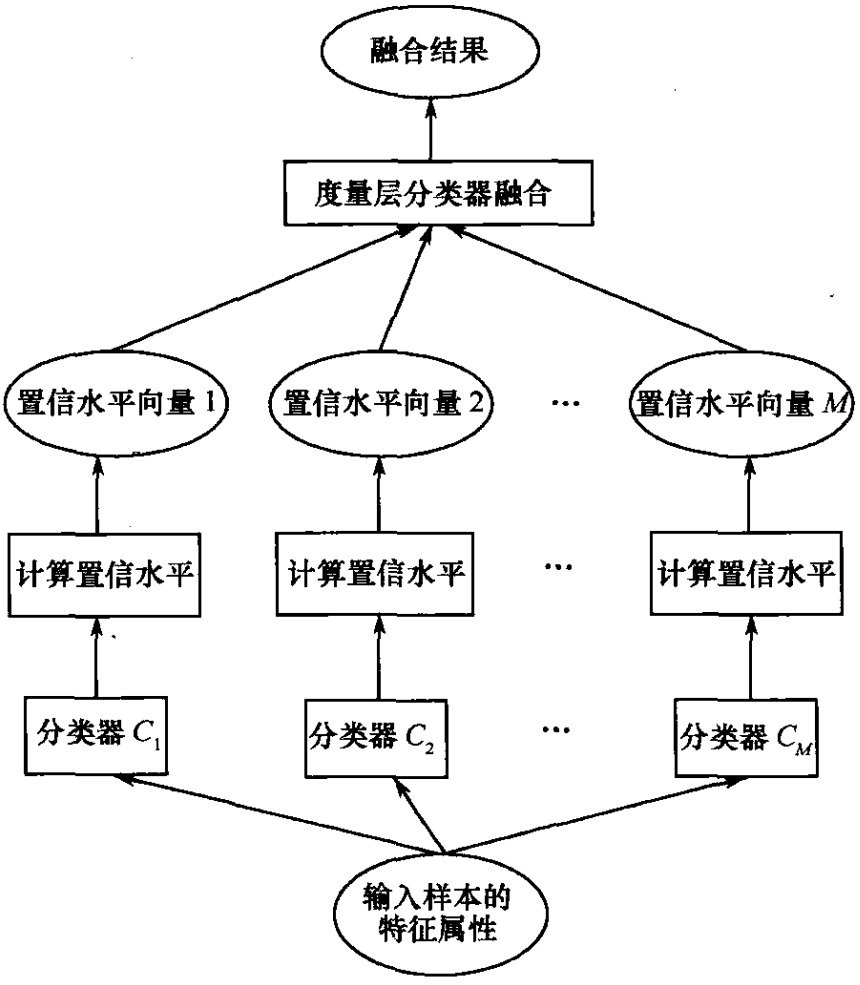


图 7.4.4　度量层分类器融合框架

下述的 $d_l^m(x)$ 表示基本分类器 C_m 输出的样本 x 属于模式类 ω_l 的置信水平,$S_l(x)$ 为融合算法计算出的样本 x 属于每一个模式类 ω_l 的总置信水平。

(1)平均规则。在这种方法中对于每一模式类,将各个基本分类器输出置信水平的平均值作为样本属于该模式类的总置信水平,即

$$S_l(x) = \frac{1}{M}\sum_{m=1}^{M} d_l^m(x)$$

(2)乘积规则。对于每一模式类,将各个基本分类器输出置信水平的乘积作为样本属于该模式类的总置信水平,即

$$S_l(x) = \prod_{m=1}^{M} d_l^m(x)$$

(3)最大规则。对于每一模式类,选取各个基本分类器输出置信水平的最大值作为样本属于它的总置信水平,即

$$S_l(x) = \max\{d_l^1(x), d_l^2(x), \cdots, d_l^M(x)\}$$

(4)最小规则。对于每一模式类,选取各个基本分类器输出置信水平的最小值作为样本属于它的总置信水平,即

$$S_l(x) = \min\{d_l^1(x), d_l^2(x), \cdots, d_l^M(x)\}$$

这些式子数学表达简洁,实现简单,容易从理论分析其性能。但是它们都不能利用训练样本,当基本分类器之间相关时难以有效地提高分类正确率。

7.5 树分类器

树分类器又称多级分类器,或简称决策树,它是模式分类的一种有效方法。在相当大的应用范围内,树分类器比其他很多分类器都能产生更精确的分类结果。树分类器采用分层次策略把一个复杂的两类或多类问题转化为一系列不同层次中的若干个简单问题,而不是用一种算法或一个决策规则把两类或多类模式一次分开。树分类器既适用于数值属性的对象分类,又适用于语义属性的对象分类。本章属性和特征通常表示一个含义。图 7.5.1 所示为一个关于某些水果分类识别的决策树示例。

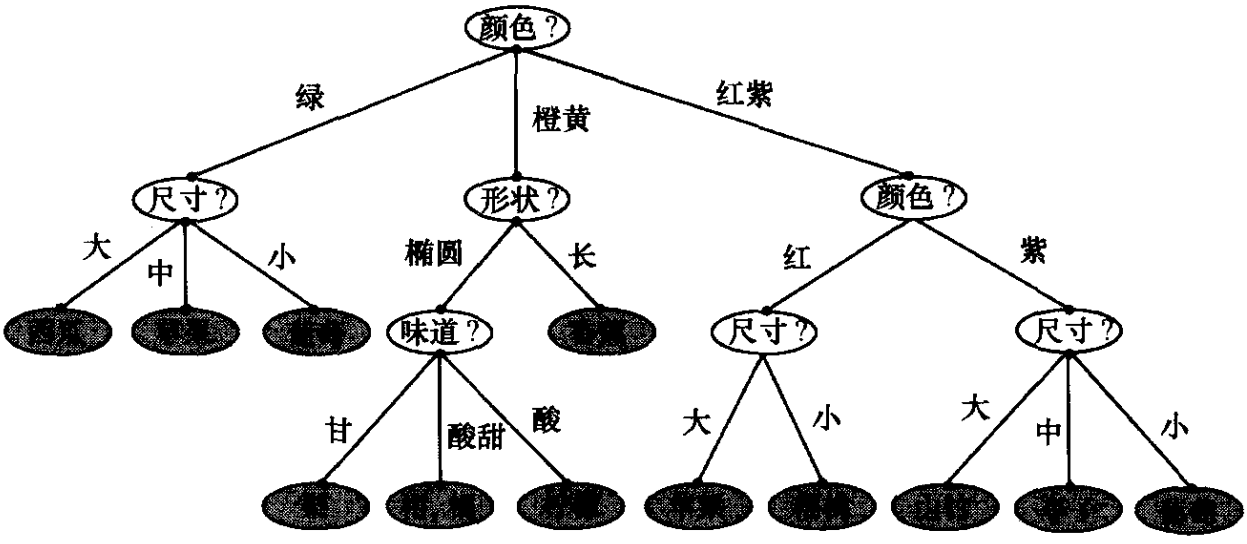


图 7.5.1 某些水果分类识别的决策树示例

7.5.1 树分类器原理及设计原则

可以用一个树状结构表示多级分类器的决策过程，这个树状结构就是决策树，它由一个根节点，一组中间节点和一组叶节点及节点间相连的分支组成，根节点和中间节点用分支连接它们的子节点。一个决策树对应一个决策方案，决策树中，每个非叶节点都有一个相应的决策规则，从而给出模式特征空间的中间分划，因即使具有某个或某些相同的属性，也可能是不同类的样本，故还要根据其他决策规则进行分划，这在决策树中体现为分支，最后分划将特征空间分成若干子区域，在每个子区域中，只含一类样本，或含几类样本但某一类样本占绝大多数；而中间分划将特征(子)空间分成较少的区域，每个区域混杂着几类样本，没有哪类样本占绝对优势。可知，决策树的任一节点都对应一个区域，从而任一节点都对应类别，中间节点对应几个类别，叶节点对应一个类别。树的各节点的分支子节点是互斥的，且各子节点覆盖该节点决策规则所涉及的属性空间。决策树的节点用类别符号来标记，不同的叶节点可能有相同的类别标记，即几个叶节点都对应同一类。父节点的分支表示该节点对应的类别向子节点的指派细分。一个节点向下的分支数称为分支系数或分支率(Branching Ratio)。图 7.5.2 所示为一个决策树决策过程，一个节点处的标记为该节点所对应区域包含的类域，即相应的类别，各节点处的 d_i 表示相应的决策，根据该决策规则将这个节点所对应的模式分派到它的子节点所代表的类别中。通常用 T 表示一个决策树。

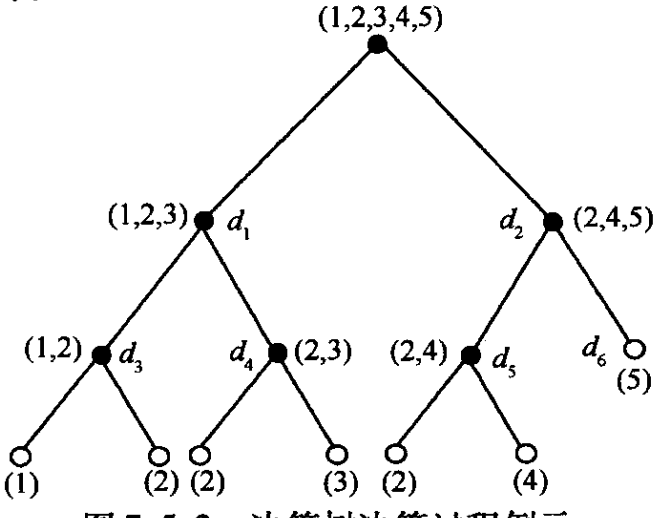


图 7.5.2 决策树决策过程例示

在各种决策树中，最简单的形式是二分树，在二分树中，除叶节点外，树的每个节点都仅有两个分支，即一个父节点只有两个子节点。二分树可以将一个复杂的两类问题或多类问题化为多级两类问题，在每个节点处都将该节点对应的区域或样本集分成两部分，力求每一部分只含有一类样本。当一个节点对应多个类别样本时就要多层次地把它对应的区域或样本集分成两部分或两个子集，直至每个节点对应的区域或子集只含同一类样本，或一类样本达到某个优势为止。

由上述讨论可知，设计一个决策树应主要解决下面几个问题。

(1)选择一个适当的树的结构。

①节点处分支数的确定；

②某节点是否是叶节点。

(2)确定在每个中间节点和根节点要使用的特征。

(3)确定每个非叶节点处的决策规则。

除此之外还有：特征缺损的解决方案，树的复杂度估计等。上述3个问题是关联的、相互影响的，因此，在实际上可以首先考虑某一个问题，在此基础上确定其他两个问题。还可采用一些约束而使可能选择的树结构种类减少，如每个节点只选用一个特征，只考虑二分树等。

一个好的决策树最重要的是有小的误判代价(损失)。影响决策树的因素较多，难于建立误判代价与树结构的关系，因此在设计时，可以逐点最优、局部最优展开，最后生成决策树，也可以采用全局最优的设计方法。在全局最优设计中通常分为两类：一类是树结构的最优化设计，通常采用的准则是：①最小化全树的节点数目，或②最小化从根节点到叶节点的最大路径长度，或③最小化从根节点到叶节点的平均路径长度。另一类方法是考虑误判代价最小化。

下面给出树分类器的设计原则和设计方法。可以发现以前学习过的知识对于解决具体问题是有重要的参照价值的。

7.5.2 树分类器关键技术

1. 分支数目

节点处的判决将使其所对应的区域或样本集分划为若干个子集，节点处的判决将产生后续分支。一个节点的分支系数或分支率通常用

B 表示。对于多类问题，在简单的情况下，尽量分支数多些，这样可以减少从根节点到叶节点的最大路径长度，或平均路径长度，这个问题显然与所使用的特征和规则有关。最简单的和常用的是二分支，其产生二分树，二分树结构可使训练过程简便。

2. 节点处的特征或特征子集的选择

与大多数模式识别技术一样，选用好的特征可以提高树分类器的效率和识别率，对于数值属性的特征矢量来说，可以在构造树之前应用第 6 章所讨论的有关特征提取与选取的方法以及其他的方法进行处理。

3. 叶节点的确定

在树的生长过程中，如果直到所有的节点都达到最小的不纯度为止（例如，一个能够实现的最极端的情况是，所有的叶节点每个只对应一个训练模式，此时的不纯度为 0），那么可能会出现“过拟合”，这将导致对有较大畸变或噪声扰变的模式推广普适性不可能很好；相反，如果分支停止过早，那么对训练模式的知识就利用不够，训练不够将出现“欠拟合”，这将导致分类性能较差。叶节点的合理确定可以提高决策树的识别率和推广普适能力。

利用不纯度和代价函数可以确定一个节点是否应该成为叶节点。这里存在两种方案：一种方案是由顶到底的方法，在由根节点向下生成树的过程中，在每个当前节点处，根据某种准则和方法确定分支是否停止，这类方法称为分支停止法；另一种方案是由底到顶的方法，首先要充分生成树，直到叶节点都有最小的不纯度为止，然后回查，按某种准则进行剪枝，当某些子树剪掉后，这些子树的根节点就成为最后的决策树的叶结点，后一种方法称为剪枝法。

此外还有决策规则的选取、属性缺损问题及计算复杂度等需要考虑的问题，这里不进行赘述，请参考相关文献。

7.5.3 决策树生成算法

决策树的生成算法是一种递归算法，目前，决策树的生成算法有许多方法，上面讨论的基本技术可以嵌入到几乎所有的决策树中。许多算法是在 CLS 算法基础上扩展和改进而来的。

1. CLS 算法

1966 年 Hunt 等人研制出了一个概念学习系统(Concept Learning System, CLS),其可以学习单个概念,并用学到的概念进行分类。实际上,该系统的 CLS 算法是早期的决策树学习算法。

CLS 生成算法如下:

设 X 是全体训练样本的集合,

(1)如果 X 中所有样本均为正例,则生成一个 YES 节点,并终止;如果 X 中所有样本均为反例,则生成一个 NO 节点并终止。否则转至(2)。

(2)根据某种启发式策略选择一个属性 A,设 A 取值为 $a_1, a_2, \cdots, a_n$,并生成新的节点,将 X 中的样本根据其属性 A 的值依照 $a_1, a_2, \cdots, a_n$ 加以分划,生成 n 个子集,记为:

$$X_1, X_2, \cdots, X_n$$

(3)对每个子集递归地运行该算法。

CLS 生成算法只针对两类问题,该算法没有指明属性选择的策略。可以将 CLS 算法扩充应用于多类问题,并且属性选择策略可以任意设定。在 CLS 算法基础上形成了诸多决策树生成算法。

2. 经典 ID3 算法

经典 ID3 算法是 1979 年由 J. R. Quinlan 提出的,它的核心算法仍然是 CLS,它采用信息熵做为属性选择的度量,每次都选择信息增益最大的那个属性,使分类的效率和质量大大提高。

将决策树 T 看成一个由多个信源组成的信息系统,树的每一个叶节点对应一个信源。信息熵在信息论中是对信源不确定性的一种度量,称为平均信息量。将信息熵的概念用于分类问题,可产生如下的概念。

设样本集 X 由 c 类样本组成,类别分别为 $\omega_1, \omega_2, \cdots, \omega_c$,各类的概率分别为 $P_1, P_2, \cdots, P_c$,该样本集 X 的分类信息熵为

$$H(X) = -\sum_{i=1}^{c} P_i \log_2 P_i \qquad (7-5-1)$$

在分类问题中,用信息熵来评价属性 A 对样本集 X 分类所做出的

贡献。设属性 A 有 n 个不同取值，根据属性的 n 个不同取值将样本集 X 划分为 n 个集合 $X_1, X_2, \cdots, X_n$，令 $p_i = \frac{|X_i|}{|X|}(i = 1,2,\cdots,n)$，$p_{ij} = \frac{|X_i \cap \omega_j|}{|X_i|}(j = 1,2,\cdots,c)$，$|Z|$ 表示样本集 Z 中样本个数，用属性 A 将样本集 X 分划之后，样本集 X 的信息熵为

$$H(X,A) = -\sum_{i=1}^{n} p_i \sum_{j=1}^{c} p_{ij} \log_2 p_{ij} = \sum_{i=1}^{n} p_i H(X_i) \quad (7-5-2)$$

从属性 A 得到的信息量，即样本集 X 的分类信息熵的减小量（熵差）为 $\text{gain}(X,A)$：

$$\text{gain}(X,A) = H(X) - H(X,A) \quad (7-5-3)$$

$\text{gain}(X,A)$ 反映了属性 A 对分类所提供的信息量。

设样本集为 X，特征集为 Q，令决策树 T 的根节点为 (X,Q)，叶节点为 $(X_i,Q_i)(i = 1,2,\cdots,n)$，叶节点 (X_i,Q_i) 的信息熵为该节点处样本集 X_i 的信息熵 $H(X_i)$，决策树 T 的信息熵 $H(T)$ 为各叶节点处信息熵的加权和，$H(T) = \sum_{i=1}^{n} \frac{|X_i|}{|X|} H(X_i)$。决策树 T 的构造是一个递归的过程，假设算法递归到叶节点 (X_j,Q_j) 处，设属性 $A(A \in \mathbf{Q}_j)$ 将叶节点 (X_j,Q_j) 分裂生成 m 个新叶节点 $(X'_1, Q_j - \{A\}), (X'_2, Q_j - \{A\}), \cdots, (X'_m, Q_j - \{A\})$，为表述方便，树生长后原来没有生长的各叶节点对应的样本集 X_i 记作 X'_i，即 $X'_i = X_i$，$i \neq j$。此时，原决策树 T 生长成新的决策树 T'。考察决策树 T' 的信息熵 $H(T')$：

$$\begin{aligned} H(T') &= \sum_{i=1}^{n+m-1} \frac{|X'_i|}{|X|} H(X'_i) \\ &= \sum_{i=1}^{n} \frac{|X_i|}{|X|} H(X_i) - \frac{|X_j|}{|X|} H(X_j) + \sum_{i=1}^{m} \frac{|X'_i|}{|X|} H(X'_i) \\ &= H(T) - \frac{|X_j|}{|X|}[H(X_j) - H(X_j,A)] \\ &= H(T) - \frac{|X_j|}{|X|} \text{gain}(X_j,A) \end{aligned} \quad (7-5-4)$$

从以上 $H(T')$ 与 $H(T)$ 的关系式可以看出，在树生长的过程中，树的不确定性在不断减小，逐渐由不确定性系统向确定性系统演变。因此，在节点 (X_j, Q_j) 处分裂生长时，我们就要在所有可能演变生成的新决策树空间中，选择具有最小信息熵的决策树 T'，由式(7-5-4)可知，就是在属性集 Q_j 中选择 $\text{gain}(X_j, A)$ 最大的那个属性。$\text{gain}(X_j, A)$ 与 $H(X_j, A)$ 具有如下关系：

$$\text{gain}(X_j, A) = H(X_j) - H(X_j, A) \qquad (7-5-5)$$

所以就是选择 $H(X_j, A)$ 最小的那个属性。式(7-5-3)、式(7-5-5)是经典 ID3 算法选择属性 A 的准则。

经典 ID3 算法如下：

设 X 是全体训练样本的集合，Q 是全体属性集合。

(1)创建根节点 (X, Q)。

(2)若节点 (X, Q) 中所有的样本都为同一类，则标记为此类，结束；若 (X, Q) 中的属性集 Q 为空或某一类的样本占绝大多数，则标记该样本集中个数最多的那一类，结束；否则在 Q 中选取使 $H(X, A)$ 最小的那个属性 A。

(3)根据属性 A 的不同取值将 X 分划成 $m(m>1)$ 个不相交的子集 $X_i(1 \leqslant i \leqslant m)$，则从 (X, Q) 长出 m 个分支，每个分支代表 A 的一个不同取值，从而形成 m 个新的叶节点 $(X_i, Q-\{A\})(i=1, \cdots, m)$。

(4)递归地对每个叶节点进行该算法。

$\text{gain}(X_i, A)$ 可理解为算法由于用属性 A 分类所获得的信息增益(Information Gain)，经典 ID3 算法每一步都从待选的属性集中找出 $\text{gain}(X_i, A)$ 值最大的那个属性。它确保建立最简单、平均深度较小的决策树。

3. C4.5 学习算法

C4.5 学习算法是 ID3 算法的改进。ID3 算法只能处理属性值为离散值的属性，通常是二值属性，同时 ID3 算法没有考虑属性值缺损的情况。C4.5 算法可以处理连续值属性、属性值缺损，以及决策树减枝、规则生成等问题。

正如上一小节所介绍，在 ID3 中使用了信息增益 $\text{gain}(X, A)$。由

信息增益的定义可知，当一个属性可能的取值越多时，信息增益就越大。例如，当一个属性 X，每个记录在其上的取值均不相同，那么它的 info(X,A) 就为 0，为此 gain(X,A) 即为最大值。因此为了弥补这一点，Quinlan 提出了用增益率来替换增益

$$\text{gainRatio}(X,A)=\frac{\text{gain}(X,A)}{\text{SplitInfo}(X,A)}$$

其中 SplitInfo(X,A) 是按照属性 X 的值划分 A 所获得的信息，其计算公式如下：

$$\text{SplitInfo}(X,A)=I(|A_1|/|A|,|A_2|/|A|,\cdots,|A_k|/|A|)$$

其中 $A_1,A_2,\cdots,A_n$ 是按照属性 X 值划分的各个不相交子树集。

C4.5 可以处理连续值属性。例如，A 为一个连续值属性，首先检查该训练集中该属性的所有取值，然后将其按升序排列为 $A_1,A_2,\cdots,A_m$。对于每一个 $A_j,j=1,2,\cdots,m$，将记录划分成两类，一类是其各记录属性 A 的值均小于等于 A_j，另一类是其记录属性 A 的值均大于 A_j，对于每个划分，计算这个划分的增益或增益率，然后选择增益或增益率最大的划分。

C4.5 在构造决策树时，对于含有缺损值的属性，通常只考虑那些属性值有定义的记录，以此来估计该属性的增益或增益率。在使用决策树时，可以通过估计一个记录缺损值属性的不同取值的概率来分类一个含有缺损值的记录。

C4.5 采用的决策树减枝策略如下：决策树是根据训练集构造的，因此它能正确处理训练集中大部分记录。事实上，这样可能导致决策树非常复杂，决策树不平衡，个别分枝很长。决策树的剪枝就是用单个叶结点来替换整个子树。替换策略是当子树的期望错误率大于单个叶子的期望错误率时，就可以用叶子来替换子树。如图 7.5.3 所示这棵简单的子树是根据训练集中一个成功的红色记录和两个蓝色的失败记录构造而得，而在测试集中我们发现有三个红色的失败记录和一个蓝色的成功记录，这时我们可以考虑用一个标记为失败的结点来替换这个子树，作了这个替换后，错误分类的记录个数由 5 个减为 2 个。

规则可以由决策树方便的生成。从决策树的根结点到叶结点的每

一条路径可以生成一条规则，规则的左边可以根据结点标记和弧标记得到。最后，将结果规则集简化。

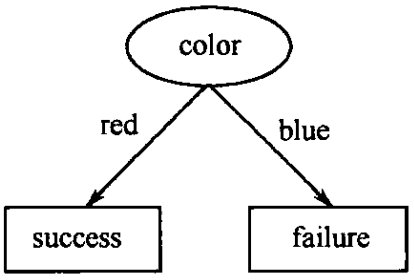


图 7.5.3　简单的决策树示例

习　题

7.1　论域 $X=[0,24]$ 表示时间（小时），试根据你的经验绘出表示“拂晓”、“中午”、“傍晚”3 个模糊概念的模糊集隶属函数。

7.2　设有上下文无关文法 $G=(V_N,V_T,P,S)$，其中 $V_N=\{S\}$，$V_T=\{a,b\}$，$P:S\to aS,S\to b$。试导出该文法生成语言 $L(G)=\{a^nb\mid n\geqslant 0\}$。给出终止符 a,b 一些具体的基元形式，看句子代表什么模式。

7.3　设有上下文无关文法 $G=(V_N,V_T,P,S)$，其中 $V_N=\{S\}$，$V_T=\{a,b\}$，

$P:S\to ab$

$S\to aSb$

验证其生成的字符串形式为

$$L(G)=\{a^nb^n\mid n\geqslant 1\}。$$

7.4　设无约束文法 $G=(V_N,V_T,P,S)$，其中

$$V_N=\{A,B,S\},\ V_T=\{a,b,c\}$$

$P:S\to aAbc$

$Ab\to bA$

$Ac\to Bbcc$

$bB\to Bb$

$aB\to aaA$

$aB \rightarrow \varepsilon$

验证其生成的句子形式为

$$L(G) = \{a^n b^{n+2} c^{n+2} \mid n \geqslant 0\}$$

其中 n 指字符串的长度。

7.5 试指出采用融合技术的优点。

7.6 试指出融合系统的功能模块与结构。

参 考 文 献

[1] 程民德,等. 图象识别导论. 上海:上海科学技术出版社,1983.

[2] 边肇祺,等. 模式识别. 北京:清华大学出版社,2000.

[3] 傅京孙. 模式识别及其应用. 北京:科学出版社,1983.

[4] 王梓坤. 概率论基础及其应用. 北京:科学出版社,1979.

[5] 戴遗山,汪浩. 概率论,哈尔滨:哈尔滨军事工程学院,1963.

[6] 周概容. 概率论与数理统计. 北京:高等教育出版社,1984.

[7] 王学仁,王松桂. 实用多元统计分析. 上海:上海科学技术出版社,1990.

[8] 蔡元龙. 模式识别. 西安:西安电子科技大学出版社,1992.

[9] 李金宗. 模式识别导论. 北京:高等教育出版社,1994.

[10] 温熙森,等. 模式识别与状态监控. 长沙:国防科技大学出版社,1997.

[11] 张尧庭、方开泰. 多元统计分析引论. 北京:科学出版社,1982.

[12] 孙文爽、陈兰祥. 多元统计分析. 北京:高等教育出版社,1994.

[13] 张建中,等. 线性规划. 北京:科学出版社,1999.

[14] 卢开澄. 图论及其应用. 北京:清华大学出版社,1981.

[15] 蔡宣三. 最优化与最优控制. 北京:清华大学出版社,1982.

[16] 魏国华,等. 线性规化. 北京:高等教育出版社,1989.

[17] [美]陈季镐. 统计模式识别. 北京:北京邮电学院出版社,1989.

[18] [美]黎子良. 统计推断与决策. 天津:南开大学出版社,1987.

[19] 陈希孺. 数理统计引论. 北京:科学出版社,1981.

[20] 瓦西里耶夫 B И. 机器识别方法与系统. 边肇祺,等译. 北京:科学出版社,1991.

[21] 成平,等. 参数估计. 上海:上海科学技术,1985.

[22] 狄昂照. 随机逼近. 北京:科学出版社,1994.

[23] 孙即祥,等. 模式识别中的特征提取与计算机视觉不变量. 北京:国防工业出版社,2001.

[24] 黄琳. 系统与控制理论中的线性代数. 北京:科学出版社,1990.

[25] 谢邦杰. 线性代数. 北京:人民教育出版社,1978.

[26] 中科院计算中心概率统计组. 概率统计计算,北京:科学出版社,1979.

[27] [日]福永圭之介,统计图形识别导论. 陶笃纯,译. 北京:科学出版社,1978.

[28] 罗承忠. 模糊集引论. 北京:北京师范大学出版社,1989.

[29] 李洪兴,汪培庄. 模糊数学. 北京:国防工业出版社,1996.

[30] 杨伦标,高英仪. 模糊数学原理及应用. 广州:华南理工大学出版社,1993.
[31] 郭桂蓉,庄钊文. 信息处理中的模糊技术. 长沙:国防科技大学出版社,1996.
[32] 刘普寅,吴孟达. 模糊理论及其应用. 长沙:国防科技大学出版社,1998.
[33] 李相镐. 模糊聚类分析及其应用. 贵阳:贵州科技出版社,1994.
[34] 刘有才,等. 模糊专家系统原理与设计. 北京:北京航空航天大学出版社,1995.
[35] 王兵山,张强,毛晓光. 离散数学. 长沙:国防科技大学出版社,1998.
[36] 张立明. 人工神经网络的模型及其应用. 上海:复旦大学出版社,1993.
[37] 杨行峻,郑君里. 人工神经网络. 北京:高等教育出版社,1992.
[38] [美]包约翰. 自适应模式识别与神经网络. 北京:科学出版社,1992.
[39] 袁曾任. 人工神经网络原理及其应用. 北京:清华大学出版社,1999.
[40] 周继成,等. 人工神经网络——第六代计算机的实现. 北京:科学普及出版社,1993.
[41] 王永骥,涂健. 神经元网络控制. 北京:机械工业出版社,1998.
[42] [美]冈察雷斯 RC,汤姆逊 MG. 句法模式识别. 北京:清华大学出版社,1984.
[43] [美]Michael Sipser. 计算理论导引. 张立昂,王捍贫,黄雄,译,北京:机械工业出版社,2000.
[44] 李介谷,蔡国廉,等. 计算机模式识别技术. 上海:上海交通大学出版社,1986.
[45] 徐扬,乔全喜. 不确定性推理. 成都:西南交通大学出版社,1994.
[46] Duda. RO, Hart P E, Stork D G. Pattern Classification John Wiley & Sons, Inc, 2001.
[47] Everitt B S, Landau S Leese M. Cluster Analysis. 4th ed., Arnold, London, 2001.
[48] Gordon A D. Classification, 2nd edn., Chapman & Hall/CRC, Boca Raton, FL, 1999.
[49] Jain A K, Dubes R C. Algorithms for Clustering Data. Prentice Hall, London, 1988.
[50] Geoffery J Mclachlan. Discriminant Analysis and Statistical Pattern Recognition. John wiley & sons, Inc, 1992.
[51] Andrew R Webb. Statistical Pattern Recognition. John Wiley & Sons, Inc 2002.
[52] Sklansky J, Wassel G N. Pattern classifiers and trainable machine. New York: Springer-Verlag, 1981.
[53] Devijver P A, Kittler J. Pattern Recognition, A Statistical Approach. London: Prentice Hall, 1982.

内 容 简 介

本书系统地论述了各类经典的模式识别的理论与方法，同时还较全面地反映了本学科的新近科技成果。本书讨论的主流模式识别技术是：统计模式识别、模糊模式识别、神经网络技术、句法模式识别、信息融合及树分类器方法。全书共7章。第1章为引论，第2章至第6章介绍的统计模式识别，包括：聚类分析、最近邻法、判别域代数界面方程法、统计判决、学习与错误率估计、特征提取与选择，第7章对模糊模式识别方法、神经网络技术、句法模式识别、信息融合及树分类器的基础知识进行了介绍。

本书可供电子科学与技术、信息与通信工程、控制科学与工程、计算机科学与技术及其他领域的有关专业和研究方向的本科高年级学生及硕士生作为信息分析、检测、识别的教材或教学参考书，也可供相关专业的科研人员参考。

Document generated by Anna’s Archive around 2023-2024 as part of the DuXiu collection (https://annas-blog.org/duxiu-exclusive.html).

Images have been losslessly embedded. Information about the original file can be found in PDF attachments. Some stats (more in the PDF attachments):

{
  "filename": "44CK5qih5byP6K+G5Yir44CLXzEyMzkyMzI1LnppcA==",
  "filename_decoded": "\u300a\u6a21\u5f0f\u8bc6\u522b\u300b_12392325.zip",
  "filesize": 16816354,
  "md5": "8d519d9f3cd5142f7826b1534e206f7a",
  "header_md5": "a1a2a8679c5fc94df2b44ad4aee97078",
  "sha1": "9059e1b37f5f66942925ebadeb8e09fc580b6500",
  "sha256": "2b7ea0db36c2fd5db3ea834bd61c3d9dc76b06b99b93fa11489f0a9acbaaaeca",
  "crc32": 3582843427,
  "zip_password": "12345678",
  "uncompressed_size": 17287728,
  "pdg_dir_name": "\u00ed\u2562\u2500\u00fa\u2569\u255c\u2569\u2562\u2592\u2261\u00ed\u2556_12392325",
  "pdg_main_pages_found": 280,
  "pdg_main_pages_max": 280,
  "total_pages": 292,
  "total_pixels": 1147705248,
  "pdf_generation_missing_pages": false
}