§2 三角分解法 /* Matrix Factorization */

➢ 高斯消元法的矩阵形式 /* Matrix Form of G.E. */：

Step 1: $m_{i1} = a_{i1} / a_{11} \quad (a_{11} \neq 0)$

记 $L_1 = \begin{pmatrix} 1 & & & \\ -m_{21} & 1 & & \\ \vdots & & \ddots & \\ -m_{n1} & & & 1 \end{pmatrix}$，则 $L_1[\,A^{(1)} \;\; \vec{b}^{(1)}] = \begin{pmatrix} a_{11}^{(1)} & \cdots & a_{1n}^{(1)} & b_1^{(1)} \\ & & A^{(2)} & \vec{b}^{(2)} \end{pmatrix}$

Step $n-1$:

$$L_{n-1}L_{n-2}\cdots L_1\left[A\;\vec{b}\right] = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} & b_1^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} & b_2^{(2)} \\ & & \cdots & \vdots & \vdots \\ & & & a_{nn}^{(n)} & b_n^{(n)} \end{bmatrix}$$

其中 $L_k = \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -m_{k+1,k} & \ddots & \\ & & \vdots & & \\ & & -m_{n,k} & & 1 \end{pmatrix}$

$$L_k^{-1} = \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & m_{k+1,k} & \ddots & \\ & & \vdots & & \\ & & m_{n,k} & & 1 \end{pmatrix}$$

$$L_1^{-1} L_2^{-1} \cdots L_{n-1}^{-1} = \begin{pmatrix} 1 & & & \\ & 1 & & \\ & & \ddots & \\ m_{i,j} & & & 1 \end{pmatrix} \xlongequal{\text{记为}} L$$

单位下三角阵
/* unitary lower-triangular matrix */

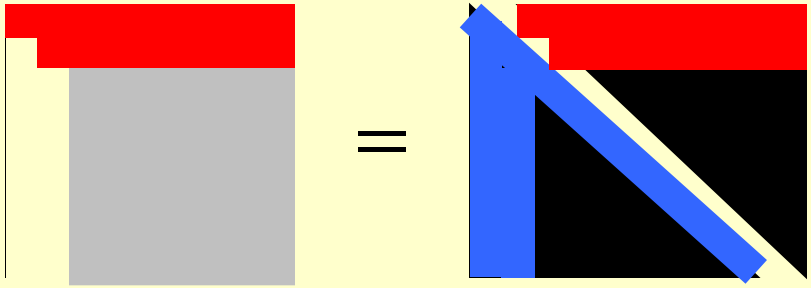
记 $U = \begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} \\ & & \cdots & \vdots \\ & & & a_{nn}^{(n)} \end{pmatrix}$

$$\Rightarrow \quad A = LU$$

A 的 LU 分解
/* LU factorization */

杜利特分解法 /* Doolittle Factorization */:

—— *LU* 分解的紧凑格式 /* compact form */





思路 通过比较法直接导出 L 和 U 的计算公式。

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & & \vdots \\ \vdots & & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} 1 & & \\ l_{21} & 1 & \\ \vdots & \cdots & \\ l_{n1} & \cdots & 1 \end{bmatrix} \begin{bmatrix} u_{11} & \cdots & u_{1n} \\ & \cdots & \vdots \\ & & \vdots \\ & & u_{nn} \end{bmatrix}$$

$$\Rightarrow \quad a_{ij} = \sum_{k=1}^{\min(i,j)} l_{ik} u_{kj}$$

$$a_{ij} = \sum_{k=1}^{\min(i,j)} l_{ik} u_{kj}$$

固定 i：

对 $j = i, i+1, \ldots, n$ 有 $a_{ij} = \sum_{k=1}^{i-1} l_{ik} u_{kj} + u_{ij}$

$l_{ii} = 1$

$$\Rightarrow \quad u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj} \qquad (a)$$



将 i，j 对换，对 $j = i, i+1, \ldots, n$

$$\Rightarrow \quad l_{ji} = (a_{ji} - \sum_{k=1}^{i-1} l_{jk} u_{ki}) / u_{ii} \qquad (b)$$

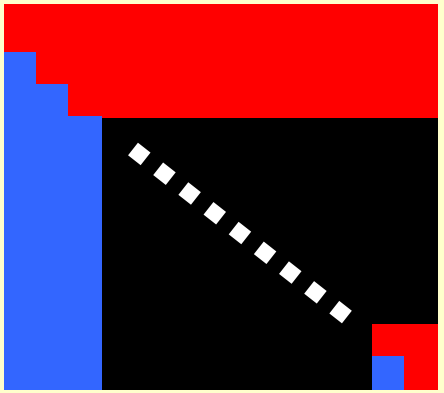
一般采用列主元法增强稳定性。但注意 $\vec{b}$ 也必须做相应的行交换。

Algorithm: Doolittle Factorization

Step 1: $u_{1j} = a_{1j}$; $l_{j1} = a_{j1} / u_{11}$; ($j = 1, \ldots, n$)

Step 2: compute (a) and (b) for $i = 2, \ldots, n-1$;

Step 3: $u_{nn} = a_{nn} - \sum_{k=1}^{n-1} l_{nk} u_{kn}$



求解Ly=b,Ux=y的计算公式

$$\begin{cases} y_1 = b \\ y_i = b_i - \sum_{k=1}^{i-1} l_{ik} y_k \end{cases} \qquad \text{i=2,3,…,n}$$

$$\begin{cases} x_n = y_n / u_{nn} \\ x_i = (y_i - \sum_{k=i+1}^{n} u_{ik} x_k) / u_{ii} \end{cases} \qquad \text{i=n-1,n-2,…,1}$$

$$\begin{bmatrix} 1 & 2 & 3 \\ 2 & 5 & 2 \\ 3 & 1 & 5 \end{bmatrix} \begin{bmatrix} x1 \\ x2 \\ x3 \end{bmatrix} = \begin{bmatrix} 14 \\ 18 \\ 20 \end{bmatrix}$$

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 3 & -5 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & -4 \\ 0 & 0 & -24 \end{bmatrix} = LU$$

$$Ly = [14 \quad 18 \quad 20]\text{^}t \qquad y = [14 \quad -10 \quad -72]$$

$$Ux = [14 \quad -10 \quad -72]\text{^}t \qquad x = [1 \quad 2 \quad 3]\text{^}t$$

■选主元的三角分解法

直接三角分解法的局限性：

当$u_{rr}=0$时计算中断

当u_{rr}绝对值很小时，引起舍入误差的累积。

设第r-1步分解已完成

$$A \rightarrow \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1,r-1} & u_{1r} & \cdots & u_{1n} \\ l_{21} & u_{22} & \cdots & u_{2,r-1} & u_{2r} & \cdots & u_{2n} \\ \vdots & \vdots & & \vdots & \vdots & & \vdots \\ & & & & & & \\ l_{r-1,1} & l_{r-1,2} & \cdots & u_{r-1,r-1} & u_{r-1,r} & \cdots & u_{r-1,n} \\ l_{r1} & l_{r2} & \cdots & l_{r,r-1} & a_{rr} & \cdots & a_{rn} \\ \vdots & \vdots & & \vdots & \vdots & & \vdots \\ l_{n1} & l_{n2} & \cdots & l_{n,r-1} & a_{nr} & \cdots & a_{nn} \end{bmatrix}$$

直接LU分解的第r步分解

$$u_{ri} = a_{ri} - \sum_{k=1}^{r-1} l_{ik} u_{ki} \qquad \text{i=r,r+1,…,n,且r≠n}$$

$$l_{ir} = (a_{ir} - \sum_{k=1}^{r-1} l_{ik} u_{kr}) / u_{rr} \qquad \text{i=r+1,…,n,且r≠n}$$

为避免u_{rr}过小

$$s_i = a_{ir} - \sum_{k=1}^{r-1} l_{ik} u_{kr} \qquad \text{(i=r,r+1,…,n)}$$

$$u_{rr} = s_r \qquad l_{ir} = s_i / s_r \qquad \text{(i=r+1,…,n)}$$

取 $\max\limits_{r \le i \le n} |s_i| = |s_{i_r}|$ **A的r行⇔A的i_r行**

$$s_{i_r} \to (r,r)$$

算法4（选主元的三角分解法）

$$PA = I_{n-1,i_{n-1}} \cdots I_{1,i_1} A = LU$$

Ip(n)记录主行

1.对于r=1,2,…,n

1) 计算s_i $a_{ir} \leftarrow s_i = a_{ir} - \sum_{k=1}^{r-1} l_{ik} u_{kr}$ (i=r,r+1,…,n)

2)选主元 $|s_{i_r}| = \max_{r \le i \le n} |s_i|$ Ip(r)←i_r

3)交换A的r行元素与i_r行元素 $a_{ri} \leftrightarrow a_{i_r,i}$

4)计算U的第r行元素，L的第r列元素

$a_{rr}=u_{rr}=s_r$

$a_{ir} \leftarrow l_{ir} = s_i / u_{rr} = a_{ir} / a_{rr}$ i=r+1,…,n,且r≠n

$a_{ri} \leftarrow u_{ir} = a_{ri} - \sum_{k=1}^{r-1} l_{rk} u_{ki}$ i=r+1,…,n,且r≠n

求解Ly=Pb及Ux=y

2.对于i=1,…,n-1

1)t←Ip(i)

2)若i=t则转3),否则 $b_i \leftrightarrow b_t$

3. $b_i \leftarrow b_i - \sum_{k=1}^{i-1} l_{ik} b_k$ (i=2,3,..,n)

4. $b_n \leftarrow b_n / u_{nn}, b_i \leftarrow (b_i - \sum_{k=i+1}^{n} u_{ik} b_k) / u_{ii}$ i=n-1,…,1

解x存放在b中

PA=LU ⟹ $A^{-1} = U^{-1} L^{-1} P$

1)计算上三角矩阵的逆阵U^{-1}

2)计算$U^{-1}L^{-1}$

3)交换$U^{-1}L^{-1}$的列

➢ 平方根法 /* Choleski's Method */：

——对称 /* symmetric */ 正定 /* positive definite */ 矩阵的分解法

定义 一个矩阵 $A=(a_{ij})_{n\times n}$ 称为对称阵，如果 $a_{ij}=a_{ji}$。

定义 一个矩阵 A 称为正定阵，如果 $\vec{x}^T A\vec{x}>0$ 对任意非零向量 $\vec{x}$ 都成立。

📖回顾：对称正定阵的几个重要性质

- A^{-1} 亦对称正定，且 $a_{ii}>0$
- A 的顺序主子阵 /* leading principal submatrices */ A_k 亦对称正定
- A 的特征值 /* eigen value */ $\lambda_i>0$
- A 的全部顺序主子式 $\det(A_k)>0$

对任意 $\vec{x}\neq\vec{0}$ $a_{ii}=\vec{x}^T A\vec{x}>0$其中 $(0\ldots1\ldots0)^T$

即

对称性显然，对任意 $\vec{x}_k\neq\vec{0}\in R^k$ 有

设对应特征值 的非零特征向量

$\lambda\|\vec{x}\|^2$。

因为 $\det(A)=\prod_{i=1}^{n}\lambda_i$

将对称 正定阵 A 做 LU 分解

$$U = \begin{pmatrix} u_{ij} \end{pmatrix} = \begin{pmatrix} u_{11} & & & \\ & u_{22} & & \\ & & \ddots & \\ & & & u_{nn} \end{pmatrix} \begin{pmatrix} 1 & u_{ij}/u_{ii} \\ & 1 & \\ & & \ddots \\ & & & 1 \end{pmatrix} \xrightarrow{\text{记为}} D\tilde{U}$$

A 对称 $\Rightarrow$ $L = \tilde{U}^T$ 即 $A = LDL^T$

定理10(对称阵的三角分解定理)

记 $D^{1/2} = \begin{pmatrix} \sqrt{u_{11}} & & & \\ & \sqrt{u_{22}} & & \\ & & \ddots & \\ & & & \sqrt{u_{nn}} \end{pmatrix}$

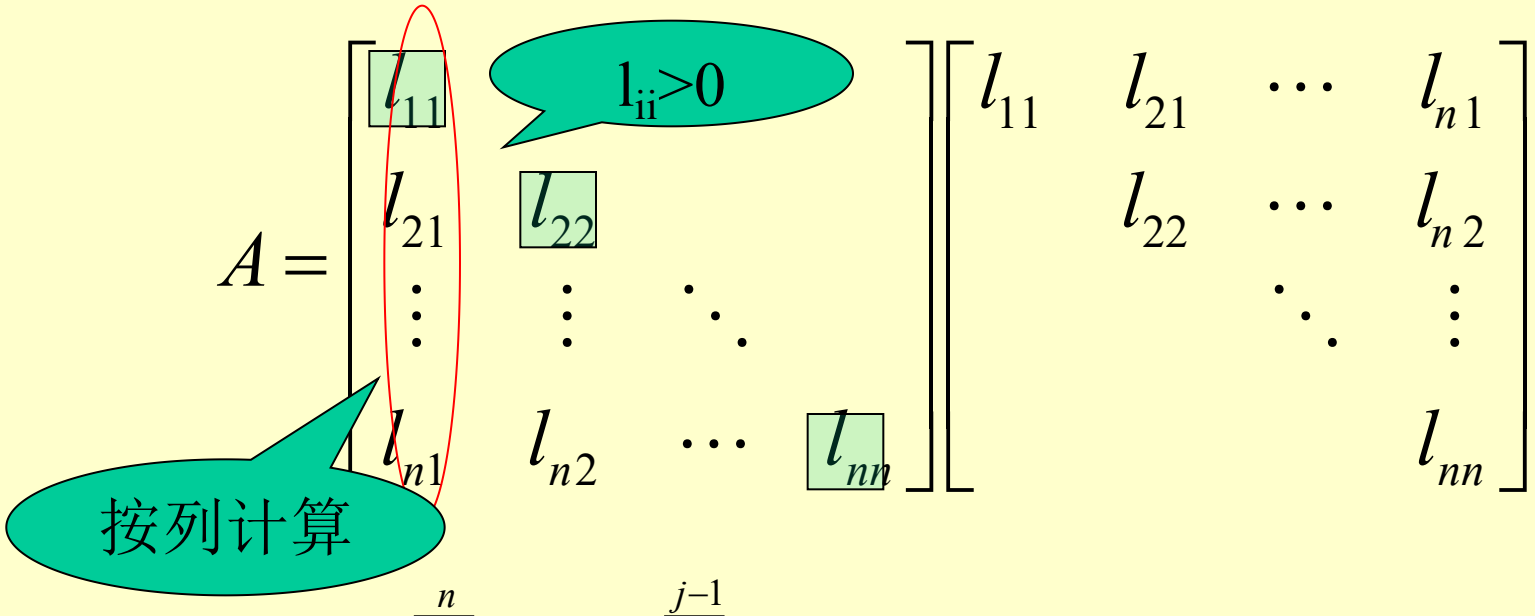
则 $\tilde{L} = LD^{1/2}$ 仍是下三角阵

$$A = \tilde{L}\tilde{L}^T$$

$\det(A_k) > 0 \Rightarrow u_{ii} > 0$

定理 设矩阵A对称正定，则存在非奇异下三角阵 $L \in R^{n\times n}$ 使得 $A = LL^T$。若限定 L 对角元为正，则分解唯一。

注： 对于对称正定阵 A，从 $a_{ii} = \sum_{k=1}^{i} l_{ik}^2$ 可知对任意 $k \le i$ 有 $|l_{ik}| \le \sqrt{a_{ii}}$。即 L 的元素不会增大，误差可控，不需选主元。



$$a_{ij}=\sum_{k=1}^{n} l_{ik}l_{jk}=\sum_{k=1}^{j-1} l_{ik}l_{jk}+l_{jj}l_{ij}$$

Algorithm: Choleski's Method

To factor the symmetric positive definite $n \times n$ matrix A into LL^T, where L is lower triangular.

Input: the dimension n; entries a_{ij} for $1 \le i, j \le n$ of A.

Output: the entries l_{ij} for $1 \le j \le i$ and $1 \le$ [illegible] $\le n$ of L.

Step 1 Set $l_{11} = \sqrt{a_{11}}$;

Step 2 For $j = 2, \ldots, n$, set [illegible]

Step 3 For [illegible]

因为A 对称，所以只需存半个 A，即

$$A\left[n(n+1)/2\right] = \left\{ a_{11}, a_{21}, a_{22}, \ldots, a_{n1}, \ldots, a_{nn} \right\}$$

其中 $A\left[i \times (i-1)/2 + j\right]$

Step [illegible]

Step 6 Set [illegible]

Step 7 O[illegible]

STOP.

运算量为 $O(n^3/6)$， 比普通LU 分解少一半，但有 n 次开方。用$A = LDL^T$ 分解，可省开方时间。

利用定理10，$A=LDL^T$,避免开方运算

$$A=\begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & \vdots & \ddots & \\ & & \cdots & 1 \end{bmatrix}\begin{bmatrix} d_1 & & & \\ & d_2 & & \\ & & \ddots & \\ & & & d_n \end{bmatrix}\begin{bmatrix} 1 & l_{21} & \cdots & l_{n1} \\ & 1 & \cdots & l_{n2} \\ & & \ddots & \vdots \\ & & & 1 \end{bmatrix}$$

按行计算

$$a_{ij}=\sum_{k=1}^{n}(LD)_{ik}(L^T)_{kj}=\sum_{k=1}^{n}l_{ik}d_k l_{jk}=\sum_{k=1}^{j-1}l_{ik}d_k l_{jk}+l_{ij}d_j l_{jj}$$

对于i=1,2,…,n

t_{ij}

$$l_{ij}=(a_{ij}-\sum_{k=1}^{j-1}l_{ik}d_k l_{jk})/d_j \qquad j=1,2,\ldots,i\text{-}1$$

$$d_i=a_{ii}-\sum_{k=1}^{i-1}l_{ik}^2 d_k$$

➢改进的平方根法

对于i=2,3,…,n

1 $t_{ij} = a_{ij} - \sum_{k=1}^{j-1} t_{ik} l_{jk}$ **j=1,2,…,i-1**

2 $l_{ij} = t_{ij} / d_j$

3 $d_i = a_{ii} - \sum_{k=1}^{i-1} t_{ik} l_{ik}$

求解Ly=b,DL^{T}x=y

4
$$\begin{cases} y_1 = b_1 \\ y_i = b_i - \sum_{k=1}^{i-1} l_{ik} y_k \quad (i = 2,...,n) \end{cases}$$

5
$$\begin{cases} x_n = y_n / d_n \\ x_i = y_i / d_i - \sum_{k=i+1}^{n} l_{ki} x_k \quad (i = n-1,...,2,1) \end{cases}$$

- $\begin{bmatrix}1 & 2 & 3\\ 2 & 6 & 10\\ 3 & 10 & 20\end{bmatrix}\begin{bmatrix}x_1\\ x_2\\ x_3\end{bmatrix}=\begin{bmatrix}4\\ 16\\ 37\end{bmatrix}$用改进的平方根法求解
- $\begin{bmatrix}1 & 2 & 3\\ 2 & 6 & 10\\ 3 & 10 & 20\end{bmatrix}=\begin{bmatrix}1 & & \\ 2 & 1 & \\ 3 & 2 & 1\end{bmatrix}\begin{bmatrix}1 & & \\ & 2 & \\ & & 3\end{bmatrix}\begin{bmatrix}1 & 2 & 3\\ & 1 & 2\\ & & 1\end{bmatrix}$
- $\begin{bmatrix}1 & & \\ 2 & 1 & \\ 3 & 2 & 1\end{bmatrix}\begin{bmatrix}y_1\\ y_2\\ y_3\end{bmatrix}=\begin{bmatrix}4\\ 16\\ 37\end{bmatrix}\quad\begin{bmatrix}y_1\\ y_2\\ y_3\end{bmatrix}=\begin{bmatrix}4\\ 8\\ 9\end{bmatrix}$
- $\begin{bmatrix}1 & & \\ & 2 & \\ & & 3\end{bmatrix}\begin{bmatrix}z_1\\ z_2\\ z_3\end{bmatrix}=\begin{bmatrix}4\\ 8\\ 9\end{bmatrix}\quad\begin{bmatrix}z_1\\ z_2\\ z_3\end{bmatrix}=\begin{bmatrix}4\\ 4\\ 3\end{bmatrix}$

- $\begin{bmatrix} 1 & 2 & 3 \\ & 1 & 2 \\ & & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 4 \\ 3 \end{bmatrix} \quad \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 4 \\ 3 \end{bmatrix}$

- $\begin{bmatrix}1 & 2 & 3\\2 & 6 & 10\\3 & 10 & 20\end{bmatrix}\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix}=\begin{bmatrix}4\\16\\37\end{bmatrix}$用平方根法求解

- $\begin{bmatrix}1 & 2 & 3\\2 & 6 & 10\\3 & 10 & 20\end{bmatrix}=\begin{bmatrix}1 & & \\2 & \sqrt{2} & \\3 & 2\sqrt{2} & \sqrt{3}\end{bmatrix}\begin{bmatrix}1 & 2 & 3\\ & \sqrt{2} & 2\sqrt{2}\\ & & \sqrt{3}\end{bmatrix}$

➢ 追赶法解三对角方程组

/* Crout Reduction for Tridiagonal Linear System */

$$\begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \end{bmatrix} = \begin{bmatrix} f_1 \\ f_2 \\ \vdots \end{bmatrix}$$

$$|b_1| > |c_1| > 0$$

$$|b_i| \geq |a_i| + |c_i|, a_i, c_i \neq 0$$

$$|b_n| > |a_n| > 0$$

与G.E.类似，一旦 $\alpha_i = 0$ 则算法中断，故并非任何三对角阵都可以用此方法分解。

Step 1: 对 A 作C

$$A = \begin{bmatrix} \alpha_1 & & & \\ \gamma_2 & \ddots & & \\ & \ddots & & \\ & & \gamma_n & \alpha_n \end{bmatrix} \begin{bmatrix} 1 & & & \\ & \ddots & & \\ & & \ddots & \beta_{n-1} \\ & & & 1 \end{bmatrix}$$

直接比较等式两边的元素，可得到计算公式。

$$\begin{cases} b_1 = a_1, c_1 = \alpha_1 \beta_1 \\ a_i = r_i, b_i = r_i \beta_{i-1} + \alpha_i \quad (i=2,3,\ldots,n) \\ c_i = \alpha_i \beta_i \quad (i=2,3,\ldots,n-1) \end{cases} \Rightarrow \begin{cases} \alpha_i = b_i - a_i \beta_{i-1} \\ \beta_i = c_i / \alpha_i \end{cases}$$

Step 2: 追——即解 $L\vec{y}=\vec{f}$：$y_1=\dfrac{f_1}{\alpha_1}$，$y_i=\dfrac{(f_i-r_i y_{i-1})}{\alpha_i}$　$(i=2,\ldots,n)$

Step 3: 赶——即解 $U\vec{x}=\vec{y}$：$x_n=y_n$，$x_i=y_i-\beta_i x_{i+1}$　$(i=n-1,\ldots,1)$

定理 若 A 为对角占优 /* diagonally dominant */ 的三对角阵，且满足 $|b_1|>|c_1|>0$，$|b_n|>|a_n|>0$，$a_i\neq 0$，$c_i\neq 0$，则追赶法可解以 A 为系数矩阵的方程组。

证明：由 $\alpha_1=b_1\neq 0$，$|b_1|>|c_1|>0$，$\beta_1=c_1/b_1$ ⇒ $0<|\beta_1|<1$

用归纳法证明 $|\alpha_i|>|c_i|\neq 0$　i=1,2,…,n-1　$0<|\beta_1|<1$　从而可求出ß

i=1时，显然成立。假设对i成立。

由归纳法假设，$0 < |\beta_{i-1}| < 1$

$$|\alpha_i| = |b_i - a_i\beta_{i-1}| \geq |b_i| - |a_i\beta_{i-1}| > |b_i| - |a_i| \geq |c_i| \neq 0$$

$$\beta_i = c_i / \alpha_i \longrightarrow 0 < |\beta_i| < 1 \ldots$$

命题得证 ∎

注：

- 如果 A 是严格对角占优阵，则不要求三对角线上的所有元素非零。
- 根据不等式 $|\beta_i| < 1$，$|b_i| - |a_i| < |b_i - \gamma_i\beta_{i-1}| < |b_i| + |a_i|$ 可知：分解过程中，矩阵元素不会过分增大，算法保证稳定。
- 运算量为 $O(6n)$。

§5.5 向量和矩阵范数 /* Norms of Vectors and Matrices */

—— 为了误差的度量

定义1: $x,y \in R_n$, 将 $(x,y) = y^T x = \sum_{i=1}^{n} x_i y_i$

称为向量x,y的数量积。

将 $\|x\|_2 = (x,x)^{\frac{1}{2}} = (\sum_{i=1}^{n} x_i^2)^{\frac{1}{2}}$ 称为向量x的欧氏范数

定理13 设$x,y \in R^n$，则

(x,x)=0 $\Longleftrightarrow$ x=0

(ax,y)=a(x,y)

(x,y)=(y,x)

$(x_1+x_2,y)=(x_1,y)+(x_2,y)$

Cauchy-Schwarz 不等式

$$|(x,y)| \le \|x\|_2 \|y\|_2$$

$$\|x+y\|_2 \le \|x\|_2 + \|y\|_2$$

三角不等式

➢ 向量范数 /* vector norms */

定义 R^n空间的向量范数 $\|\cdot\|$ 对任意 $\vec{x},\vec{y}\in R^n$ 满足下列条件：

(1) $\|\vec{x}\|\geq 0$；$\|\vec{x}\|=0 \Leftrightarrow \vec{x}=\vec{0}$ （正定性 /* positive definite */ ）

(2) $\|\alpha\vec{x}\|=|\alpha|\cdot\|\vec{x}\|$ 对任意$\alpha\in C$ (齐次性 /* homogeneous */)

(3) $\|\vec{x}+\vec{y}\|\leq\|\vec{x}\|+\|\vec{y}\|$ （三角不等式 /* triangle inequality */)

$$|\|x\|-\|y\||\leq\|x-y\|$$

常用向量范数：

$$\|\vec{x}\|_1=\sum_{i=1}^{n}|x_i|$$

$$\|\vec{x}\|_2=\sqrt{\sum_{i=1}^{n}|x_i|^2}$$

$$\|\vec{x}\|_p=\left(\sum_{i=1}^{n}|x_i|^p\right)^{1/p}$$

$$\|\vec{x}\|_\infty=\max_{1\leq i\leq n}|x_i|$$

注：$\lim\limits_{p\to\infty}\|\vec{x}\|_p=\|\vec{x}\|_\infty$

定义 向量序列 $\{\vec{x}^{(k)}\}$收敛于向量 $\vec{x}^*$是指对每一个 $1 \le i \le n$ 都有 $\lim\limits_{k\to\infty} x_i^{(k)} = x_i^*$。 可以理解为 $\|\vec{x}^{(k)} - \vec{x}^*\|_\infty \to 0$

定理14 (N(x)的连续性) 设非负函数N(x)=||x||为R^n上任一向量范数，则N(x)是x的分量$x_1,x_2,\ldots,x_n$的连续函数。 证明见P199

定理15 R^n 上一切范数都等价。

可以理解为对任何向量范数都成立。

证明：只要证明

$$c_1\|x\|_\infty \le \|x\|_t \le c_2\|x\|_\infty$$

考虑函数 $\|x\|_t$ $x \in R^n$

有界闭集

记 $S = \{x \mid \|x\|_\infty = 1, x \in R^n\}$

若能证明向量序列在一种范数意义下向量序列收敛，则在任何一种范数意义下该向量序列均收敛。

由于f(x)是S上的连续函数，所以f(x)在S上有最大最小值，即

$$f(x') = \min_{x\in S} f(x) = c_1 \qquad f(x'') = \max_{x\in S} f(x) = c_2$$

设$x \in R^n$且$x \neq 0$, 则 $\dfrac{x}{\|x\|_\infty} \in S$

定理15不能推广到无穷维空间

$$c_1 \le f\left(\frac{x}{\|x\|_\infty}\right) \le c_2 \Rightarrow c_1 \le \left\|\frac{x}{\|x\|_\infty}\right\|_t \le c_2$$

$$\Rightarrow c_1\|x\|_\infty \le \|x\|_t \le c_2\|x\|_\infty$$

定理16

$$\lim_{k\to\infty} x^{(k)} = x^* \Longleftrightarrow \lim_{k\to\infty} \left\| x^{(k)} - x^* \right\| = 0$$

证明:显然 $\lim_{k\to\infty} x^{(k)} = x^* \Longrightarrow \lim_{k\to\infty} \left\| x^{(k)} - x^* \right\| = 0$

对于R^n上的任何一种范数$\|\ \|$,由定理15，存在常数$c_1, c_2 > 0$

$$c_1 \left\| x^{(k)} - x^* \right\|_\infty \le \left\| x^{(k)} - x^* \right\| \le c_2 \left\| x^{(k)} - x^* \right\|_\infty$$

$$\lim_{k\to\infty} \left\| x^{(k)} - x^* \right\|_\infty = 0 \Longrightarrow \lim_{k\to\infty} x^{(k)} = x^*$$

➢ 矩阵范数 /* matrix norms */

定义 $R^{m\times n}$空间的矩阵范数 $\|\cdot\|$ 对任意$A, B \in R^{m\times n}$ 满足：

(1) $\|A\|\geq 0$； $\|A\|=0 \Leftrightarrow A=0$ （正定性 /* positive definite */)

(2) $\|\alpha A\|=|\alpha|\cdot\|A\|$ 对任意$\alpha\in C$ (齐次性 /* homogeneous */)

(3) $\|A+B\|\leq\|A\|+\|B\|$ （三角不等式 /* triangle inequality */)

(4)* $\|AB\|\leq\|A\|\cdot\|B\|$ （相容 /* consistent */ 当 $m=n$ 时)

常用矩阵范数：

Frobenius 范数 $\| A \|_F = \sqrt{\sum_{i=1}^{n}\sum_{j=1}^{n} | a_{ij} |^2}$ — 向量$\| \cdot \|_2$的直接推广

对方阵$A \in R^{n\times n}$ 以及 $\vec{x} \in R^n$有 $\| A\vec{x} \|_2 \le \| A \|_F \cdot \| \vec{x} \|_2$

算子范数 /* operator norm */

由向量范数 $\| \cdot \|_p$ 导出关于矩阵 $A \in R^{n\times n}$ 的 p 范数：

$$\| A \|_p = \max_{\vec{x}\neq\vec{0}} \frac{\| A\vec{x} \|_p}{\| \vec{x} \|_p} = \max_{\| \vec{x} \|_p = 1} \| A\vec{x} \|_p$$

利用 Cauchy 不等式 $| \vec{x} \cdot \vec{y} | \le \| \vec{x} \|_2 \| \vec{y} \|_2$ 可证。

则 $\| AB \|_p \le \| A \|_p \| B \|_p$

$\| A\vec{x} \|_p \le \| A \|_p \| \vec{x} \|_p$

矩阵 A^TA 的最大特征根 /* eigenvalue */

特别有：

$\| A \|_\infty = \max_{1\le i\le n} \sum_{j=1}^{n} | a_{ij} |$ （行和范数）

$\| A \|_1 = \max_{1\le j\le n} \sum_{i=1}^{n} | a_{ij} |$ （列和范数）

$\| A \|_2 = \sqrt{\lambda_{\max}(A^TA)}$ （谱范数 /* spectral norm */ ）

定理17 设$\|x\|_v$是R^n上一个向量范数，则$\|A\|_v$是$R^{n\times n}$上的矩阵范数，且满足相容条件

$$\|Ax\|_v \le \|A\|_v \|x\|_v$$

证明：$\|A\|_v = \max_{x\neq 0} \dfrac{\|Ax\|_v}{\|x\|_v}$ $\Rightarrow$ $\|A\|_v = \max_{x\neq 0} \dfrac{\|Ax\|_v}{\|x\|_v} \ge \dfrac{\|Ax\|_v}{\|x\|_v}$

$\Downarrow$

$$\|Ax\|_v \le \|A\|_v \|x\|_v$$

容易证明，由向量范数诱导的矩阵范数符合定义1),2),3),下面证明4)

$$\|ABx\|_v \le \|A\|_v \|Bx\|_v \le \|A\|_v \|B\|_v \|x\|_v$$

当x≠0时，有

$$\frac{\|ABx\|_v}{\|x\|_v} \le \|A\|_v \|B\|_v$$

$$\|AB\|_v = \max_{x\neq 0} \frac{\|ABx\|_v}{\|x\|_v} \le \|A\|_v \|B\|_v$$

证明 **1)** $\|A\|_\infty = \max\limits_{1\le i\le n}\sum\limits_{j=1}^{n}|a_{ij}|$

设x=$(x_1,x_2,\ldots,x_n)^T$≠0,A≠0.

$$t=\|x\|_\infty=\max_{1\le i\le n}|x_i| \qquad \mu=\max_{1\le i\le n}\sum_{j=1}^{n}|a_{ij}|$$

$$\|Ax\|_\infty=\max_{1\le i\le n}|\sum_{j=1}^{n}a_{ij}x_j|\le\max_{i}\sum_{j=1}^{n}|a_{ij}||x_j|\le t\max_{i}\sum_{i=1}^{n}|a_{ij}|$$

$$\frac{\|Ax\|_\infty}{\|x\|_\infty}\le\mu$$

下面说明存在向量x_0≠0,使 $\dfrac{\|Ax\|_\infty}{\|x\|_\infty}=\mu$

设 $\mu=\sum\limits_{j=1}^{n}|a_{i_0j}|$ **取向量$x_0=(x_1,x_2,\ldots,x_n)^T$,其中**

$$x_j=\mathrm{sgn}(a_{i_0j}),(j=1,2,\ldots,n)$$

显然 $\|x_0\|_\infty = 1$ $\mathbf{Ax_0}$的第$\mathbf{i_0}$个分量为

$$\sum_{i=1}^{n} a_{i_0 j} x_j = \sum_{j=1}^{n} |a_{i_0 j}|$$

$$\|Ax_0\|_\infty = \max_{1\le i\le n} |\sum_{j=1}^{n} a_{ij} x_j| = \sum_{j=1}^{n} |a_{i_0 j}| = \mu$$

2) $\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$

对称阵

$$\|Ax\|_2^2 = (Ax, Ax) = (A^T Ax, x) \ge 0$$

$$\lambda_1 \ge \lambda_2 \ge \cdots \ge \lambda_n$$

设$u_1, u_2, \ldots, u_n$为A^TA的相应于特征值的特征向量 $(u_i, u_j) = \delta_{ij}$

$$\forall x \in R^n \quad x = \sum_{i=1}^{n} c_i u_i$$

$$\frac{\|Ax\|_2^2}{\|x\|_2^2} = \frac{(A^T Ax, x)}{(x, x)} = \frac{\sum_{i=1}^{n} c_i^2 \lambda_i}{\sum_{i=1}^{n} c_i^2} \le \lambda_1$$

当$x=u_1$时，等号成立

$$\|A\|_2 = \max_{x\ne 0} \frac{\|Ax\|_2}{\|x\|_2} = \sqrt{\lambda_1} = \sqrt{\lambda_{\max}(A^T A)}$$

3) $\|A\|_1 = \max\limits_{1\le j\le n}\sum\limits_{i=1}^{n}|a_{ij}|$

记 $A=[a_1,a_2,\cdots,a_n]$ $a_j=[a_{1j},a_{2j},\cdots,a_{nj}]^T$

$$\max_{1\le j\le n}\sum_{i=1}^{n}|a_{ij}| = \max_{1\le j\le n}\|a_j\|_1$$

$$\forall x=[x_1,x_2,\cdots x_n]^T\in R^n$$

$$\|Ax\|_1 = \|x_1a_1+x_2a_2+\cdots+x_na_n\|_1 \le |x_1|\|a_1\|_1+\cdots+|x_n|\|a_n\|_1$$

$$\le (|x_1|+|x_2|+\cdots+|x_n|)\max_{1\le j\le n}\|a_j\|_1 = \|x\|_1\max_{1\le j\le n}\|a_j\|_1$$

$$\frac{\|Ax\|_1}{\|x\|_1}\le\max_{1\le j\le n}\|a_j\|_1$$

若 $\max\limits_{1\le j\le n}\|a_j\|_1=\|a_k\|_1$ 取x=e_k,能使等号成立, $\|e_k\|_1$=1,

$$\|Ae_k\|_1=\|a_k\|_1=\max_{1\le j\le n}\|a_j\|_1=\max_{1\le j\le n}\sum_{i=1}^{n}|a_{ij}|$$

注：☞ Frobenius 范数不是算子范数。

☞ 我们只关心有相容性的范数，算子范数总是相容的。

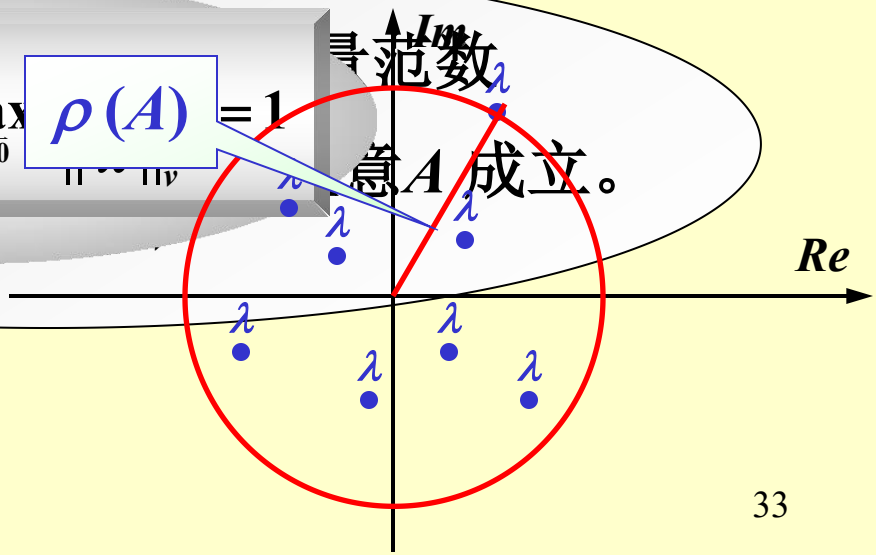
☞ 即使 A 中元素全为实数，其特征根和相应特征向量 /* eigenvector */ 仍可能为复数。将上述定义中绝对值换成复数模均成立。

$\sqrt{n} = \| I \|_F \neq \max_{\vec{x}\neq\vec{0}} \frac{\| I\vec{x} \|_v}{\| \vec{x} \|_v} = 1$

$\rho(A)$

➢ 谱半径 /* spectral radius */

定义 矩阵 A 的谱半径记为 $\rho(A) = \max_{1\le i\le n} |\lambda_i|$，其中 λ_i 为 A 的特征根。



定理 对任意算子范数 $\|\cdot\|$ 有 $\rho(A)\le\|A\|$

证明：由算子范数的相容性，得到 $\|A\bar{x}\|\le\|A\|\cdot\|\bar{x}\|$

将任意一个特征根 λ 所对应的特征向量 $\bar{u}$ 代入

$$|\lambda|\cdot\|\bar{u}\|=\|\lambda\bar{u}\|=\|A\bar{u}\|\le\|A\|\cdot\|\bar{u}\|$$

∎

定理 若A对称，则有 $\|A\|_2=\rho(A)$

证明：$\|A\|_2=\sqrt{\lambda_{\max}(A^TA)}=\sqrt{\lambda_{\max}(A^2)}$

若λ 是 A 的一个特征根，则λ^2 必是 A^2 的特征根。

$\Rightarrow\quad \lambda_{\max}(A^2)=\lambda^2(A)$ 某个 A 的特征根λ 成立

又：对称矩阵的特征[illegible]数，即 $\lambda^2(A)$ 为非负实数，

故得证。 ∎

A对称

所以2-范数亦称为谱范数。

定理 若矩阵 B 对某个算子范数满足 $\|B\| < 1$，则必有

① $I \pm B$ 可逆；　② $\left\|(I \pm B)^{-1}\right\| \le \dfrac{1}{1 - \|B\|}$

证明：① 若不然，则 $(I \pm B)\vec{x} = \vec{0}$ 有非零解，即存在非零向量 $\vec{x}_0$ 使得 $\pm B\vec{x}_0 = -\vec{x}_0$ $\Rightarrow$ $\dfrac{\|B\vec{x}_0\|}{\|\vec{x}_0\|} = 1$ $\Rightarrow$ $\|B\| \ge 1$ ✓

② $(I \pm B)^{-1} \pm B(I \pm B)^{-1} = (I \pm B)(I \pm B)^{-1} = I$

$\Rightarrow$ $(I \pm B)^{-1} = I \mp B(I \pm B)^{-1}$

$\Rightarrow$ $\|(I \pm B)^{-1}\| \le 1 + \|B\| \cdot \|(I \pm B)^{-1}\|$

∎

§5.6 线性方程组的误差分析

/* Error Analysis for Linear system of Equations */

求解 $A\vec{x}=\vec{b}$ 时，A 和 $\vec{b}$ 的误差对解 $\vec{x}$ 有何影响？

- 设 A 精确，$\vec{b}$ 有误差 $\delta\vec{b}$，得到的解为 $\vec{x}+\delta\vec{x}$，即

$$A(\vec{x}+\delta\vec{x})=\vec{b}+\delta\vec{b}$$

$$\Rightarrow \quad \delta\vec{x}=A^{-1}\delta\vec{b} \qquad \Rightarrow \quad \|\delta\vec{x}\|\le\|A^{-1}\|\,\|\delta\vec{b}\|$$

又 $\|\vec{b}\|=\|A\vec{x}\|\le\|A\|\cdot\|\vec{x}\| \quad \Rightarrow \quad \frac{1}{\|\vec{x}\|}\le\frac{\|A\|}{\|\vec{b}\|}$

绝对误差放大因子

相对误差放大因子

定理22

$$\frac{\|\delta\vec{x}\|}{\|\vec{x}\|}\le\|A\|\cdot\|A^{-1}\|\cdot\frac{\|\delta\vec{b}\|}{\|\vec{b}\|}$$

➢ 设 $\vec{b}$ 精确，$\|A\|\cdot\|A^{-1}\|$是关键 为$\vec{x}+\delta\vec{x}$，即



$\|A\|\cdot\|A^{-1}\|$的误差放大因子，称为A的条件数，记为$cond(A)$，越大 则 A 越病态，难得准确解。



$$A(\vec{x}+\delta\vec{x})+\delta A(x+\quad)=\vec{b} \qquad (A+\delta A)\vec{x}+(A+\delta A)\delta\vec{x}=\vec{b}$$

$$\Rightarrow\quad \delta\vec{x}=-A^{-1}\delta A(\quad+\delta\vec{x}) \qquad \Rightarrow\quad (A+\delta A)\delta\vec{x}=-\delta A\vec{x}$$

$$\Rightarrow\quad \frac{\|\delta\vec{x}\|}{\|\vec{x}+\delta\vec{x}\|}\le\|A^{-1}\|\cdot\|\delta A\|$$

$$\Rightarrow\quad A(I+A^{-1}\delta A)\delta\vec{x}=-\delta A\vec{x}$$

$$=\|A\|\cdot\|A^{-1}\|\cdot\frac{\|\delta A\|}{\|A\|} \qquad =\quad \delta\vec{x}=-(I+A^{-1}\delta A)^{-1}A^{-1}\delta A\vec{x}$$

定理23

(只要δA充分小，使得

$\|A^{-1}\delta A\|\le\|A^{-1}\|\cdot\|\delta A\|<1$)

$$\Rightarrow\frac{\|\delta\vec{x}\|}{\|\vec{x}\|}\le\frac{\|A^{-1}\|\cdot\|\delta A\|}{1-\|A^{-1}\|\cdot\|\delta A\|}=\frac{\|A\|\cdot\|A^{-1}\|\cdot\frac{\|\delta A\|}{\|A\|}}{1-\|A\|\cdot\|A^{-1}\|\cdot\frac{\|\delta A\|}{\|A\|}}$$

注: ☞ $cond\,(A)$ 的具体大小与 $\|\cdot\|$ 的取法有关，但相对大小一致。

☞ $cond\,(A)$ 取决于A，与解题方法无关。

☞ $$\frac{\|\delta\vec{x}\|}{\|\vec{x}\|} \le \frac{cond\ (A)}{1 - cond\ (A)\|\delta A\|/\|A\|}\left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta\vec{b}\|}{\|\vec{b}\|}\right)$$

常用条件数有：

$cond\,(A)_1$ $cond\,(A)_\infty$ $cond\,(A)_2$ $= \sqrt{\lambda_{\max}(A^TA)/\lambda_{\min}(A^TA)}$

特别地，若 A 对称，则 $cond\,(A)_2 = \dfrac{\max|\lambda|}{\min|\lambda|}$

条件数的性质：

- A可逆，则 $cond\,(A)_p \ge 1$;
- A可逆，$\alpha \in R$ 则 $cond\,(\alpha A) = cond\,(A)$;
- A正交，则 $cond\,(A)_2=1$;
- A可逆，R正交，则 $cond\,(RA)_2 = cond\,(AR)_2 = cond\,(A)_2$ 。

例： $A=\begin{pmatrix}1 & 0.99\\ 0.99 & 0.98\end{pmatrix}$, $\vec{b}=\begin{pmatrix}1.99\\ 1.97\end{pmatrix}$ 精确解为 $\vec{x}=\begin{pmatrix}1\\ 1\end{pmatrix}$.

$A^{-1}=\begin{pmatrix}-9800 & 9900\\ 9900 & -10000\end{pmatrix}$

计算$cond\,(A)_2$。

解：考察 A 的特征根

$\det(\lambda I-A)=0 \Rightarrow \lambda_1=1.980050504$

$\lambda_2=-0.000050504$

$$cond\,(A)_2=\left|\frac{\lambda_1}{\lambda_2}\right|\approx 39206 >> 1$$



测试病态程度：

给 $\vec{b}$ 一个扰动 $\delta\vec{b}=\begin{pmatrix}-0.97\times10^{-4}\\ 0.106\times10^{-3}\end{pmatrix}$，其相对误差为

$\dfrac{\|\delta\vec{b}\|_2}{\|\vec{b}\|_2}\approx 0.513\times10^{-4}<0.01\%$ 此时精确解为 $\vec{x}^*=\begin{pmatrix}3\\ -1.0203\end{pmatrix}$

$\delta\vec{x}=\vec{x}^*-\vec{x}=\begin{pmatrix}2\\ -2.0203\end{pmatrix}$ $\Rightarrow$ $\dfrac{\|\delta\vec{x}\|_2}{\|\vec{x}\|_2}\approx 2.0102>200\%$

例：Hilbert 阵 $H_n=\begin{bmatrix} 1 & \frac{1}{2} & \cdots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \iddots & \vdots \\ \vdots & \vdots & & \\ \frac{1}{n} & \frac{1}{n+1} & \cdots & \frac{1}{2n-1} \end{bmatrix}$

$cond\,(H_2)_\infty = 27$　　$cond\,(H_3)_\infty \approx 748$

$cond\,(H_6)_\infty = 2.9\times 10^6$　　$cond\,(H_n)_\infty \to \infty$ as $n \to \infty$

注：一般判断矩阵是否病态，并不计算A^{-1}，而由经验得出。

- ☞ 行列式很大或很小（如某些行、列近似相关）；
- ☞ 元素间相差大数量级，且无规则；
- ☞ 主元消去过程中出现小主元；
- ☞ 特征值相差大数量级。

对于病态方程组可采用高精度的算术运算或采用预处理方法，即

$$\begin{cases} PAQy = Pb \\ y = Q^{-1}x \end{cases}$$

选择非奇异阵P,Q使　cond(PAQ)<cond(

不能保证A的条件数得到改善

当矩阵A的元素大小不均时，对A的行（或列）引进适当的比例因子，对A的条件数

作为第一行的比例因子

例10　$\begin{bmatrix} 1 & 10^4 \\ 1 & 1 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 10^4 \\ 2 \end{bmatrix}$　计算$\mathrm{cond}(A)_\infty$　$\begin{bmatrix} 10^{-4} & 1 \\ 1 & 1 \end{bmatrix}\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$

A　　A’

$$A^{-1} = \frac{1}{10^4 - 1}\begin{bmatrix} -1 & 10^4 \\ 1 & -1 \end{bmatrix}$$

$$A'^{-1} = \frac{1}{1-10^{-4}}\begin{bmatrix} -1 & 1 \\ 1 & -10^{-4} \end{bmatrix}$$

$$cond(A)_\infty = \frac{(1+10^4)^2}{10^4 - 1} \approx 10^4$$

$$cond(A')_\infty = \frac{4}{1-10^{-4}} \approx 4$$

x=(0,1)　　x=(1,1)

➢ 近似解的误差估计

定理24（事后误差估计）

设 $A\vec{x}=\vec{b}$ 的近似解为 $\vec{x}^*$，则一般有 $\vec{r}=\vec{b}-A\vec{x}^*\neq\vec{0}$

$$\Rightarrow \quad \frac{\|\vec{x}-\vec{x}^*\|}{\|\vec{x}\|}\leq cond(A)\frac{\|\vec{r}\|}{\|\vec{b}\|}$$

误差上限

🛠 改善方法：

Step 1: $A\vec{x}=\vec{b}\Rightarrow$ 近似解 $\vec{x}_1$；

Step 2: $\vec{r}_1=\vec{b}-A\vec{x}_1$；

Step 3: $A\vec{d}_1=\vec{r}_1\Rightarrow \vec{d}_1$；

Step 4: $\vec{x}_2=\vec{x}_1+\vec{d}_1$；

若 $\vec{d}_1$ 可被精确解出，则有

$$\vec{x}_2=\vec{x}_1+A^{-1}(\vec{b}-A\vec{x}_1)=A^{-1}\vec{b}$$

$\vec{x}_2$ 就是精确解了。

经验表明：若 A 不是非常病态（例如：$\varepsilon\cdot cond(A)_\infty<1$），则如此迭代可达到机器精度；但若 A 病态，则此算法也不能改进。